

**ĐẠI HỌC QUỐC GIA TP. HCM
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH**



BÁO CÁO BÀI TẬP CÁ NHÂN

Môn: Học máy và ứng dụng

Building and Optimizing Deep Neural Networks

**Phân tích cảm xúc IMDB bằng BiLSTM, Attention và
Dropout**

Thực hiện

Đặng Nguyễn Tấn Tài

2570357

Lớp: CH01

Thành phố Hồ Chí Minh, 05/2026

Mục lục

1	Xác định đề bài và mục tiêu	1
2	Dữ liệu và tiền xử lý	1
3	Mô hình đề xuất	3
4	Huấn luyện và các thí nghiệm siêu tham số.	4
5	Đánh giá trên tập test	5
6	Phân tích định tính bằng Attention	7
7	Kết luận và hướng mở rộng	7

Danh sách hình vẽ

1	Luồng xử lý tổng quát của notebook.	1
2	Khảo sát dữ liệu đầu vào trước khi huấn luyện.	2
3	Các token xuất hiện nhiều nhất trong tập train.	3
4	Kiến trúc mô hình BiLSTM + Attention + Dropout.	3
5	Quá trình học và so sánh siêu tham số.	5
6	Phân tích dự đoán trên tập test.	6
7	Đánh giá mô hình theo nhiều ngưỡng phân loại.	6
8	Các token có attention weight cao nhất trong một review mẫu.	7

Danh sách bảng

1	Đối chiếu yêu cầu assignment và phần triển khai trong notebook.	1
2	Phân chia dữ liệu sau khi tách validation.	2
3	Thống kê độ dài sau tiền xử lý.	2
4	Các thành phần chính của mô hình.	4
5	Thiết lập huấn luyện chung cho các thí nghiệm.	4
6	Kết quả validation của 7 thí nghiệm, sắp xếp theo F1.	4
7	Diễn biến của thí nghiệm tốt nhất exp03_lr_2e3.	5
8	Kết quả đánh giá trên test set.	5

1 Xác định đề bài và mục tiêu

Theo quy tắc phân đề của assignment, MSSV 2570357 cho chữ số cuối là 7 và chữ số áp chót là 5. Do đó:

$$D = 7 \bmod 4 = 3, \quad A = 5 \bmod 3 = 2.$$


Bộ dữ liệu tương ứng là IMDB Reviews, còn kiến trúc bắt buộc thuộc nhóm LSTM kết hợp Dropout. Bài toán được triển khai trong notebook `SourceCode.ipynb` là phân loại sentiment nhị phân, trong đó đầu vào là một review phim tiếng Anh và đầu ra là nhãn *tiêu cực* hoặc *tích cực*.

Mục tiêu thực nghiệm. Notebook không chỉ huấn luyện một mô hình duy nhất, mà xây dựng pipeline đầy đủ từ tải dữ liệu, tokenization, padding, định nghĩa mô hình, huấn luyện 7 cấu hình siêu tham số, vẽ learning curves và đánh giá chi tiết trên test set.

Các yêu cầu chính của assignment được chuyển thành các quyết định triển khai cụ thể trong notebook. Cách tổ chức này giúp phần thực nghiệm bám sát đề bài, đồng thời tạo đủ bằng chứng để phân tích mô hình thay vì chỉ báo cáo một con số accuracy cuối cùng.

Bảng 1: Đối chiếu yêu cầu assignment và phần triển khai trong notebook.

Yêu cầu	Cách đáp ứng trong notebook
Bộ dữ liệu theo MSSV	Sử dụng IMDB Reviews vì $D = 7 \bmod 4 = 3$. Dữ liệu được tải từ <code>stanfordnlp/imdb</code> .
Mô hình theo MSSV	Sử dụng nhóm LSTM + Dropout vì $A = 5 \bmod 3 = 2$. Kiến trúc được mở rộng bằng BiLSTM và Attention để tăng khả năng biểu diễn chuỗi.
Thực nghiệm tối thiểu	Thực hiện 7 thí nghiệm thay vì chỉ 3 thí nghiệm, thay đổi learning rate, dropout, weight decay và độ dài chuỗi.
Đánh giá và báo cáo	Ghi lại history huấn luyện, bảng validation, confusion matrix, ROC, precision-recall và trực quan hóa attention.



Hình 1: Luồng xử lý tổng quát của notebook.

2 Dữ liệu và tiền xử lý


Bộ dữ liệu `stanfordnlp/imdb` được nạp bằng Hugging Face Datasets. Tập train gốc được chia thành 20,000 mẫu train và 5,000 mẫu validation; tập test chuẩn gồm 25,000 mẫu được giữ nguyên để đánh giá cuối cùng. Cả ba tập đều cân bằng giữa hai lớp, như thể hiện trong Bảng 2.

Việc tách validation từ tập train giúp lựa chọn siêu tham số mà không chạm vào test set. Test set chỉ được dùng sau khi đã chọn được cấu hình tốt nhất, nhờ đó kết quả cuối cùng phản ánh khả


năng tổng quát hóa tốt hơn. Vì dữ liệu cân bằng, accuracy có thể dùng như một chỉ số trực quan; tuy nhiên F1-score vẫn được ưu tiên khi chọn mô hình vì F1 kết hợp cả precision và recall, phù hợp hơn khi phân tích lỗi dự đoán theo từng lớp.

Bảng 2: Phân chia dữ liệu sau khi tách validation.

Tập dữ liệu	Tiêu cực	Tích cực	Tổng số mẫu
Train	10,000	10,000	20,000
Validation	2,500	2,500	5,000
Test	12,500	12,500	25,000



(a) Phân bố nhân



(b) Độ dài review

Hình 2: Khảo sát dữ liệu đầu vào trước khi huấn luyện.


Quá trình tiền xử lý gồm chuyển chữ thường, loại bỏ ký hiệu HTML xuống dòng, tách token bằng biểu thức chính quy, xây vocabulary từ tập train và mã hóa token thành chỉ số. Vocabulary được giới hạn ở 50,000 token, với hai token đặc biệt <PAD> và <UNK>. Độ dài cache tối đa là 420 token; từng thí nghiệm có thể sử dụng độ dài ngắn hơn thông qua DataLoader.

Notebook không loại bỏ stopwords. Quyết định này phù hợp với phân tích cảm xúc vì nhiều stopwords có vai trò ngữ nghĩa quan trọng trong câu, đặc biệt là các từ phủ định như not, no, never, hoặc các cụm như do not. Nếu loại bỏ cơ học các token này, mô hình có thể mất tín hiệu đảo chiều cảm xúc, ví dụ giữa “good” và “not good”. Thay vào đó, mô hình được để tự học trọng số của token thông qua Embedding, BiLSTM và Attention.

Các bước xử lý trung gian được tổ chức theo hướng có thể tái sử dụng: dữ liệu tải về, vocabulary, tensor đã mã hóa, kết quả huấn luyện và hình ảnh đánh giá được lưu thành các nhóm thư mục riêng. Cách làm này giúp notebook chạy lại ổn định hơn, đồng thời các kết quả phục vụ báo cáo có thể được truy xuất trực tiếp từ output đã sinh.

Bảng 3: Thống kê độ dài sau tiền xử lý.

Tập dữ liệu	Độ dài gốc TB	Độ dài sau xử lý TB	Tỷ lệ bị cắt
Train	234.23	210.78	12.20%
Validation	232.70	210.09	11.48%
Test	228.64	207.22	11.28%



Hình 3: Các token xuất hiện nhiều nhất trong tập train.


3 Mô hình đề xuất

Mô hình `SentimentBiLSTM` có 17,851,842 tham số. Kiến trúc gồm Embedding 300 chiều, BiLSTM hai lớp với hidden size 256, Attention pooling và classifier tuyến tính. Dropout được đặt sau embedding, trong LSTM và trước classifier nhằm giảm overfitting. Attention pooling giúp mô hình sử dụng toàn bộ chuỗi hidden states thay vì chỉ dựa vào trạng thái cuối.

Với một review đã được mã hóa thành chuỗi token ID, Embedding biến mỗi token thành vector liên tục. BiLSTM sau đó đọc chuỗi theo cả hai chiều trái-phải và phải-trái, nhờ đó biểu diễn tại một vị trí có thể chứa ngữ cảnh trước và sau token. Cơ chế Attention tính điểm quan trọng cho từng hidden state, chuẩn hóa bằng softmax và lấy tổng có trọng số:

$$\alpha_t = \frac{\exp(e_t)}{\sum_j \exp(e_j)}, \quad c = \sum_t \alpha_t h_t.$$

Vector ngữ cảnh c được đưa qua classifier để sinh một logit. Khi đánh giá, logit được chuyển thành xác suất bằng sigmoid; ngưỡng 0.5 được dùng để quyết định nhãn tiêu cực hoặc tích cực.



Hình 4: Kiến trúc mô hình BiLSTM + Attention + Dropout.

Bảng 4: Các thành phần chính của mô hình.

Thành phần	Vai trò
Embedding	Biến mỗi token ID thành vector 300 chiều.
BiLSTM	Học ngữ cảnh hai chiều của review, gồm 2 layers và hidden size 256.
Attention	Gán trọng số cho từng token để gom đặc trưng quan trọng của chuỗi.
Dropout	Giảm overfitting ở embedding, LSTM và classifier.
Classifier	Sinh một logit cho bài toán phân loại nhị phân.

4 Huấn luyện và các thí nghiệm siêu tham số

Notebook sử dụng `BCEWithLogitsLoss`, optimizer `AdamW`, mixed precision, gradient clipping, early stopping và scheduler giảm learning rate. Validation được chạy mỗi 2 epoch và ở epoch cuối, giúp giảm thời gian chờ nhưng vẫn đủ điểm dữ liệu để chọn mô hình. Batch size được giữ ở 512 cho cả 7 thí nghiệm để tận dụng GPU Tesla T4.

Hàm mất mát nhị phân được tính trực tiếp từ logit, ổn định số học hơn so với việc tự áp dụng sigmoid trước rồi mới tính binary cross entropy. Mixed precision giúp giảm bộ nhớ GPU và tăng tốc huấn luyện; gradient clipping được dùng để hạn chế exploding gradient, một rủi ro thường gặp với mô hình hồi tiếp như LSTM khi chuỗi đầu vào dài.

Bảng 5: Thiết lập huấn luyện chung cho các thí nghiệm.

Thành phần	Thiết lập
Thiết bị	GPU Tesla T4 trên Google Colab; notebook dừng nếu không có GPU.
Batch size	512 cho train, validation và test nhằm tăng tốc trên GPU.
Số epoch tối đa	20 epoch; early stopping dừng sớm nếu validation không cải thiện.
Tần suất validation	Mỗi 2 epoch, đồng thời kiểm tra ở epoch cuối của mỗi thí nghiệm.
Tiêu chí chọn mô hình	Validation F1-score, vì cân bằng giữa precision và recall.
Kết quả lưu lại	Bảng history, mô hình tốt nhất, biểu đồ learning curves và các hình đánh giá.


Bảng 6: Kết quả validation của 7 thí nghiệm, sắp xếp theo F1.

Thí nghiệm	LR	Dropout	MaxLen	Val Acc	Val F1
exp03_lr_2e3	0.0020	0.55	400	0.8936	0.8959
exp07_len_420	0.0008	0.50	420	0.8936	0.8930
exp06_len_320	0.0010	0.50	320	0.8916	0.8923
exp05_wd_3e4	0.0008	0.50	400	0.8850	0.8879
exp04_dropout_45	0.0010	0.45	400	0.8844	0.8873
exp02_lr_5e4	0.0005	0.55	400	0.8848	0.8863
exp01_base	0.0010	0.55	400	0.8700	0.8786


Bảng kết quả cho thấy learning rate là yếu tố ảnh hưởng rõ nhất. Learning rate 0.002 trong exp03_lr_2e3 giúp mô hình học nhanh và đạt F1 cao nhất, trong khi learning rate 0.0005 ở exp02_lr_5e4 ổn định hơn nhưng chậm hơn. Các thí nghiệm thay đổi độ dài chuỗi cũng cho thấy max length 320–420 đều có kết quả tốt, nghĩa là phần lớn tín hiệu cảm xúc quan trọng đã nằm trong đoạn đầu và đoạn giữa của review.

Bảng 7: Diễn biến của thí nghiệm tốt nhất exp03_lr_2e3.

Epoch	Train loss	Train acc	Val loss	Val acc	Val F1
2	0.3244	0.8662	0.2929	0.8780	0.8762
4	0.1600	0.9393	0.3248	0.8834	0.8770
6	0.0836	0.9693	0.4247	0.8852	0.8919
8	0.0300	0.9894	0.4926	0.8936	0.8959



(a) Learning curves của mô hình tốt nhất



(b) So sánh validation F1

Hình 5: Quá trình học và so sánh siêu tham số.

Thí nghiệm tốt nhất là exp03_lr_2e3, đạt validation F1 bằng 0.8959 tại epoch 8. Cấu hình này sử dụng learning rate 0.002, max length 400, dropout 0.55 và weight decay 0.0001. Kết quả cho thấy learning rate lớn hơn baseline giúp mô hình đạt F1 validation cao hơn, dù early stopping vẫn cần thiết để tránh overfitting ở các epoch sau.

5 Đánh giá trên tập test


Sau khi chọn mô hình tốt nhất bằng validation F1, trọng số tương ứng được nạp lại và đánh giá trên test set 25,000 mẫu. Kết quả tổng hợp được trình bày trong Bảng 8.

Bảng 8: Kết quả đánh giá trên test set.


Lớp / Metric	Precision	Recall	F1-score	Support
Tiêu cực	0.8505	0.8918	0.8707	12,500
Tích cực	0.8863	0.8432	0.8642	12,500
Accuracy		0.8675		25,000
Macro avg	0.8684	0.8675	0.8674	25,000
Weighted avg	0.8684	0.8675	0.8674	25,000

Mô hình đạt test accuracy 0.86752 và F1-score lớp tích cực 0.86422. Confusion matrix tương ứng là khoảng 11,148 review tiêu cực dự đoán đúng, 10,540 review tích cực dự đoán đúng, 1,352 tiêu cực bị dự đoán thành tích cực và 1,960 tích cực bị dự đoán thành tiêu cực.

Kết quả theo từng lớp cho thấy mô hình nhận diện review tiêu cực có recall cao hơn, trong khi lớp tích cực có precision cao hơn. Điều này nghĩa là khi mô hình dự đoán một review là tích cực thì dự đoán thường khá đáng tin cậy, nhưng vẫn còn bỏ sót một phần review tích cực và gán nhầm sang tiêu cực. Với bài toán sentiment analysis, dạng lỗi này thường xuất hiện ở các review có giọng văn mỉa mai, câu dài nhiều ý trái chiều, hoặc review có cả lời khen và lời chê trong cùng một đoạn.




(a) Confusion matrix




(b) Phân bố xác suất dự đoán

Hình 6: Phân tích dự đoán trên tập test.



(a) ROC curve



(b) Precision-Recall curve


Hình 7: Đánh giá mô hình theo nhiều ngưỡng phân loại.

ROC curve và precision-recall curve được đưa vào để quan sát mô hình dưới nhiều ngưỡng

phân loại khác nhau, không chỉ tại ngưỡng mặc định 0.5. Nếu ứng dụng ưu tiên tránh gán nhầm review tiêu cực thành tích cực, ngưỡng dự đoán tích cực có thể được tăng lên để cải thiện precision. Ngược lại, nếu mục tiêu là thu được càng nhiều review tích cực càng tốt, ngưỡng có thể giảm để tăng recall.

6 Phân tích định tính bằng Attention

Ngoài các chỉ số tổng hợp, notebook cũng trích một số mẫu dự đoán đúng/sai với độ tự tin cao và trực quan hóa attention. Một ví dụ tiêu biểu cho thấy các token có trọng số cao gồm *waste*, *terrible*, *don't*, *money*, *movie*. Đây là những từ/cụm từ có sắc thái tiêu cực rõ ràng, phù hợp với mục tiêu phân tích cảm xúc.



Hình 8: Các token có attention weight cao nhất trong một review mẫu.

Việc trực quan hóa attention giúp kiểm tra định tính xem mô hình có tập trung vào các tín hiệu ngôn ngữ hợp lý hay không. Tuy attention không phải bằng chứng giải thích tuyệt đối, nó vẫn cung cấp góc nhìn hữu ích để phân tích những trường hợp mô hình tự tin hoặc mắc lỗi.

Phân phân tích này có ý nghĩa bổ sung cho các chỉ số định lượng. Accuracy và F1 cho biết mô hình đúng sai ở mức tổng quát, còn attention cho thấy các token nào đang góp phần mạnh vào quyết định. Khi một dự đoán sai nhưng attention tập trung vào những từ cảm xúc đơn lẻ, có thể suy luận rằng mô hình chưa hiểu tốt quan hệ giữa các vế câu. Khi attention tập trung vào các cụm mang cảm xúc rõ ràng và dự đoán đúng, kết quả này củng cố độ tin cậy của pipeline tiền xử lý và biểu diễn chuỗi.

7 Kết luận và hướng mở rộng

Notebook đã hoàn thành đầy đủ pipeline cho bài toán IMDB sentiment classification: tải dữ liệu, khảo sát dữ liệu, tokenization, padding, định nghĩa mô hình LSTM + Dropout, huấn luyện nhiều cấu hình, trực quan hóa learning curves và đánh giá chi tiết bằng F1-score, confusion matrix, ROC và precision-recall curve. Mô hình tốt nhất là `exp03_lr_2e3`, đạt validation

F1 0.8959 và test accuracy 0.8675.

Kết quả cho thấy mô hình BiLSTM + Attention là một lựa chọn phù hợp với yêu cầu của đề bài: kiến trúc vẫn thuộc nhóm LSTM + Dropout, nhưng có thêm cơ chế attention để tăng khả năng tổng hợp thông tin từ review dài. Hạn chế chính là mô hình học embedding từ đầu nên cần nhiều dữ liệu và có thể chưa nắm tốt các sắc thái ngữ nghĩa phức tạp như mỉa mai, phủ định dài, hoặc các câu có nhiều quan điểm trái chiều. Ngoài ra, validation loss tăng trong khi F1 vẫn tăng ở một số epoch cho thấy mô hình bắt đầu overfit, vì vậy early stopping và dropout là cần thiết.

Một hướng mở rộng phù hợp là dùng pretrained word embeddings như GloVe hoặc fastText để khởi tạo lớp Embedding, giúp mô hình có kiến thức ngữ nghĩa tốt hơn ngay từ đầu. Một hướng mạnh hơn là Transformer/transfer learning, chẳng hạn BERT hoặc RoBERTa; tuy nhiên, mô hình chính trong báo cáo vẫn giữ LSTM + Dropout để đúng yêu cầu kiến trúc của assignment.