

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP

Môn: Học sâu và ứng dụng trong thị giác máy tính

**Phân loại ảnh bằng mạng tuyến tính,
CNN, Attention và mạng hồi tiếp**

E1 – E2 – E3 – A1

CO5085 – Học kỳ 261 (2026–2027)

Giảng viên: Lê Thành Sách, Nguyễn Quốc Minh

Thực hiện

Đặng Nguyễn Tấn Tài 2570357

Lớp: CH01

Thành phố Hồ Chí Minh, 10/2026

Tóm tắt

Báo cáo trình bày 34 lượt huấn luyện đầy đủ: bốn mô hình E1, tám cấu hình attention E2, tám cấu hình recurrent/baseline E3 và 14 cấu hình CNN/Transformer A1. E1–E3 cùng dùng Fashion-MNIST với 54.000 ảnh train, 6.000 validation và 10.000 test. A1 dùng GTSRB với 43 lớp, chia train/validation theo track biển báo và giữ tập test nguồn. Mỗi notebook độc lập, tự viết vòng lặp PyTorch và lưu kết quả trong output cell. Số liệu, learning curves, ma trận nhầm lẫn và ảnh lỗi được lấy từ các output đã lưu; sơ đồ TikZ mô tả kiến trúc trong code.

Trên Fashion-MNIST, CNN-B đạt test accuracy 91,97% với 94.186 tham số; MSA PyTorch với CNN-stem đạt 90,78%; GRU đọc theo hàng đạt 90,06%. Trên GTSRB, fine-tune toàn bộ pretrained ResNet-50 và DeiT-Small/16 đạt 98,37% và 98,92% ở seed 42. Trung bình ba seed tương ứng là $98,44 \pm 0,29\%$ và $98,95 \pm 0,33\%$. Các so sánh được diễn giải cùng chi phí huấn luyện, lỗi theo lớp và giới hạn dữ liệu.

Phạm vi thực nghiệm của bản báo cáo này là E1–E3 và A1. A2 có notebook và nguồn chương riêng trong project, chưa được đưa vào phần kết quả khi chưa có full run được kiểm chứng.

Mục lục

Tóm tắt	i
1 Bài toán và thiết kế thực nghiệm	1
1.1 Mục tiêu và đối chiếu đề bài	1
1.2 Dữ liệu dùng chung cho E1–E3	1
1.3 Môi trường, loop và quy tắc đánh giá	2
2 E1: Softmax, MLP và CNN	4
2.1 Mục tiêu và kiến trúc	4
2.2 Huấn luyện	5
2.3 Kết quả định lượng và chi phí	5
2.4 Learning curves và phân tích lỗi	6
2.5 Nhận xét và giới hạn	8
3 E2: Multi-head self-attention và tokenization	9
3.1 Mục tiêu và biểu diễn token	9
3.2 Kiến trúc encoder và MSA	9
3.3 Protocol và tám cấu hình	10
3.4 Kết quả và so sánh theo đề	11
3.5 Learning curves, attention và lỗi	13
4 E3: LSTM và GRU trên chuỗi ảnh	16
4.1 Biểu diễn ảnh thành chuỗi	16
4.2 Cell LSTM/GRU tự hiện thực	17
4.3 Baseline và training protocol	17
4.4 Kết quả, representation và chi phí	18
4.5 Learning curves và lỗi	20
5 A1: CNN và Transformer trên GTSRB	22
5.1 Dataset, EDA và split	22
5.2 DataLoader, augmentation và kiến trúc	23
5.3 Tám cấu hình và protocol huấn luyện	24
5.4 Kết quả chính: CNN vs Transformer và pretraining	25

5.5	Freeze, chi phí và đường cong	26
5.6	Augmentation và độ ổn định qua seed	28
5.7	Confusion matrix, lỗi và trùng ảnh	29
5.8	Kết luận A1 và giới hạn	30
6	Kết luận	31
6.1	AI hỗ trợ và trách nhiệm kiểm chứng	31
A	Kết quả chi tiết và tái lập	33
A.1	Audit huấn luyện E1–E3	33
A.2	Metric theo lớp và độ nhạy A1	34
A.3	Ma trận nhầm lẫn E2 và E3	36
A.4	Nguồn số liệu và hướng dẫn tái lập	44

Danh sách hình vẽ

1.1	Fashion-MNIST: một ảnh đại diện mỗi lớp và phân bố train/validation cân bằng.	2
2.1	Softmax classifier: không Conv, một FC; 7.850 tham số.	4
2.2	MLP: ba FC, hai tầng ẩn; 235.146 tham số.	4
2.3	CNN-A: hai Conv, hai MaxPool, hai FC; 421.642 tham số. Conv stride 1, padding 1, có bias.	4
2.4	CNN-B: ba Conv/BN/MaxPool, một FC; 94.186 tham số. Conv stride 1, padding 1, không bias. Kích thước sau pool thứ ba là 3×3 .	5
2.5	So sánh validation accuracy, số tham số và thời gian train+validation của E1.	6
2.6	Loss và accuracy của bốn model; nét đứt train, nét liền validation.	6
2.7	Confusion matrix test của Softmax và MLP: mỗi ô ghi số ảnh và tỷ lệ theo lớp thật.	7
2.8	Confusion matrix test của CNN-A và CNN-B, cùng thang 0–100%.	7
2.9	Ảnh dự đoán sai của E1; cùng cột là cùng lớp thật, mỗi hàng là một model.	8
3.1	Ba tokenizer E2; CNN-stem có hai Conv kernel 3, stride 1, padding 1, bias, ReLU và MaxPool 2 sau mỗi Conv. Rows không có Conv; patch lấy trực tiếp pixel.	9
3.2	Classifier E2: một FC embedding, hai encoder block và một FC head; không CLS token.	9
3.3	Một pre-norm encoder block: hai projection MSA và hai FC trong FFN, tổng bốn ánh xạ Linear/block. Đường ngoài là residual.	10
3.4	Tổng quan accuracy validation, capacity và chi phí E2.	11
3.5	So sánh manual/PyTorch cùng tokenizer: accuracy, params và giây/epoch.	12
3.6	Ablation H=2/4/8 trên manual CNN-stem, giữ D=64.	12
3.7	Loss theo epoch, nhóm theo tokenizer; train nét đứt, validation nét liền.	13
3.8	Accuracy theo epoch của các cấu hình E2.	13
3.9	Attention của manual CNN-stem H=4 trên hai ảnh validation cố định; trung bình head, block cuối, gộp 7 nhóm query/key, tổng mỗi hàng 100%.	14
3.10	Gallery lỗi của các model đại diện E2 chọn bằng validation.	15
4.1	Cùng một ảnh validation được chuyển thành rows, columns và patch: thứ tự quét cùng ma trận timestep–feature.	16
4.2	Classifier recurrent E3: không Conv, một recurrent layer unroll T lần và một FC head. Trạng thái khởi tạo 0, chỉ dùng hidden cuối.	16

4.3	LSTM cell: hai projection dùng chung ở mọi bước; không tạo thêm bộ tham số cho mỗi timestep.	17
4.4	GRU cell: hai projection cho ba nhóm gate, chỉ duy trì hidden state.	17
4.5	Accuracy, capacity và thời gian E3 trên cùng Fashion-MNIST.	19
4.6	LSTM vs GRU với cùng representation.	19
4.7	So sánh recurrent rows chọn bằng validation với MLP và CNN-B train trong E3.	20
4.8	Loss E3 theo representation; nét đứt train, nét liền validation.	20
4.9	Accuracy E3 theo representation.	20
4.10	Gallery lỗi recurrent và baseline E3; ma trận của mọi run nằm ở Phụ lục.	21
5.1	Phân bố 43 lớp trên các split và kích thước ảnh train gốc.	23
5.2	Một ảnh train đại diện cho mỗi lớp GTSRB; ID dùng để tra ma trận nhầm lẫn.	23
5.3	A1 ResNet-50: backbone thể hiện bằng một khối, chỉ thay một FC43 lớp. Head có 88.107 tham số; tổng 23.596.139.	24
5.4	A1 DeiT-Small/16: backbone gom khối, thể hiện token và kích thước FFN; head 16.555 tham số, tổng 21.682.219.	24
5.5	Accuracy validation/test, trainable params và giây/epoch của tám cấu hình chính.	26
5.6	Loss của hai family theo bốn regime; train nét đứt, validation nét liền.	27
5.7	Accuracy theo epoch A1; mỗi panel một family.	27
5.8	Augmentation và ba seed của full pretrained; đồ thị dựng từ bảng output, trực tung thu hẹp 97,5–100,6% để đọc chênh lệch; error bar là std mẫu.	29
5.9	Trích 10 lớp liên quan nhiều ảnh sai của mỗi full pretrained seed 42; mẫu số vẫn là toàn bộ lớp thật trong 43 lớp.	29
5.10	Các ảnh sai của hai full model seed 42; hàng trên ResNet, hàng dưới DeiT, ghi cả nhãn thật/dự đoán.	30
A.1	E2: confusion matrix test, cặp1; tên model ghi trên từng panel.	36
A.2	E2: confusion matrix test, cặp2; tên model ghi trên từng panel.	37
A.3	E2: confusion matrix test, cặp3; tên model ghi trên từng panel.	38
A.4	E2: confusion matrix test, cặp4; tên model ghi trên từng panel.	39
A.5	E3: confusion matrix test, cặp1; tên model ghi trên từng panel.	40
A.6	E3: confusion matrix test, cặp2; tên model ghi trên từng panel.	41
A.7	E3: confusion matrix test, cặp3; tên model ghi trên từng panel.	42
A.8	E3: confusion matrix test, cặp4; tên model ghi trên từng panel.	43

Danh sách bảng

1.1	Đối chiếu yêu cầu đề bài và bằng chứng thực nghiệm.	1
1.2	Split Fashion-MNIST, giống nhau trong E1–E3.	1
1.3	Audit các lần chạy tạo ra số liệu trong báo cáo.	3
2.1	Metric E1 tại checkpoint chọn bằng validation loss; F1 là macro-F1.	5
2.2	Capacity và chi phí E1; epoch/best ghi số epoch thực chạy và epoch checkpoint.	5
2.3	Cập nhậm nhiều nhất trong E1; mỗi lớp test có 1.000 ảnh.	7
3.1	Metric E2; mọi model đánh giá đủ 10.000 ảnh test, F1 là macro-F1.	11
3.2	Capacity và chi phí của tám cấu hình E2.	11
3.3	So sánh manual/PyTorch ở H=4, cùng weights khởi tạo.	12
3.4	Nhằm lẫn lớn nhất của ba tokenizer manual H=4.	14
4.1	Metric của sáu recurrent model và hai baseline E3, F1 là macro-F1.	18
4.2	Số tham số, epoch và chi phí E3.	18
4.3	Cập nhậm lớn nhất của recurrent đại diện và baseline E3.	21
5.1	Split GTSRB sử dụng toàn bộ dữ liệu.	22
5.2	Các mức freeze và số tham số được tối ưu.	24
5.3	Tám cấu hình chính A1; mọi F1 là macro-F1.	25
5.4	Capacity, số epoch và peak allocated GPU memory A1.	25
5.5	Thời gian train+val và inference FP32; CUDA Events batch 32, tách DataLoader.	27
5.6	Sáu thực nghiệm bổ sung trên full pretrained; cấu hình đã chọn trước test.	28
5.7	Augmentation ablation, cùng full mode và seed 42.	28
5.8	Full pretrained, 3 seed 42/43/44, giữ split42; std mẫu(ddof=1), không phải khoảng tin cậy.	28
5.9	Một số lớp khó trong hai full model seed 42; test support và recall/F1.	30
A.1	Audit E1.	33
A.2	Audit E2; ký hiệu M/T và R/P/C như Chương E2.	33
A.3	Audit E3.	33
A.4	Epoch, cập nhật và peak memory của sáu run mở rộng A1.	34
A.5	Precision/recall/F1 trên test GTSRB, lớp 0–21.	34
A.6	Precision/recall/F1 trên test GTSRB, lớp 22–42.	35
A.7	Độ nhạy A1 với 8 ảnh test trùng train.	35

1. Bài toán và thiết kế thực nghiệm

1.1 Mục tiêu và đối chiếu đề bài

Các bài tập khảo sát cách biểu diễn cùng một ảnh thành vector, feature map, token và chuỗi. A1 mở rộng sang dữ liệu biến báo nhiều lớp để so sánh CNN/Transformer và mức độ sử dụng trọng số pretrained. Nội dung mỗi chương gồm dữ liệu, kiến trúc, huấn luyện, kết quả định lượng, phân tích lỗi và giới hạn, theo bố cục báo cáo mẫu được cung cấp.

Bảng 1.1: Đối chiếu yêu cầu đề bài và bằng chứng thực nghiệm.

Bài	Yêu cầu bắt buộc	Cách đáp ứng
E1	Softmax, MLP, CNN; loop tự viết; accuracy, capacity, curves, lỗi	4 model; bảng metric/chi phí, 2 CNN, confusion matrix và gallery.
E2	MSA thủ công/PyTorch; ít nhất 2 tokenizer; so sánh cùng tokenizer và giữa tokenizer	2 implementations $\times$ 3 tokenizer; parity gradient; thêm H=2/4/8.
E3	LSTM và GRU; biểu diễn chuỗi; so sánh MLP/CNN	2 cell $\times$ 3 cách quét; 2 baseline tự train trên cùng split.
A1	Dataset khác tập toy; CNN/Transformer; scratch/pretrained; 3 mức freeze; accuracy/F1, thời gian, trainable và lỗi	GTSRB 43 lớp; 8 cấu hình chính, 2 no-augmentation, 4 seed repeats; VRAM và throughput bổ sung.

Các yêu cầu công bố repository, GitHub Pages và link PDF là phần sản phẩm nộp riêng; bảng trên đối chiếu nội dung kỹ thuật và báo cáo, không xác nhận việc đã nộp online.

1.2 Dữ liệu dùng chung cho E1–E3

Fashion-MNIST [6] gồm ảnh grayscale 28×28 của 10 loại sản phẩm: T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag và Ankle boot. Độ tương tự giữa các loại áo tạo bài toán khó hơn nhận diện chữ số nhưng vẫn phù hợp quy mô các bài Ei. Từ 60.000 ảnh train gốc, mỗi lớp lấy 600 ảnh validation bằng seed 42; official test 10.000 ảnh được giữ riêng.


Bảng 1.2: Split Fashion-MNIST, giống nhau trong E1–E3.

Tập	Số ảnh	Mỗi lớp	Vai trò
Train	54.000	5.400	Cập nhật trọng số
Validation	6.000	600	Checkpoint, dừng sớm, lựa chọn cấu hình
Test	10.000	1.000	Đánh giá sau lựa chọn

Pixel chuyển sang $[0, 1]$ và chuẩn hóa bằng mean 0, 285886, std 0, 352960 chỉ tính từ train.

Không augmentation trong E1–E3. Fingerprint split giống nhau trong cả ba output:

```
bd9f3884131e411a26892e15ff685f2849
216340505ea615f3fb3b901e30fe80
```



Hình 1.1: Fashion-MNIST: một ảnh đại diện mỗi lớp và phân bố train/validation cân bằng.

1.3 Môi trường, loop và quy tắc đánh giá

Máy chạy Python 3.14.7, PyTorch 2.11.0+cu128, torchvision 0.26.0+cu128, NumPy 2.5.2, Matplotlib 3.11.2, Pillow 12.3.0; GPU NVIDIA RTX A3000 12GB Laptop, CUDA 12.8. Windows dùng DataLoader workers=0. Các notebook kiểm tra tensor/model/logit/gradient trên CUDA, xử lý batch cuối, và tự thực hiện forward, cross-entropy, backward, optimizer step.

Loss được tính trực tiếp trên logits:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp z_{i,y_i}}{\sum_{c=1}^C \exp z_{i,c}}. \quad (1.1)$$

Softmax chuyển logits thành xác suất khi diễn giải dự đoán; $\arg \max z$ và $\arg \max \text{softmax}(z)$ cho cùng nhãn. Loss tổng hợp theo số ảnh. Accuracy là tỷ lệ dự đoán đúng; $F1_c = 2P_cR_c/(P_c + R_c)$ và macro-F1 là trung bình không trọng số của $F1_c$ trên mọi lớp. Ma trận nhầm lẫn dùng hàng là nhãn thật, cột là dự đoán; phần trăm mỗi ô chia cho tổng số ảnh của lớp thật.

Training dùng AMP và GradScaler; validation/test dùng eval mode, no-grad. Checkpoint có validation loss nhỏ nhất được sao chép vào CPU RAM rồi nạp lại để đánh giá. Early stopping có ngưỡng cải thiện 10^{-4} ; counter dùng sớm và checkpoint tối ưu tuyệt đối được quản lý riêng. Model đại diện và ablation được chọn bằng validation accuracy, macro-F1, rồi loss; test không được dùng để lựa chọn cấu hình. Mỗi notebook tự dựng dataset/model/loop, không đọc checkpoint hoặc notebook khác.

Số liệu E1–E3 được tạo bởi full run ngày 07/10/2026, với patience=10 theo log output. Code hiện tại có patience=4 cho lần Run All tiếp theo; báo cáo giữ cấu hình đã sinh số liệu và không gán kết quả cũ cho cấu hình mới. Full run A1 ngày 07–08/10/2026 dùng patience=4.

Bảng 1.3: Audit các lần chạy tạo ra số liệu trong báo cáo.


Bài	Run	Epoch	CUDA updates	AMP skips
E1	4	108	45.574	2
E2	8	259	109.290	8
E3	8	238	100.434	2
A1	14	208	51.168	0

AMP skips là các bước optimizer bị scaler bỏ qua để tránh cập nhật gradient không hữu hạn; chúng được trừ khỏi số updates. Tất cả run vẫn xử lý đầy đủ ảnh train/validation/test. Train accuracy tại best được đo trong train mode khi weights đang cập nhật, vì vậy chênh lệch train–validation cần đọc cùng dropout/augmentation, không coi là hai phép đo eval hoàn toàn tương đương. Thời gian train+val loại test và vẽ hình; peak MiB là `torch.cuda.max_memory_allocated`, không phải tổng VRAM toàn máy.


2. E1: Softmax, MLP và CNN

2.1 Mục tiêu và kiến trúc


E1 so sánh classifier tuyến tính, MLP và CNN trên cùng Fashion-MNIST. Softmax dùng vector flatten 784 chiều; MLP thêm phi tuyến; CNN giữ cấu trúc không gian trước khi gom feature. Hai CNN giúp phân biệt số tham số và chất lượng: CNN-A có head lớn, CNN-B dùng global average pooling.




Hình 2.1: Softmax classifier: không Conv, một FC; 7.850 tham số.



Hình 2.2: MLP: ba FC, hai tầng ẩn; 235.146 tham số.



Hình 2.3: CNN-A: hai Conv, hai MaxPool, hai FC; 421.642 tham số. Conv stride 1, padding 1, có bias.



Hình 2.4: CNN-B: ba Conv/BN/MaxPool, một FC; 94.186 tham số. Conv stride 1, padding 1, không bias. Kích thước sau pool thứ ba là 3×3 .

Trong sơ đồ, B là batch và 3^2 là kernel 3×3 ; batch được giữ xuyên suốt dù lược khỏi một số nhân tensor. CNN-A dành 401.536 tham số cho FC $3136 \rightarrow 128$, khoảng 95,2% tổng số tham số. CNN-B thay head này bằng average pooling, nên ít tham số hơn dù có thêm một Conv.

2.2 Huấn luyện

AdamW LR 10^{-3} , weight decay 10^{-4} , batch 128, tối đa 100 epoch. Mỗi epoch có 422 batch train, 47 validation; test có 79 batch, giữ batch cuối. Lần chạy tạo số liệu dùng patience 10, min-delta 10^{-4} và checkpoint theo validation loss nhỏ nhất. Không dùng scheduler hoặc augmentation. Các kiểm tra forward/backward trước train xác nhận đủ bốn model trên CUDA.


2.3 Kết quả định lượng và chi phí

Bảng 2.1: Metric E1 tại checkpoint chọn bằng validation loss; F1 là macro-F1.

Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
Softmax	86.51	84.88	0.8481	84.27	0.8418	0.4408
MLP	91.58	89.47	0.8951	89.45	0.8948	0.3142
CNN-A	94.61	92.00	0.9203	91.66	0.9169	0.2339
CNN-B	95.82	91.92	0.9190	91.97	0.9193	0.2320

Bảng 2.2: Capacity và chi phí E1; epoch/best ghi số epoch thực chạy và epoch checkpoint.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
Softmax	7,850	24/14	28.58	1.191	19
MLP	235,146	26/16	50.52	1.943	23
CNN-A	421,642	18/8	38.19	2.121	52
CNN-B	94,186	40/30	126.33	3.158	57




Hình 2.5: So sánh validation accuracy, số tham số và thời gian train+validation của E1.

MLP tăng test accuracy từ 84,27% lên 89,45%, tương đương 5,18 điểm phần trăm. Điều này cho thấy phi tuyến hữu ích trên cùng vector flatten. CNN-A đạt 91,66%, CNN-B đạt 91,97%, cao hơn MLP lần lượt 2,21 và 2,52 điểm phần trăm.


CNN-A có số tham số gấp 4,48 lần CNN-B; CNN-B vẫn đạt test cao hơn 0,31 điểm phần trăm nhưng val thấp hơn 0,08 điểm. Đây là khác biệt nhỏ trong một seed, không phải bằng chứng CNN-B luôn tốt hơn. Hai mạng khác cả normalization, độ sâu, pooling và head; không quy chất lượng chỉ cho số tham số. CNN-A có val accuracy cao nhất 92,00%; model đại diện không được chọn bằng test của CNN-B. Tính theo mỗi epoch, CNN-B chậm hơn CNN-A (3,158 so với 2,121 s) dù ít tham số hơn, vì convolution/BN và kích thước activation cũng quyết định chi phí.

2.4 Learning curves và phân tích lỗi




Hình 2.6: Loss và accuracy của bốn model; nét đứt train, nét liền validation.

Train–validation gap ở best lần lượt khoảng 1,62; 2,11; 2,61; 3,91 điểm phần trăm. CNN-B có gap lớn nhất nhưng vẫn đạt test tốt; gap cần đọc cùng dropout và đường cong, không dùng riêng để xếp hạng tổng quát hóa. Đường cong train tiếp tục cải thiện sau khi validation chứng lại giải thích việc chọn best checkpoint thay cho last epoch.




Hình 2.7: Confusion matrix test của Softmax và MLP: mỗi ô ghi số ảnh và tỷ lệ theo lớp thật.



Hình 2.8: Confusion matrix test của CNN-A và CNN-B, cùng thang 0–100%.

Bảng 2.3: Cặp nhầm nhiều nhất trong E1; mỗi lớp test có 1.000 ảnh.

Model	Thật → dự đoán	Số ảnh	% lớp thật
Softmax	Shirt → T-shirt/top	154	15,4
MLP	T-shirt/top → Shirt	124	12,4
CNN-A	T-shirt/top → Shirt	137	13,7
CNN-B	Shirt → T-shirt/top	103	10,3



Hình 2.9: Ảnh dự đoán sai của E1; cùng cột là cùng lớp thật, mỗi hàng là một model.

Nhằm lẫn tập trung ở nhóm áo có silhouette gần nhau, trong khi giày/túi có hình dáng khác biệt dễ tách hơn trên ma trận. CNN giảm nhiều lỗi nhưng không loại bỏ sự mơ hồ giữa Shirt và T-shirt/top. Ảnh gallery là lỗi đầu tiên mỗi lớp/model, dùng minh họa; tần suất phải lấy từ toàn bộ confusion matrix.


2.5 Nhận xét và giới hạn

Softmax nhẹ và nhanh, nhưng ranh giới tuyến tính hạn chế biểu diễn. MLP tăng chất lượng với phi tuyến, song flatten không áp đặt locality và đòi hỏi nhiều FC. CNN phù hợp ảnh nhỏ nhờ receptive field và chia sẻ trọng số; CNN-B cho hiệu quả tham số tốt trong protocol này. Kết luận dựa trên một seed và một dataset cân bằng; chưa đo độ biến thiên hay kiểm soát matched capacity.

3. E2: Multi-head self-attention và tokenization

3.1 Mục tiêu và biểu diễn token


E2 hiện thực MSA bằng Linear, reshape, matmul, softmax và concat; bản đối chiếu dùng `nn.MultiheadAttention`. Encoder và classifier giống nhau giữa hai bản. Ba tokenizer cùng dùng split/normalization Fashion-MNIST ở Chương 1; không sử dụng checkpoint E1.




Hình 3.1: Ba tokenizer E2; CNN-stem có hai Conv kernel 3, stride 1, padding 1, bias, ReLU và MaxPool 2 sau mỗi Conv. Rows không có Conv; patch lấy trực tiếp pixel.

Rows có $N = 28$, $F = 28$; patch/CNN-stem có $N = 49$, $F = 16$. CNN-stem thêm 2.480 tham số học so với patch cùng chiều feature, nên so sánh tokenizer thay đổi cả inductive bias và capacity.

3.2 Kiến trúc encoder và MSA



Hình 3.2: Classifier E2: một FC embedding, hai encoder block và một FC head; không CLS token.



Hình 3.3: Một pre-norm encoder block: hai projection MSA và hai FC trong FFN, tổng bốn ánh xạ Linear/block. Đường ngoài là residual.

Với $D = 64, H = 4, d_h = 16$, QKV reshape thành $B \times H \times N \times d_h$:

$$A_h = \text{softmax}_{\text{key}} \left(Q_h K_h^\top / \sqrt{d_h} \right), \quad Y = \text{Concat}_{h=1}^H (A_h V_h) W_O + b_O. \quad (3.1)$$

Attention dropout 0,1 áp dụng lên A_h trước khi nhân V_h ; output dropout nằm trên nhánh residual. Mỗi block có FFN $64 \rightarrow 128 \rightarrow 64$, GELU, dropout 0,1. Toàn classifier có 10 ánh xạ Linear theo cách đếm QKV gộp là một Linear: 1 embedding + 2×4 trong encoder + 1 head. CNN-stem bổ sung 2 Conv.

Cập manual/PyTorch copy toàn bộ weights khởi tạo, gồm tokenizer, position, FFN và head. Kiểm tra CUDA float64 với dropout tắt đạt sai số tối đa $1,665 \times 10^{-16}$ ở forward và input/weight/bias gradients. Parity xác nhận phép toán; không đảm bảo dropout/RNG và đường tối ưu của hai lần training giống nhau.

3.3 Protocol và tám cấu hình

AdamW LR 10^{-3} , WD 10^{-4} , batch 128, tối đa 100 epoch; full run dùng patience 10, min-delta 10^{-4} và checkpoint min validation loss. Sáu run cơ sở là manual/PyTorch $\times$ rows/patch/stem, $H=4$. Tokenizer manual tốt nhất theo validation là CNN-stem, được dùng thêm $H=2$ và $H=8$; $H=4$ tái dùng run đã train. D giữ 64 nên số tham số không thay đổi theo H.

Ký hiệu bảng: M>manual, T=PyTorch; R=rows, P=patch 4, C=CNN-stem; chữ số cuối là H. Ví dụ M-C4 là manual CNN-stem, 4 head.


3.4 Kết quả và so sánh theo đề

Bảng 3.1: Metric E2; mọi model đánh giá đủ 10.000 ảnh test, F1 là macro-F1.


Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
M-R4	91.61	89.97	0.8988	89.51	0.8941	0.3050
M-P4	91.89	89.17	0.8916	88.85	0.8882	0.3302
M-C4	92.18	90.65	0.9063	90.50	0.9048	0.2717
T-R4	91.75	89.90	0.8983	89.22	0.8913	0.3054
T-P4	90.90	88.47	0.8844	88.67	0.8865	0.3266
T-C4	92.79	90.68	0.9068	90.78	0.9078	0.2695
M-C2	92.84	90.50	0.9056	90.74	0.9079	0.2789
M-C8	92.13	90.35	0.9031	90.23	0.9020	0.2752

Bảng 3.2: Capacity và chi phí của tám cấu hình E2.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
M-R4	71,370	26/16	161.65	6.217	44
M-P4	71,946	40/30	293.87	7.347	69
M-C4	74,426	30/20	194.62	6.487	78
T-R4	71,370	26/16	159.69	6.142	47
T-P4	71,946	34/24	234.66	6.902	79
T-C4	74,426	34/24	232.01	6.824	89
M-C2	74,426	41/31	269.20	6.566	70
M-C8	74,426	28/18	188.28	6.724	98



Hình 3.4: Tổng quan accuracy validation, capacity và chi phí E2.




Hình 3.5: So sánh manual/PyTorch cùng tokenizer: accuracy, params và giây/epoch.

Bảng 3.3: So sánh manual/PyTorch ở H=4, cùng weights khởi tạo.

Tokenizer	M val	T val	M-T (điểm%)	M/T s/epoch
Rows	89,97	89,90	+0,07	6,217 / 6,142
Patch	89,17	88,47	+0,70	7,347 / 6,902
CNN-stem	90,65	90,68	-0,03	6,487 / 6,824

Sai số parity rất nhỏ không có nghĩa metric training phải bằng nhau: dropout, random-number consumption và AMP làm đường tối ưu khác. Chênh lệch 0,07 hoặc 0,03 điểm ở rows/stem nhỏ; chênh lệch 0,70 ở patch cũng chỉ quan sát ở một seed, chưa kết luận implementation nào tốt hơn.

CNN-stem đạt validation cao nhất trong cả hai implementation (90,65% manual, 90,68% PyTorch). So với patch, cải thiện tương ứng 1,48 và 2,21 điểm; so với rows là 0,68 và 0,78 điểm. Các convolution học đặc trưng cục bộ trước attention là giải thích kiến trúc hợp lý, nhưng chưa cô lập tác động vì capacity và token features cũng thay đổi. Rows $N = 28$ có attention matrix 784 phần tử/head; patch/stem $N = 49$ có 2.401, gấp 3,06 lần. Chi phí toàn mạng còn gồm projections/FFN/CNN, nên không suy tốc độ chỉ từ N^2 .




Hình 3.6: Ablation H=2/4/8 trên manual CNN-stem, giữ D=64.


H=2/4/8 đạt val 90,50/90,65/90,35%; test 90,74/90,50/90,23%. H=4 tốt nhất theo validation nhưng H=2 cao hơn trên test; giữ quy tắc chọn H=4 thay vì đổi quyết định sau test. Tăng head

không tăng tham số projection, mà chia feature mỗi head thành 32/16/8 chiều; accuracy không tăng đơn điệu.

3.5 Learning curves, attention và lỗi




Hình 3.7: Loss theo epoch, nhóm theo tokenizer; train nét đứt, validation nét liền.



Hình 3.8: Accuracy theo epoch của các cấu hình E2.

Các train–val gap khoảng 1,53–2,72 điểm phần trăm. Đọc curves cùng best epoch cho thấy cần dừng khi validation chững, thay vì chọn loss train thấp nhất.




Hình 3.9: Attention của manual CNN-stem H=4 trên hai ảnh validation cố định; trung bình head, block cuối, gộp 7 nhóm query/key, tổng mỗi hàng 100%.

Map thể hiện phân bố trọng số giữa các nhóm token sau CNN-stem, không phải saliency trực tiếp ở pixel gốc. Việc trung bình head và gộp 7 nhóm làm mất chi tiết từng head/token. Các ô sáng cho biết trọng số kết hợp lớn, không tự chứng minh token là nguyên nhân của quyết định phân loại.

Bảng 3.4: Nhầm lẫn lớn nhất của ba tokenizer manual H=4.

Model	Thật → dự đoán	Số ảnh	% lớp thật
M-R4	Shirt → T-shirt/top	139	13,9
M-P4	Coat → Pullover	127	12,7
M-C4	Shirt → T-shirt/top	94	9,4




Hình 3.10: Gallery lỗi của các model đại diện E2 chọn bằng validation.

Ảnh lỗi và ma trận đầy đủ ở Phụ lục cho thấy nhóm áo vẫn khó tách. Patch hay nhầm Coat/Pullover; stem giảm cặp Shirt/T-shirt/top trong bản manual, song không xóa lỗi. E2 đã đáp ứng hai implementation và ba tokenizers; giới hạn là encoder nhỏ, một seed, chưa kiểm soát capacity giữa tokenizers và attention visualization chỉ mang tính mô tả.


4. E3: LSTM và GRU trên chuỗi ảnh

4.1 Biểu diễn ảnh thành chuỗi

E3 đọc ảnh như một chuỗi các vector và phân loại bằng hidden state cuối. Rows quét từ trên xuống, mỗi token là 28 pixel của một hàng. Columns quét từ trái sang phải, mỗi token là 28 pixel của một cột. Patch 4×4 không overlap, quét raster trái-phải rồi trên-dưới, tạo 49 bước, mỗi bước 16 pixel. Không thêm CNN/token embedding trước recurrent.



Hình 4.1: Cùng một ảnh validation được chuyển thành rows, columns và patch: thứ tự quét cùng ma trận timestep-feature.




Hình 4.2: Classifier recurrent E3: không Conv, một recurrent layer unroll T lần và một FC head. Trạng thái khởi tạo 0, chỉ dùng hidden cuối.

4.2 Cell LSTM/GRU tự hiện thực

Với $H = 128$, LSTM có input projection $F \rightarrow 4H = 512$, hidden projection $128 \rightarrow 512$, hai bias và bốn nhóm gate:

$$[i_t, f_t, g_t, o_t] = [\sigma, \sigma, \tanh, \sigma](W_{ih}x_t + b_{ih} + W_{hh}h_{t-1} + b_{hh}), \quad (4.1)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t, \quad h_t = o_t \odot \tanh c_t. \quad (4.2)$$




Hình 4.3: LSTM cell: hai projection dùng chung ở mọi bước; không tạo thêm bộ tham số cho mỗi timestep.

GRU có hai projection $F \rightarrow 384$ và $128 \rightarrow 384$ cho reset, update và candidate:

$$r_t = \sigma(x_r + h_r), \quad z_t = \sigma(x_z + h_z), \quad (4.3)$$

$$n_t = \tanh(x_n + r_t \odot h_n), \quad h_t = (1 - z_t) \odot n_t + z_t \odot h_{t-1}. \quad (4.4)$$

x và h đã gồm bias. Reset nhân *sau* projection hidden, kể cả hidden bias, theo convention PyTorch.



Hình 4.4: GRU cell: hai projection cho ba nhóm gate, chỉ duy trì hidden state.

Kể cả head, số tham số là $4H(F+H+2)+10H+10$ cho LSTM và $3H(F+H+2)+10H+10$ cho GRU. Cùng F , GRU ít tham số hơn vì dùng ba nhóm thay cho bốn. Kiểm tra copy weight sang `nn.LSTMCell/nn.GRUCell` trên CUDA float64 qua 4 bước, so forward và gradients của state/input/tất cả params, đạt max error 5, 551×10^{-17} (LSTM) và $3,331 \times 10^{-16}$ (GRU).

4.3 Baseline và training protocol

Sáu recurrent run là LSTM/GRU $\times$ rows/columns/patch. MLP và CNN-B có đúng kiến trúc E1, tự định nghĩa và train mới trong E3 trên cùng split; không đọc trọng số E1. Baseline MLP

có 3 FC, CNN-B có 3 Conv và 1 FC như sơ đồ E1.

AdamW LR 10^{-3} , WD 10^{-4} , batch 128, tối đa 100 epoch. Full run dùng patience 10 và min-delta 10^{-4} , checkpoint min val loss. Recurrent clip gradient norm 1; baseline giữ protocol tương ứng E1, không clipping. Vòng lặp recurrent unroll từng token bằng Python/PyTorch, không dùng fused `nn.LSTM/nn.GRU` trong train; điều này cần ghi khi diễn giải tốc độ.


4.4 Kết quả, representation và chi phí

Bảng 4.1: Metric của sáu recurrent model và hai baseline E3, F1 là macro-F1.


Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
LSTM Rows	91.95	89.95	0.8990	89.70	0.8965	0.2940
LSTM Columns	92.79	88.72	0.8881	88.81	0.8885	0.3260
LSTM Patch	92.40	88.62	0.8861	88.22	0.8823	0.3414
GRU Rows	93.95	90.47	0.9044	90.06	0.9001	0.2882
GRU Columns	93.16	89.83	0.8983	89.51	0.8951	0.3137
GRU Patch	92.36	89.05	0.8900	88.44	0.8841	0.3352
MLP	91.58	89.47	0.8951	89.45	0.8948	0.3142
CNN-B	95.82	91.92	0.9190	91.97	0.9193	0.2320

Bảng 4.2: Số tham số, epoch và chi phí E3.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
LSTM Rows	82,186	24/14	410.70	17.113	27
LSTM Columns	82,186	29/19	452.70	15.610	27
LSTM Patch	76,042	34/24	853.58	25.105	34
GRU Rows	61,962	26/20	393.42	15.132	28
GRU Columns	61,962	29/19	407.87	14.064	28
GRU Patch	57,354	30/20	696.60	23.220	35
MLP	235,146	26/16	49.98	1.922	23
CNN-B	94,186	40/30	100.38	2.509	57




Hình 4.5: Accuracy, capacity và thời gian E3 trên cùng Fashion-MNIST.



Hình 4.6: LSTM vs GRU với cùng representation.

Rows tốt nhất trong từng family: LSTM val 89,95%, test 89,70%; GRU val 90,47%, test 90,06%. Với columns, test giảm còn 88,81%/89,51%; patch giảm còn 88,22%/88,44%. Rows/columns cùng T , F và capacity, nên thay đổi hướng quét làm thay đổi thông tin ở mỗi bước. Patch đổi cả thông tin, độ dài 49 và input 16, nên không cô lập riêng tác động thứ tự.


GRU cao hơn LSTM trên test ở cả ba representation lần lượt 0,36/0,70/0,22 điểm phần trăm, dùng ít tham số và ít giây/epoch hơn. Rows: 61.962 so với 82.186 params; 15,132 so với 17,113 s/epoch. Patch dài 49 bước làm thời gian/epoch lớn hơn rows, dù ít tham số hơn. Đây là chi phí của implementation unroll hiện tại, không khẳng định mọi GRU/LSTM kernel đều có cùng tỷ lệ tốc độ.




Hình 4.7: So sánh recurrent rows chọn bằng validation với MLP và CNN-B train trong E3.

GRU rows test 90,06% cao hơn MLP 89,45% khoảng 0,61 điểm, nhưng thấp hơn CNN-B 91,97% khoảng 1,91 điểm. CNN-B chỉ 2,509 s/epoch so với GRU 15,132 s và LSTM 17,113 s. Locality/chia sẻ Conv cùng khả năng tính song song phù hợp ảnh tĩnh trong thí nghiệm này. Hidden state có thể tích lũy thông tin qua toàn chuỗi, nhưng accuracy không chứng minh model đã học phụ thuộc xa; chưa có ablation độ dài/che timestep để kiểm tra giả thuyết đó.

4.5 Learning curves và lỗi



Hình 4.8: Loss E3 theo representation; nét đứt train, nét liền validation.



Hình 4.9: Accuracy E3 theo representation.

LSTM columns có train 92,79% so với val 88,72% tại best; GRU rows có train 93,95% và val 90,47%. Khoảng cách cùng curves cho thấy validation không theo kịp train hoàn toàn; best checkpoint giữ chất lượng trước các epoch làm val loss xấu hơn.

Bảng 4.3: Cặp nhầm lẫn lớn nhất của recurrent đại diện và baseline E3.

Model	Thật → dự đoán	Số ảnh	% lớp thật
LSTM Rows	Shirt → T-shirt/top	133	13,3
GRU Rows	Shirt → T-shirt/top	125	12,5
MLP	T-shirt/top → Shirt	124	12,4
CNN-B	Shirt → T-shirt/top	103	10,3



Hình 4.10: Gallery lỗi recurrent và baseline E3; ma trận của mọi run nằm ở Phụ lục.

Các mô hình khác họ vẫn nhầm nhóm áo tương tự, cho thấy representation chuỗi không giải quyết hết mơ hồ hình dáng. CNN-B giảm số Shirt thành T-shirt/top so với hai recurrent rows; cần xem cả recall từng lớp và chiều nhầm ngược trên ma trận, không dùng riêng một cặp để đánh giá toàn model.

Nhận xét và giới hạn. Cả LSTM và GRU hoạt động với ba biểu diễn, có parity và baseline độc lập. GRU rows là recurrent được chọn bằng validation; CNN-B vẫn là lựa chọn hiệu quả hơn về accuracy và thời gian ở bài toán ảnh tĩnh này. Một seed, gradient clip chỉ cho recurrent và unroll không fused là giới hạn khi suy rộng kết luận.

5. A1: CNN và Transformer trên GTSRB

5.1 Dataset, EDA và split

GTSRB [2, 3] là bộ ảnh 43 loại biển giao thông, khác Fashion-MNIST/CIFAR-10 và phù hợp ràng buộc A1 về nhiều lớp, quy mô hàng chục nghìn ảnh, biến đổi góc nhìn/ánh sáng và lớp gần nhau. Nguồn là archive tác giả trên ERDA [4], gồm 39.209 ảnh train nguồn và 12.630 test. Nhân ClassId là số nguyên 0–42; filename train chứa class/track/frame, metadata local chứa path, kích thước, nhãn và SHA256. PPM được chuyển thành PNG lossless với kiểm tra pixel; ảnh không được phân phối qua Git.

Trang metadata archive chưa nêu mã giấy phép SPDX; báo cáo ghi đúng nguồn, tác giả và điều kiện/README nguồn, không tự gán MIT/CC cho dataset. Việc dùng học tập/nghiên cứu và trích dẫn được mô tả trong hồ sơ dữ liệu local; thông tin giấy phép chuẩn hóa chưa được xác nhận từ metadata công khai.

Train/validation chia theo nhóm `class_id + physical_sign_track`, seed 42, giữ khoảng 20% track mỗi lớp cho validation. Cách chia này hạn chế frame cùng biển vật lý rơi vào hai tập. Số ảnh thực tế:


Bảng 5.1: Split GTSRB sử dụng toàn bộ dữ liệu.

Tập	Ảnh	Lớp	Vai trò
Train	31.380	43	Huấn luyện
Validation	7.829	43	Checkpoint, freeze/augmentation protocol
Official-source test	12.630	43	Đánh giá cuối
Test không trùng SHA256	12.622	43	Phân tích độ nhạy bổ sung


Fingerprint:

```
c1c1759f478eaaaaac0faddf424717574
f6f1895f6a5511ed77964c34eb2c7ac
```

Output xác nhận không có trùng SHA256 train–val/val–test, nhưng có 8 ảnh test lớp Stop (ID 14) trùng train. Giữ full test nguồn để đối chiếu và báo thêm test không trùng; full test có giới hạn độc lập, không coi là hoàn toàn sạch.



Hình 5.1: Phân bố 43 lớp trên các split và kích thước ảnh train gốc.



Hình 5.2: Một ảnh train đại diện cho mỗi lớp GTSRB; ID dùng để tra ma trận nhầm lẫn.


Train mất cân bằng: lớp Speed limit 50 có 1.800 ảnh, trong khi Speed limit 20, Pedestrians và nhiều lớp hiếm có 180 ảnh. Validation lớp Turn right ahead có 149 ảnh, phản ánh split track không ép tỷ lệ ảnh chính xác 20%. Resize không làm tăng thông tin ảnh nhỏ, vì vậy mờ/thiếu sáng vẫn là khó khăn thực tế.

5.2 DataLoader, augmentation và kiến trúc


Ảnh RGB được resize toàn ảnh 224×224 , không center-crop, rồi chuẩn hóa ImageNet mean $(.485, .456, .406)$, std $(.229, .224, .225)$ cho mọi regime. Augmentation train gồm RandomAffine góc trong $\pm 10^\circ$, translate tối đa 5% theo mỗi trục, ColorJitter brightness/contrast 0,2 và saturation 0,1. Không flip vì có thể đảo ý nghĩa biển; val/test chỉ resize và normalize. DataLoader shuffle train, seed cố định, workers 0, không bỏ batch cuối. Notebook đọc ảnh và kiểm tra SHA256 trong Dataset; thời gian train+val vì vậy gồm cả xử lý dữ liệu và kiểm tra integrity của implementation local.

ResNet-50 dùng Bottleneck 3/4/6/3, expansion 4, stride tại Conv 3×3 , khớp convention torchvision [1]. DeiT-Small/16 non-distilled dùng patch 16, embedding 384, depth 12, 6 head, MLP ratio 4 và LayerNorm eps 10^{-6} [5]. Cả hai tự định nghĩa trong notebook, nạp pretrained Im-

ageNet backbone tương thích rồi thay head 43 lớp. ResNet dùng ImageNet-1K V1 của torchvision, DeiT dùng checkpoint ImageNet-1K chính thức non-distilled. DeiT ở đây không dùng distillation token/teacher hoặc loss distillation.



Hình 5.3: A1 ResNet-50: backbone thể hiện bằng một khối, chỉ thay một FC43 lớp. Head có 88.107 tham số; tổng 23.596.139.



Hình 5.4: A1 DeiT-Small/16: backbone gom khối, thể hiện token và kích thước FFN; head 16.555 tham số, tổng 21.682.219.

Kiểm tra forward ResNet cùng weights khớp torchvision; attention DeiT khớp forward/input/QKV-output gradients của PyTorch float64. Head được kiểm tra thay đổi sau optimizer step, còn frozen parameters/BN buffers giữ nguyên.

5.3 Tám cấu hình và protocol huấn luyện

Ký hiệu bảng: R=ResNet-50, D=DeiT-Small/16; S=scratch, H=head-only, P=partial, F=full pre-trained. Số sau dấu/ là seed.

Bảng 5.2: Các mức freeze và số tham số được tối ưu.

Họ	Chế độ	Thành phần trainable	Số tham số	% tổng
ResNet	Scratch/full	Toàn bộ mạng	23.596.139	100,00
ResNet	Head-only	FC43	88.107	0,37
ResNet	Partial	layer4 và FC43	15.052.843	63,79
DeiT	Scratch/full	Toàn bộ mạng	21.682.219	100,00
DeiT	Head-only	FC43	16.555	0,08
DeiT	Partial	2 block cuối, norm, head	3.566.251	16,45

Partial không tương đương về tỷ lệ trainable giữa hai family, nên đây là so sánh hai chiến lược thực tế, không phải ablation matched capacity. Frozen BN giữ eval mode và running buffers bất biến.

AdamW WD 0,01; scratch LR 3×10^{-4} cho toàn mạng, tối đa 40 epoch; pretrained backbone LR 10^{-4} và head 10^{-3} , tối đa 25 epoch. Warmup 3 epoch rồi cosine; clip gradient norm 1, AMP train, FP32 eval, patience 4/min-delta 10^{-4} . Batch 128 cố định cho train/val/test, accumulation 1, effective 128; mỗi epoch 246 batch train, giữ batch cuối 20 ảnh. Best checkpoint min val loss; regime đại diện chọn theo val accuracy/F1/loss.

Hai family $\times 4$ regime tạo 8 run chính cùng seed 42/augmentation. Sau khi chọn full mode cho mỗi family bằng validation, thêm 1 no-augmentation seed 42 và 2 repeat seed 43/44/family, tổng 14 run. Các seed repeats đổi RNG train nhưng giữ splitseed 42. Test chỉ đánh giá sau khi khóa mọi lựa chọn.


5.4 Kết quả chính: CNN vs Transformer và pretraining

Bảng 5.3: Tám cấu hình chính A1; mọi F1 là macro-F1.

Run	Train (%)	Val (%)	Val F1	Test (%)	Test F1
R-S/42	98.51	98.26	0.9688	96.33	0.9447
R-H/42	91.12	69.22	0.5952	70.35	0.6143
R-P/42	99.76	97.89	0.9720	96.05	0.9438
R-F/42	99.94	99.80	0.9981	98.37	0.9743
D-S/42	99.98	98.38	0.9752	96.14	0.9350
D-H/42	91.34	71.31	0.6066	69.73	0.6125
D-P/42	98.64	89.32	0.8360	87.85	0.8063
D-F/42	99.79	99.39	0.9863	98.92	0.9790

Bảng 5.4: Capacity, số epoch và peak allocated GPU memory A1.

Run	Total params	Trainable	%	Epoch/best	s/epoch	Peak MiB
R-S/42	23,596,139	23,596,139	100.00	9/5	259.408	5830
R-H/42	23,596,139	88,107	0.37	24/20	185.367	1567
R-P/42	23,596,139	15,052,843	63.79	13/9	194.699	1681
R-F/42	23,596,139	23,596,139	100.00	11/7	255.018	5823
D-S/42	21,682,219	21,682,219	100.00	39/35	265.317	6635
D-H/42	21,682,219	16,555	0.08	25/21	187.817	636
D-P/42	21,682,219	3,566,251	16.45	8/4	197.725	1374
D-F/42	21,682,219	21,682,219	100.00	10/6	251.002	6632



Hình 5.5: Accuracy validation/test, trainable params và giây/epoch của tám cấu hình chính.

Full pretrained được chọn bằng validation ở cả hai family: ResNet val 99,80%, test 98,37%; DeiT val 99,39%, test 98,92%. DeiT test cao hơn 0,55 điểm, trong khi ResNet val cao hơn 0,41 điểm; không dùng test để đảo lựa chọn regime.

Pretraining cải thiện full so với scratch: ResNet test từ 96,33% lên 98,37% (+2,04điểm), DeiT từ 96,14% lên 98,92% (+2,78điểm). DeiT scratch cần 39 epoch/10.347,38 s; full cần 10 epoch/2.510,02 s. ResNet scratch 9 epoch/2.334,67 s còn full 11 epoch/2.805,20 s: pretraining cải thiện chất lượng nhưng không luôn giảm thời gian tổng, vì early stopping và learning-rate protocol khác nhau. DeiT vẫn học scratch đến 96,14%; không kết luận Transformer bắt buộc pretrain để chạy được.

Cùng scratch, test ResNet cao hơn DeiT 0,19 điểm; cùng head-only, ResNet cao hơn 0,62 điểm. Cùng partial, ResNet đạt 96,05% so với 87,85% của DeiT, nhưng phần mạng được mở khác lớn (63,79% so với 16,45% params). Không quy chênh lệch này chỉ cho CNN/Transformer. Full mode cho thấy DeiT có lợi về accuracy trong thí nghiệm, đổi lại chi phí suy luận/bộ nhớ.

5.5 Freeze, chi phí và đường cong



Head-only val 69,22% / 71,31%, test 70,35% / 69,73%, thấp xa full; train tại best vẫn 91,12% / 91,34%. Chỉ học head chưa thích nghi tốt backbone với split GTSRB này. Freeze có lợi nếu cần tiết kiệm VRAM, ít weights phải tối ưu và lượt train ngắn theo mỗi epoch; ở đây không phải lựa chọn tốt nếu ưu tiên accuracy. Head-only kéo dài 24/25 epoch nên thời gian tổng còn lớn hơn full 11/10 epoch.

Partial ResNet đạt gần scratch với peak 1.681 MiB; full đạt accuracy cao hơn với 5.823 MiB. Partial DeiT peak 1.374 MiB, full 6.632 MiB; head-only chỉ 636 MiB nhưng accuracy thấp. Các peak là allocated PyTorch, không phải reserved hoặc tổng VRAM trong Task Manager.

Bảng 5.5: Thời gian train+val và inference FP32; CUDA Events batch 32, tách DataLoader.

Run	Train+val (s)	GPU ms/batch	Images/s	Test (s)
R-S/42	2334.67	77.06	415.3	51.30
R-H/42	4448.81	77.54	412.7	45.32
R-P/42	2531.09	76.63	417.6	44.35
R-F/42	2805.20	77.09	415.1	44.70
D-S/42	10347.38	138.44	231.1	64.70
D-H/42	4695.43	139.91	228.7	64.56
D-P/42	1581.80	139.99	228.6	65.06
D-F/42	2510.02	139.22	229.9	64.99

ResNet full đạt 415,1 ảnh/s và 77,09 ms/batch 32; DeiT229,9 ảnh/s, 139,22ms/batch 32. Throughput ResNet khoảng 1,81 lần DeiT trong phép đo này. Test end-to-end dùng batch 128 và gồm DataLoader/H2 D/evaluation, nên không đồng nhất với benchmark GPU-only batch 32.

**Hình 5.6:** Loss của hai family theo bốn regime; train nét đứt, validation nét liền.**Hình 5.7:** Accuracy theo epoch A1; mỗi panel một family.

Full pretrained nhanh chóng đạt val cao; head-only có gap train–val lớn và val loss gần 1. DeiT scratch có quá trình học dài hơn ResNet scratch. Training accuracy dùng augmenta-

tion/train mode, validation dùng eval mode; curves cần được đọc với sự khác biệt này và epoch của checkpoint.

5.6 Augmentation và độ ổn định qua seed

Bảng 5.6: Sáu thực nghiệm bổ sung trên full pretrained; cấu hình đã chọn trước test.

Run	Val (%)	Val F1	Test (%)	Test F1	Train+val (s)
R-F/42 no-aug	98.85	0.9811	97.20	0.9545	941.91
R-F/43	99.92	0.9991	98.76	0.9834	1912.95
R-F/44	99.28	0.9881	98.19	0.9630	1717.14
D-F/42 no-aug	99.46	0.9896	99.22	0.9896	3547.77
D-F/43	99.85	0.9963	99.29	0.9914	6838.98
D-F/44	99.50	0.9908	98.64	0.9781	2510.36


Bảng 5.7: Augmentation ablation, cùng full mode và seed 42.

Họ	Aug val	No-aug val	Aug test	No-aug test
ResNet	99,80	98,85	98,37	97,20
DeiT	99,39	99,46	98,92	99,22

Augmentation cải thiện ResNet val 0,95 và test 1,17 điểm; DeiT val thay đổi $-0,08$ điểm theo số liệu chưa làm tròn, test $-0,30$ điểm. Không khẳng định augmentation luôn tốt: hiệu quả phụ thuộc family và biến đổi đã chọn, ablation này chỉ có seed 42.

Bảng 5.8: Full pretrained, 3 seed 42/43/44, giữ split42; std mẫu (ddof=1), không phải khoảng tin cậy.


Họ	Val acc(%)	Test acc(%)	Val macro-F1	Test macro-F1
ResNet	99,67 $\pm$ 0,34	98,44 $\pm$ 0,29	.9951 $\pm$.0061	.9736 $\pm$.0102
DeiT	99,58 $\pm$ 0,24	98,95 $\pm$ 0,33	.9912 $\pm$.0050	.9828 $\pm$.0074



Hình 5.8: Augmentation và ba seed của full pretrained; đồ thị dựng từ bảng output, trực tung thu hẹp 97,5–100,6% để đọc chênh lệch; error bar là std mẫu.

DeiT có test trung bình cao hơn 0,51 điểm trong ba seed. Chỉ $n = 3$ trên cùng split nên chưa là bằng chứng thống kê mạnh hoặc khả năng tổng quát qua split/dataset; không chọn seed 43 theo test 99,29% làm kết quả đại diện.

5.7 Confusion matrix, lỗi và trùng ảnh



Hình 5.9: Trích 10 lớp liên quan nhiều ảnh sai của mỗi full pretrained seed 42; mẫu số vẫn là toàn bộ lớp thật trong 43 lớp.

Submatrix chỉ giữ 10 lớp nên tổng hàng hiển thị có thể nhỏ hơn 100%; không chuẩn hóa lại trên 10 lớp. Full 43×43 của cả hai model có trong output cell 28; Phụ lục liệt kê precision/recall/F1 của toàn bộ 43 lớp để tra cứu.

ResNet full nhầm 30/60 Pedestrians (ID 27) thành Road work (ID 25), recall Pedestrians 0,500, F1 0,667. DeiT full nhầm 30/60 Speed limit 20 (ID 0) thành Speed limit 120 (ID 8), recall lớp 0,500, F1 0,667. DeiT Pedestrians recall 0,883, F1 0,938, trong khi ResNet Speed 20 recall/F1 đều 1,000. Accuracy tổng cao không đảm bảo chất lượng mọi lớp hiếm.

Bảng 5.9: Một số lớp khó trong hai full model seed 42; test support và recall/F1.

Lớp	Support	Res recall	Res F1	DeiT recall	DeiT F1
Speed 20	60	1.000	1.000	.500	.667
Pedestrians	60	.500	.667	.883	.938
Bumpy road	120	.800	.881	.950	.970
Roundabout	90	.878	.919	.844	.916
Ice/snow	150	.940	.913	.960	.938

**Hình 5.10:** Các ảnh sai của hai full model seed 42; hàng trên ResNet, hàng dưới DeiT, ghi cả nhãn thật/dự đoán.

Ảnh mẫu cho thấy bóng che, mờ, thiếu sáng và ký hiệu có outline gần nhau. Đây là các yếu tố nhìn thấy trong ví dụ, chưa là bằng chứng nhân quả hoặc tỷ lệ lỗi do từng điều kiện. Nhiều ảnh có thể cùng track nên số ảnh sai không đồng nghĩa số biến vật lý độc lập.

Trên 12.622 test không trùng, accuracy 8 run chính thay đổi từ $-0,001$ đến $-0,019$ điểm phần trăm; macro-F1 không đôi khi làm tròn 4 chữ số. Hai full model lần lượt 98,37% và 98,91%, so với 98,37%/98,92% full test. Ảnh trùng ảnh hưởng nhỏ đến metric tổng ở lần chạy này nhưng vẫn là giới hạn độc lập; SHA256 chỉ phát hiện trùng byte, không loại mọi ảnh gần giống.

5.8 Kết luận A1 và giới hạn

Full pretrained được chọn bằng validation ở cả hai họ. DeiT có test accuracy cao hơn, ResNet có throughput tốt hơn trong protocol này.

Giới hạn gồm dữ liệu mất cân bằng, 8 test trùng train, nhiều frame cùng track, chỉ 3 seed cho full và 1 seed cho các regime khác; partial không matched capacity, ngân sách 40/25 epoch và learning rate khác scratch/pretrained. Không chuyển kết luận quan sát thành khẳng định một kiến trúc luôn thắng, hoặc augmentation/pretraining luôn giảm chi phí.

6. Kết luận

E1 cho thấy MLP phi tuyến cải thiện rõ so với classifier tuyến tính; CNN tiếp tục tăng accuracy bằng locality và chia sẻ trọng số. CNN-B dùng ít tham số hơn CNN-A nhưng chất lượng test tương đương trong một seed. E2 xác nhận MSA thủ công đúng qua parity forward/gradient; CNN-stem hữu ích trong cả hai implementation. Tăng số head không tạo cải thiện đơn điệu. E3 cho thấy rows tốt nhất trong các cách biểu diễn đã thử; GRU dùng ít tham số và chạy nhanh hơn LSTM cùng representation, nhưng CNN-B vẫn có accuracy cao hơn và thời gian/epoch thấp hơn.

A1 cho thấy fine-tune toàn bộ pretrained backbone cho kết quả tốt nhất theo validation trong hai family. Head-only tiết kiệm bộ nhớ nhưng accuracy thấp; partial là điểm cân bằng tùy family và phạm vi unfreeze. DeiT pretrained full có test accuracy trung bình ba seed cao hơn ResNet trong protocol này, trong khi ResNet suy luận nhanh hơn và dùng ít peak memory hơn ở full mode. Kết quả không thay thế kiểm chứng trên dataset khác hoặc nhiều seed hơn.

Hướng mở rộng gồm nhiều seed cho E1–E3, đối chiếu matched capacity và cùng ngân sách cập nhật; kiểm tra balanced sampling/class-weight cho GTSRB và độ ổn định theo track. Các hướng này là đề xuất, chưa được dùng để thay đổi protocol sau khi quan sát test trong báo cáo.

6.1 AI hỗ trợ và trách nhiệm kiểm chứng

Công cụ AI hỗ trợ hiện thực/kiểm tra code, tổng hợp output, đối chiếu đề bài, biên tập LaTeX và vẽ sơ đồ TikZ. Người thực hiện chạy full notebook A1 và cung cấp báo cáo mẫu; các số liệu được trích từ output lưu trên máy. Việc hiểu, giải thích và xác nhận phần đóng góp cá nhân của sản phẩm nộp thuộc người thực hiện. Khai báo này nêu phạm vi hỗ trợ thực tế, không tự nhận phần code hay phân tích do AI hỗ trợ là đóng góp độc lập của người học; tuân theo mục 1.6 của đề E1–E3.

Tài liệu tham khảo

- [1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, 2016. URL https://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html.
- [2] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. The german traffic sign recognition benchmark: A multi-class classification competition. In *International Joint Conference on Neural Networks*, pages 1453–1460, 2011.
- [3] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition. *Neural Networks*, 32:323–332, 2012. doi: 10.1016/j.neunet.2012.02.016.
- [4] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. German traffic sign recognition benchmark: Public archive, 2019. URL <https://sid.erda.dk/public/archives/daaeac0d7ce1152aea9b61d9f1e19370/published-archive.html>. Accessed 8 October 2026.
- [5] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Herve Jegou. Training data-efficient image transformers and distillation through attention. In *ICML*, 2021. URL <https://proceedings.mlr.press/v139/touvron21a.html>.
- [6] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms. *arXiv:1708.07747*, 2017. URL <https://arxiv.org/abs/1708.07747>.

A. Kết quả chi tiết và tái lập

A.1 Audit huấn luyện E1–E3

Các bảng dưới ghi số epoch đã chạy, best epoch, optimizer updates thực tế, AMP skips và peak allocated MiB. Chúng đối chiếu trực tiếp output cell, không suy số updates chỉ từ số epoch.

Bảng A.1: Audit E1.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
Softmax	24	14	10,128	0	19
MLP	26	16	10,972	0	23
CNN-A	18	8	7,596	0	52
CNN-B	40	30	16,878	2	57

Bảng A.2: Audit E2; ký hiệu M/T và R/P/C như Chương E2.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
M-R4	26	16	10,972	0	44
M-P4	40	30	16,879	1	69
M-C4	30	20	12,658	2	78
T-R4	26	16	10,972	0	47
T-P4	34	24	14,348	0	79
T-C4	34	24	14,346	2	89
M-C2	41	31	17,299	3	70
M-C8	28	18	11,816	0	98

Bảng A.3: Audit E3.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
LSTM Rows	24	14	10,128	0	27
LSTM Columns	29	19	12,238	0	27
LSTM Patch	34	24	14,348	0	34
GRU Rows	26	20	10,972	0	28
GRU Columns	29	19	12,238	0	28
GRU Patch	30	20	12,660	0	35
MLP	26	16	10,972	0	23
CNN-B	40	30	16,878	2	57

Bảng A.4: Epoch, cập nhật và peak memory của sáu run mở rộng A1.

Run	Epoch	Best	Updates	Peak MiB
R-F/42 no-aug	5	3	1,230	5831
R-F/43	8	4	1,968	5826
R-F/44	7	3	1,722	5827
D-F/42 no-aug	17	13	4,182	6633
D-F/43	22	18	5,412	6632
D-F/44	10	6	2,460	6632

A.2 Metric theo lớp và độ nhảy A1

Hai cột model là full pretrained seed 42, được chọn bằng validation. Support là số ảnh test nguồn. ID tra bằng bảng tên lớp dưới đây.

Bảng A.5: Precision/recall/F1 trên test GTSRB, lớp 0–21.

ID	Lớp	n	ResNet full			DeiT full		
			P	R	F1	P	R	F1
0	Speed limit 20	60	1.000	1.000	1.000	1.000	0.500	0.667
1	Speed limit 30	720	0.984	1.000	0.992	0.997	0.997	0.997
2	Speed limit 50	750	0.989	0.996	0.993	0.999	0.997	0.998
3	Speed limit 60	450	0.985	0.993	0.989	1.000	0.993	0.997
4	Speed limit 70	660	0.998	0.986	0.992	0.997	0.998	0.998
5	Speed limit 80	630	0.964	0.990	0.977	0.994	0.998	0.996
6	End speed limit 80	150	1.000	0.993	0.997	1.000	0.973	0.986
7	Speed limit 100	450	1.000	0.996	0.998	0.976	1.000	0.988
8	Speed limit 120	450	0.986	0.938	0.961	0.937	0.996	0.966
9	No passing	480	1.000	1.000	1.000	0.986	1.000	0.993
10	No passing >3.5t	660	0.990	1.000	0.995	0.998	1.000	0.999
11	Right-of-way intersection	420	0.976	0.955	0.965	0.978	0.971	0.975
12	Priority road	690	1.000	0.993	0.996	0.996	1.000	0.998
13	Yield	720	0.989	0.996	0.992	1.000	0.997	0.999
14	Stop	270	0.944	1.000	0.971	0.996	1.000	0.998
15	No vehicles	210	0.991	0.995	0.993	0.991	0.995	0.993
16	Vehicles >3.5t prohibited	150	1.000	1.000	1.000	0.987	1.000	0.993
17	No entry	360	1.000	0.956	0.977	1.000	0.969	0.984
18	General caution	390	1.000	0.992	0.996	0.982	0.990	0.986
19	Dangerous curve left	60	1.000	1.000	1.000	1.000	1.000	1.000
20	Dangerous curve right	90	1.000	1.000	1.000	1.000	1.000	1.000
21	Double curve	90	1.000	0.978	0.989	0.968	1.000	0.984

Bảng A.6: Precision/recall/F1 trên test GTSRB, lớp 22–42.

ID	Lớp	n	ResNet full			DeiT full		
			P	R	F1	P	R	F1
22	Bumpy road	120	0.980	0.800	0.881	0.991	0.950	0.970
23	Slippery road	150	0.974	1.000	0.987	0.968	1.000	0.984
24	Road narrows right	90	1.000	1.000	1.000	0.947	1.000	0.973
25	Road work	480	0.897	0.998	0.945	0.985	0.967	0.976
26	Traffic signals	180	1.000	0.994	0.997	1.000	0.972	0.986
27	Pedestrians	60	1.000	0.500	0.667	1.000	0.883	0.938
28	Children crossing	150	1.000	1.000	1.000	1.000	1.000	1.000
29	Bicycle crossing	90	0.978	1.000	0.989	1.000	1.000	1.000
30	Ice/snow caution	150	0.887	0.940	0.913	0.917	0.960	0.938
31	Wild animals crossing	270	0.996	1.000	0.998	0.993	1.000	0.996
32	End speed/passing limits	60	1.000	0.967	0.983	1.000	1.000	1.000
33	Turn right ahead	210	1.000	1.000	1.000	1.000	1.000	1.000
34	Turn left ahead	120	0.960	1.000	0.980	0.992	1.000	0.996
35	Ahead only	390	0.990	0.990	0.990	1.000	0.982	0.991
36	Straight or right	120	0.966	0.942	0.954	0.976	1.000	0.988
37	Straight or left	60	1.000	0.983	0.992	1.000	1.000	1.000
38	Keep right	690	0.993	0.988	0.991	0.989	1.000	0.994
39	Keep left	90	1.000	0.922	0.960	1.000	1.000	1.000
40	Roundabout mandatory	90	0.963	0.878	0.919	1.000	0.844	0.916
41	End no passing	60	0.984	1.000	0.992	1.000	1.000	1.000
42	End no passing >3.5t	90	0.978	1.000	0.989	0.927	0.989	0.957


Bảng A.7: Độ nhảy A1 với 8 ảnh test trùng train.

Run	Full acc	Clean acc	Δ (điểm%)	Full F1	Clean F1
R-S/42	96.33	96.33	-0.002	0.9447	0.9447
R-H/42	70.35	70.33	-0.019	0.6143	0.6143
R-P/42	96.05	96.05	-0.003	0.9438	0.9438
R-F/42	98.37	98.37	-0.001	0.9743	0.9743
D-S/42	96.14	96.13	-0.002	0.9350	0.9350
D-H/42	69.73	69.71	-0.019	0.6125	0.6125
D-P/42	87.85	87.85	-0.008	0.8063	0.8063
D-F/42	98.92	98.91	-0.001	0.9790	0.9790


Full test có 12.630 ảnh, clean test có 12.622; mọi accuracy là%. Bảng ghi mức làm tròn trong output; delta tính trên giá trị chưa làm tròn nên không nhất thiết bằng phép trừ hai cột accuracy hiển thị.

A.3 Ma trận nhầm lẫn E2 và E3


Mỗi cặp dùng cùng thang màu 0–100%, ghi cả count và tỷ lệ theo hàng. Toàn bộ 10.000 ảnh test mỗi model được đưa vào ma trận. Các model không được chọn/tune lại theo lỗi test ở các hình này.




Hình A.1: E2: confusion matrix test, cặp1; tên model ghi trên từng panel.




Hình A.2: E2: confusion matrix test, cặp2; tên model ghi trên từng panel.




Hình A.3: E2: confusion matrix test, cặp3; tên model ghi trên từng panel.




Hình A.4: E2: confusion matrix test, cặp4; tên model ghi trên từng panel.






Hình A.6: E3: confusion matrix test, cặp2; tên model ghi trên từng panel.



Hình A.7: E3: confusion matrix test, cặp3; tên model ghi trên từng panel.



Hình A.8: E3: confusion matrix test, cặp4; tên model ghi trên từng panel.

A.4 Nguồn số liệu và hướng dẫn tái lập

Nguồn số liệu là output đã lưu của E1.ipynb, E2.ipynb, E3.ipynb và A1.ipynb trong `source_code`. Manifest dưới `assets/e1`, `e2`, `e3`, `a1` ghi cell/output và bảng Markdown nguồn; PNG trích từ ảnh embedded trong notebook, không chạy training để tạo lại số liệu. Notebook không tự ghi assets của báo cáo.

Chuẩn bị dữ liệu theo README trong thư mục `datasets`. Mở notebook tương ứng, chọn Python 3.14 có CUDA, Restart Kernel và Run All, sau đó Save. Mỗi notebook chạy độc lập; không cần thứ tự. Để tái hiện đúng số liệu lịch sử E1–E3, cần dùng cấu hình `patience10` ghi trong output; mặc định code hiện tại là 4. A1 sử dụng `patience 4` như số liệu đã báo cáo. Seed cố định không đảm bảo tái lập bitwise qua mọi GPU, phiên bản thư viện hoặc đường thực thi AMP.

Báo cáo biên dịch bằng XeLaTeX và BibTeX từ `report/source_latex/main.tex`; các sơ đồ kiến trúc là mã TikZ trong từng chương, ảnh kết quả nằm ở `assets`. Sản phẩm PDF chung giữ tại `report/CO5085_Report.pdf`.