ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÁO CÁO BÀI TẬP

Môn: Học sâu và ứng dụng trong thị giác máy tính

Thực nghiệm học sâu cho phân loại ảnh và phát hiện đối tượng

E1 – E2 – E3 – A1 – A2

CO5085 – Học kỳ 261 (2026–2027)

Giảng viên: Lê Thành Sách

Thực hiện

Đặng Nguyễn Tấn Tài 2570357
Lương Minh Duy 2570083

Lớp: CH01

Thành phố Hồ Chí Minh, 10/2026

Tóm tắt

Báo cáo khảo sát năm nhóm thực nghiệm qua 36 lượt huấn luyện: bốn mô hình E1, tám cấu hình attention E2, tám cấu hình hồi tiếp/baseline E3, 14 cấu hình CNN/Transformer A1 và hai detector A2. E1–E3 dùng Fashion-MNIST với 54,000 ảnh train, 6,000 validation và 10,000 test. A1 dùng GTSRB 43 lớp, tách validation theo track biển báo. A2 dùng toàn bộ 11,540 ảnh VOC2012 trainval có nhãn, chia 9,232/1,154/1,154 thành train/validation/test nội bộ. Mỗi notebook độc lập, có vòng lặp PyTorch và lưu kết quả ngay trong output cell.

Trên Fashion-MNIST, CNN-A đạt test accuracy 91.66%; CNN-B đạt 91.45% với 94,186 tham số. MSA thủ công với CNN-stem đạt 90.50%; GRU theo hàng đạt 90.06%. Trên GTSRB, pretrained full ResNet-50 và DeiT-Small/16 ở seed 42 đạt 97.83% và 98.92%; trung bình ba seed là $97.95 \pm 0.21\%$ và $98.50 \pm 0.36\%$. Trên VOC2012, RetinaNet/Faster R-CNN đạt mAP50 70.88%/73.16% và COCO-style AP50:95 39.13%/40.98%. Không có kiến trúc tốt nhất trên mọi tiêu chí: kết quả được phân tích cùng chi phí, chất lượng từng lớp và các trường hợp sai. Sơ đồ TikZ thể hiện luồng tensor, kích thước feature map và cấu trúc head; số liệu/hình kết quả được lấy từ output notebook đã lưu.

Mục lục

Tóm tắt **i**

1 Bài toán và thiết kế thực nghiệm **1**

1.1 Mục tiêu và phạm vi 1

1.2 Dữ liệu và cách chia tập 1

1.3 Môi trường và quy tắc đánh giá 2

2 E1: Softmax, MLP và CNN **4**

2.1 Mục tiêu và kiến trúc 4

2.2 Huấn luyện 5

2.3 Kết quả định lượng và số tham số 5

2.4 Đường cong học và phân tích lỗi 5

3 E2: Multi-head self-attention và tokenization **8**

3.1 Mục tiêu và biểu diễn token 8

3.2 Kiến trúc encoder và MSA 8

3.3 Thiết lập huấn luyện và tám cấu hình 9

3.4 Kết quả và hai phép so sánh bắt buộc 10

3.5 Đường cong học, attention và lỗi 11

4 E3: LSTM và GRU trên chuỗi ảnh **16**

4.1 Biểu diễn ảnh thành chuỗi 16

4.2 Cell LSTM/GRU tự hiện thực 17

4.3 Mô hình đối chiếu và thiết lập huấn luyện 17

4.4 So sánh LSTM, GRU và cách biểu diễn 18

4.5 Đường cong học và phân tích lỗi 19

5 A1: CNN và Transformer trên GTSRB **22**

5.1 Dữ liệu, phân bố lớp và cách chia tập 22

5.2 DataLoader, augmentation và kiến trúc 26

5.3 Các cấu hình và thiết lập huấn luyện 27

5.4 Kết quả chính: CNN, Transformer và pretraining 28

5.5 Freeze, chi phí và đường cong học 30

5.6 Augmentation và độ biến thiên giữa seed 30
5.7 Ma trận nhầm lẫn, lỗi và ảnh trùng 33
5.8 Kết luận A1 và giới hạn 35

6 A2: RetinaNet và Faster R-CNN trên VOC2012 37
6.1 Bài toán và dữ liệu 37
6.2 Tiền xử lý và DataLoader 39
6.3 FPN: phương pháp, thí nghiệm và giới hạn 40
6.4 RetinaNet và Focal Loss 41
6.4.1 Động cơ và hàm mất mát 41
6.4.2 Neck, anchors và head 41
6.5 Faster R-CNN: RPN và RoI head 43
6.6 Huấn luyện và lựa chọn weights 43
6.7 Chỉ số đánh giá 45
6.8 Kết quả test và so sánh 45
6.9 Theo lớp, ma trận và trường hợp sai 50
6.10 Kết luận A2 và giới hạn 53

7 Kết luận 54

A Kết quả chi tiết và tái lập 57
A.1 Chi tiết huấn luyện E1–E3 và A1 57
A.2 Metric theo lớp và độ nhạy A1 58
A.3 Đường cong theo tokenizer và biểu diễn chuỗi 60
A.4 Ma trận nhầm lẫn E1–E3 66
A.5 Dữ liệu và chỉ số theo lớp A2 76
A.6 Ma trận chẩn đoán A2 78
A.7 Precision–recall theo lớp A2 81
A.8 Ảnh test và dự đoán A2 91
A.9 Trường hợp sai A2 94
A.10 Nguồn số liệu và hướng dẫn tái lập 96

1. Bài toán và thiết kế thực nghiệm

1.1 Mục tiêu và phạm vi

E1–E3 khảo sát biểu diễn ảnh và các họ classifier; A1 so sánh CNN/Transformer cùng các chế độ pretraining; A2 đối chiếu hai detector một/hai giai đoạn và phân tích FPN/Focal Loss.

Bảng 1.1: Đối chiếu nội dung kỹ thuật với đề E1–E3, A1 và A2.

Bài	Yêu cầu	Nội dung thực nghiệm
E1	Softmax, MLP, CNN; loop tự viết; accuracy, số tham số, curves, lỗi	4 mô hình, 2 CNN; bảng metric/chi phí, ma trận và ảnh sai.
E2	MSA thủ công/PyTorch; ≥ 2 tokenizer; so sánh từng cặp	2 cách cài đặt $\times$ 3 tokenizer, kiểm tra forward/gradient, H=2/4/8.
E3	LSTM/GRU, biểu diễn chuỗi và baseline MLP/CNN	2 cell $\times$ 3 cách quét, 2 baseline train độc lập trên cùng split.
A1	CNN/Transformer, scratch/pretrained, 3 mức freeze; metric/chi phí/lỗi	GTSRB 43 lớp, 8 cấu hình chính, 2 no-augmentation, 4 seed repeats.
A2	Detection, ≥ 2 phương pháp; mAP50, AP50:95 nếu được; phân tích paper	VOC2012, RetinaNet/Faster R-CNN, FPN/Focal Loss, AP/AR/F1/FPS và failure cases.

Các nội dung kỹ thuật được tổng hợp trong PDF này; video demo và việc công bố repository/Pages là các sản phẩm nộp riêng. Trang public cung cấp đường dẫn tới notebook, đề bài, báo cáo và nguồn LaTeX.

1.2 Dữ liệu và cách chia tập

Fashion-MNIST [13] gồm ảnh grayscale 28×28 của 10 loại sản phẩm: T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag và Ankle boot. Từ 60,000 ảnh train nguồn, lấy 600 ảnh/lớp làm validation với seed 42; giữ nguyên official test 10,000 ảnh.

Bảng 1.2: Ba tập dữ liệu sử dụng trong báo cáo.

Bài	Dataset	Lớp	Train	Val	Test
E1–E3	Fashion-MNIST	10	54,000	6,000	10,000
A1	GTSRB	43	31,380	7,829	12,630
A2	VOC2012	20	9,232	1,154	1,154

Fashion-MNIST được chia cân bằng theo lớp, mỗi lớp có 5,400 ảnh train, 600 ảnh validation và 1,000 ảnh test. Pixel chuyển về $[0, 1]$, chuẩn hóa bằng mean 0.285886 và std 0.352960 tính từ train; không augmentation. E1–E3 sử dụng cùng cách chia tập.

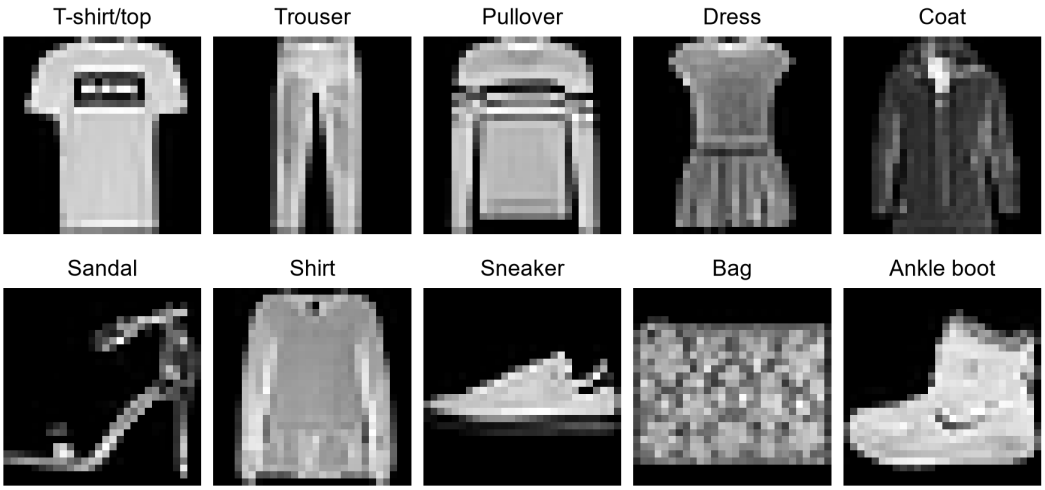

Hình 1.1: Ảnh đại diện mười lớp Fashion-MNIST, lấy trực tiếp từ dữ liệu train.

GTSRB chia theo track để hạn chế các frame cùng biển vật lý rơi vào cả train và validation. VOC2012 chia theo ảnh; test là holdout nội bộ. Chi tiết nhãn, augmentation, nguồn tải và giới hạn độc lập dữ liệu được trình bày ở từng chương và README dataset.

1.3 Môi trường và quy tắc đánh giá

E1–E3/A1 chạy với Python 3.14.7, PyTorch 2.11.0+cu128, torchvision 0.26.0+cu128, NumPy 2.5.2, Matplotlib 3.11.2 và Pillow 12.3.0 chạy trên Windows, GPU NVIDIA RTX A3000 12 GB Laptop, CUDA 12.8. A2 chạy trên Kaggle với hai Tesla T4, mỗi GPU 14.6 GiB khả dụng; metadata notebook ghi Python 3.13.15. Phiên bản thư viện A2 không được ghi trong output đã lưu. Hai model train song song trên hai GPU riêng, test/benchmark lần lượt trên cùng GPU 0. DataLoader workers 0 ở các bài. Training loop thực hiện forward, loss, backward và optimizer step; AMP/GradScaler hỗ trợ train, validation/test không tính gradient.

Với các bài phân loại E1–E3/A1, cross-entropy tính trực tiếp trên logits:

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N} \log \frac{\exp z_{i,y_i}}{\sum_{c=1}^{C} \exp z_{i,c}}. \tag{1.1}$$

Softmax chỉ cần khi diễn giải xác suất; argmax logits cho cùng nhãn. Loss được tổng hợp theo số ảnh. Accuracy là tỷ lệ dự đoán đúng; $F1_c = 2P_cR_c/(P_c + R_c)$, macro-F1 trung bình đều qua các lớp. Ma trận có hàng là GT, cột là prediction; phần trăm chuẩn hóa theo hàng.

E1–E3 dừng sớm theo validation loss, patience 4 và min-delta 10^{-4}. A1 dùng patience 2 và min-delta 10^{-3} theo validation loss. Checkpoint phân loại giữ validation loss nhỏ nhất; đại diện/ablation chọn bằng validation accuracy, macro-F1 rồi loss. A2 chọn weights và dừng sớm theo validation VOC mAP50, patience 2, min-delta 10^{-3}. Cách matching và detection metrics trình bày ở Chương 6. Mọi lựa chọn cấu hình dùng validation trước khi đánh giá test.

Bảng 1.3: Quy mô các lượt huấn luyện tạo ra số liệu báo cáo.

Bài	Lượt train	Epoch	CUDA updates	AMP skips
E1	4	64	27,008	0
E2	8	177	74,693	1
E3	8	168	70,896	0
A1	14	94	23,124	0
A2	2	38	14,630	0
Tổng	36	541	210,351	1

AMP skips không tính vào optimizer updates. Train accuracy đo trong train mode với dropout/augmentation; validation dùng eval mode. Thời gian train gồm validation, không gồm test/vẽ hình; peak là allocated PyTorch, không phải reserved hay tổng VRAM máy.

Mỗi notebook tự chứa dataset/model/loop và giữ một best weights tại model/<bài>/<thí nghiệm>/latest.pt, chỉ thay khi validation tốt hơn. Run All nạp weights nếu có, hoặc khởi tạo theo seed; optimizer/scheduler, epoch/early-stop counter và RNG bắt đầu cho lượt hiện tại. Cơ chế này không khôi phục đầy đủ trạng thái train như full resume. Bảng/hình nằm trong output; A2 Kaggle còn xuất PNG/CSV và history dưới /kaggle/working. Sơ đồ dùng $H \times W \times C$ cho feature, $N \times D$ cho token, bỏ chiều batch; hình khối gợi kích thước không gian/channels, không cùng tỷ lệ hình học.

2. E1: Softmax, MLP và CNN

2.1 Mục tiêu và kiến trúc

E1 so sánh Softmax tuyến tính, MLP và hai CNN trên cùng Fashion-MNIST. Softmax/MLP nhận vector 784 chiều; CNN giữ cấu trúc không gian. CNN-A dùng head flatten lớn, CNN-B dùng global average pooling.

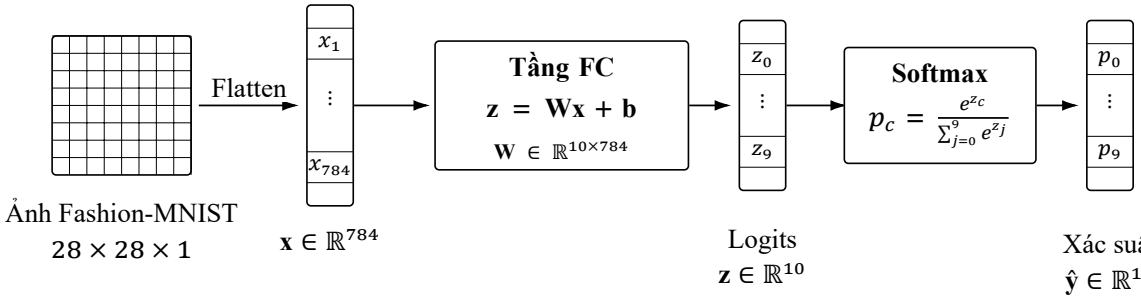

(a) Softmax: một FC, 7,850 tham số.

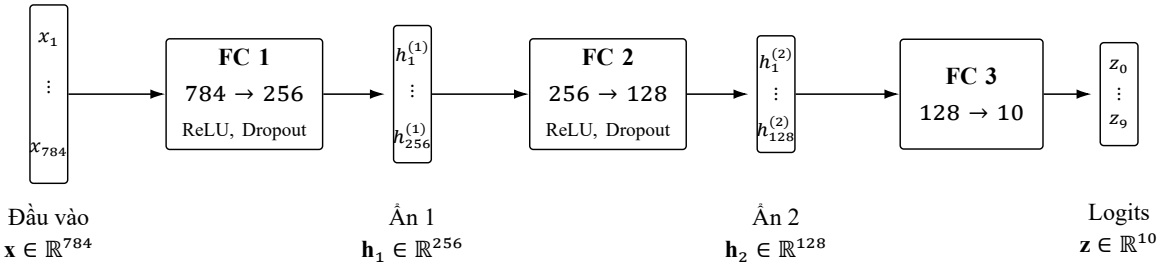

(b) MLP: ba FC, 235,146 tham số.

Hình 2.1: Classifier vector E1: (a) tuyến tính, (b) hai tầng ẩn phi tuyến; input Fashion-MNIST 28×28.

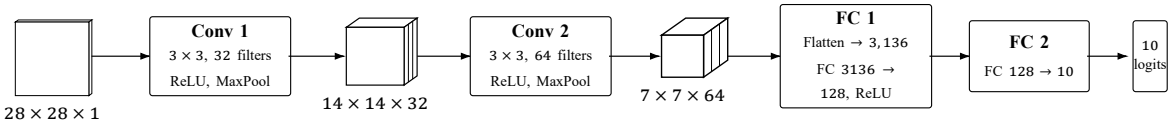

(a) CNN-A: hai Conv/MaxPool, hai FC, 421,642 tham số.

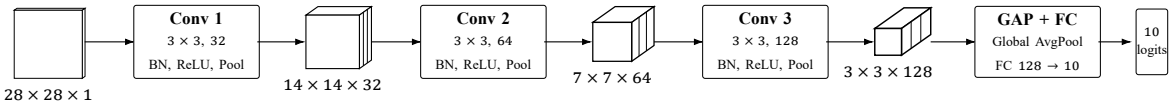

(b) CNN-B: ba Conv/BN/MaxPool, một FC, 94,186 tham số.

Hình 2.2: CNN E1: Conv kernel 3×3, stride 1, padding 1; (a) có bias và flatten, (b) không bias và global average pooling, feature sau pool cuối 3×3.

Ký hiệu 3^2 chỉ kernel 3×3; chiều batch được lược khỏi sơ đồ. CNN-A dành 401,536 tham số cho FC $3136 \rightarrow 128$, khoảng 95.2% tổng số tham số. CNN-B thay head này bằng average pooling, nên ít tham số hơn dù có thêm một Conv.

2.2 Huấn luyện

AdamW LR 10^{-3}, weight decay 10^{-4}, batch 128, tối đa 100 epoch; AMP train, không augmentation/scheduler. Mỗi epoch có 422 train và 47 validation batches; test có 79, giữ batch cuối. Loop forward/loss/backward/update tự viết. Dừng sớm theo validation loss, patience 4, min-delta 10^{-4}; Quy tắc chọn checkpoint và đánh giá theo Chương 1.

2.3 Kết quả định lượng và số tham số

Bảng 2.1: Kết quả E1 trên validation và 10,000 ảnh test; F1 là macro-F1.

Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
Softmax	86.04	85.05	0.8495	84.11	0.8401	0.4431
MLP	91.58	89.47	0.8951	89.45	0.8948	0.3142
CNN-A	94.61	92.00	0.9203	91.66	0.9169	0.2339
CNN-B	93.63	91.93	0.9195	91.45	0.9144	0.2333

Bảng 2.2: Số tham số và chi phí E1; thời gian gồm train và validation.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
Softmax	7,850	12/8	16.35	1.363	18
MLP	235,146	20/16	44.87	2.244	22
CNN-A	421,642	12/8	38.76	3.230	50
CNN-B	94,186	20/16	78.04	3.902	56

MLP cải thiện test accuracy so với Softmax, trong khi cả hai CNN đạt kết quả cao hơn MLP trong protocol đã thử. CNN-A đạt 91.66% test accuracy; CNN-B đạt 91.45% với số tham số ít hơn khoảng 4.48 lần. Đây là đánh đổi giữa accuracy và số tham số thuận lợi cho CNN-B, nhưng hai CNN khác nhau về độ sâu, BatchNorm và classifier head nên không thể quy chênh lệch chỉ cho số tham số.

2.4 Đường cong học và phân tích lỗi

Đường cong ở Hình 2.3 cho thấy train loss giảm khi validation dao động. Gap accuracy train–validation tại best checkpoint là 0.99/2.11/2.61/1.70 điểm (Softmax/MLP/CNN-A/CNN-B), cần diễn giải theo khác biệt train/eval ở Chương 1.

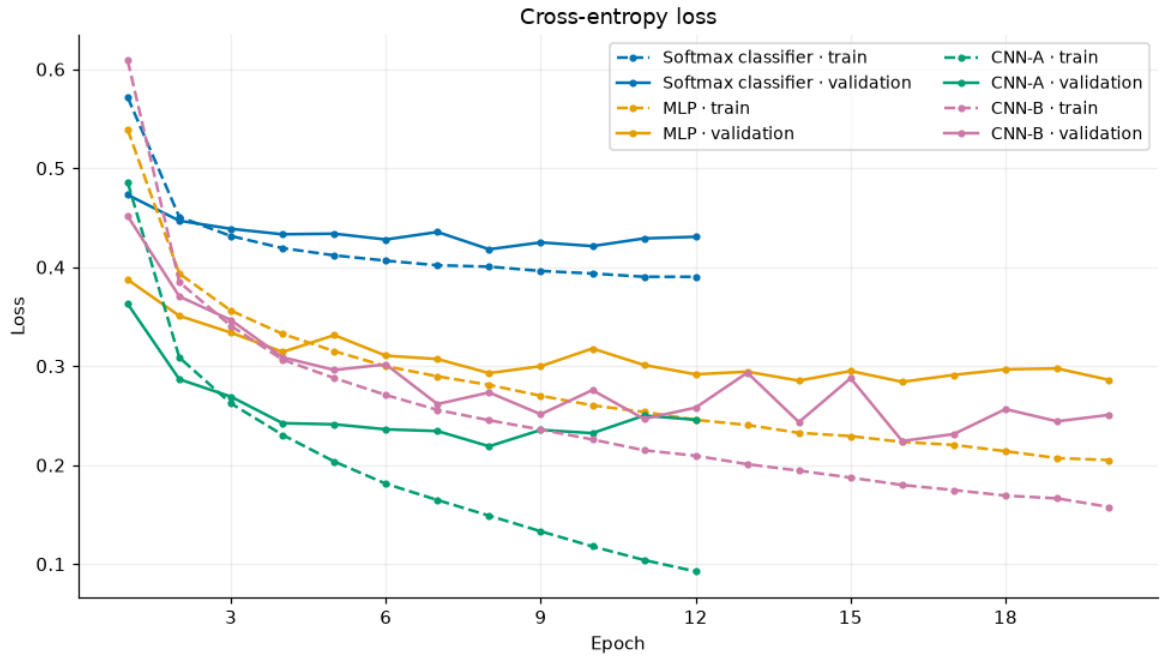

(a) Cross-entropy

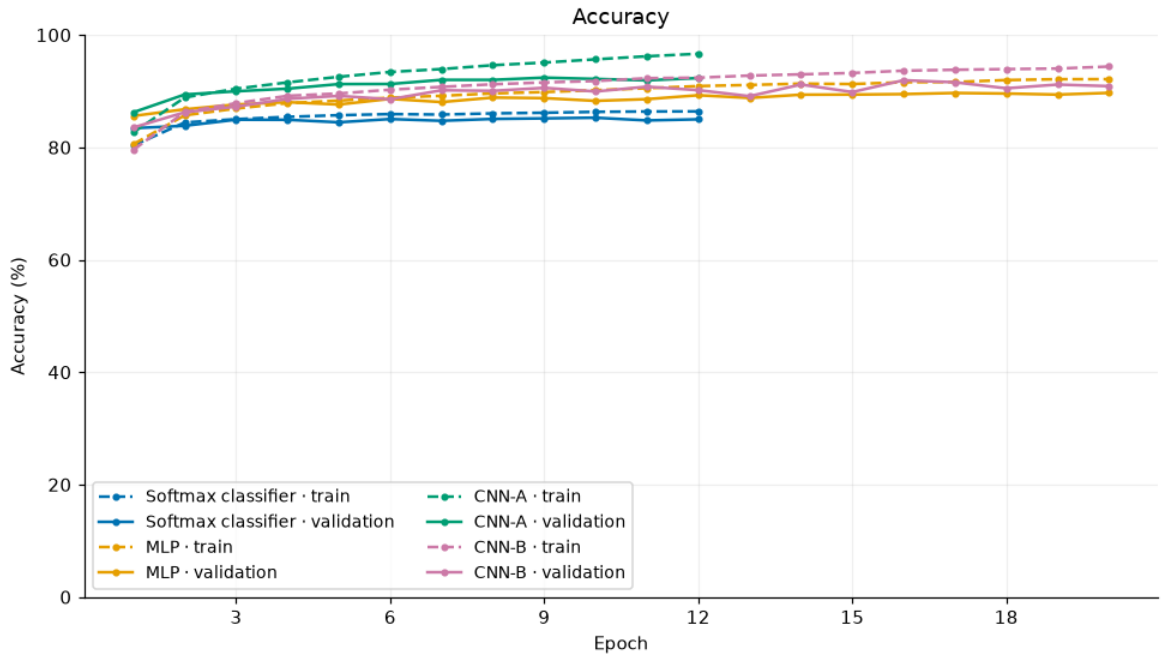

(b) Accuracy (%).

Hình 2.3: E1 trên train/validation: bốn model; train nét đứt, validation nét liền.

Bảng 2.3: Cặp lớp nhầm nhiều nhất trên test; mỗi lớp có 1,000 ảnh.

Model	Thật → dự đoán	Số ảnh	% lớp thật
Softmax	Pullover → Coat	136	13.6%
MLP	T-shirt/top → Shirt	124	12.4%
CNN-A	T-shirt/top → Shirt	137	13.7%
CNN-B	Shirt → Coat	103	10.3%

Recall của lớp Shirt lần lượt đạt 57%, 75%, 79% và 73% đối với Softmax, MLP, CNN-A và CNN-B. Các cặp nhầm lẫn chính được tổng hợp trong Bảng 2.3; ma trận đầy đủ nằm ở Phụ lục. Các ảnh minh họa không đại diện cho phân bố lỗi toàn tập. Kết luận giới hạn ở một seed trên Fashion-MNIST.

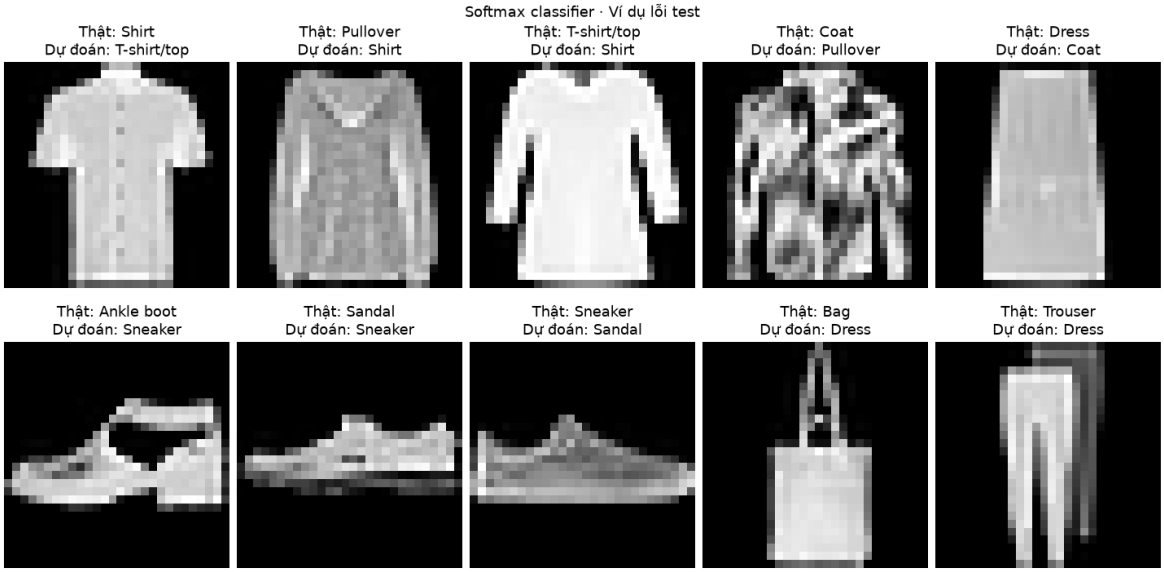

(a) Softmax

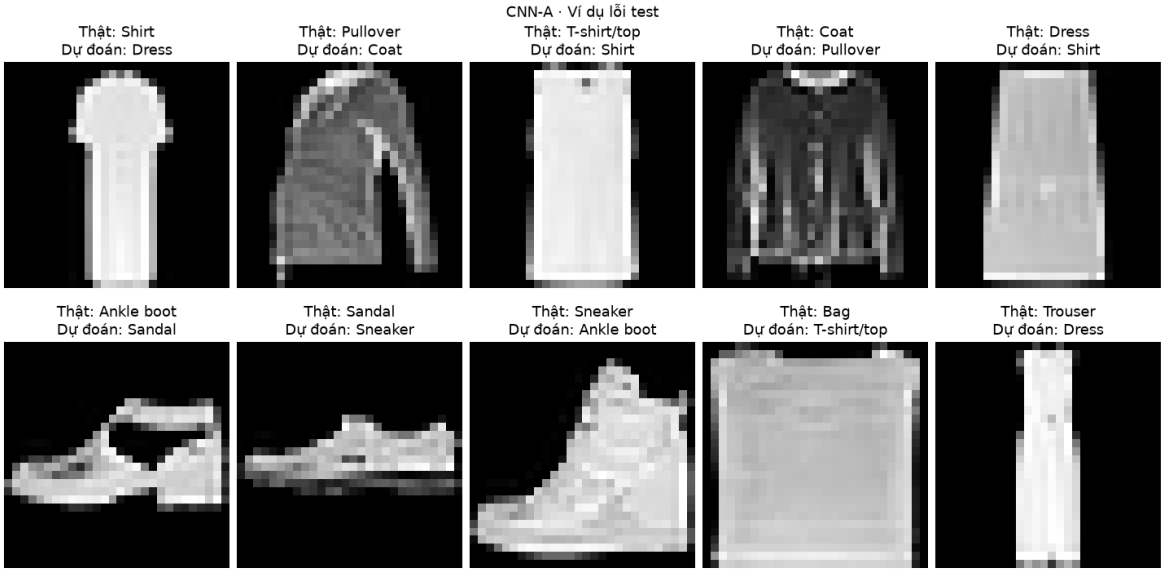

(b) CNN-A

Hình 2.4: Mẫu lỗi test E1; mỗi panel gồm 2 × 5 ảnh, nhãn thật và dự đoán. Đây là minh họa; tần suất lỗi dùng bảng và ma trận toàn test.

3. E2: Multi-head self-attention và tokenization

3.1 Mục tiêu và biểu diễn token

MSA thủ công dùng Linear/reshape/matmul/softmax/concat; bản tham chiếu dùng nn.MultiheadAttention. Encoder/head, split và normalization giống nhau; ba tokenizer được định nghĩa độc lập trong E2.

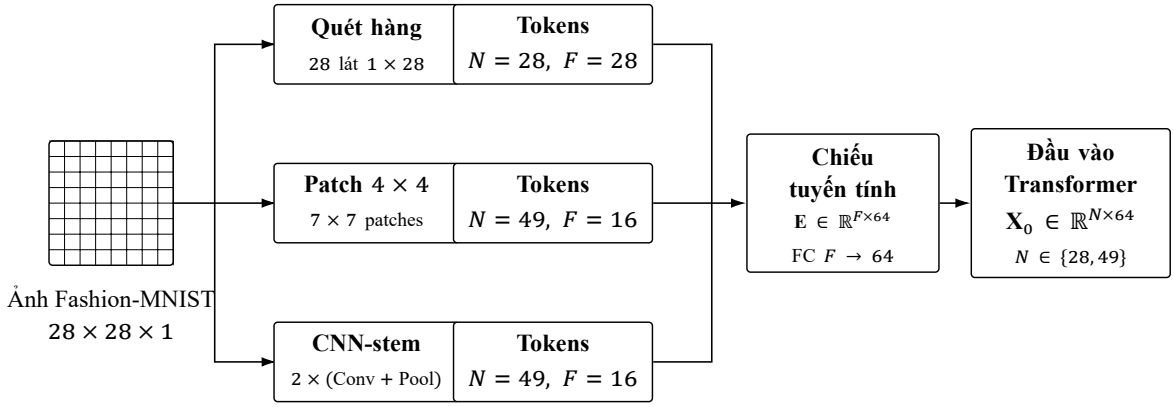

Hình 3.1: Ba tokenizer E2; CNN-stem có hai Conv kernel 3, stride 1, padding 1, bias, ReLU và MaxPool 2 sau mỗi Conv. Rows không có Conv; patch lấy trực tiếp pixel.

Rows có $N = 28, F = 28$; patch/CNN-stem có $N = 49, F = 16$. CNN-stem thêm 2,480 tham số học so với patch cùng chiều feature, nên so sánh tokenizer thay đổi cả inductive bias và số tham số.

3.2 Kiến trúc encoder và MSA

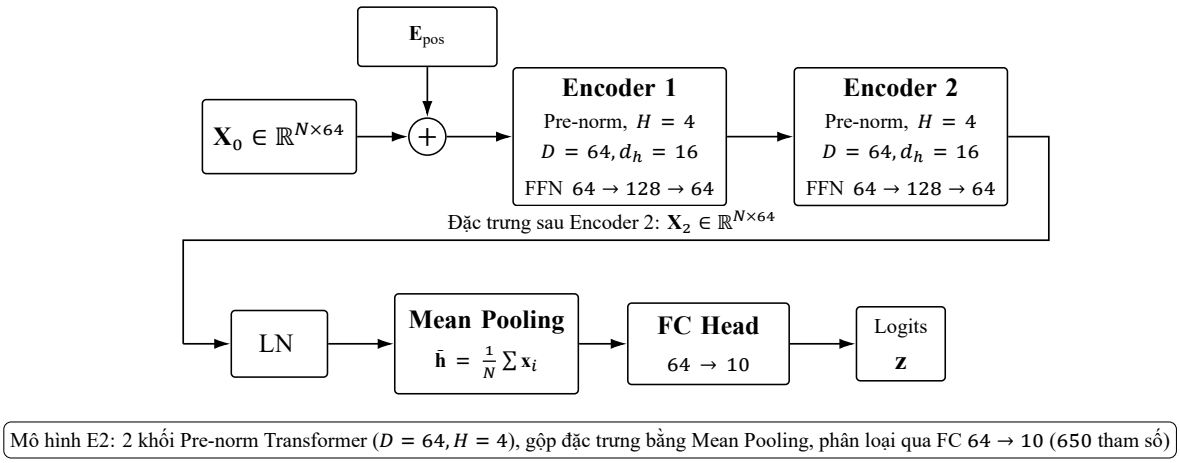

Hình 3.2: Classifier E2: một FC embedding, hai encoder block và một FC head; không CLS token.

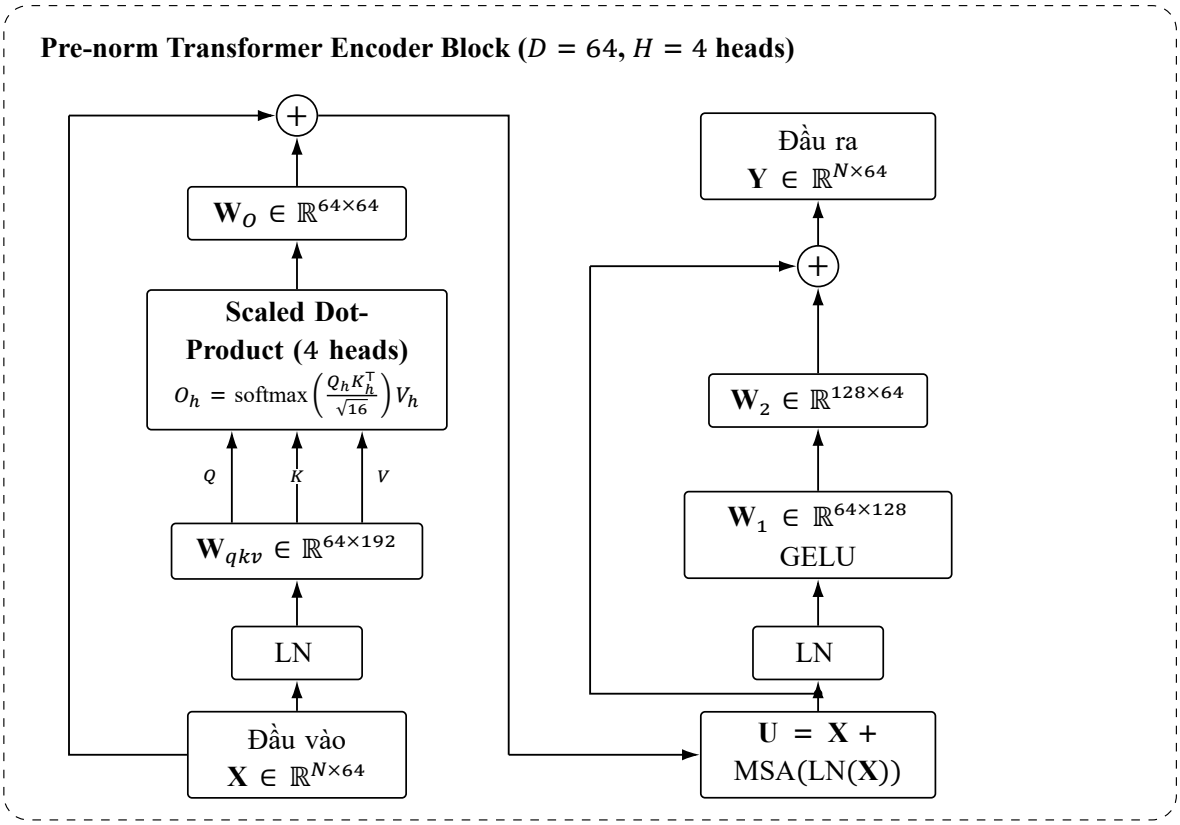

Hình 3.3: Một pre-norm encoder block: hai projection MSA và hai FC trong FFN, tổng bốn ánh xạ Linear/block. Đường ngoài là residual.

Với $D = 64, H = 4, d_h = 16$, QKV reshape thành $B \times H \times N \times d_h$:

$$A_h = \text{softmax}_{\text{key}}\left(Q_h K_h^\top / \sqrt{d_h}\right), \qquad Y = \text{Concat}_{h=1}^{H}(A_h V_h) W_O + b_O. \tag{3.1}$$

Attention dropout 0.1 áp dụng lên A_h trước khi nhân V_h; output dropout nằm trên nhánh residual. Mỗi block có FFN $64 \to 128 \to 64$, GELU, dropout 0.1. Toàn classifier có 10 ánh xạ Linear theo cách đếm QKV gộp là một Linear: 1 embedding + 2×4 trong encoder + 1 head. CNN-stem bổ sung 2 Conv.

Hai bản copy toàn bộ initial weights, gồm tokenizer, position, FFN và head. CUDA float64 với dropout tắt cho sai số forward tối đa 1.665×10^{-16}; gradient input/weight/bias khớp kiểm tra. Đây là parity phép toán, không bảo đảm dropout/RNG tạo cùng đường tối ưu khi train.

3.3 Thiết lập huấn luyện và tám cấu hình

AdamW learning rate 10^{-3}, weight decay 10^{-4}, batch 128, tối đa 100 epoch; early stopping dùng validation loss, patience 4, min-delta 10^{-4}. Sáu cấu hình chính là Manual/PyTorch × Rows/Patch/CNN-stem với H=4. CNN-stem được chọn từ các cấu hình Manual bằng validation, rồi thử thêm H=2 và H=8; giữ $D = 64$, tương ứng mỗi head có 32/16/8 chiều.

Ký hiệu bảng: M=Manual, T=PyTorch; R=Rows, P=Patch, C=CNN-stem; số cuối là số head. M-C4 là Manual CNN-stem với bốn head.

3.4 Kết quả và hai phép so sánh bắt buộc

Bảng 3.1: Kết quả tám cấu hình E2; test dùng đầy đủ 10,000 ảnh, F1 là macro-F1.

Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
M-R4	91.61	89.97	0.8988	89.51	0.8941	0.3050
M-P4	90.39	88.60	0.8861	88.35	0.8837	0.3305
M-C4	92.18	90.65	0.9063	90.50	0.9048	0.2717
T-R4	91.75	89.90	0.8983	89.22	0.8913	0.3054
T-P4	90.33	88.35	0.8833	88.47	0.8849	0.3292
T-C4	92.09	90.47	0.9049	90.17	0.9021	0.2733
M-C2	91.42	90.33	0.9037	90.21	0.9023	0.2792
M-C8	92.13	90.35	0.9031	90.23	0.9020	0.2752

Bảng 3.2: Số tham số, epoch và thời gian của tám cấu hình E2.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
M-R4	71,370	20/16	189.93	9.497	43
M-P4	71,946	23/19	243.28	10.577	69
M-C4	74,426	24/20	243.08	10.128	78
T-R4	71,370	20/16	186.63	9.332	47
T-P4	71,946	23/19	242.75	10.554	79
T-C4	74,426	23/19	198.74	8.641	89
M-C2	74,426	22/18	213.65	9.711	70
M-C8	74,426	22/18	215.44	9.793	99

Bảng 3.3: Manual và PyTorch ở H=4 với cùng tokenizer; chênh lệch tính theo điểm phần trăm.

Tokenizer	M val (%)	T val (%)	Δ val (điểm %)	M/T s/epoch
Rows	89.97	89.90	+0.07	9.497 / 9.332
Patch	88.60	88.35	+0.25	10.577 / 10.554
CNN-stem	90.65	90.47	+0.18	10.128 / 8.641

Với cùng tokenizer và $H = 4$, hai cách cài đặt MSA cho chất lượng gần nhau; sai khác validation chỉ ở mức vài phần mười điểm phần trăm. Kiểm tra forward/gradient xác nhận tính tương đương phép toán trong điều kiện thử nghiệm, không bảo đảm hai đường tối ưu huấn luyện giống hệt nhau. CNN-stem đạt validation accuracy cao nhất trong ba tokenizer ở cả hai bản, nhưng tăng đồng thời inductive bias và số tham số so với patch thuần.

Thời gian mỗi epoch của PyTorch thấp hơn Manual 1.7% với Rows, 0.2% với Patch và 14.7% với CNN-stem. Rows dùng 28 token, Patch/stem dùng 49; số phần tử attention mỗi head tăng từ 784 lên 2,401 (3.06 lần). Chi phí còn gồm projections, FFN và CNN; không suy thời gian chỉ từ N^2.

Ảnh hưởng số head được kiểm tra trên Manual CNN-stem khi giữ $D = 64$.

Bảng 3.4: H=2/4/8, $d_h = D/H$, cùng 74,426 tham số.

H	d_h	Val (%)	Test (%)	Test F1	Params
2	32	90.33	90.21	0.9023	74,426
4	16	90.65	90.50	0.9048	74,426
8	8	90.35	90.23	0.9020	74,426

H=4 đạt validation accuracy cao nhất trong ba lượt (Hình 3.4); khác biệt trên một seed chưa chứng minh một số head tối ưu tổng quát.

3.5 Đường cong học, attention và lỗi

Gap tại best checkpoint là 1.09–1.98 điểm; loss/accuracy CNN-stem ở Hình 3.5, Rows/Patch ở Phụ lục. Attention lấy từ block cuối M-C4, trung bình bốn head, gộp 49 token thành bảy nhóm. Shirt (index 0) và Ankle boot (index 31) là hai ảnh validation dự đoán đúng; mỗi hàng attention tổng bằng 1 trước làm tròn.

Bảng 3.5: Entropy attention chuẩn hóa theo head; số đọc từ biểu đồ, làm tròn ba chữ số.

Ảnh	H1	H2	H3	H4
Shirt	0.864	0.582	0.658	0.844
Ankle boot	0.326	0.694	0.736	0.698

Entropy thấp biểu thị attention tập trung: head 1 của Ankle boot là 0.326, so với 0.864 ở Shirt. Trọng số này kết hợp token sau CNN-stem, không phải saliency pixel hay bằng chứng nhân quả; hai ảnh không đại diện toàn dataset.

Bảng 3.6: Cặp lớp nhầm nhiều nhất của từng cấu hình E2 trên test.

Model	Thật → dự đoán	Số ảnh	% lớp thật
M-R4	Shirt → T-shirt/top	139	13.9%
M-P4	T-shirt/top → Shirt	120	12.0%
M-C4	Shirt → T-shirt/top	94	9.4%
T-R4	Shirt → T-shirt/top	129	12.9%
T-P4	T-shirt/top → Shirt	126	12.6%
T-C4	T-shirt/top → Shirt	151	15.1%
M-C2	T-shirt/top → Shirt	141	14.1%
M-C8	Shirt → T-shirt/top	119	11.9%

M-C4 nhầm Shirt thành T-shirt/top 94 ảnh, so với M-R4 139; T-C4 nhầm chiều ngược 151 ảnh. Nhóm áo vẫn khó dù CNN-stem có accuracy cao hơn. Ma trận tám cấu hình ở Phụ lục. Encoder nhỏ, một seed và tokenizer khác số tham số giới hạn khả năng suy rộng kết quả.

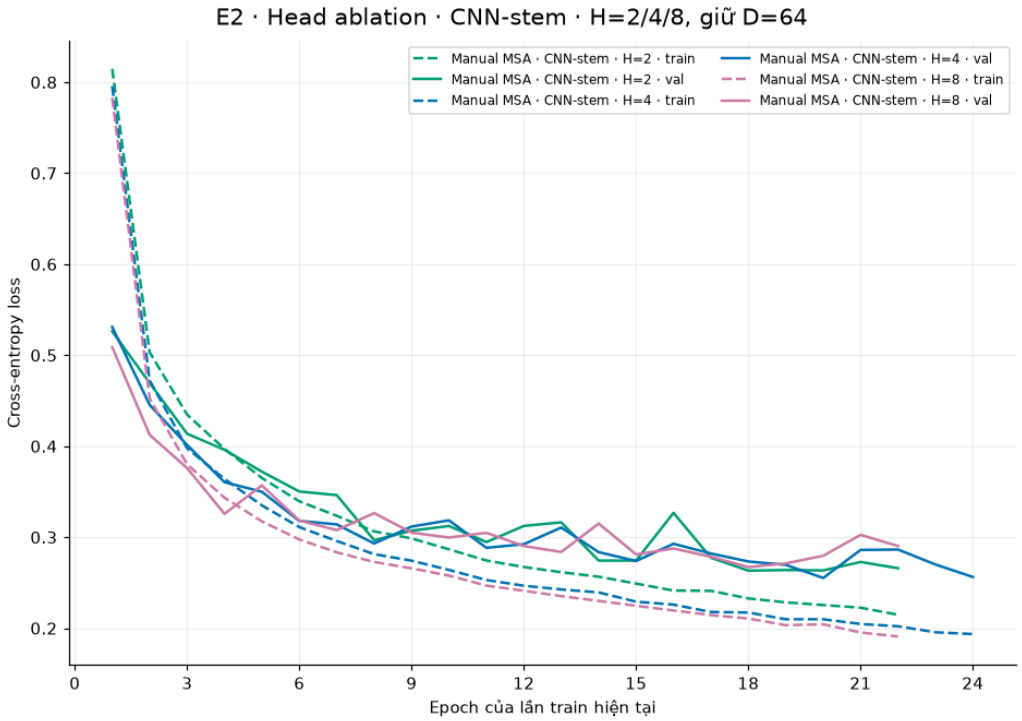

(a) Cross-entropy

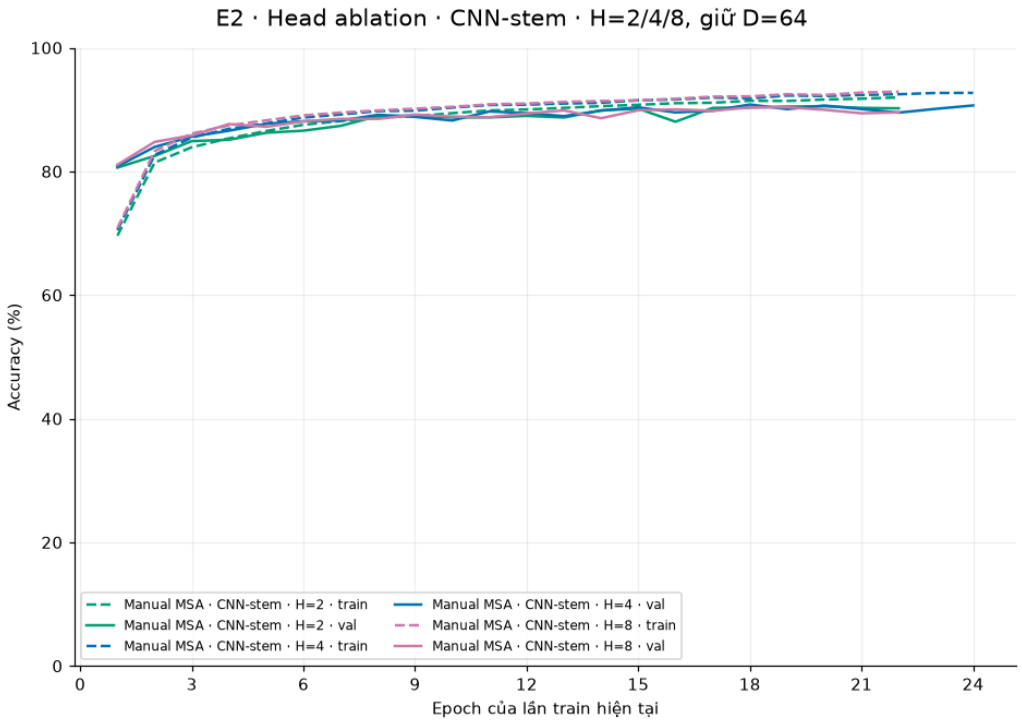

(b) Accuracy (%).

Hình 3.4: Head ablation E2, Manual CNN-stem H=2/4/8; train và validation trên cùng split.

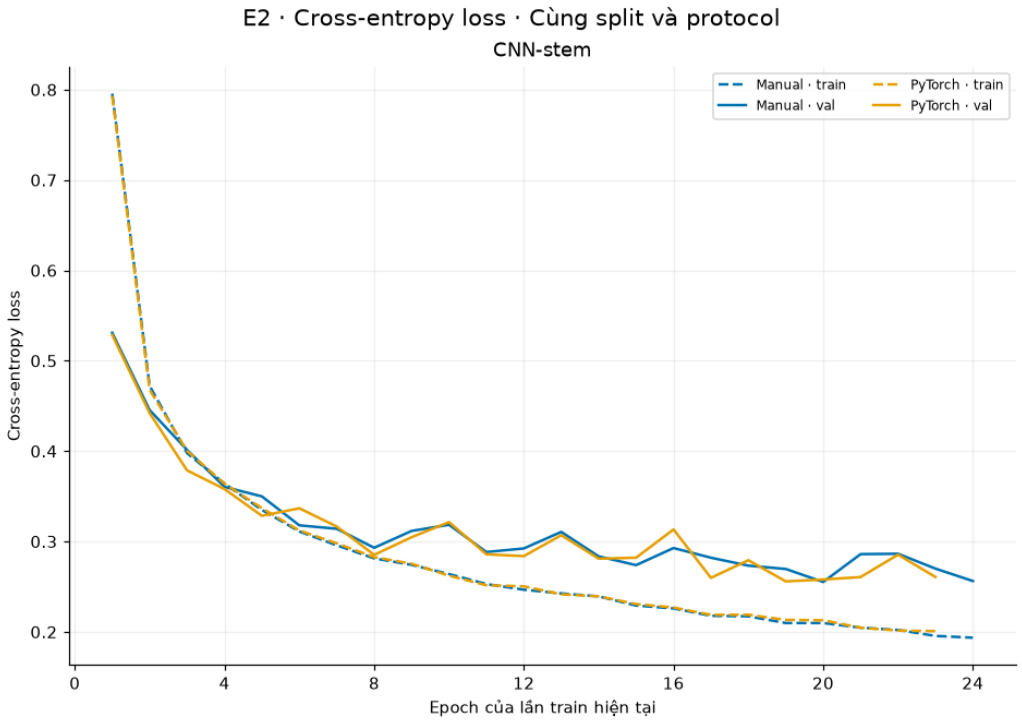

(a) Cross-entropy

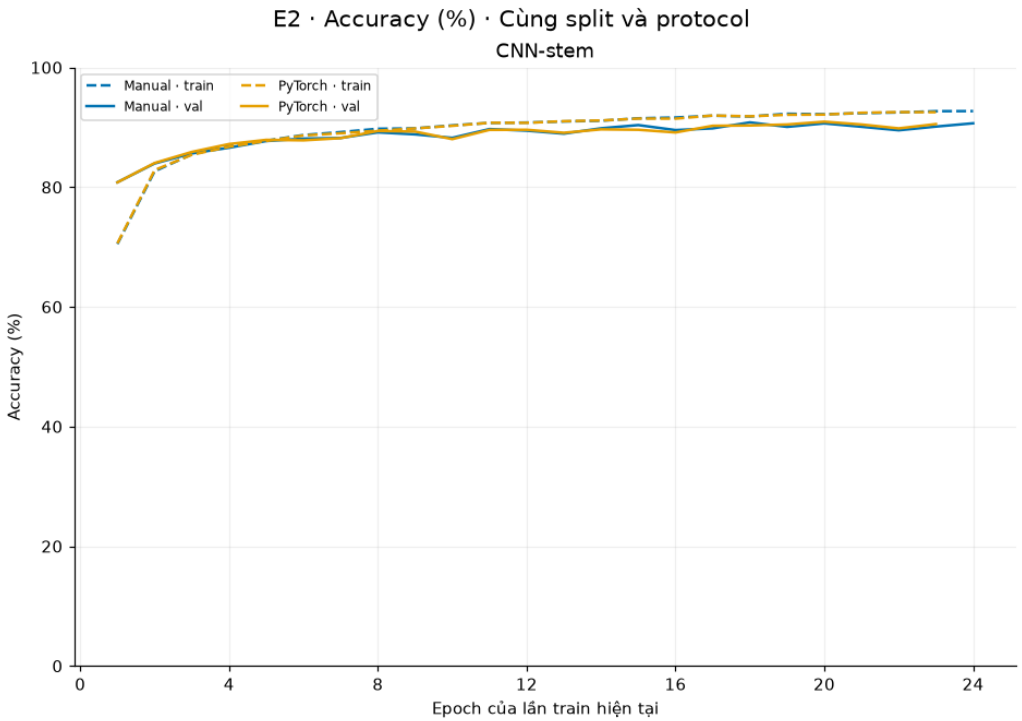

(b) Accuracy (%).

Hình 3.5: E2 CNN-stem H=4: Manual/PyTorch trên train/validation, train nét đứt và validation nét liền.

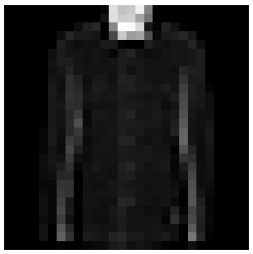

(a) Shirt, index 0; confidence 99.6%.

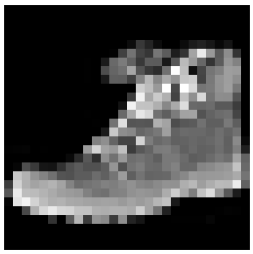

(b) Ankle boot, index 31; confidence 97.5%.

Hình 3.6: Hai ảnh validation phân tích attention M-C4; dự đoán và confidence từ output đã lưu.

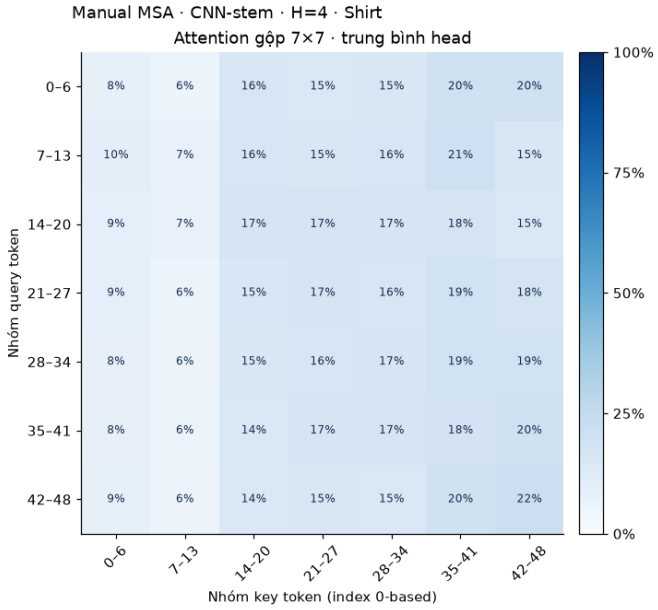

(a) Shirt

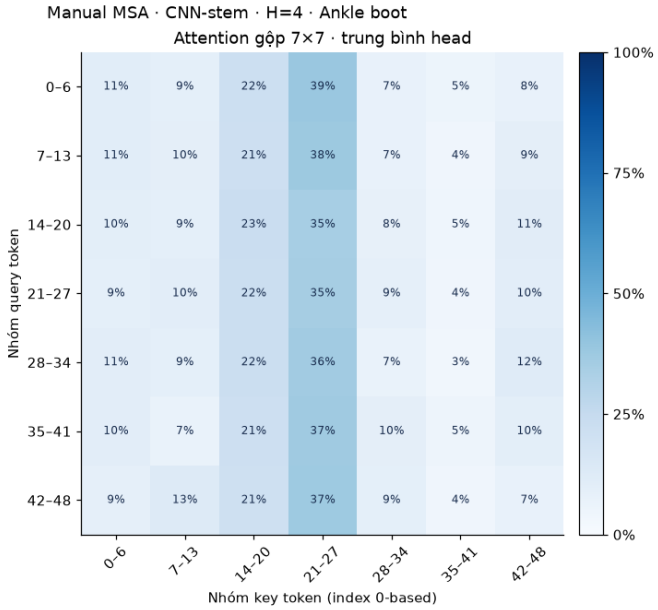

(b) Ankle boot

Hình 3.7: Attention M-C4: hàng query, cột key, bảy nhóm token sau CNN-stem; trung bình bốn head, mỗi hàng chuẩn hóa về 1, cùng thang 0–100%.

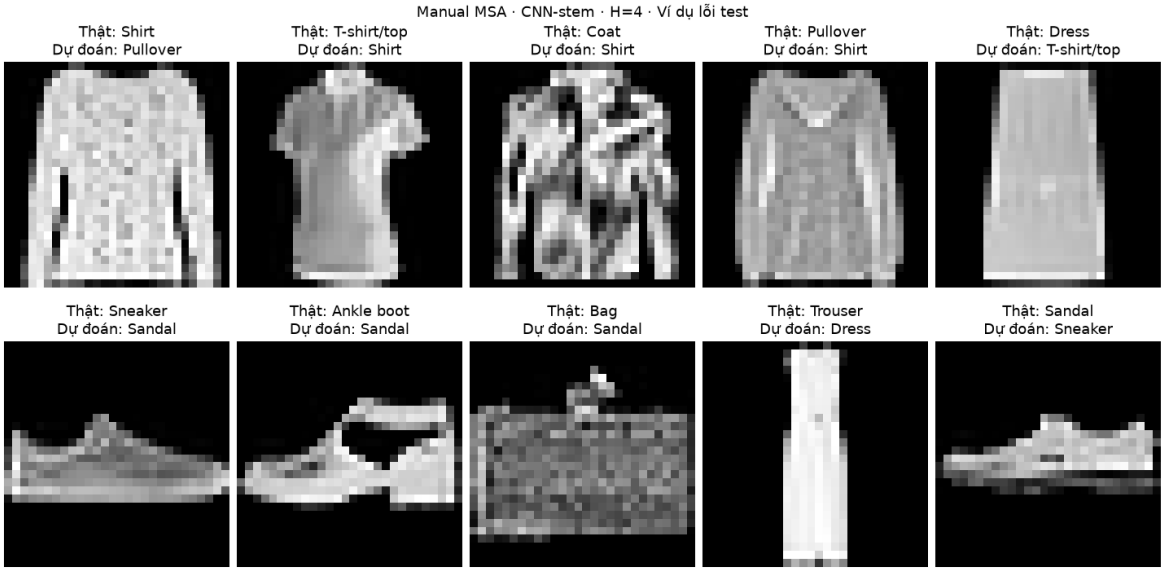

(a) Manual CNN-stem H=4

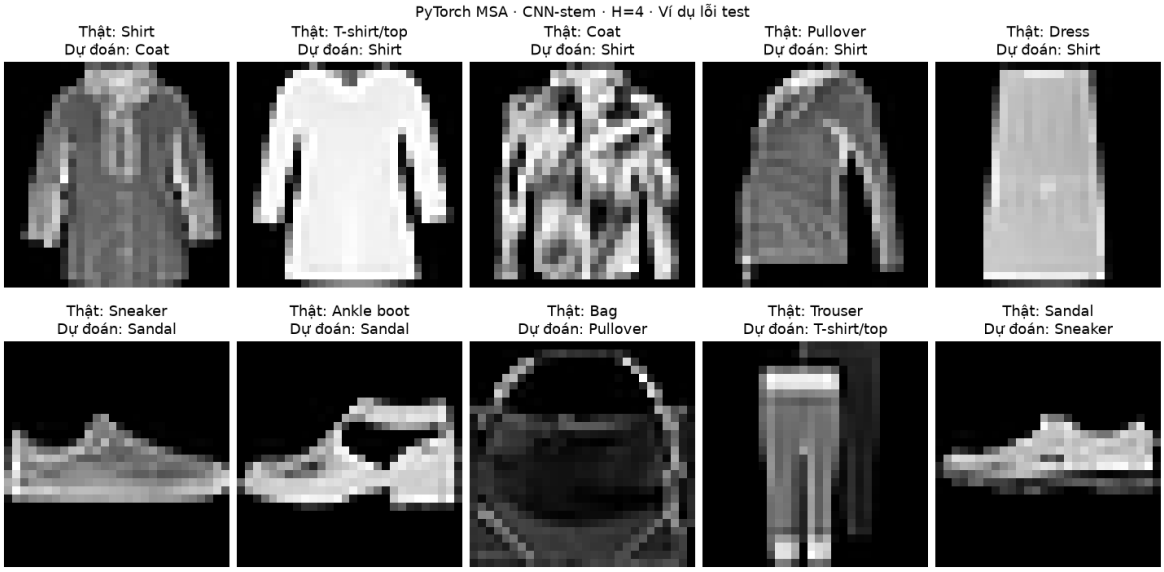

(b) PyTorch CNN-stem H=4

Hình 3.8: Mẫu lỗi test E2, mỗi panel 2 × 5 ảnh có nhãn thật/dự đoán; không dùng bộ ảnh minh họa suy tần suất toàn tập.

4. E3: LSTM và GRU trên chuỗi ảnh

4.1 Biểu diễn ảnh thành chuỗi

E3 đọc ảnh như một chuỗi các vector và phân loại bằng hidden state cuối. Rows quét từ trên xuống, mỗi token là 28 pixel của một hàng. Columns quét từ trái sang phải, mỗi token là 28 pixel của một cột. Patch 4×4 không overlap, quét raster trái–phải rồi trên–dưới, tạo 49 bước, mỗi bước 16 pixel. Không thêm CNN/token embedding trước recurrent.

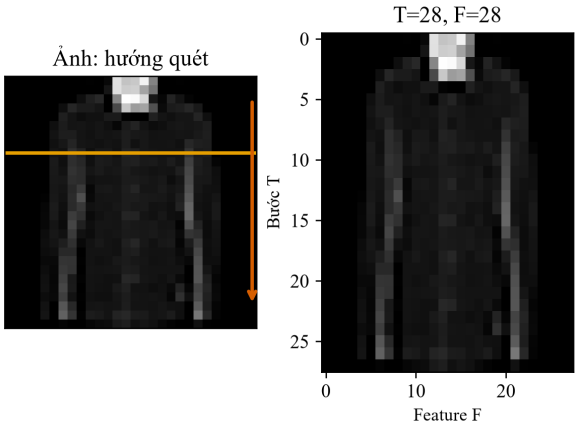

(a) Rows: $T = 28, F = 28$.

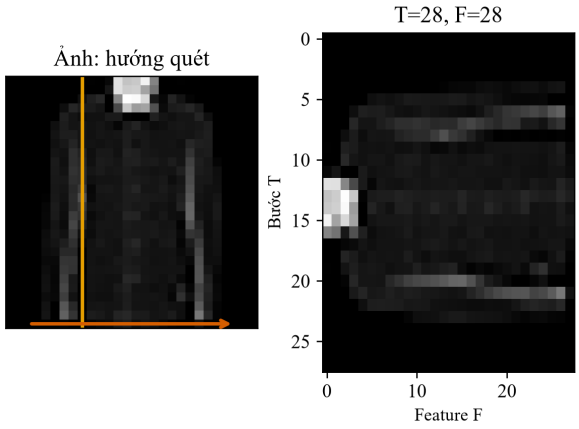

(b) Columns: $T = 28, F = 28$.

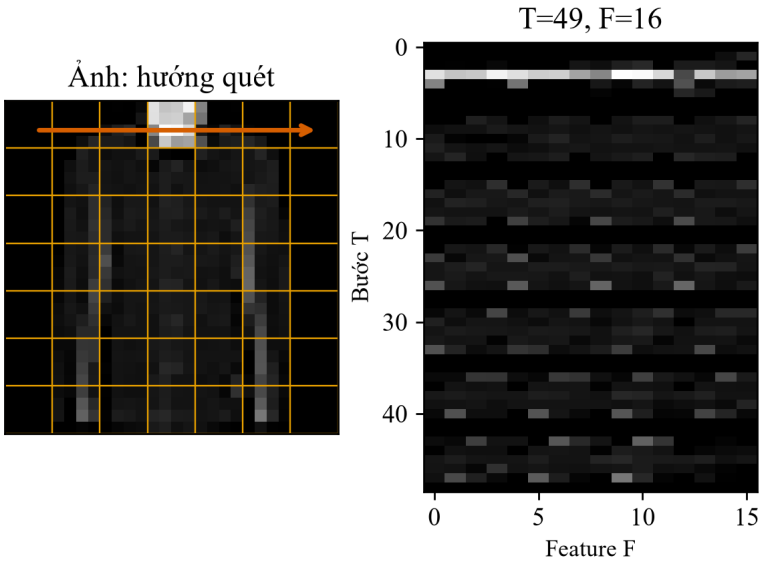

(c) Patch: $T = 49, F = 16$.

Hình 4.1: Ảnh Fashion-MNIST thành chuỗi; hướng quét và ma trận token, không dùng CNN/embedding trước recurrent.

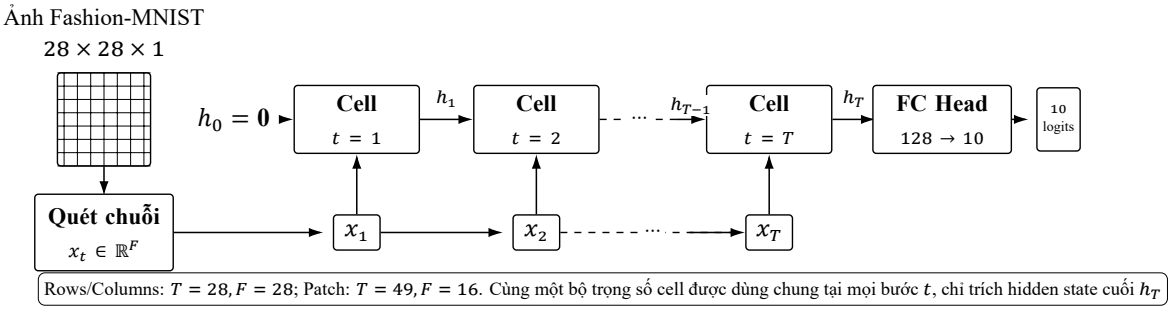

Hình 4.2: Classifier recurrent E3: không Conv, một recurrent layer unroll T lần và một FC head. Trạng thái khởi tạo bằng 0, chỉ dùng hidden cuối.

4.2 Cell LSTM/GRU tự hiện thực

Với $H = 128$, LSTM có input projection $F \to 4H = 512$, hidden projection $128 \to 512$, hai bias và bốn nhóm gate:

$$[i_t, f_t, g_t, o_t] = [\,\sigma, \sigma, \tanh, \sigma\,](W_{ih}x_t + b_{ih} + W_{hh}h_{t-1} + b_{hh}), \tag{4.1}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t, \qquad h_t = o_t \odot \tanh c_t. \tag{4.2}$$

GRU có hai projection $F \to 384$ và $128 \to 384$ cho reset, update và candidate:

$$r_t = \sigma(x_r + h_r), \quad z_t = \sigma(x_z + h_z), \tag{4.3}$$

$$n_t = \tanh(x_n + r_t \odot h_n), \quad h_t = (1 - z_t) \odot n_t + z_t \odot h_{t-1}. \tag{4.4}$$

$x_\cdot$ và $h_\cdot$ đã gồm bias. Reset nhân *sau* projection hidden, kể cả hidden bias, theo convention PyTorch. Kể cả head, số tham số là $4H(F + H + 2) + 10H + 10$ cho LSTM và $3H(F + H + 2) + 10H + 10$ cho GRU. Cùng F, GRU ít tham số hơn vì dùng ba nhóm thay cho bốn. Kiểm tra copy weight sang nn.LSTMCell/ nn.GRUCell trên CUDA float64 qua 4 bước: sai số forward tối đa là 5.551×10^{-17} (LSTM) và 3.331×10^{-16} (GRU). Gradient của state/input/tất cả tham số khớp theo kiểm tra.

4.3 Mô hình đối chiếu và thiết lập huấn luyện

LSTM/GRU dùng Rows, Columns và Patch; MLP/CNN-B giữ kiến trúc E1 nhưng được định nghĩa/train độc lập trên cùng split. AdamW LR 10^{-3}, weight decay 10^{-4}, batch 128, tối đa 100 epoch; patience 4, min-delta 10^{-4} theo validation loss. Clip norm 1 chỉ áp dụng cho recurrent; không augmentation/scheduler.

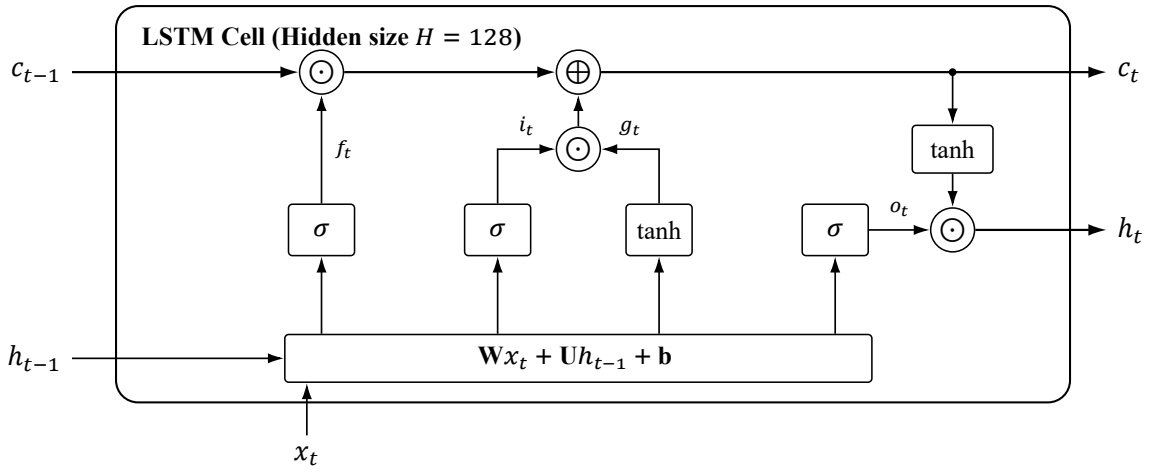

LSTM: 4 cổng gồm quên $f_t = \sigma(\cdot)$, vào $i_t = \sigma(\cdot)$, ứng viên $g_t = \tanh(\cdot)$, ra $o_t = \sigma(\cdot)$; $c_t = f_t \odot c_{t-1} + i_t \odot g_t$, $h_t = o_t \odot \tanh(c_t)$

(a) LSTM: input/hidden projections cho bốn gate, hidden và cell state.

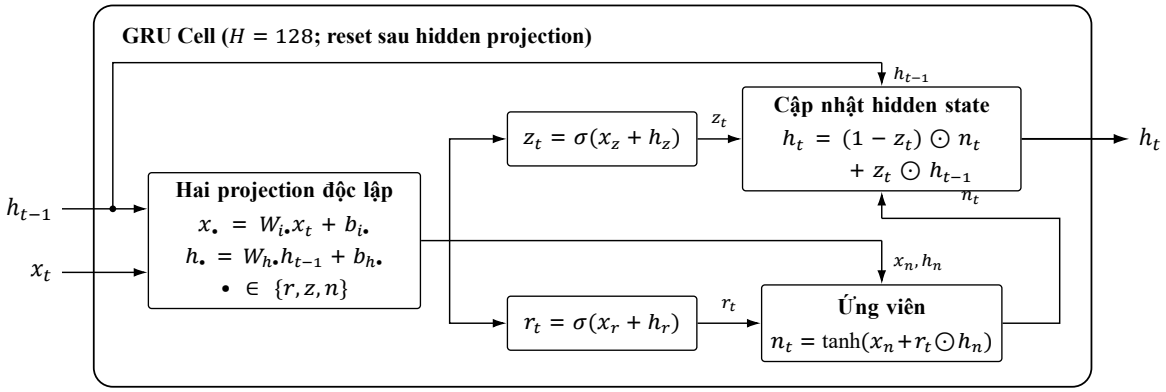

Input projection $F \to 384$; hidden projection $128 \to 384$; reset nhân trên h_n, gồm hidden bias

(b) GRU: hai projections cho ba gate, reset sau hidden projection kể cả bias.

Hình 4.3: Recurrent cell E3, $H = 128$: cùng bộ tham số ở mọi timestep; chỉ dùng hidden cuối để phân loại.

4.4 So sánh LSTM, GRU và cách biểu diễn

Bảng 4.1: Metric E3 trên validation và test; F1 là macro-F1.

Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
LSTM Rows	91.95	89.95	0.8990	89.70	0.8965	0.2940
LSTM Columns	92.79	88.72	0.8881	88.81	0.8885	0.3260
LSTM Patch	90.10	87.63	0.8769	87.55	0.8761	0.3444
GRU Rows	93.95	90.47	0.9044	90.06	0.9001	0.2882
GRU Columns	93.16	89.83	0.8983	89.51	0.8951	0.3137
GRU Patch	92.36	89.05	0.8900	88.44	0.8841	0.3352
MLP	91.58	89.47	0.8951	89.45	0.8948	0.3142
CNN-B	93.63	91.93	0.9195	91.45	0.9144	0.2333

Bảng 4.2: Số tham số, epoch và chi phí E3; cell được unroll bằng Python/PyTorch, không dùng fused kernel.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
LSTM Rows	82,186	18/14	472.13	26.230	27
LSTM Columns	82,186	23/19	625.00	27.174	27
LSTM Patch	76,042	20/16	928.90	46.445	33
GRU Rows	61,962	20/20	576.49	28.824	28
GRU Columns	61,962	23/19	642.46	27.933	28
GRU Patch	57,354	24/20	1,171.26	48.802	35
MLP	235,146	20/16	69.09	3.455	22
CNN-B	94,186	20/16	76.78	3.839	56

Trên cùng biểu diễn, GRU vượt LSTM lần lượt 0.36, 0.70 và 0.89 điểm phần trăm ở Rows, Columns và Patch. Rows/Columns giữ $T = 28, F = 28$ nhưng đổi hướng quét; Patch đổi cả $F = 16$ và $T = 49$, nên không cô lập riêng thứ tự token.

Để đánh giá vai trò của tính hồi tiếp, các cấu hình recurrent được đối chiếu với MLP và CNN-B huấn luyện độc lập trên cùng split. Rows là biểu diễn tốt nhất trong các cấu hình recurrent đã thử. GRU dùng ít tham số hơn LSTM cùng đầu vào, nhưng thời gian đo không thấp hơn: cell được unroll bằng các phép toán PyTorch thay vì fused kernel. CNN-B đạt accuracy cao hơn các cấu hình hồi tiếp đại diện với thời gian mỗi epoch thấp hơn đáng kể. Kết luận chỉ áp dụng cho ảnh tĩnh Fashion-MNIST và protocol hiện tại; accuracy không đủ chứng minh mô hình đã học phụ thuộc xa.

4.5 Đường cong học và phân tích lỗi

Gap LSTM Columns là 4.07 điểm, GRU Rows là 3.48 điểm: train cải thiện khi validation chững lại. Hình 4.4 đối chiếu cấu hình đại diện với MLP/CNN-B; đường cong theo từng cách biểu diễn ở Phụ lục.

Bảng 4.3: Cặp nhầm lớn nhất của tám mô hình E3; mỗi lớp test có 1,000 ảnh.

Model	Thật → dự đoán	Số ảnh	% lớp thật
LSTM Rows	Shirt → T-shirt/top	133	13.3%
LSTM Columns	T-shirt/top → Shirt	141	14.1%
LSTM Patch	T-shirt/top → Shirt	141	14.1%
GRU Rows	Shirt → T-shirt/top	125	12.5%
GRU Columns	Shirt → T-shirt/top	126	12.6%
GRU Patch	Shirt → T-shirt/top	135	13.5%
MLP	T-shirt/top → Shirt	124	12.4%
CNN-B	Shirt → Coat	103	10.3%

LSTM/GRU Rows nhầm Shirt thành T-shirt/top 133/125 ảnh; CNN-B nhầm Shirt thành Coat 103 ảnh. Vì cặp lớp khác nhau, không dùng ba số đếm này xếp hạng nhận diện Shirt.

Recall Shirt làm tròn là 70/71/73%; giày/túi dễ phân biệt hơn nhóm áo. Ma trận tám model ở Phụ lục; kết luận giới hạn ở một seed và cell unroll không fused.

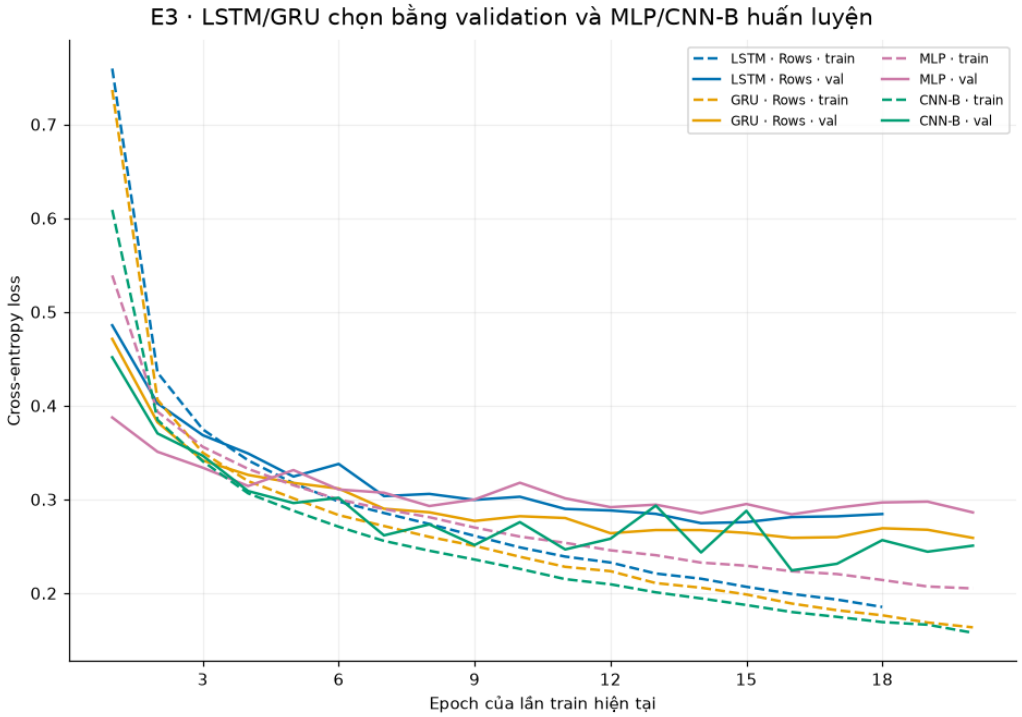

(a) Cross-entropy

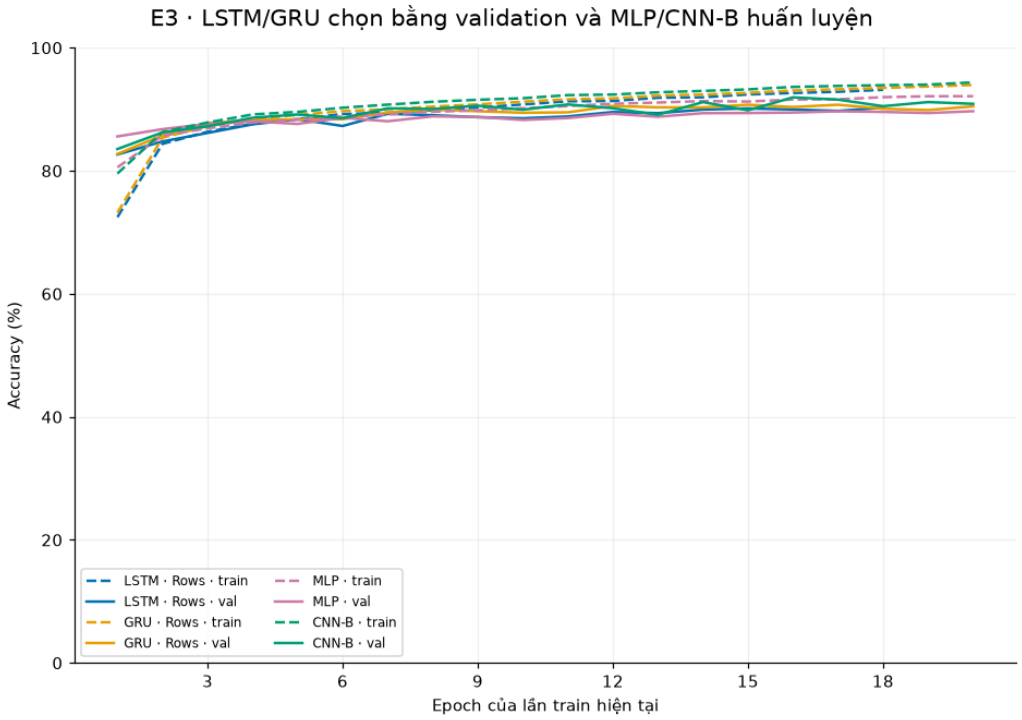

(b) Accuracy (%).

Hình 4.4: E3: LSTM/GRU Rows và baseline MLP/CNN-B trên train/validation; train nét đứt, validation nét liền.

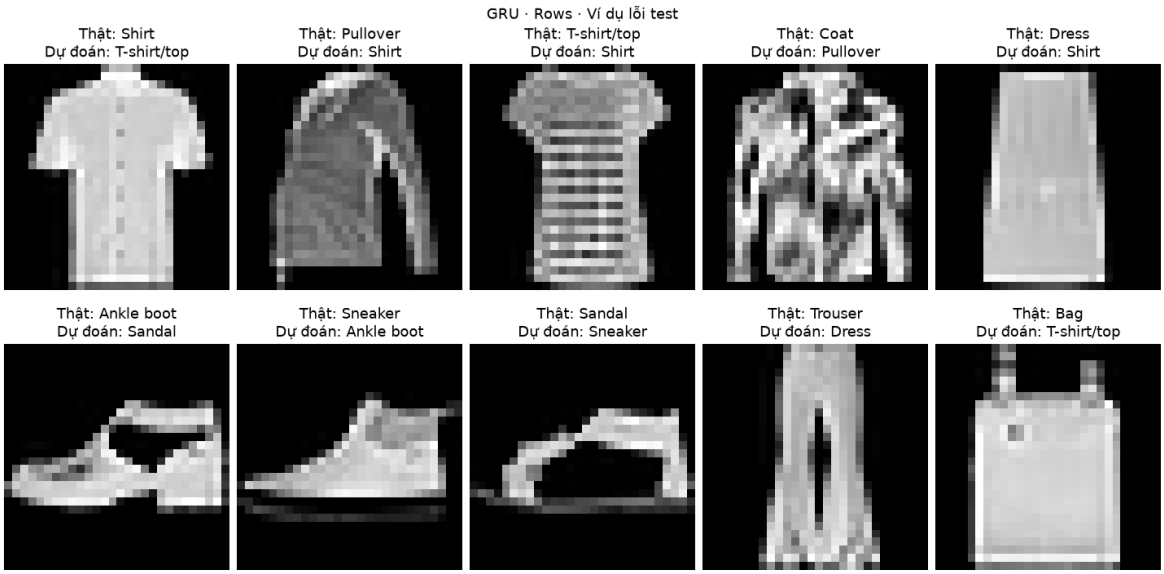

(a) GRU Rows

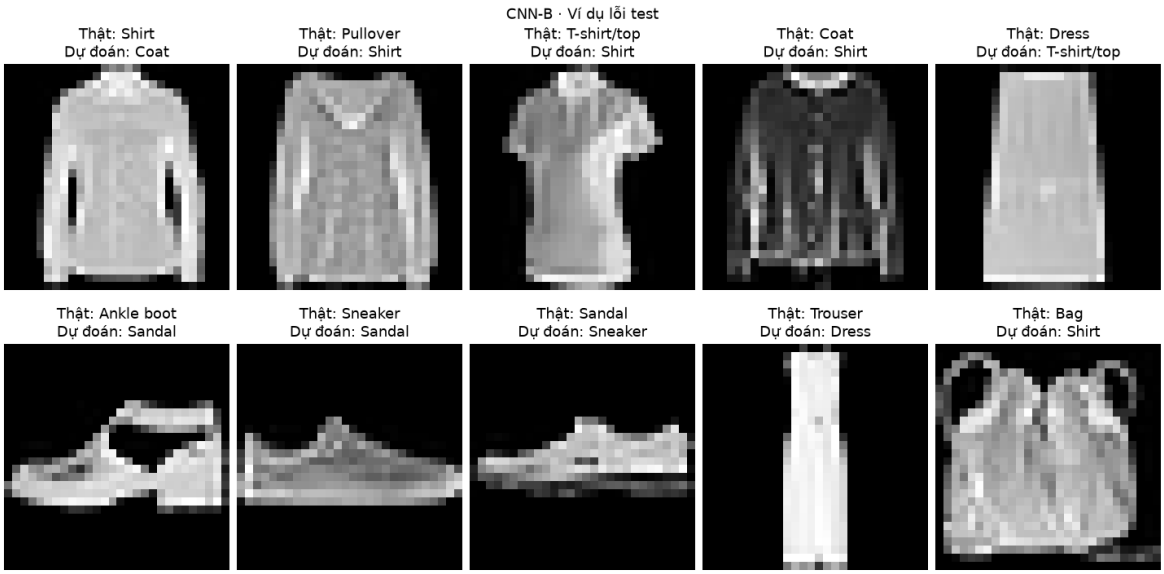

(b) CNN-B

Hình 4.5: Mẫu lỗi test E3, mỗi panel 2 × 5 ảnh; cùng split, mỗi model train độc lập.

5. A1: CNN và Transformer trên GTSRB

5.1 Dữ liệu, phân bố lớp và cách chia tập

GTSRB [9, 10] có 43 lớp, 39,209 ảnh train nguồn và 12,630 test; khác Fashion-MNIST/CIFAR-10, có biến đổi ánh sáng/góc nhìn và lớp gần nhau. Archive ERDA [11] cung cấp ảnh PPM/nhãn ClassId 0–42; prepared giữ pixel bằng PNG lossless.

Điều kiện sử dụng và giấy phép. Mục Citation của trang benchmark gốc [5] ghi "The data is free to use" và đề nghị trích dẫn Stallkamp và cộng sự (IJCNN 2011). Giấy phép cụ thể và điều khoản phân phối lại của archive ERDA chưa được xác minh; không gán mã SPDX hay giấy phép MIT/CC cho dữ liệu ảnh.

Train/validation chia theo nhóm class_id + physical_sign_track, seed 42, giữ khoảng 20% track mỗi lớp cho validation. Cách chia hạn chế các frame của cùng biển vật lý xuất hiện trong cả hai tập.

Bảng 5.1: Split GTSRB sử dụng toàn bộ dữ liệu.

Tập	Ảnh	Lớp	Vai trò
Train	31,380	43	Huấn luyện
Validation	7,829	43	Chọn weights và protocol
Official-source test	12,630	43	Đánh giá cuối
Test không trùng SHA256	12,622	43	Phân tích độ nhạy

Đối chiếu SHA256 trong metadata không ghi nhận trùng train–validation hoặc validation–test; có 8 ảnh test lớp Stop (ID 14) trùng train. Giữ test nguồn và báo thêm kết quả trên test không trùng. SHA256 chỉ phát hiện trùng byte, không loại mọi ảnh gần giống.

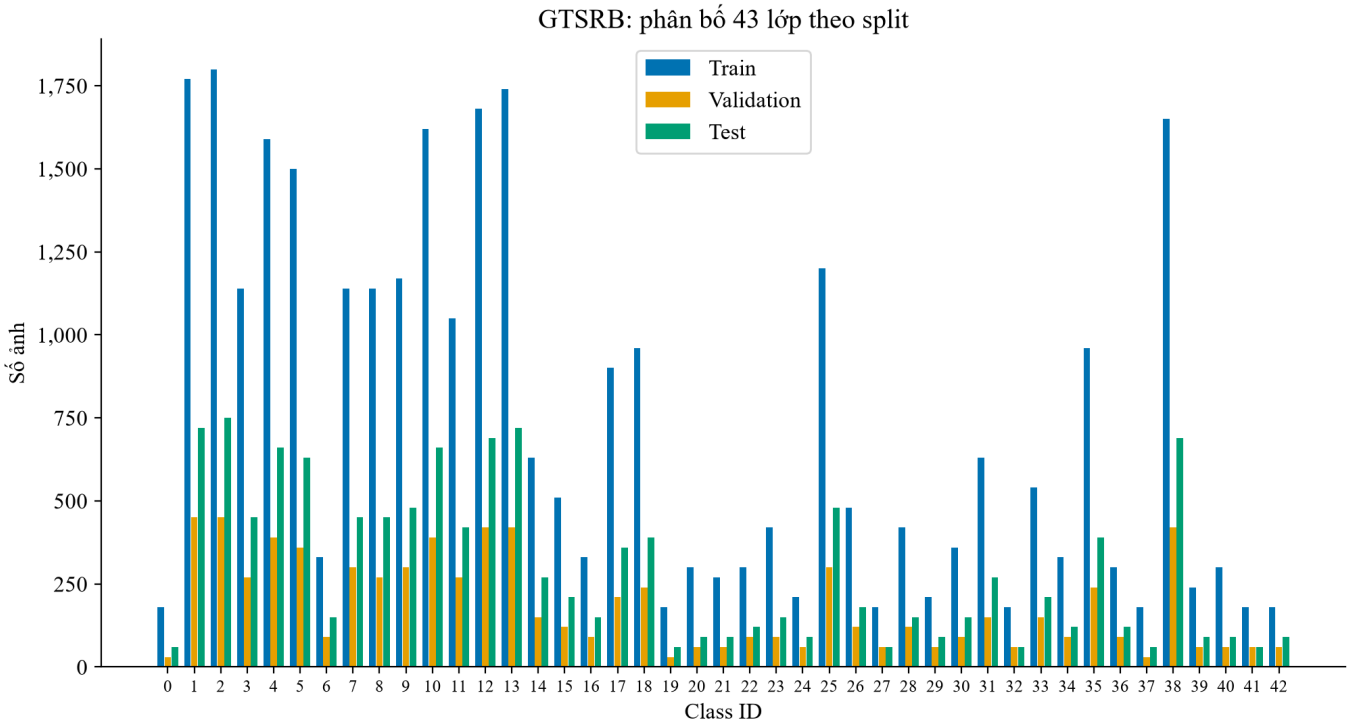

Hình 5.1: Số ảnh theo 43 lớp trong train, validation và test; ID tra theo bảng lớp ở Phụ lục.

Train mất cân bằng: Speed limit 50 có 1,800 ảnh, trong khi Speed limit 20, Pedestrians và một số lớp hiếm có 180 ảnh. Validation Turn right ahead có 149 ảnh, phản ánh split theo track không ép đúng tỷ lệ ảnh 20%.

Hình 5.2: Ảnh train đại diện các lớp GTSRB 0–21; giữ ID và tên lớp.

Hình 5.3: Ảnh train đại diện các lớp GTSRB 22–42; hai bộ ảnh minh họa có đủ 43 lớp.

5.2 DataLoader, augmentation và kiến trúc

Ảnh RGB resize toàn ảnh về 224×224, không center-crop; chuẩn hóa ImageNet mean $(0.485; 0.456; 0.406)$, std $(0.229; 0.224; 0.225)$. Train dùng RandomAffine $\pm 10°$, translate tối đa 5%, ColorJitter brightness/contrast 0.2, saturation 0.1; không flip vì đổi ý nghĩa biển. Validation/test chỉ resize/normalize. DataLoader đọc samples.csv, shuffle train, workers 0, seed cố định, giữ batch cuối.

ResNet-50 dùng Bottleneck 3/4/6/3, expansion 4, stride tại Conv 3×3 theo convention torchvision [4]. DeiT-Small/16 non-distilled dùng patch 16, embedding 384, depth 12, 6 head, FFN $384 \rightarrow 1536 \rightarrow 384$ và LayerNorm eps 10^{-6} [12]. Hai mạng được định nghĩa trong notebook, dùng head 43 lớp. Pretrained ResNet lấy ImageNet-1K V1 của torchvision; DeiT lấy checkpoint ImageNet-1K chính thức non-distilled, không dùng distillation token/teacher hoặc loss distillation.

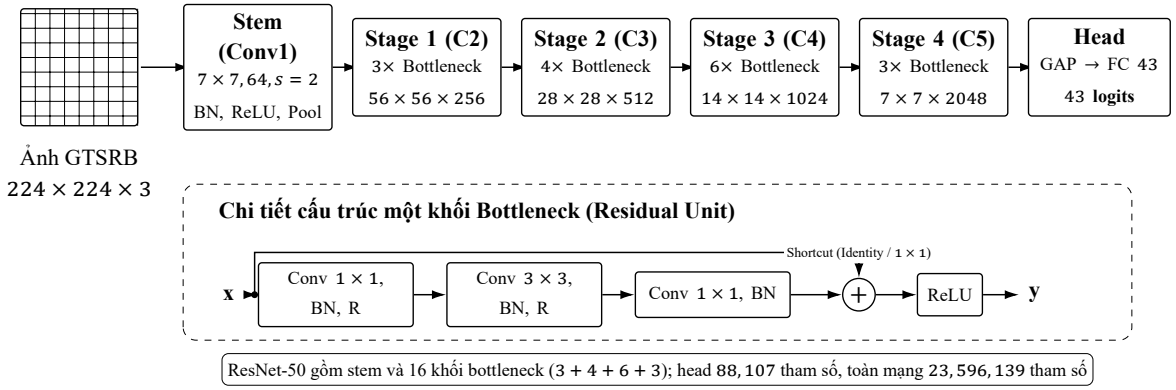

Hình 5.4: ResNet-50: backbone gom khối, global average pooling và FC 43 lớp. Head 88,107 tham số; toàn mạng 23,596,139.

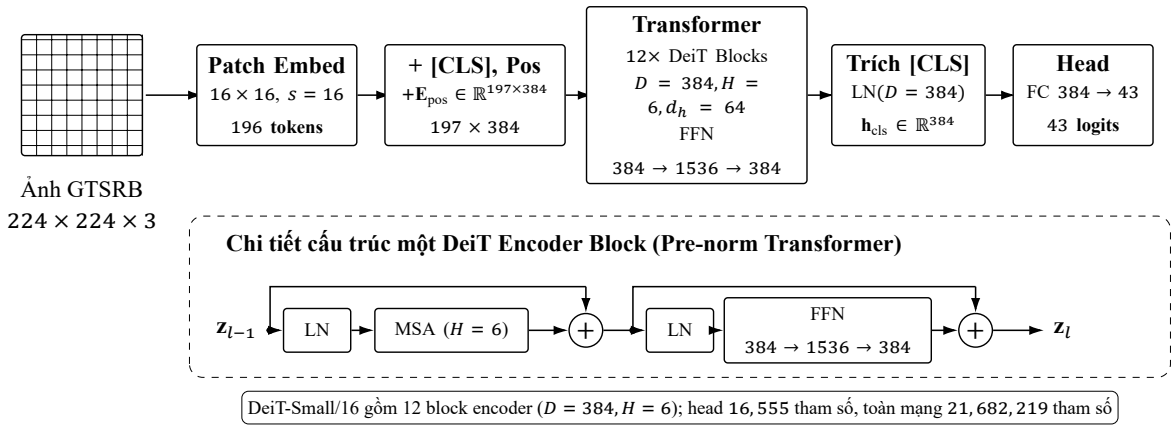

Hình 5.5: DeiT-Small/16: 196 patch và CLS, 12 encoder block, một head 43 lớp. Head 16,555 tham số; toàn mạng 21,682,219.

Pretrained chỉ nạp backbone, giữ head 43 lớp của bài toán GTSRB; code đối chiếu đầy đủ tên/kích thước trọng số khi nạp.

5.3 Các cấu hình và thiết lập huấn luyện

Ký hiệu bảng: R=ResNet-50, D=DeiT-Small/16; S=scratch, H=head-only, P=partial, F=full pretrained; số sau dấu/ là seed.

Bảng 5.2: Các mức freeze và số tham số được tối ưu.

Họ	Chế độ	Thành phần trainable	Tham số	% tổng
ResNet	Scratch/full	Toàn bộ mạng	23,596,139	100.00
ResNet	Head-only	FC 43	88,107	0.37
ResNet	Partial	layer4 và FC 43	15,052,843	63.79
DeiT	Scratch/full	Toàn bộ mạng	21,682,219	100.00
DeiT	Head-only	FC 43	16,555	0.08
DeiT	Partial	Hai block cuối, norm, head	3,566,251	16.45

Partial mở 63.79% tham số ResNet và 16.45% DeiT; vì vậy phép so sánh này không có cùng số tham số trainable. BatchNorm bị freeze dùng eval mode, không cập nhật running statistics.

AdamW weight decay 0.01; scratch LR 3×10^{-4}, tối đa 40 epoch; pretrained backbone LR 10^{-4} và head 10^{-3}, tối đa 25 epoch. Warmup 3 epoch rồi cosine, clip gradient norm 1, AMP train và FP32 eval. Early stopping theo validation loss, patience 2, min-delta 10^{-3}. Best weights lưu khi loss thấp hơn best loss; min-delta dùng riêng cho bộ đếm dừng sớm, nên best epoch có thể gần epoch dừng. Batch 128, accumulation 1 cho mọi run; train có 246 batch/epoch, batch cuối 20 ảnh. Validation/test có 62/99 batch.

Hai họ × bốn regime tạo tám run chính, cùng seed 42 và augmentation. Mỗi họ chọn regime bằng validation accuracy, macro-F1 rồi loss; full được chọn ở cả hai. Với regime này, thêm no-augmentation seed 42 và repeat seed 43/44 cho mỗi họ, tổng 14 run. Split giữ seed 42; test đánh giá sau khi khóa các lựa chọn.

Scratch không nạp ImageNet weights. Mỗi run có latest.pt riêng; quy tắc nạp weights và giới hạn resume được mô tả ở Chương 1. Epoch, updates và thời gian trong bảng chỉ tính vòng train/validation được ghi trong output, không gồm test, vẽ hình hoặc đánh giá trọng số đầu vào.

5.4 Kết quả chính: CNN, Transformer và pretraining

Bảng 5.3: Accuracy và macro-F1 của tám cấu hình chính; test có 12,630 ảnh.

Run	Train (%)	Val (%)	Val F1	Test (%)	Test F1
R-S/42	98.51	98.26	0.9688	96.33	0.9447
R-H/42	86.06	66.84	0.5682	67.33	0.5759
R-P/42	99.53	97.02	0.9560	95.21	0.9261
R-F/42	99.43	99.32	0.9911	97.83	0.9678
D-S/42	93.78	91.76	0.8791	88.64	0.8267
D-H/42	89.37	70.26	0.5932	69.41	0.6016
D-P/42	98.64	89.32	0.8360	87.85	0.8063
D-F/42	99.79	99.39	0.9863	98.92	0.9790

Bảng 5.4: Số tham số, số epoch/best, thời gian mỗi epoch và peak allocated VRAM.

Run	Total params	Trainable	%	Epoch/best	s/epoch	Peak MiB
R-S/42	23,596,139	23,596,139	100.00	7/5	230.838	5828
R-H/42	23,596,139	88,107	0.37	10/8	153.500	1567
R-P/42	23,596,139	15,052,843	63.79	7/5	164.455	1682
R-F/42	23,596,139	23,596,139	100.00	4/2	222.561	5827
D-S/42	21,682,219	21,682,219	100.00	11/9	240.167	6631
D-H/42	21,682,219	16,555	0.08	12/10	170.014	636
D-P/42	21,682,219	3,566,251	16.45	6/4	182.845	1373
D-F/42	21,682,219	21,682,219	100.00	8/6	236.812	6635

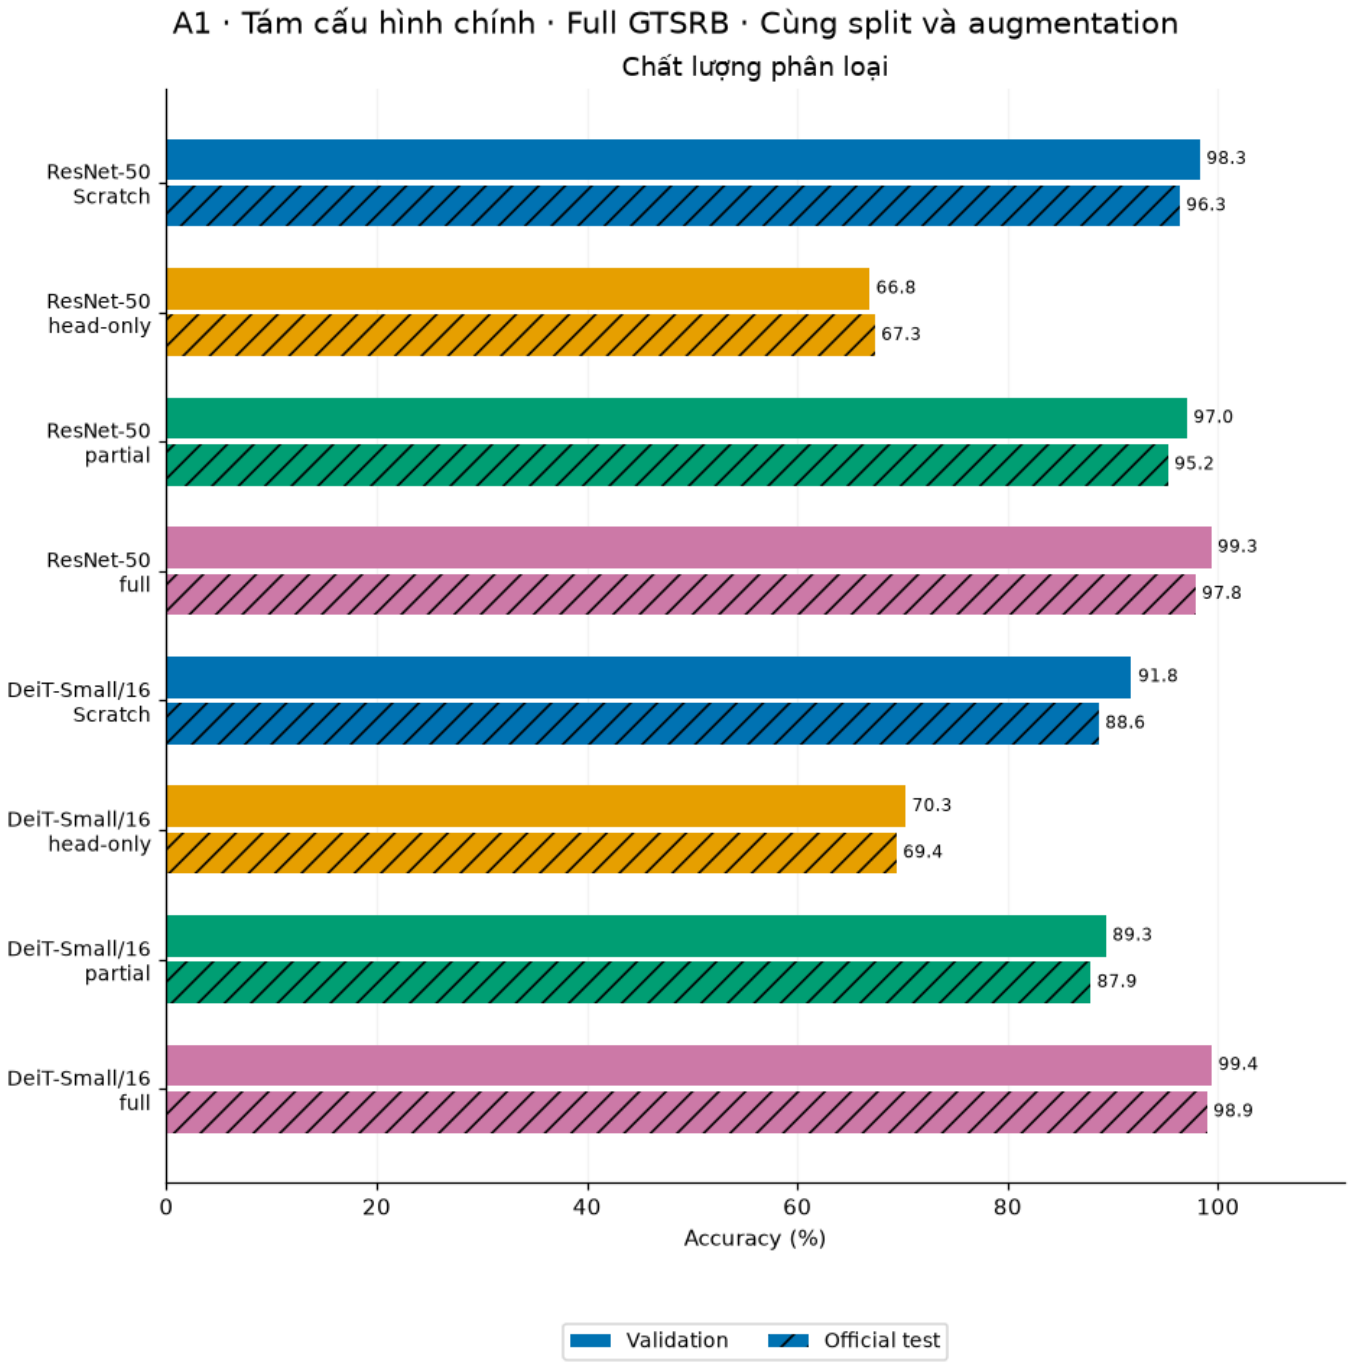

Hình 5.6: Validation và test accuracy của tám cấu hình A1, cùng split và augmentation.

Trong các regime đã thử, full pretrained đạt validation accuracy cao nhất cho cả ResNet-50 và DeiT-Small/16. Trên test seed 42, hai model lần lượt đạt 97.83% và 98.92%. Scratch, head-only và partial khác nhau về điều kiện tối ưu; đặc biệt hai cấu hình partial không có cùng tỷ lệ tham số trainable. Các so sánh mô tả hiệu quả toàn bộ regime, không cô lập riêng backbone hay pretraining.

Full pretrained tăng test so với scratch 1.50 điểm ở ResNet và 10.28 điểm ở DeiT. Scratch ResNet cao hơn DeiT 7.69 điểm test; head-only DeiT cao hơn 2.08 điểm, còn partial ResNet cao hơn 7.36 điểm với phạm vi unfreeze khác nhau. Các chênh lệch này không chứng minh một họ luôn tốt hơn ở mọi chế độ/dataset.

5.5 Freeze, chi phí và đường cong học

Head-only có gap train–validation 19.22/19.11 điểm (ResNet/DeiT), chưa thích nghi tốt với GTSRB. Freeze giảm trainable parameters và VRAM; partial ResNet là đánh đổi đáng xét khi hạn chế bộ nhớ, còn full cao nhất về accuracy trong các chế độ đã thử.

Bảng 5.5: Thời gian train+validation và inference FP32; CUDA Events batch 32, tách DataLoader.

Run	Train+val (s)	GPU ms/batch	Images/s	Test (s)
R-S/42	1,615.87	76.84	416.5	50.93
R-H/42	1,535.00	74.80	427.8	42.04
R-P/42	1,151.19	75.20	425.5	41.91
R-F/42	890.24	74.78	427.9	41.96
D-S/42	2,641.83	139.56	229.3	62.57
D-H/42	2,040.17	139.92	228.7	62.91
D-P/42	1,097.07	139.93	228.7	62.85
D-F/42	1,894.50	140.50	227.8	62.92

Throughput GPU-only của full ResNet khoảng 1.88 lần DeiT trong benchmark FP32 batch 32; thời gian train tổng còn phụ thuộc số epoch dừng sớm. Test end-to-end dùng batch 128, gồm DataLoader/H2D/metric, nên không đồng nhất với benchmark GPU-only. Peak là allocated PyTorch, không phải reserved hoặc tổng VRAM máy.

Hình 5.7–5.8 cho thấy head-only có gap lớn, full pretrained hội tụ sớm. DeiT scratch dừng sau 11 epoch, test 88.64%; kết quả phụ thuộc cả khởi tạo và quy tắc dừng, không chỉ backbone.

5.6 Augmentation và độ biến thiên giữa seed

Bảng 5.6: Sáu thực nghiệm bổ sung trên full pretrained; cấu hình chọn bằng validation.

Run	Val (%)	Val F1	Test (%)	Test F1	Train+val (s)
R-F/42 no-aug	98.85	0.9811	97.20	0.9545	543.43
R-F/43	98.80	0.9817	97.83	0.9591	683.57
R-F/44	99.28	0.9881	98.19	0.9630	1,133.57
D-F/42 no-aug	98.10	0.9776	97.80	0.9593	587.72
D-F/43	99.39	0.9902	98.29	0.9768	2,362.09
D-F/44	99.02	0.9864	98.30	0.9705	1,176.05

Bảng 5.7: Augmentation ablation, cùng full mode và seed 42; accuracy tính bằng %.

Họ	Aug val	No-aug val	Aug test	No-aug test
ResNet-50	99.32	98.85	97.83	97.20
DeiT-Small/16	99.39	98.10	98.92	97.80

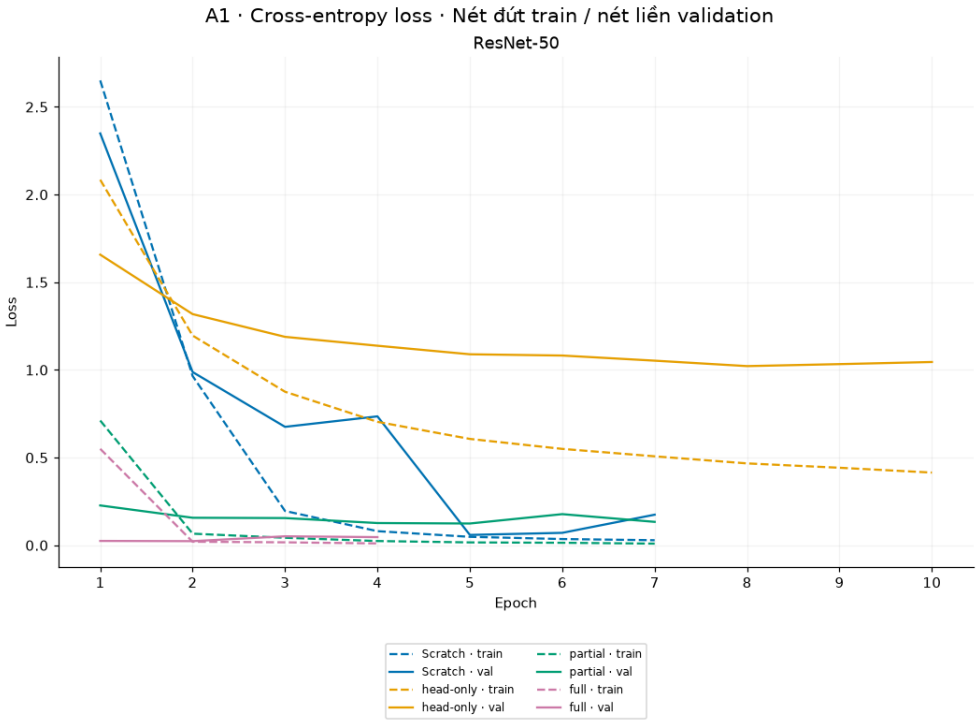

(a) ResNet-50

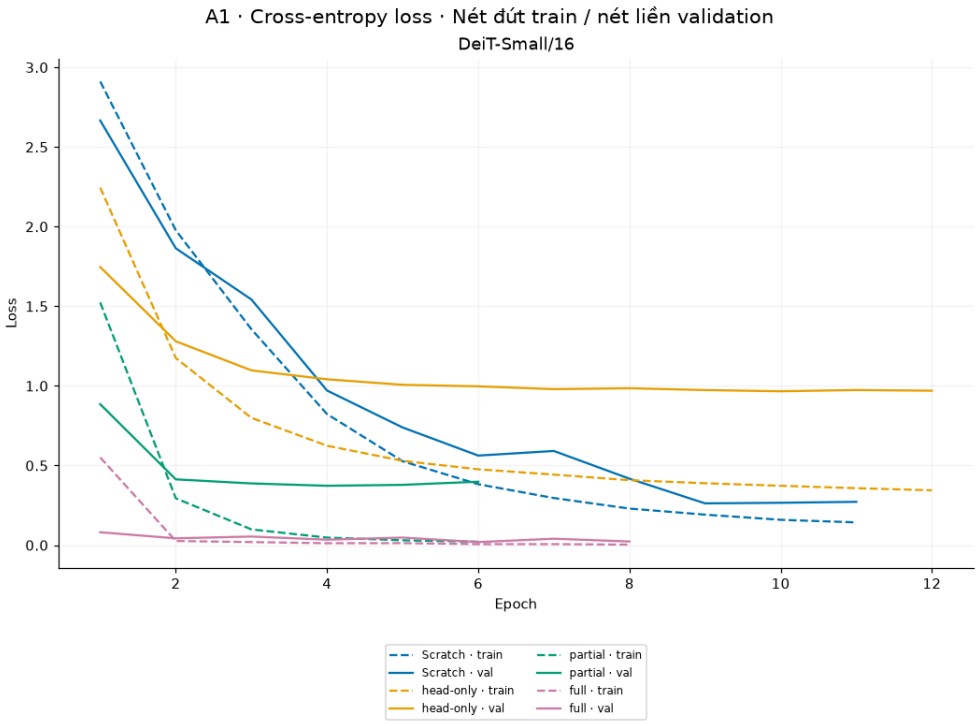

(b) DeiT-Small/16

Hình 5.7: Cross-entropy A1 theo bốn regime trên train/validation; train nét đứt, validation nét liền.

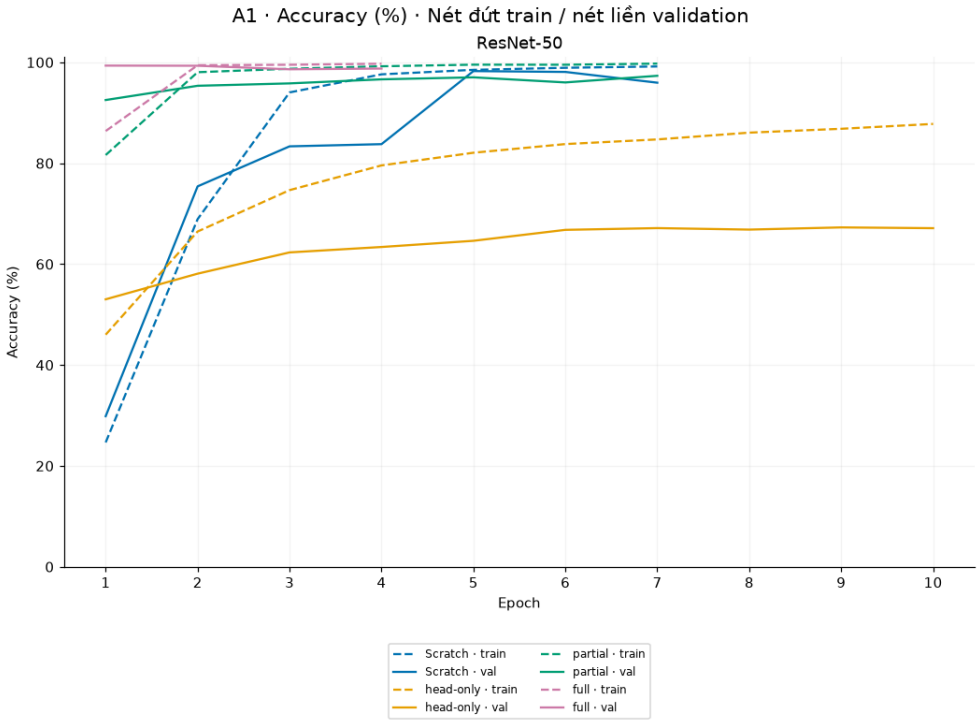

(a) ResNet-50

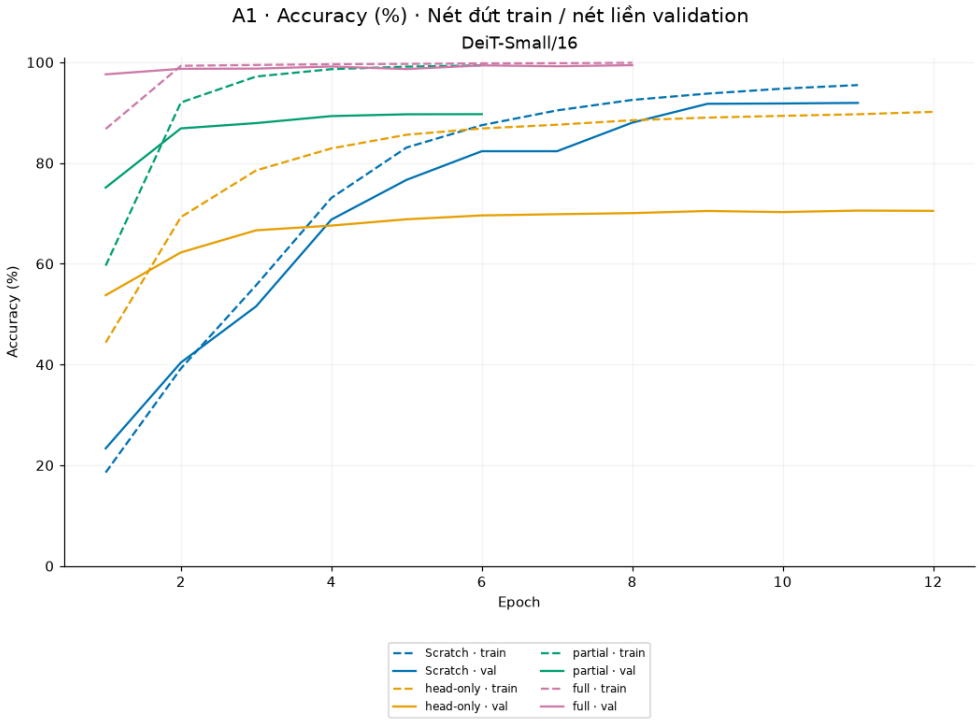

(b) DeiT-Small/16

Hình 5.8: Accuracy A1 (%) qua epoch, cùng màu regime và split; train có augmentation, validation trong eval mode.

Augmentation tăng validation 0.47/1.29 điểm và test 0.63/1.12 điểm cho ResNet/DeiT. Biến đổi đã chọn hữu ích với cả hai họ trong lượt đo này; một seed chưa xác lập tác dụng trên mọi split hoặc cách augmentation.

Bảng 5.8: Full pretrained qua seed 42/43/44, giữ split 42; mean ± std mẫu, ddof=1.

Họ	Val acc (%)	Test acc (%)	Val macro-F1	Test macro-F1
ResNet-50	99.14 ± 0.29	97.95 ± 0.21	0.9870 ± 0.0048	0.9633 ± 0.0044
DeiT-Small/16	99.26 ± 0.21	98.50 ± 0.36	0.9876 ± 0.0022	0.9754 ± 0.0044

Test accuracy trung bình là $97.95 \pm 0.21\%$ cho ResNet và $98.50 \pm 0.36\%$ cho DeiT; chênh lệch 0.55 điểm. Với $n = 3$ trên một split, đây là độ biến thiên mô tả, không phải khoảng tin cậy hay bằng chứng thống kê mạnh. Kết quả đại diện giữ seed 42, không chọn seed tốt nhất theo test.

5.7 Ma trận nhầm lẫn, lỗi và ảnh trùng

Hình 5.9 có hàng là lớp thật, cột là dự đoán; tổng hàng hiển thị có thể dưới 100%. Ô làm tròn số nguyên. Ma trận đầy đủ 43×43 có trong notebook; Phụ lục liệt kê precision/recall/F1 của toàn bộ 43 lớp.

Bảng 5.9: Cặp lớp nhầm nhiều nhất của tám cấu hình chính; ID đi cùng tên lớp.

Run	Thật → dự đoán	Ảnh	% lớp thật
R-S/42	27: Pedestrians → 11: Right-of-way intersection	29	48.33%
R-H/42	1: Speed limit 30 → 2: Speed limit 50	197	27.36%
R-P/42	4: Speed limit 70 → 3: Speed limit 60	53	8.03%
R-F/42	27: Pedestrians → 25: Road work	30	50.00%
D-S/42	0: Speed limit 20 → 4: Speed limit 70	50	83.33%
D-H/42	1: Speed limit 30 → 2: Speed limit 50	133	18.47%
D-P/42	34: Turn left ahead → 33: Turn right ahead	78	65.00%
D-F/42	0: Speed limit 20 → 8: Speed limit 120	30	50.00%

ResNet full nhầm 30/60 Pedestrians (ID 27) thành Road work (ID 25), recall 0.500 và F1 0.638. DeiT full nhầm 30/60 Speed limit 20 (ID 0) thành Speed limit 120 (ID 8), recall 0.500 và F1 0.667. DeiT có recall Pedestrians 0.883; ResNet có recall Speed limit 20 0.967. Accuracy tổng cao vẫn có thể đi cùng lỗi ở lớp hiếm.

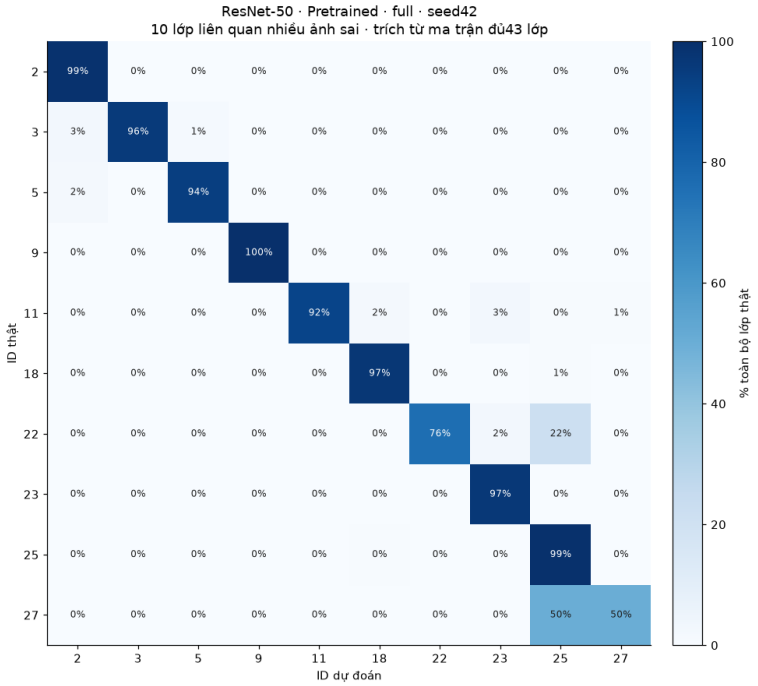

(a) ResNet-50 full, seed 42.

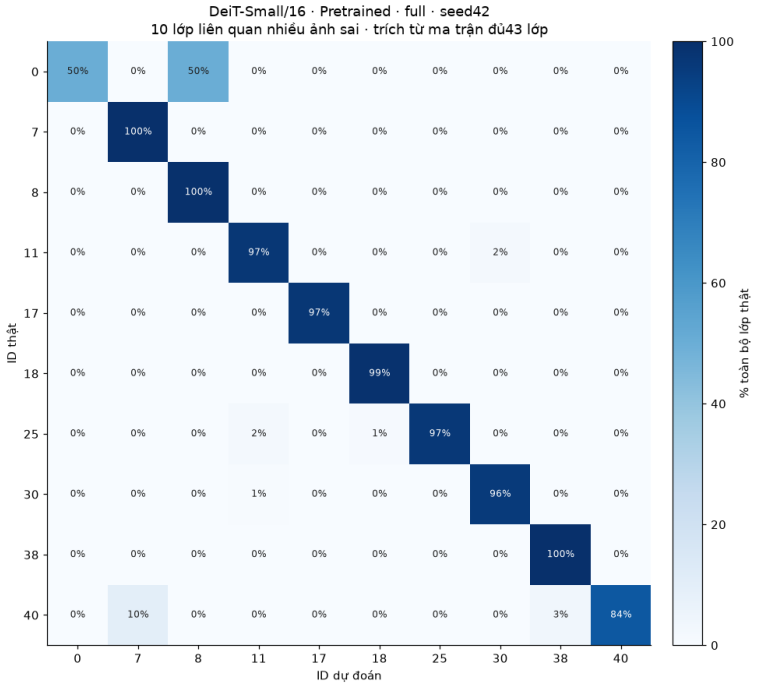

(b) DeiT-Small/16 full, seed 42.

Hình 5.9: A1: mỗi mô hình chọn riêng 10 lớp có tổng lỗi hàng và cột lớn nhất sau khi loại đường chéo khỏi ma trận 43×43. Phần trăm tính theo tổng support của lớp thật trên toàn bộ test, không chuẩn hóa lại trên nhóm hiển thị. Hai panel cùng thang 0–100% nhưng không nhất thiết có cùng tập lớp.

Bảng 5.10: Một số lớp khó trong hai full model seed 42; support, recall và F1.

Lớp	Support	R recall	R F1	D recall	D F1
Speed 20	60	0.967	0.983	0.500	0.667
Pedestrians	60	0.500	0.638	0.883	0.938
Bumpy road	120	0.758	0.863	0.950	0.970
Roundabout	90	0.933	0.923	0.844	0.916
Ice/snow	150	0.987	0.961	0.960	0.938

Hình 5.10 minh họa mờ, thiếu sáng và ký hiệu gần nhau. Đây là yếu tố nhìn thấy trong ảnh, chưa chứng minh nguyên nhân lỗi. Nhiều frame có thể cùng track, nên số ảnh sai không đồng nghĩa số biển vật lý độc lập.

Loại 8 ảnh trùng khỏi test làm accuracy tám run thay đổi từ -0.001 đến -0.021 điểm phần trăm. Hai full model đạt 97.83%/98.91% trên 12,622 ảnh không trùng. Macro-F1 head-only giảm 0.0001 ở mức làm tròn bốn chữ số; các run còn lại giữ cùng mức hiển thị. Độ nhạy tổng nhỏ nhưng không loại bỏ giới hạn độc lập của test nguồn.

5.8 Kết luận A1 và giới hạn

Full pretrained được chọn bằng validation. DeiT cao hơn về test accuracy ở seed 42 và trung bình ba seed; ResNet có throughput suy luận tốt hơn. Head-only tiết kiệm memory nhưng accuracy thấp, partial phụ thuộc unfreeze; augmentation có lợi trong ablation seed 42.

Giới hạn gồm mất cân bằng, ảnh trùng/gần giống, frame cùng track, ba seed chỉ cho full, partial không có cùng số tham số trainable và ngân sách/LR khác giữa scratch–pretrained. Trạng thái weights đầu vào cũng ảnh hưởng tái lập; epoch dừng hiện tại không phản ánh toàn bộ ngân sách học của checkpoint.

(a) ResNet-50 full

(b) DeiT-Small/16 full

Hình 5.10: Mẫu lỗi test A1 seed 42; mỗi panel 2 × 5 ảnh ghi nhãn thật/dự đoán, không đại diện tần suất lỗi toàn tập.

6. A2: RetinaNet và Faster R-CNN trên VOC2012

6.1 Bài toán và dữ liệu

A2 dự đoán bbox, class và confidence cho nhiều đối tượng/ảnh. RetinaNet một giai đoạn và Faster R-CNN hai giai đoạn cùng dùng ResNet-50 pretrained ImageNet/FPN, nhưng khác pyramid levels, anchors, sampling và head.

PASCAL VOC2012 [2, 3] có 20 lớp và 11,540 ảnh trainval có nhãn, chia 80/10/10 theo ID ảnh, seed 42. Đây là test holdout nội bộ, không phải test chính thức/leaderboard VOC. Manifest tham chiếu JPEG/XML, không nhân bản ảnh. VOC Database Rights và quyền tác giả ảnh áp dụng; nguồn/schema trong README dữ liệu.

Bảng 6.1: Số ảnh và annotation VOC2012. Một bbox có thể vừa difficult vừa truncated.

Tập	Ảnh	Bbox thường	Difficult	Truncated
train	9,232	21,975	3,267	13,182
val	1,154	2,788	468	1,647
test	1,154	2,687	376	1,561

Nhãn XML gồm tên lớp, bndbox, difficult và truncated. Tọa độ VOC đánh số từ 1, bao gồm cả hai đầu, được chuyển thành khoảng nửa mở đánh số từ 0: $[x_{\min}-1, y_{\min}-1, x_{\max}, y_{\max}]$. Manifest lưu bbox, nhãn lớp và các cờ difficult/truncated. Dataset tạo tensor RGB và target gồm bbox, class ID 1–20, difficult và image ID; truncated được giữ trong metadata để thống kê. RetinaNet ánh xạ nhãn sang 0–19 khi tính loss, rồi chuyển về 1–20 khi suy luận. Faster R-CNN dành ID 0 cho background.

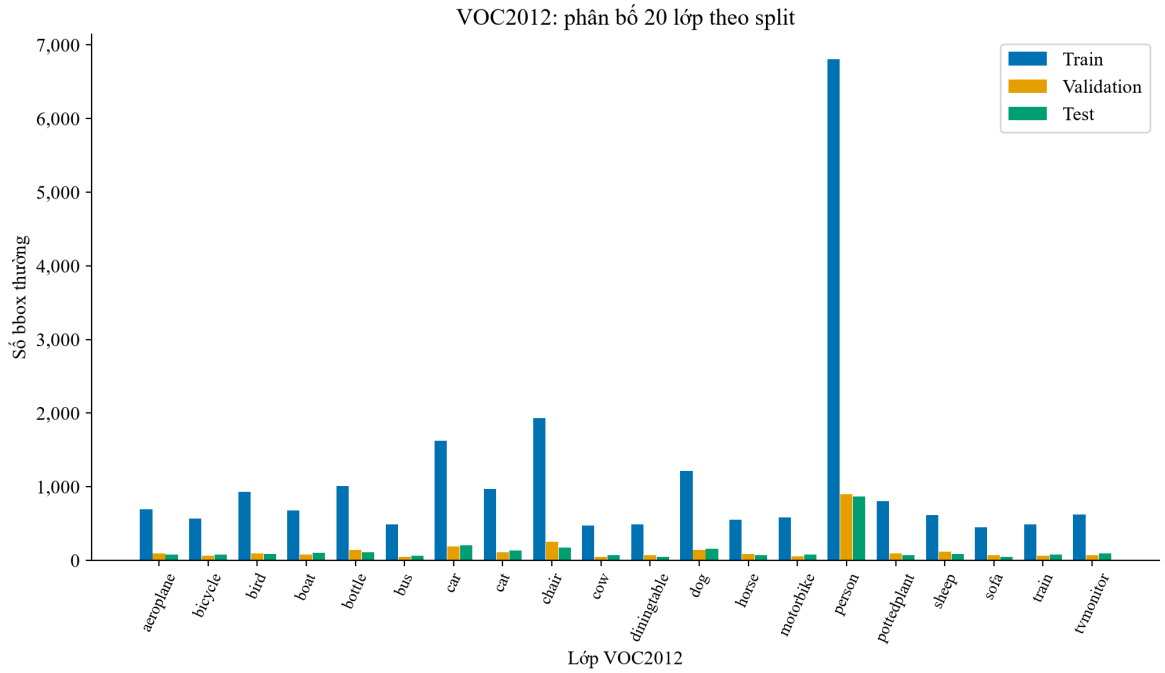

Hình 6.1: VOC2012: số bbox thường theo 20 lớp và ba split, từ bảng output; difficult không nằm trong số lượng.

Person chiếm 6,802/21,975 bbox thường train (30.95%), sofa có 447. Số lượng theo lớp là số đối tượng, không phải ảnh; AP từng lớp/macro-F1 giúp đọc ảnh hưởng mất cân bằng.

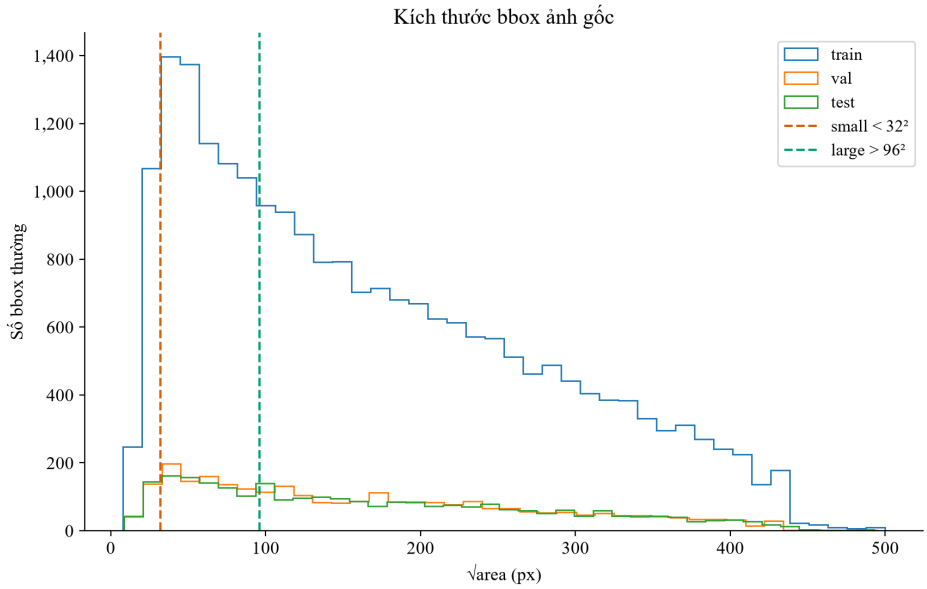

(a) Căn bậc hai diện tích (px).

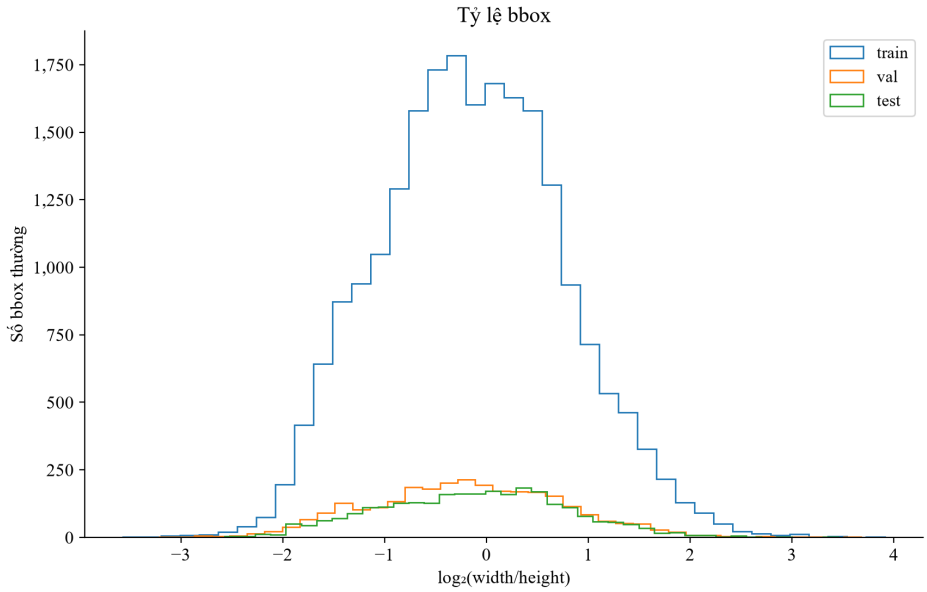

(b) Log-ratio chiều rộng/chiều cao.

Hình 6.2: BBox thường của VOC2012: scale và aspect ratio trên ảnh gốc, cùng ba split.

BBox đa dạng về scale và tỷ lệ cạnh. FPN cung cấp nhiều stride, còn ba aspect ratio bao phủ vật thể cao, vuông và rộng.

6.2 Tiền xử lý và DataLoader

Resize giữ tỷ lệ, short side 600/max long side 1,000; pad batch tới bội 32. Ảnh/tỷ lệ cạnh khác nhau tạo lượng padding và VRAM khác nhau; resize không phục hồi chi tiết đã mất. Tensor ở $[0, 1]$, chuẩn hóa ImageNet một lần, không tiling. Train flip ngang $p = 0.5$ cùng bbox; val/test không augmentation. DataLoader shuffle train, workers 0, giữ batch cuối. Train học cả difficult; eval bỏ GT/detection khớp difficult theo VOC, không lọc đối tượng theo cờ truncated.

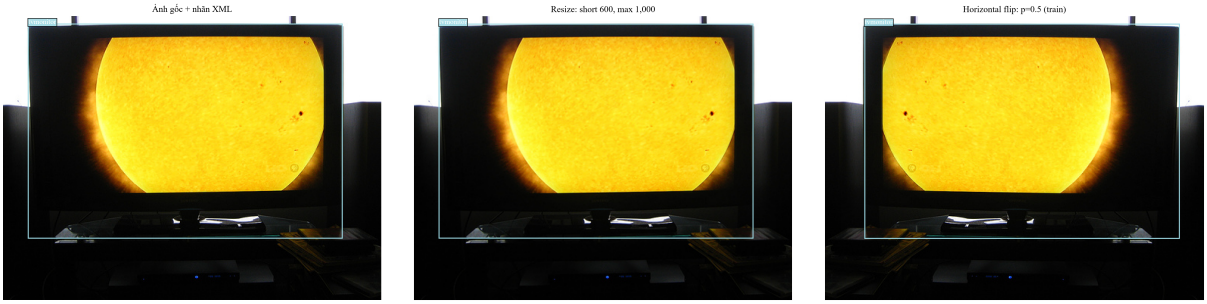

(a) Ảnh gốc và GT. **(b)** Resize 600/max 1,000. **(c)** Flip ngang, $p = 0.5$.

Hình 6.3: Một ảnh train VOC2012: bbox đi cùng phép biến đổi; tọa độ lấy từ CSV đã chuẩn bị từ annotation VOC, không dự đoán lại.

6.3 FPN: phương pháp, thí nghiệm và giới hạn

Feature tầng sớm giữ chi tiết vị trí, trong khi tầng sâu có ngữ nghĩa mạnh hơn. FPN [6] kết hợp chúng bằng top-down và lateral connections. ResNet-50 xuất C2–C5, strides 4/8/16/32, channels 256/512/1,024/2,048. Với lateral L_l là Conv 1×1 đưa về 256 channels:

$$T_5 = L_5(C_5), \quad T_l = L_l(C_l) + \text{Upsample}_{\text{nearest}}(T_{l+1}), \quad P_l = \text{Conv}_{3\times3}(T_l). \tag{6.1}$$

Upsample đến đúng shape lateral; nhánh top-down truyền T trước smoothing, không truyền P sau smoothing. Neck không thêm BN/ReLU tại các mức này.

Bảng 6.2: Kết quả và ablation của FPN trên COCO; số liệu tác giả [6].

Thiết lập	Chỉ số	Giá trị
Table 1, ResNet-50 RPN C4	AR@1k	48.3
RPN FPN đầy đủ	AR@1k	56.3
Bỏ top-down / bỏ lateral	AR@1k	49.5 / 46.1
Chỉ P2, tăng anchors lên 750k	AR@1k	51.3
Table 3, Faster R-CNN C4 / FPN	AP	31.6 / 33.9
Table 3, Faster R-CNN C4 / FPN	AP50	53.1 / 56.9

Ablation dùng COCO trainval35k/minival 5k. Giảm recall khi bỏ top-down hoặc lateral, và việc P2 nhiều anchors vẫn kém FPN, hỗ trợ phối hợp ngữ nghĩa–định vị. VOC dùng FPN ở cả hai detector nên chưa đo riêng đóng góp neck. Feature độ phân giải cao tăng activation; FPN không tự giải quyết vật thể quá nhỏ, che khuất hay nhãn nhiễu.

6.4 RetinaNet và Focal Loss

6.4.1 Động cơ và hàm mất mát

Các anchors phủ dày trên ảnh tạo nhiều mẫu nền dễ phân loại, có thể lấn át gradient từ đối tượng thật. Focal Loss [7] giảm đóng góp của mẫu đã được dự đoán đúng:

$$\mathrm{FL}(p_t) = -\alpha_t(1-p_t)^{\gamma}\log p_t, \qquad \alpha = 0.25, \quad \gamma = 2. \tag{6.2}$$

Với $p_t = 0.9$, hệ số điều chỉnh là 0.01; với $p_t = 0.1$ là 0.81. $\alpha_t = \alpha$ cho mẫu dương, $1-\alpha$ cho mẫu âm; đây là cân bằng foreground/background, không phải cân bằng tần suất 20 lớp. Mỗi anchor có 20 xác suất sigmoid độc lập, không thêm một logit background. Loss phân loại chuẩn hóa theo số anchors dương; bbox dùng Smooth L1 beta 1. Bias classification khởi tạo theo xác suất tiên nghiệm của foreground $\pi = 0.01$.

Bảng 6.3: RetinaNet Table 1: ablation trên COCO minival và đánh đổi tốc độ/AP trên test-dev; số liệu tác giả [7].

Thiết lập	AP	Thời gian
Ablation, COCO minival (Table 1a–d)		
Alpha-balanced CE tốt nhất / Focal Loss	31.1 / 34.0	–
3 scales × 3 ratios	34.0	–
ResNet-101: OHEM tốt nhất / Focal Loss	32.8 / 36.0	–
Tốc độ/chất lượng, COCO test-dev (Table 1e)		
ResNet-50, cạnh ngắn 500	32.5	72 ms
ResNet-50, cạnh ngắn 800	35.7	153 ms

Paper dùng COCO trainval35k, benchmark GPU M40. Focal Loss hơn balanced CE 2.9 điểm AP và OHEM trên ResNet-101 3.2 điểm; tăng resize cải thiện AP nhưng tăng latency. Đây là bằng chứng chọn loss/scale, không phải mốc trực tiếp cho holdout VOC. Tập trung vào mẫu khó cũng có thể nhấn mạnh annotation nhiễu, không bảo đảm giải quyết lớp hiếm/che khuất.

6.4.2 Neck, anchors và head

RetinaNet dùng P3–P7. P3–P5 lấy từ C3–C5; P6 là Conv 3^2/stride 2 trên C5; P7 là Conv 3^2/stride 2 trên ReLU(P6).

Anchor bases 32/64/128/256/512, scales $1, 2^{1/3}, 2^{2/3}$, ratios $0.5, 1, 2$ tạo 9 anchors/vị trí. IoU ≥ 0.5 là positive, < 0.4 là negative, khoảng giữa bỏ qua; matching giữ low-quality matches theo torchvision. Hai subnet có trọng số riêng; mỗi subnet gồm bốn Conv 3^2/256 + ReLU và một Conv output. Trọng số mỗi subnet dùng chung trên các mức; head đối chiếu ở Hình 6.5.

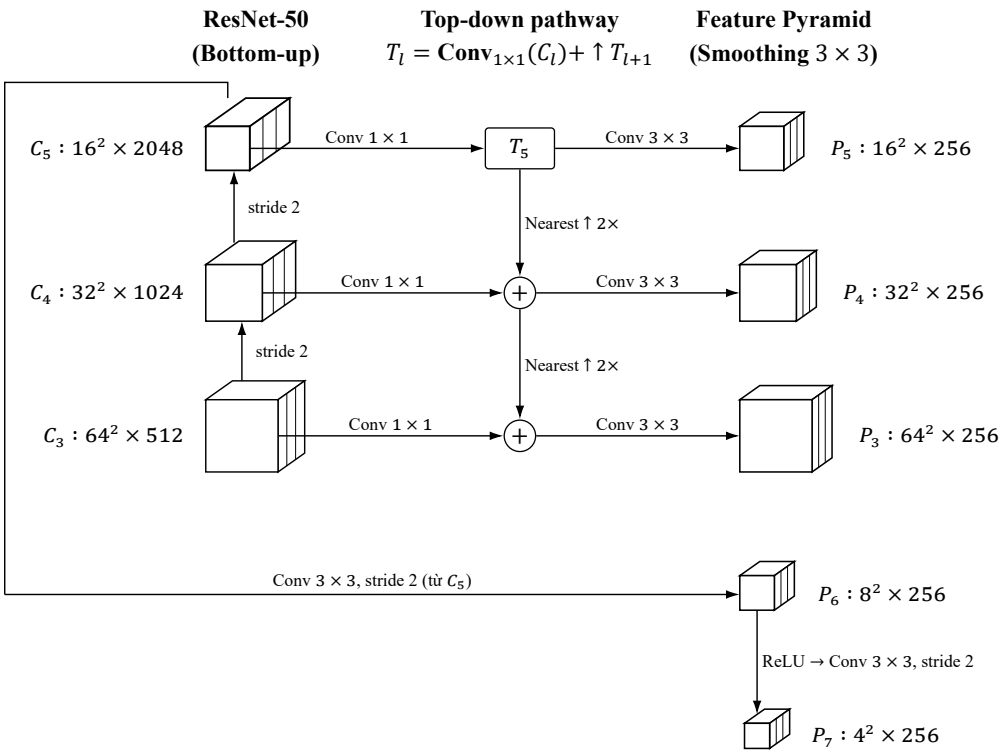

FPN trong RetinaNet sử dụng 5 mức P_3–P_7 để bao phủ các kích thước vật thể từ nhỏ đến rất lớn

(a) RetinaNet: P3–P7, P6 từ C5 và P7 từ ReLU(P6).

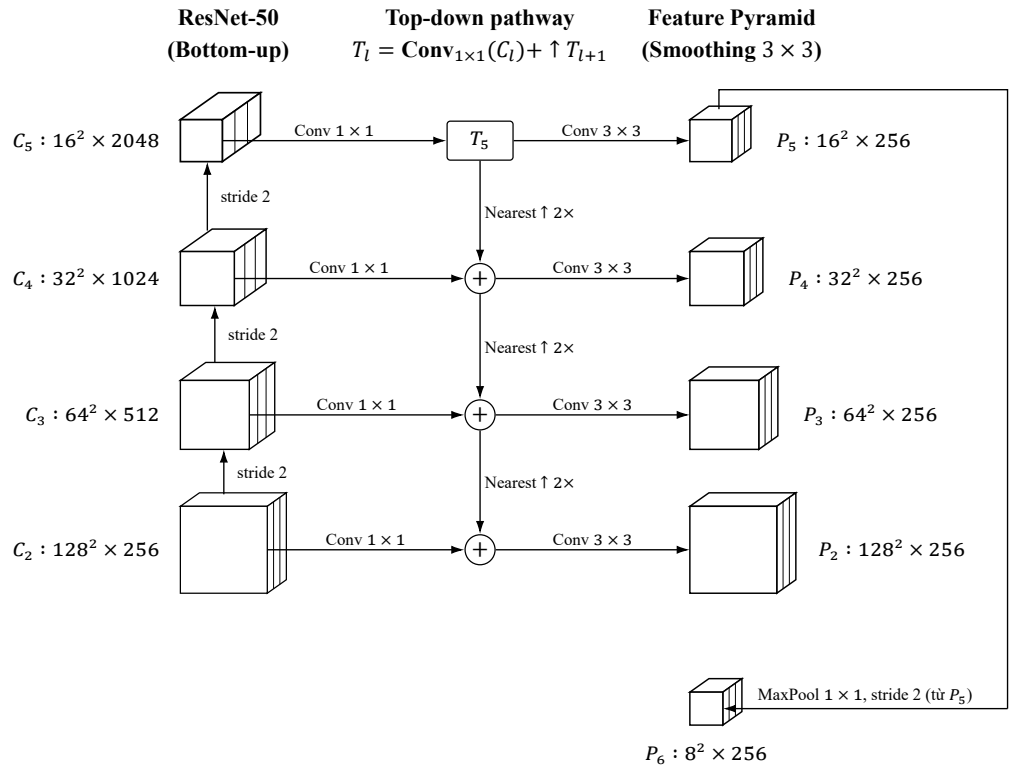

FPN trong Faster R-CNN bổ sung P_2 độ phân giải cao cho vật thể nhỏ; P_6 được dùng riêng cho RPN

(b) Faster R-CNN: P2–P6, P6 maxpool từ P5.

Hình 6.4: Hai FPN ResNet-50: lateral/top-down/smoothing và nhánh mức cao. Shape tại input 512×512 chỉ minh họa; train resize 600/max 1,000. Độ sâu khối gợi channels, không cùng tỷ lệ với không gian.

6.5 Faster R-CNN: RPN và RoI head

Faster R-CNN [8] tạo đề xuất vùng rồi phân loại/hiệu chỉnh vùng. FPN dùng P2–P6 cho RPN; P6 là MaxPool 1^2/stride 2 trên P5. RoI head dùng P2–P5.

RPN gồm Conv $3^2/256$ + ReLU và hai nhánh 1^2 cho objectness/bbox. Bases 32–512, một scale, ba ratios tạo 3 anchors/vị trí. Positive IoU ≥ 0.7 hoặc best anchor, negative < 0.3; sample 256 anchors/ảnh, tối đa 50% positive. NMS proposals dùng 0.7, giữ 2,000 proposals/train và 1,000/test.

RoI gán mức theo FPN:

$$k = \text{clip}_{[2,5]} \left\lfloor 4 + \log_2 \left(\frac{\sqrt{wh}}{224} \right) \right\rfloor. \tag{6.3}$$

RoI Pooling 7^2 lượng tử hóa tọa độ và max pooling, không dùng RoIAlign. Tensor $7 \times 7 \times 256$ flatten thành 12,544, qua hai FC 1,024 + ReLU rồi tách 21 logits và 84 class-specific offsets. Train sample 512 RoIs/ảnh, tối đa 25% positive. Bốn loss gồm RPN objectness/bbox và RoI classification/bbox; hai bbox loss dùng Smooth L1 beta $1/9$. Hai mạng cùng decode bbox, score floor 0.05, class-wise Hard-NMS 0.5, cap 100 detections/ảnh. RetinaNet lọc top 1,000 candidates/mức trước NMS. Bộ ảnh minh họa dùng score từ 0.30 và tối đa 15 boxes; metric không bị giới hạn theo số box hiển thị.

Bảng 6.4: Số tham số trainable. FrozenBatchNorm giữ statistics/buffers cố định.

Mạng	Backbone	FPN	Head/RPN/RoI	Tổng
RetinaNet	23,454,912	7,997,440	5,218,520	36,670,872
Faster R-CNN	23,454,912	3,344,384	14,597,240	41,396,536

6.6 Huấn luyện và lựa chọn weights

ResNet-50 nạp ImageNet-1K V1, bỏ FC ImageNet; các Conv được fine-tune. Các lateral/smoothing chung khởi tạo giống nhau theo seed; head và neck bổ sung khởi tạo mới. Không nạp pretrained detection trên COCO.

Kaggle T4 x2: RetinaNet/GPU 0 và Faster R-CNN/GPU 1 train đồng thời, hai worker độc lập, không DDP hay chia một model qua hai GPU. Train/eval batch 8, accumulation 3, effective batch 24; 1,154 train và 145 val/test batches, 385 updates/epoch. Gradient chuẩn hóa theo số ảnh cửa sổ, kể cả cửa sổ cuối 16 ảnh.

SGD LR 0.01, momentum 0.9, weight decay 10^{-4}; warmup một epoch từ 0.1 lần LR rồi cosine đến 0.01 lần LR theo lịch tối đa 30 epoch. Clip norm 10, AMP float16 convolution; RetinaNet loss/RoI Pool FP32. Dừng theo validation VOC mAP50, patience 2, min-delta 0.001. Best checkpoint cập nhật khi có bất kỳ cải thiện, còn stop counter chỉ reset khi cải thiện hơn min-delta. Weights nạp sẵn được đánh giá validation làm baseline; giới hạn resume ở Chương 1. Sau khi cả hai worker xong, test/benchmark lần lượt trên GPU 0, không chọn epoch/confidence bằng test.

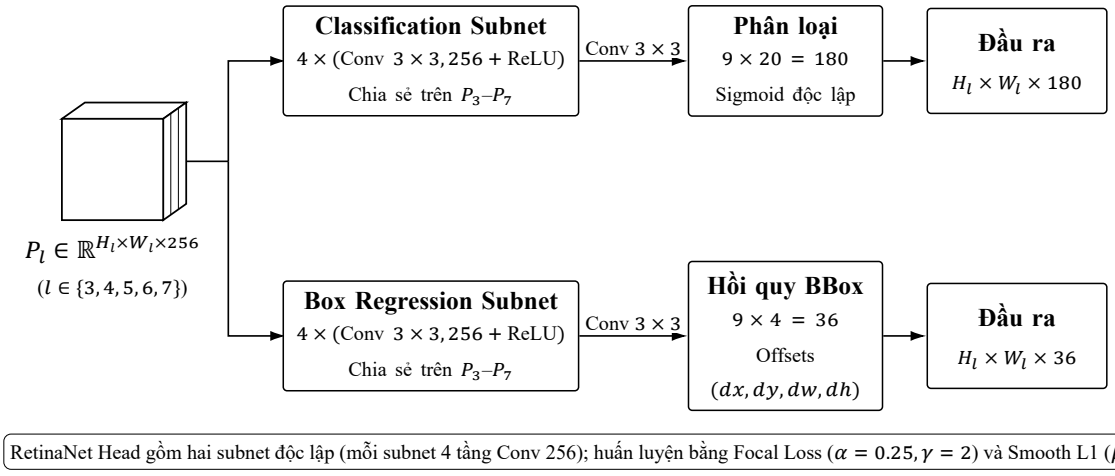

RetinaNet Head gồm hai subnet độc lập (mỗi subnet 4 tầng Conv 256); huấn luyện bằng Focal Loss ($\alpha = 0.25, \gamma = 2$) và Smooth L1 ($\beta = 1$)

(a) RetinaNet: 9×20 class logits và 9×4 bbox offsets/vị trí.

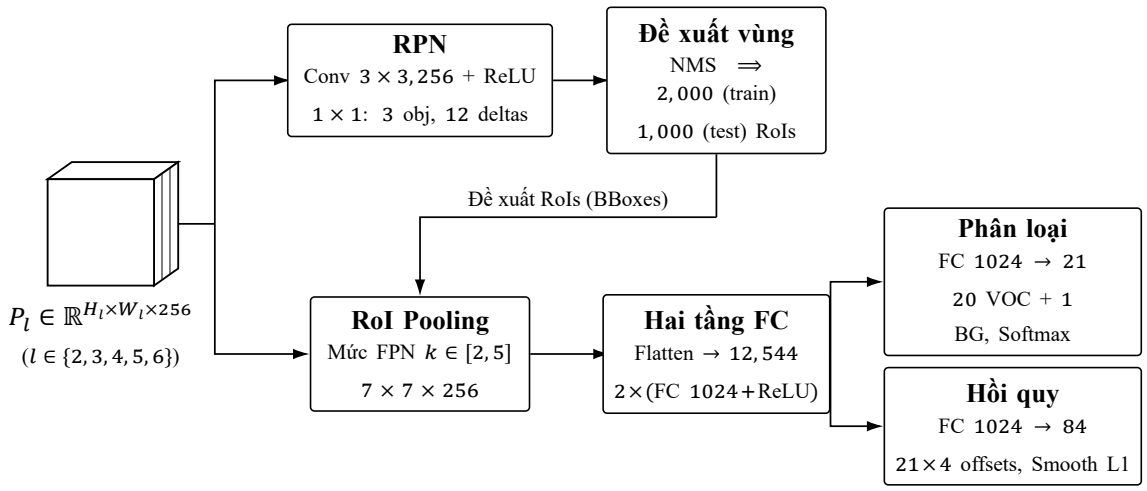

Faster R-CNN gồm hai giai đoạn: RPN đề xuất vùng trên P2–P6; RoI Pooling trích đặc trưng 7×7 trên P2–P5 qua hai tầng FC 1024

(b) Faster R-CNN: RPN, RoI Pool 7×7, hai FC 1,024, nhánh 21 lớp và 84 offsets.

Hình 6.5: Hai detection head trên FPN: (a) dense sigmoid/Focal Loss, (b) proposals và RoI classification/regression. Các subnet RetinaNet chia sẻ trọng số qua P3–P7.

Bảng 6.5: Epoch thực chạy, best epoch, validation VOC mAP50 và số cập nhật SGD.

Mạng	Epoch	Best	Val mAP50	Updates	AMP skips
RetinaNet	21	19	0.7323	8,085	0
Faster R-CNN	17	15	0.7626	6,545	0

Tổng 38 epoch, 14,630 updates, không AMP skips. Worker RetinaNet/Faster R-CNN tốn 465.01/430.23 phút (train/validation/ghi history-checkpoint, không test/vẽ hình). Vì chạy song song, thời gian chờ chung là 465.1 phút, không cộng runtime worker. Best epoch và validation score nằm trong bảng.

Phạm vi đối chiếu paper. *Đã tái hiện:* lateral connections, top-down pathway, smoothing, cách tạo các mức pyramid và head/loss theo cấu hình triển khai. *Đã thay đổi:* dùng VOC2012 thay COCO, train joint RPN/RoI thay lịch feature sharing bốn bước của FPN. RetinaNet paper dùng batch 16 và lịch 90k iterations với các mốc giảm LR; ở đây dùng effective batch 24, lịch SGD theo epoch/cosine/dừng sớm và resize chung 600/max 1,000. ResNet-v1.5, anchor rounding,

low-quality matching và Smooth L1 theo torchvision cũng khác một số chi tiết của tác giả. *Chưa tái hiện:* benchmark COCO và các phép ablation cô lập đóng góp của FPN/Focal Loss. Hai detector dùng chung split, backbone khởi tạo, resize, optimizer và protocol đánh giá để so sánh trong phạm vi holdout VOC.

6.7 Chỉ số đánh giá

VOC2010–2012 mAP50 all-point là metric chính: sort score, matching one-to-one cùng class, IoU > 0.5, tích phân precision envelope theo recall [3]. Duplicate thường là FP; matches difficult bị bỏ qua. VOC07 AP11 bổ sung để phân biệt cách nội suy.

COCO-style AP trung bình 10 ngưỡng IoU 0.50–0.95, bước 0.05, 101 recall points, max 100 detections/ảnh [1]. AP50/AP75 và AP/AR theo scale bổ sung phân tích định vị. Small/medium/large dùng diện tích bbox ảnh gốc, theo mốc $32^2/96^2$. Evaluator giữ union IoU và bỏ qua repeated matches difficult theo VOC. Đây là metric COCO-style trên VOC, không phải điểm chính thức COCO; cách xử lý difficult không tương đương crowd annotation của COCO. VOC AP50 và COCO-style AP50 khác cách nội suy/biên IoU.

P/R/F1 dùng matching class-wise VOC tại score 0.30; micro-F1 gộp TP/FP/FN, macro-F1 trung bình 20 lớp. Ma trận chẩn đoán dùng class-agnostic greedy theo score, IoU ≥ 0.5, để nhìn nhầm lớp. Background biểu diễn FP/FN. Matched IoU là trung bình TP trong chẩn đoán, không thay thế AP. Score floor/cap chung có thể giới hạn recall, được giữ như nhau ở hai mạng.

6.8 Kết quả test và so sánh

Bảng 6.6: Test holdout 1,154 ảnh, 2,687 bbox thường. Metric ở thang 0–1.

Chỉ số	RetinaNet	Faster R-CNN
VOC mAP50	0.7088	0.7316
VOC07 mAP11	0.6886	0.7123
COCO-style AP50:95	0.3913	0.4098
COCO-style AP50	0.7077	0.7308
COCO-style AP75	0.3767	0.4189
Precision (score 0.30)	0.5037	0.3873
Recall (score 0.30)	0.7838	0.8366
Micro-F1 (score 0.30)	0.6133	0.5295
Macro-F1 (score 0.30)	0.5836	0.5324
Matched IoU (chẩn đoán)	0.7707	0.7775

Trên holdout VOC2012, Faster R-CNN đạt VOC mAP50 và COCO-style AP50:95 cao hơn RetinaNet trong hai cấu hình đã thử. RetinaNet ít tham số hơn và có median latency batch 1 thấp hơn. P95 latency và throughput pipeline không cùng thứ tự với median GPU-only, nên không có model vượt trội mọi chỉ số. Hai detector khác đồng thời về FPN levels, anchors, matching, head và loss; phép so sánh không cô lập riêng hiệu quả one-stage/two-stage. Khoảng

cách validation–test mAP50 là 2.35/3.10 điểm phần trăm.

Ở score 0.30, Faster R-CNN ưu tiên recall nhưng RetinaNet có precision/F1 cao hơn. AP tổng hợp cả thứ hạng precision–recall, F1 chỉ phản ánh một confidence cố định; hai thứ tự không mâu thuẫn. Confidence được giữ trước test.

Bảng 6.7: COCO-style AP theo scale và AR trung bình qua các ngưỡng IoU.

Chỉ số	RetinaNet	Faster R-CNN
AP small	0.1296	0.1392
AP medium	0.2684	0.3057
AP large	0.4473	0.4606
AR@1	0.3730	0.3862
AR@10	0.5210	0.5386
AR@100	0.5345	0.5437
AR small	0.2860	0.2038
AR medium	0.4238	0.4616
AR large	0.5814	0.5866

APsmall thấp hơn nhiều APlarge. Faster R-CNN cao hơn APsmall 0.96 điểm, nhưng RetinaNet cao hơn ARsmall: recall và AP không đo cùng đánh đổi. Không quy riêng lợi ích cho P2 vì nhiều thành phần khác nhau. AR@10 lên AR@100 chỉ tăng 0.0135/0.0051, nên cap cao hơn đem lại ít recall.

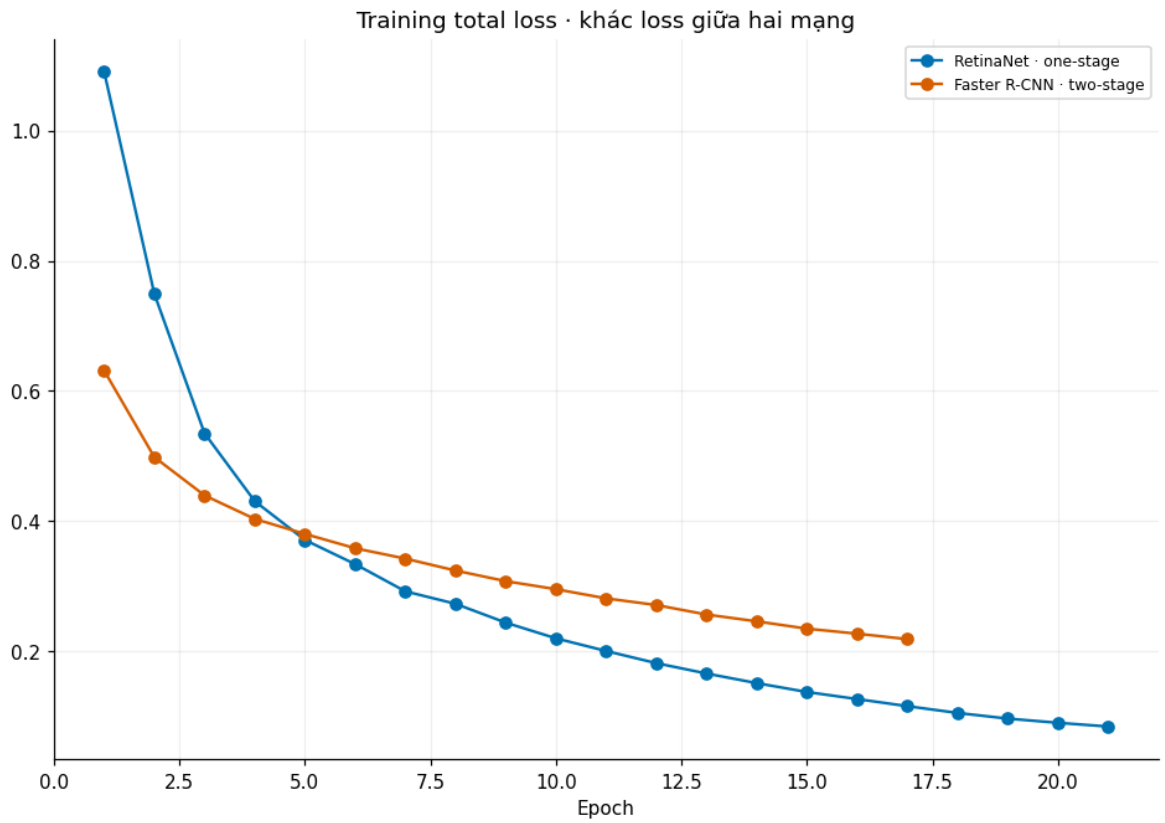

Hình 6.6: Tổng loss train của hai detector; độ lớn loss không dùng xếp hạng vì thành phần và chuẩn hóa khác nhau.

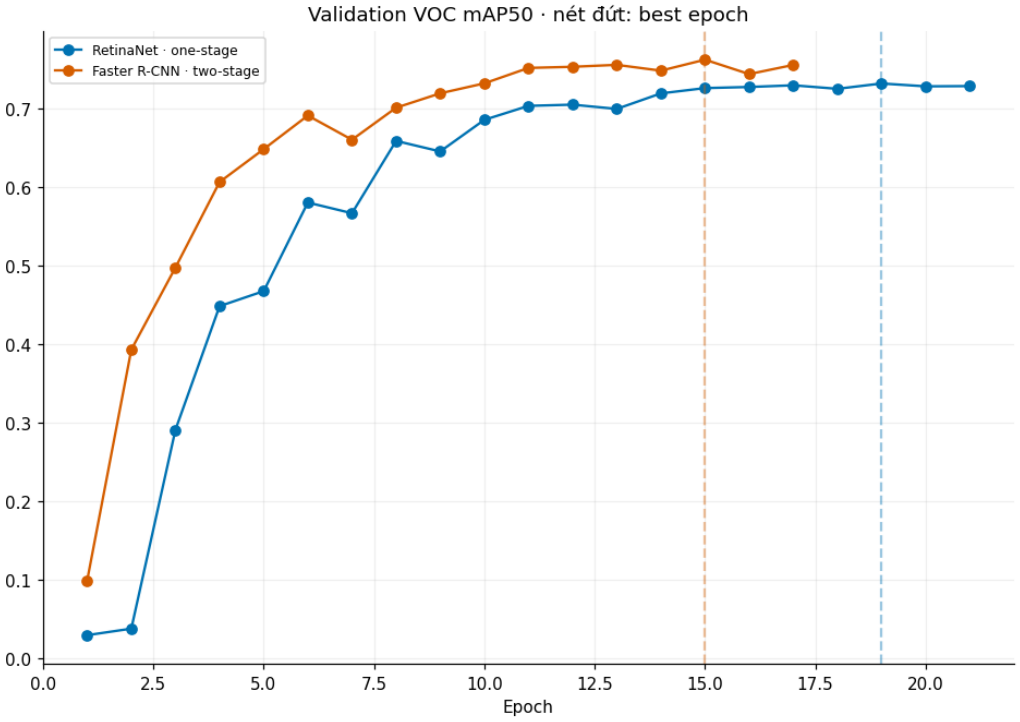

(a) VOC mAP50

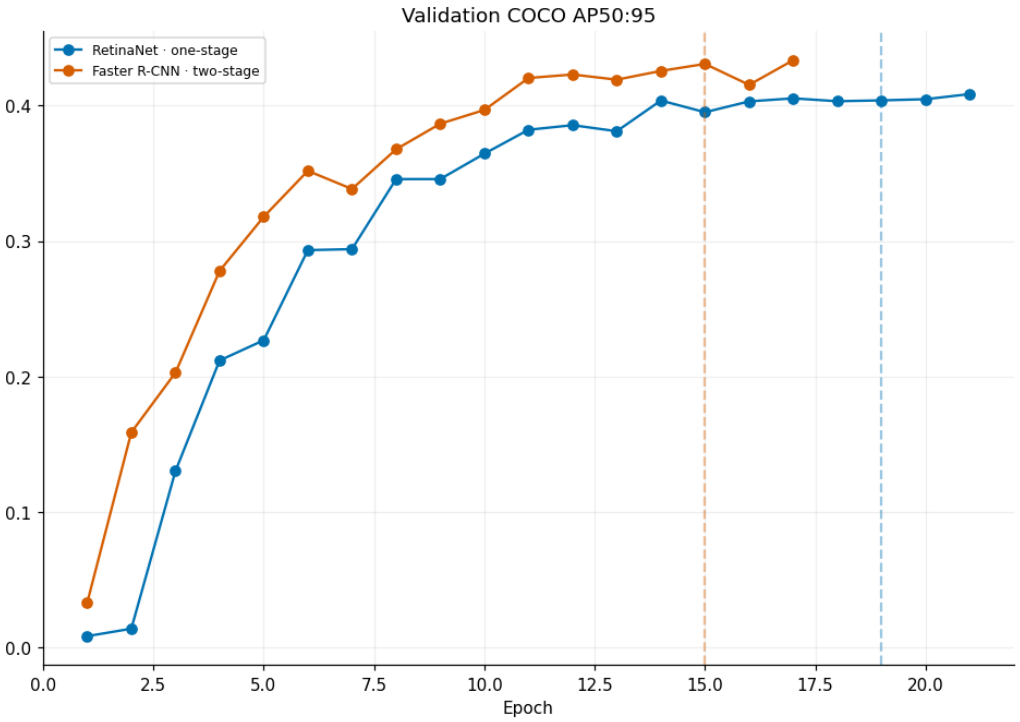

(b) COCO-style AP50:95 trên VOC2012.

Hình 6.7: Validation A2: hai detector, nét đứt đứng đánh dấu best epoch; metric ở thang 0–1.

Loss giảm khi validation gần bão hòa (Hình 6.7); RetinaNet chạy nhiều epoch hơn nhưng không cao hơn AP test. Các thành phần loss ở Hình 6.8 khác nhau về số lượng/chuẩn hóa, không dùng xếp hạng model.

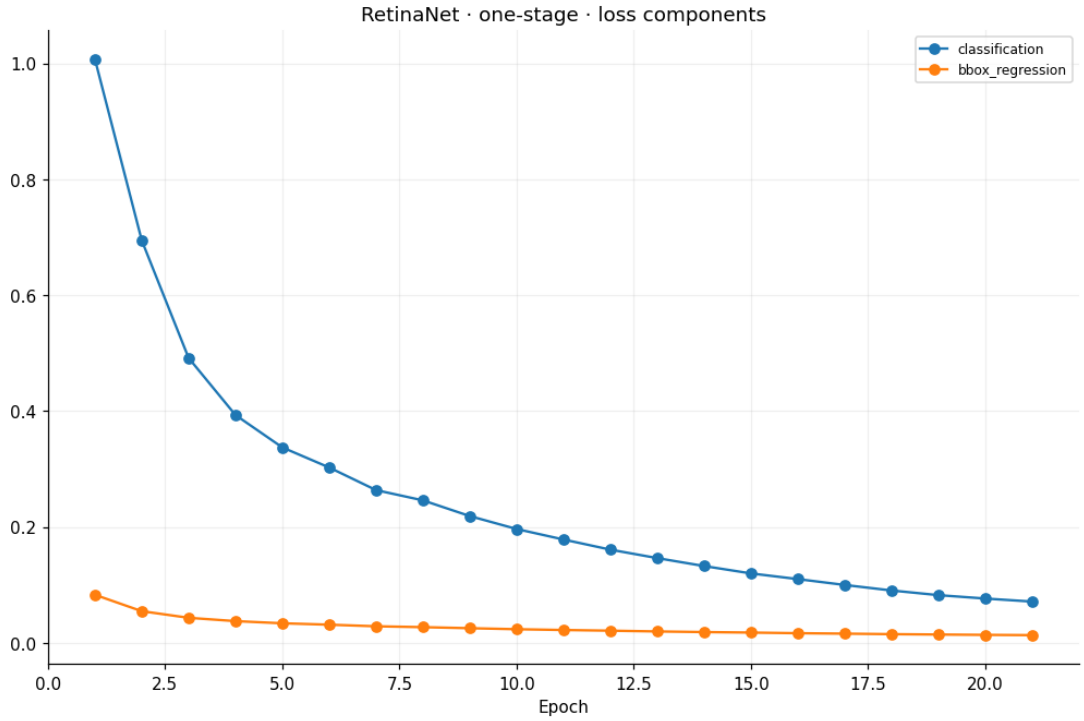

(a) RetinaNet: classification và bbox.

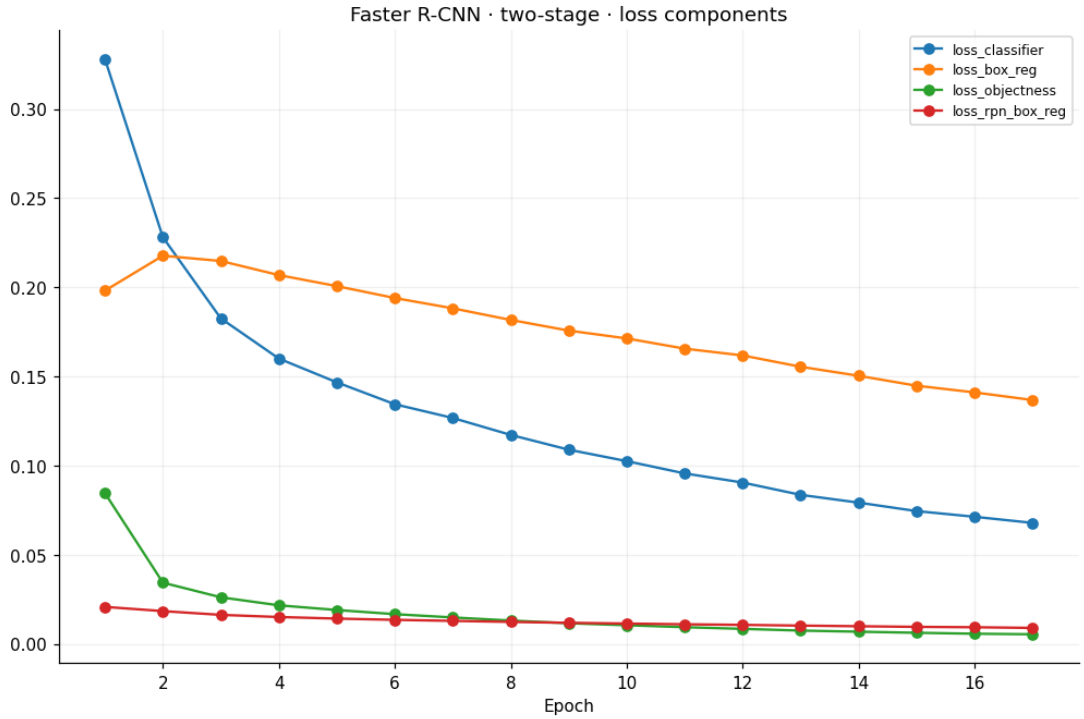

(b) Faster R-CNN: hai loss RPN và hai loss RoI.

Hình 6.8: Thành phần loss train A2; mỗi panel giữ nhãn loss trong output, không dùng độ lớn loss xếp hạng kiến trúc.

Chi phí huấn luyện và suy luận.

Bảng 6.8: Chi phí trên Tesla T4. Peak là allocated PyTorch từng worker; benchmark hai model lần lượt trên cùng GPU 0. VRAM làm tròn một chữ số; thời gian và tốc độ làm tròn hai chữ số thập phân.

Chỉ số	RetinaNet	Faster R-CNN
Tham số	36,670,872	41,396,536
Peak allocated VRAM (MiB)	12,818.5	12,939.5
Train + validation (phút)	465.01	430.23
Median latency batch 1 (ms)	39.87	44.09
P95 latency batch 1 (ms)	47.38	45.79
FPS batch 1	25.08	22.68
Throughput batch 8 (ảnh/s)	17.67	15.19
Batch benchmark	8	8
Pipeline test (ảnh/s)	13.83	14.48

Train/validation trung bình 22.14/25.31 phút mỗi epoch; Faster R-CNN có tổng runtime riêng thấp hơn do ít epoch. Số tham số không đủ dự đoán chi phí.

Benchmark AMP/CUDA events: warmup 3 lượt, batch 1 đo 20 lần, batch 8 đo 10 lần. GPU latency gồm resize/normalize, backbone/FPN/head và decode/NMS; không gồm JPEG/H2D/metric CPU. RetinaNet hơn khoảng 10.6% FPS median batch 1, nhưng P95 không cùng thứ tự. Batch 1 và 8 dùng ảnh khác tỷ lệ/padding, nên không phải workload đồng nhất để suy scaling theo batch.

Pipeline test gồm DataLoader/H2D/thu predictions về CPU, không gồm metric; Faster R-CNN cao hơn ở phép đo này. Peak dùng allocated PyTorch từng worker. Kết quả áp dụng cho workload T4 đã đo, không suy tốc độ mọi ảnh/phần cứng.

6.9 Theo lớp, ma trận và trường hợp sai

Bảng 6.9: AP50 là VOC all-point AP tại IoU 0.5; AP là COCO-style AP50:95. R và F lần lượt chỉ RetinaNet và Faster R-CNN. F1 tính tại confidence 0.30.

Lớp	GT	R AP50	F AP50	R AP	F AP	R F1	F F1
aeroplane	76	0.7757	0.7752	0.4617	0.4761	0.6243	0.6448
bicycle	80	0.8074	0.8405	0.4664	0.4842	0.6878	0.5681
bird	88	0.8353	0.7748	0.4322	0.4351	0.6609	0.6303
boat	99	0.5562	0.6065	0.2442	0.2465	0.5210	0.4928
bottle	109	0.6330	0.6252	0.3143	0.3276	0.5153	0.4883
bus	62	0.8706	0.8982	0.5768	0.5908	0.6250	0.4609
car	204	0.8186	0.8362	0.4994	0.4750	0.6252	0.4753
cat	135	0.9178	0.9107	0.5354	0.5262	0.7697	0.6513
chair	175	0.4547	0.4842	0.1987	0.2206	0.4265	0.3666
cow	67	0.6813	0.7748	0.3559	0.4190	0.5171	0.6087
diningtable	48	0.3173	0.5423	0.1488	0.2789	0.3279	0.5082
dog	159	0.8530	0.8697	0.5189	0.5157	0.6682	0.6729
horse	68	0.8287	0.8025	0.4855	0.4889	0.5911	0.6506
motorbike	75	0.8222	0.8149	0.4677	0.4498	0.6231	0.5185
person	866	0.8229	0.8429	0.4001	0.4464	0.6654	0.5613
pottedplant	72	0.3072	0.3012	0.1271	0.1342	0.3704	0.2558
sheep	83	0.7221	0.7632	0.4309	0.4544	0.5603	0.6244
sofa	49	0.5919	0.5733	0.3201	0.3186	0.5691	0.3111
train	77	0.8125	0.8132	0.4585	0.4459	0.6425	0.6740
tvmonitor	95	0.7479	0.7822	0.3831	0.4616	0.6800	0.4841

Cat, bus và dog có VOC AP50 cao; pottedplant/chair khó hơn ở cả hai model. Faster R-CNN cải thiện diningtable từ 0.3173 lên 0.5423 (22.50 điểm phần trăm) và cow từ 0.6813 lên 0.7748. RetinaNet cao hơn ở bird (0.8353/0.7748) và bottle (0.6330/0.6252). Trung bình toàn tập che khuất các khác biệt theo lớp.

Phụ lục giữ PR curves 20 lớp và ma trận chẩn đoán phần trăm theo hàng: background hàng là prediction không ghép GT, background cột là GT bỏ sót. P/R/F1 tính class-wise riêng. Cùng ba preview, FP RetinaNet/Faster R-CNN lần lượt 0/3 (tvmonitor), 1/0 (boat), 3/2 (horse).

Ba failure cases minh họa các nhóm lỗi: car/bottle có FP 4/11; kiosk có một FN ở RetinaNet, Faster R-CNN tìm được GT nhưng có 10 FP; boat còn lại có TP=1, FP=3 ở RetinaNet và nhầm lớp=1, FP=9 ở Faster R-CNN. Chẩn đoán dùng mọi detection score ≥ 0.30, bộ ảnh minh họa chỉ vẽ tối đa 15 boxes. Không suy tần suất toàn tập từ mẫu chọn sau test. Prediction không ghép GT có thể lặp, lệch bbox, nhầm lớp hoặc vật thể không có annotation; cần đọc cùng GT.

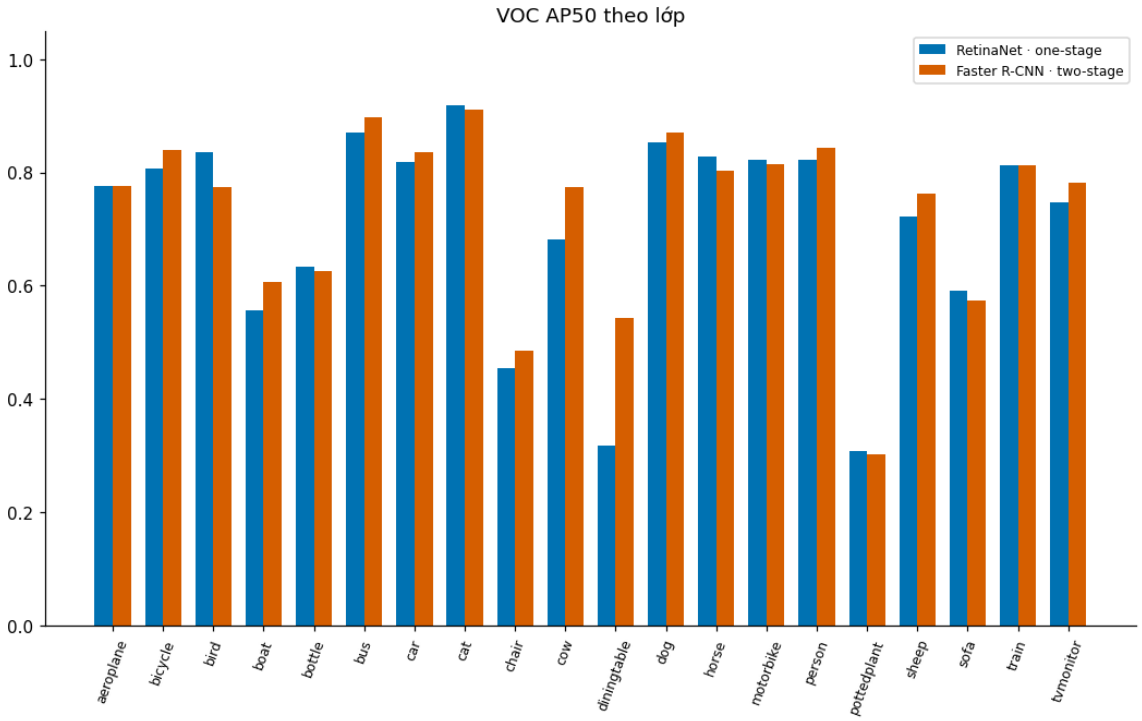

(a) VOC AP50

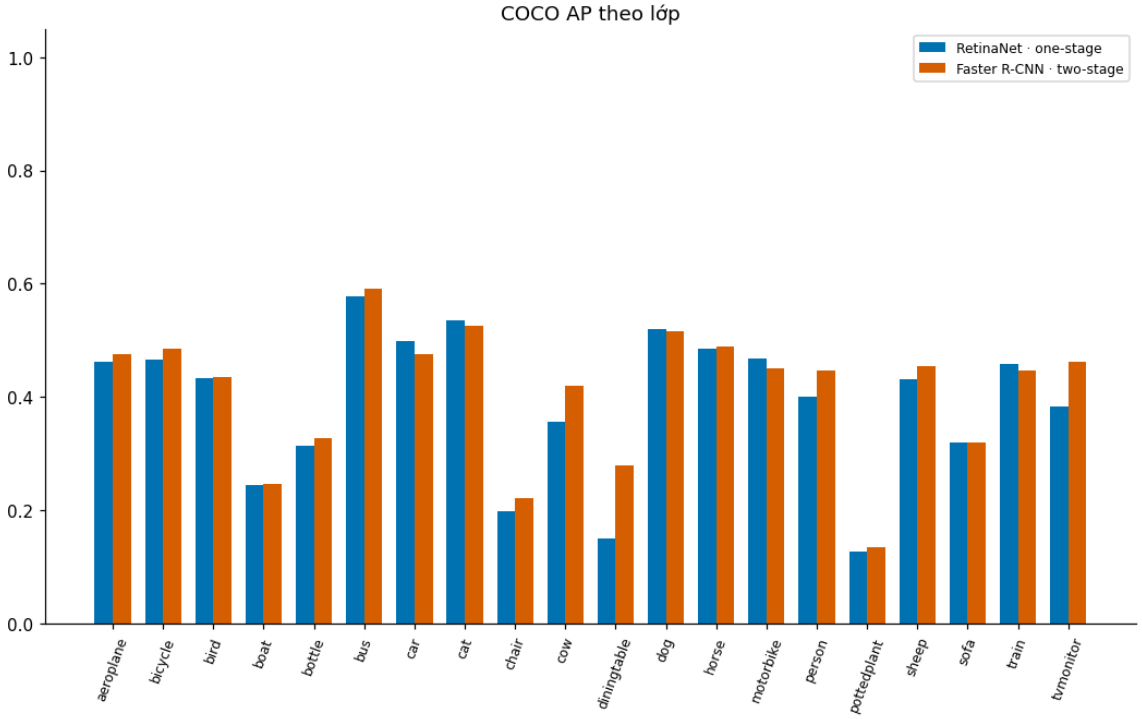

(b) COCO-style AP50:95 trên VOC2012.

Hình 6.9: AP từng lớp trên cùng test holdout và cùng thứ tự 20 lớp; hai detector dùng chung trục (0–1).

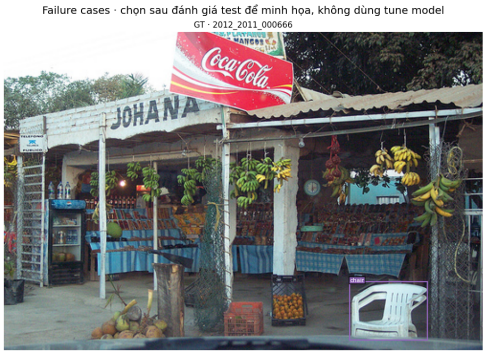

(a) Ground truth

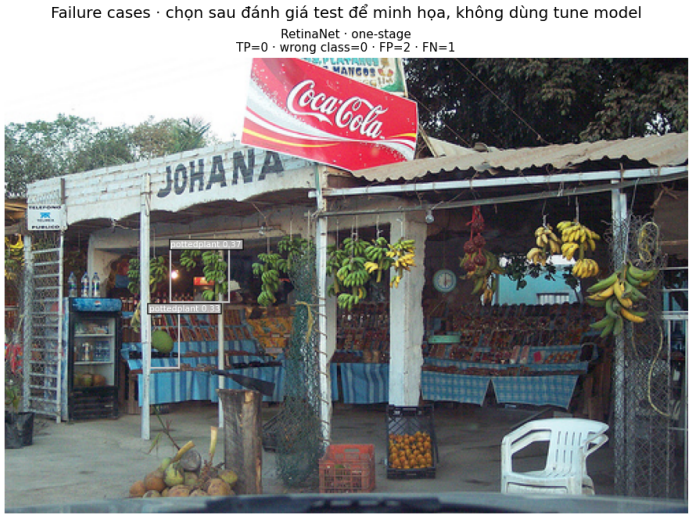

(b) RetinaNet

(c) Faster R-CNN

Hình 6.10: Đối chiếu lỗi trên ảnh VOC2012 test 2012_2011_000666. Cùng confidence ≥ 0.30; ảnh dự đoán hiển thị tối đa 15 bbox, còn số chẩn đoán dùng mọi detection vượt ngưỡng.

Một GT lớp chair nằm ở góc dưới phải. RetinaNet có TP=0, FN=1 và 2 FP; Faster R-CNN có TP=1, FN=0 và 10 FP. FP theo annotation/matching có thể gồm dự đoán lặp hoặc vật thể không được gán nhãn. Mẫu chọn sau test chỉ minh họa đánh đổi giữa bỏ sót và dự đoán thừa, không ước lượng tần suất lỗi.

6.10 Kết luận A2 và giới hạn

Faster R-CNN tốt hơn về VOC mAP50, COCO-style AP50:95/AP75, recall tại score 0.30 và APsmall. RetinaNet có precision/F1 cao hơn ở ngưỡng này, ít tham số hơn và FPS median batch 1 cao hơn. Lựa chọn phụ thuộc ưu tiên chất lượng AP, precision–recall và workload suy luận; P95 và pipeline không cùng thứ tự với median.

Kết luận dựa trên một seed và holdout nội bộ. Hai mạng khác nhiều thành phần cùng lúc, chưa cô lập riêng P2, Focal Loss hoặc proposals. Giới hạn epoch, dừng sớm, score floor/cap, nhãn difficult và resize ảnh hưởng phép so sánh. Các hướng tiếp theo là nhiều seed, ablation neck/anchors với head giữ cố định và chọn confidence bằng validation; chưa nằm trong kết quả báo cáo.

7. Kết luận

E1–E3 cho thấy biểu diễn ảnh ảnh hưởng cả chất lượng và chi phí. CNN-B có đánh đổi giữa accuracy và số tham số thuận lợi so với CNN-A; CNN-stem cải thiện MSA nhưng tăng số tham số. MSA thủ công khớp phép toán PyTorch; số head không có tác dụng đơn điệu. GRU Rows tốt nhất trong các cấu hình recurrent, song CNN-B hiệu quả hơn trên ảnh tĩnh.

A1 chọn full pretrained bằng validation ở cả hai họ. DeiT có accuracy trung bình ba seed cao hơn; ResNet suy luận nhanh hơn và ít peak memory hơn. Head-only thiếu khả năng thích nghi; partial phải đọc cùng phạm vi unfreeze. Augmentation có lợi cho hai họ trong ablation seed 42.

A2 cho thấy Faster R-CNN cao hơn ở VOC mAP50 và COCO-style AP50:95/AP75; RetinaNet cao hơn ở precision/F1 tại score 0.30 và FPS median batch 1. P95 và throughput pipeline đổi thứ tự, nên không có detector tốt nhất mọi tiêu chí. FPN/Focal Loss hỗ trợ detection nhưng chưa giải quyết hết vật thể nhỏ, nhầm lớp và dự đoán thừa.

Các kết luận phụ thuộc split, seed, ngân sách và trạng thái weights đầu vào. Hướng chưa thực hiện gồm nhiều seed cho E1–E3/A2, đối chứng cùng số tham số, cô lập neck/anchors và kiểm tra độc lập theo track GTSRB.

Ghi nhận hỗ trợ của công cụ AI. AI hỗ trợ lập trình, kiểm tra code, tổng hợp output, đối chiếu tài liệu và biên tập LaTeX/TikZ. Số liệu lấy từ notebook đã chạy, không được tạo để minh họa. Nhóm thực hiện chịu trách nhiệm hiểu, kiểm chứng và bảo vệ code, kết quả và phân tích; phạm vi hỗ trợ được ghi nhận theo mục 1.6 đề E1–E3.

Tài liệu tham khảo

[1] COCO Consortium. COCO Detection Evaluation, 2015. URL https://cocodataset.org/dataset/detection-eval.htm.

[2] Mark Everingham, Luc Van Gool, Christopher K. I. Williams, John Winn, and Andrew Zisserman. The PASCAL Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision*, 88:303–338, 2010. doi: 10.1007/s11263-009-0275-4.

[3] Mark Everingham et al. The PASCAL Visual Object Classes Challenge 2012 Development Kit, 2012. URL https://www.robots.ox.ac.uk/~vgg/projects/pascal/VOC/voc2012/htmldoc/index.html.

[4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep Residual Learning for Image Recognition. In *CVPR*, 2016. URL https://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html.

[5] Institut für Neuroinformatik, Ruhr-Universität Bochum. German Traffic Sign Benchmarks: GTSRB Dataset. GTSRB dataset page, Citation section, 2019. Nội dung được đối chiếu qua bản trang do công cụ tìm kiếm lưu chỉ mục; truy cập trực tiếp không khả dụng ngày 17/10/2026.

[6] Tsung-Yi Lin, Piotr Dollar, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature Pyramid Networks for Object Detection. In *CVPR*, 2017. URL https://openaccess.thecvf.com/content_cvpr_2017/html/Lin_Feature_Pyramid_Networks_CVPR_2017_paper.html.

[7] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollar. Focal Loss for Dense Object Detection. In *ICCV*, pages 2980–2988, 2017. URL https://openaccess.thecvf.com/content_ICCV_2017/html/Lin_Focal_Loss_for_ICCV_2017_paper.html.

[8] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. In *NeurIPS*, 2015. URL https://arxiv.org/abs/1506.01497.

[9] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. The German Traffic Sign Recognition Benchmark: A Multi-class Classification Competition. In *International Joint Conference on Neural Networks*, pages 1453–1460, 2011.

[10] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. Man vs. Computer: Benchmarking Machine Learning Algorithms for Traffic Sign Recognition. *Neural Networks*, 32:323–332, 2012. doi: 10.1016/j.neunet.2012.02.016.

[11] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. German Traffic Sign Recognition Benchmark: Public Archive. GTSRB Public Archive (ERDA), 2019. Accessed 8 October 2026.

[12] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Herve Jegou. Training Data-Efficient Image Transformers and Distillation Through Attention. In *ICML*, 2021. URL https://proceedings.mlr.press/v139/touvron21a.html.

[13] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. *arXiv:1708.07747*, 2017. URL https://arxiv.org/abs/1708.07747.

A. Kết quả chi tiết và tái lập

A.1 Chi tiết huấn luyện E1–E3 và A1

Các bảng dưới ghi số epoch đã chạy, best epoch, optimizer updates thực tế, AMP skips và peak allocated MiB. Chúng đối chiếu trực tiếp output cell, không suy số updates chỉ từ số epoch.

Bảng A.1: Chi tiết lượt train E1.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
Softmax	12	8	5,064	0	18
MLP	20	16	8,440	0	22
CNN-A	12	8	5,064	0	50
CNN-B	20	16	8,440	0	56

Bảng A.2: Chi tiết lượt train E2; ký hiệu M/T và R/P/C như Chương E2.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
M-R4	20	16	8,440	0	43
M-P4	23	19	9,706	0	69
M-C4	24	20	10,127	1	78
T-R4	20	16	8,440	0	47
T-P4	23	19	9,706	0	79
T-C4	23	19	9,706	0	89
M-C2	22	18	9,284	0	70
M-C8	22	18	9,284	0	99

Bảng A.3: Chi tiết lượt train E3.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
LSTM Rows	18	14	7,596	0	27
LSTM Columns	23	19	9,706	0	27
LSTM Patch	20	16	8,440	0	33
GRU Rows	20	20	8,440	0	28
GRU Columns	23	19	9,706	0	28
GRU Patch	24	20	10,128	0	35
MLP	20	16	8,440	0	22
CNN-B	20	16	8,440	0	56

Bảng A.4: Chi tiết tám lượt train chính A1.

Run	Epoch	Best	Updates	AMP skips	Peak MiB
R-S/42	7	5	1,722	0	5828
R-H/42	10	8	2,460	0	1567
R-P/42	7	5	1,722	0	1682
R-F/42	4	2	984	0	5827
D-S/42	11	9	2,706	0	6631
D-H/42	12	10	2,952	0	636
D-P/42	6	4	1,476	0	1373
D-F/42	8	6	1,968	0	6635

Bảng A.5: Epoch, cập nhật và peak memory của sáu run mở rộng A1.

Run	Epoch	Best	Updates	AMP skips	Peak MiB
R-F/42 no-aug	3	3	738	0	5830
R-F/43	3	1	738	0	5829
R-F/44	5	3	1,230	0	5830
D-F/42 no-aug	3	2	738	0	6631
D-F/43	10	8	2,460	0	6635
D-F/44	5	3	1,230	0	6635

A.2 Metric theo lớp và độ nhạy A1

Hai cột model là full pretrained seed 42, được chọn bằng validation. Support là số ảnh test nguồn. ID tra bằng bảng tên lớp dưới đây.

Bảng A.6: Precision/recall/F1 trên test GTSRB, lớp 0–21.

ID	Lớp	n	R-P	R-R	R-F1	D-P	D-R	D-F1
0	Speed limit 20	60	1.000	0.967	0.983	1.000	0.500	0.667
1	Speed limit 30	720	0.977	1.000	0.988	0.997	0.997	0.997
2	Speed limit 50	750	0.957	0.991	0.974	0.999	0.997	0.998
3	Speed limit 60	450	1.000	0.958	0.978	1.000	0.993	0.997
4	Speed limit 70	660	0.994	0.986	0.990	0.997	0.998	0.998
5	Speed limit 80	630	0.988	0.944	0.966	0.994	0.998	0.996
6	End speed limit 80	150	0.955	1.000	0.977	1.000	0.973	0.986
7	Speed limit 100	450	0.968	0.993	0.980	0.976	1.000	0.988
8	Speed limit 120	450	0.991	0.991	0.991	0.937	0.996	0.966
9	No passing	480	0.939	0.998	0.968	0.986	1.000	0.993
10	No passing >3.5t	660	1.000	0.980	0.990	0.998	1.000	0.999
11	Right-of-way intersection	420	0.997	0.921	0.958	0.978	0.971	0.975
12	Priority road	690	1.000	0.999	0.999	0.996	1.000	0.998
13	Yield	720	0.996	0.999	0.997	1.000	0.997	0.999
14	Stop	270	1.000	0.993	0.996	0.996	1.000	0.998
15	No vehicles	210	1.000	0.990	0.995	0.991	0.995	0.993
16	Vehicles >3.5t prohibited	150	1.000	0.907	0.951	0.987	1.000	0.993
17	No entry	360	0.992	1.000	0.996	1.000	0.969	0.984
18	General caution	390	0.972	0.969	0.970	0.982	0.990	0.986
19	Dangerous curve left	60	1.000	1.000	1.000	1.000	1.000	1.000
20	Dangerous curve right	90	0.989	1.000	0.994	1.000	1.000	1.000
21	Double curve	90	0.934	0.944	0.939	0.968	1.000	0.984

Bảng A.7: Precision/recall/F1 trên test GTSRB, lớp 22–42.

ID	Lớp	n	R-P	R-R	R-F1	D-P	D-R	D-F1
22	Bumpy road	120	1.000	0.758	0.863	0.991	0.950	0.970
23	Slippery road	150	0.879	0.967	0.921	0.968	1.000	0.984
24	Road narrows right	90	1.000	0.989	0.994	0.947	1.000	0.973
25	Road work	480	0.885	0.994	0.936	0.985	0.967	0.976
26	Traffic signals	180	0.989	0.989	0.989	1.000	0.972	0.986
27	Pedestrians	60	0.882	0.500	0.638	1.000	0.883	0.938
28	Children crossing	150	1.000	0.993	0.997	1.000	1.000	1.000
29	Bicycle crossing	90	0.978	1.000	0.989	1.000	1.000	1.000
30	Ice/snow caution	150	0.937	0.987	0.961	0.917	0.960	0.938
31	Wild animals crossing	270	0.971	0.996	0.984	0.993	1.000	0.996
32	End speed/passing limits	60	1.000	1.000	1.000	1.000	1.000	1.000
33	Turn right ahead	210	0.991	1.000	0.995	1.000	1.000	1.000
34	Turn left ahead	120	1.000	1.000	1.000	0.992	1.000	0.996
35	Ahead only	390	0.992	0.974	0.983	1.000	0.982	0.991
36	Straight or right	120	0.991	0.933	0.961	0.976	1.000	0.988
37	Straight or left	60	0.968	1.000	0.984	1.000	1.000	1.000
38	Keep right	690	0.991	0.996	0.993	0.989	1.000	0.994
39	Keep left	90	1.000	0.989	0.994	1.000	1.000	1.000
40	Roundabout mandatory	90	0.913	0.933	0.923	1.000	0.844	0.916
41	End no passing	60	0.982	0.933	0.957	1.000	1.000	1.000
42	End no passing >3.5t	90	1.000	0.944	0.971	0.927	0.989	0.957

Bảng A.8: Độ nhạy A1 với 8 ảnh test trùng train; accuracy tính bằng %.

Run	Full acc	Clean acc	Δ (điểm%)	Full F1	Clean F1
R-S/42	96.33	96.33	-0.002	0.9447	0.9447
R-H/42	67.33	67.31	-0.021	0.5759	0.5758
R-P/42	95.21	95.21	-0.003	0.9261	0.9261
R-F/42	97.83	97.83	-0.001	0.9678	0.9678
D-S/42	88.64	88.63	-0.007	0.8267	0.8267
D-H/42	69.41	69.39	-0.019	0.6016	0.6015
D-P/42	87.85	87.85	-0.008	0.8063	0.8063
D-F/42	98.92	98.91	-0.001	0.9790	0.9790

Full test có 12,630 ảnh, clean test có 12,622; mọi accuracy tính bằng %. Bảng ghi mức làm tròn trong output; delta tính trên giá trị chưa làm tròn nên không nhất thiết bằng phép trừ hai cột accuracy hiển thị.

A.3 Đường cong theo tokenizer và biểu diễn chuỗi

Mỗi cặp gồm loss và accuracy cùng thí nghiệm; train nét đứt, validation nét liền. Các model dùng chung split và protocol với bảng kết quả ở phần chính.

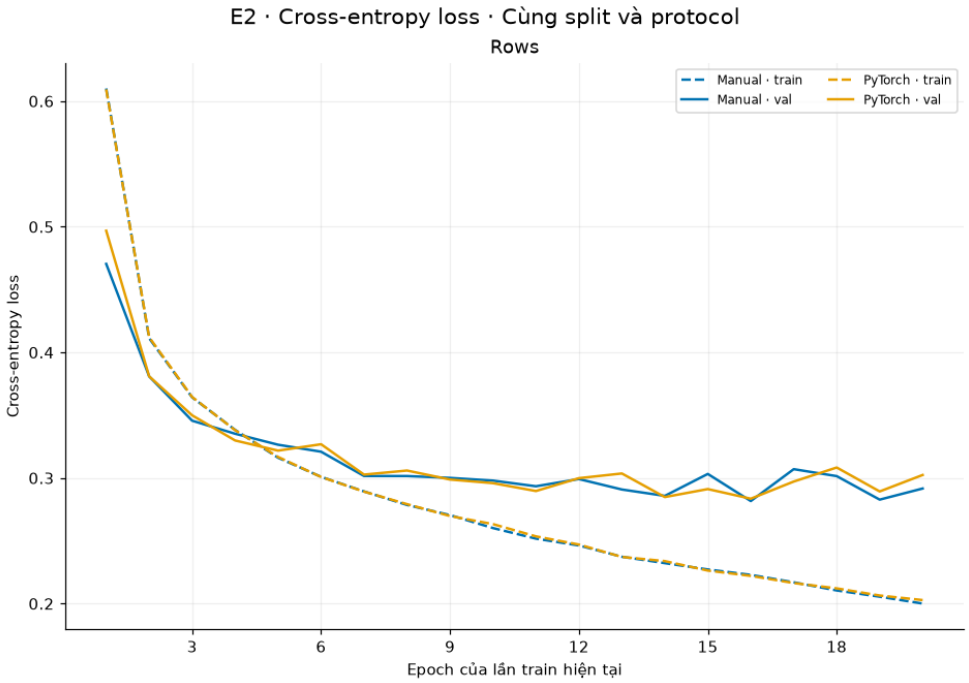

(a) Cross-entropy

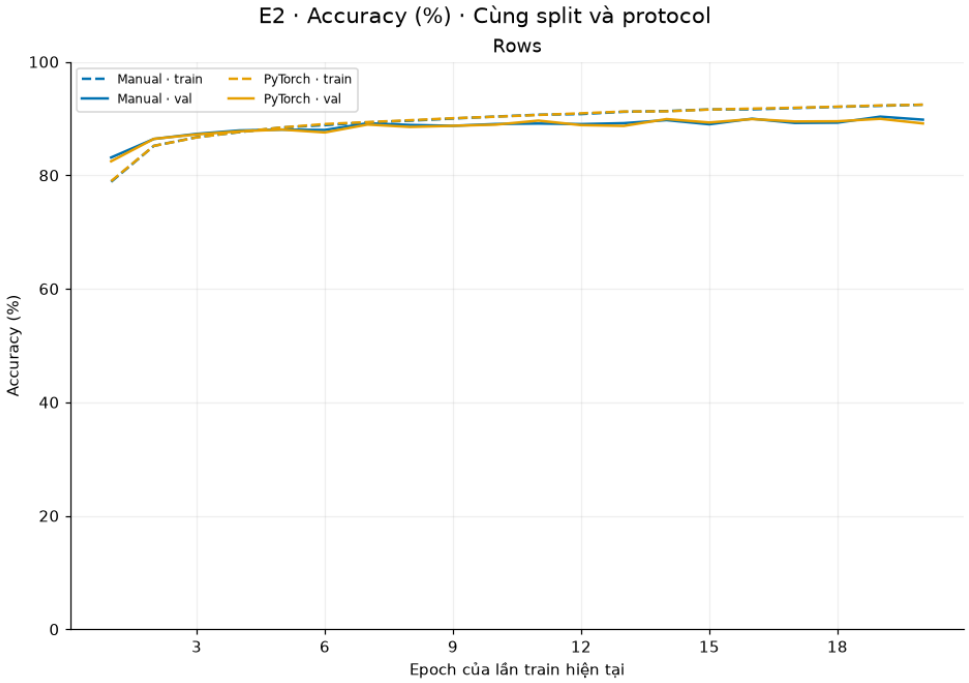

(b) Accuracy (%).

Hình A.1: E2 Manual/PyTorch, Rows H=4.

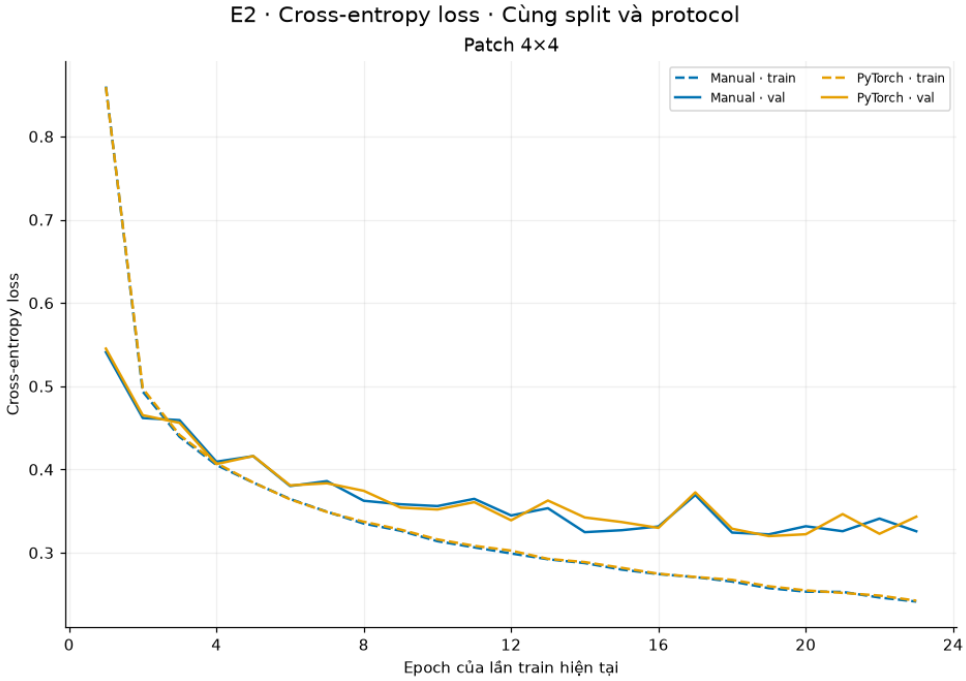

(a) Cross-entropy

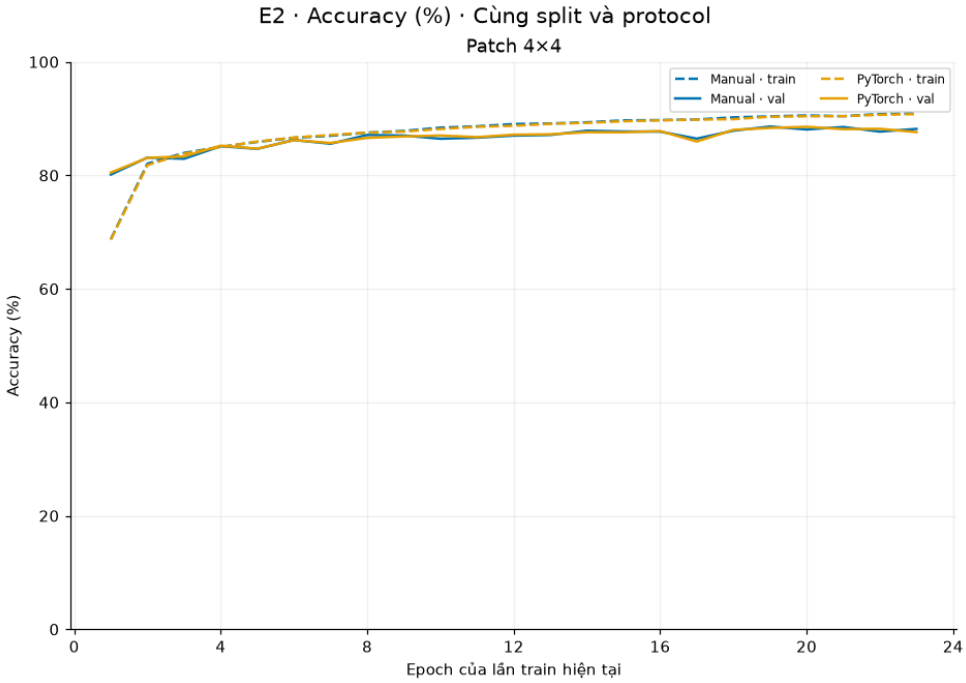

(b) Accuracy (%).

Hình A.2: E2 Manual/PyTorch, Patch H=4.

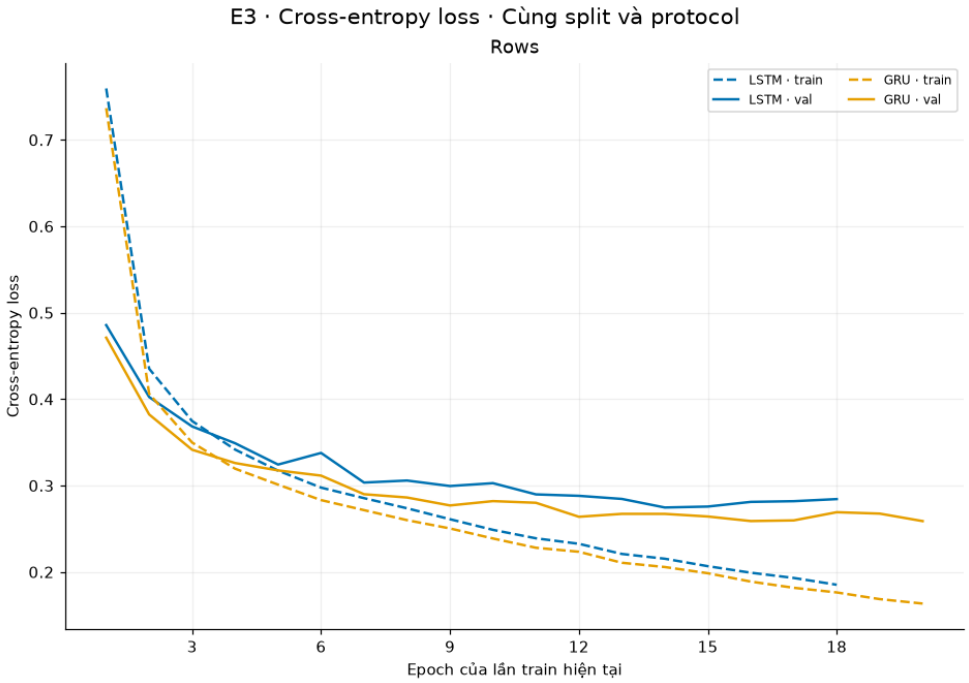

(a) Cross-entropy

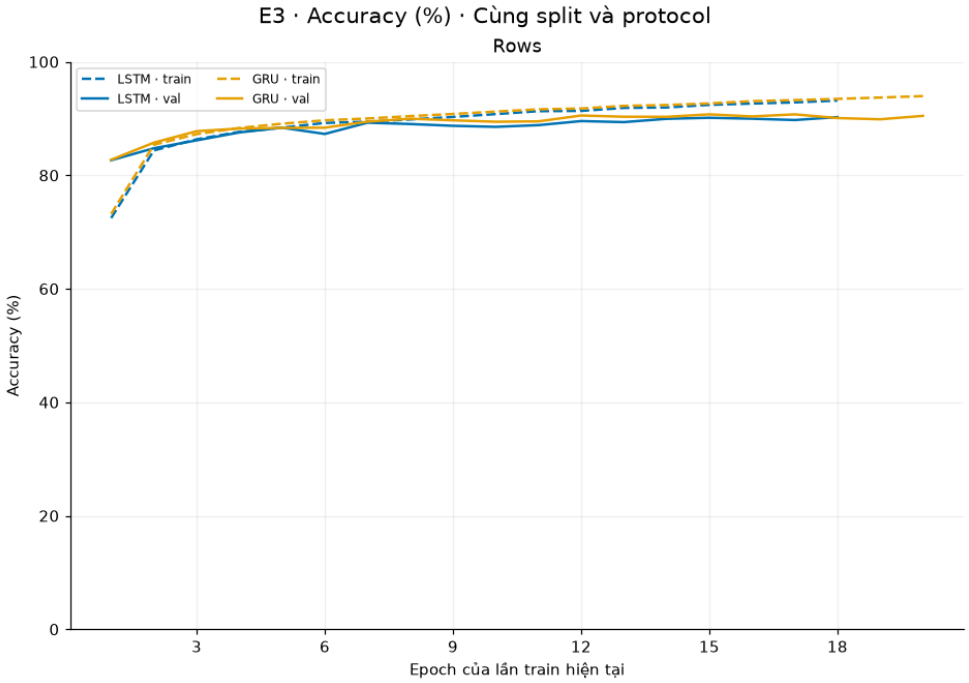

(b) Accuracy (%).

Hình A.3: E3 LSTM/GRU, Rows.

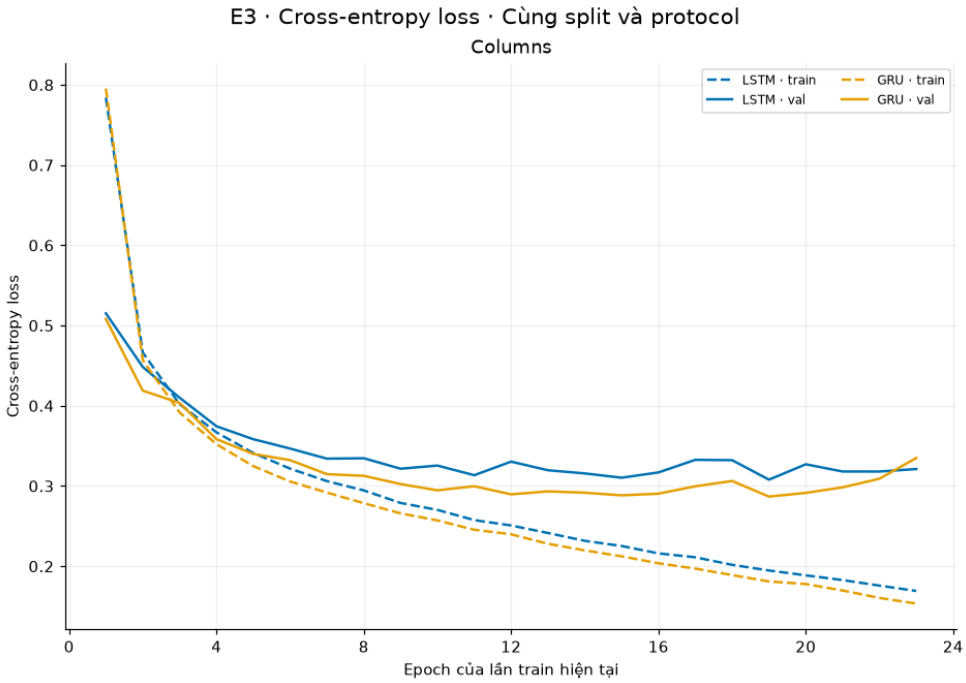

(a) Cross-entropy

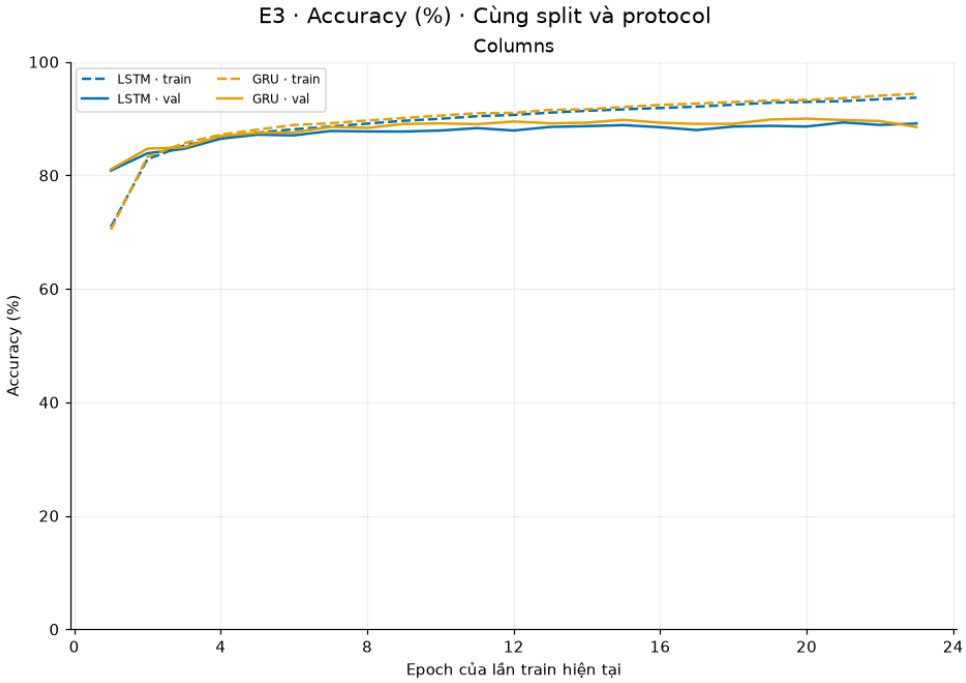

(b) Accuracy (%).

Hình A.4: E3 LSTM/GRU, Columns.

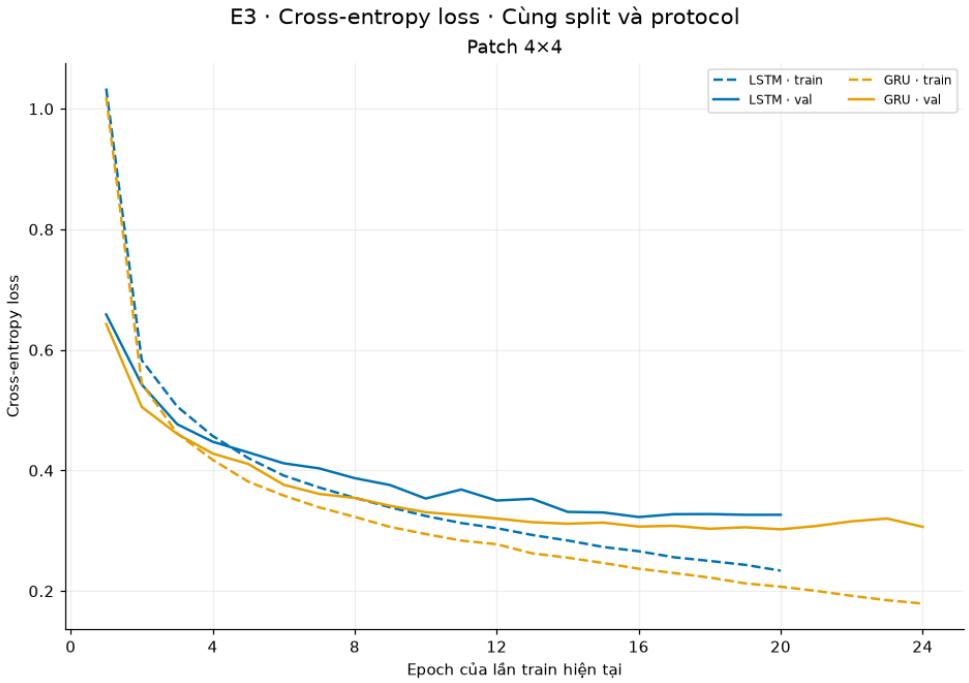

(a) Cross-entropy

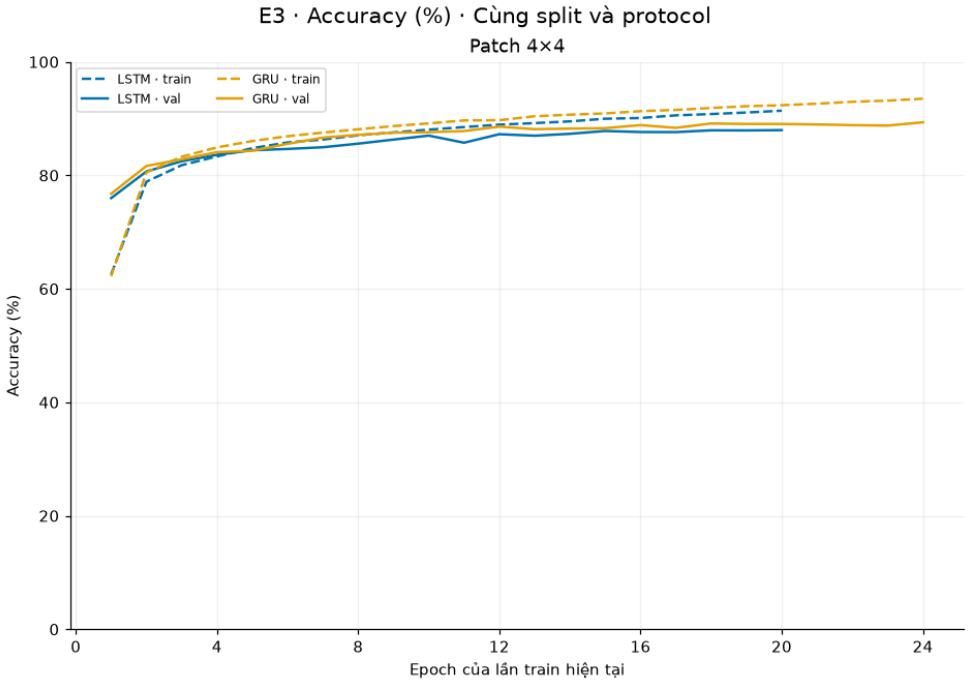

(b) Accuracy (%).

Hình A.5: E3 LSTM/GRU, Patch.

A.4 Ma trận nhầm lẫn E1–E3

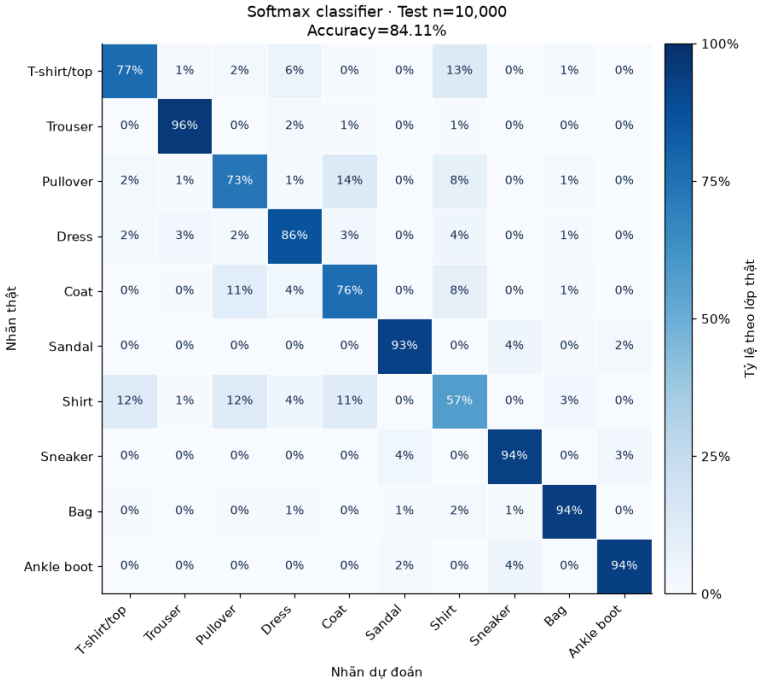

(a) Softmax

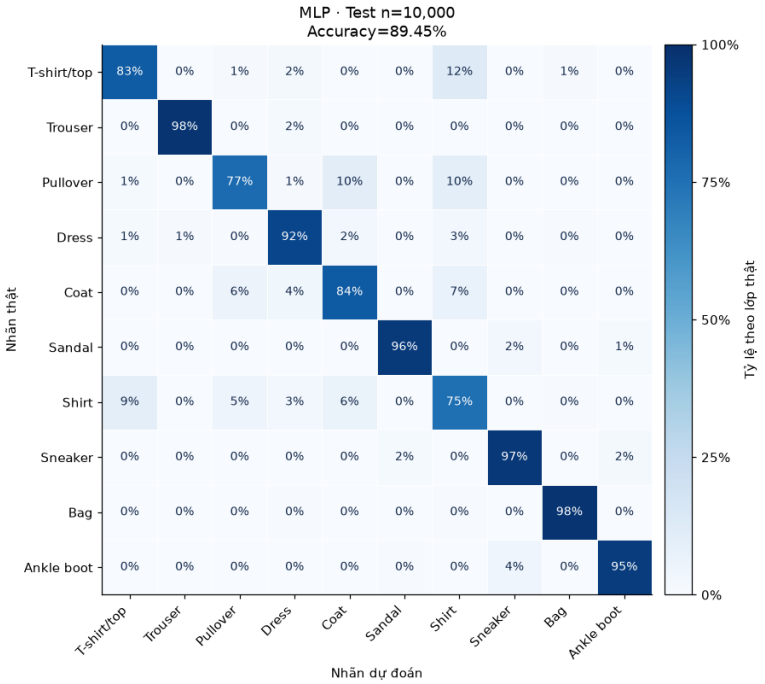

(b) MLP

Hình A.6: E1: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

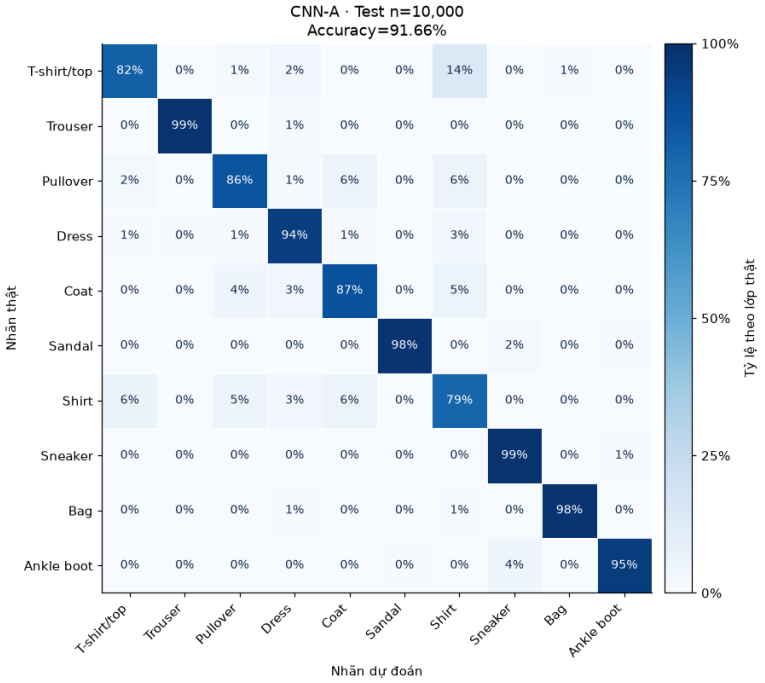

(a) CNN-A

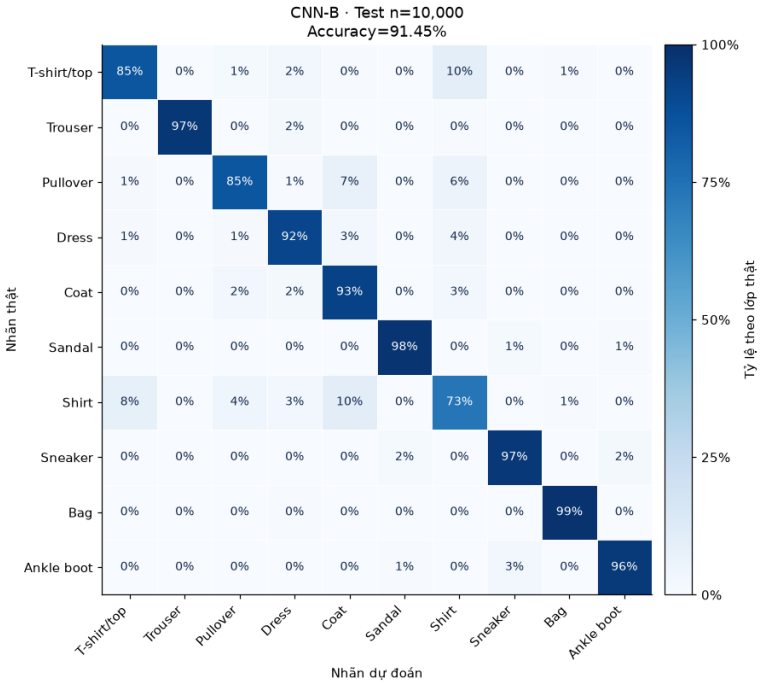

(b) CNN-B

Hình A.7: E1: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

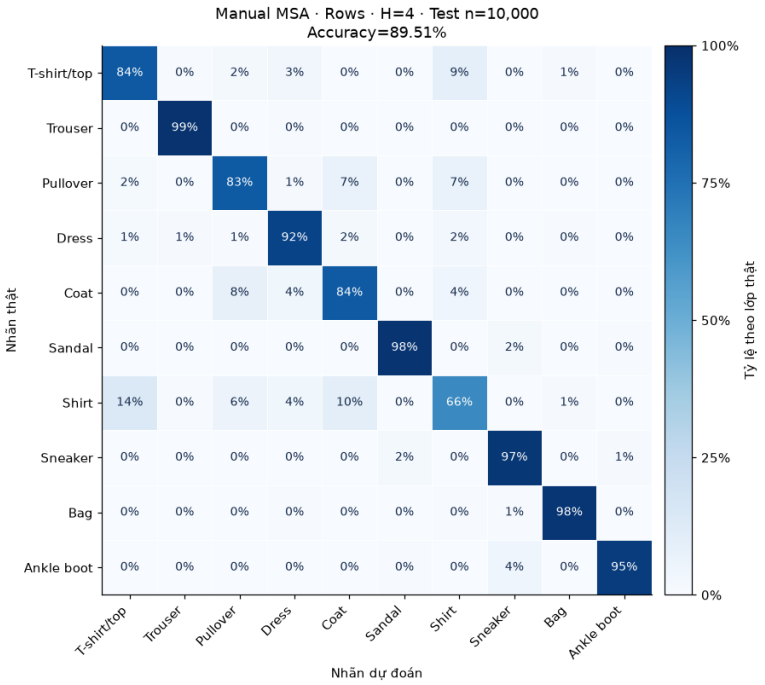

(a) Manual Rows H=4

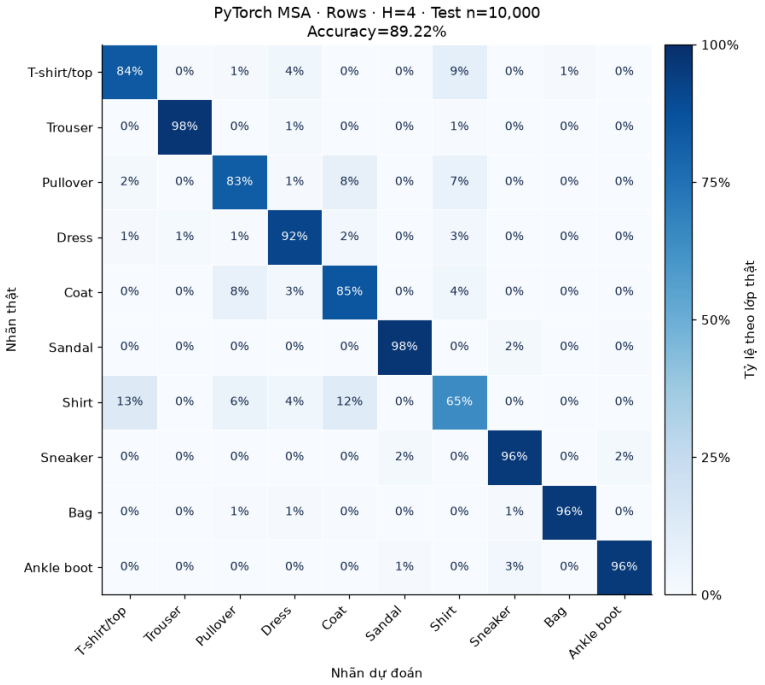

(b) PyTorch Rows H=4

Hình A.8: E2: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

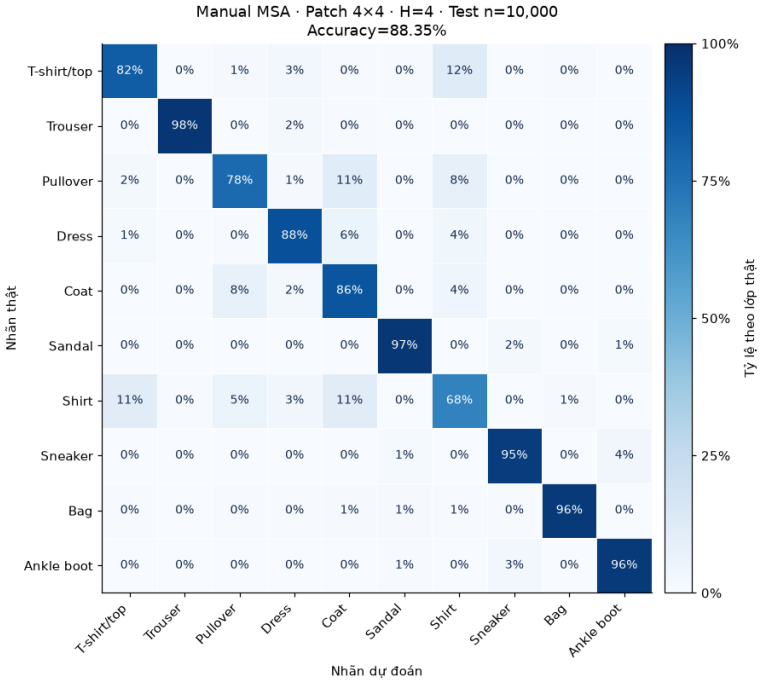

(a) Manual Patch H=4

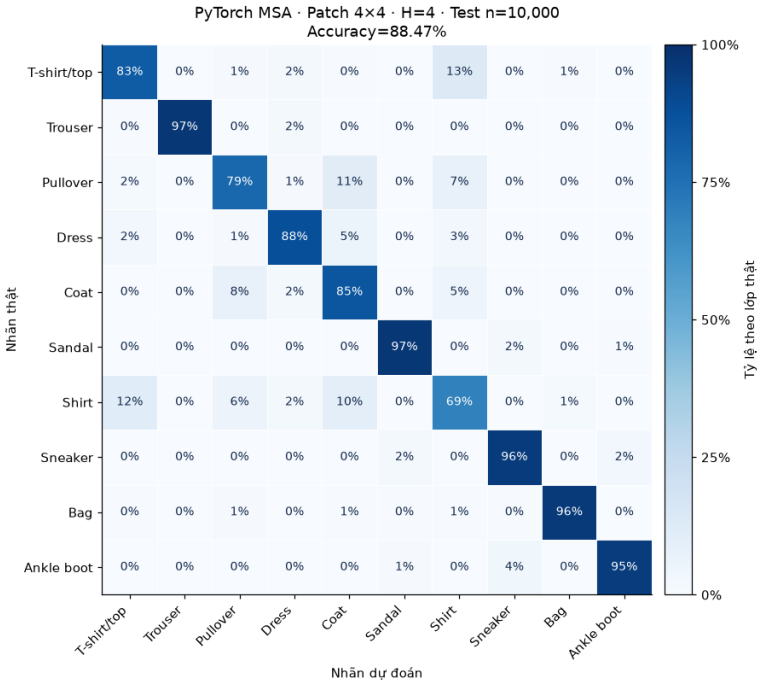

(b) PyTorch Patch H=4

Hình A.9: E2: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

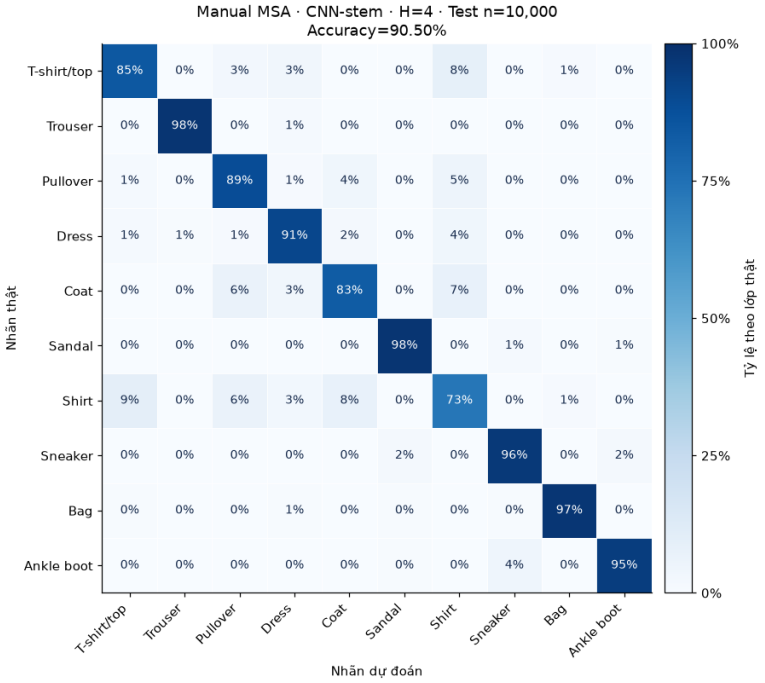

(a) Manual CNN-stem H=4

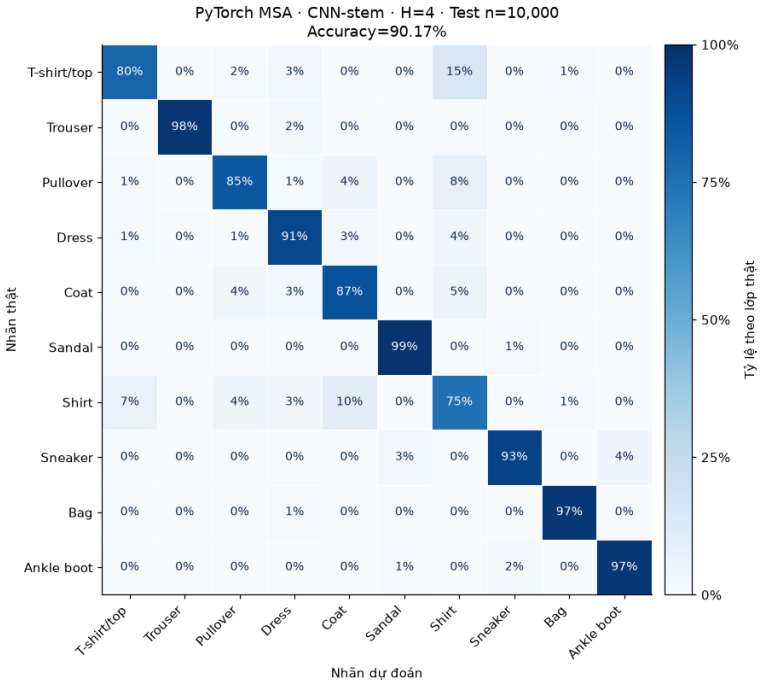

(b) PyTorch CNN-stem H=4

Hình A.10: E2: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

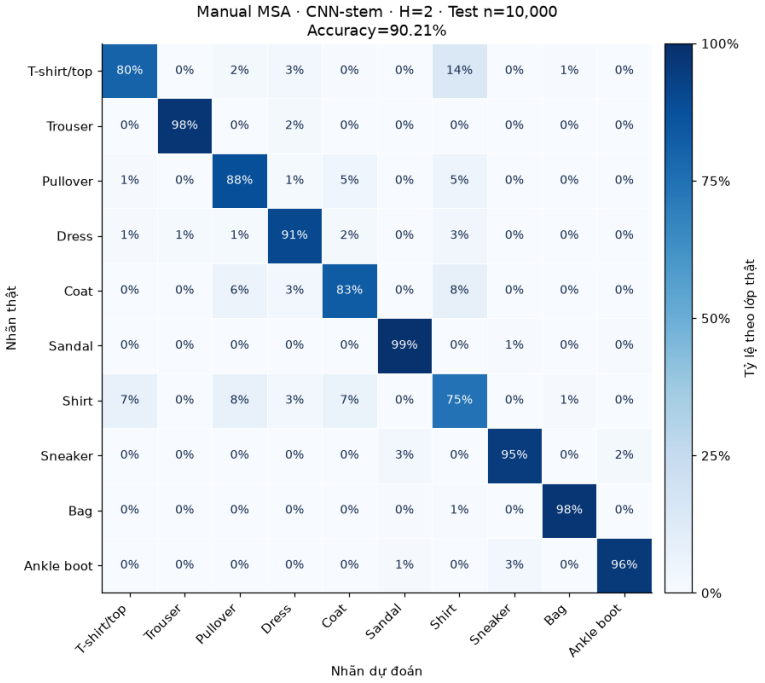

(a) Manual CNN-stem H=2

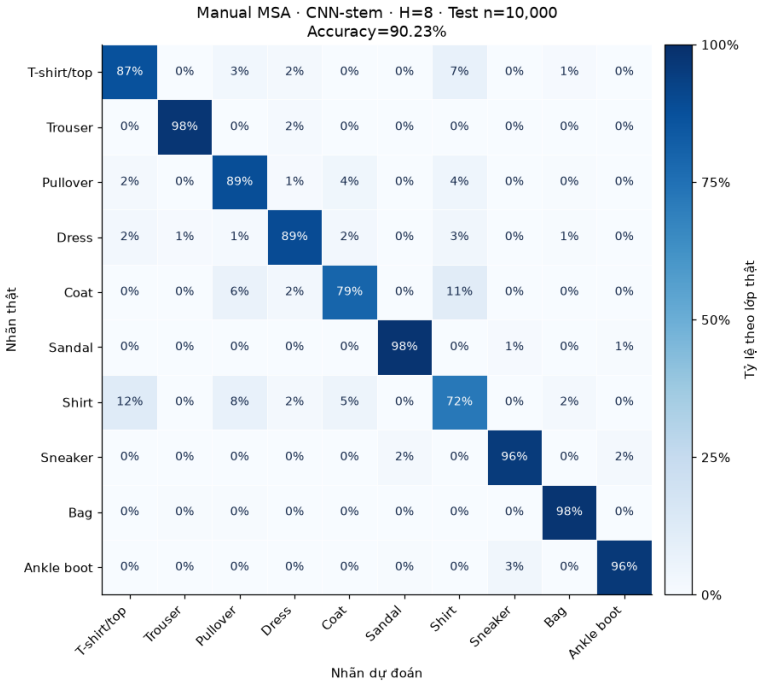

(b) Manual CNN-stem H=8

Hình A.11: E2: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

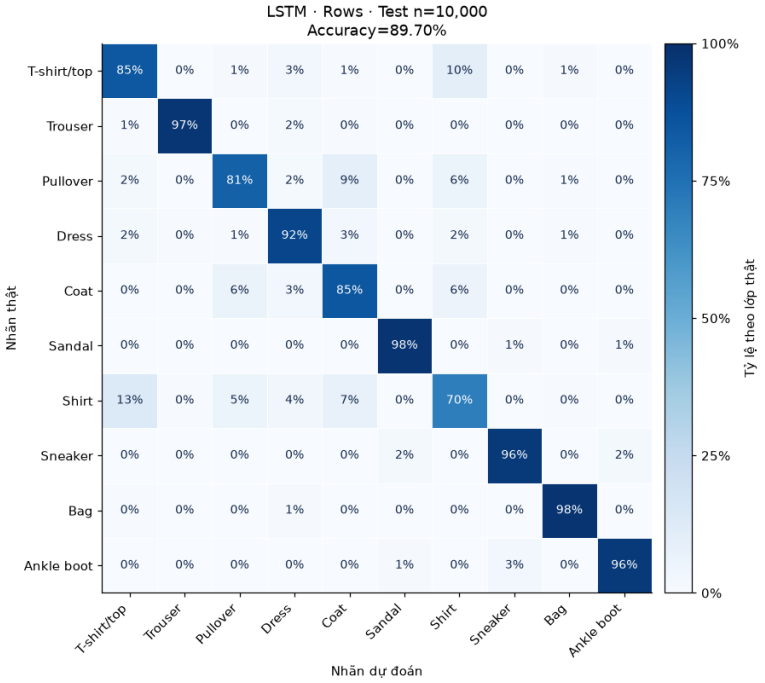

(a) LSTM Rows

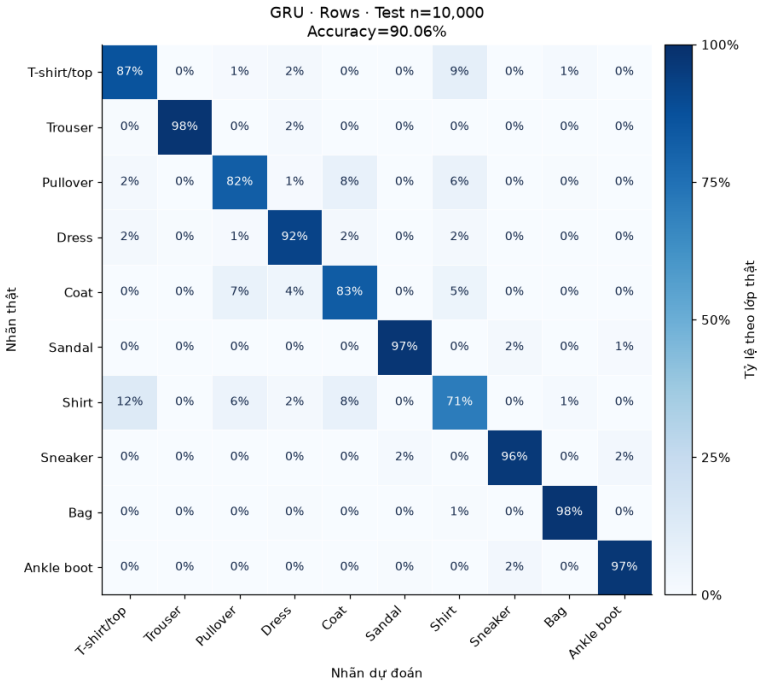

(b) GRU Rows

Hình A.12: E3: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

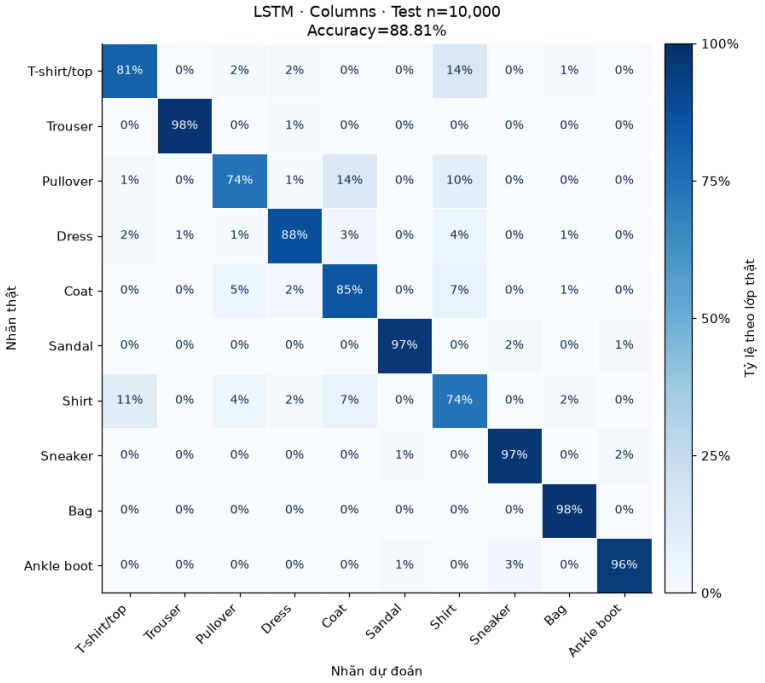

(a) LSTM Columns

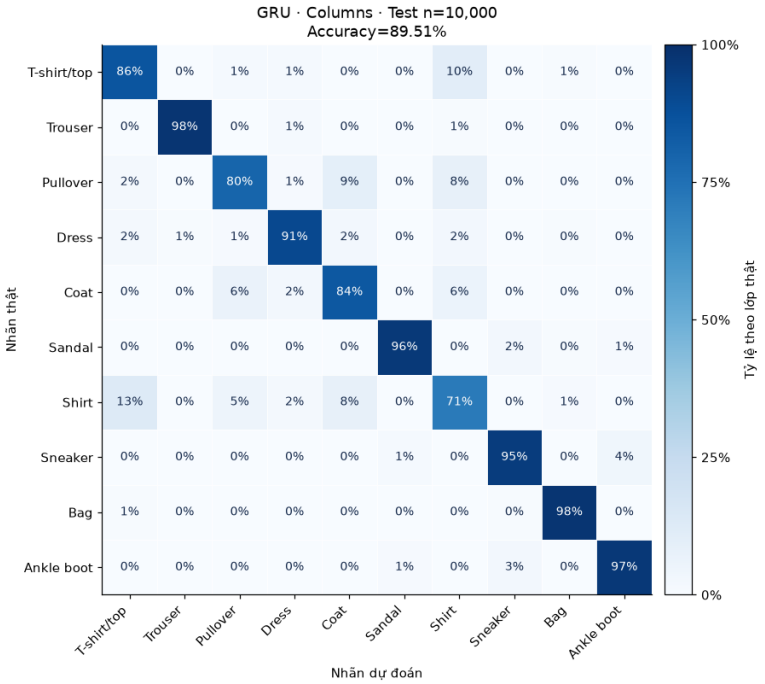

(b) GRU Columns

Hình A.13: E3: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

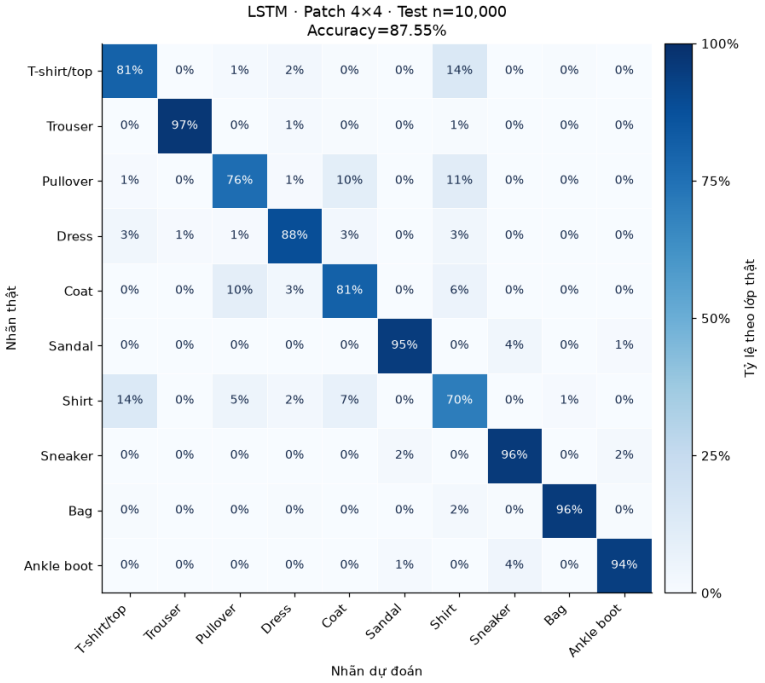

(a) LSTM Patch

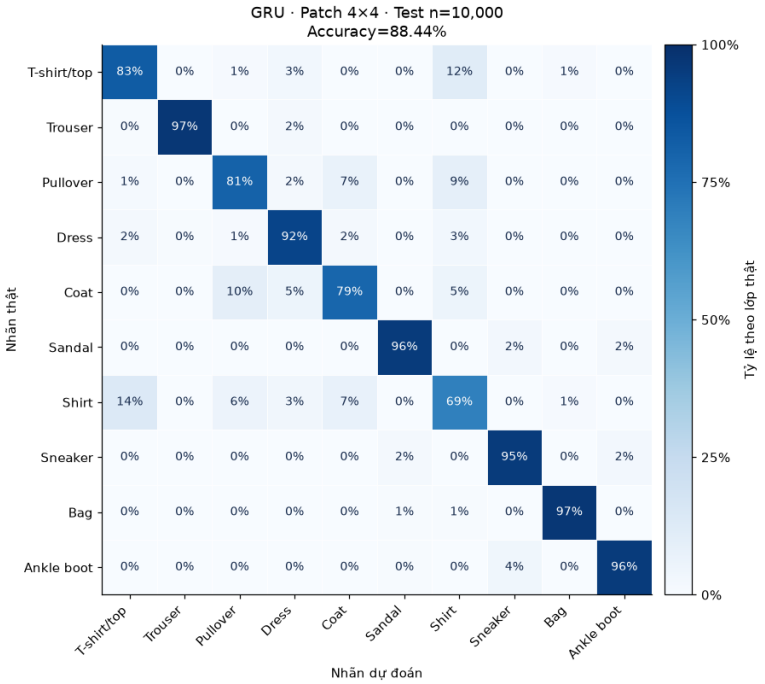

(b) GRU Patch

Hình A.14: E3: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

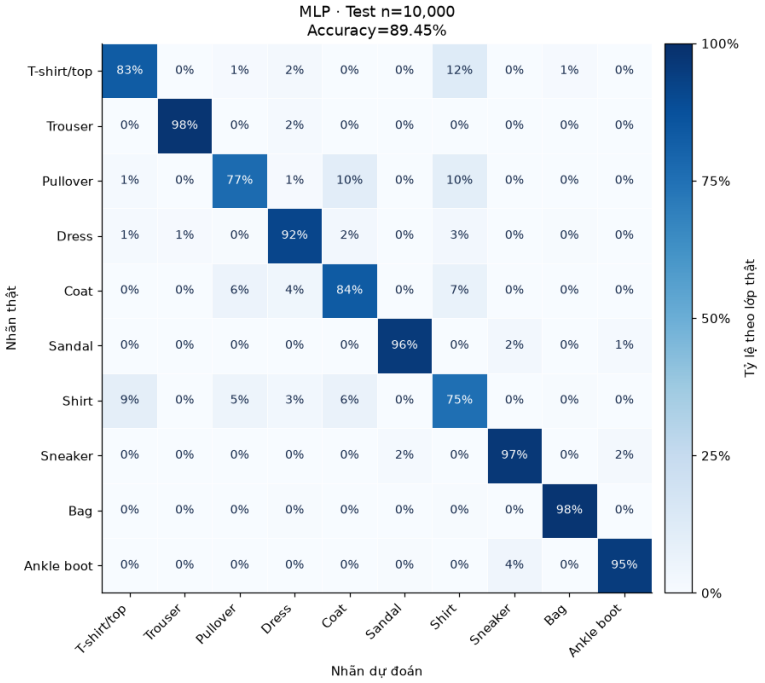

(a) MLP

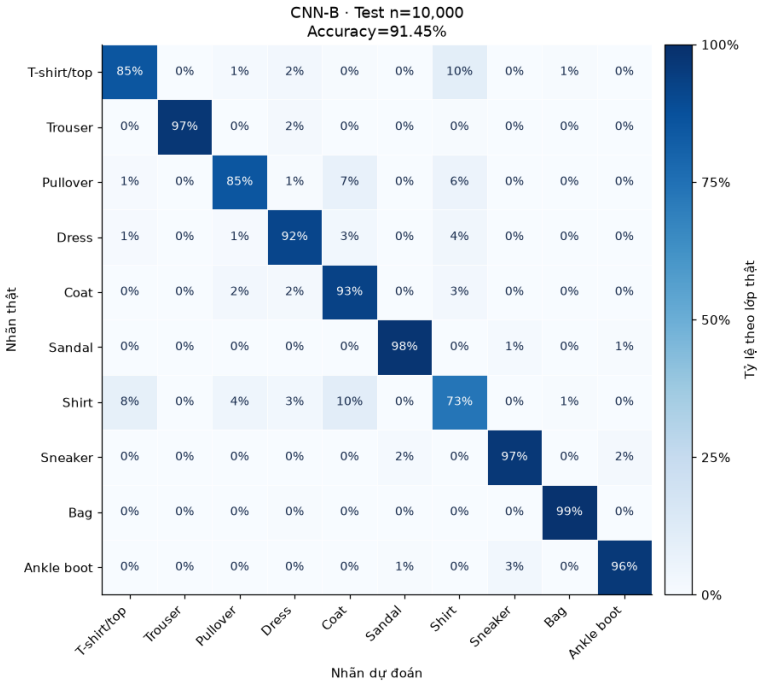

(b) CNN-B

Hình A.15: E3: ma trận toàn bộ 10,000 ảnh test; hàng GT/cột prediction; phần trăm theo hàng, làm tròn số nguyên (tổng có thể khác 100%); cùng thang 0–100%.

A.5 Dữ liệu và chỉ số theo lớp A2

Bảng A.9: Số bbox thường từng lớp VOC2012; difficult không nằm trong các cột này.

Lớp	Train	Validation	Test
aeroplane	692	97	76
bicycle	566	65	80
bird	933	98	88
boat	676	75	99
bottle	1,011	139	109
bus	487	44	62
car	1,624	189	204
cat	970	112	135
chair	1,929	250	175
cow	473	48	67
diningtable	487	74	48
dog	1,213	143	159
horse	554	88	68
motorbike	585	53	75
person	6,802	898	866
pottedplant	804	97	72
sheep	611	119	83
sofa	447	70	49
train	492	59	77
tvmonitor	619	70	95

Bảng A.10: P/R/F1 tại score 0.30; R=RetinaNet, F=Faster R-CNN, Rec là recall.

Lớp	R P	R Rec	R F1	F P	F Rec	F F1
aeroplane	0.5221	0.7763	0.6243	0.5514	0.7763	0.6448
bicycle	0.5963	0.8125	0.6878	0.4124	0.9125	0.5681
bird	0.5310	0.8750	0.6609	0.5000	0.8523	0.6303
boat	0.4460	0.6263	0.5210	0.3842	0.6869	0.4928
bottle	0.4086	0.6972	0.5153	0.3842	0.6697	0.4883
bus	0.4825	0.8871	0.6250	0.3041	0.9516	0.4609
car	0.4985	0.8382	0.6252	0.3203	0.9216	0.4753
cat	0.6513	0.9407	0.7697	0.4980	0.9407	0.6513
chair	0.3644	0.5143	0.4265	0.2569	0.6400	0.3666
cow	0.3841	0.7910	0.5171	0.4786	0.8358	0.6087
diningtable	0.2703	0.4167	0.3279	0.4189	0.6458	0.5082
dog	0.5316	0.8994	0.6682	0.5331	0.9119	0.6729
horse	0.4444	0.8824	0.5911	0.5510	0.7941	0.6506
motorbike	0.5000	0.8267	0.6231	0.3750	0.8400	0.5185
person	0.5517	0.8383	0.6654	0.4074	0.9018	0.5613
pottedplant	0.3333	0.4167	0.3704	0.1774	0.4583	0.2558
sheep	0.4362	0.7831	0.5603	0.5246	0.7711	0.6244
sofa	0.4730	0.7143	0.5691	0.1900	0.8571	0.3111
train	0.5345	0.8052	0.6425	0.5865	0.7922	0.6740
tvmonitor	0.6476	0.7158	0.6800	0.3333	0.8842	0.4841

Bảng A.11: AP50/AP75 COCO-style và AP11 VOC07 từng lớp; metric ở thang 0–1.

Lớp	R AP50	F AP50	R AP75	F AP75	R AP11	F AP11
aeroplane	0.7733	0.7727	0.4642	0.5304	0.7494	0.7504
bicycle	0.8154	0.8482	0.4475	0.5418	0.7823	0.8094
bird	0.8317	0.7715	0.4608	0.4788	0.7927	0.7428
boat	0.5551	0.6044	0.1775	0.1392	0.5445	0.6001
bottle	0.6310	0.6243	0.2458	0.2861	0.6123	0.6194
bus	0.8670	0.8964	0.6035	0.6571	0.8309	0.8615
car	0.8150	0.8362	0.5320	0.5418	0.7912	0.8067
cat	0.9134	0.9061	0.5668	0.5394	0.8686	0.8655
chair	0.4557	0.4906	0.1515	0.2008	0.4602	0.4883
cow	0.6811	0.7724	0.2501	0.3833	0.6740	0.7576
diningtable	0.3203	0.5424	0.1113	0.2228	0.3417	0.5436
dog	0.8499	0.8671	0.5499	0.6080	0.8140	0.8414
horse	0.8262	0.8003	0.4770	0.5385	0.7878	0.7794
motorbike	0.8201	0.8136	0.4664	0.4178	0.8091	0.7942
person	0.8230	0.8412	0.3261	0.4221	0.7961	0.8143
pottedplant	0.3096	0.3035	0.0770	0.0736	0.3225	0.3094
sheep	0.7199	0.7613	0.4787	0.5093	0.6937	0.7513
sofa	0.5902	0.5727	0.2758	0.3385	0.5762	0.5784
train	0.8093	0.8104	0.5118	0.4701	0.7894	0.7680
tvmonitor	0.7463	0.7803	0.3613	0.4796	0.7350	0.7636

A.6 Ma trận chẩn đoán A2

Hàng là ground truth, cột là prediction. Hàng background biểu diễn false positives, cột background biểu diễn false negatives. Ô ghi tỷ lệ theo hàng làm tròn số nguyên; tổng một hàng có thể khác 100%. Matching class-agnostic dùng IoU ≥ 0.5, confidence ≥ 0.30; các chỉ số class-wise được tính riêng.

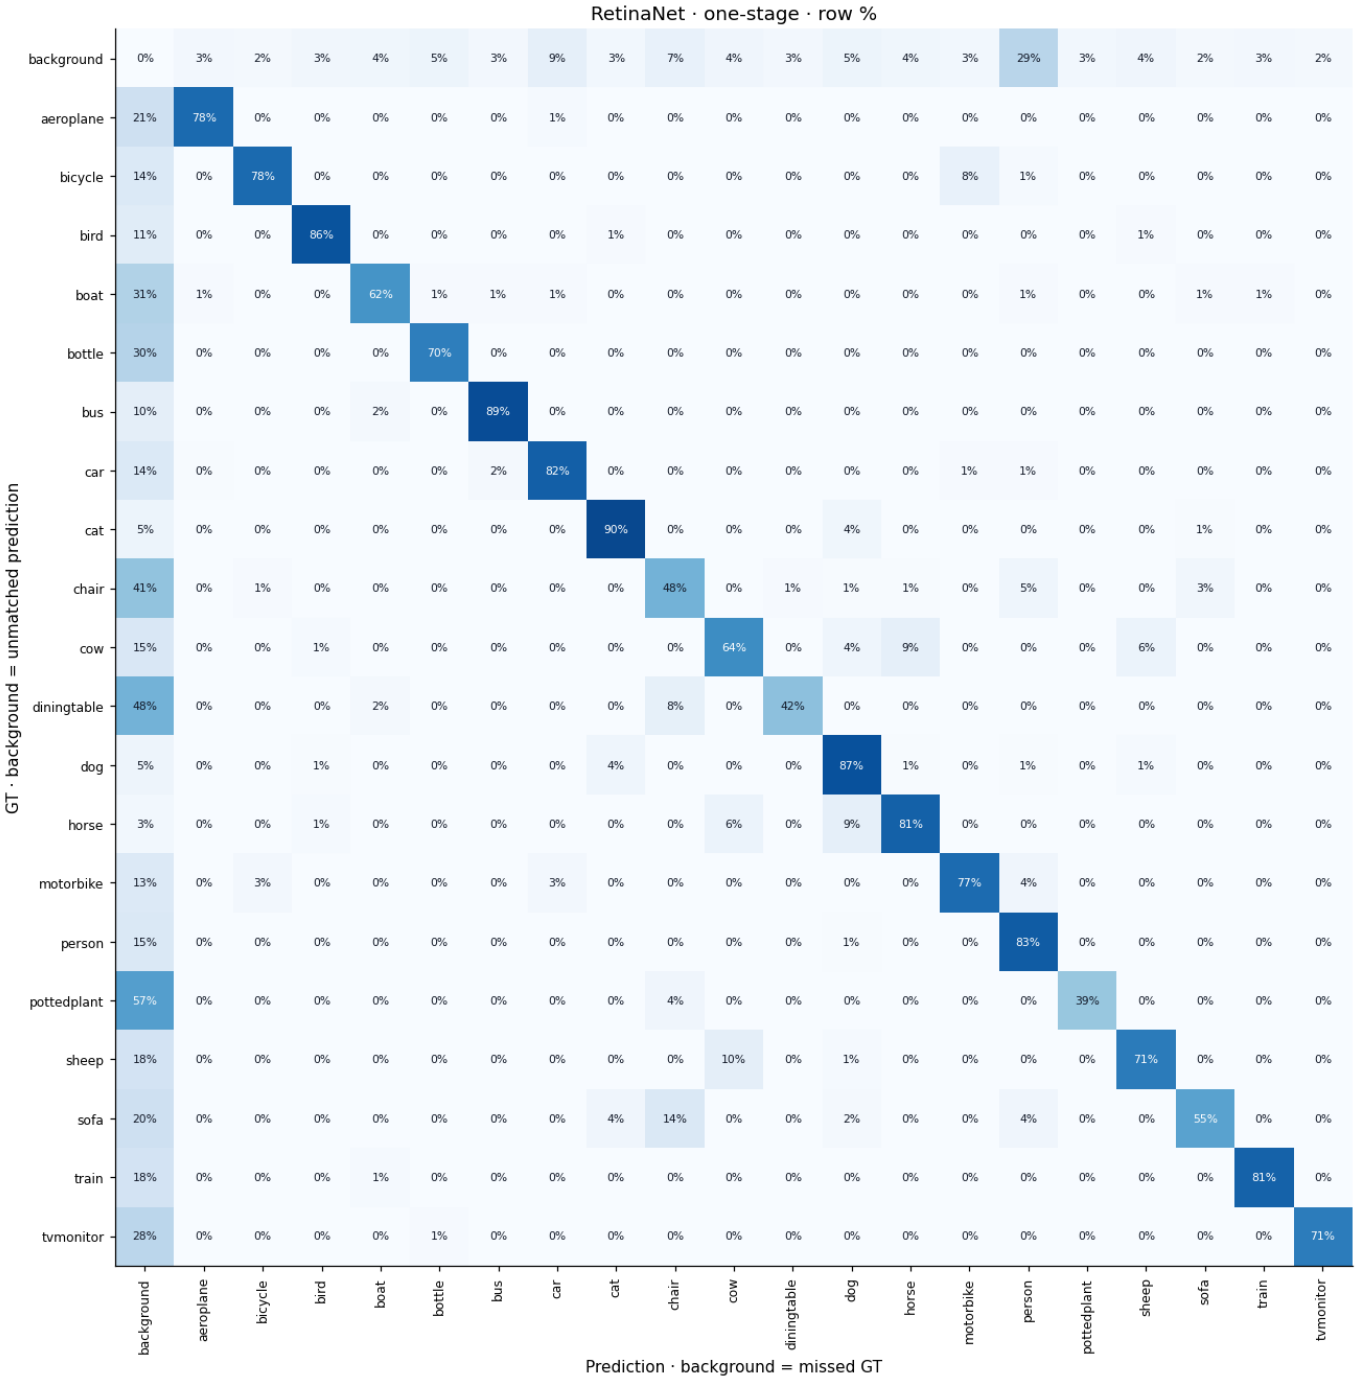

Hình A.16: A2 RetinaNet: ma trận chẩn đoán chuẩn hóa theo hàng.

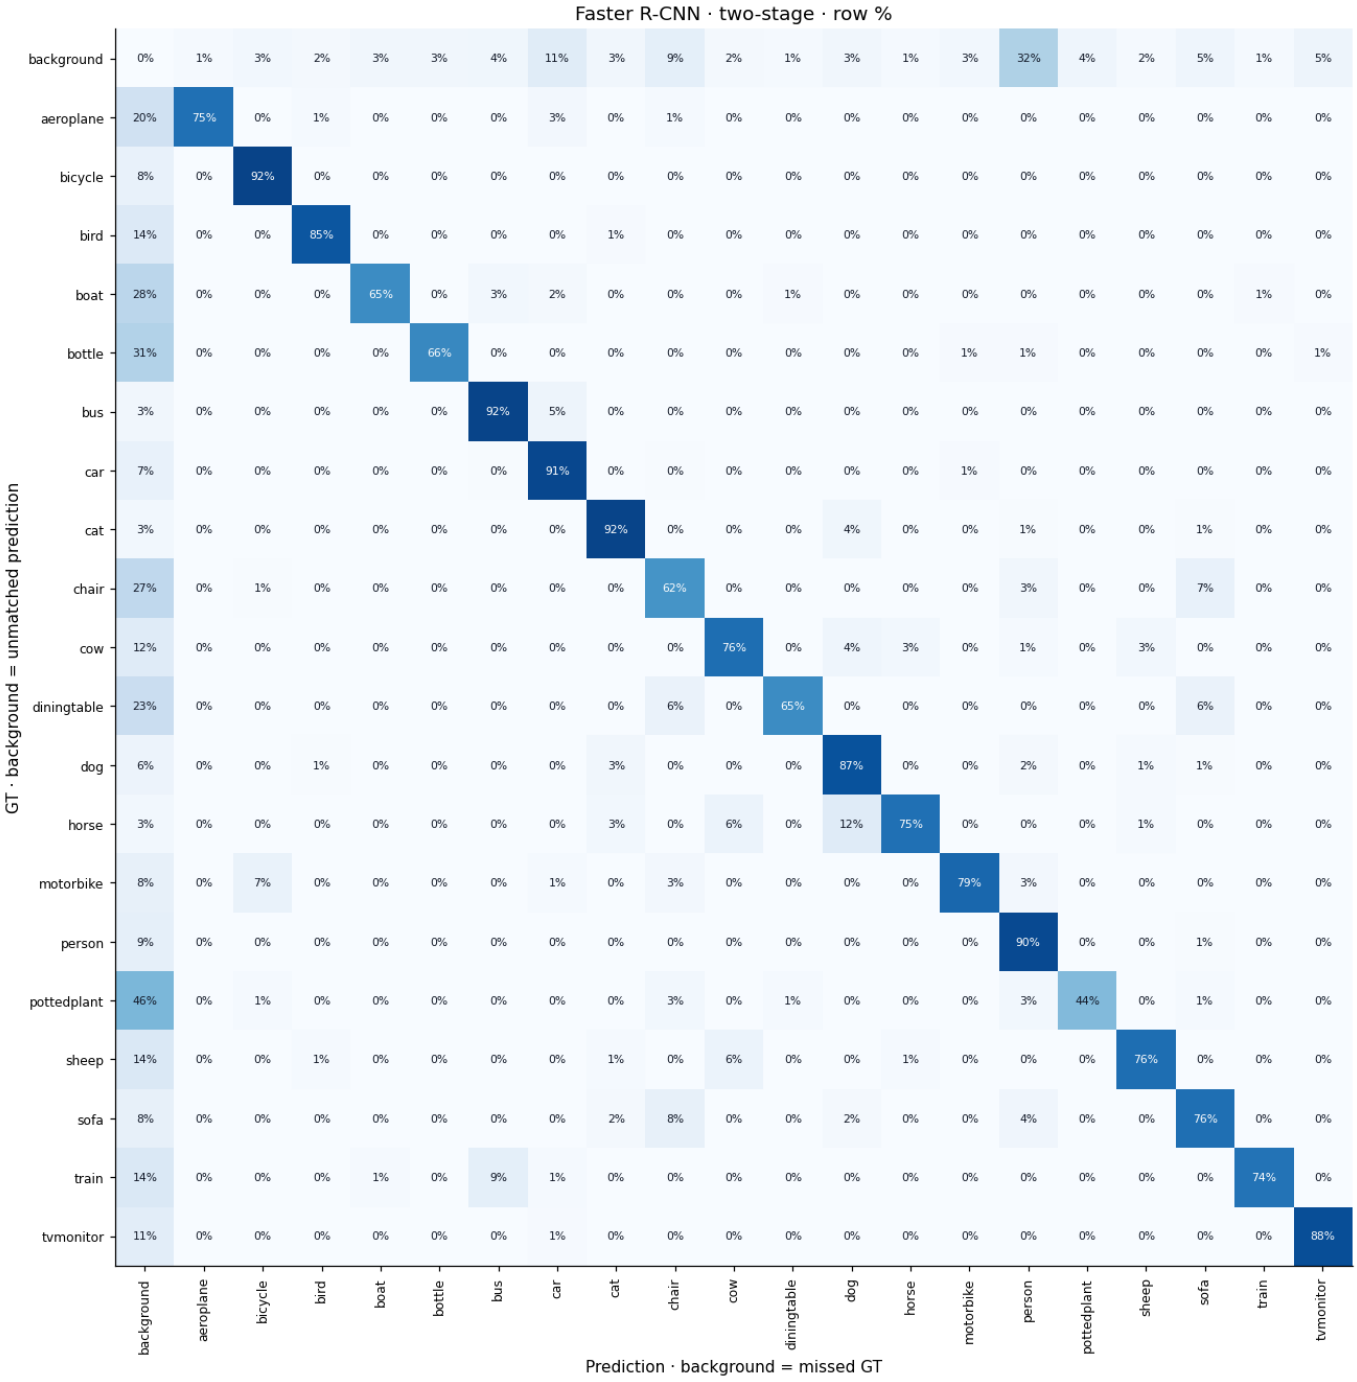

Hình A.17: A2 Faster R-CNN: ma trận chẩn đoán chuẩn hóa theo hàng.

A.7 Precision–recall theo lớp A2

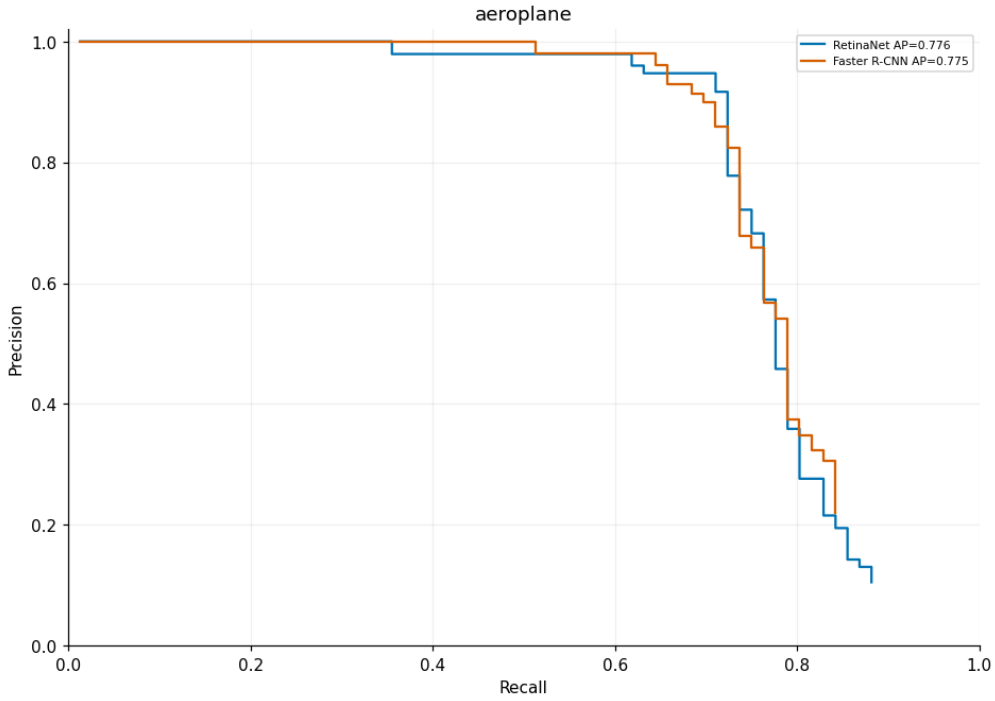

(a) aeroplane

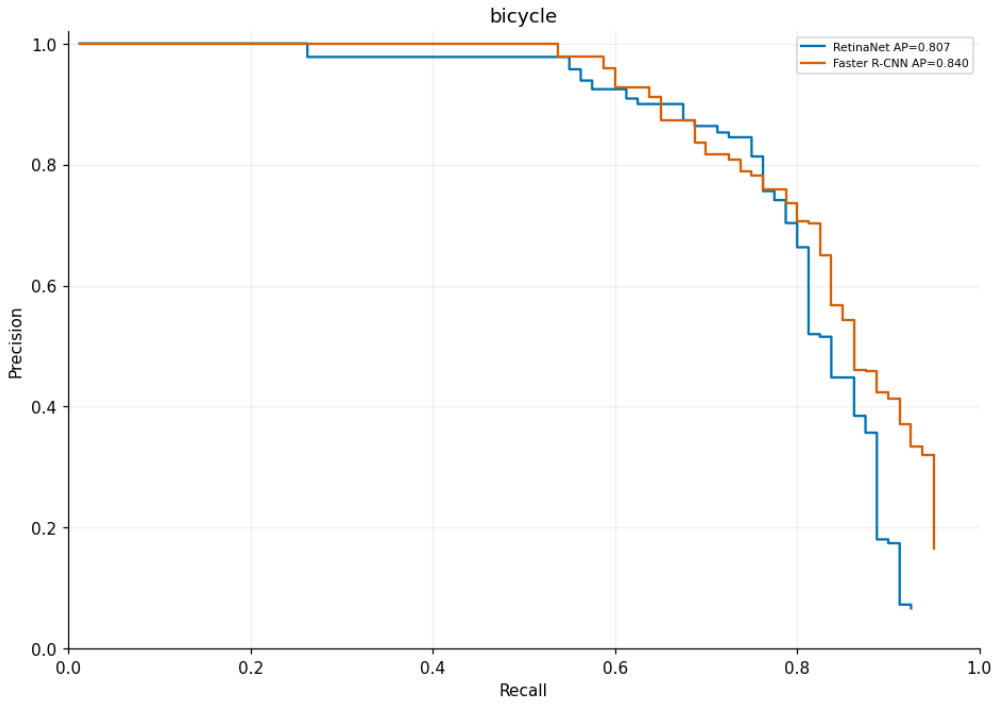

(b) bicycle

Hình A.18: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

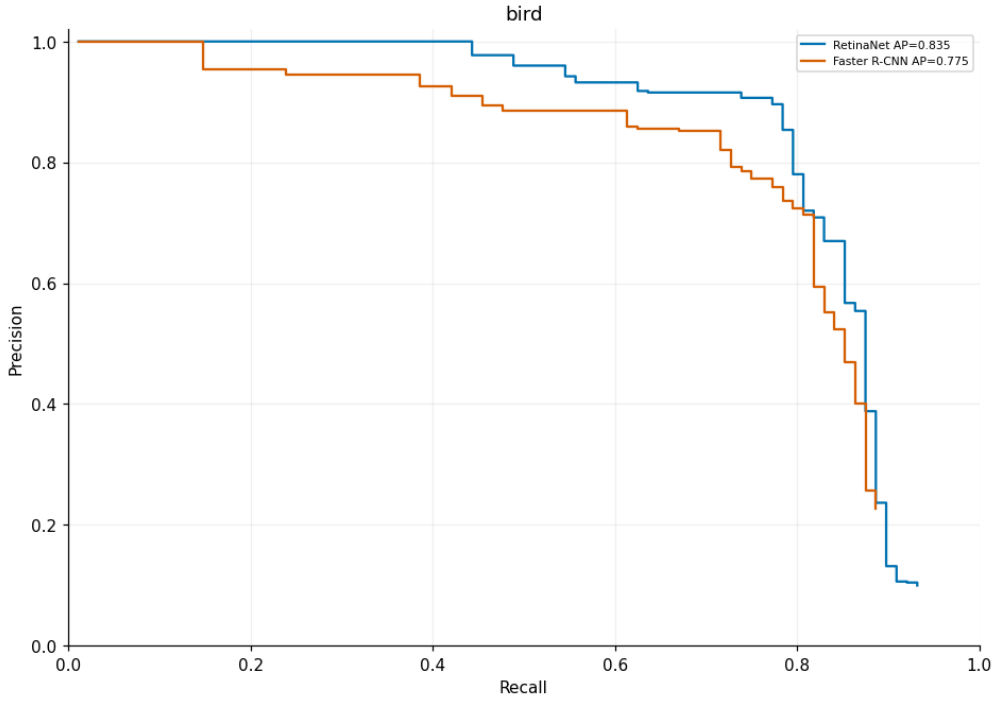

(a) bird

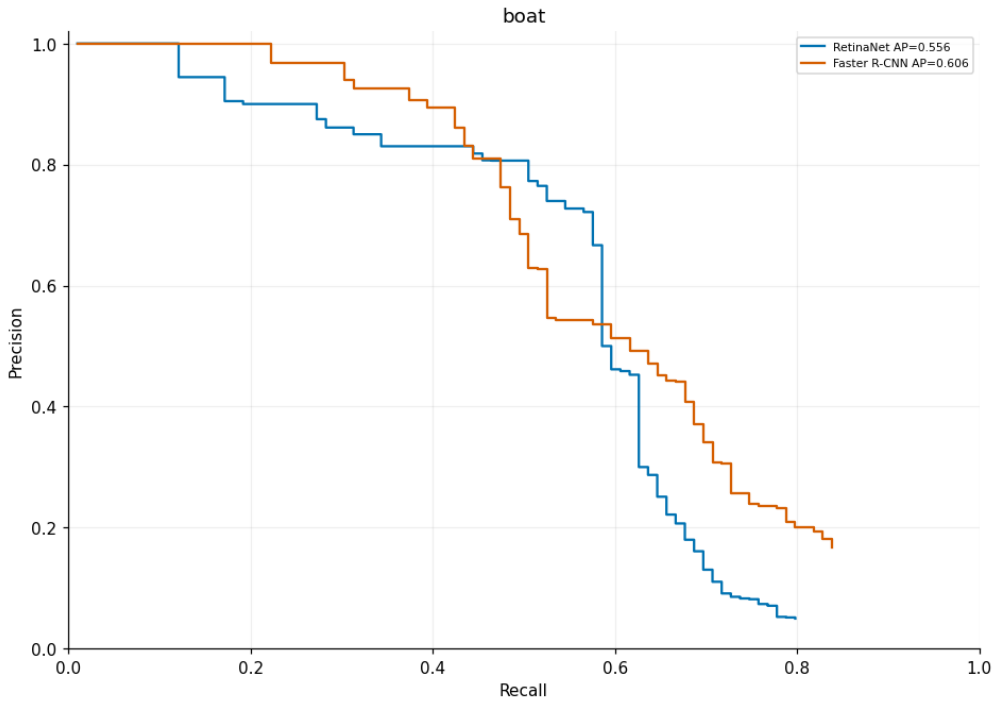

(b) boat

Hình A.19: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

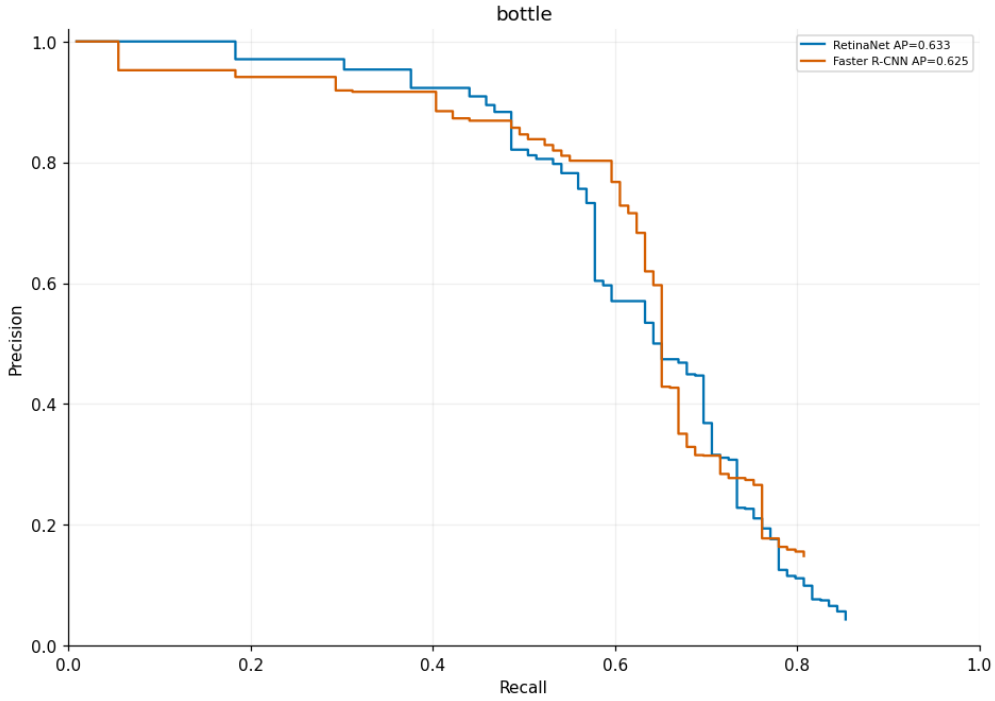

(a) bottle

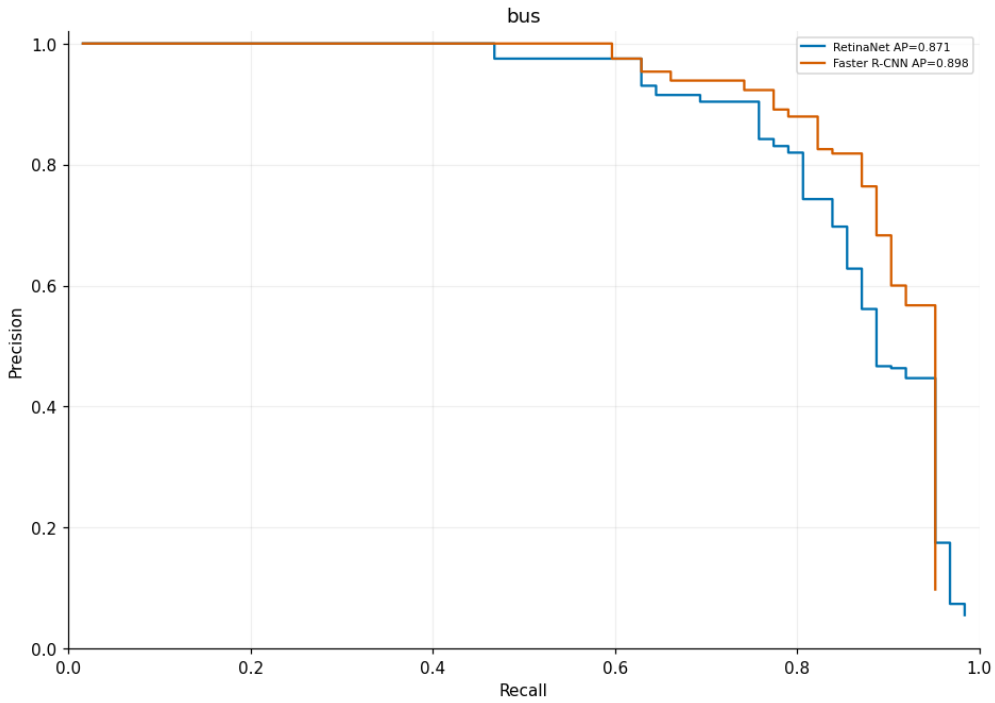

(b) bus

Hình A.20: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

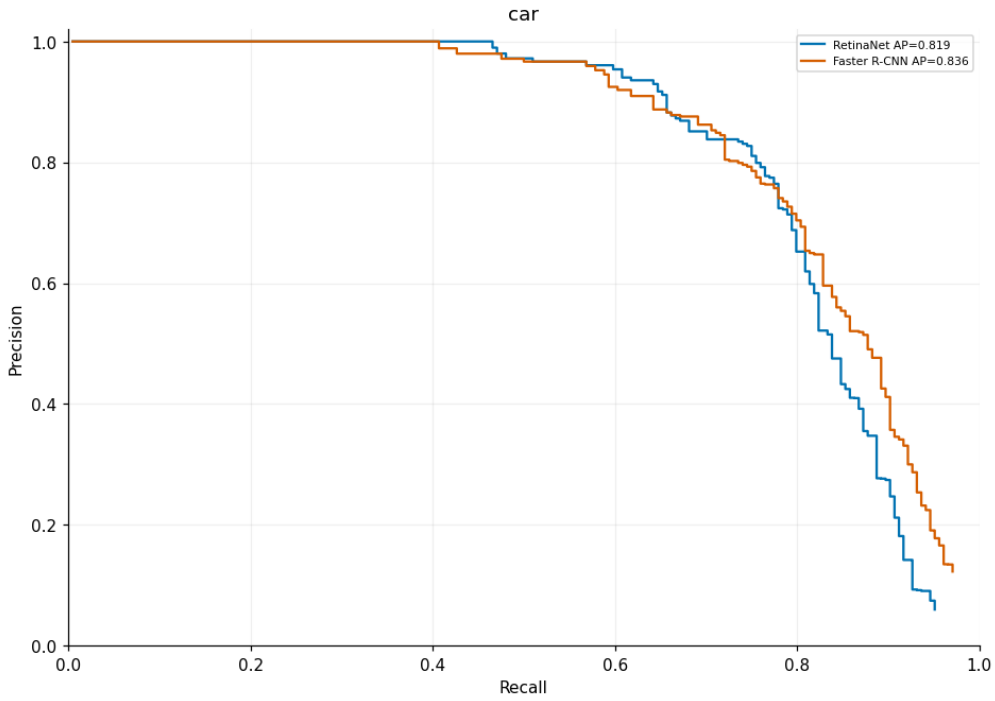

(a) car

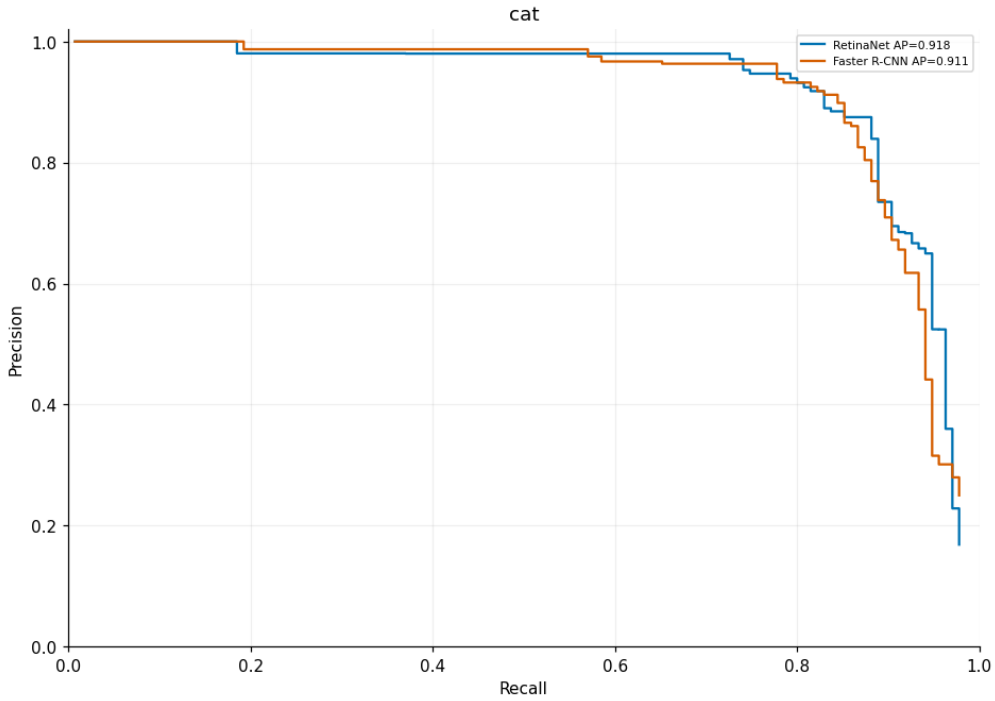

(b) cat

Hình A.21: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

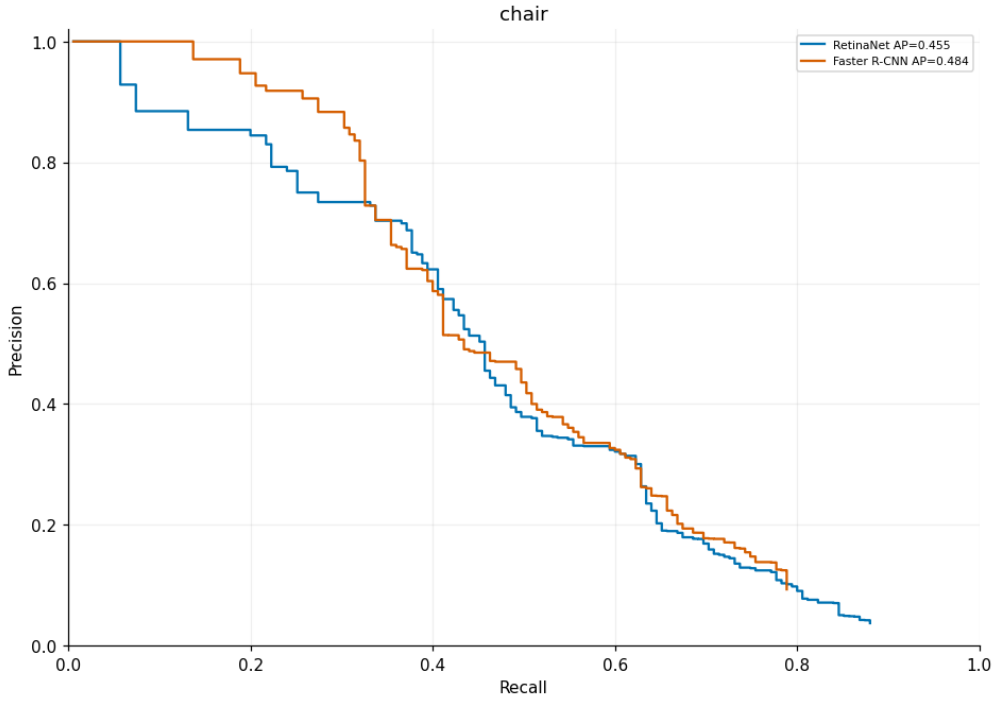

(a) chair

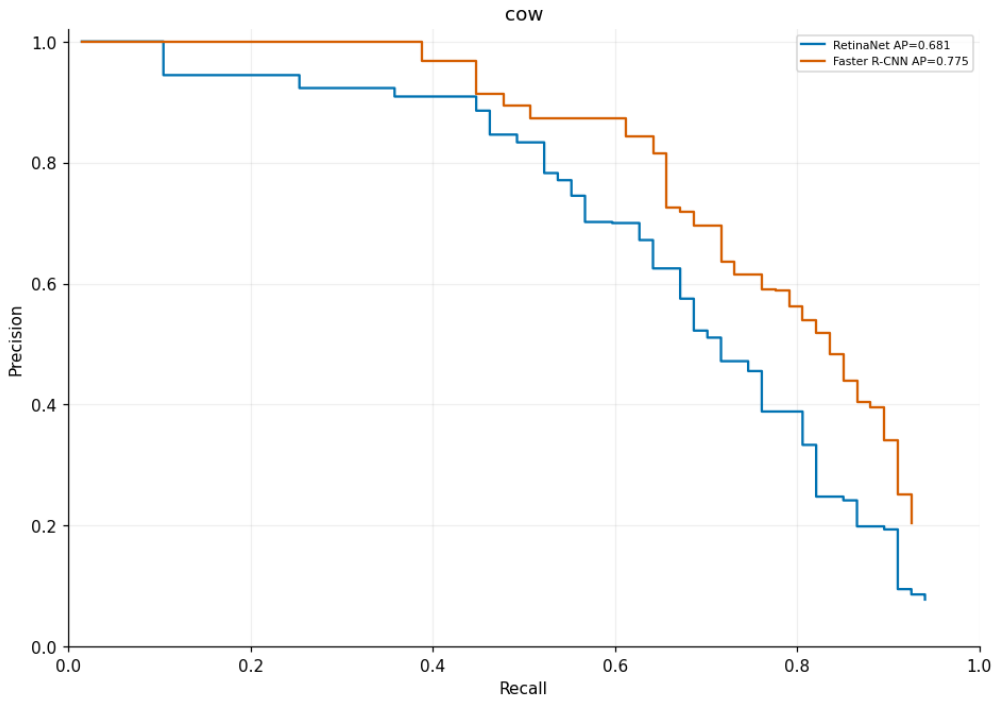

(b) cow

Hình A.22: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

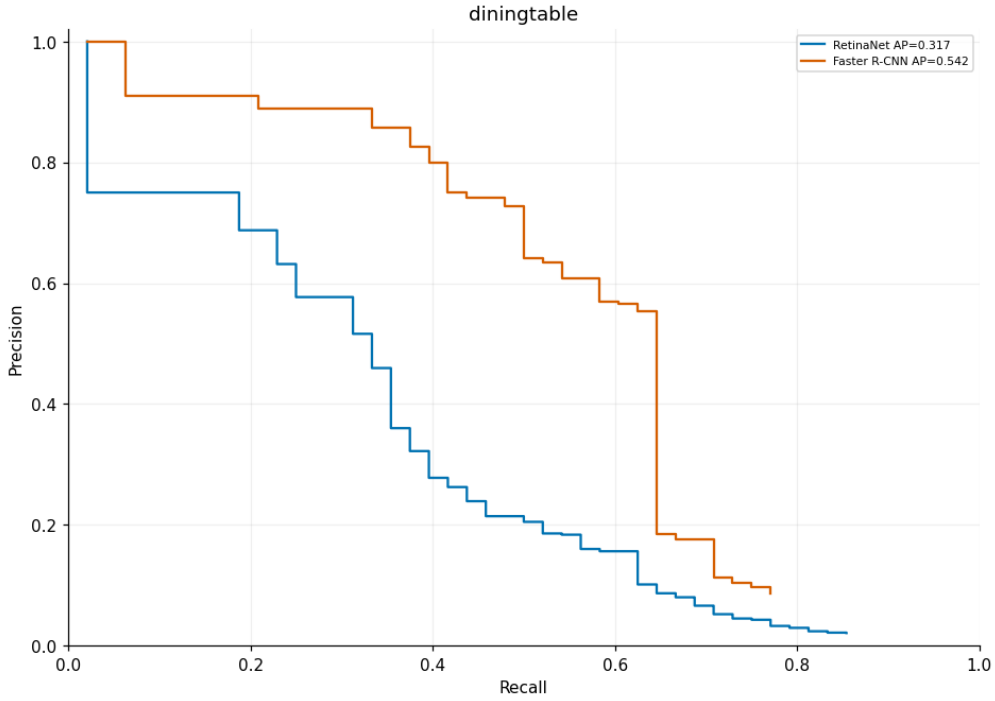

(a) diningtable

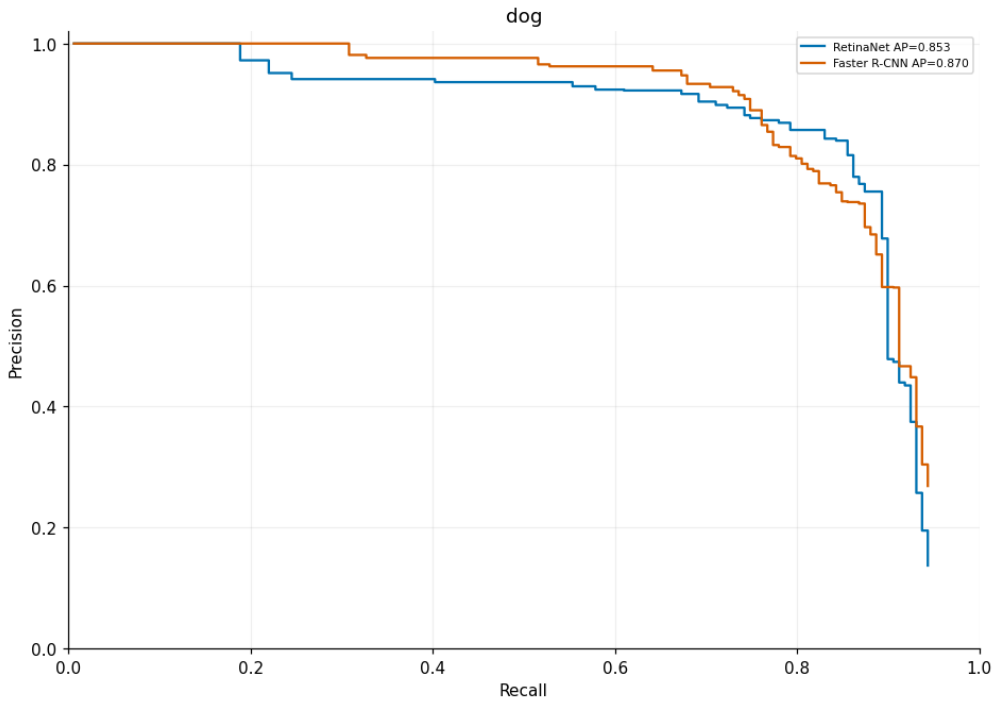

(b) dog

Hình A.23: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

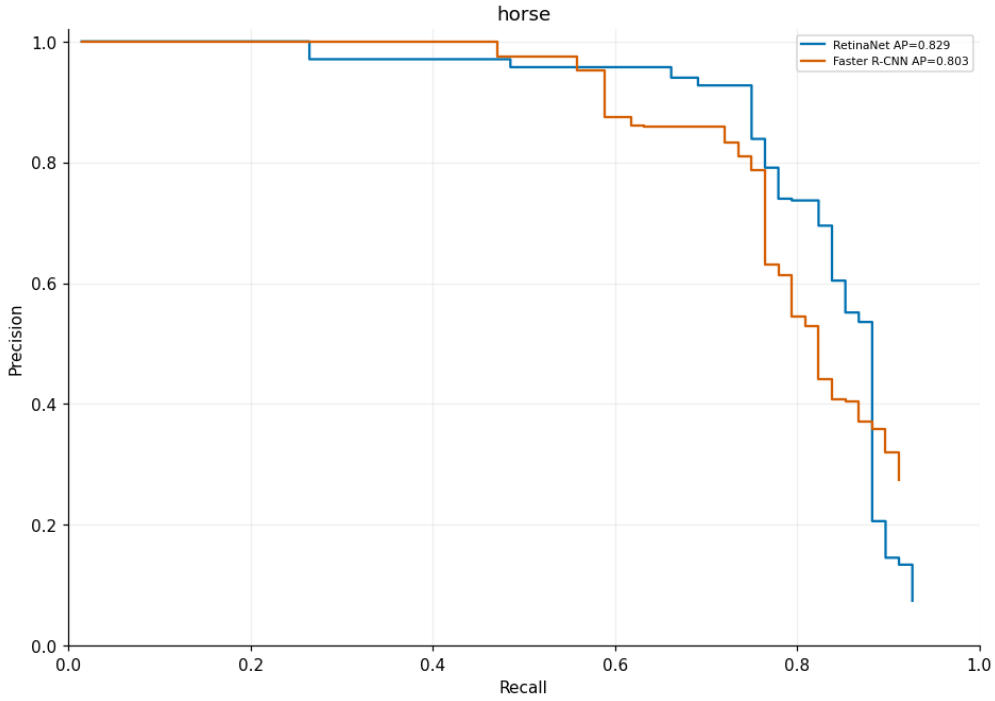

(a) horse

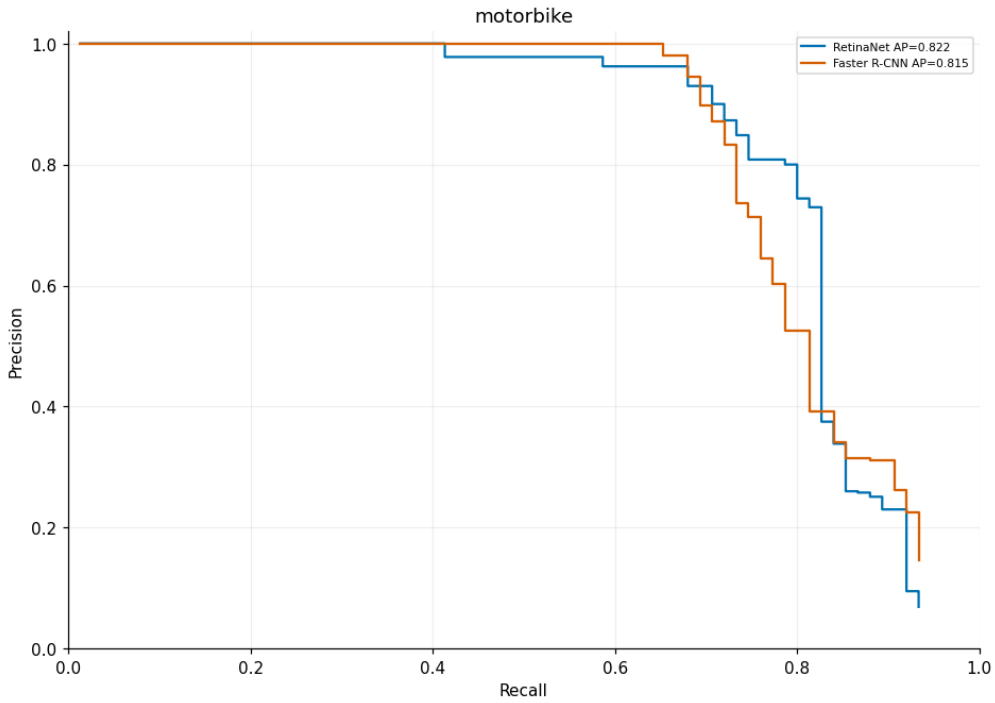

(b) motorbike

Hình A.24: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

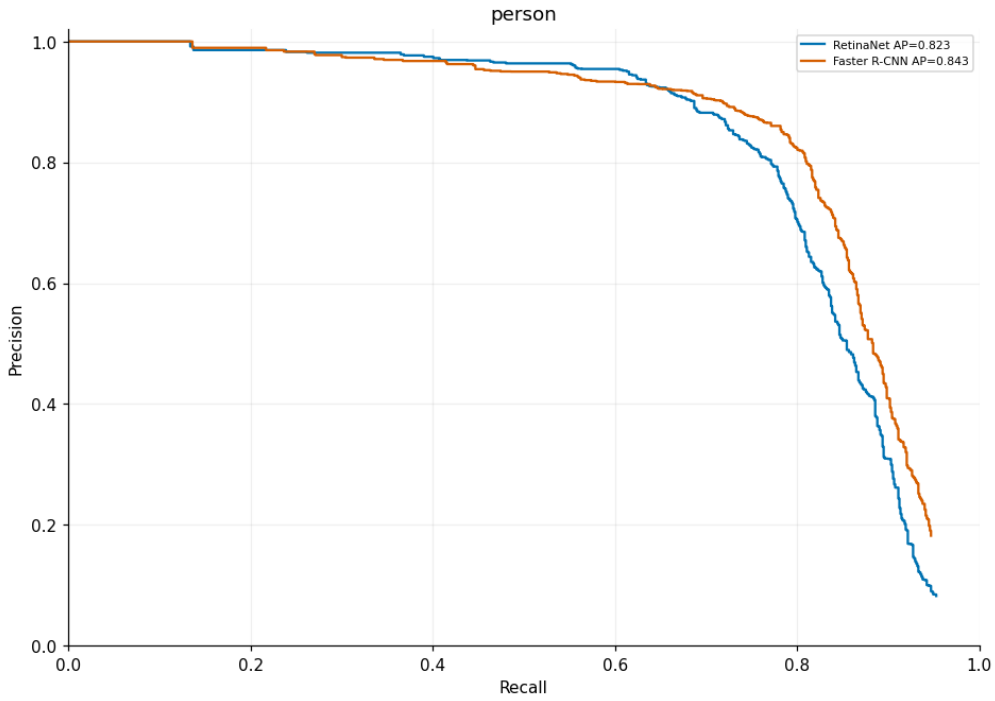

(a) person

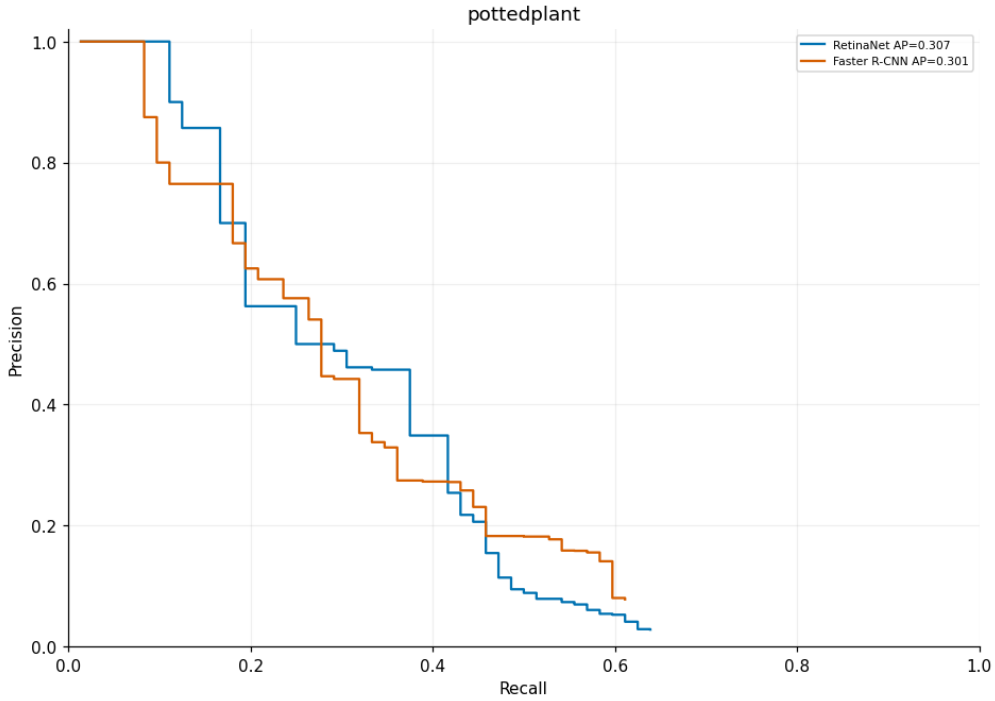

(b) pottedplant

Hình A.25: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

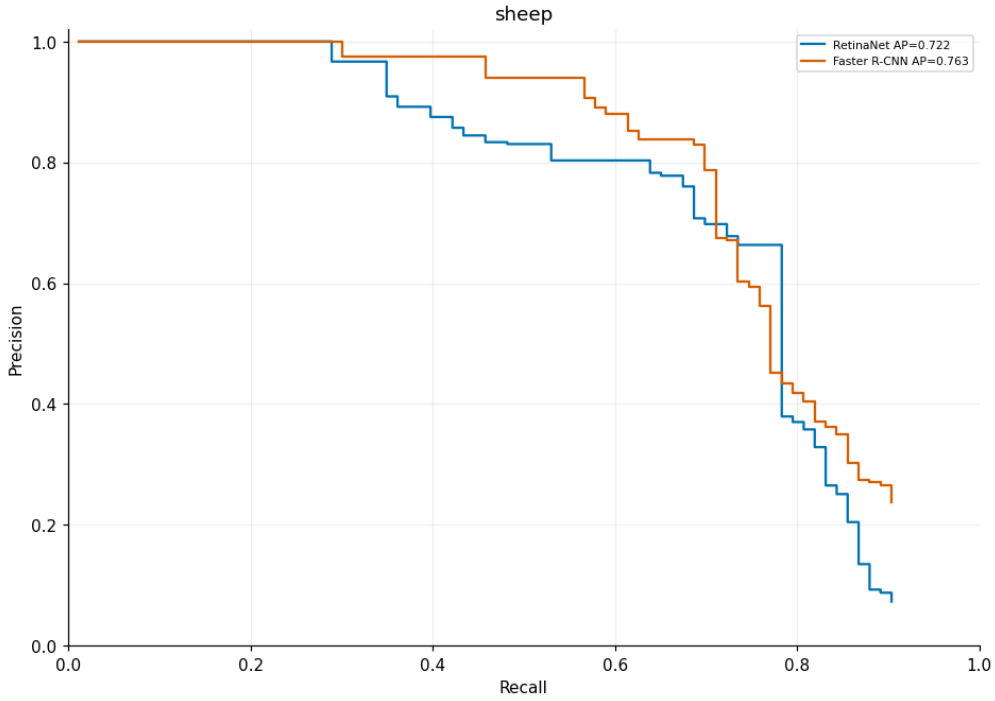

(a) sheep

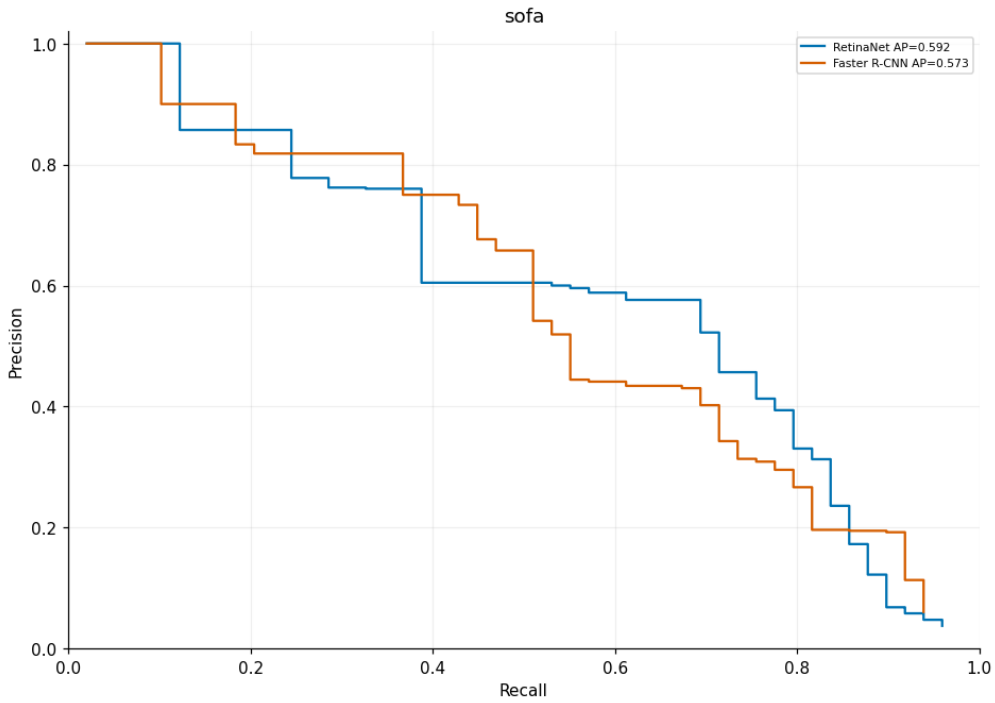

(b) sofa

Hình A.26: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

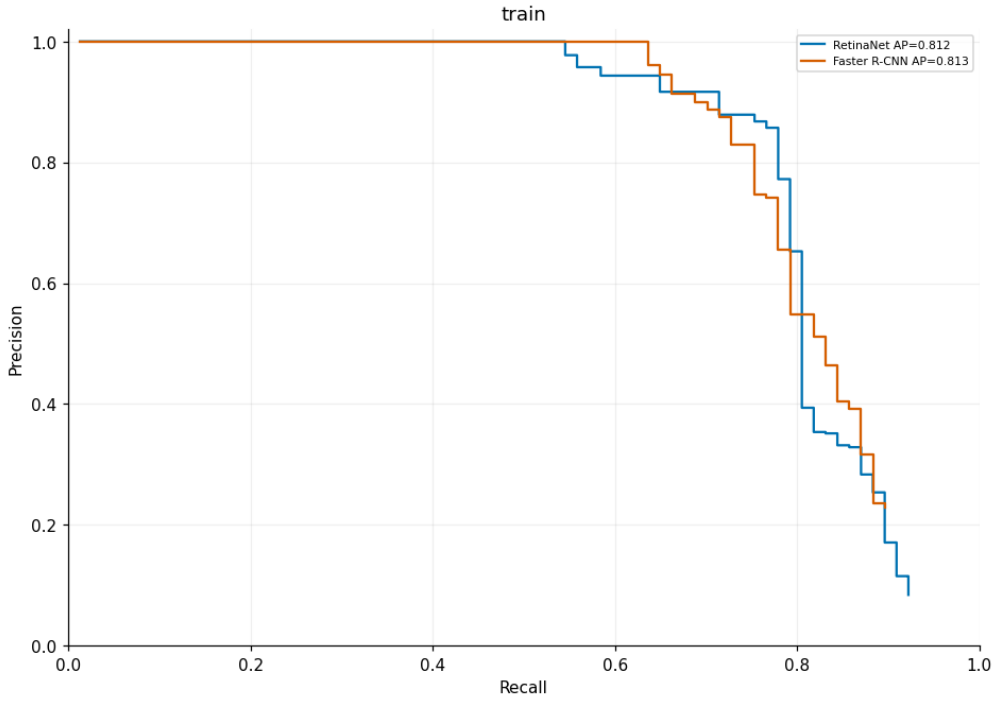

(a) train

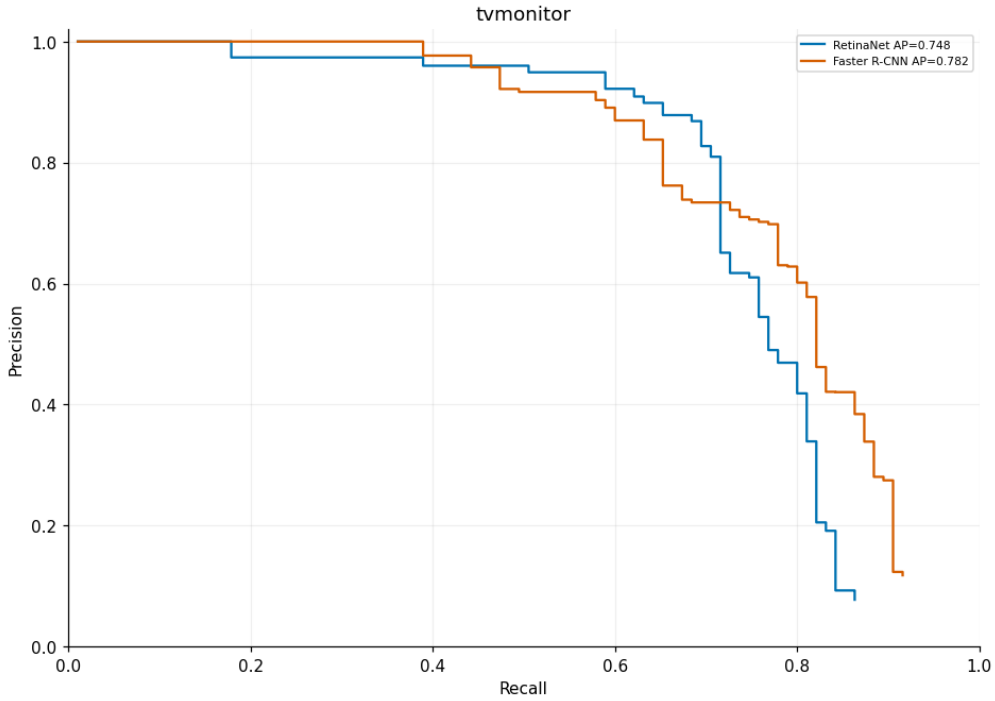

(b) tvmonitor

Hình A.27: Precision–recall A2 trên test holdout: RetinaNet và Faster R-CNN; legend ghi VOC AP50, recall/precision ở [0,1].

A.8 Ảnh test và dự đoán A2

(a) Ground truth

(b) RetinaNet

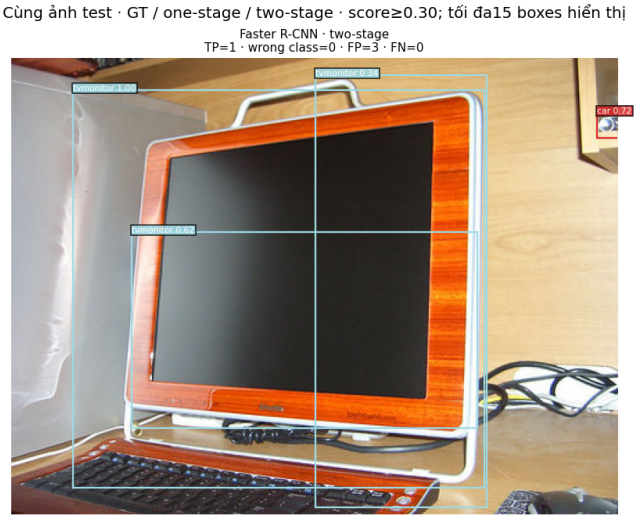

(c) Faster R-CNN

Hình A.28: VOC2012 test 2012_2008_000016. Predictions dùng score ≥ 0.30, tối đa 15 boxes; difficult GT nét đứt. Các số chẩn đoán trong tiêu đề dùng mọi detection vượt ngưỡng.

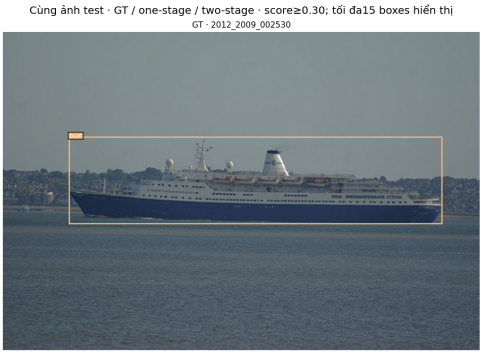

(a) Ground truth

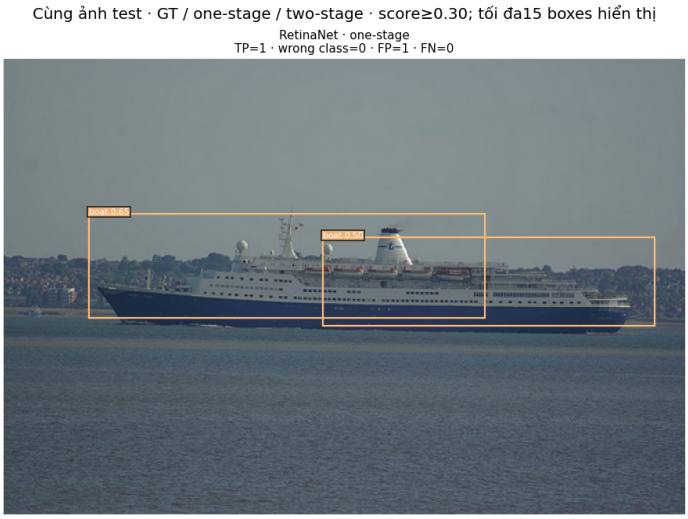

(b) RetinaNet

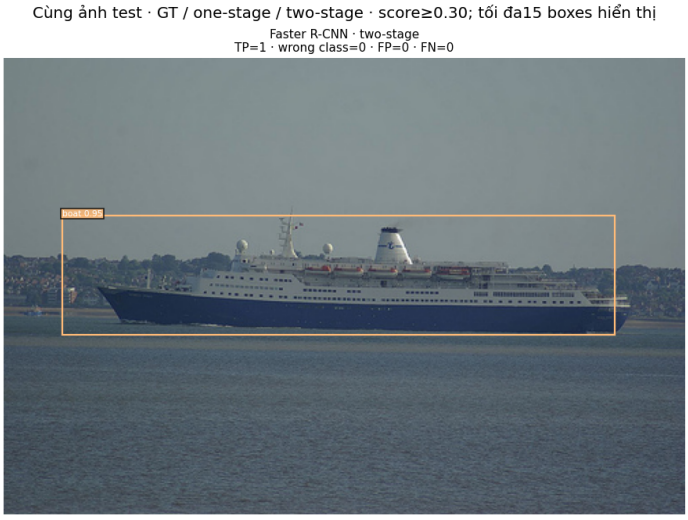

(c) Faster R-CNN

Hình A.29: VOC2012 test 2012_2009_002530. Predictions dùng score ≥ 0.30, tối đa 15 boxes; difficult GT nét đứt. Các số chẩn đoán trong tiêu đề dùng mọi detection vượt ngưỡng.

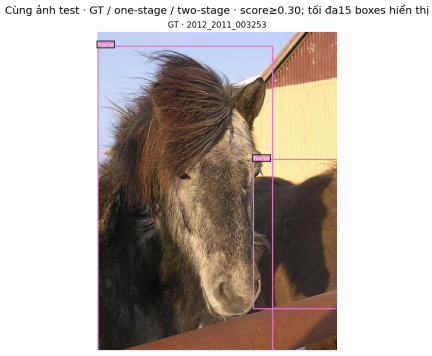

(a) Ground truth

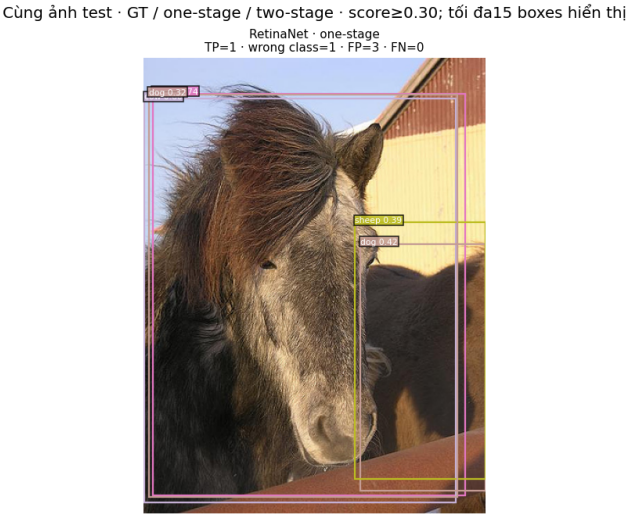

(b) RetinaNet

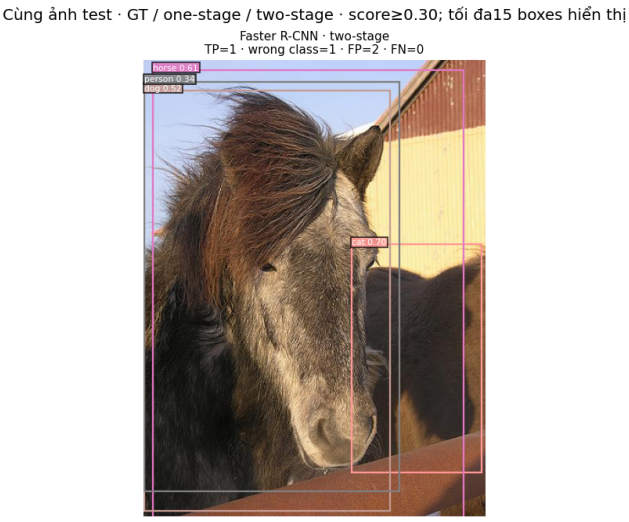

(c) Faster R-CNN

Hình A.30: VOC2012 test 2012_2011_003253. Predictions dùng score ≥ 0.30, tối đa 15 boxes; difficult GT nét đứt. Các số chẩn đoán trong tiêu đề dùng mọi detection vượt ngưỡng.

A.9 Trường hợp sai A2

(a) Ground truth

(b) RetinaNet

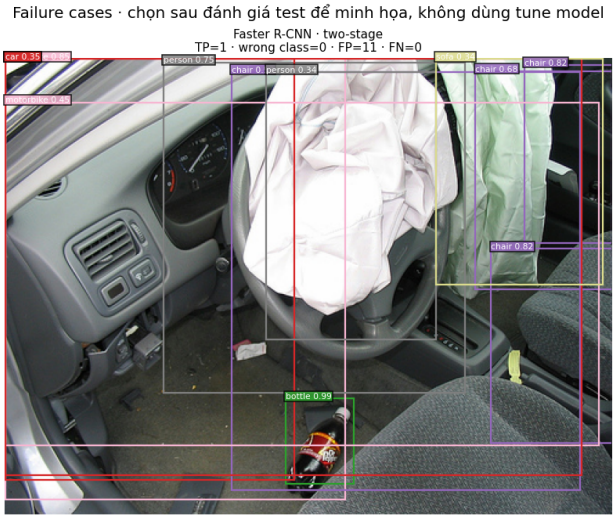

(c) Faster R-CNN

Hình A.31: VOC2012 test 2012_2008_004581. Predictions dùng score ≥ 0.30, tối đa 15 boxes; difficult GT nét đứt. Các số chẩn đoán trong tiêu đề dùng mọi detection vượt ngưỡng.

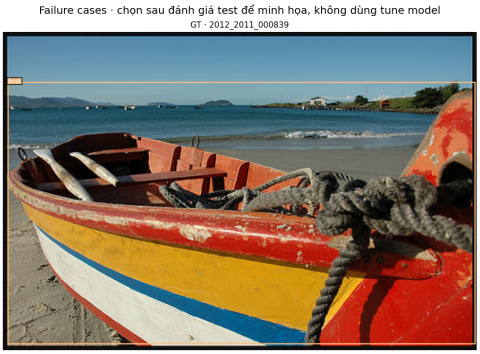

(a) Ground truth

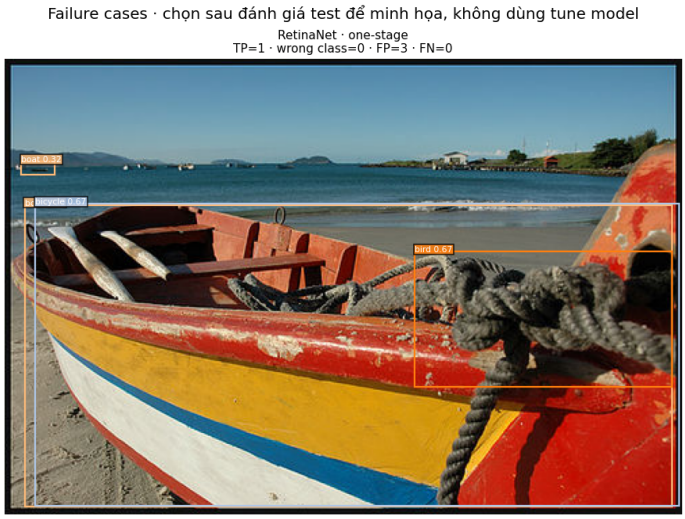

(b) RetinaNet

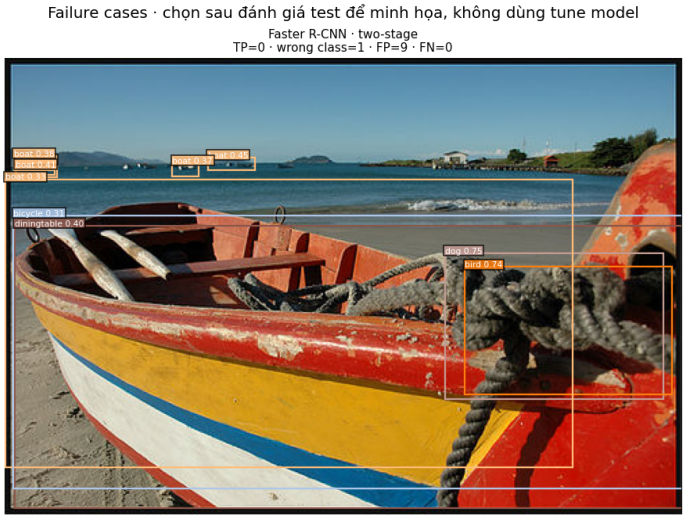

(c) Faster R-CNN

Hình A.32: VOC2012 test 2012_2011_000839. Predictions dùng score ≥ 0.30, tối đa 15 boxes; difficult GT nét đứt. Các số chẩn đoán trong tiêu đề dùng mọi detection vượt ngưỡng.

Trường hợp 2012_2011_000666 được đối chiếu tại Hình 6.10, mục 6.9.

A.10 Nguồn số liệu và hướng dẫn tái lập

Số liệu lấy từ output E1.ipynb, E2.ipynb, E3.ipynb, A1.ipynb và A2.ipynb trong source_code. Manifest assets ghi notebook/cell/output; report_figures.json ghi các hình tĩnh dựng từ bảng/dữ liệu nguồn đã kiểm chứng. Hình độc lập được ghép bằng LaTeX, không cắt từ raster ghép; TikZ theo code. Mã kiểm chứng cách chia tập Fashion-MNIST/GTSRB được lưu tại assets/split_identifiers.json trong nguồn báo cáo.

E1–E3/A1: chuẩn bị dữ liệu theo README datasets, chọn Python 3.14 CUDA, Restart Kernel/Run All/Save; các file độc lập. Patience/min-delta là $4/10^{-4}$ cho E1–E3 và $2/10^{-3}$ cho A1. A2.ipynb dùng dataset a2-voc2012 tại đường dẫn trong code, accelerator T4 x2 và Internet khi cần weights/thư viện. Run All train hai worker, rồi test/benchmark lần lượt; batch 8, accumulation 3, effective 24, tối đa 30 epoch, patience 2/min-delta 0.001. Metadata ghi Python 3.13.15; output không có phiên bản PyTorch/torchvision nên cần ghi môi trường khi tái lập. Save notebook và tải /kaggle/working/report/A2 cùng /kaggle/working/model/A2 trước khi kết thúc session.

Dùng CHECKPOINT_ROOT trống để khởi tạo theo seed; latest.pt có sẵn thay đổi weights đầu vào theo quy tắc Chương 1. Seed không bảo đảm bitwise qua GPU, thư viện hay AMP. Số liệu A2 lấy từ output A2.ipynb chạy trên Kaggle, theo protocol Chương 6.

Báo cáo biên dịch bằng XeLaTeX và BibTeX từ report/source_latex/main.tex; TikZ định nghĩa trong architectures.tex, ảnh kết quả nằm ở assets. PDF chung giữ tại report/CO5085_Report.pdf.