

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP

Môn: Học sâu và ứng dụng trong thị giác máy tính

**Thực nghiệm học sâu cho phân loại ảnh
và phát hiện đối tượng**

E1 – E2 – E3 – A1 – A2

CO5085 – Học kỳ 261 (2026–2027)

Giảng viên: Lê Thành Sách, Nguyễn Quốc Minh

Thực hiện

Đặng Nguyễn Tấn Tài 2570357

Lớp: CH01

Thành phố Hồ Chí Minh, 10/2026

Tóm tắt

Báo cáo khảo sát năm nhóm thực nghiệm qua 36 lượt huấn luyện: bốn mô hình E1, tám cấu hình attention E2, tám cấu hình hồi tiếp/baseline E3, 14 cấu hình CNN/Transformer A1 và hai detector A2. E1–E3 dùng Fashion-MNIST với 54.000 ảnh train, 6.000 validation và 10.000 test. A1 dùng GTSRB 43 lớp, tách validation theo track biển báo. A2 dùng toàn bộ 11.540 ảnh VOC2012 trainval có nhãn, chia 9.232/1.154/1.154 thành train/validation/test nội bộ. Mỗi notebook độc lập, có vòng lặp PyTorch và lưu kết quả ngay trong output cell.

Trên Fashion-MNIST, CNN-B đạt test accuracy 91,97% với 94.186 tham số; MSA PyTorch với CNN-stem đạt 90,78%; GRU theo hàng đạt 90,06%. Trên GTSRB, pretrained full ResNet-50 và DeiT-Small/16 ở seed 42 đạt 98,37% và 98,92%; trung bình ba seed là $98,44 \pm 0,29\%$ và $98,95 \pm 0,33\%$. Trên VOC2012, RetinaNet/Faster R-CNN đạt mAP50 71,58%/73,07% và COCO-style AP50:95 41,36%/40,75%. Không có kiến trúc tốt nhất trên mọi tiêu chí: kết quả được phân tích cùng chi phí, chất lượng từng lớp và các trường hợp sai. Sơ đồ TikZ thể hiện luồng tensor, kích thước feature map và cấu trúc head; số liệu/hình kết quả được lấy từ output notebook đã lưu.

Mục lục

Tóm tắt	i
1 Bài toán và thiết kế thực nghiệm	1
1.1 Mục tiêu và phạm vi	1
1.2 Dữ liệu và cách chia tập	1
1.3 Môi trường và quy tắc đánh giá	2
2 E1: Softmax, MLP và CNN	4
2.1 Mục tiêu và kiến trúc	4
2.2 Huấn luyện	5
2.3 Kết quả định lượng và chi phí	6
2.4 Learning curves và phân tích lỗi	7
2.5 Nhận xét và giới hạn	9
3 E2: Multi-head self-attention và tokenization	10
3.1 Mục tiêu và biểu diễn token	10
3.2 Kiến trúc encoder và MSA	11
3.3 Thiết lập huấn luyện và tám cấu hình	12
3.4 Kết quả và so sánh theo đề	12
3.5 Learning curves, attention và lỗi	15
4 E3: LSTM và GRU trên chuỗi ảnh	18
4.1 Biểu diễn ảnh thành chuỗi	18
4.2 Cell LSTM/GRU tự hiện thực	19
4.3 Baseline và thiết lập huấn luyện	20
4.4 Kết quả, representation và chi phí	20
4.5 Learning curves và lỗi	22
5 A1: CNN và Transformer trên GTSRB	24
5.1 Dữ liệu, phân bố lớp và cách chia tập	24
5.2 DataLoader, augmentation và kiến trúc	25
5.3 Các cấu hình và thiết lập huấn luyện	27
5.4 Kết quả chính: CNN vs Transformer và pretraining	27

5.5	Freeze, chi phí và đường cong	29
5.6	Augmentation và độ ổn định qua seed	30
5.7	Confusion matrix, lỗi và trùng ảnh	31
5.8	Kết luận A1 và giới hạn	33
6	A2: RetinaNet và Faster R-CNN trên VOC2012	34
6.1	Bài toán và dữ liệu	34
6.2	Tiền xử lý và DataLoader	35
6.3	FPN: phương pháp, thí nghiệm và giới hạn	35
6.4	RetinaNet và Focal Loss	36
6.4.1	Động cơ và hàm mất mát	36
6.4.2	Neck, anchors và head	37
6.5	Faster R-CNN: RPN và RoI head	38
6.6	Huấn luyện và lựa chọn weights	40
6.6.1	Phạm vi đối chiếu paper	41
6.7	Chỉ số đánh giá	41
6.8	Kết quả test và so sánh	42
6.8.1	Chi phí huấn luyện và suy luận	43
6.9	Theo lớp, ma trận và trường hợp sai	44
6.10	Kết luận A2 và giới hạn	45
7	Kết luận	49
7.1	Ghi nhận hỗ trợ của công cụ AI	49
A	Kết quả chi tiết và tái lập	52
A.1	Chi tiết huấn luyện E1–E3 và A1	52
A.2	Metric theo lớp và độ nhạy A1	53
A.3	Ma trận nhầm lẫn E2 và E3	55
A.4	Dữ liệu và chỉ số theo lớp A2	63
A.5	Ma trận chẩn đoán A2	65
A.6	Nguồn số liệu và hướng dẫn tái lập	70

Danh sách hình vẽ

1.1	Fashion-MNIST: ảnh đại diện và phân bố train/validation cân bằng.	2
2.1	Softmax classifier: không Conv, một FC; 7.850 tham số.	4
2.2	MLP: ba FC, hai tầng ẩn; 235.146 tham số.	4
2.3	CNN-A: hai Conv, hai MaxPool, hai FC; 421.642 tham số. Conv stride 1, padding 1, có bias.	5
2.4	CNN-B: ba Conv/BN/MaxPool, một FC; 94.186 tham số. Conv stride 1, padding 1, không bias. Kích thước sau pool thứ ba là 3×3	5
2.5	So sánh validation accuracy, số tham số và thời gian train+validation của E1. . .	6
2.6	Loss và accuracy của bốn model; nét đứt train, nét liền validation.	7
2.7	Confusion matrix test của Softmax và MLP: mỗi ô ghi số ảnh và tỷ lệ theo lớp thật.	7
2.8	Confusion matrix test của CNN-A và CNN-B, cùng thang 0–100%.	8
2.9	Ảnh dự đoán sai của E1; cùng cột là cùng lớp thật, mỗi hàng là một model. . .	9
3.1	Ba tokenizer E2; CNN-stem có hai Conv kernel 3, stride 1, padding 1, bias, ReLU và MaxPool 2 sau mỗi Conv. Rows không có Conv; patch lấy trực tiếp pixel.	10
3.2	Classifier E2: một FC embedding, hai encoder block và một FC head; không CLS token.	11
3.3	Một pre-norm encoder block: hai projection MSA và hai FC trong FFN, tổng bốn ánh xạ Linear/block. Đường ngoài là residual.	11
3.4	Tổng quan accuracy validation, capacity và chi phí E2.	13
3.5	So sánh manual/PyTorch cùng tokenizer: accuracy, params và giây/epoch. . . .	13
3.6	Ablation H=2/4/8 trên manual CNN-stem, giữ D=64.	14
3.7	Loss theo epoch, nhóm theo tokenizer; train nét đứt, validation nét liền.	15
3.8	Accuracy theo epoch của các cấu hình E2.	15
3.9	Attention của manual CNN-stem H=4 trên hai ảnh validation cố định; trung bình head, block cuối, gộp 7 nhóm query/key, tổng mỗi hàng 100%.	16
3.10	Gallery lỗi của các mô hình đại diện E2 chọn bằng validation.	17
4.1	Cùng một ảnh validation được chuyển thành rows, columns và patch: thứ tự quét cùng ma trận timestep–feature.	18
4.2	Classifier recurrent E3: không Conv, một recurrent layer unroll T lần và một FC head. Trạng thái khởi tạo bằng 0, chỉ dùng hidden cuối.	18

4.3	LSTM cell: hai projection dùng chung ở mọi bước; không tạo thêm bộ tham số cho mỗi timestep.	19
4.4	GRU cell: hai projection cho ba nhóm gate, chỉ duy trì hidden state.	19
4.5	Accuracy, capacity và thời gian E3 trên cùng Fashion-MNIST.	21
4.6	LSTM vs GRU với cùng representation.	21
4.7	So sánh recurrent rows chọn bằng validation với MLP và CNN-B train trong E3.	22
4.8	Loss E3 theo representation; nét đứt train, nét liền validation.	22
4.9	Accuracy E3 theo representation.	22
4.10	Gallery lỗi recurrent và baseline E3; ma trận của mọi run nằm ở Phụ lục.	23
5.1	Phân bố 43 lớp trên các split và kích thước ảnh train gốc.	25
5.2	Một ảnh train đại diện cho mỗi lớp GTSRB; ID dùng để tra ma trận nhầm lẫn.	25
5.3	A1 ResNet-50: backbone thể hiện bằng một khối, chỉ thay một FC 43 lớp. Head có 88.107 tham số; tổng 23.596.139.	26
5.4	A1 DeiT-Small/16: backbone gom khối, thể hiện token và kích thước FFN; head 16.555 tham số, tổng 21.682.219.	26
5.5	Accuracy validation/test, trainable params và giây/epoch của tám cấu hình chính.	28
5.6	Loss của hai họ kiến trúc theo bốn regime; train nét đứt, validation nét liền.	29
5.7	Accuracy theo epoch A1; mỗi panel một họ kiến trúc.	30
5.8	Augmentation và ba seed của full pretrained; đồ thị dựng từ bảng output, trực tung thu hẹp 97,5–100,6% để đọc chênh lệch; error bar là std mẫu.	31
5.9	Trích 10 lớp liên quan nhiều ảnh sai của mỗi full pretrained seed 42; mẫu số vẫn là toàn bộ lớp thật trong 43 lớp.	31
5.10	Các ảnh sai của hai full model seed 42; hàng trên ResNet, hàng dưới DeiT, ghi cả nhãn thật/dự đoán.	32
6.1	Phân bố bbox thường của 20 lớp trong train, validation và test; mỗi panel dùng trục riêng.	34
6.2	Kích thước, tỷ lệ cạnh bbox và chiều rộng/cao ảnh gốc.	35
6.3	Ảnh gốc, resize giữ tỷ lệ và horizontal flip; bbox đi cùng phép biến đổi.	35
6.4	FPN RetinaNet. Shape minh họa tại input 512×512 ; thí nghiệm dùng resize 600/max 1000. Độ sâu khối thể hiện channels, không dùng cùng tỷ lệ với kích thước không gian.	37
6.5	RetinaNet head: $9 \times 20 = 180$ class logits, $9 \times 4 = 36$ offsets mỗi vị trí; không có logit background riêng.	38
6.6	FPN Faster R-CNN: P2 có độ phân giải cao, P6 lấy từ P5. Shape ở input 512×512 chỉ để đổi chiều cấu trúc.	39
6.7	Faster R-CNN: RPN tạo proposals, RoI Pool gom feature, hai FC trước hai nhánh output.	40

6.8	Loss train và validation VOC mAP50/COCO-style AP; nét đứt đứng chỉ epoch được chọn.	43
6.9	Hai thành phần loss RetinaNet và bốn thành phần RPN/RoI; mỗi panel có trục riêng.	43
6.10	So sánh AP, latency batch 1 và peak allocated VRAM; số và đơn vị ghi trên đồ thị.	44
6.11	VOC AP50 và COCO-style AP theo lớp; hai detector dùng chung mỗi panel. . .	45
6.12	Precision–recall 20 lớp; mỗi subplot có hai detector, AP trong legend là VOC AP50.	46
6.13	Cùng ba ảnh test: GT / RetinaNet / Faster R-CNN; score hiển thị 0,30, difficult nét đứt.	47
6.14	Ba ảnh có nhiều false positives: con chó, xe đồ chơi và trang trí nội thất. Các ví dụ được chọn sau test để phân tích, không dùng để chọn cấu hình.	48
A.1	E2: confusion matrix test, cặp 1; tên model ghi trên từng panel.	55
A.2	E2: confusion matrix test, cặp 2; tên model ghi trên từng panel.	56
A.3	E2: confusion matrix test, cặp 3; tên model ghi trên từng panel.	57
A.4	E2: confusion matrix test, cặp 4; tên model ghi trên từng panel.	58
A.5	E3: confusion matrix test, cặp 1; tên model ghi trên từng panel.	59
A.6	E3: confusion matrix test, cặp 2; tên model ghi trên từng panel.	60
A.7	E3: confusion matrix test, cặp 3; tên model ghi trên từng panel.	61
A.8	E3: confusion matrix test, cặp 4; tên model ghi trên từng panel.	62
A.9	A2 RetinaNet: số đếm, $\text{IoU} \geq 0,5$, $\text{confidence} \geq 0,30$	66
A.10	A2 RetinaNet: tỷ lệ theo hàng, $\text{IoU} \geq 0,5$, $\text{confidence} \geq 0,30$	67
A.11	A2 Faster R-CNN: số đếm, $\text{IoU} \geq 0,5$, $\text{confidence} \geq 0,30$	68
A.12	A2 Faster R-CNN: tỷ lệ theo hàng, $\text{IoU} \geq 0,5$, $\text{confidence} \geq 0,30$	69

Danh sách bảng

1.1	Đối chiếu nội dung kỹ thuật với đề E1–E3, A1 và A2.	1
1.2	Ba tập dữ liệu sử dụng trong báo cáo.	1
1.3	Quy mô các lượt huấn luyện tạo ra số liệu báo cáo.	3
2.1	Metric E1 tại checkpoint chọn bằng validation loss; F1 là macro-F1.	6
2.2	Capacity và chi phí E1; epoch/best ghi số epoch thực chạy và epoch checkpoint.	6
2.3	Cặp nhầm nhiều nhất trong E1; mỗi lớp test có 1.000 ảnh.	8
3.1	Metric E2; mọi model đánh giá đủ 10.000 ảnh test, F1 là macro-F1.	12
3.2	Capacity và chi phí của tám cấu hình E2.	13
3.3	So sánh manual/PyTorch ở H=4, cùng weights khởi tạo.	14
3.4	Nhầm lẫn lớn nhất của ba tokenizer manual H=4.	16
4.1	Metric của sáu recurrent model và hai baseline E3, F1 là macro-F1.	20
4.2	Số tham số, epoch và chi phí E3.	20
4.3	Cặp nhầm lớn nhất của recurrent đại diện và baseline E3.	23
5.1	Split GTSRB sử dụng toàn bộ dữ liệu.	24
5.2	Các mức freeze và số tham số được tối ưu.	27
5.3	Tám cấu hình chính A1; mọi F1 là macro-F1.	27
5.4	Capacity, số epoch và peak allocated GPU memory A1.	28
5.5	Thời gian train+val và inference FP32; CUDA Events batch 32, tách DataLoader.	29
5.6	Sáu thực nghiệm bổ sung trên full pretrained; cấu hình đã chọn trước test.	30
5.7	Augmentation ablation, cùng full mode và seed 42.	30
5.8	Full pretrained, 3 seed 42/43/44, giữ split 42; độ lệch chuẩn mẫu (ddof=1), không phải khoảng tin cậy.	31
5.9	Một số lớp khó trong hai full model seed 42; test support và recall/F1.	32
6.1	Số ảnh và annotation VOC2012. Một bbox có thể vừa difficult vừa truncated.	34
6.2	Kết quả và ablation của FPN trên COCO; số liệu tác giả [5].	36
6.3	RetinaNet Table 1: ablation trên COCO minival và đánh đổi tốc độ/AP trên test-dev; số liệu tác giả [6].	36
6.4	Số tham số trainable. FrozenBatchNorm giữ statistics/buffers cố định.	40
6.5	Epoch thực chạy, epoch chọn, validation mAP50 và số cập nhật SGD.	41
6.6	Test holdout 1.154 ảnh, 2.687 bbox thường. Metric ở thang 0–1.	42
6.7	COCO-style AP theo scale và AR trung bình qua các ngưỡng IoU.	42

6.8	Chi phí trên RTX A3000 12 GB Laptop; peak là allocated PyTorch, không phải tổng VRAM.	43
6.9	R=RetinaNet, F=Faster R-CNN; AP là COCO-style AP50:95, F1 tại score 0,30.	44
A.1	Chi tiết lượt train E1.	52
A.2	Chi tiết lượt train E2; ký hiệu M/T và R/P/C như Chương E2.	52
A.3	Chi tiết lượt train E3.	52
A.4	Epoch, cập nhật và peak memory của sáu run mở rộng A1.	53
A.5	Precision/recall/F1 trên test GTSRB, lớp 0–21.	53
A.6	Precision/recall/F1 trên test GTSRB, lớp 22–42.	54
A.7	Độ nhảy A1 với 8 ảnh test trùng train.	54
A.8	Số bbox thường của từng lớp VOC2012; difficult không nằm trong các cột này.	63
A.9	P/R/F1 tại score 0,30; R=RetinaNet, F=Faster R-CNN, Rec là recall.	64
A.10	AP50/AP75 COCO-style và AP11 VOC07 từng lớp; metric ở thang 0–1.	65

1. Bài toán và thiết kế thực nghiệm

1.1 Mục tiêu và phạm vi

E1–E3 khảo sát cách biểu diễn cùng một ảnh thành vector, feature map, token và chuỗi. A1 mở rộng sang ảnh RGB biến báo để so sánh CNN/Transformer và các mức sử dụng trọng số pretrained. A2 chuyển sang phát hiện nhiều đối tượng trong ảnh, so sánh detector một/hai giai đoạn và phân tích hai paper FPN, Focal Loss. Mỗi chương trình bày dữ liệu, phương pháp, huấn luyện, kết quả và giới hạn theo bố cục báo cáo mẫu.

Bảng 1.1: Đối chiếu nội dung kỹ thuật với đề E1–E3, A1 và A2.

Bài	Yêu cầu	Nội dung thực nghiệm
E1	Softmax, MLP, CNN; loop tự viết; accuracy, capacity, curves, lỗi	4 mô hình, 2 CNN; bảng metric/chi phí, ma trận và ảnh sai.
E2	MSA thủ công/PyTorch; ≥ 2 tokenizer; so sánh từng cặp	2 cách cài đặt $\times$ 3 tokenizer, kiểm tra forward/gradient, $H=2/4/8$.
E3	LSTM/GRU, biểu diễn chuỗi và baseline MLP/CNN	2 cell $\times$ 3 cách quét, 2 baseline train độc lập trên cùng split.
A1	CNN/Transformer, scratch/pretrained, 3 mức freeze; metric/chi phí/lỗi	GTSRB 43 lớp, 8 cấu hình chính, 2 no-augmentation, 4 seed repeats.
A2	Detection, ≥ 2 phương pháp; mAP50, AP50:95 nếu được; phân tích paper	VOC2012, RetinaNet/Faster R-CNN, FPN/Focal Loss, AP/AR/F1/FPS và failure cases.

Các nội dung kỹ thuật được tổng hợp trong PDF này; video demo và việc công bố repository/Pages là các sản phẩm nộp riêng. Trang public cung cấp đường dẫn tới notebook, đề bài, báo cáo và nguồn LaTeX.

1.2 Dữ liệu và cách chia tập


Fashion-MNIST [12] gồm ảnh grayscale 28×28 của 10 loại sản phẩm: T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag và Ankle boot. Từ 60.000 ảnh train nguồn, lấy 600 ảnh/lớp làm validation với seed 42; giữ nguyên official test 10.000 ảnh.

Bảng 1.2: Ba tập dữ liệu sử dụng trong báo cáo.

Bài	Dataset	Lớp	Train	Val	Test
E1–E3	Fashion-MNIST	10	54.000	6.000	10.000
A1	GTSRB	43	31.380	7.829	12.630
A2	VOC2012	20	9.232	1.154	1.154

Fashion-MNIST có 5.400/600/1.000 ảnh mỗi lớp ở train/val/test. Pixel chuyển về $[0, 1]$, chuẩn hóa bằng mean 0,285886 và std 0,352960 tính từ train; không augmentation. E1–E3 dùng cùng split fingerprint:

```
bd9f3884131e411a26892e15ff685f2849
216340505ea615f3fb3b901e30fe80
```



Hình 1.1: Fashion-MNIST: ảnh đại diện và phân bố train/validation cân bằng.

GTSRB chia theo track để hạn chế các frame cùng biển vật lý rơi vào cả train và validation. VOC2012 chia theo ảnh; test là holdout nội bộ. Chi tiết nhãn, augmentation, nguồn tải và giới hạn độc lập dữ liệu được trình bày ở từng chương và README dataset.

1.3 Môi trường và quy tắc đánh giá

Python 3.14.7, PyTorch 2.11.0+cu128, torchvision 0.26.0+cu128, NumPy 2.5.2, Matplotlib 3.11.2 và Pillow 12.3.0 chạy trên Windows, GPU NVIDIA RTX A3000 12 GB Laptop, CUDA 12.8. DataLoader workers 0. Training loop thực hiện forward, loss, backward và optimizer step; AMP/GradScaler hỗ trợ train, validation/test không tính gradient.

Với các bài phân loại E1–E3/A1, cross-entropy tính trực tiếp trên logits:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp z_{i,y_i}}{\sum_{c=1}^C \exp z_{i,c}}. \quad (1.1)$$

Softmax chỉ cần khi diễn giải xác suất; argmax logits cho cùng nhãn. Loss được tổng hợp theo số ảnh. Accuracy là tỷ lệ dự đoán đúng; $F1_c = 2P_cR_c/(P_c + R_c)$, macro-F1 trung bình đều qua các lớp. Ma trận có hàng là GT, cột là prediction; phần trăm chuẩn hóa theo hàng.

Checkpoint phân loại chọn validation loss nhỏ nhất; dừng sớm dùng min-delta 10^{-4} . E1–E3 dùng patience 10 trong thực nghiệm, A1 dùng patience 4. Đại diện/ablation chọn bằng validation accuracy, macro-F1 rồi loss. A2 chọn weights và dừng sớm theo validation VOC mAP50, patience 2, min-delta 0,001; cách matching và detection metrics được trình bày ở Chương 6. Cấu hình được chốt bằng validation trước khi đánh giá test.

Bảng 1.3: Quy mô các lượt huấn luyện tạo ra số liệu báo cáo.

Bài	Lượt train	Epoch	CUDA updates	AMP skips
E1	4	108	45.574	2
E2	8	259	109.290	8
E3	8	238	100.434	2
A1	14	208	51.168	0
A2	2	36	27.720	0
Tổng	36	849	334.186	12


AMP skips là các optimizer steps bị scaler bỏ qua khi gradient không hữu hạn; không tính chúng vào updates thực tế. Train accuracy được đo khi weights đang cập nhật, có dropout/augmentation; không xem chênh lệch train–validation như hai phép đo eval hoàn toàn tương đương. Thời gian train + validation không gồm test/vẽ hình. Peak memory dùng `torch.cuda.max_memory_allocated`, không phải reserved hoặc tổng VRAM máy.

Mỗi notebook tự dựng dataset, model và loop, không đọc code/checkpoint của notebook khác. Best weights chỉ giữ trong RAM cho cùng lần chạy; notebook không xuất thêm file kết quả. Kích thước tensor trên sơ đồ dùng thứ tự $H \times W \times C$ cho ảnh/feature map, $N \times D$ cho token; batch được lược để dễ đọc. Mặt trước biểu diễn không gian, phần sâu và độ dày nét gọi số channels; sơ đồ không dùng một tỷ lệ hình học chung.


2. E1: Softmax, MLP và CNN

2.1 Mục tiêu và kiến trúc

E1 so sánh classifier tuyến tính, MLP và CNN trên cùng Fashion-MNIST. Softmax dùng vector flatten 784 chiều; MLP thêm phi tuyến; CNN giữ cấu trúc không gian trước khi gom feature. Hai CNN giúp phân biệt số tham số và chất lượng: CNN-A có head lớn, CNN-B dùng global average pooling.




Hình 2.1: Softmax classifier: không Conv, một FC; 7.850 tham số.




Mỗi cột minh họa một tầng; các nơ-ron được lược bớt.

Hình 2.2: MLP: ba FC, hai tầng ẩn; 235.146 tham số.



Hình 2.3: CNN-A: hai Conv, hai MaxPool, hai FC; 421.642 tham số. Conv stride 1, padding 1, có bias.



Hình 2.4: CNN-B: ba Conv/BN/MaxPool, một FC; 94.186 tham số. Conv stride 1, padding 1, không bias. Kích thước sau pool thứ ba là 3×3 .

Ký hiệu 3^2 chỉ kernel 3×3 ; chiều batch được lược bỏ sơ đồ. CNN-A dành 401.536 tham số cho FC $3136 \rightarrow 128$, khoảng 95,2% tổng số tham số. CNN-B thay head này bằng average pooling, nên ít tham số hơn dù có thêm một Conv.

2.2 Huấn luyện

AdamW LR 10^{-3} , weight decay 10^{-4} , batch 128, tối đa 100 epoch. Mỗi epoch có 422 batch train, 47 validation; test có 79 batch, giữ batch cuối. Thí nghiệm dùng patience 10, min-delta 10^{-4} và checkpoint theo validation loss nhỏ nhất. Không dùng scheduler hoặc augmentation. Các kiểm tra forward/backward trước train xác nhận đủ bốn model trên CUDA.


2.3 Kết quả định lượng và chi phí

Bảng 2.1: Metric E1 tại checkpoint chọn bằng validation loss; F1 là macro-F1.

Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
Softmax	86,51	84,88	0,8481	84,27	0,8418	0,4408
MLP	91,58	89,47	0,8951	89,45	0,8948	0,3142
CNN-A	94,61	92,00	0,9203	91,66	0,9169	0,2339
CNN-B	95,82	91,92	0,9190	91,97	0,9193	0,2320

Bảng 2.2: Capacity và chi phí E1; epoch/best ghi số epoch thực chạy và epoch checkpoint.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
Softmax	7,850	24/14	28,58	1,191	19
MLP	235,146	26/16	50,52	1,943	23
CNN-A	421,642	18/8	38,19	2,121	52
CNN-B	94,186	40/30	126,33	3,158	57




Hình 2.5: So sánh validation accuracy, số tham số và thời gian train+validation của E1.

MLP tăng test accuracy từ 84,27% lên 89,45%, tương đương 5,18 điểm phần trăm. Điều này cho thấy phi tuyến hữu ích trên cùng vector flatten. CNN-A đạt 91,66%, CNN-B đạt 91,97%, cao hơn MLP lần lượt 2,21 và 2,52 điểm phần trăm.


CNN-A có số tham số gấp 4,48 lần CNN-B; CNN-B vẫn đạt test cao hơn 0,31 điểm phần trăm nhưng val thấp hơn 0,08 điểm. Đây là khác biệt nhỏ trong một seed, không phải bằng chứng CNN-B luôn tốt hơn. Hai mạng khác cả normalization, độ sâu, pooling và head; không quy chất lượng chỉ cho số tham số. CNN-A có val accuracy cao nhất 92,00%; mô hình đại diện không được chọn bằng kết quả test của CNN-B. Tính theo mỗi epoch, CNN-B chậm hơn CNN-A (3,158 so với 2,121 s) dù ít tham số hơn, vì convolution/BN và kích thước activation cũng quyết định chi phí.

2.4 Learning curves và phân tích lỗi




Hình 2.6: Loss và accuracy của bốn model; nét đứt train, nét liền validation.

Train–validation gap ở best lần lượt khoảng 1,62; 2,11; 2,61; 3,91 điểm phần trăm. CNN-B có gap lớn nhất nhưng vẫn đạt test tốt; gap cần đọc cùng dropout và đường cong, không dùng riêng để xếp hạng tổng quát hóa. Đường cong train tiếp tục cải thiện sau khi validation chứng lại giải thích việc dùng trọng số tại epoch tốt nhất thay cho epoch cuối.




Hình 2.7: Confusion matrix test của Softmax và MLP: mỗi ô ghi số ảnh và tỷ lệ theo lớp thật.



Hình 2.8: Confusion matrix test của CNN-A và CNN-B, cùng thang 0–100%.

Bảng 2.3: Cặp nhầm nhiều nhất trong E1; mỗi lớp test có 1.000 ảnh.

Model	Thật → dự đoán	Số ảnh	% lớp thật
Softmax	Shirt → T-shirt/top	154	15,4
MLP	T-shirt/top → Shirt	124	12,4
CNN-A	T-shirt/top → Shirt	137	13,7
CNN-B	Shirt → T-shirt/top	103	10,3



Hình 2.9: Ảnh dự đoán sai của E1; cùng cột là cùng lớp thật, mỗi hàng là một model.

Nhằm lẫn tập trung ở nhóm áo có silhouette gần nhau, trong khi giày/túi có hình dáng khác biệt dễ tách hơn trên ma trận. CNN giảm nhiều lỗi nhưng không loại bỏ sự mơ hồ giữa Shirt và T-shirt/top. Ảnh gallery là lỗi đầu tiên mỗi lớp/model, dùng minh họa; tần suất phải lấy từ toàn bộ confusion matrix.


2.5 Nhận xét và giới hạn

Softmax nhẹ và nhanh, nhưng ranh giới tuyến tính hạn chế biểu diễn. MLP tăng chất lượng với phi tuyến, song flatten không áp đặt locality và đòi hỏi nhiều FC. CNN phù hợp ảnh nhỏ nhờ receptive field và chia sẻ trọng số; CNN-B cho hiệu quả tham số tốt trong thiết lập này. Kết luận dựa trên một seed và một dataset cân bằng; chưa đo độ biến thiên hay kiểm soát matched capacity.

3. E2: Multi-head self-attention và tokenization

3.1 Mục tiêu và biểu diễn token


E2 hiện thực MSA bằng Linear, reshape, matmul, softmax và concat; bản đối chiếu dùng `nn.MultiheadAttention`. Encoder và classifier giống nhau giữa hai bản. Ba tokenizer cùng dùng split/normalization Fashion-MNIST ở Chương 1; không sử dụng checkpoint E1.




Hình 3.1: Ba tokenizer E2; CNN-stem có hai Conv kernel 3, stride 1, padding 1, bias, ReLU và MaxPool 2 sau mỗi Conv. Rows không có Conv; patch lấy trực tiếp pixel.

Rows có $N = 28$, $F = 28$; patch/CNN-stem có $N = 49$, $F = 16$. CNN-stem thêm 2.480 tham số học so với patch cùng chiều feature, nên so sánh tokenizer thay đổi cả inductive bias và capacity.

3.2 Kiến trúc encoder và MSA



Hình 3.2: Classifier E2: một FC embedding, hai encoder block và một FC head; không CLS token.



Hình 3.3: Một pre-norm encoder block: hai projection MSA và hai FC trong FFN, tổng bốn ánh xạ Linear/block. Đường ngoài là residual.

Với $D = 64, H = 4, d_h = 16$, QKV reshape thành $B \times H \times N \times d_h$:

$$A_h = \text{softmax}_{\text{key}} \left(Q_h K_h^\top / \sqrt{d_h} \right), \quad Y = \text{Concat}_{h=1}^H (A_h V_h) W_O + b_O. \quad (3.1)$$

Attention dropout 0,1 áp dụng lên A_h trước khi nhân V_h ; output dropout nằm trên nhánh residual. Mỗi block có FFN $64 \rightarrow 128 \rightarrow 64$, GELU, dropout 0,1. Toàn classifier có 10 ánh xạ Linear theo cách đếm QKV gộp là một Linear: 1 embedding + 2×4 trong encoder + 1 head. CNN-stem bổ sung 2 Conv.

Cập manual/PyTorch copy toàn bộ weights khởi tạo, gồm tokenizer, position, FFN và head. Kiểm tra CUDA float64 với dropout tắt đạt sai số tối đa $1,665 \times 10^{-16}$ ở forward và input/weight/bias gradients. Parity xác nhận phép toán; không đảm bảo dropout/RNG và đường tối ưu của hai lần training giống nhau.

3.3 Thiết lập huấn luyện và tám cấu hình

AdamW LR 10^{-3} , WD 10^{-4} , batch 128, tối đa 100 epoch; thí nghiệm dùng patience 10, min-delta 10^{-4} và checkpoint min validation loss. Sáu run cơ sở là manual/PyTorch $\times$ rows/patch/stem, H=4. Tokenizer manual tốt nhất theo validation là CNN-stem, được dùng thêm H=2 và H=8; H=4 tái dùng run đã train. D giữ 64 nên số tham số không thay đổi theo H.

Ký hiệu bảng: M=manual, T=PyTorch; R=rows, P=patch 4, C=CNN-stem; chữ số cuối là H. Ví dụ M-C4 là manual CNN-stem, 4 head.



3.4 Kết quả và so sánh theo đề

Bảng 3.1: Metric E2; mọi model đánh giá đủ 10.000 ảnh test, F1 là macro-F1.

Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
M-R4	91,61	89,97	0,8988	89,51	0,8941	0,3050
M-P4	91,89	89,17	0,8916	88,85	0,8882	0,3302
M-C4	92,18	90,65	0,9063	90,50	0,9048	0,2717
T-R4	91,75	89,90	0,8983	89,22	0,8913	0,3054
T-P4	90,90	88,47	0,8844	88,67	0,8865	0,3266
T-C4	92,79	90,68	0,9068	90,78	0,9078	0,2695
M-C2	92,84	90,50	0,9056	90,74	0,9079	0,2789
M-C8	92,13	90,35	0,9031	90,23	0,9020	0,2752

Bảng 3.2: Capacity và chi phí của tám cấu hình E2.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
M-R4	71,370	26/16	161,65	6,217	44
M-P4	71,946	40/30	293,87	7,347	69
M-C4	74,426	30/20	194,62	6,487	78
T-R4	71,370	26/16	159,69	6,142	47
T-P4	71,946	34/24	234,66	6,902	79
T-C4	74,426	34/24	232,01	6,824	89
M-C2	74,426	41/31	269,20	6,566	70
M-C8	74,426	28/18	188,28	6,724	98


**Hình 3.4:** Tổng quan accuracy validation, capacity và chi phí E2.**Hình 3.5:** So sánh manual/PyTorch cùng tokenizer: accuracy, params và giây/epoch.

Bảng 3.3: So sánh manual/PyTorch ở H=4, cùng weights khởi tạo.

Tokenizer	M val	T val	M–T (điểm%)	M/T s/epoch
Rows	89,97	89,90	+0,07	6,217 / 6,142
Patch	89,17	88,47	+0,70	7,347 / 6,902
CNN-stem	90,65	90,68	–0,03	6,487 / 6,824


Sai số đối chiếu phép toán rất nhỏ không có nghĩa metric training phải bằng nhau: dropout, thứ tự sử dụng số ngẫu nhiên và AMP làm đường tối ưu khác. Chênh lệch 0,07 hoặc 0,03 điểm ở rows/stem nhỏ; chênh lệch 0,70 ở patch cũng chỉ quan sát ở một seed, chưa kết luận implementation nào tốt hơn.

CNN-stem đạt validation cao nhất trong cả hai implementation (90,65% manual, 90,68% PyTorch). So với patch, cải thiện tương ứng 1,48 và 2,21 điểm; so với rows là 0,68 và 0,78 điểm. Các convolution học đặc trưng cục bộ trước attention là giải thích kiến trúc hợp lý, nhưng chưa cô lập tác động vì capacity và token features cũng thay đổi. Rows $N = 28$ có attention matrix 784 phần tử/head; patch/stem $N = 49$ có 2.401, gấp 3,06 lần. Chi phí toàn mạng còn gồm projections/FFN/CNN, nên không suy tốc độ chỉ từ N^2 .


**Hình 3.6:** Ablation H=2/4/8 trên manual CNN-stem, giữ D=64.

H=2/4/8 đạt val 90,50/90,65/90,35%; test 90,74/90,50/90,23%. H=4 tốt nhất theo validation nhưng H=2 cao hơn trên test; giữ quy tắc chọn H=4 thay vì đổi quyết định sau test. Tăng head không tăng tham số projection, mà chia feature mỗi head thành 32/16/8 chiều; accuracy không tăng đơn điệu.

3.5 Learning curves, attention và lỗi




Hình 3.7: Loss theo epoch, nhóm theo tokenizer; train nét đứt, validation nét liền.



Hình 3.8: Accuracy theo epoch của các cấu hình E2.

Các train–val gap khoảng 1,53–2,72 điểm phần trăm. Đọc curves cùng best epoch cho thấy cần dừng khi validation chững, thay vì chọn loss train thấp nhất.




Hình 3.9: Attention của manual CNN-stem H=4 trên hai ảnh validation cố định; trung bình head, block cuối, gộp 7 nhóm query/key, tổng mỗi hàng 100%.

Map thể hiện phân bố trọng số giữa các nhóm token sau CNN-stem, không phải saliency trực tiếp ở pixel gốc. Việc trung bình head và gộp 7 nhóm làm mất chi tiết từng head/token. Các ô sáng cho biết trọng số kết hợp lớn, không tự chứng minh token là nguyên nhân của quyết định phân loại.

Bảng 3.4: Nhầm lẫn lớn nhất của ba tokenizer manual H=4.

Model	Thật → dự đoán	Số ảnh	% lớp thật
M-R4	Shirt → T-shirt/top	139	13,9
M-P4	Coat → Pullover	127	12,7
M-C4	Shirt → T-shirt/top	94	9,4




Hình 3.10: Gallery lỗi của các mô hình đại diện E2 chọn bằng validation.

Ảnh lỗi và ma trận đầy đủ ở Phụ lục cho thấy nhóm áo vẫn khó tách. Patch hay nhầm Coat/Pullover; stem giảm cặp Shirt/T-shirt/top trong bản manual, song không xóa lỗi. E2 sử dụng hai cách cài đặt và ba cách tạo token; giới hạn là encoder nhỏ, một seed, chưa kiểm soát capacity giữa tokenizers và attention visualization chỉ mang tính mô tả.


4. E3: LSTM và GRU trên chuỗi ảnh

4.1 Biểu diễn ảnh thành chuỗi

E3 đọc ảnh như một chuỗi các vector và phân loại bằng hidden state cuối. Rows quét từ trên xuống, mỗi token là 28 pixel của một hàng. Columns quét từ trái sang phải, mỗi token là 28 pixel của một cột. Patch 4×4 không overlap, quét raster trái–phải rồi trên–dưới, tạo 49 bước, mỗi bước 16 pixel. Không thêm CNN/token embedding trước recurrent.



Hình 4.1: Cùng một ảnh validation được chuyển thành rows, columns và patch: thứ tự quét cùng ma trận timestep–feature.



Rows/columns: $T = 28, F = 28$; patch: $T = 49, F = 16$.

Một bộ trọng số được dùng chung ở mọi bước.

Hình 4.2: Classifier recurrent E3: không Conv, một recurrent layer unroll T lần và một FC head. Trạng thái khởi tạo bằng 0, chỉ dùng hidden cuối.


4.2 Cell LSTM/GRU tự hiện thực

Với $H = 128$, LSTM có input projection $F \rightarrow 4H = 512$, hidden projection $128 \rightarrow 512$, hai bias và bốn nhóm gate:

$$[i_t, f_t, g_t, o_t] = [\sigma, \sigma, \tanh, \sigma](W_{ih}x_t + b_{ih} + W_{hh}h_{t-1} + b_{hh}), \quad (4.1)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t, \quad h_t = o_t \odot \tanh c_t. \quad (4.2)$$

Đường trên truyền bộ nhớ; các nút tròn là phép toán theo phân tử.




Hình 4.3: LSTM cell: hai projection dùng chung ở mọi bước; không tạo thêm bộ tham số cho mỗi timestep.

GRU có hai projection $F \rightarrow 384$ và $128 \rightarrow 384$ cho reset, update và candidate:

$$r_t = \sigma(x_r + h_r), \quad z_t = \sigma(x_z + h_z), \quad (4.3)$$

$$n_t = \tanh(x_n + r_t \odot h_n), \quad h_t = (1 - z_t) \odot n_t + z_t \odot h_{t-1}. \quad (4.4)$$

x . và h . đã gồm bias. Reset nhân sau projection hidden, kể cả hidden bias, theo convention PyTorch.



Hình 4.4: GRU cell: hai projection cho ba nhóm gate, chỉ duy trì hidden state.

Kể cả head, số tham số là $4H(F+H+2)+10H+10$ cho LSTM và $3H(F+H+2)+10H+10$ cho GRU. Cùng F , GRU ít tham số hơn vì dùng ba nhóm thay cho bốn. Kiểm tra copy weight sang `nn.LSTMCell/nn.GRUCell` trên CUDA float64 qua 4 bước, so forward và gradients của state/input/tất cả params, đạt max error 5, 551×10^{-17} (LSTM) và $3,331 \times 10^{-16}$ (GRU).

4.3 Baseline và thiết lập huấn luyện

Sáu recurrent run là LSTM/GRU $\times$ rows/columns/patch. MLP và CNN-B có đúng kiến trúc E1, tự định nghĩa và huấn luyện độc lập trong E3 trên cùng split; không đọc trọng số E1. Baseline MLP có 3 FC, CNN-B có 3 Conv và 1 FC như sơ đồ E1.

AdamW LR 10^{-3} , WD 10^{-4} , batch 128, tối đa 100 epoch. Thí nghiệm dùng patience 10 và min-delta 10^{-4} , checkpoint min val loss. Recurrent clip gradient norm 1; baseline giữ protocol tương ứng E1, không clipping. Vòng lặp recurrent unroll từng token bằng Python/PyTorch, không dùng fused `nn.LSTM/nn.GRU` trong train; điều này cần ghi khi diễn giải tốc độ.


4.4 Kết quả, representation và chi phí

Bảng 4.1: Metric của sáu recurrent model và hai baseline E3, F1 là macro-F1.


Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
LSTM Rows	91,95	89,95	0,8990	89,70	0,8965	0,2940
LSTM Columns	92,79	88,72	0,8881	88,81	0,8885	0,3260
LSTM Patch	92,40	88,62	0,8861	88,22	0,8823	0,3414
GRU Rows	93,95	90,47	0,9044	90,06	0,9001	0,2882
GRU Columns	93,16	89,83	0,8983	89,51	0,8951	0,3137
GRU Patch	92,36	89,05	0,8900	88,44	0,8841	0,3352
MLP	91,58	89,47	0,8951	89,45	0,8948	0,3142
CNN-B	95,82	91,92	0,9190	91,97	0,9193	0,2320

Bảng 4.2: Số tham số, epoch và chi phí E3.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
LSTM Rows	82,186	24/14	410,70	17,113	27
LSTM Columns	82,186	29/19	452,70	15,610	27
LSTM Patch	76,042	34/24	853,58	25,105	34
GRU Rows	61,962	26/20	393,42	15,132	28
GRU Columns	61,962	29/19	407,87	14,064	28
GRU Patch	57,354	30/20	696,60	23,220	35
MLP	235,146	26/16	49,98	1,922	23
CNN-B	94,186	40/30	100,38	2,509	57




Hình 4.5: Accuracy, capacity và thời gian E3 trên cùng Fashion-MNIST.



Hình 4.6: LSTM vs GRU với cùng representation.

Rows tốt nhất trong từng họ kiến trúc: LSTM val 89,95%, test 89,70%; GRU val 90,47%, test 90,06%. Với columns, test giảm còn 88,81%/89,51%; patch giảm còn 88,22%/88,44%. Rows/columns cùng T , F và capacity, nên thay đổi hướng quét làm thay đổi thông tin ở mỗi bước. Patch đổi cả thông tin, độ dài 49 và input 16, nên không cô lập riêng tác động thứ tự.


GRU cao hơn LSTM trên test ở cả ba representation lần lượt 0,36/0,70/0,22 điểm phần trăm, dùng ít tham số và ít giây/epoch hơn. Với rows: 61.962 so với 82.186 params; 15,132 so với 17,113 s/epoch. Patch dài 49 bước làm thời gian/epoch lớn hơn rows, dù ít tham số hơn. Đây là chi phí của implementation vòng lặp unroll bằng Python/PyTorch, không khẳng định mọi GRU/LSTM kernel đều có cùng tỷ lệ tốc độ.




Hình 4.7: So sánh recurrent rows chọn bằng validation với MLP và CNN-B train trong E3.

GRU rows test 90,06% cao hơn MLP 89,45% khoảng 0,61 điểm, nhưng thấp hơn CNN-B 91,97% khoảng 1,91 điểm. CNN-B chỉ 2,509 s/epoch so với GRU 15,132 s và LSTM 17,113 s. Locality/chia sẻ Conv cùng khả năng tính song song phù hợp ảnh tĩnh trong thí nghiệm này. Hidden state có thể tích lũy thông tin qua toàn chuỗi, nhưng accuracy không chứng minh model đã học phụ thuộc xa; chưa có ablation độ dài/che timestep để kiểm tra giả thuyết đó.

4.5 Learning curves và lỗi



Hình 4.8: Loss E3 theo representation; nét đứt train, nét liền validation.



Hình 4.9: Accuracy E3 theo representation.

LSTM columns có train 92,79% so với val 88,72% tại best; GRU rows có train 93,95% và val 90,47%. Khoảng cách cùng curves cho thấy validation không theo kịp train hoàn toàn; checkpoint được chọn giữ chất lượng trước các epoch làm val loss xấu hơn.

Bảng 4.3: Cặp nhầm lẫn lớn nhất của recurrent đại diện và baseline E3.

Model	Thật → dự đoán	Số ảnh	% lớp thật
LSTM Rows	Shirt → T-shirt/top	133	13,3
GRU Rows	Shirt → T-shirt/top	125	12,5
MLP	T-shirt/top → Shirt	124	12,4
CNN-B	Shirt → T-shirt/top	103	10,3



Hình 4.10: Gallery lỗi recurrent và baseline E3; ma trận của mọi run nằm ở Phụ lục.

Các mô hình khác họ vẫn nhầm nhóm áo tương tự, cho thấy representation chuỗi không giải quyết hết mơ hồ hình dáng. CNN-B giảm số Shirt thành T-shirt/top so với hai recurrent rows; cần xem cả recall từng lớp và chiều nhầm ngược trên ma trận, không dùng riêng một cặp để đánh giá toàn model.

Nhận xét và giới hạn. Cả LSTM và GRU hoạt động với ba biểu diễn, có parity và baseline độc lập. GRU rows là recurrent được chọn bằng validation; CNN-B vẫn là lựa chọn hiệu quả hơn về độ chính xác và thời gian ở bài toán ảnh tĩnh này. Một seed, gradient clip chỉ cho recurrent và unroll không fused là giới hạn khi suy rộng kết luận.

5. A1: CNN và Transformer trên GTSRB

5.1 Dữ liệu, phân bố lớp và cách chia tập

GTSRB [8, 9] là bộ ảnh 43 loại biển giao thông, khác Fashion-MNIST/CIFAR-10 và phù hợp ràng buộc A1 về nhiều lớp, quy mô hàng chục nghìn ảnh, biến đổi góc nhìn/ánh sáng và lớp gần nhau. Nguồn là archive tác giả trên ERDA [10], gồm 39.209 ảnh train nguồn và 12.630 test. Nhân ClassId là số nguyên 0–42; filename train chứa class/track/frame, metadata local chứa path, kích thước, nhãn và SHA256. PPM được chuyển thành PNG lossless với kiểm tra pixel; ảnh không được phân phối qua Git.

Trang metadata archive chưa nêu mã giấy phép SPDX; báo cáo ghi đúng nguồn, tác giả và điều kiện/README nguồn, không tự gán MIT/CC cho dataset. Việc dùng học tập/nghiên cứu và trích dẫn được mô tả trong hồ sơ dữ liệu local; thông tin giấy phép chuẩn hóa chưa được xác nhận từ metadata công khai.

Train/validation chia theo nhóm `class_id + physical_sign_track`, seed 42, giữ khoảng 20% track mỗi lớp cho validation. Cách chia này hạn chế frame cùng biển vật lý rơi vào hai tập. Số ảnh thực tế:


Bảng 5.1: Split GTSRB sử dụng toàn bộ dữ liệu.

Tập	Ảnh	Lớp	Vai trò
Train	31.380	43	Huấn luyện
Validation	7.829	43	Checkpoint, freeze/augmentation protocol
Official-source test	12.630	43	Đánh giá cuối
Test không trùng SHA256	12.622	43	Phân tích độ nhạy bổ sung

Fingerprint:

```
c1c1759f478eeeeeac0faddf424717574
f6f1895f6a5511ed77964c34eb2c7ac
```

Output xác nhận không có trùng SHA256 train–val/val–test, nhưng có 8 ảnh test lớp Stop (ID 14) trùng train. Giữ full test nguồn để đối chiếu và báo thêm test không trùng; full test có giới hạn độc lập, không coi là hoàn toàn sạch.



Hình 5.1: Phân bố 43 lớp trên các split và kích thước ảnh train gốc.



Hình 5.2: Một ảnh train đại diện cho mỗi lớp GTSRB; ID dùng để tra ma trận nhầm lẫn.


Train mất cân bằng: lớp Speed limit 50 có 1.800 ảnh, trong khi Speed limit 20, Pedestrians và nhiều lớp hiếm có 180 ảnh. Validation lớp Turn right ahead có 149 ảnh, phản ánh split track không ép tỷ lệ ảnh chính xác 20%. Resize không làm tăng thông tin ảnh nhỏ, vì vậy mờ/thiếu sáng vẫn là khó khăn thực tế.

5.2 DataLoader, augmentation và kiến trúc


Ảnh RGB được resize toàn ảnh 224×224 , không center-crop, rồi chuẩn hóa ImageNet mean (0,485; 0,456; 0,406), std (0,229; 0,224; 0,225) cho mọi regime. Augmentation train gồm RandomAffine góc trong $\pm 10^\circ$, translate tối đa 5% theo mỗi trục, ColorJitter brightness/contrast 0,2 và saturation 0,1. Không flip vì có thể đảo ý nghĩa biển; val/test chỉ resize và normalize. DataLoader shuffle train, seed cố định, workers 0, không bỏ batch cuối. Notebook đọc ảnh và kiểm tra SHA256 trong Dataset; thời gian train+val vì vậy gồm cả xử lý dữ liệu và kiểm tra integrity của cài đặt trong notebook.

ResNet-50 dùng Bottleneck 3/4/6/3, expansion 4, stride tại Conv 3×3 , khớp convention torchvision [4]. DeiT-Small/16 non-distilled dùng patch 16, embedding 384, depth 12, 6 head, MLP ratio 4 và LayerNorm eps 10^{-6} [11]. Cả hai tự định nghĩa trong notebook, nạp pre-trained ImageNet backbone tương thích rồi thay head 43 lớp. ResNet dùng ImageNet-1K V1 của

torchvision, DeiT dùng checkpoint ImageNet-1K chính thức non-distilled. DeiT ở đây không dùng distillation token/teacher hoặc loss distillation.



Hình 5.3: A1 ResNet-50: backbone thể hiện bằng một khối, chỉ thay một FC 43 lớp. Head có 88.107 tham số; tổng 23.596.139.



Hình 5.4: A1 DeiT-Small/16: backbone gom khối, thể hiện token và kích thước FFN; head 16.555 tham số, tổng 21.682.219.

Kiểm tra forward ResNet cùng weights khớp torchvision; attention DeiT khớp forward/input/QKV-output gradients của PyTorch float64. Head được kiểm tra thay đổi sau optimizer step, còn frozen parameters/BN buffers giữ nguyên.

5.3 Các cấu hình và thiết lập huấn luyện

Ký hiệu bảng: R=ResNet-50, D=DeiT-Small/16; S=scratch, H=head-only, P=partial, F=full pre-trained. Số sau dấu/ là seed.

Bảng 5.2: Các mức freeze và số tham số được tối ưu.

Họ	Chế độ	Thành phần trainable	Số tham số	% tổng
ResNet	Scratch/full	Toàn bộ mạng	23.596.139	100,00
ResNet	Head-only	FC 43	88.107	0,37
ResNet	Partial	layer4 và FC 43	15.052.843	63,79
DeiT	Scratch/full	Toàn bộ mạng	21.682.219	100,00
DeiT	Head-only	FC 43	16.555	0,08
DeiT	Partial	2 block cuối, norm, head	3.566.251	16,45

Partial không tương đương về tỷ lệ trainable giữa hai họ kiến trúc, nên đây là so sánh hai chiến lược thực tế, không phải ablation matched capacity. Frozen BN giữ eval mode và running buffers bất biến.

AdamW WD 0,01; scratch LR 3×10^{-4} cho toàn mạng, tối đa 40 epoch; pretrained backbone LR 10^{-4} và head 10^{-3} , tối đa 25 epoch. Warmup 3 epoch rồi cosine; clip gradient norm 1, AMP train, FP32 eval, patience 4/min-delta 10^{-4} . Batch 128 cố định cho train/val/test, accumulation 1, effective batch 128; mỗi epoch 246 batch train, giữ batch cuối 20 ảnh. Best checkpoint min val loss; regime đại diện chọn theo val accuracy/F1/loss.

Hai họ kiến trúc $\times 4$ regime tạo 8 run chính cùng seed 42/augmentation. Sau khi chọn full mode cho mỗi họ kiến trúc bằng validation, thêm 1 no-augmentation seed 42 và 2 repeat seed 43/44/họ kiến trúc, tổng 14 run. Các seed repeats đổi RNG train nhưng giữ seed chia tập 42. Test chỉ đánh giá sau khi khóa mọi lựa chọn.


5.4 Kết quả chính: CNN vs Transformer và pretraining

Bảng 5.3: Tám cấu hình chính A1; mọi F1 là macro-F1.

Run	Train (%)	Val (%)	Val F1	Test (%)	Test F1
R-S/42	98,51	98,26	0,9688	96,33	0,9447
R-H/42	91,12	69,22	0,5952	70,35	0,6143
R-P/42	99,76	97,89	0,9720	96,05	0,9438
R-F/42	99,94	99,80	0,9981	98,37	0,9743
D-S/42	99,98	98,38	0,9752	96,14	0,9350
D-H/42	91,34	71,31	0,6066	69,73	0,6125
D-P/42	98,64	89,32	0,8360	87,85	0,8063
D-F/42	99,79	99,39	0,9863	98,92	0,9790

Bảng 5.4: Capacity, số epoch và peak allocated GPU memory A1.

Run	Total params	Trainable	%	Epoch/best	s/epoch	Peak MiB
R-S/42	23,596,139	23,596,139	100,00	9/5	259,408	5830
R-H/42	23,596,139	88,107	0,37	24/20	185,367	1567
R-P/42	23,596,139	15,052,843	63,79	13/9	194,699	1681
R-F/42	23,596,139	23,596,139	100,00	11/7	255,018	5823
D-S/42	21,682,219	21,682,219	100,00	39/35	265,317	6635
D-H/42	21,682,219	16,555	0,08	25/21	187,817	636
D-P/42	21,682,219	3,566,251	16,45	8/4	197,725	1374
D-F/42	21,682,219	21,682,219	100,00	10/6	251,002	6632

**Hình 5.5:** Accuracy validation/test, trainable params và giây/epoch của tám cấu hình chính.

Full pretrained được chọn bằng validation ở cả hai họ kiến trúc: ResNet val 99,80%, test 98,37%; DeiT val 99,39%, test 98,92%. DeiT test cao hơn 0,55 điểm, trong khi ResNet val cao hơn 0,41 điểm; không dùng test để đảo lựa chọn regime.

Pretraining cải thiện full so với scratch: ResNet test từ 96,33% lên 98,37% (+2,04 điểm), DeiT từ 96,14% lên 98,92% (+2,78 điểm). DeiT scratch cần 39 epoch/10.347,38 s; full cần 10 epoch/2.510,02 s. ResNet scratch 9 epoch/2.334,67 s còn full 11 epoch/2.805,20 s: pretraining cải thiện chất lượng nhưng không luôn giảm thời gian tổng, vì early stopping và learning-rate protocol khác nhau. DeiT vẫn học scratch đến 96,14%; không kết luận Transformer bắt buộc pretrain để chạy được.

Cùng scratch, test ResNet cao hơn DeiT 0,19 điểm; cùng head-only, ResNet cao hơn 0,62 điểm. Cùng partial, ResNet đạt 96,05% so với 87,85% của DeiT, nhưng phần mạng được mở khác nhau nhiều (63,79% so với 16,45% params). Không quy chênh lệch này chỉ cho CNN/Transformer. Full mode cho thấy DeiT có lợi về độ chính xác trong thí nghiệm, đổi lại chi phí suy luận/bộ nhớ.

5.5 Freeze, chi phí và đường cong


Head-only val 69,22% / 71,31%, test 70,35% / 69,73%, thấp xa full; train tại best vẫn 91,12% / 91,34%. Chỉ học head chưa thích nghi tốt backbone với split GTSRB này. Freeze có lợi nếu cần tiết kiệm VRAM, ít weights phải tối ưu và lượt train ngắn theo mỗi epoch; ở đây không phải lựa chọn tốt nếu ưu tiên accuracy. Head-only kéo dài 24/25 epoch nên thời gian tổng còn lớn hơn full 11/10 epoch.

Partial ResNet đạt gần scratch với peak 1.681 MiB; full đạt accuracy cao hơn với 5.823 MiB. Partial DeiT peak 1.374 MiB, full 6.632 MiB; head-only chỉ 636 MiB nhưng accuracy thấp. Các peak là allocated PyTorch, không phải reserved hoặc tổng VRAM trong Task Manager.


Bảng 5.5: Thời gian train+val và inference FP32; CUDA Events batch 32, tách DataLoader.

Run	Train+val (s)	GPU ms/batch	Images/s	Test (s)
R-S/42	2334,67	77,06	415,3	51,30
R-H/42	4448,81	77,54	412,7	45,32
R-P/42	2531,09	76,63	417,6	44,35
R-F/42	2805,20	77,09	415,1	44,70
D-S/42	10347,38	138,44	231,1	64,70
D-H/42	4695,43	139,91	228,7	64,56
D-P/42	1581,80	139,99	228,6	65,06
D-F/42	2510,02	139,22	229,9	64,99

ResNet full đạt 415,1 ảnh/s và 77,09 ms/batch 32; DeiT 229,9 ảnh/s, 139,22 ms/batch 32. Throughput ResNet khoảng 1,81 lần DeiT trong phép đo này. Test end-to-end dùng batch 128 và gồm DataLoader/H2D/evaluation, nên không đồng nhất với benchmark GPU-only batch 32.



Hình 5.6: Loss của hai họ kiến trúc theo bốn regime; train nét đứt, validation nét liền.



Hình 5.7: Accuracy theo epoch A1; mỗi panel một họ kiến trúc.

Full pretrained nhanh chóng đạt val cao; head-only có gap train–val lớn và val loss gần 1. DeiT scratch có quá trình học dài hơn ResNet scratch. Training accuracy dùng augmentation/train mode, validation dùng eval mode; curves cần được đọc với sự khác biệt này và epoch của checkpoint.

5.6 Augmentation và độ ổn định qua seed

Bảng 5.6: Sáu thực nghiệm bổ sung trên full pretrained; cấu hình đã chọn trước test.

Run	Val (%)	Val F1	Test (%)	Test F1	Train+val (s)
R-F/42 no-aug	98,85	0,9811	97,20	0,9545	941,91
R-F/43	99,92	0,9991	98,76	0,9834	1912,95
R-F/44	99,28	0,9881	98,19	0,9630	1717,14
D-F/42 no-aug	99,46	0,9896	99,22	0,9896	3547,77
D-F/43	99,85	0,9963	99,29	0,9914	6838,98
D-F/44	99,50	0,9908	98,64	0,9781	2510,36


Bảng 5.7: Augmentation ablation, cùng full mode và seed 42.

Họ	Aug val	No-aug val	Aug test	No-aug test
ResNet	99,80	98,85	98,37	97,20
DeiT	99,39	99,46	98,92	99,22

Augmentation cải thiện ResNet val 0,95 và test 1,17 điểm; DeiT val thay đổi $-0,08$ điểm theo số liệu chưa làm tròn, test $-0,30$ điểm. Không khẳng định augmentation luôn tốt: hiệu quả phụ thuộc họ kiến trúc và biến đổi đã chọn, ablation này chỉ có seed 42.

Bảng 5.8: Full pretrained, 3 seed 42/43/44, giữ split 42; độ lệch chuẩn mẫu (ddof=1), không phải khoảng tin cậy.


Họ	Val acc(%)	Test acc(%)	Val macro-F1	Test macro-F1
ResNet	99,67 ± 0,34	98,44 ± 0,29	0,9951 ± 0,0061	0,9736 ± 0,0102
DeiT	99,58 ± 0,24	98,95 ± 0,33	0,9912 ± 0,0050	0,9828 ± 0,0074



Hình 5.8: Augmentation và ba seed của full pretrained; đồ thị dựng từ bảng output, trực tung thu hẹp 97,5–100,6% để đọc chênh lệch; error bar là std mẫu.

DeiT có test trung bình cao hơn 0,51 điểm trong ba seed. Chỉ $n = 3$ trên cùng split nên chưa là bằng chứng thống kê mạnh hoặc khả năng tổng quát qua split/dataset; không chọn seed 43 theo test 99,29% làm kết quả đại diện.

5.7 Confusion matrix, lỗi và trùng ảnh



Hình 5.9: Trích 10 lớp liên quan nhiều ảnh sai của mỗi full pretrained seed 42; mẫu số vẫn là toàn bộ lớp thật trong 43 lớp.

Submatrix chỉ giữ 10 lớp nên tổng hàng hiển thị có thể nhỏ hơn 100%; không chuẩn hóa lại trên 10 lớp. Full 43×43 của cả hai model có trong notebook A1; Phụ lục liệt kê precision/recall/F1 của toàn bộ 43 lớp để tra cứu.

ResNet full nhằm 30/60 Pedestrians (ID 27) thành Road work (ID 25), recall Pedestrians 0,500, F1 0,667. DeiT full nhằm 30/60 Speed limit 20 (ID 0) thành Speed limit 120 (ID 8), recall lớp 0,500, F1 0,667. DeiT Pedestrians recall 0,883, F1 0,938, trong khi ResNet Speed 20 recall/F1 đều 1,000. Accuracy tổng cao không đảm bảo chất lượng mọi lớp hiếm.

Bảng 5.9: Một số lớp khó trong hai full model seed 42; test support và recall/F1.

Lớp	Support	Res recall	Res F1	DeiT recall	DeiT F1
Speed 20	60	1,000	1,000	0,500	0,667
Pedestrians	60	0,500	0,667	0,883	0,938
Bumpy road	120	0,800	0,881	0,950	0,970
Roundabout	90	0,878	0,919	0,844	0,916
Ice/snow	150	0,940	0,913	0,960	0,938



Hình 5.10: Các ảnh sai của hai full model seed 42; hàng trên ResNet, hàng dưới DeiT, ghi cả nhãn thật/dự đoán.

Ảnh mẫu cho thấy bóng che, mờ, thiếu sáng và ký hiệu có outline gần nhau. Đây là các yếu tố nhìn thấy trong ví dụ, chưa là bằng chứng nhân quả hoặc tỷ lệ lỗi do từng điều kiện. Nhiều ảnh có thể cùng track nên số ảnh sai không đồng nghĩa số biến vật lý độc lập.

Trên 12.622 test không trùng, accuracy 8 run chính thay đổi từ $-0,001$ đến $-0,019$ điểm phần trăm; macro-F1 không đổi khi làm tròn 4 chữ số. Hai full model lần lượt 98,37% và 98,91%, so với 98,37%/98,92% full test. Ảnh trùng ảnh hưởng nhỏ đến metric tổng ở lần chạy này nhưng vẫn là giới hạn độc lập; SHA256 chỉ phát hiện trùng byte, không loại mọi ảnh gần giống.

5.8 Kết luận A1 và giới hạn

Full pretrained được chọn bằng validation ở cả hai họ. DeiT có test accuracy cao hơn, ResNet có throughput tốt hơn trong thiết lập này.

Giới hạn gồm dữ liệu mất cân bằng, 8 test trùng train, nhiều frame cùng track, chỉ 3 seed cho full và 1 seed cho các regime khác; partial không matched capacity, ngân sách 40/25 epoch và learning rate khác scratch/pretrained. Các kết quả chỉ áp dụng cho thiết lập và dữ liệu đã khảo sát.

6. A2: RetinaNet và Faster R-CNN trên VOC2012

6.1 Bài toán và dữ liệu


Khác với phân loại ở A1, mỗi ảnh ở A2 có thể chứa nhiều đối tượng thuộc nhiều lớp. Mạng phải đồng thời dự đoán nhãn, bounding box và độ tin cậy. Thí nghiệm so sánh RetinaNet một giai đoạn với Faster R-CNN hai giai đoạn. Cả hai dùng ResNet-50 pretrained ImageNet và FPN; sự khác biệt nằm ở các mức pyramid, anchors, cách chọn mẫu và detection head.

PASCAL VOC2012 [2, 3] có 20 lớp và 11.540 ảnh trainval có nhãn. Toàn bộ số ảnh này được chia 80/10/10 bằng seed 42; các tập không giao nhau theo định danh ảnh. Test trong báo cáo là *holdout nội bộ*, không phải test chính thức VOC2012; không so trực tiếp với leaderboard của cuộc thi. Manifest tham chiếu JPEG/XML có sẵn, không nhân bản ảnh. Việc sử dụng tuân theo VOC Database Rights; quyền đối với từng ảnh thuộc về tác giả/chủ sở hữu gốc. Nguồn tài và định dạng nhãn được ghi trong README dữ liệu.

Bảng 6.1: Số ảnh và annotation VOC2012. Một bbox có thể vừa difficult vừa truncated.

Tập	Ảnh	BBox thường	Difficult	Truncated
train	9.232	21.975	3.267	13.182
val	1.154	2.788	468	1.647
test	1.154	2.687	376	1.561


Nhãn XML gồm tên lớp, bndbox, difficult và truncated. Tọa độ VOC đánh số từ 1, bao gồm cả hai đầu, được chuyển thành khoảng nửa mở đánh số từ 0: $[x_{\min} - 1, y_{\min} - 1, x_{\max}, y_{\max}]$. Dataset trả về tensor RGB và danh sách bbox, class ID 1–20 cùng các cờ annotation. RetinaNet ánh xạ nhãn sang 0–19 khi tính loss, rồi chuyển về 1–20 khi suy luận. Faster R-CNN dành ID 0 cho background.



Hình 6.1: Phân bố bbox thường của 20 lớp trong train, validation và test; mỗi panel dùng trục riêng.

Person chiếm 6.802/21.975 bbox thường ở train, khoảng 30,95%; sofa chỉ có 447 bbox. Báo cáo dùng cả AP từng lớp và macro-F1 để nhìn ảnh hưởng của mất cân bằng. Tổng theo lớp là

số đối tượng, không phải số ảnh.




Hình 6.2: Kích thước, tỷ lệ cạnh bbox và chiều rộng/cao ảnh gốc.

BBox đa dạng về scale và tỷ lệ cạnh. FPN cung cấp nhiều stride, còn ba aspect ratio bao phủ vật thể cao, vuông và rộng.

6.2 Tiền xử lý và DataLoader

Resize giữ tỷ lệ, cạnh ngắn 600 px, cạnh dài tối đa 1.000 px. Phóng ảnh không bổ sung chi tiết đã mất ở ảnh gốc. Tensor nằm trong $[0, 1]$; model chuẩn hóa ImageNet một lần. Batch được pad đến bội số 32, nên VRAM còn phụ thuộc tỷ lệ cạnh các ảnh cùng batch. Không chia tiles.

Train áp dụng horizontal flip xác suất 0,5 và biến đổi bbox tương ứng; validation/test không có augmentation. DataLoader shuffle train, workers 0, không bỏ batch cuối. Cả hai mạng học toàn bộ bbox có nhãn, kể cả difficult. Khi đánh giá, difficult không tính vào số GT thường và detection khó difficult được bỏ qua theo VOC. Truncated vẫn được học/đánh giá.



Hình 6.3: Ảnh gốc, resize giữ tỷ lệ và horizontal flip; bbox đi cùng phép biến đổi.

6.3 FPN: phương pháp, thí nghiệm và giới hạn

Feature tầng sớm giữ chi tiết vị trí, trong khi tầng sâu có ngữ nghĩa mạnh hơn. FPN [5] kết hợp chúng bằng top-down và lateral connections. ResNet-50 xuất C2–C5, strides 4/8/16/32, channels 256/512/1.024/2.048. Với lateral L_l là Conv 1×1 đưa về 256 channels:

$$T_5 = L_5(C_5), \quad T_l = L_l(C_l) + \text{Upsample}_{\text{nearest}}(T_{l+1}), \quad P_l = \text{Conv}_{3 \times 3}(T_l). \quad (6.1)$$

Upsample đến đúng shape lateral; nhánh top-down truyền T trước smoothing, không truyền P sau smoothing. Neck không thêm BN/ReLU tại các mức này.

Bảng 6.2: Kết quả và ablation của FPN trên COCO; số liệu tác giả [5].

Thiết lập	Chỉ số	Giá trị
Table 1, ResNet-50 RPN C4	AR@1k	48,3
RPN FPN đầy đủ	AR@1k	56,3
Bỏ top-down / bỏ lateral	AR@1k	49,5 / 46,1
Chỉ P2, tăng anchors lên 750k	AR@1k	51,3
Table 3, Faster R-CNN C4 / FPN	AP	31,6 / 33,9
Table 3, Faster R-CNN C4 / FPN	AP50	53,1 / 56,9

Paper dùng COCO trainval35k và minival 5 k cho ablation. Bỏ một nhánh làm giảm recall; chỉ tăng số anchors ở P2 chưa đạt FPN đầy đủ. Kết quả hỗ trợ vai trò phối hợp ngữ nghĩa và độ phân giải, ngoài việc tăng số vị trí dự đoán. Thí nghiệm VOC dùng FPN cho cả hai mạng; không có ablation bỏ nhánh để đo riêng đóng góp của neck. FPN tăng activation ở mức độ phân giải cao và không tự giải quyết vật thể quá nhỏ, che khuất hoặc lẫn nhiễu.

6.4 RetinaNet và Focal Loss

6.4.1 Động cơ và hàm mất mát

Các anchors phủ dày trên ảnh tạo nhiều mẫu nền để phân loại, có thể lấn át gradient từ đối tượng thật. Focal Loss [6] giảm đóng góp của mẫu đã được dự đoán đúng:

$$\text{FL}(p_t) = -\alpha_t(1 - p_t)^\gamma \log p_t, \quad \alpha = 0,25, \quad \gamma = 2. \quad (6.2)$$

Với $p_t = 0,9$, hệ số điều chỉnh là 0,01; với $p_t = 0,1$ là 0,81. $\alpha_t = \alpha$ cho mẫu dương, $1 - \alpha$ cho mẫu âm; đây là cân bằng foreground/background, không phải cân bằng tần suất 20 lớp. Mỗi anchor có 20 xác suất sigmoid độc lập, không thêm một logit background. Loss phân loại chuẩn hóa theo số anchors dương; bbox dùng Smooth L1 beta 1. Bias classification khởi tạo theo xác suất tiên nghiệm của foreground $\pi = 0,01$.


Bảng 6.3: RetinaNet Table 1: ablation trên COCO minival và đánh đổi tốc độ/AP trên test-dev; số liệu tác giả [6].

Thiết lập	AP	Thời gian
Ablation, COCO minival (Table 1a–d)		
Alpha-balanced CE tốt nhất / Focal Loss	31,1 / 34,0	—
3 scales $\times$ 3 ratios	34,0	—
ResNet-101: OHEM tốt nhất / Focal Loss	32,8 / 36,0	—
Tốc độ/chất lượng, COCO test-dev (Table 1e)		
ResNet-50, cạnh ngắn 500	32,5	72 ms
ResNet-50, cạnh ngắn 800	35,7	153 ms

Paper dùng COCO trainval35k; thời gian đo trên GPU M40. Focal Loss cải thiện 2,9 điểm AP so với CE được cân bằng; trên ResNet-101, hơn OHEM tốt nhất 3,2 điểm AP. Tăng resize cũng tăng AP nhưng tốn thời gian. Các kết quả giải thích lựa chọn loss/scale, không phải mốc trực tiếp cho holdout VOC. Mẫu khó cũng có thể là annotation nhiều; tập trung vào chúng không bảo đảm giải quyết mọi lớp hiếm hoặc che khuất.


6.4.2 Neck, anchors và head

RetinaNet dùng P3–P7. P3–P5 lấy từ C3–C5; P6 là Conv 3^2 /stride 2 trên C5; P7 là Conv 3^2 /stride 2 trên ReLU(P6).



Hình 6.4: FPN RetinaNet. Shape minh họa tại input 512 × 512; thí nghiệm dùng resize 600/max 1000. Độ sâu khối thể hiện channels, không dùng cùng tỷ lệ với kích thước không gian.

Anchor bases 32/64/128/256/512, scales $1, 2^{1/3}, 2^{2/3}$, ratios 0, 5, 1, 2 tạo 9 anchors/vị trí. IoU $\geq 0,5$ là positive, $< 0,4$ là negative, khoảng giữa bỏ qua; matching giữ low-quality matches theo torchvision. Hai subnet có trọng số riêng; mỗi subnet gồm bốn Conv $3^2/256 + \text{ReLU}$ và một Conv output. Trọng số mỗi subnet dùng chung trên các mức.




Hai subnet riêng; trọng số từng subnet dùng chung trên P3–P7.

Focal Loss ($\alpha = 0,25, \gamma = 2$) + Smooth L1.

Hình 6.5: RetinaNet head: $9 \times 20 = 180$ class logits, $9 \times 4 = 36$ offsets mỗi vị trí; không có logit background riêng.

6.5 Faster R-CNN: RPN và RoI head

Faster R-CNN [7] tạo đề xuất vùng rồi phân loại/hiệu chỉnh vùng. FPN dùng P2–P6 cho RPN; P6 là MaxPool $1^2/\text{stride } 2$ trên P5. RoI head dùng P2–P5.



Hình 6.6: FPN Faster R-CNN: P2 có độ phân giải cao, P6 lấy từ P5. Shape ở input 512×512 chỉ để đổi chiều cấu trúc.


RPN gồm Conv $3^2/256 + \text{ReLU}$ và hai nhánh 1^2 cho objectness/bbox. Bases 32–512, một scale, ba ratios tạo 3 anchors/vị trí. Positive IoU $\geq 0,7$ hoặc best anchor, negative $< 0,3$; sample 256 anchors/ảnh, tối đa 50% positive. NMS proposals dùng 0,7, giữ 2.000 proposals/train và 1.000/test.

RoI gán mức theo FPN:

$$k = \text{clip}_{[2,5]} \left\lfloor 4 + \log_2 \left(\frac{\sqrt{wh}}{224} \right) \right\rfloor. \quad (6.3)$$

RoI Pooling 7^2 lượng tử hóa tọa độ và max pooling, không dùng RoIAlign. Tensor $7 \times 7 \times 256$ flatten thành 12.544, qua hai FC 1.024 + ReLU rồi tách 21 logits và 84 class-specific offsets.

Train sample 512 RoIs/ảnh, tối đa 25% positive. Bốn loss gồm RPN objectness/bbox và RoI classification/bbox; hai bbox loss dùng Smooth L1 beta 1/9.



RPN: P2–P6; RoI Pool: P2–P5 theo $\lfloor 4 + \log_2(\sqrt{wh}/224) \rfloor$.
 Loss: objectness + classification CE, hai thành phần Smooth L1.

Hình 6.7: Faster R-CNN: RPN tạo proposals, RoI Pool gom feature, hai FC trước hai nhánh output.

Hai mạng cùng decode bbox, score floor 0,05, class-wise Hard-NMS 0,5, cap 100 detections/ảnh. RetinaNet lọc top 1.000 candidates/mức trước NMS. Gallery dùng score từ 0,30 và tối đa 15 boxes; metric không bị giới hạn theo số box hiển thị.

Bảng 6.4: Số tham số trainable. FrozenBatchNorm giữ statistics/buffers cố định.

Mạng	Backbone	FPN	Head/RPN/RoI	Tổng
RetinaNet	23.454.912	7.997.440	5.218.520	36.670.872
Faster R-CNN	23.454.912	3.344.384	14.597.240	41.396.536

6.6 Huấn luyện và lựa chọn weights

ResNet-50 nạp ImageNet-1K V1, bỏ FC ImageNet; các Conv được fine-tune. Các lateral/smoothing chung khởi tạo giống nhau theo seed; head và neck bổ sung khởi tạo mới. Không nạp pretrained detection trên COCO.

SGD LR 0,01, momentum 0,9, weight decay 10^{-4} ; warmup một epoch từ 0,1 lần LR rồi cosine đến 0,01 lần LR. Clip gradient norm 10, AMP float16 cho convolution; RetinaNet loss/RoI Pool tính FP32. Batch train/eval 4, accumulation 3, effective batch 12. Mỗi epoch có 2.308 batches train, 289 validation; test cũng có 289. Gradient chuẩn hóa theo số ảnh thực của cửa sổ, kể cả cửa sổ cuối.

Giới hạn 30 epoch; dừng sớm theo validation VOC mAP50, patience 2, min-delta 0,001. Chỉ cập nhật checkpoint khi vượt best đang giữ hơn min-delta. Best weights theo quy tắc này giữ trong CPU RAM. Hai lượt train/validation hoàn tất trước khi mở test; test không chọn epoch hoặc confidence.

Bảng 6.5: Epoch thực chạy, epoch chọn, validation mAP50 và số cập nhật SGD.

Mạng	Epoch	Best	Val mAP50	Updates	AMP skips
RetinaNet	23	21	0,7501	17.710	0
Faster R-CNN	13	11	0,7536	10.010	0

RetinaNet dừng ở epoch 23, dùng epoch 21; Faster R-CNN dừng ở epoch 13, dùng epoch 11. Tổng 36 epoch, 27.720 cập nhật, không AMP skips. Train + validation lần lượt 8 giờ 01 phút 47 giây và 4 giờ 57 phút 25 giây, gồm tải dữ liệu và tính metric, không gồm test/vẽ hình.

6.6.1 Phạm vi đối chiếu paper

FPN paper dùng COCO và feature sharing bốn bước; cài đặt VOC train joint RPN/RoI. RetinaNet paper dùng batch 16/100k iterations với các mốc giảm LR; ở đây dùng epoch/cosine/dừng sớm. Resize chung 600/max 1000, ResNet-v1.5, anchor rounding, low-quality matching và Smooth L1 theo torchvision cũng khác một số chi tiết của tác giả. Thí nghiệm sử dụng nguyên lý neck/head của paper; các khác biệt trên giới hạn khả năng đối chiếu trực tiếp với kết quả COCO của tác giả.

6.7 Chỉ số đánh giá

VOC2010–2012 mAP50 all-point là metric chính: sort score, matching one-to-one cùng class, $\text{IoU} > 0,5$, tích phân precision envelope theo recall [3]. Duplicate thường là FP; matches difficult bị bỏ qua. VOC07 AP11 bổ sung để phân biệt cách nội suy.

COCO-style AP trung bình 10 ngưỡng IoU 0,50–0,95, bước 0,05, 101 recall points, max 100 detections/ảnh [1]. AP50/AP75 và AP/AR theo scale bổ sung phân tích định vị. Small/medium/large dùng diện tích bbox ảnh gốc, theo mốc $32^2/96^2$. Evaluator giữ union IoU và bỏ qua repeated matches difficult theo VOC. Đây là metric COCO-style trên VOC, không phải dataset COCO. VOC AP50 và COCO-style AP50 khác cách nội suy/biên IoU.

P/R/F1 dùng matching class-wise VOC tại score 0,30; micro-F1 gộp TP/FP/FN, macro-F1 trung bình 20 lớp. Ma trận chẩn đoán dùng class-agnostic greedy theo score, $\text{IoU} \geq 0,5$, để nhìn nhầm lớp. Background biểu diễn FP/FN. Matched IoU là trung bình TP trong chẩn đoán, không thay thế AP. Score floor/cap chung có thể giới hạn recall, được giữ như nhau ở hai mạng.

6.8 Kết quả test và so sánh

Bảng 6.6: Test holdout 1.154 ảnh, 2.687 bbox thường. Metric ở thang 0–1.

Chỉ số	RetinaNet	Faster R-CNN
VOC mAP50	0,7158	0,7307
VOC07 mAP11	0,6963	0,7113
COCO-style AP50:95	0,4136	0,4075
COCO-style AP50	0,7148	0,7290
COCO-style AP75	0,4149	0,4245
Precision (score 0,30)	0,4625	0,4053
Recall (score 0,30)	0,7983	0,8269
Micro-F1 (score 0,30)	0,5857	0,5440
Macro-F1 (score 0,30)	0,5714	0,5336
Matched IoU (chẵn đoán)	0,7796	0,7776


Faster R-CNN đạt VOC mAP50 0,7307, hơn RetinaNet 1,49 điểm phần trăm. COCO-style AP50:95 đảo thứ tự: RetinaNet 0,4136 so với 0,4075, hơn 0,61 điểm. AP75 riêng lẻ vẫn cao hơn ở Faster R-CNN (0,4245 so với 0,4149). Vì vậy không dùng một ngưỡng IoU để khẳng định toàn bộ chất lượng định vị. Validation mAP50 cao hơn test 3,43 điểm ở RetinaNet, 2,29 điểm ở Faster R-CNN.

Tại score 0,30, Faster R-CNN recall cao hơn (0,8269 so với 0,7983), nhưng precision thấp hơn (0,4053 so với 0,4625). RetinaNet có micro-F1 cao hơn (0,5857 so với 0,5440). Đánh đổi precision–recall ở một confidence cố định không mâu thuẫn với thứ tự mAP50, vì AP tổng hợp cả đường precision–recall. Ngưỡng confidence được giữ cố định khi đánh giá test.

Bảng 6.7: COCO-style AP theo scale và AR trung bình qua các ngưỡng IoU.


Chỉ số	RetinaNet	Faster R-CNN
AP small	0,1057	0,1487
AP medium	0,2829	0,2953
AP large	0,4687	0,4645
AR@1	0,3887	0,3849
AR@10	0,5349	0,5382
AR@100	0,5422	0,5441
AR small	0,2495	0,2683
AR medium	0,4296	0,4359
AR large	0,5896	0,5937

APsmall thấp ở cả hai: 0,1057/0,1487, trong khi APlarge là 0,4687/0,4645. Faster R-CNN hơn APsmall 4,30 điểm, song còn khác anchors/head/sampling, chưa thể quy toàn bộ lợi ích cho P2. AR@10 gần AR@100: tăng detections giữ lại từ 10 lên 100 chỉ cải thiện recall trung bình ít trong thiết lập này.



Hình 6.8: Loss train và validation VOC mAP50/COCO-style AP; nét đứt đứng chỉ epoch được chọn.

Loss train tiếp tục giảm khi validation gần bão hòa. RetinaNet học nhiều epoch hơn nhưng không vượt Faster R-CNN ở mAP50 test. Độ lớn tổng loss không dùng xếp hạng hai kiến trúc vì thành phần/chuẩn hóa khác nhau.



Hình 6.9: Hai thành phần loss RetinaNet và bốn thành phần RPN/RoI; mỗi panel có trục riêng.

6.8.1 Chi phí huấn luyện và suy luận


Bảng 6.8: Chi phí trên RTX A3000 12 GB Laptop; peak là allocated PyTorch, không phải tổng VRAM.

Chỉ số	RetinaNet	Faster R-CNN
Số tham số (triệu)	36,6709	41,3965
Peak allocated VRAM (MiB)	6713,1270	6757,0645
Train + validation (phút)	481,7784	297,4104
Latency median batch 1 (ms)	47,3509	48,9216
Latency p95 batch 1 (ms)	51,5552	50,4023
FPS batch 1	21,1189	20,4409
Throughput batch 4 (ảnh/s)	17,8860	16,5063
Pipeline test (ảnh/s)	16,9982	16,3088

RetinaNet có 36,67 triệu tham số, ít hơn Faster R-CNN 4,73 triệu. Train + validation trung bình mỗi epoch khoảng 20,95/22,88 phút. Faster R-CNN chạy ít epoch nên thời gian tổng thấp hơn 184,37 phút. Số tham số và số giai đoạn chưa đủ để dự đoán chi phí huấn luyện tổng.

Benchmark CUDA events warmup ba lượt; batch 1 đo 20 lần, batch 4 đo 10 lần. Latency model gồm resize, normalize, backbone, neck, head, decode/NMS; không gồm đọc JPEG/metric

CPU. Median batch 1 là 47,35/48,92 ms, tương ứng 21,12/20,44 FPS; RetinaNet nhanh hơn khoảng 3,3% theo FPS. Throughput batch 4 thấp hơn FPS batch 1. Các batch dùng ảnh khác tỷ lệ cạnh/padding nên không đọc hai cột như phép đo scaling với workload đồng nhất. Pipeline test gồm đọc ảnh, chuyển tensor và thu predictions, đạt 17,00/16,31 ảnh/s.




Hình 6.10: So sánh AP, latency batch 1 và peak allocated VRAM; số và đơn vị ghi trên đồ thị.

6.9 Theo lớp, ma trận và trường hợp sai

Bảng 6.9: R=RetinaNet, F=Faster R-CNN; AP là COCO-style AP50:95, F1 tại score 0,30.

Lớp	GT	R AP50	F AP50	R AP	F AP	R F1	F F1
aeroplane	76	0,8042	0,7523	0,4629	0,4680	0,6971	0,5339
bicycle	80	0,7874	0,8367	0,4903	0,5215	0,5789	0,5591
bird	88	0,8184	0,7982	0,4375	0,4198	0,6549	0,6167
boat	99	0,6180	0,6227	0,2891	0,2849	0,5227	0,5691
bottle	109	0,5763	0,6325	0,2914	0,3298	0,5180	0,4401
bus	62	0,8852	0,8710	0,6134	0,5678	0,5957	0,5556
car	204	0,7881	0,8214	0,5070	0,4538	0,6154	0,4554
cat	135	0,8938	0,9061	0,5618	0,5354	0,7219	0,6368
chair	175	0,4424	0,4847	0,1994	0,2381	0,3630	0,3323
cow	67	0,7501	0,7069	0,4456	0,3608	0,5579	0,5348
diningtable	48	0,3852	0,6225	0,1619	0,3043	0,3453	0,4186
dog	159	0,8585	0,8465	0,5402	0,5079	0,6843	0,6407
horse	68	0,8309	0,7675	0,5257	0,3864	0,6519	0,5761
motorbike	75	0,8313	0,7985	0,4759	0,4620	0,6161	0,6349
person	866	0,8258	0,8587	0,4166	0,4457	0,6288	0,6139
pottedplant	72	0,2969	0,3360	0,1247	0,1451	0,2857	0,2905
sheep	83	0,7446	0,7514	0,4693	0,4539	0,5893	0,5234
sofa	49	0,6306	0,6010	0,3526	0,3458	0,4098	0,4823
train	77	0,8135	0,8400	0,4874	0,4677	0,7381	0,5872
tvmonitor	95	0,7349	0,7586	0,4188	0,4523	0,6540	0,6697

Cat, bus và dog có AP50 cao; pottedplant/chair thấp ở cả hai. Faster R-CNN cải thiện diningtable từ 0,3852 lên 0,6225, nhưng RetinaNet cao hơn ở horse (0,8309/0,7675) và aeroplane (0,8042/0,7523). Các chỉ số trung bình che khuất một phần chênh lệch giữa các lớp.



Hình 6.11: VOC AP50 và COCO-style AP theo lớp; hai detector dùng chung mỗi panel.


Ma trận ở Phụ lục trình bày riêng số đếm và tỷ lệ theo hàng. Hàng background là detection không ghép GT; cột background là GT bị bỏ sót. Lềch bbox, dự đoán lặp và nhầm lớp đều có thể tạo FP/FN. P/R/F1 chính được tính class-wise riêng, không lấy trực tiếp từ ma trận chẩn đoán.

Ba ảnh lỗi minh họa chủ yếu là dự đoán thừa: mỗi ảnh có một TP và không có FN theo chẩn đoán tại score 0,30. Ở ảnh con chó giữa các chân người, RetinaNet/Faster R-CNN có 8/9 FP; nhiều bbox lặp hoặc chỉ bao phủ một phần vật thể. Ảnh xe đồ chơi có 10/5 FP, với các dự đoán chair/car không khớp annotation. Ảnh trang trí nội thất có 10/8 FP, gồm nhiều bbox pottedplant/chair. Những hình này cho thấy sự khác nhau giữa một vùng trông giống đối tượng và một detection khớp nhãn theo IoU. Chúng không đại diện cho tỷ lệ lỗi toàn tập; số đếm đầy đủ nằm trong ma trận và metric test.


6.10 Kết luận A2 và giới hạn

Faster R-CNN có lợi thế mAP50, recall và APsmall; RetinaNet có lợi thế COCO-style AP tổng hợp, F1 tại score 0,30, số tham số và latency batch 1. Nếu ưu tiên recall vật thể nhỏ, Faster R-CNN phù hợp hơn theo số liệu này; nếu cân bằng AP nhiều ngưỡng IoU và chi phí suy luận, RetinaNet đáng cân nhắc.


Kết luận dựa trên một seed và holdout nội bộ. Hai mạng khác nhiều thành phần cùng lúc, chưa cô lập riêng P2, Focal Loss hoặc proposals. Giới hạn epoch/dừng sớm, score floor/cap và resize chung ảnh hưởng phép so sánh. Các hướng tiếp theo là nhiều seed, ablation neck/anchors với head giữ cố định và chọn confidence bằng validation; chưa nằm trong kết quả báo cáo.



Hình 6.12: Precision–recall 20 lớp; mỗi subplot có hai detector, AP trong legend là VOC AP50.



Hình 6.13: Cùng ba ảnh test: GT / RetinaNet / Faster R-CNN; score hiển thị 0,30, difficult nét đứt.



Hình 6.14: Ba ảnh có nhiều false positives: con chó, xe đồ chơi và trang trí nội thất. Các ví dụ được chọn sau test để phân tích, không dùng để chọn cấu hình.

7. Kết luận

E1 cho thấy MLP phi tuyến cải thiện so với classifier tuyến tính; CNN tăng accuracy bằng locality và chia sẻ trọng số. CNN-B ít tham số hơn CNN-A nhưng test accuracy tương đương trong một seed. E2 xác nhận MSA thủ công qua forward/gradient; CNN-stem hữu ích trong cả hai cách cài đặt. Tăng số head không tạo cải thiện đơn điệu. E3 cho thấy rows tốt nhất trong các biểu diễn đã thử; GRU dùng ít tham số và chạy nhanh hơn LSTM cùng representation, nhưng CNN-B vẫn hiệu quả hơn về độ chính xác/thời gian ở bài toán ảnh tĩnh.

A1 cho thấy pretrained full cho kết quả validation tốt nhất trong hai họ. Head-only tiết kiệm bộ nhớ nhưng accuracy thấp; partial phụ thuộc phạm vi unfreeze. DeiT pretrained full có test accuracy trung bình ba seed cao hơn ResNet; ResNet suy luận nhanh hơn và dùng ít peak memory hơn. Tác dụng augmentation không giống nhau giữa hai họ.

A2 cho thấy thứ tự detector phụ thuộc metric: Faster R-CNN hơn ở mAP50, recall và APs-small; RetinaNet hơn ở COCO-style AP50:95, F1 tại score 0,30 và latency batch 1. FPN tạo feature đa tỉ lệ, nhưng vẫn khó với vật thể nhỏ/nội thất; Focal Loss không thay thế phân tích FP/FN hoặc lựa chọn confidence trên validation.

Các kết luận gắn với dataset, split, seed và ngân sách thực nghiệm. Hướng tiếp theo là nhiều seed cho E1–E3/A2, so sánh cùng capacity/ngân sách cập nhật, ablation neck/anchors ở detection và kiểm tra độ ổn định theo track ở GTSRB. Những hướng này chưa nằm trong số liệu báo cáo.

7.1 Ghi nhận hỗ trợ của công cụ AI

Công cụ AI được dùng để hỗ trợ lập trình, kiểm tra code, tổng hợp output, đối chiếu tài liệu và biên tập LaTeX/TikZ. Số liệu thực nghiệm lấy từ các notebook đã chạy và lưu output, không được tạo để minh họa kết quả. Người thực hiện chịu trách nhiệm hiểu, kiểm chứng và bảo vệ code, số liệu và phân phân tích; phạm vi hỗ trợ được ghi nhận theo mục 1.6 đề E1–E3.

Tài liệu tham khảo

- [1] COCO Consortium. Coco detection evaluation, 2015. URL <https://cocodataset.org/dataset/detection-eval.htm>.
- [2] Mark Everingham, Luc Van Gool, Christopher K. I. Williams, John Winn, and Andrew Zisserman. The pascal visual object classes (voc) challenge. *International Journal of Computer Vision*, 88:303–338, 2010. doi: 10.1007/s11263-009-0275-4.
- [3] Mark Everingham et al. The pascal visual object classes challenge 2012 development kit, 2012. URL <https://www.robots.ox.ac.uk/~vgg/projects/pascal/VOC/voc2012/html/doc/index.html>.
- [4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, 2016. URL https://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html.
- [5] Tsung-Yi Lin, Piotr Dollar, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *CVPR*, 2017. URL https://openaccess.thecvf.com/content_cvpr_2017/html/Lin_Feature_Pyramid_Networks_CVPR_2017_paper.html.
- [6] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollar. Focal loss for dense object detection. In *ICCV*, pages 2980–2988, 2017. URL https://openaccess.thecvf.com/content_ICCV_2017/html/Lin_Focal_Loss_for_ICCV_2017_paper.html.
- [7] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster r-cnn: Towards real-time object detection with region proposal networks. In *NeurIPS*, 2015. URL <https://arxiv.org/abs/1506.01497>.
- [8] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. The german traffic sign recognition benchmark: A multi-class classification competition. In *International Joint Conference on Neural Networks*, pages 1453–1460, 2011.
- [9] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition. *Neural Networks*, 32:323–332, 2012. doi: 10.1016/j.neunet.2012.02.016.
- [10] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. German traffic sign recognition benchmark: Public archive, 2019. URL <https://sid.erda.dk/public/archives/daaeac0d7ce1152aea9b61d9f1e19370/published-archive.html>. Accessed 8 October 2026.

- [11] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Herve Jegou. Training data-efficient image transformers and distillation through attention. In *ICML*, 2021. URL <https://proceedings.mlr.press/v139/touvron21a.html>.
- [12] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms. *arXiv:1708.07747*, 2017. URL <https://arxiv.org/abs/1708.07747>.

A. Kết quả chi tiết và tái lập

A.1 Chi tiết huấn luyện E1–E3 và A1

Các bảng dưới ghi số epoch đã chạy, best epoch, optimizer updates thực tế, AMP skips và peak allocated MiB. Chúng đối chiếu trực tiếp output cell, không suy số updates chỉ từ số epoch.

Bảng A.1: Chi tiết lượt train E1.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
Softmax	24	14	10,128	0	19
MLP	26	16	10,972	0	23
CNN-A	18	8	7,596	0	52
CNN-B	40	30	16,878	2	57

Bảng A.2: Chi tiết lượt train E2; ký hiệu M/T và R/P/C như Chương E2.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
M-R4	26	16	10,972	0	44
M-P4	40	30	16,879	1	69
M-C4	30	20	12,658	2	78
T-R4	26	16	10,972	0	47
T-P4	34	24	14,348	0	79
T-C4	34	24	14,346	2	89
M-C2	41	31	17,299	3	70
M-C8	28	18	11,816	0	98

Bảng A.3: Chi tiết lượt train E3.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
LSTM Rows	24	14	10,128	0	27
LSTM Columns	29	19	12,238	0	27
LSTM Patch	34	24	14,348	0	34
GRU Rows	26	20	10,972	0	28
GRU Columns	29	19	12,238	0	28
GRU Patch	30	20	12,660	0	35
MLP	26	16	10,972	0	23
CNN-B	40	30	16,878	2	57

Bảng A.4: Epoch, cập nhật và peak memory của sáu run mở rộng A1.

Run	Epoch	Best	Updates	Peak MiB
R-F/42 no-aug	5	3	1,230	5831
R-F/43	8	4	1,968	5826
R-F/44	7	3	1,722	5827
D-F/42 no-aug	17	13	4,182	6633
D-F/43	22	18	5,412	6632
D-F/44	10	6	2,460	6632

A.2 Metric theo lớp và độ nhảy A1

Hai cột model là full pretrained seed 42, được chọn bằng validation. Support là số ảnh test nguồn. ID tra bằng bảng tên lớp dưới đây.

Bảng A.5: Precision/recall/F1 trên test GTSRB, lớp 0–21.

ID	Lớp	n	ResNet full			DeiT full		
			P	R	F1	P	R	F1
0	Speed limit 20	60	1,000	1,000	1,000	1,000	0,500	0,667
1	Speed limit 30	720	0,984	1,000	0,992	0,997	0,997	0,997
2	Speed limit 50	750	0,989	0,996	0,993	0,999	0,997	0,998
3	Speed limit 60	450	0,985	0,993	0,989	1,000	0,993	0,997
4	Speed limit 70	660	0,998	0,986	0,992	0,997	0,998	0,998
5	Speed limit 80	630	0,964	0,990	0,977	0,994	0,998	0,996
6	End speed limit 80	150	1,000	0,993	0,997	1,000	0,973	0,986
7	Speed limit 100	450	1,000	0,996	0,998	0,976	1,000	0,988
8	Speed limit 120	450	0,986	0,938	0,961	0,937	0,996	0,966
9	No passing	480	1,000	1,000	1,000	0,986	1,000	0,993
10	No passing >3.5t	660	0,990	1,000	0,995	0,998	1,000	0,999
11	Right-of-way intersection	420	0,976	0,955	0,965	0,978	0,971	0,975
12	Priority road	690	1,000	0,993	0,996	0,996	1,000	0,998
13	Yield	720	0,989	0,996	0,992	1,000	0,997	0,999
14	Stop	270	0,944	1,000	0,971	0,996	1,000	0,998
15	No vehicles	210	0,991	0,995	0,993	0,991	0,995	0,993
16	Vehicles >3.5t prohibited	150	1,000	1,000	1,000	0,987	1,000	0,993
17	No entry	360	1,000	0,956	0,977	1,000	0,969	0,984
18	General caution	390	1,000	0,992	0,996	0,982	0,990	0,986
19	Dangerous curve left	60	1,000	1,000	1,000	1,000	1,000	1,000
20	Dangerous curve right	90	1,000	1,000	1,000	1,000	1,000	1,000
21	Double curve	90	1,000	0,978	0,989	0,968	1,000	0,984

Bảng A.6: Precision/recall/F1 trên test GTSRB, lớp 22–42.

ID	Lớp	n	ResNet full			DeiT full		
			P	R	F1	P	R	F1
22	Bumpy road	120	0,980	0,800	0,881	0,991	0,950	0,970
23	Slippery road	150	0,974	1,000	0,987	0,968	1,000	0,984
24	Road narrows right	90	1,000	1,000	1,000	0,947	1,000	0,973
25	Road work	480	0,897	0,998	0,945	0,985	0,967	0,976
26	Traffic signals	180	1,000	0,994	0,997	1,000	0,972	0,986
27	Pedestrians	60	1,000	0,500	0,667	1,000	0,883	0,938
28	Children crossing	150	1,000	1,000	1,000	1,000	1,000	1,000
29	Bicycle crossing	90	0,978	1,000	0,989	1,000	1,000	1,000
30	Ice/snow caution	150	0,887	0,940	0,913	0,917	0,960	0,938
31	Wild animals crossing	270	0,996	1,000	0,998	0,993	1,000	0,996
32	End speed/passing limits	60	1,000	0,967	0,983	1,000	1,000	1,000
33	Turn right ahead	210	1,000	1,000	1,000	1,000	1,000	1,000
34	Turn left ahead	120	0,960	1,000	0,980	0,992	1,000	0,996
35	Ahead only	390	0,990	0,990	0,990	1,000	0,982	0,991
36	Straight or right	120	0,966	0,942	0,954	0,976	1,000	0,988
37	Straight or left	60	1,000	0,983	0,992	1,000	1,000	1,000
38	Keep right	690	0,993	0,988	0,991	0,989	1,000	0,994
39	Keep left	90	1,000	0,922	0,960	1,000	1,000	1,000
40	Roundabout mandatory	90	0,963	0,878	0,919	1,000	0,844	0,916
41	End no passing	60	0,984	1,000	0,992	1,000	1,000	1,000
42	End no passing >3.5t	90	0,978	1,000	0,989	0,927	0,989	0,957


Bảng A.7: Độ nhảy A1 với 8 ảnh test trùng train.

Run	Full acc	Clean acc	Δ (điểm%)	Full F1	Clean F1
R-S/42	96,33	96,33	-0,002	0,9447	0,9447
R-H/42	70,35	70,33	-0,019	0,6143	0,6143
R-P/42	96,05	96,05	-0,003	0,9438	0,9438
R-F/42	98,37	98,37	-0,001	0,9743	0,9743
D-S/42	96,14	96,13	-0,002	0,9350	0,9350
D-H/42	69,73	69,71	-0,019	0,6125	0,6125
D-P/42	87,85	87,85	-0,008	0,8063	0,8063
D-F/42	98,92	98,91	-0,001	0,9790	0,9790


Full test có 12.630 ảnh, clean test có 12.622; mọi accuracy tính bằng %. Bảng ghi mức làm tròn trong output; delta tính trên giá trị chưa làm tròn nên không nhất thiết bằng phép trừ hai cột accuracy hiển thị.

A.3 Ma trận nhầm lẫn E2 và E3


Mỗi cặp dùng cùng thang màu 0–100%, ghi cả count và tỷ lệ theo hàng. Toàn bộ 10.000 ảnh test mỗi model được đưa vào ma trận. Các model không được chọn/tune lại theo lỗi test ở các hình này.




Hình A.1: E2: confusion matrix test, cặp 1; tên model ghi trên từng panel.




Hình A.2: E2: confusion matrix test, cặp 2; tên model ghi trên từng panel.




Hình A.3: E2: confusion matrix test, cặp 3; tên model ghi trên từng panel.





Hình A.4: E2: confusion matrix test, cặp 4; tên model ghi trên từng panel.





Hình A.6: E3: confusion matrix test, cặp 2; tên model ghi trên từng panel.





A.4 Dữ liệu và chỉ số theo lớp A2

Bảng A.8: Số bbox thường của từng lớp VOC2012; difficult không nằm trong các cột này.

Lớp	Train	Validation	Test
aeroplane	692	97	76
bicycle	566	65	80
bird	933	98	88
boat	676	75	99
bottle	1.011	139	109
bus	487	44	62
car	1.624	189	204
cat	970	112	135
chair	1.929	250	175
cow	473	48	67
diningtable	487	74	48
dog	1.213	143	159
horse	554	88	68
motorbike	585	53	75
person	6.802	898	866
pottedplant	804	97	72
sheep	611	119	83
sofa	447	70	49
train	492	59	77
tvmonitor	619	70	95

Bảng A.9: P/R/F1 tại score 0,30; R=RetinaNet, F=Faster R-CNN, Rec là recall.


Lớp	GT	R P	R Rec	R F1	F P	F Rec	F F1
aeroplane	76	0,6162	0,8026	0,6971	0,4069	0,7763	0,5339
bicycle	80	0,4459	0,8250	0,5789	0,4080	0,8875	0,5591
bird	88	0,5362	0,8409	0,6549	0,4868	0,8409	0,6167
boat	99	0,4182	0,6970	0,5227	0,4762	0,7071	0,5691
bottle	109	0,4260	0,6606	0,5180	0,3160	0,7248	0,4401
bus	62	0,4444	0,9032	0,5957	0,4044	0,8871	0,5556
car	204	0,4985	0,8039	0,6154	0,3046	0,9020	0,4554
cat	135	0,6010	0,9037	0,7219	0,4794	0,9481	0,6368
chair	175	0,2660	0,5714	0,3630	0,2274	0,6171	0,3323
cow	67	0,4309	0,7910	0,5579	0,4167	0,7463	0,5348
diningtable	48	0,2637	0,5000	0,3453	0,2903	0,7500	0,4186
dog	159	0,5547	0,8931	0,6843	0,5036	0,8805	0,6407
horse	68	0,5221	0,8676	0,6519	0,4569	0,7794	0,5761
motorbike	75	0,4779	0,8667	0,6161	0,5263	0,8000	0,6349
person	866	0,4947	0,8626	0,6288	0,4669	0,8961	0,6139
pottedplant	72	0,2105	0,4444	0,2857	0,2071	0,4861	0,2905
sheep	83	0,4681	0,7952	0,5893	0,3873	0,8072	0,5234
sofa	49	0,2692	0,8571	0,4098	0,3696	0,6939	0,4823
train	77	0,6813	0,8052	0,7381	0,4367	0,8961	0,5872
tvmonitor	95	0,5948	0,7263	0,6540	0,5873	0,7789	0,6697

Bảng A.10: AP50/AP75 COCO-style và AP11 VOC07 từng lớp; metric ở thang 0–1.


Lớp	R AP50	F AP50	R AP75	F AP75	R AP11	F AP11
aeroplane	0,8016	0,7502	0,4949	0,5495	0,7851	0,7291
bicycle	0,7978	0,8410	0,4852	0,6381	0,7750	0,8138
bird	0,8146	0,7940	0,4284	0,4054	0,7887	0,7827
boat	0,6157	0,6202	0,2315	0,2279	0,6059	0,6069
bottle	0,5749	0,6313	0,2733	0,3251	0,5594	0,6199
bus	0,8826	0,8680	0,6551	0,6866	0,8422	0,8368
car	0,7845	0,8187	0,5378	0,4819	0,7633	0,7940
cat	0,8892	0,9012	0,5784	0,5434	0,8548	0,8640
chair	0,4451	0,4893	0,1744	0,1989	0,4476	0,4882
cow	0,7496	0,7049	0,4893	0,3358	0,7295	0,6921
diningtable	0,3874	0,6215	0,1098	0,2605	0,4080	0,6156
dog	0,8562	0,8429	0,5952	0,5616	0,8245	0,8124
horse	0,8270	0,7649	0,5445	0,3705	0,7940	0,7466
motorbike	0,8313	0,7959	0,4870	0,5357	0,7949	0,7741
person	0,8259	0,8565	0,3563	0,4354	0,7998	0,8308
pottedplant	0,2984	0,3379	0,0845	0,0746	0,3060	0,3505
sheep	0,7421	0,7488	0,4981	0,4931	0,7208	0,7354
sofa	0,6289	0,5986	0,2935	0,4205	0,6205	0,5899
train	0,8110	0,8370	0,5821	0,4418	0,7875	0,8110
tvmonitor	0,7327	0,7565	0,3993	0,5044	0,7192	0,7317

A.5 Ma trận chẩn đoán A2


Hàng là ground truth, cột là prediction. Background ở hàng biểu diễn false positives, ở cột biểu diễn false negatives. Số đếm và tỷ lệ theo hàng được tách trang để đọc rõ từng ô; cùng một ảnh output nguồn được hiển thị theo từng panel, không thay đổi các số trong ma trận.




Hình A.9: A2 RetinaNet: số đếm, $\text{IoU} \geq 0,5$, $\text{confidence} \geq 0,30$.



Hình A.10: A2 RetinaNet: tỷ lệ theo hàng, $\text{IoU} \geq 0,5$, $\text{confidence} \geq 0,30$.



Hình A.11: A2 Faster R-CNN: số đếm, $\text{IoU} \geq 0,5$, $\text{confidence} \geq 0,30$.



Hình A.12: A2 Faster R-CNN: tỷ lệ theo hàng, $\text{IoU} \geq 0,5$, $\text{confidence} \geq 0,30$.

A.6 Nguồn số liệu và hướng dẫn tái lập

Nguồn số liệu là output đã lưu của E1.ipynb, E2.ipynb, E3.ipynb, A1.ipynb và A2.ipynb trong `source_code`. Manifest dưới `assets/e1`, `e2`, `e3`, `a1` ghi cell/output và bảng Markdown nguồn; `assets/a2` có cùng thông tin truy nguồn cho A2. PNG được trích trực tiếp từ ảnh trong output; sơ đồ kiến trúc được vẽ bằng TikZ từ định nghĩa mạng.

Chuẩn bị dữ liệu theo README trong thư mục `datasets`. Mở notebook tương ứng, chọn Python 3.14 có CUDA, Restart Kernel và Run All, sau đó Save. Mỗi notebook chạy độc lập; không cần thứ tự. Các tham số thực nghiệm cần giữ là patience 10 cho E1–E3, patience 4 cho A1; A2 batch 4, accumulation 3, tối đa 30 epoch, patience 2/min-delta 0,001. Các lựa chọn weights và nguồn split được mô tả trong từng chương. Seed cố định không đảm bảo tái lập bitwise qua mọi GPU, phiên bản thư viện hoặc đường thực thi AMP.

Báo cáo biên dịch bằng XeLaTeX và BibTeX từ `report/source_latex/main.tex`; các sơ đồ TikZ được định nghĩa trong `architectures.tex`, ảnh kết quả nằm ở `assets`. Sản phẩm PDF chung giữ tại `report/CO5085_Report.pdf`.