ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÁO CÁO BÀI TẬP

Môn: Học sâu và ứng dụng trong thị giác máy tính

Thực nghiệm học sâu cho phân loại ảnh và phát hiện đối tượng

E1 – E2 – E3 – A1 – A2

CO5085 – Học kỳ 261 (2026–2027)

Giảng viên: Lê Thành Sách, Nguyễn Quốc Minh

Thực hiện

Đặng Nguyễn Tấn Tài 2570357

Lớp: CH01

Thành phố Hồ Chí Minh, 10/2026

Tóm tắt

Báo cáo khảo sát năm nhóm thực nghiệm qua 36 lượt huấn luyện: bốn mô hình E1, tám cấu hình attention E2, tám cấu hình hồi tiếp/baseline E3, 14 cấu hình CNN/Transformer A1 và hai detector A2. E1–E3 dùng Fashion-MNIST với 54.000 ảnh train, 6.000 validation và 10.000 test. A1 dùng GTSRB 43 lớp, tách validation theo track biển báo. A2 dùng toàn bộ 11.540 ảnh VOC2012 trainval có nhãn, chia 9.232/1.154/1.154 thành train/validation/test nội bộ. Mỗi notebook độc lập, có vòng lặp PyTorch và lưu kết quả ngay trong output cell.

Trên Fashion-MNIST, CNN-A đạt test accuracy 91,66%; CNN-B đạt 91,45% với 94.186 tham số. MSA thủ công với CNN-stem đạt 90,50%; GRU theo hàng đạt 90,06%. Trên GTSRB, pretrained full ResNet-50 và DeiT-Small/16 ở seed 42 đạt 97,83% và 98,92%; trung bình ba seed là $97,95 \pm 0,21\%$ và $98,50 \pm 0,36\%$. Trên VOC2012, RetinaNet/Faster R-CNN đạt mAP50 70,88%/73,16% và COCO-style AP50:95 39,13%/40,98%. Không có kiến trúc tốt nhất trên mọi tiêu chí: kết quả được phân tích cùng chi phí, chất lượng từng lớp và các trường hợp sai. Sơ đồ TikZ thể hiện luồng tensor, kích thước feature map và cấu trúc head; số liệu/hình kết quả được lấy từ output notebook đã lưu.

Mục lục

Tóm tắt **i**

1 Bài toán và thiết kế thực nghiệm **1**

1.1 Mục tiêu và phạm vi 1

1.2 Dữ liệu và cách chia tập 1

1.3 Môi trường và quy tắc đánh giá 3

2 E1: Softmax, MLP và CNN **5**

2.1 Mục tiêu và kiến trúc 5

2.2 Huấn luyện 6

2.3 Kết quả định lượng và capacity 7

2.4 Đường cong học và phân tích lỗi 8

3 E2: Multi-head self-attention và tokenization **12**

3.1 Mục tiêu và biểu diễn token 12

3.2 Kiến trúc encoder và MSA 13

3.3 Thiết lập huấn luyện và tám cấu hình 14

3.4 Kết quả và hai phép so sánh bắt buộc 14

3.4.1 Ảnh hưởng số head 15

3.5 Đường cong học, attention và lỗi 18

4 E3: LSTM và GRU trên chuỗi ảnh **24**

4.1 Biểu diễn ảnh thành chuỗi 24

4.2 Cell LSTM/GRU tự hiện thực 26

4.3 Mô hình đối chiếu và thiết lập huấn luyện 27

4.4 So sánh LSTM, GRU và cách biểu diễn 28

4.4.1 Đối chiếu với MLP và CNN 29

4.5 Đường cong học và phân tích lỗi 29

5 A1: CNN và Transformer trên GTSRB **33**

5.1 Dữ liệu, phân bố lớp và cách chia tập 33

5.2 DataLoader, augmentation và kiến trúc 37

5.3 Các cấu hình và thiết lập huấn luyện 39

5.4 Kết quả chính: CNN, Transformer và pretraining . . . 40
5.5 Freeze, chi phí và đường cong học . . . 43
5.6 Augmentation và độ biến thiên giữa seed . . . 47
5.7 Ma trận nhầm lẫn, lỗi và ảnh trùng . . . 50
5.8 Kết luận A1 và giới hạn . . . 53

6 A2: RetinaNet và Faster R-CNN trên VOC2012 54
6.1 Bài toán và dữ liệu . . . 54
6.2 Tiền xử lý và DataLoader . . . 58
6.3 FPN: phương pháp, thí nghiệm và giới hạn . . . 61
6.4 RetinaNet và Focal Loss . . . 62
6.4.1 Động cơ và hàm mất mát . . . 62
6.4.2 Neck, anchors và head . . . 62
6.5 Faster R-CNN: RPN và RoI head . . . 64
6.6 Huấn luyện và lựa chọn weights . . . 66
6.6.1 Phạm vi đối chiếu paper . . . 67
6.7 Chỉ số đánh giá . . . 67
6.8 Kết quả test và so sánh . . . 68
6.8.1 Chi phí huấn luyện và suy luận . . . 72
6.9 Theo lớp, ma trận và trường hợp sai . . . 75
6.10 Kết luận A2 và giới hạn . . . 77

7 Kết luận 78
7.1 Ghi nhận hỗ trợ của công cụ AI . . . 78

A Kết quả chi tiết và tái lập 81
A.1 Chi tiết huấn luyện E1–E3 và A1 . . . 81
A.2 Metric theo lớp và độ nhạy A1 . . . 82
A.3 Đường cong theo tokenizer và biểu diễn chuỗi . . . 85
A.4 Ma trận nhầm lẫn E1–E3 . . . 95
A.5 Dữ liệu và chỉ số theo lớp A2 . . . 116
A.6 Ma trận chẩn đoán A2 . . . 118
A.7 Precision–recall theo lớp A2 . . . 120
A.8 Ảnh test và dự đoán A2 . . . 131
A.9 Trường hợp sai A2 . . . 139
A.10 Nguồn số liệu và hướng dẫn tái lập . . . 148

Danh sách hình vẽ

1.1 Ảnh đại diện mười lớp Fashion-MNIST, lấy trực tiếp từ dữ liệu train. 2
1.2 Phân bố Fashion-MNIST: mỗi lớp có 5.400 ảnh train và 600 ảnh validation. . . 2

2.1 Softmax classifier: không Conv, một FC; 7.850 tham số. 5
2.2 MLP: ba FC, hai tầng ẩn; 235.146 tham số. 5
2.3 CNN-A: hai Conv, hai MaxPool, hai FC; 421.642 tham số. Conv stride 1, padding 1, có bias. 6
2.4 CNN-B: ba Conv/BN/MaxPool, một FC; 94.186 tham số. Conv stride 1, padding 1, không bias. Kích thước sau pool thứ ba là 3×3. 6
2.5 Accuracy và macro-F1 trên validation, cùng thang phần trăm. 7
2.6 Số tham số của bốn mô hình E1. 8
2.7 Cross-entropy của E1: nét đứt train, nét liền validation; mỗi đường có tên mô hình. 9
2.8 Accuracy theo epoch của bốn mô hình E1. 9
2.9 Mẫu lỗi Softmax, bố cục 2×5; mỗi ảnh ghi nhãn thật và dự đoán. 10
2.10 Mẫu lỗi CNN-A; các ảnh minh họa không thay thế tần suất từ toàn bộ test. . . . 11

3.1 Ba tokenizer E2; CNN-stem có hai Conv kernel 3, stride 1, padding 1, bias, ReLU và MaxPool 2 sau mỗi Conv. Rows không có Conv; patch lấy trực tiếp pixel. 12
3.2 Classifier E2: một FC embedding, hai encoder block và một FC head; không CLS token. 13
3.3 Một pre-norm encoder block: hai projection MSA và hai FC trong FFN, tổng bốn ánh xạ Linear/block. Đường ngoài là residual. 13
3.4 So sánh accuracy validation giữa Manual và PyTorch cho từng tokenizer. . . . 16
3.5 Thời gian train và validation trung bình mỗi epoch, cùng protocol và GPU. . . 17
3.6 Đường cong accuracy của Manual CNN-stem với H=2, 4 và 8. 18
3.7 Loss của Manual và PyTorch với CNN-stem H=4; nét đứt train, nét liền validation. 19
3.8 Accuracy của Manual và PyTorch với CNN-stem H=4. 20
3.9 Hai ảnh validation dùng để phân tích attention của Manual CNN-stem H=4: Shirt (index 0) và Ankle boot (index 31). Confidence lấy từ output đã lưu. . . . 20
3.10 Attention gộp của ảnh Shirt; hàng là nhóm query, cột là nhóm key. 21
3.11 Attention gộp của ảnh Ankle boot, cùng thang màu và cách nhóm token. 22
3.12 Mẫu lỗi của Manual CNN-stem H=4, bố cục 2×5. 23

3.13 Mẫu lỗi của PyTorch CNN-stem H=4, cùng nhóm lớp thật. 23

4.1 Rows: quét theo hàng và ma trận $T = 28, F = 28$. 24
4.2 Columns: quét theo cột và ma trận $T = 28, F = 28$. 25
4.3 Patch: raster trên lưới 4×4, chuỗi $T = 49, F = 16$. 25
4.4 Classifier recurrent E3: không Conv, một recurrent layer unroll T lần và một FC head. Trạng thái khởi tạo bằng 0, chỉ dùng hidden cuối. 26
4.5 LSTM cell: hai projection dùng chung ở mọi bước; không tạo thêm bộ tham số cho mỗi timestep. 26
4.6 GRU cell: hai projection cho ba nhóm gate, chỉ duy trì hidden state. 27
4.7 Loss của LSTM/GRU Rows và MLP/CNN-B; nét đứt train, nét liền validation. 30
4.8 Accuracy của recurrent đại diện và hai mô hình không hồi tiếp. 31
4.9 Mẫu lỗi của GRU Rows, bố cục 2×5. 31
4.10 Mẫu lỗi của CNN-B huấn luyện độc lập trong E3. 32

5.1 Số ảnh theo 43 lớp trong train, validation và test; ID tra theo bảng lớp ở Phụ lục. 34
5.2 Kích thước gốc của 39.209 ảnh train nguồn, trước khi chia train/validation. . . 35
5.3 Ảnh train đại diện cho lớp 0–9, bố cục 2×5. 35
5.4 Ảnh train đại diện cho lớp 10–19. 36
5.5 Ảnh train đại diện cho lớp 20–29. 36
5.6 Ảnh train đại diện cho lớp 30–39. 37
5.7 Ảnh train đại diện cho ba lớp 40–42. 37
5.8 ResNet-50: backbone gom khối, global average pooling và FC 43 lớp. Head 88.107 tham số; toàn mạng 23.596.139. 38
5.9 DeiT-Small/16: 196 patch và CLS, 12 encoder block, một head 43 lớp. Head 16.555 tham số; toàn mạng 21.682.219. 38
5.10 Validation và test accuracy của tám cấu hình A1, cùng split và augmentation. . 41
5.11 Số tham số được tối ưu trong từng regime; phần backbone freeze không tính vào trainable. 42
5.12 Cross-entropy ResNet-50 theo bốn regime; train nét đứt, validation nét liền. . . 44
5.13 Cross-entropy DeiT-Small/16 theo bốn regime. 45
5.14 Accuracy train/validation ResNet-50 theo epoch. 46
5.15 Accuracy train/validation DeiT-Small/16 theo epoch. 47
5.16 Validation accuracy có/không augmentation, cùng seed 42. 48
5.17 Accuracy trung bình và độ lệch chuẩn mẫu của ba seed; error bar không phải khoảng tin cậy. 49
5.18 ResNet full seed 42: 10 lớp liên quan nhiều ảnh sai, trích chỉ số từ ma trận 43 lớp. 50

5.19 DeiT full seed 42: 10 lớp liên quan nhiều ảnh sai, cùng thang 0–100%. 51
5.20 Ảnh sai ResNet full seed 42, bố cục 2×5; ghi nhãn thật và dự đoán. 52
5.21 Ảnh sai DeiT full seed 42; các mẫu minh họa không thay thế tần suất lỗi toàn tập. 53

6.1 Số bbox thường theo lớp trong train. 55
6.2 Số bbox thường theo lớp trong validation. 55
6.3 Số bbox thường theo lớp trong test. 56
6.4 Phân bố diện tích bbox trên ảnh gốc theo split. 57
6.5 Phân bố tỷ lệ chiều rộng/chiều cao bbox. 57
6.6 Chiều rộng và chiều cao ảnh nguồn. 58
6.7 Ảnh gốc và bbox annotation. 59
6.8 Resize giữ tỷ lệ; tọa độ bbox được đổi cùng ảnh. 60
6.9 Horizontal flip của ảnh và bbox, chỉ áp dụng khi train. 61
6.10 FPN RetinaNet. Shape minh họa tại input 512×512; thí nghiệm dùng resize 600/max 1000. Độ sâu khối thể hiện channels, không dùng cùng tỷ lệ với kích thước không gian. 63
6.11 RetinaNet head: $9 \times 20 = 180$ class logits, $9 \times 4 = 36$ offsets mỗi vị trí; không có logit background riêng. 64
6.12 FPN Faster R-CNN: P2 có độ phân giải cao, P6 lấy từ P5. Shape ở input 512×512 chỉ để đối chiếu cấu trúc. 65
6.13 Faster R-CNN: RPN tạo proposals, RoI Pool gom feature, hai FC trước hai nhánh output. 66
6.14 Tổng loss train của hai detector; độ lớn loss không dùng xếp hạng vì thành phần và chuẩn hóa khác nhau. 69
6.15 Validation VOC mAP50; nét đứt đứng chỉ best epoch của từng model. 70
6.16 Validation COCO-style AP50:95 qua các epoch. 70
6.17 Hai thành phần loss RetinaNet: classification và bbox regression. 71
6.18 Bốn thành phần loss Faster R-CNN: objectness/bbox RPN và classification/bbox RoI. 72
6.19 Đối chiếu các chỉ số AP trên cùng tập test. 73
6.20 Peak allocated VRAM từng worker khi train. 74
6.21 VOC AP50 từng lớp; hai detector dùng chung trục. 76
6.22 COCO-style AP50:95 từng lớp. 76

A.1 Loss E2: Manual/PyTorch với Rows, H=4. 85
A.2 Accuracy E2: Manual/PyTorch với Rows, H=4. 86
A.3 Loss E2: Manual/PyTorch với Patch, H=4. 87
A.4 Accuracy E2: Manual/PyTorch với Patch, H=4. 88

A.5 Loss E2: Manual CNN-stem với H=2, 4 và 8. 89
A.6 Loss E3: LSTM/GRU với Rows. 90
A.7 Accuracy E3: LSTM/GRU với Rows. 91
A.8 Loss E3: LSTM/GRU với Columns. 92
A.9 Accuracy E3: LSTM/GRU với Columns. 93
A.10 Loss E3: LSTM/GRU với Patch. 94
A.11 Accuracy E3: LSTM/GRU với Patch. 95
A.12 E1: ma trận test của Softmax. 96
A.13 E1: ma trận test của MLP. 97
A.14 E1: ma trận test của CNN-A. 98
A.15 E1: ma trận test của CNN-B. 99
A.16 E2: ma trận test của Manual Rows H=4. 100
A.17 E2: ma trận test của PyTorch Rows H=4. 101
A.18 E2: ma trận test của Manual Patch H=4. 102
A.19 E2: ma trận test của PyTorch Patch H=4. 103
A.20 E2: ma trận test của Manual CNN-stem H=4. 104
A.21 E2: ma trận test của PyTorch CNN-stem H=4. 105
A.22 E2: ma trận test của Manual CNN-stem H=2. 106
A.23 E2: ma trận test của Manual CNN-stem H=8. 107
A.24 E3: ma trận test của LSTM Rows. 108
A.25 E3: ma trận test của GRU Rows. 109
A.26 E3: ma trận test của LSTM Columns. 110
A.27 E3: ma trận test của GRU Columns. 111
A.28 E3: ma trận test của LSTM Patch. 112
A.29 E3: ma trận test của GRU Patch. 113
A.30 E3: ma trận test của MLP. 114
A.31 E3: ma trận test của CNN-B. 115
A.32 A2 RetinaNet: ma trận chẩn đoán chuẩn hóa theo hàng. 119
A.33 A2 Faster R-CNN: ma trận chẩn đoán chuẩn hóa theo hàng. 120
A.34 A2: precision–recall của lớp aeroplane. 121
A.35 A2: precision–recall của lớp bicycle. 121
A.36 A2: precision–recall của lớp bird. 122
A.37 A2: precision–recall của lớp boat. 122
A.38 A2: precision–recall của lớp bottle. 123
A.39 A2: precision–recall của lớp bus. 123

A.40 A2: precision–recall của lớp car. 124
A.41 A2: precision–recall của lớp cat. 124
A.42 A2: precision–recall của lớp chair. 125
A.43 A2: precision–recall của lớp cow. 125
A.44 A2: precision–recall của lớp diningtable. 126
A.45 A2: precision–recall của lớp dog. 126
A.46 A2: precision–recall của lớp horse. 127
A.47 A2: precision–recall của lớp motorbike. 127
A.48 A2: precision–recall của lớp person. 128
A.49 A2: precision–recall của lớp pottedplant. 128
A.50 A2: precision–recall của lớp sheep. 129
A.51 A2: precision–recall của lớp sofa. 129
A.52 A2: precision–recall của lớp train. 130
A.53 A2: precision–recall của lớp tvmonitor. 130
A.54 Ảnh test 2012_2008_000016: ground truth. 131
A.55 Ảnh test 2012_2008_000016: RetinaNet. 132
A.56 Ảnh test 2012_2008_000016: Faster R-CNN. 133
A.57 Ảnh test 2012_2009_002530: ground truth. 134
A.58 Ảnh test 2012_2009_002530: RetinaNet. 135
A.59 Ảnh test 2012_2009_002530: Faster R-CNN. 136
A.60 Ảnh test 2012_2011_003253: ground truth. 137
A.61 Ảnh test 2012_2011_003253: RetinaNet. 138
A.62 Ảnh test 2012_2011_003253: Faster R-CNN. 139
A.63 Trường hợp sai 2012_2008_004581: ground truth. 140
A.64 Trường hợp sai 2012_2008_004581: RetinaNet. 141
A.65 Trường hợp sai 2012_2008_004581: Faster R-CNN. 142
A.66 Trường hợp sai 2012_2011_000666: ground truth. 143
A.67 Trường hợp sai 2012_2011_000666: RetinaNet. 144
A.68 Trường hợp sai 2012_2011_000666: Faster R-CNN. 145
A.69 Trường hợp sai 2012_2011_000839: ground truth. 146
A.70 Trường hợp sai 2012_2011_000839: RetinaNet. 147
A.71 Trường hợp sai 2012_2011_000839: Faster R-CNN. 148

Danh sách bảng

1.1 Đối chiếu nội dung kỹ thuật với đề E1–E3, A1 và A2. 1
1.2 Ba tập dữ liệu sử dụng trong báo cáo. 1
1.3 Quy mô các lượt huấn luyện tạo ra số liệu báo cáo. 3

2.1 Kết quả E1 trên validation và 10.000 ảnh test; F1 là macro-F1. 7
2.2 Số tham số và chi phí E1; thời gian gồm train và validation. 7
2.3 Cặp lớp nhầm nhiều nhất trên test; mỗi lớp có 1.000 ảnh. 10

3.1 Kết quả tám cấu hình E2; test dùng đầy đủ 10.000 ảnh, F1 là macro-F1. 14
3.2 Capacity, epoch và thời gian của tám cấu hình E2. 15
3.3 Manual và PyTorch ở H=4 với cùng tokenizer; chênh lệch tính theo điểm phần trăm. . . 15
3.4 H=2/4/8 trên Manual CNN-stem; $d_h = D/H$, giữ $D = 64$. 15
3.5 Entropy attention chuẩn hóa theo head; số đọc từ biểu đồ, làm tròn ba chữ số. 18
3.6 Cặp lớp nhầm nhiều nhất của từng cấu hình E2 trên test. 19

4.1 Metric E3 trên validation và test; F1 là macro-F1. 28
4.2 Số tham số, epoch và chi phí E3; cell được unroll bằng Python/PyTorch, không dùng fused kernel. 28
4.3 LSTM và GRU trên cùng biểu diễn; chênh lệch test tính theo điểm phần trăm. 28
4.4 Recurrent đại diện chọn bằng validation và hai mô hình không hồi tiếp. 29
4.5 Cặp nhầm lớn nhất của tám mô hình E3; mỗi lớp test có 1.000 ảnh. 29

5.1 Split GTSRB sử dụng toàn bộ dữ liệu. 33
5.2 Các mức freeze và số tham số được tối ưu. 39
5.3 Accuracy và macro-F1 của tám cấu hình chính; test có 12.630 ảnh. 40
5.4 Capacity, số epoch/best, thời gian mỗi epoch và peak allocated VRAM. 40
5.5 CNN và Transformer cùng regime; Δ val là DeiT trừ ResNet, tính theo điểm phần trăm từ giá trị chưa làm tròn. 40
5.6 Lợi ích validation của pretraining và unfreeze; mọi chênh lệch tính theo điểm phần trăm. 42
5.7 Thời gian train+validation và inference FP32; CUDA Events batch 32, tách DataLoader. 43
5.8 Sáu thực nghiệm bổ sung trên full pretrained; cấu hình chọn bằng validation. 47
5.9 Augmentation ablation, cùng full mode và seed 42; accuracy tính bằng %. 48
5.10 Full pretrained qua seed 42/43/44, giữ split 42; mean ± std mẫu, ddof=1. 48
5.11 Cặp lớp nhầm nhiều nhất của tám cấu hình chính; ID đi cùng tên lớp. 52
5.12 Một số lớp khó trong hai full model seed 42; support, recall và F1. 52

6.1 Số ảnh và annotation VOC2012. Một bbox có thể vừa difficult vừa truncated. 54
6.2 Kết quả và ablation của FPN trên COCO; số liệu tác giả [5]. 61
6.3 RetinaNet Table 1: ablation trên COCO minival và đánh đổi tốc độ/AP trên test-dev; số liệu tác giả [6]. 62
6.4 Số tham số trainable. FrozenBatchNorm giữ statistics/buffers cố định. 66
6.5 Epoch thực chạy, best epoch, validation VOC mAP50 và số cập nhật SGD. 67
6.6 Test holdout 1.154 ảnh, 2.687 bbox thường. Metric ở thang 0–1. 68
6.7 COCO-style AP theo scale và AR trung bình qua các ngưỡng IoU. 69
6.8 Chi phí trên Tesla T4. Peak là allocated PyTorch từng worker; benchmark hai model lần lượt trên cùng GPU 0. 72
6.9 R=RetinaNet, F=Faster R-CNN; AP là COCO-style AP50:95, F1 tại score 0,30. 75

A.1 Chi tiết lượt train E1. 81
A.2 Chi tiết lượt train E2; ký hiệu M/T và R/P/C như Chương E2. 81
A.3 Chi tiết lượt train E3. 81
A.4 Chi tiết tám lượt train chính A1. 82
A.5 Epoch, cập nhật và peak memory của sáu run mở rộng A1. 82
A.6 Precision/recall/F1 trên test GTSRB, lớp 0–21. 83
A.7 Precision/recall/F1 trên test GTSRB, lớp 22–42. 84
A.8 Độ nhạy A1 với 8 ảnh test trùng train; accuracy tính bằng %. 84
A.9 Số bbox thường từng lớp VOC2012; difficult không nằm trong các cột này. 116
A.10 P/R/F1 tại score 0,30; R=RetinaNet, F=Faster R-CNN, Rec là recall. 117
A.11 AP50/AP75 COCO-style và AP11 VOC07 từng lớp; metric ở thang 0–1. 118

1. Bài toán và thiết kế thực nghiệm

1.1 Mục tiêu và phạm vi

E1–E3 khảo sát cách biểu diễn cùng một ảnh thành vector, feature map, token và chuỗi. A1 mở rộng sang ảnh RGB biển báo để so sánh CNN/Transformer và các mức sử dụng trọng số pretrained. A2 chuyển sang phát hiện nhiều đối tượng trong ảnh, so sánh detector một/hai giai đoạn và phân tích hai paper FPN, Focal Loss. Mỗi chương trình bày dữ liệu, phương pháp, huấn luyện, kết quả và giới hạn theo bố cục báo cáo mẫu.

Bảng 1.1: Đối chiếu nội dung kỹ thuật với đề E1–E3, A1 và A2.

Bài	Yêu cầu	Nội dung thực nghiệm
E1	Softmax, MLP, CNN; loop tự viết; accuracy, capacity, curves, lỗi	4 mô hình, 2 CNN; bảng metric/chi phí, ma trận và ảnh sai.
E2	MSA thủ công/PyTorch; ≥ 2 tokenizer; so sánh từng cặp	2 cách cài đặt × 3 tokenizer, kiểm tra forward/gradient, H=2/4/8.
E3	LSTM/GRU, biểu diễn chuỗi và baseline MLP/CNN	2 cell × 3 cách quét, 2 baseline train độc lập trên cùng split.
A1	CNN/Transformer, scratch/pretrained, 3 mức freeze; metric/chi phí/lỗi	GTSRB 43 lớp, 8 cấu hình chính, 2 no-augmentation, 4 seed repeats.
A2	Detection, ≥ 2 phương pháp; mAP50, AP50:95 nếu được; phân tích paper	VOC2012, RetinaNet/Faster R-CNN, FPN/Focal Loss, AP/AR/F1/FPS và failure cases.

Các nội dung kỹ thuật được tổng hợp trong PDF này; video demo và việc công bố repository/Pages là các sản phẩm nộp riêng. Trang public cung cấp đường dẫn tới notebook, đề bài, báo cáo và nguồn LaTeX.

1.2 Dữ liệu và cách chia tập

Fashion-MNIST [12] gồm ảnh grayscale 28×28 của 10 loại sản phẩm: T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag và Ankle boot. Từ 60.000 ảnh train nguồn, lấy 600 ảnh/lớp làm validation với seed 42; giữ nguyên official test 10.000 ảnh.

Bảng 1.2: Ba tập dữ liệu sử dụng trong báo cáo.

Bài	Dataset	Lớp	Train	Val	Test
E1–E3	Fashion-MNIST	10	54.000	6.000	10.000
A1	GTSRB	43	31.380	7.829	12.630
A2	VOC2012	20	9.232	1.154	1.154

Fashion-MNIST có 5.400/600/1.000 ảnh mỗi lớp ở train/val/test. Pixel chuyển về $[0, 1]$, chuẩn hóa bằng mean 0,285886 và std 0,352960 tính từ train; không augmentation. E1–E3 dùng cùng split fingerprint:

bd9f3884131e411a26892e15ff685f2849
216340505ea615f3fb3b901e30fe80

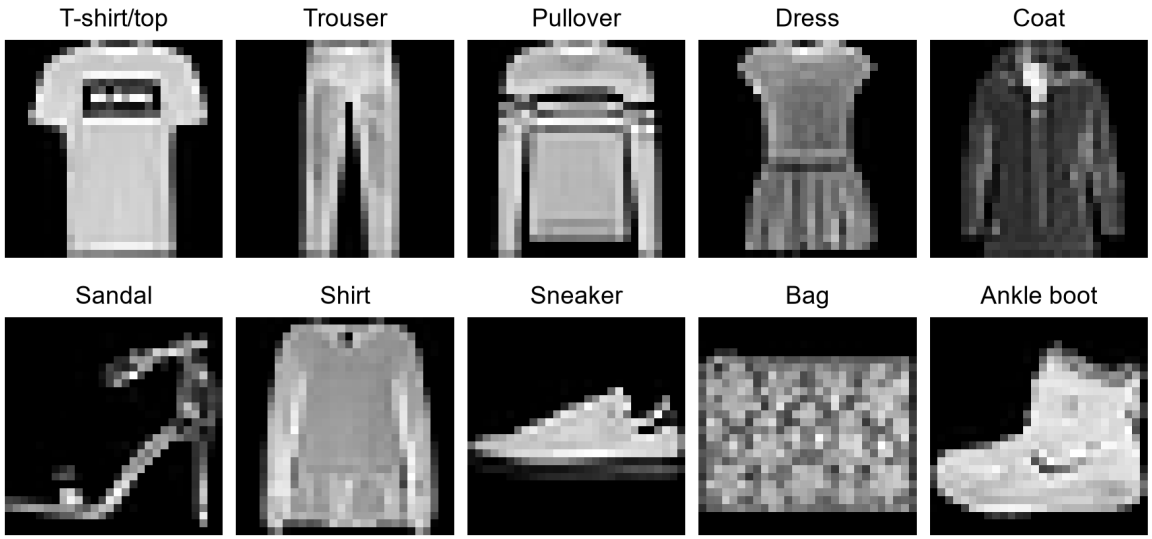

Hình 1.1: Ảnh đại diện mười lớp Fashion-MNIST, lấy trực tiếp từ dữ liệu train.

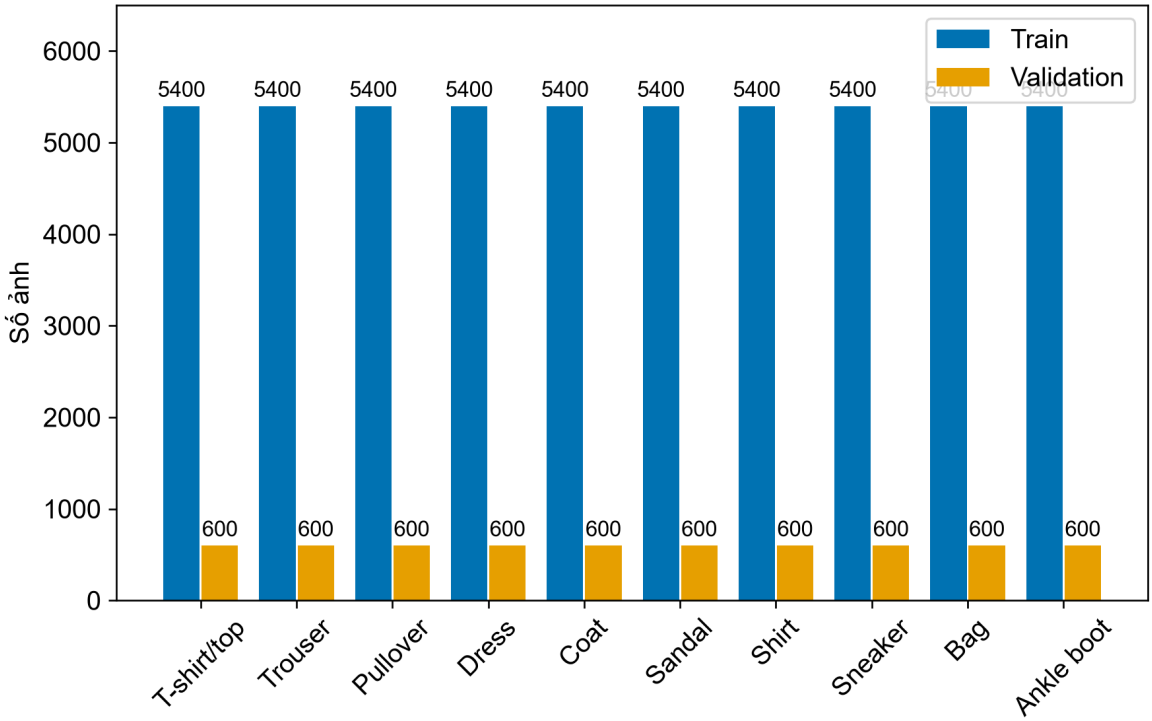

Hình 1.2: Phân bố Fashion-MNIST: mỗi lớp có 5.400 ảnh train và 600 ảnh validation.

GTSRB chia theo track để hạn chế các frame cùng biển vật lý rơi vào cả train và validation.

VOC2012 chia theo ảnh; test là holdout nội bộ. Chi tiết nhãn, augmentation, nguồn tải và giới hạn độc lập dữ liệu được trình bày ở từng chương và README dataset.

1.3 Môi trường và quy tắc đánh giá

E1–E3/A1 chạy với Python 3.14.7, PyTorch 2.11.0+cu128, torchvision 0.26.0+cu128, NumPy 2.5.2, Matplotlib 3.11.2 và Pillow 12.3.0 chạy trên Windows, GPU NVIDIA RTX A3000 12 GB Laptop, CUDA 12.8. A2 chạy trên Kaggle với hai Tesla T4, mỗi GPU 14,6 GiB khả dụng; metadata notebook ghi Python 3.13.15. Phiên bản thư viện A2 không được ghi trong output đã lưu. Hai model train song song trên hai GPU riêng, test/benchmark lần lượt trên cùng GPU 0. DataLoader workers 0 ở các bài. Training loop thực hiện forward, loss, backward và optimizer step; AMP/GradScaler hỗ trợ train, validation/test không tính gradient.

Với các bài phân loại E1–E3/A1, cross-entropy tính trực tiếp trên logits:

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N} \log \frac{\exp z_{i,y_i}}{\sum_{c=1}^{C} \exp z_{i,c}}. \tag{1.1}$$

Softmax chỉ cần khi diễn giải xác suất; argmax logits cho cùng nhãn. Loss được tổng hợp theo số ảnh. Accuracy là tỷ lệ dự đoán đúng; $F1_c = 2P_cR_c/(P_c + R_c)$, macro-F1 trung bình đều qua các lớp. Ma trận có hàng là GT, cột là prediction; phần trăm chuẩn hóa theo hàng.

E1–E3 dừng sớm theo validation loss, patience 4 và min-delta 10^{-4}. A1 dùng patience 2 và min-delta 10^{-3} theo validation loss. Checkpoint phân loại giữ validation loss nhỏ nhất; đại diện/ablation chọn bằng validation accuracy, macro-F1 rồi loss. A2 chọn weights và dừng sớm theo validation VOC mAP50, patience 2, min-delta 10^{-3}. Cách matching và detection metrics trình bày ở Chương 6. Mọi lựa chọn cấu hình dùng validation trước khi đánh giá test.

Bảng 1.3: Quy mô các lượt huấn luyện tạo ra số liệu báo cáo.

Bài	Lượt train	Epoch	CUDA updates	AMP skips
E1	4	64	27.008	0
E2	8	177	74.693	1
E3	8	168	70.896	0
A1	14	94	23.124	0
A2	2	38	14.630	0
Tổng	36	541	210.351	1

AMP skips là các optimizer steps bị scaler bỏ qua khi gradient không hữu hạn; không tính chúng vào updates thực tế. Train accuracy được đo khi weights đang cập nhật, có dropout/augmentation; không xem chênh lệch train–validation như hai phép đo eval hoàn toàn tương đương. Thời gian train + validation không gồm test/vẽ hình. Peak memory dùng torch.cuda.max_memory_allocated, không phải reserved hoặc tổng VRAM máy.

Mỗi notebook tự dựng dataset, model và loop, không đọc code/checkpoint của notebook khác. Mỗi thí nghiệm giữ best weights trong model/<bài>/<thí nghiệm>/latest.pt; chỉ thay file khi validation cải thiện. Run All nạp file này nếu có, nếu không thì khởi tạo theo seed. Optimizer, lịch learning rate và bộ đếm epoch/dừng sớm bắt đầu cho lượt train hiện tại. Bảng và hình được lưu trong output cell; A2 Kaggle xuất thêm PNG/CSV và lịch sử dưới /kaggle/working để tải về. Kích thước tensor trên sơ đồ dùng thứ tự $H \times W \times C$ cho ảnh/feature map, $N \times D$ cho token; batch được lược để dễ đọc. Mặt trước biểu diễn không gian, phần sâu và độ dày nét gợi số channels; sơ đồ không dùng một tỷ lệ hình học chung.

2. E1: Softmax, MLP và CNN

2.1 Mục tiêu và kiến trúc

E1 so sánh classifier tuyến tính, MLP và CNN trên cùng Fashion-MNIST. Softmax dùng vector flatten 784 chiều; MLP thêm phi tuyến; CNN giữ cấu trúc không gian trước khi gom feature. Hai CNN giúp phân biệt số tham số và chất lượng: CNN-A có head lớn, CNN-B dùng global average pooling.

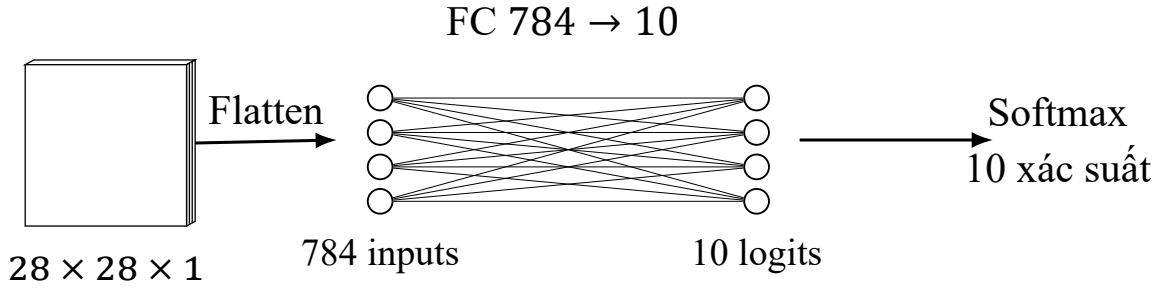

Hình 2.1: Softmax classifier: không Conv, một FC; 7.850 tham số.

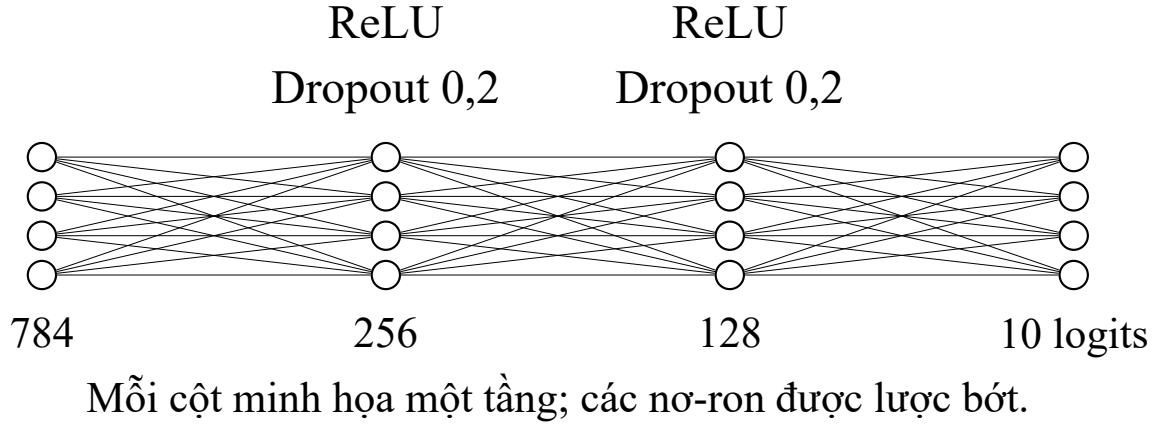

Hình 2.2: MLP: ba FC, hai tầng ẩn; 235.146 tham số.

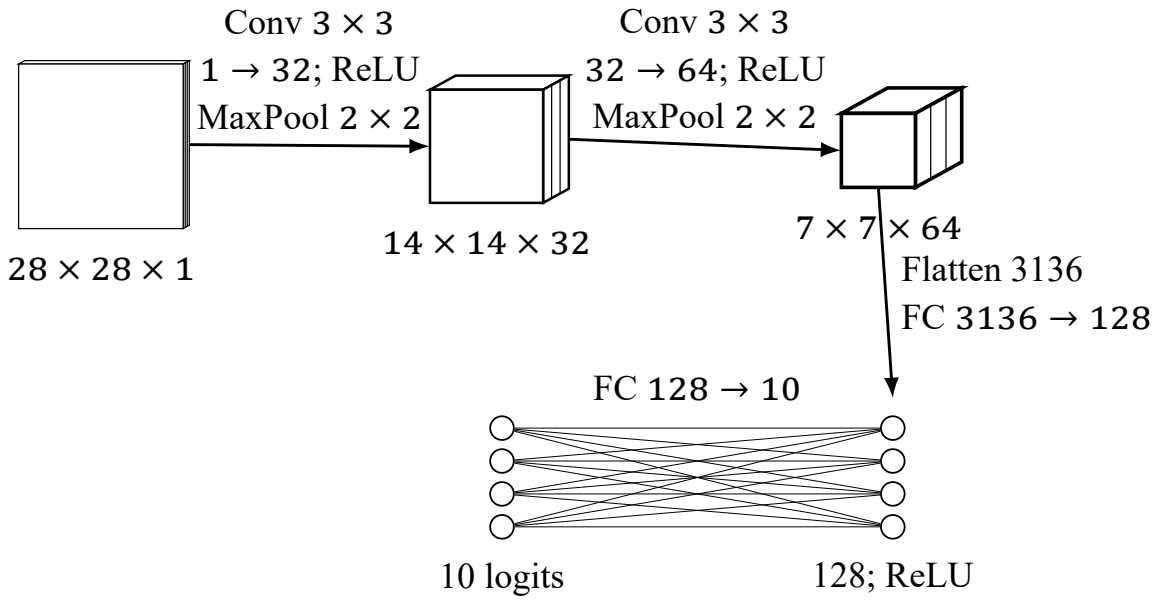

Hình 2.3: CNN-A: hai Conv, hai MaxPool, hai FC; 421.642 tham số. Conv stride 1, padding 1, có bias.

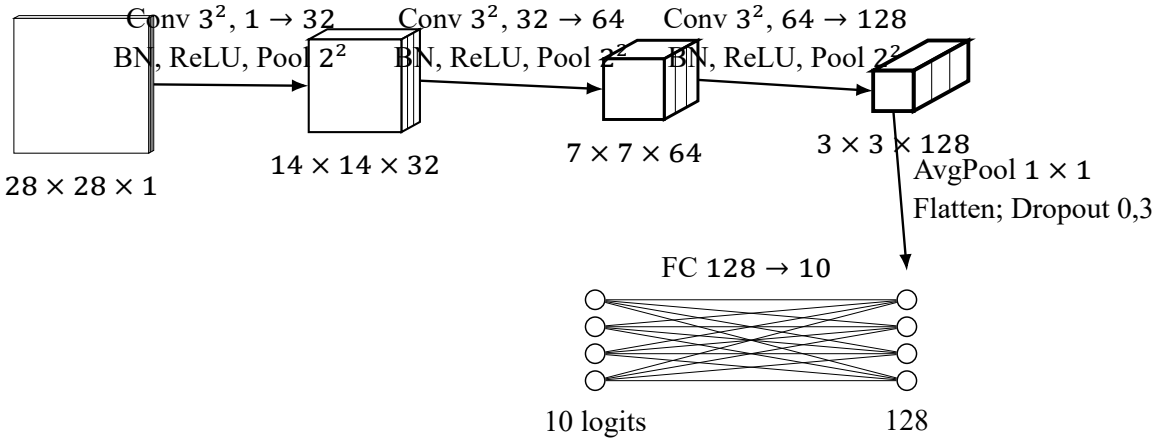

Hình 2.4: CNN-B: ba Conv/BN/MaxPool, một FC; 94.186 tham số. Conv stride 1, padding 1, không bias. Kích thước sau pool thứ ba là 3×3.

Ký hiệu 3^2 chỉ kernel 3×3; chiều batch được lược khỏi sơ đồ. CNN-A dành 401.536 tham số cho FC $3136 \rightarrow 128$, khoảng 95,2% tổng số tham số. CNN-B thay head này bằng average pooling, nên ít tham số hơn dù có thêm một Conv.

2.2 Huấn luyện

AdamW learning rate 10^{-3}, weight decay 10^{-4}, batch 128, tối đa 100 epoch. Mỗi epoch dùng 422 batch train, 47 batch validation; test có 79 batch và giữ batch cuối. Vòng lặp tự viết gồm forward, cross-entropy, backward và optimizer step; train dùng AMP. Dừng sau bốn epoch không cải thiện validation loss ít nhất 10^{-4}; trọng số đánh giá là checkpoint có validation loss nhỏ nhất. Không augmentation hoặc scheduler.

2.3 Kết quả định lượng và capacity

Bảng 2.1: Kết quả E1 trên validation và 10.000 ảnh test; F1 là macro-F1.

Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
Softmax	86,04	85,05	0,8495	84,11	0,8401	0,4431
MLP	91,58	89,47	0,8951	89,45	0,8948	0,3142
CNN-A	94,61	92,00	0,9203	91,66	0,9169	0,2339
CNN-B	93,63	91,93	0,9195	91,45	0,9144	0,2333

Bảng 2.2: Số tham số và chi phí E1; thời gian gồm train và validation.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
Softmax	7.850	12/8	16,35	1,363	18
MLP	235.146	20/16	44,87	2,244	22
CNN-A	421.642	12/8	38,76	3,230	50
CNN-B	94.186	20/16	78,04	3,902	56

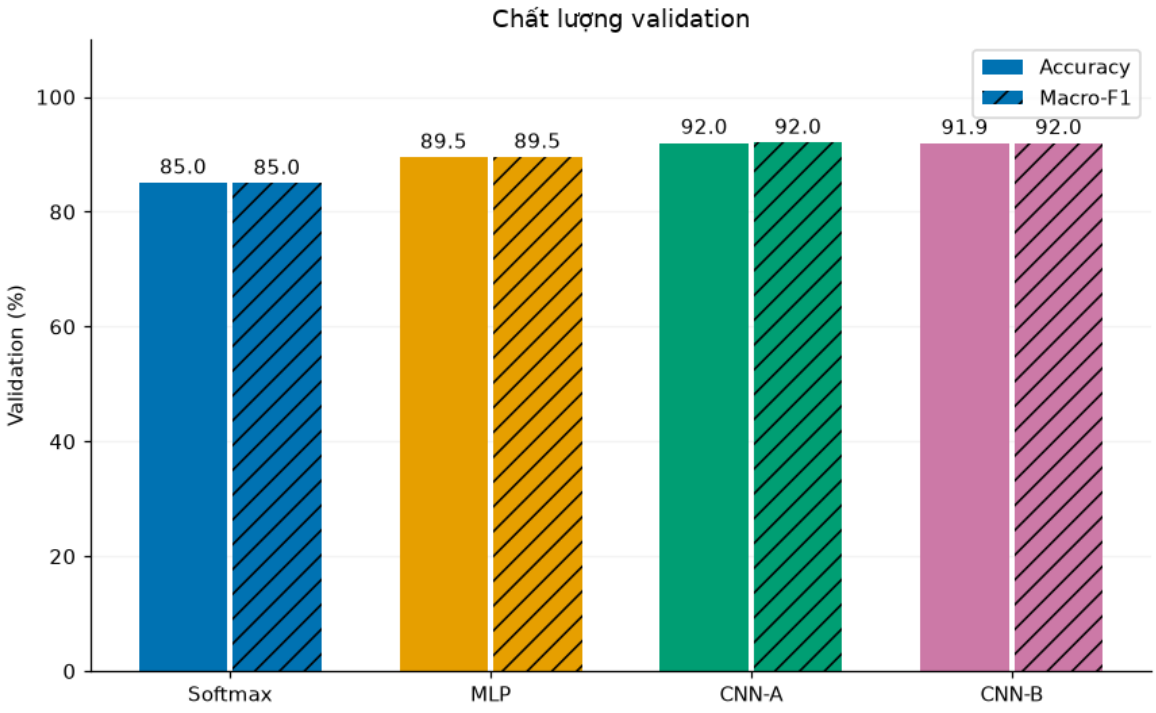

Hình 2.5: Accuracy và macro-F1 trên validation, cùng thang phần trăm.

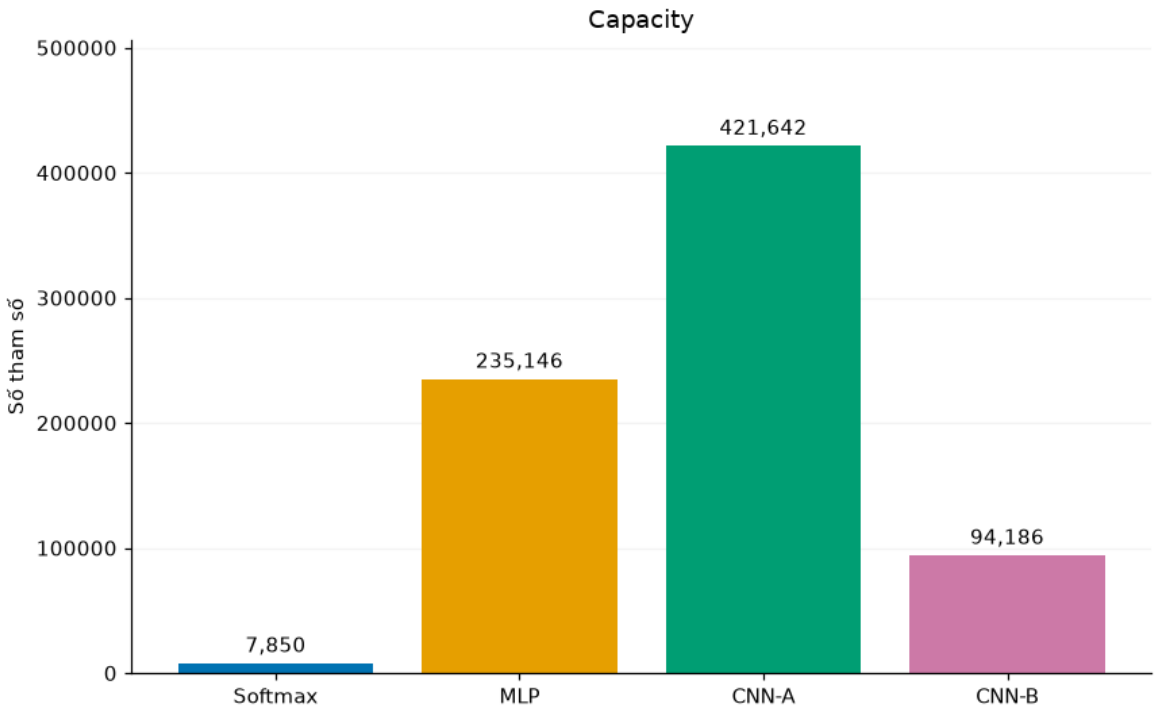

Hình 2.6: Số tham số của bốn mô hình E1.

MLP đạt test accuracy 89,45%, cao hơn Softmax 5,34 điểm phần trăm. Hai CNN đạt 91,66% và 91,45%, hơn MLP lần lượt 2,21 và 2,00 điểm. Phi tuyến giúp MLP biểu diễn ranh giới phức tạp hơn; convolution bổ sung khả năng học đặc trưng không gian và chia sẻ trọng số.

CNN-A đạt validation cao nhất (92,00%) và test cao nhất (91,66%). CNN-B dùng ít tham số hơn 4,48 lần nhưng thấp hơn 0,21 điểm trên test. CNN-A tập trung khoảng 95,2% tham số ở FC $3136 \rightarrow 128$; CNN-B thay head lớn bằng average pooling. Hai mô hình còn khác độ sâu và BatchNorm, nên chênh lệch này không phải tác động riêng của số tham số.

2.4 Đường cong học và phân tích lỗi

Train–validation gap tại checkpoint của Softmax, MLP, CNN-A và CNN-B lần lượt 0,99; 2,11; 2,61; 1,70 điểm phần trăm. Loss train tiếp tục giảm trong khi loss validation dao động, cho thấy không nên chọn trọng số chỉ theo mức khớp train. Train accuracy được đo trong train mode, với dropout/BatchNorm tùy mô hình; validation dùng eval mode nên gap chỉ là chỉ báo tham khảo.

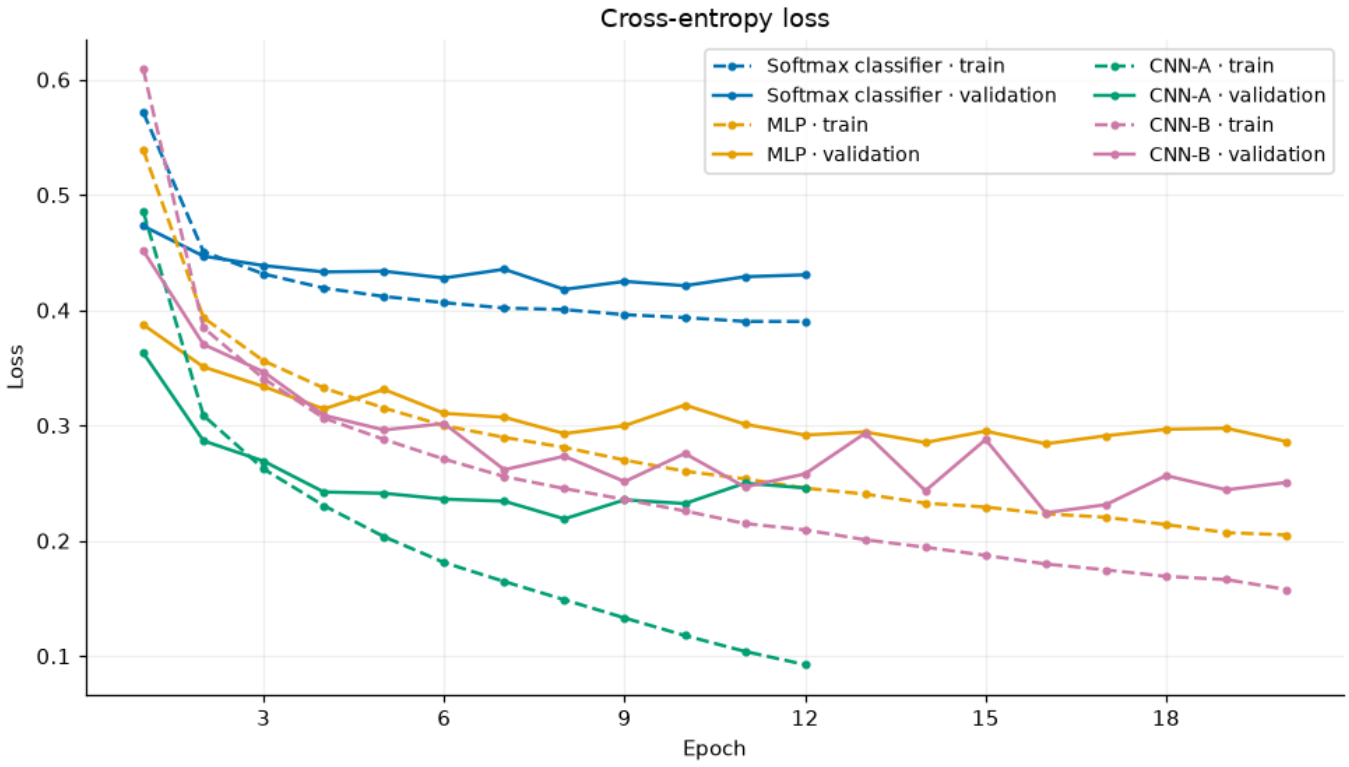

Hình 2.7: Cross-entropy của E1: nét đứt train, nét liền validation; mỗi đường có tên mô hình.

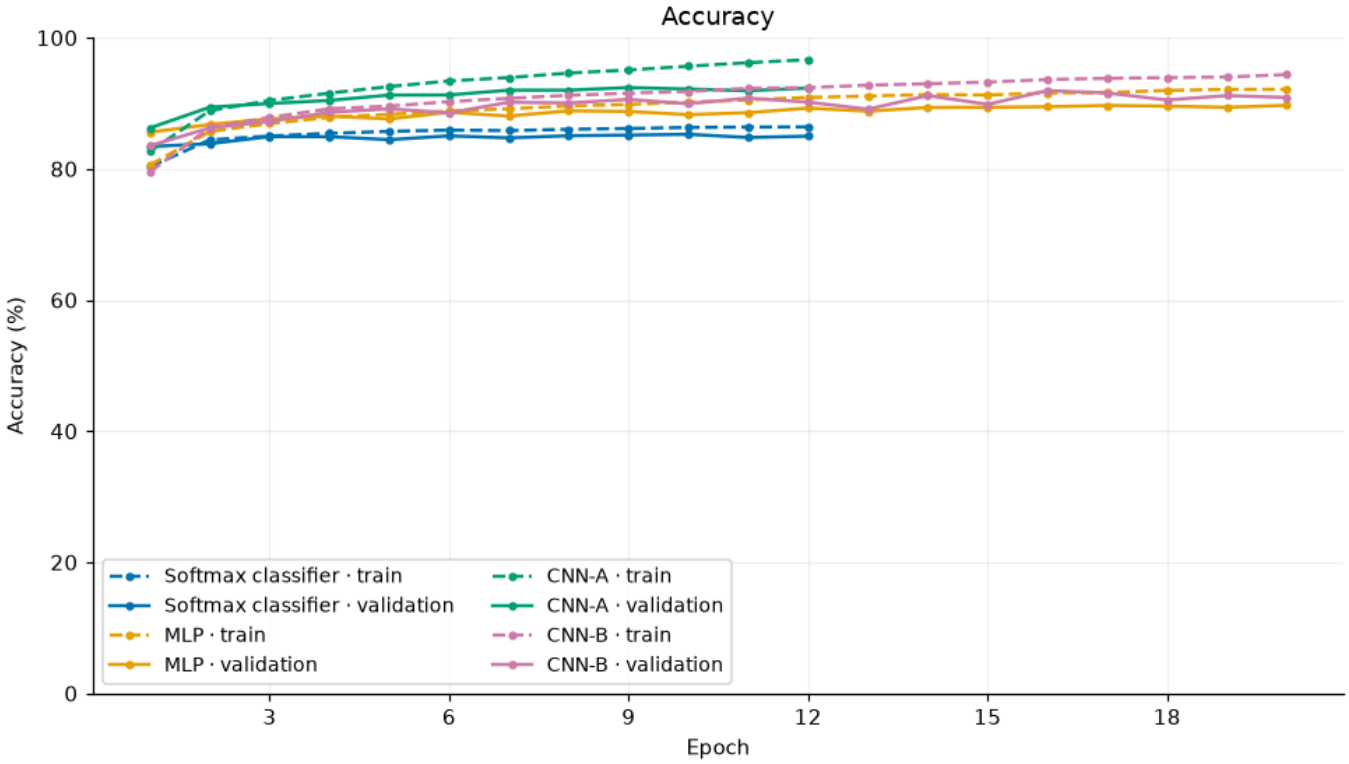

Hình 2.8: Accuracy theo epoch của bốn mô hình E1.

Bảng 2.3: Cặp lớp nhầm nhiều nhất trên test; mỗi lớp có 1.000 ảnh.

Model	Thật → dự đoán	Số ảnh	% lớp thật
Softmax	Pullover → Coat	136	13,6%
MLP	T-shirt/top → Shirt	124	12,4%
CNN-A	T-shirt/top → Shirt	137	13,7%
CNN-B	Shirt → Coat	103	10,3%

Shirt là lớp khó: recall làm tròn trên ma trận lần lượt 57%, 75%, 79%, 73%. Softmax nhầm Pullover thành Coat 136 ảnh; MLP và CNN-A nhầm T-shirt/top thành Shirt 124/137 ảnh. CNN-B nhầm Shirt thành Coat 103 ảnh. Vì vậy accuracy chung cần đọc cùng recall theo lớp và chiều nhầm. Ma trận riêng của cả bốn mô hình nằm ở Phụ lục. Mỗi ô ghi phần trăm theo lớp thật, làm tròn số nguyên. CNN phù hợp ảnh nhỏ trong thiết lập này; CNN-B tiết kiệm tham số, còn CNN-A cho accuracy cao nhất. Kết quả dùng một seed và một dataset cân bằng, chưa đo độ biến thiên giữa nhiều lượt train.

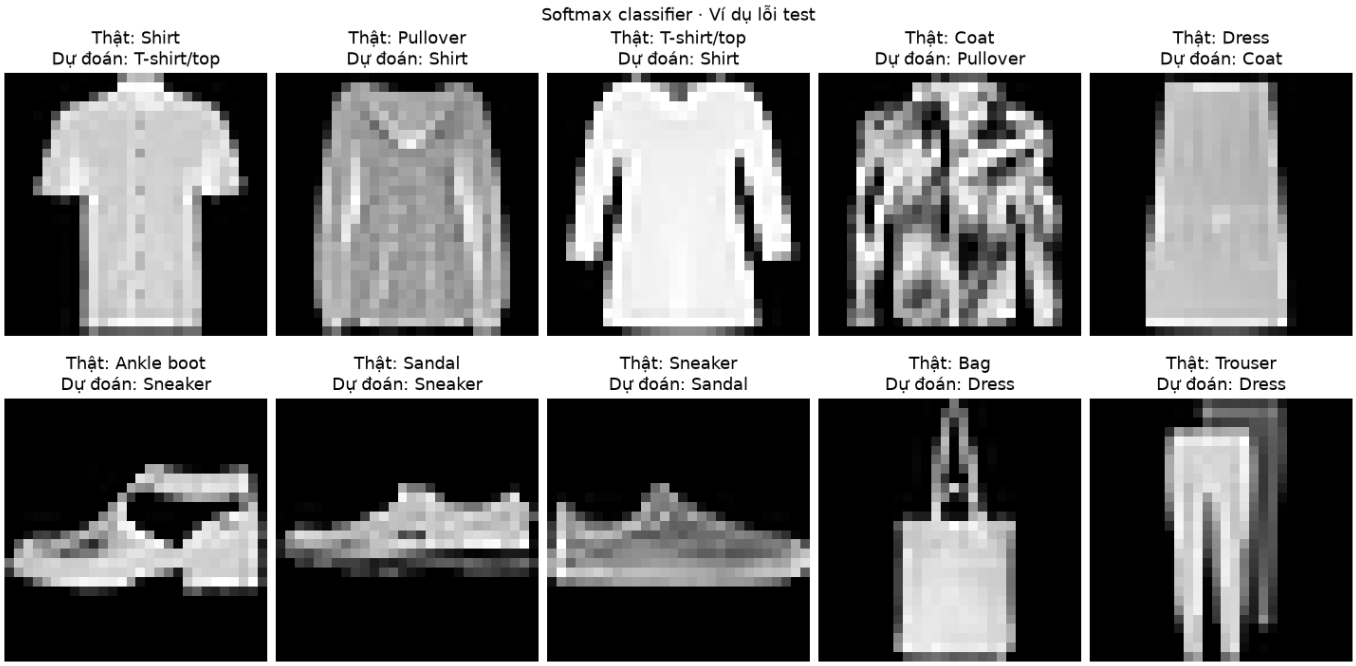

Hình 2.9: Mẫu lỗi Softmax, bố cục 2×5; mỗi ảnh ghi nhãn thật và dự đoán.

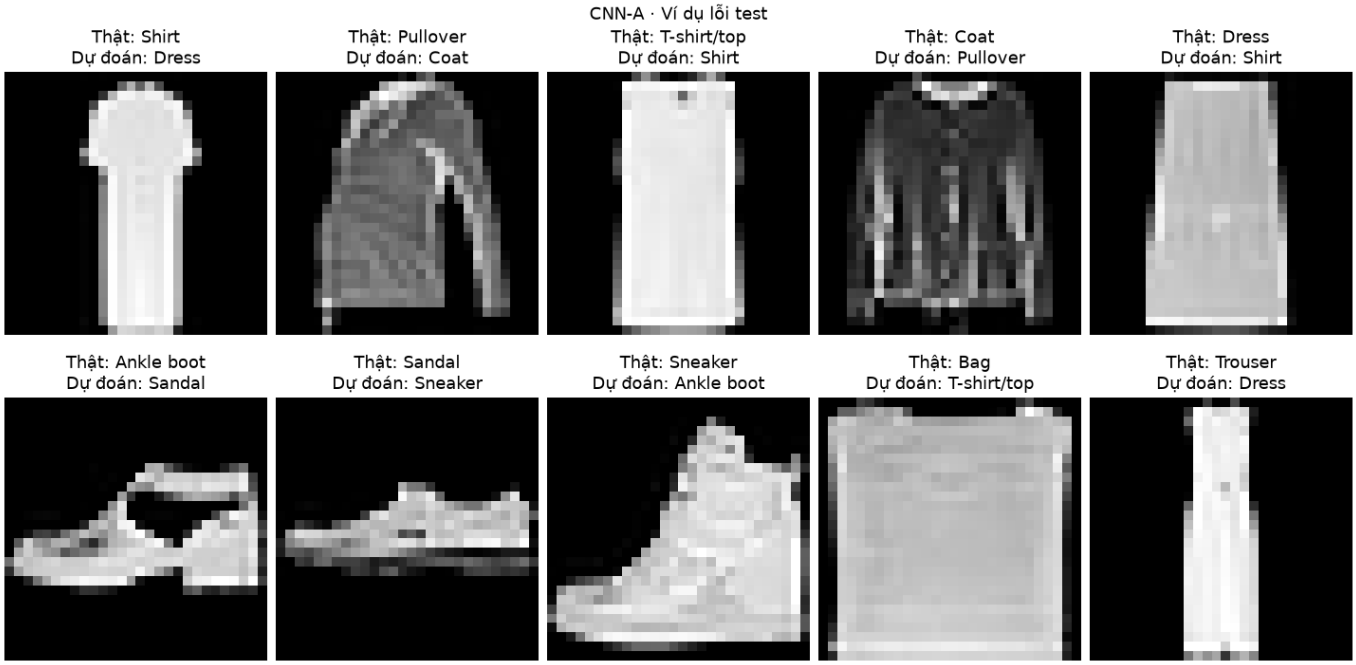

Hình 2.10: Mẫu lỗi CNN-A; các ảnh minh họa không thay thế tần suất từ toàn bộ test.

3. E2: Multi-head self-attention và tokenization

3.1 Mục tiêu và biểu diễn token

E2 hiện thực MSA bằng Linear, reshape, matmul, softmax và concat; bản đối chiếu dùng nn.MultiheadAttention. Encoder và classifier giống nhau giữa hai bản. Ba tokenizer cùng dùng split/normalization Fashion-MNIST ở Chương 1; không sử dụng checkpoint E1.

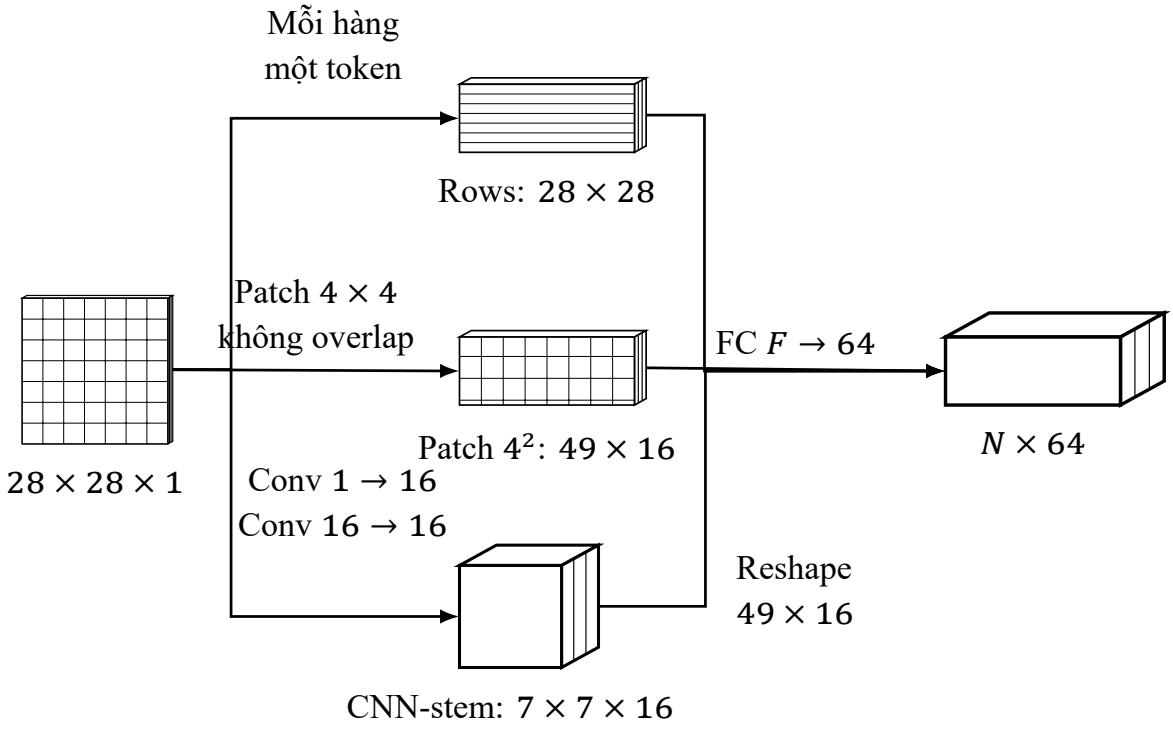

Hình 3.1: Ba tokenizer E2; CNN-stem có hai Conv kernel 3, stride 1, padding 1, bias, ReLU và MaxPool 2 sau mỗi Conv. Rows không có Conv; patch lấy trực tiếp pixel.

Rows có $N = 28, F = 28$; patch/CNN-stem có $N = 49, F = 16$. CNN-stem thêm 2.480 tham số học so với patch cùng chiều feature, nên so sánh tokenizer thay đổi cả inductive bias và capacity.

3.2 Kiến trúc encoder và MSA

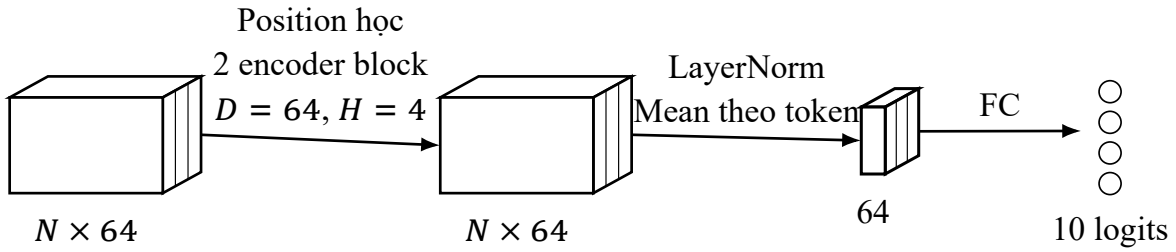

Hình 3.2: Classifier E2: một FC embedding, hai encoder block và một FC head; không CLS token.

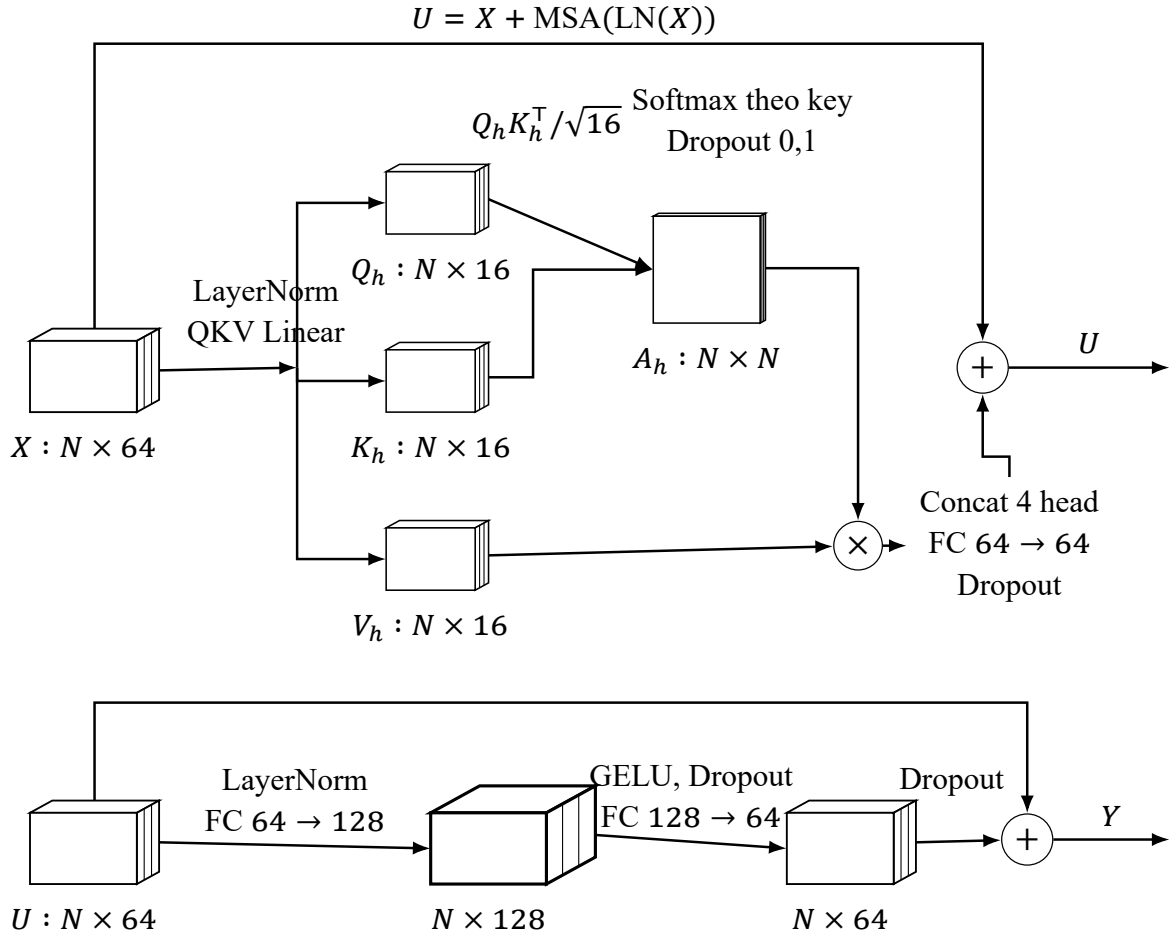

Hình 3.3: Một pre-norm encoder block: hai projection MSA và hai FC trong FFN, tổng bốn ánh xạ Linear/block. Đường ngoài là residual.

Với $D = 64, H = 4, d_h = 16$, QKV reshape thành $B \times H \times N \times d_h$:

$$A_h = \text{softmax}_{\text{key}}\left(Q_h K_h^\top / \sqrt{d_h}\right), \qquad Y = \text{Concat}_{h=1}^{H}(A_h V_h) W_O + b_O. \tag{3.1}$$

Attention dropout 0,1 áp dụng lên A_h trước khi nhân V_h; output dropout nằm trên nhánh residual. Mỗi block có FFN $64 \to 128 \to 64$, GELU, dropout 0,1. Toàn classifier có 10 ánh xạ Linear theo cách đếm QKV gộp là một Linear: 1 embedding + 2×4 trong encoder + 1 head. CNN-stem bổ sung 2 Conv.

Cặp manual/PyTorch copy toàn bộ weights khởi tạo, gồm tokenizer, position, FFN và head. Kiểm tra CUDA float64 với dropout tắt đạt sai số forward tối đa $1,665 \times 10^{-16}$; các gradient input/weight/bias khớp theo kiểm tra. Parity xác nhận phép toán; không đảm bảo dropout/RNG và đường tối ưu của hai lần training giống nhau.

3.3 Thiết lập huấn luyện và tám cấu hình

AdamW learning rate 10^{-3}, weight decay 10^{-4}, batch 128, tối đa 100 epoch; early stopping dùng validation loss, patience 4, min-delta 10^{-4}. Checkpoint có validation loss nhỏ nhất được dùng để test. Sáu cấu hình chính là Manual/PyTorch × Rows/Patch/CNN-stem với H=4. CNN-stem được chọn từ các cấu hình Manual bằng validation, rồi thử thêm H=2 và H=8; giữ $D = 64$, tương ứng mỗi head có 32/16/8 chiều.

Ký hiệu bảng: M=Manual, T=PyTorch; R=Rows, P=Patch, C=CNN-stem; số cuối là số head. M-C4 là Manual CNN-stem với bốn head.

3.4 Kết quả và hai phép so sánh bắt buộc

Bảng 3.1: Kết quả tám cấu hình E2; test dùng đầy đủ 10.000 ảnh, F1 là macro-F1.

Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
M-R4	91,61	89,97	0,8988	89,51	0,8941	0,3050
M-P4	90,39	88,60	0,8861	88,35	0,8837	0,3305
M-C4	92,18	90,65	0,9063	90,50	0,9048	0,2717
T-R4	91,75	89,90	0,8983	89,22	0,8913	0,3054
T-P4	90,33	88,35	0,8833	88,47	0,8849	0,3292
T-C4	92,09	90,47	0,9049	90,17	0,9021	0,2733
M-C2	91,42	90,33	0,9037	90,21	0,9023	0,2792
M-C8	92,13	90,35	0,9031	90,23	0,9020	0,2752

Bảng 3.2: Capacity, epoch và thời gian của tám cấu hình E2.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
M-R4	71.370	20/16	189,93	9,497	43
M-P4	71.946	23/19	243,28	10,577	69
M-C4	74.426	24/20	243,08	10,128	78
T-R4	71.370	20/16	186,63	9,332	47
T-P4	71.946	23/19	242,75	10,554	79
T-C4	74.426	23/19	198,74	8,641	89
M-C2	74.426	22/18	213,65	9,711	70
M-C8	74.426	22/18	215,44	9,793	99

Bảng 3.3: Manual và PyTorch ở H=4 với cùng tokenizer; chênh lệch tính theo điểm phần trăm.

Tokenizer	M val (%)	T val (%)	Δ val (điểm %)	M/T s/epoch
Rows	89,97	89,90	+0,07	9,497 / 9,332
Patch	88,60	88,35	+0,25	10,577 / 10,554
CNN-stem	90,65	90,47	+0,18	10,128 / 8,641

Với cùng tokenizer, Manual cao hơn PyTorch trên validation 0,07; 0,25; 0,18 điểm tương ứng Rows, Patch và CNN-stem. Trên test, chênh lệch là +0,29; $-0,12$; +0,33 điểm. Parity forward/gradient xác nhận phép toán MSA, nhưng một seed không đủ để xếp hạng hai cách cài đặt theo các chênh lệch nhỏ này; dropout và AMP có thể tạo đường tối ưu khác nhau.

CNN-stem đạt validation tốt nhất ở cả hai bản: 90,65% Manual và 90,47% PyTorch. So với Patch, tăng 2,05 và 2,12 điểm; so với Rows, tăng 0,68 và 0,57 điểm. CNN-stem có thêm 2.480 tham số so với Patch, nên lợi ích có thể đến từ cả đặc trưng cục bộ lẫn capacity.

Thời gian mỗi epoch của PyTorch thấp hơn Manual 1,7% với Rows, 0,2% với Patch và 14,7% với CNN-stem trong phép đo này. Rows dùng 28 token, Patch/stem dùng 49; số phần tử attention mỗi head tăng từ 784 lên 2.401 (3,06 lần). Chi phí toàn mạng còn có projections, FFN và CNN; không suy thời gian chỉ từ N^2. Tổng thời gian còn phụ thuộc số epoch dừng sớm.

3.4.1 Ảnh hưởng số head

Bảng 3.4: H=2/4/8 trên Manual CNN-stem; $d_h = D/H$, giữ $D = 64$.

H	d_h	Val (%)	Test (%)	Test F1	Params
2	32	90,33	90,21	0,9023	74.426
4	16	90,65	90,50	0,9048	74.426
8	8	90,35	90,23	0,9020	74.426

H=4 đạt accuracy validation/test cao nhất trong ba lượt. Giữ $D = 64$ nên cả ba cùng 74.426 tham số; tăng số head không đảm bảo kết quả tốt hơn.

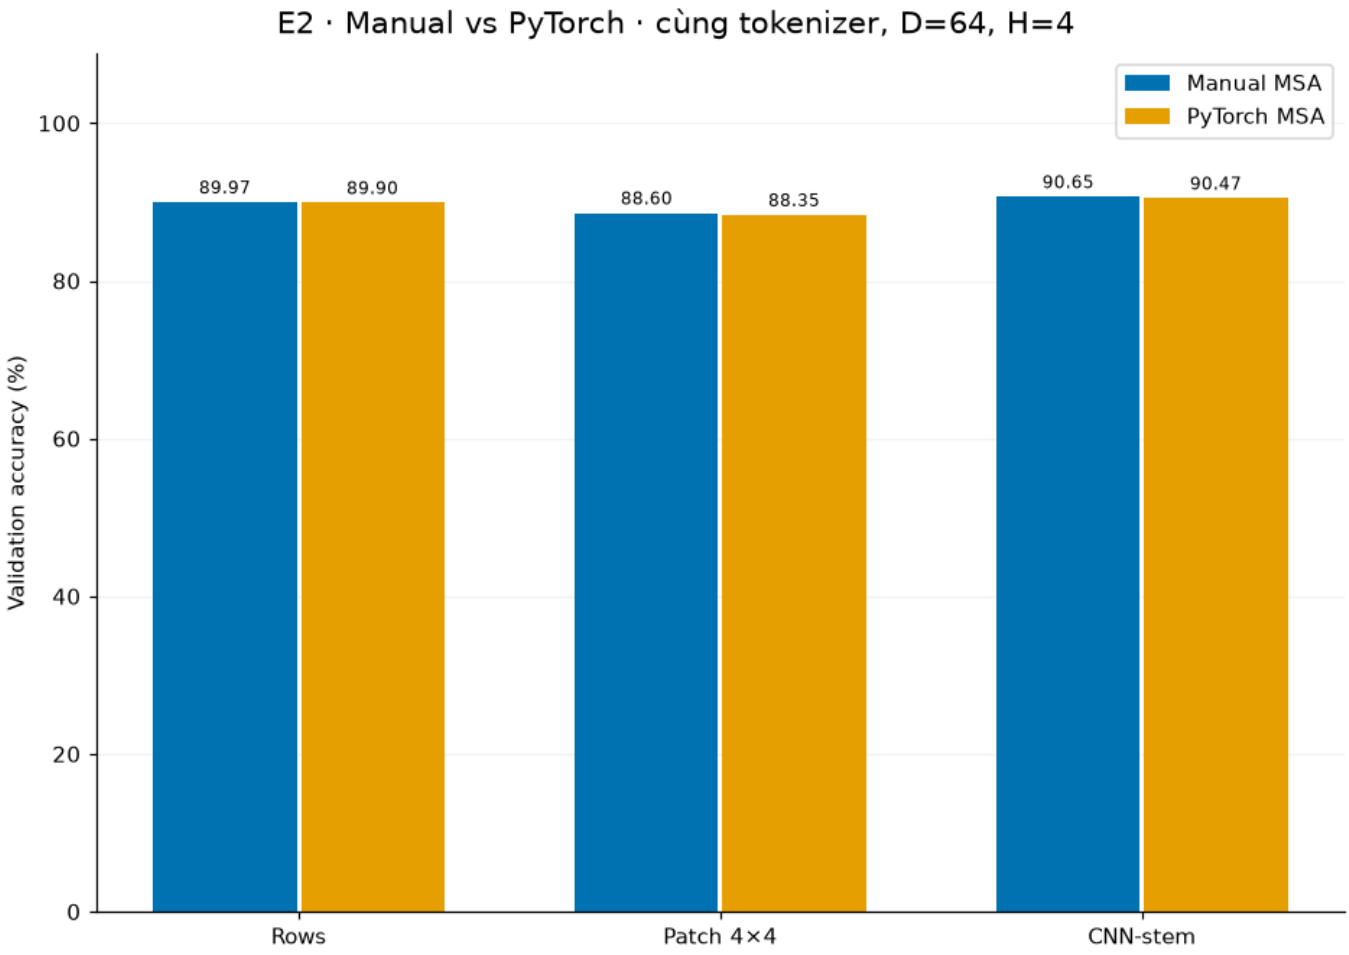

Hình 3.4: So sánh accuracy validation giữa Manual và PyTorch cho từng tokenizer.

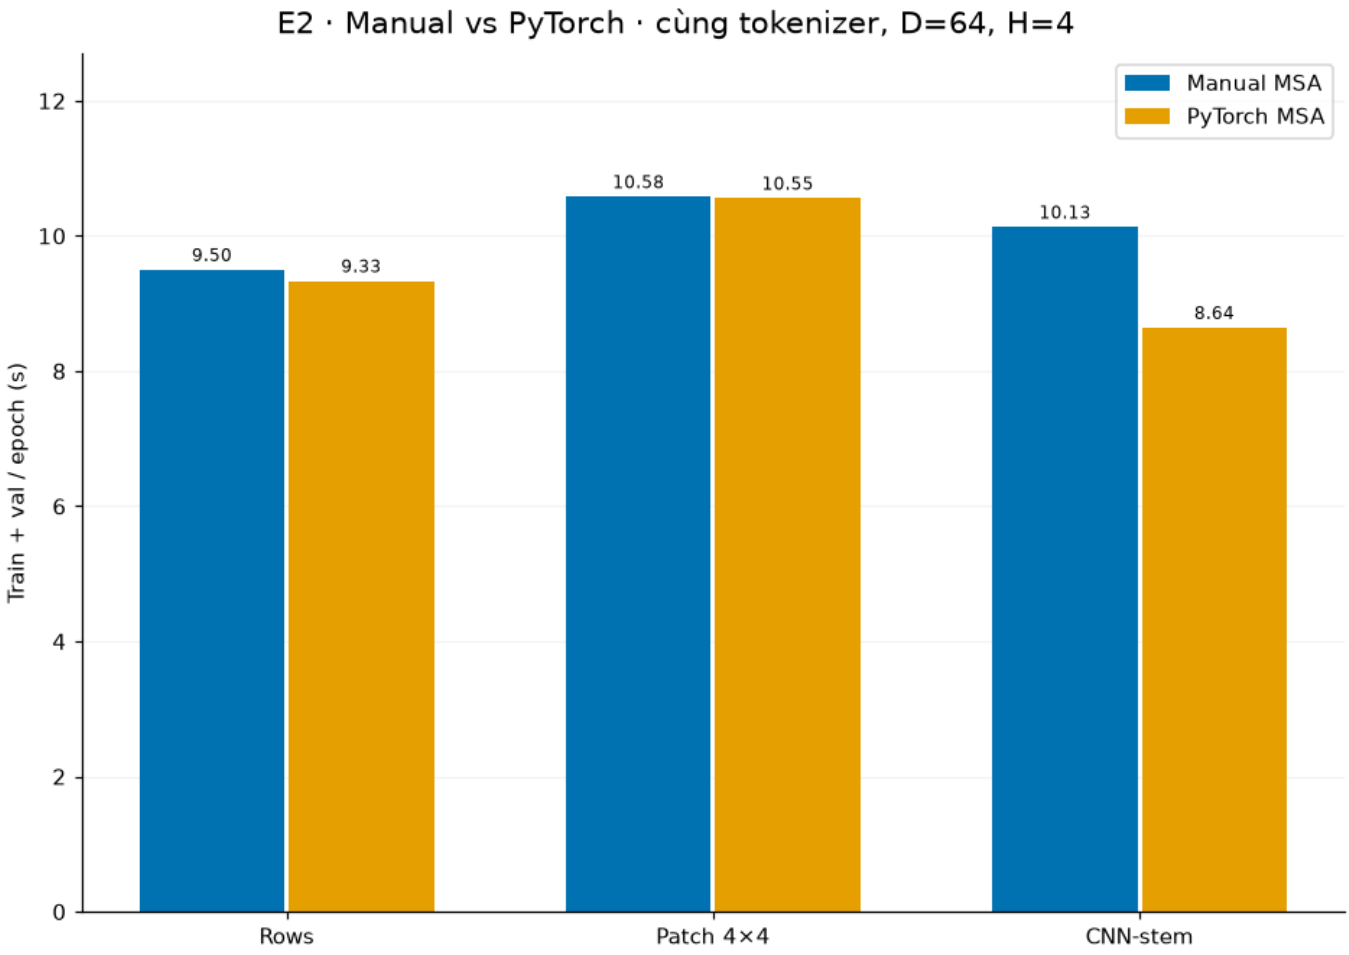

Hình 3.5: Thời gian train và validation trung bình mỗi epoch, cùng protocol và GPU.

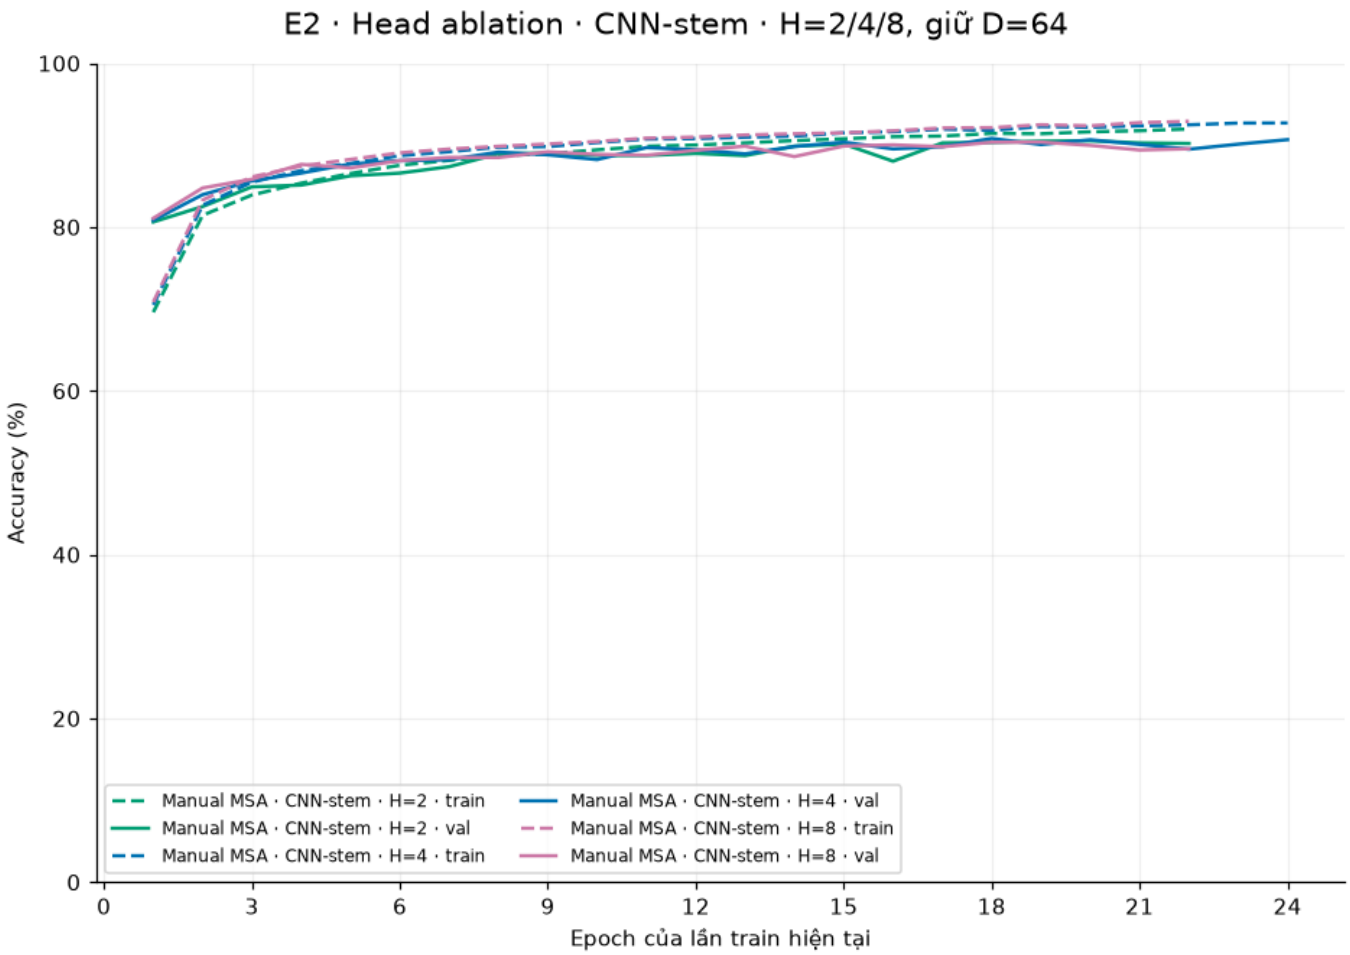

Hình 3.6: Đường cong accuracy của Manual CNN-stem với H=2, 4 và 8.

3.5 Đường cong học, attention và lỗi

Khoảng cách train–validation tại checkpoint nằm trong 1,09–1,98 điểm. Trên CNN-stem, hai bản có quá trình hội tụ gần nhau nhưng validation loss vẫn dao động khi train loss giảm. Đường cong Rows/Patch và loss của thí nghiệm số head được trình bày riêng ở Phụ lục.

Attention lấy từ block cuối của M-C4, trung bình bốn head, gộp 49 token thành bảy nhóm. Hai ảnh validation cố định là Shirt (index 0) và Ankle boot (index 31), đều dự đoán đúng. Tổng mỗi hàng bằng 1 trước khi làm tròn; tổng các ô phần trăm nguyên có thể lệch 100%.

Bảng 3.5: Entropy attention chuẩn hóa theo head; số đọc từ biểu đồ, làm tròn ba chữ số.

Ảnh	H1	H2	H3	H4
Shirt	0,864	0,582	0,658	0,844
Ankle boot	0,326	0,694	0,736	0,698

Entropy thấp hơn cho biết attention tập trung hơn; head 1 của Ankle boot có entropy 0,326 so với 0,864 ở Shirt. Đây là trọng số kết hợp token sau CNN-stem, không phải saliency pixel

hay bằng chứng nhân quả. Hai ảnh chỉ minh họa, không đại diện cho phân bố toàn bộ mười lớp.

Bảng 3.6: Cặp lớp nhầm nhiều nhất của từng cấu hình E2 trên test.

Model	Thật → dự đoán	Số ảnh	% lớp thật
M-R4	Shirt → T-shirt/top	139	13,9%
M-P4	T-shirt/top → Shirt	120	12,0%
M-C4	Shirt → T-shirt/top	94	9,4%
T-R4	Shirt → T-shirt/top	129	12,9%
T-P4	T-shirt/top → Shirt	126	12,6%
T-C4	T-shirt/top → Shirt	151	15,1%
M-C2	T-shirt/top → Shirt	141	14,1%
M-C8	Shirt → T-shirt/top	119	11,9%

M-C4 nhầm Shirt thành T-shirt/top 94 ảnh, ít hơn M-R4 (139 ảnh); T-C4 nhầm chiều ngược T-shirt/top thành Shirt 151 ảnh. Nhóm áo vẫn là nguồn lỗi chính, dù accuracy tổng của CNN-stem cao hơn. Ma trận của tám cấu hình nằm ở Phụ lục. E2 đáp ứng hai cách cài đặt và ba tokenizer; giới hạn là encoder nhỏ, một seed và các tokenizer khác capacity. Không suy kết luận tổng quát về Transformer từ một dataset.

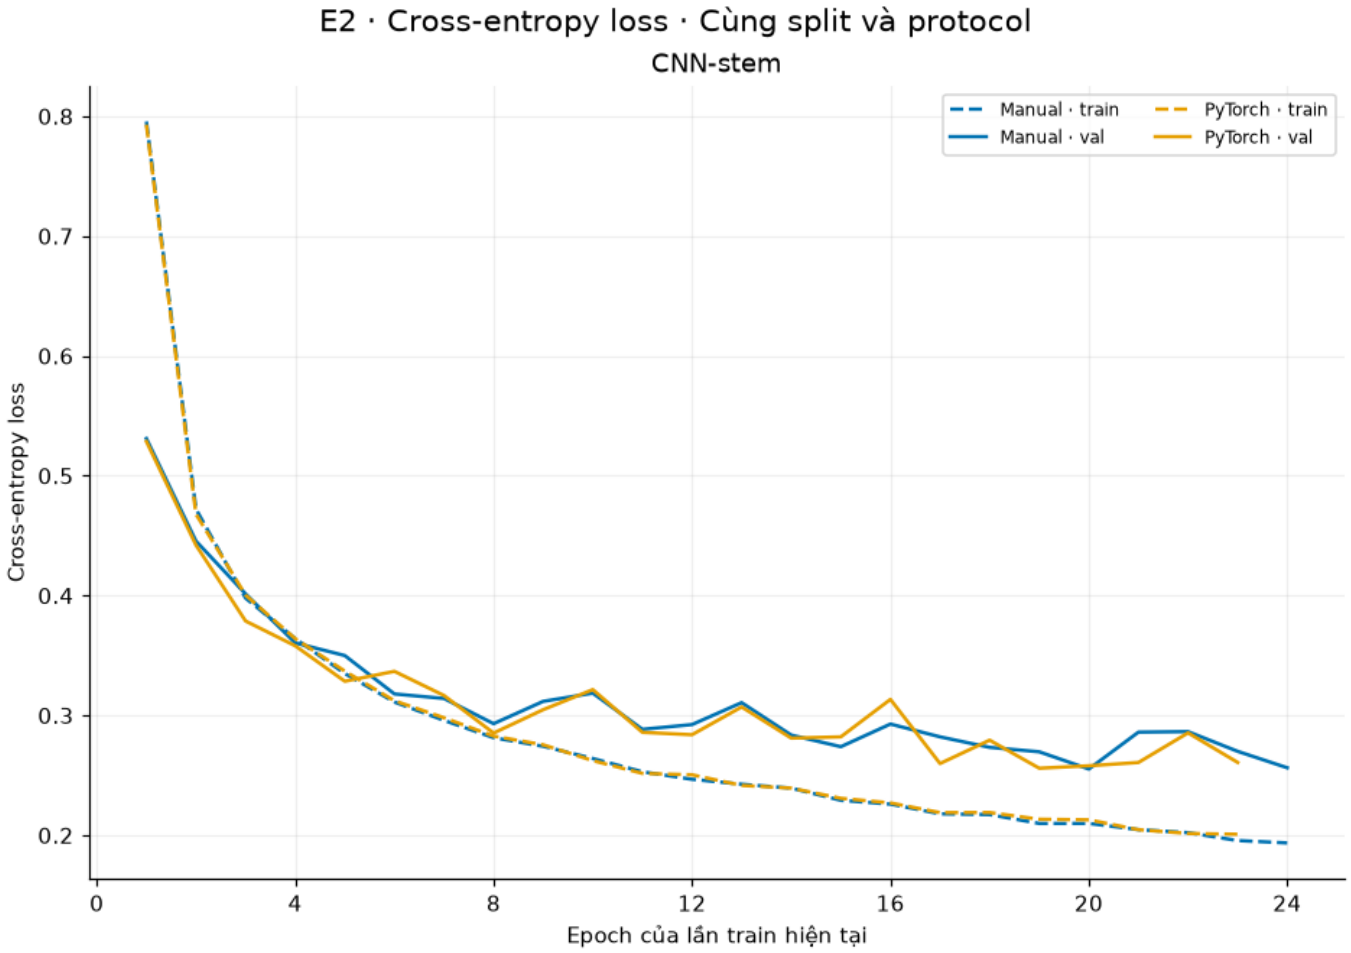

Hình 3.7: Loss của Manual và PyTorch với CNN-stem H=4; nét đứt train, nét liền validation.

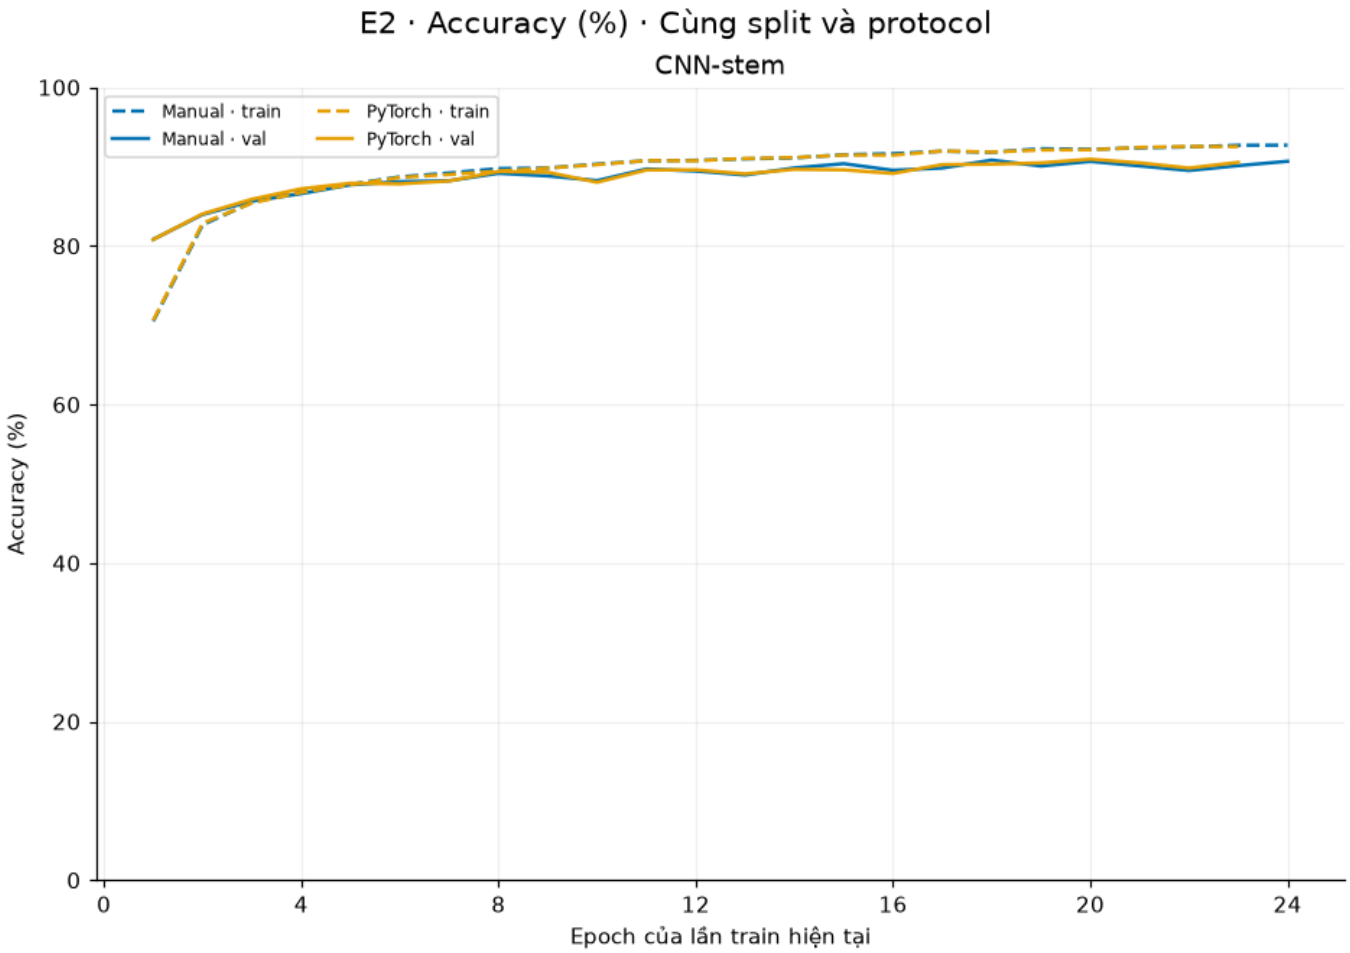

Hình 3.8: Accuracy của Manual và PyTorch với CNN-stem H=4.

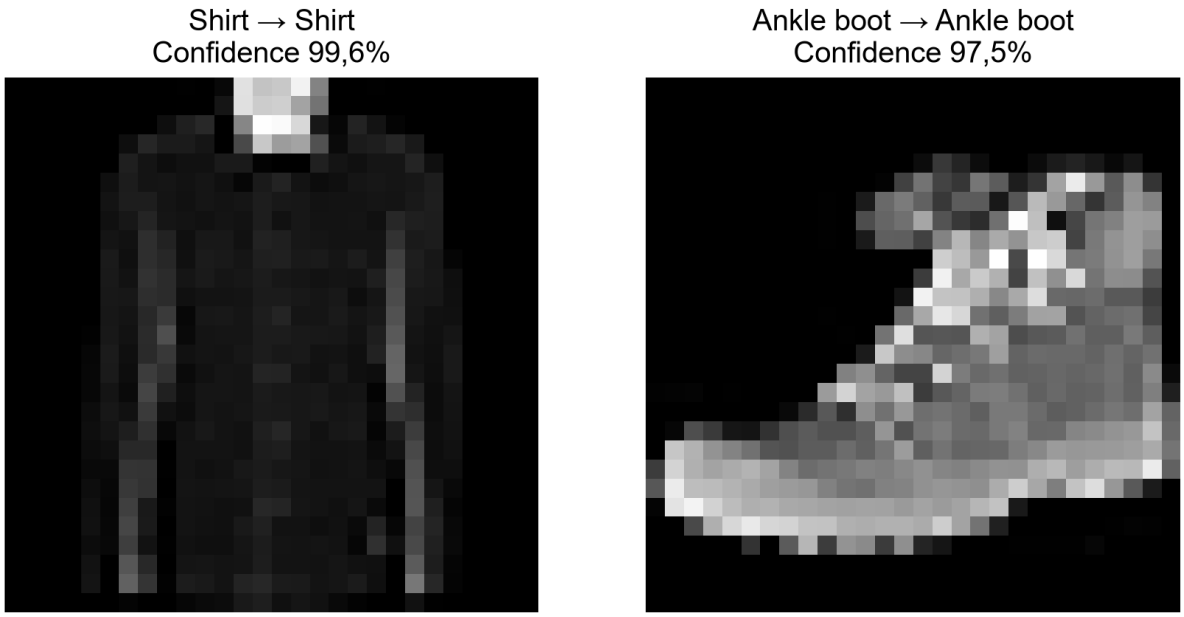

Hình 3.9: Hai ảnh validation dùng để phân tích attention của Manual CNN-stem H=4: Shirt (index 0) và Ankle boot (index 31). Confidence lấy từ output đã lưu.

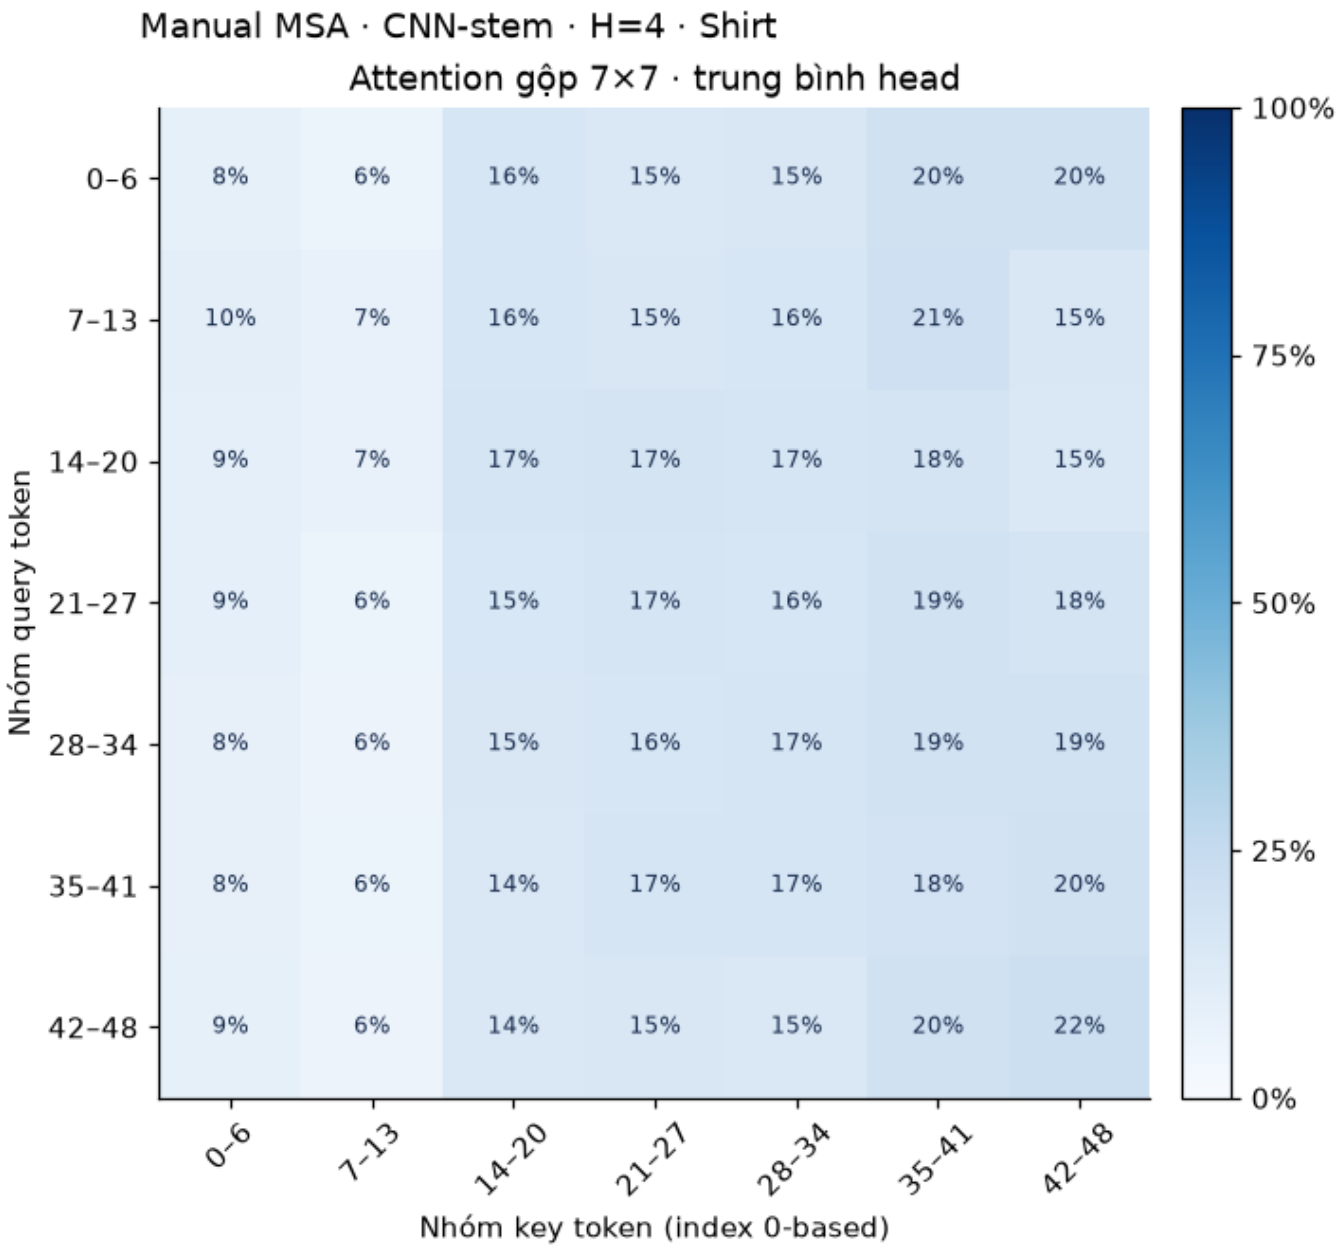

Hình 3.10: Attention gộp của ảnh Shirt; hàng là nhóm query, cột là nhóm key.

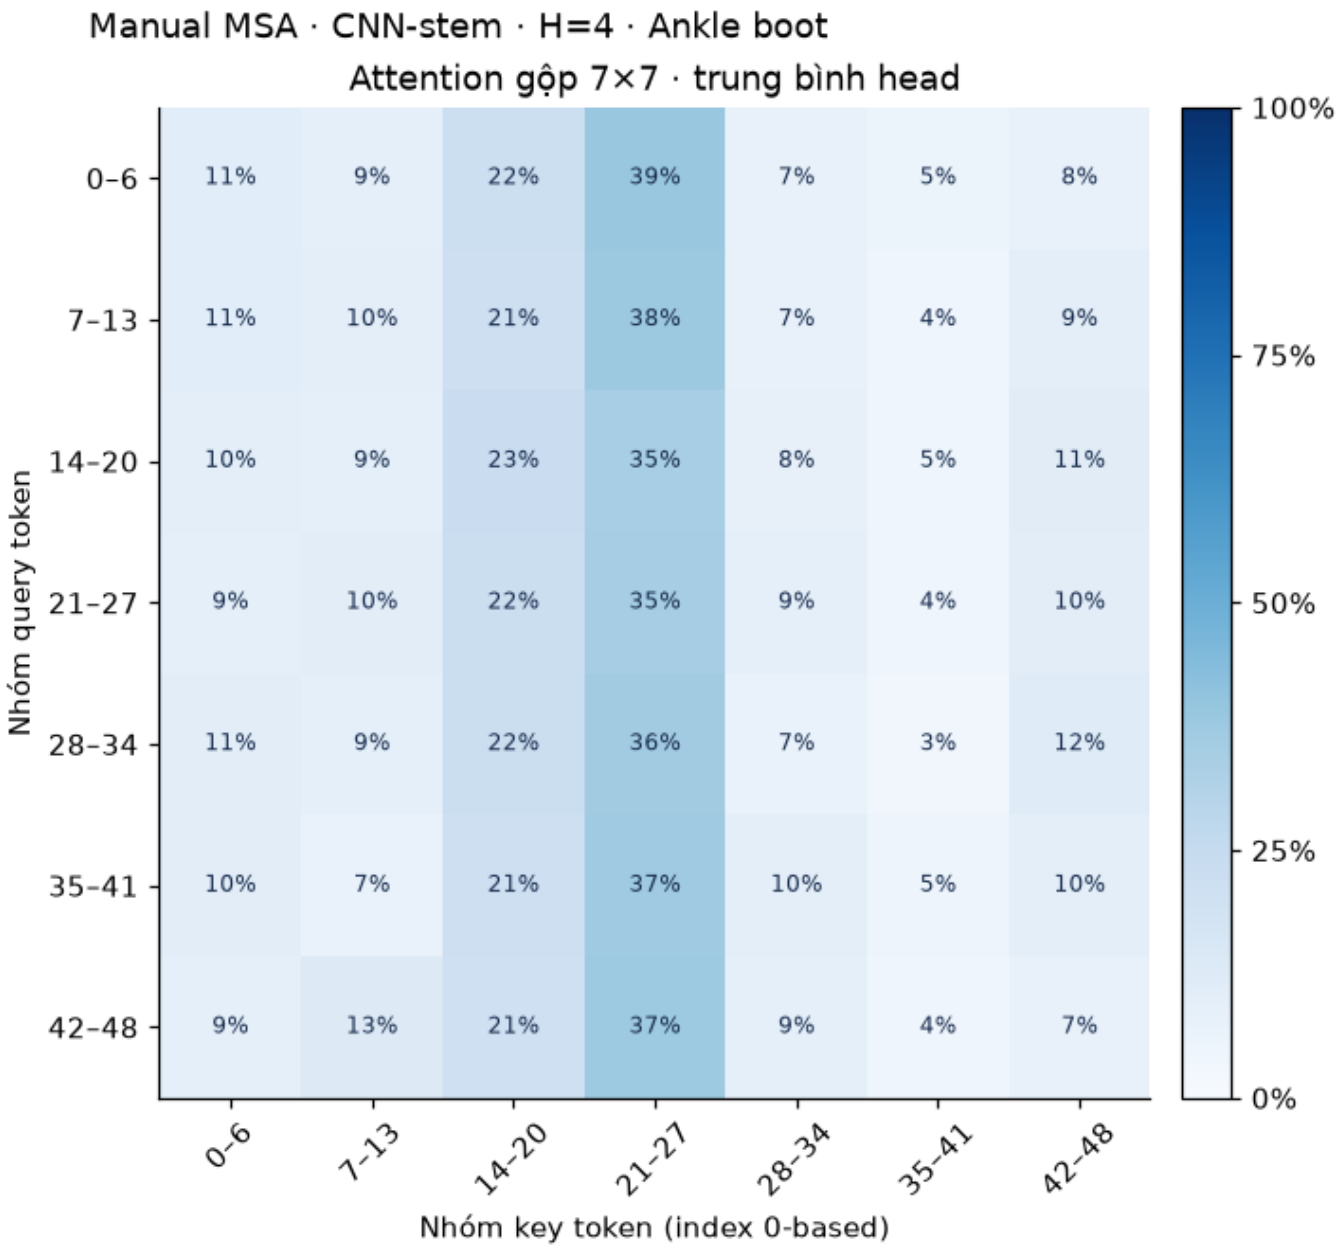

Hình 3.11: Attention gộp của ảnh Ankle boot, cùng thang màu và cách nhóm token.

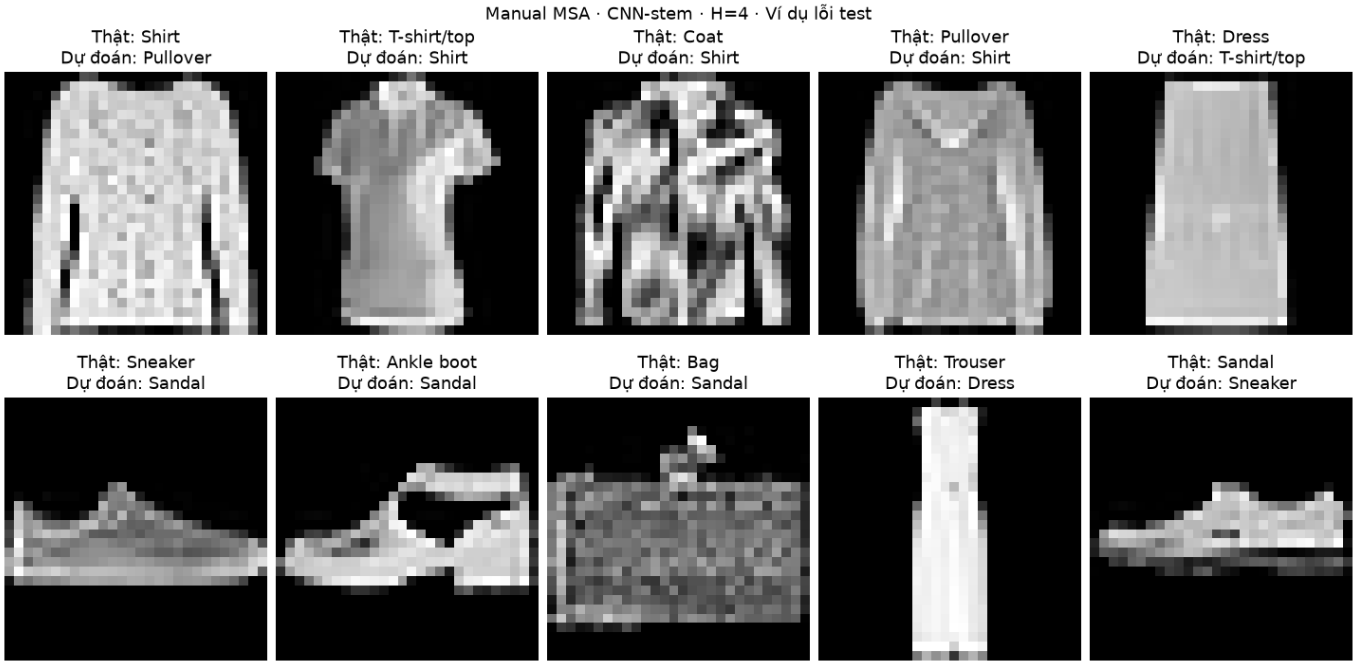

Hình 3.12: Mẫu lỗi của Manual CNN-stem H=4, bố cục 2×5.

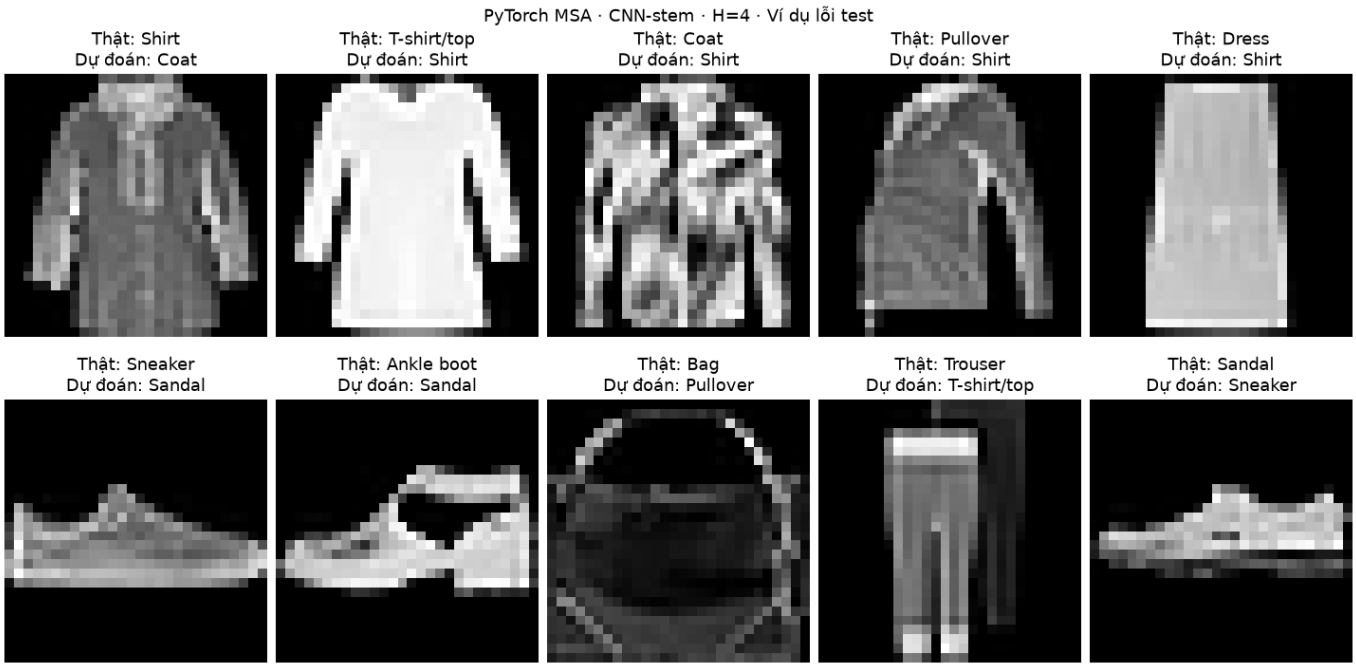

Hình 3.13: Mẫu lỗi của PyTorch CNN-stem H=4, cùng nhóm lớp thật.

4. E3: LSTM và GRU trên chuỗi ảnh

4.1 Biểu diễn ảnh thành chuỗi

E3 đọc ảnh như một chuỗi các vector và phân loại bằng hidden state cuối. Rows quét từ trên xuống, mỗi token là 28 pixel của một hàng. Columns quét từ trái sang phải, mỗi token là 28 pixel của một cột. Patch 4×4 không overlap, quét raster trái–phải rồi trên–dưới, tạo 49 bước, mỗi bước 16 pixel. Không thêm CNN/token embedding trước recurrent.

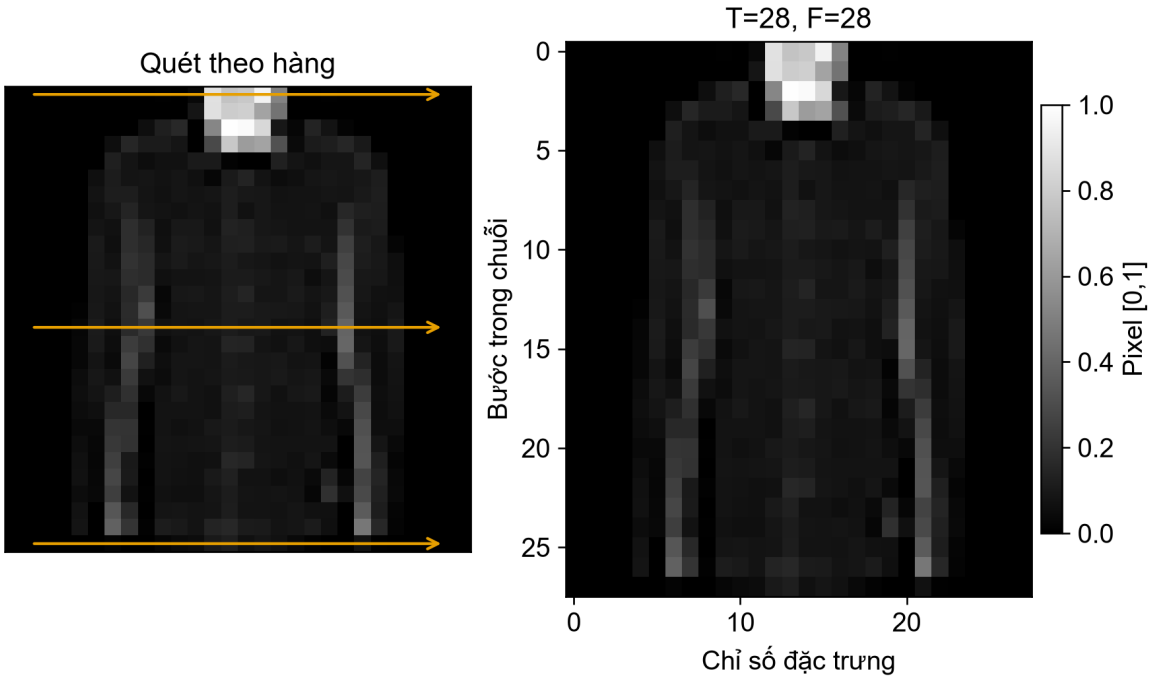

Hình 4.1: Rows: quét theo hàng và ma trận $T = 28, F = 28$.

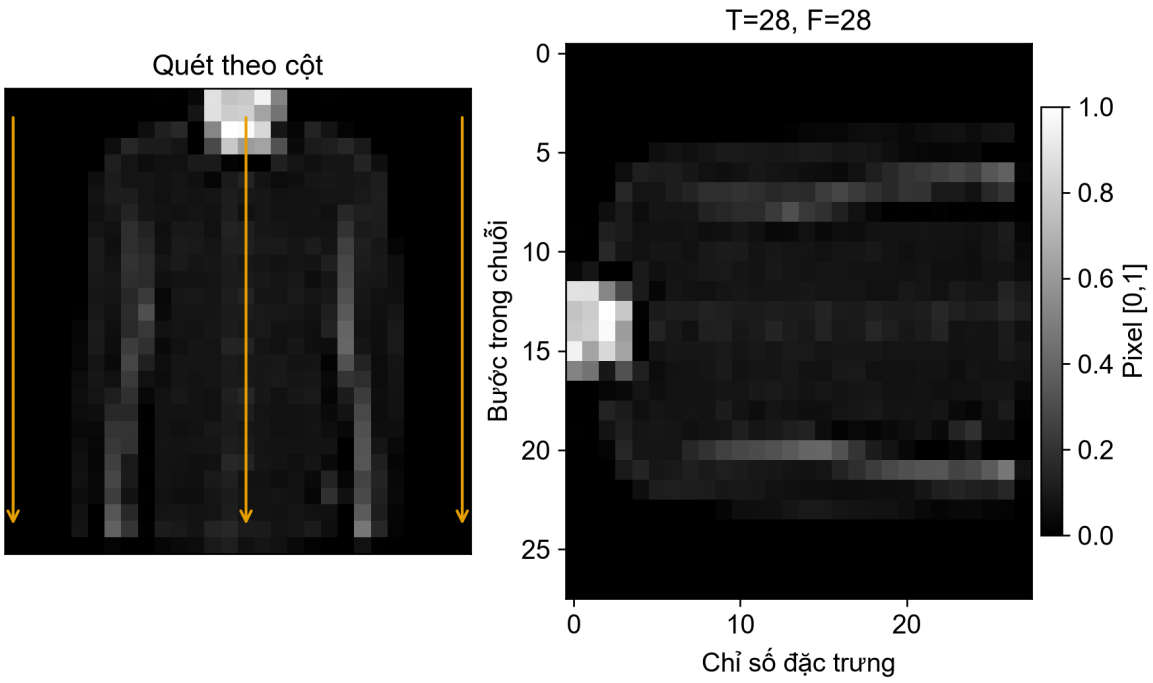

Hình 4.2: Columns: quét theo cột và ma trận $T = 28, F = 28$.

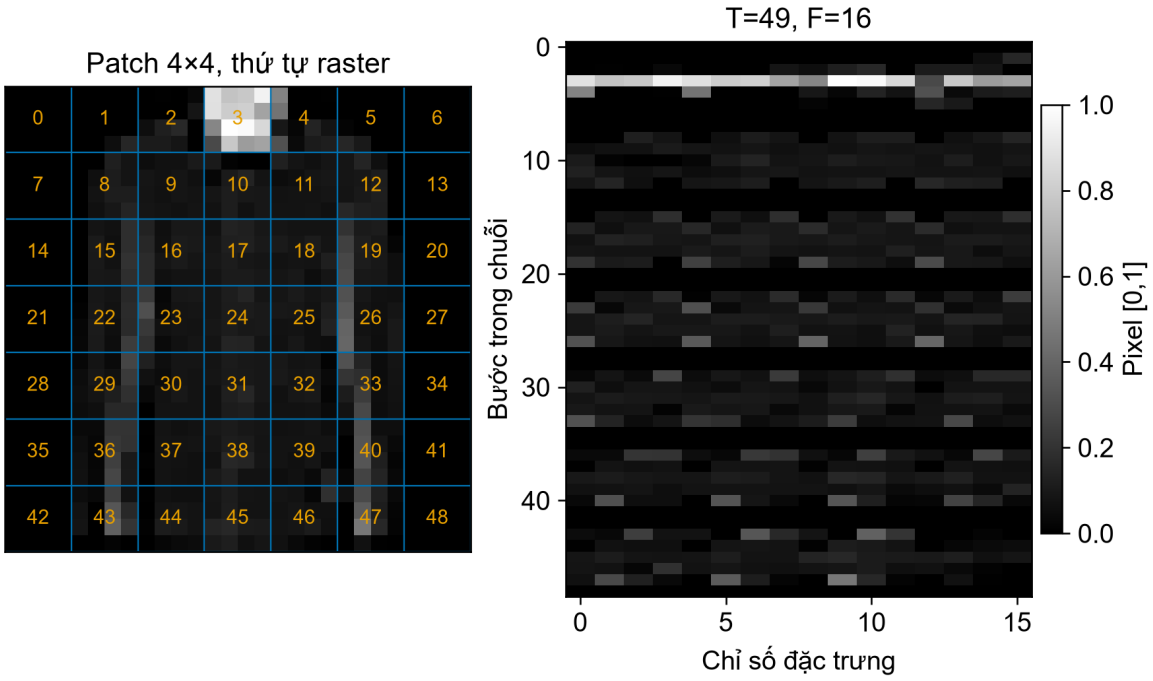

Hình 4.3: Patch: raster trên lưới 4×4, chuỗi $T = 49, F = 16$.

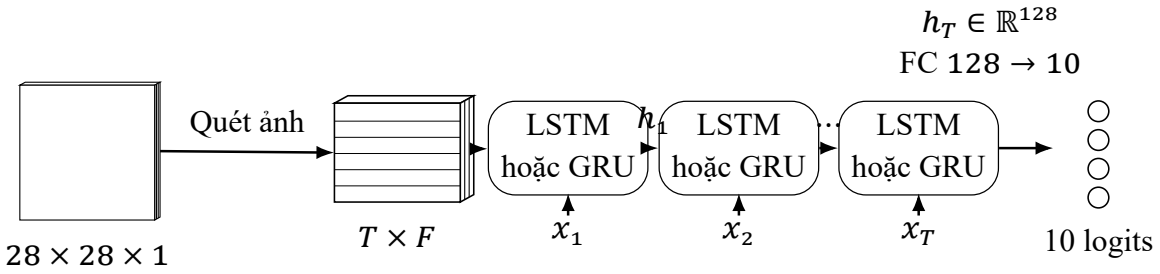

Rows/columns: $T = 28, F = 28$; patch: $T = 49, F = 16$.
Một bộ trọng số được dùng chung ở mọi bước.

Hình 4.4: Classifier recurrent E3: không Conv, một recurrent layer unroll T lần và một FC head. Trạng thái khởi tạo bằng 0, chỉ dùng hidden cuối.

4.2 Cell LSTM/GRU tự hiện thực

Với $H = 128$, LSTM có input projection $F \to 4H = 512$, hidden projection $128 \to 512$, hai bias và bốn nhóm gate:

$$[i_t, f_t, g_t, o_t] = [\,\sigma, \sigma, \tanh, \sigma\,](W_{ih}x_t + b_{ih} + W_{hh}h_{t-1} + b_{hh}), \tag{4.1}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t, \qquad h_t = o_t \odot \tanh c_t. \tag{4.2}$$

Đường trên truyền bộ nhớ; các nút tròn là phép toán theo phần tử.

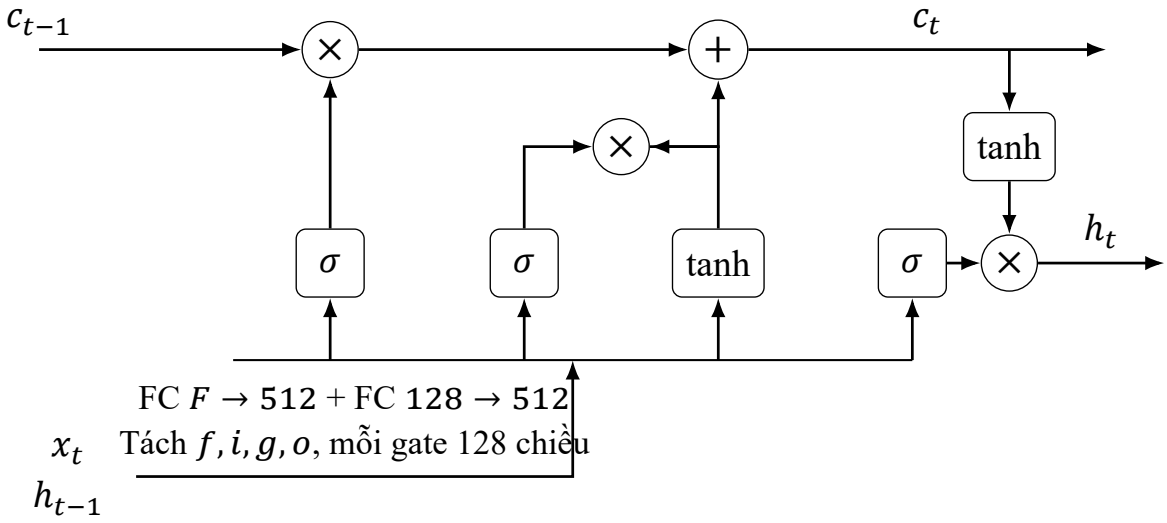

Hình 4.5: LSTM cell: hai projection dùng chung ở mọi bước; không tạo thêm bộ tham số cho mỗi timestep.

GRU có hai projection $F \to 384$ và $128 \to 384$ cho reset, update và candidate:

$$r_t = \sigma(x_r + h_r), \quad z_t = \sigma(x_z + h_z), \tag{4.3}$$

$$n_t = \tanh(x_n + r_t \odot h_n), \quad h_t = (1 - z_t) \odot n_t + z_t \odot h_{t-1}. \tag{4.4}$$

$x_.$ và $h_.$ đã gồm bias. Reset nhân *sau* projection hidden, kể cả hidden bias, theo convention PyTorch.

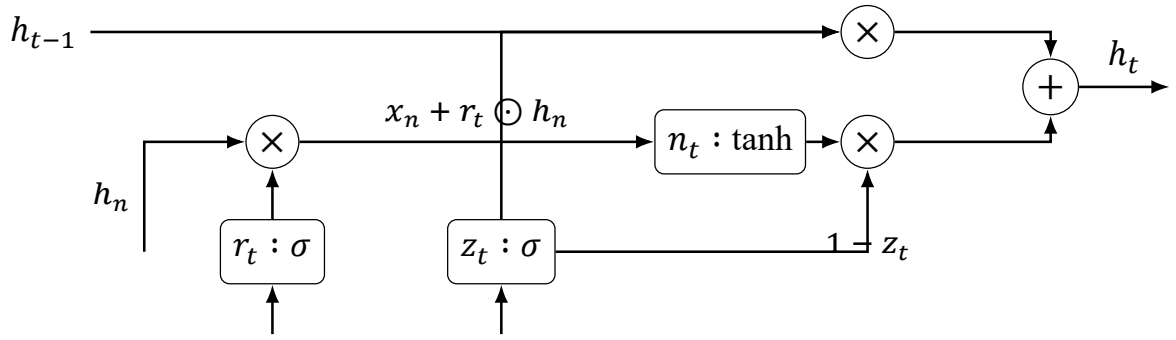

Hình 4.6: GRU cell: hai projection cho ba nhóm gate, chỉ duy trì hidden state.

Kể cả head, số tham số là $4H(F + H + 2) + 10H + 10$ cho LSTM và $3H(F + H + 2) + 10H + 10$ cho GRU. Cùng F, GRU ít tham số hơn vì dùng ba nhóm thay cho bốn. Kiểm tra copy weight sang nn.LSTMCell/ nn.GRUCell trên CUDA float64 qua 4 bước: sai số forward tối đa là $5,551 \times 10^{-17}$ (LSTM) và $3,331 \times 10^{-16}$ (GRU). Gradient của state/input/tất cả tham số khớp theo kiểm tra.

4.3 Mô hình đối chiếu và thiết lập huấn luyện

LSTM/GRU được thử với Rows, Columns và Patch. MLP và CNN-B giữ kiến trúc E1 nhưng được định nghĩa, huấn luyện độc lập trong E3 trên cùng split. AdamW learning rate 10^{-3}, weight decay 10^{-4}, batch 128, tối đa 100 epoch, patience 4 và min-delta 10^{-4} theo validation loss. Checkpoint là trọng số có validation loss nhỏ nhất. Gradient clipping norm 1 chỉ áp dụng cho recurrent; không augmentation hoặc scheduler.

4.4 So sánh LSTM, GRU và cách biểu diễn

Bảng 4.1: Metric E3 trên validation và test; F1 là macro-F1.

Model	Train (%)	Val (%)	Val F1	Test (%)	Test F1	Test loss
LSTM Rows	91,95	89,95	0,8990	89,70	0,8965	0,2940
LSTM Columns	92,79	88,72	0,8881	88,81	0,8885	0,3260
LSTM Patch	90,10	87,63	0,8769	87,55	0,8761	0,3444
GRU Rows	93,95	90,47	0,9044	90,06	0,9001	0,2882
GRU Columns	93,16	89,83	0,8983	89,51	0,8951	0,3137
GRU Patch	92,36	89,05	0,8900	88,44	0,8841	0,3352
MLP	91,58	89,47	0,8951	89,45	0,8948	0,3142
CNN-B	93,63	91,93	0,9195	91,45	0,9144	0,2333

Bảng 4.2: Số tham số, epoch và chi phí E3; cell được unroll bằng Python/PyTorch, không dùng fused kernel.

Model	Params	Epoch/best	Train+val (s)	s/epoch	Peak MiB
LSTM Rows	82.186	18/14	472,13	26,230	27
LSTM Columns	82.186	23/19	625,00	27,174	27
LSTM Patch	76.042	20/16	928,90	46,445	33
GRU Rows	61.962	20/20	576,49	28,824	28
GRU Columns	61.962	23/19	642,46	27,933	28
GRU Patch	57.354	24/20	1171,26	48,802	35
MLP	235.146	20/16	69,09	3,455	22
CNN-B	94.186	20/16	76,78	3,839	56

Bảng 4.3: LSTM và GRU trên cùng biểu diễn; chênh lệch test tính theo điểm phần trăm.

Biểu diễn	LSTM test (%)	GRU test (%)	GRU–LSTM (điểm %)	LSTM/GRU params
Rows	89,70	90,06	+0,36	82.186 / 61.962
Columns	88,81	89,51	+0,70	82.186 / 61.962
Patch	87,55	88,44	+0,89	76.042 / 57.354

Rows tốt nhất ở cả hai họ, đạt test 89,70% (LSTM) và 90,06% (GRU). GRU cao hơn LSTM 0,36; 0,70; 0,89 điểm với Rows, Columns và Patch. Với Rows, GRU dùng 61.962 tham số so với 82.186 của LSTM, giảm 24,6%. Rows và Columns cùng $T = 28, F = 28$, nhưng đổi hướng quét; Patch đổi cả feature ($F = 16$) lẫn chiều dài ($T = 49$), nên không cô lập riêng tác động thứ tự token.

GRU ít tham số hơn nhưng thời gian đo cao hơn LSTM: Rows là 28,824/26,230 s/epoch, Patch là 48,802/46,445 s/epoch. Tốc độ còn phụ thuộc gate, unroll, kernel và tải máy.

4.4.1 Đối chiếu với MLP và CNN

Bảng 4.4: Recurrent đại diện chọn bằng validation và hai mô hình không hồi tiếp.

Model	Val (%)	Test (%)	Test F1	Params
LSTM Rows	89,95	89,70	0,8965	82.186
GRU Rows	90,47	90,06	0,9001	61.962
MLP	89,47	89,45	0,8948	235.146
CNN-B	91,93	91,45	0,9144	94.186

GRU Rows hơn MLP 0,61 điểm test nhưng thấp hơn CNN-B 1,39 điểm. Chênh lệch validation GRU–CNN-B là $-1,47$ điểm, tính từ số chưa làm tròn. CNN-B đạt 3,839 s/epoch; cấu trúc không gian và tính song song giúp CNN phù hợp ảnh tĩnh trong thiết lập này.

Hidden state tích lũy thông tin qua 28/49 bước; LSTM thêm cell state, GRU duy trì hidden với ba gate. Accuracy hiện có không chứng minh mô hình đã học phụ thuộc xa: cần thêm thí nghiệm che token hoặc thay đổi độ dài để kiểm tra giả thuyết đó.

4.5 Đường cong học và phân tích lỗi

LSTM Columns có train–validation gap 4,07 điểm; GRU Rows là 3,48 điểm. Các đường train tiếp tục cải thiện trong khi validation chững lại, cho thấy cần chọn checkpoint theo validation. Đường cong của ba cách biểu diễn được tách riêng trong Phụ lục để đọc rõ từng model.

Bảng 4.5: Cặp nhầm lớn nhất của tám mô hình E3; mỗi lớp test có 1.000 ảnh.

Model	Thật → dự đoán	Số ảnh	% lớp thật
LSTM Rows	Shirt → T-shirt/top	133	13,3%
LSTM Columns	T-shirt/top → Shirt	141	14,1%
LSTM Patch	T-shirt/top → Shirt	141	14,1%
GRU Rows	Shirt → T-shirt/top	125	12,5%
GRU Columns	Shirt → T-shirt/top	126	12,6%
GRU Patch	Shirt → T-shirt/top	135	13,5%
MLP	T-shirt/top → Shirt	124	12,4%
CNN-B	Shirt → Coat	103	10,3%

LSTM Rows và GRU Rows nhầm Shirt thành T-shirt/top 133/125 ảnh. CNN-B nhầm Shirt thành Coat 103 ảnh; vì đây là cặp khác, không dùng ba số đếm đó để xếp hạng riêng khả năng nhận diện Shirt. Ma trận cho thấy recall Shirt làm tròn là 70%, 71%, 73% tương ứng; các lớp giày/túi nhìn chung dễ phân biệt hơn nhóm áo. Ma trận của tám mô hình nằm ở Phụ lục. Kết luận giới hạn ở một seed, Fashion-MNIST và cell unroll không fused.

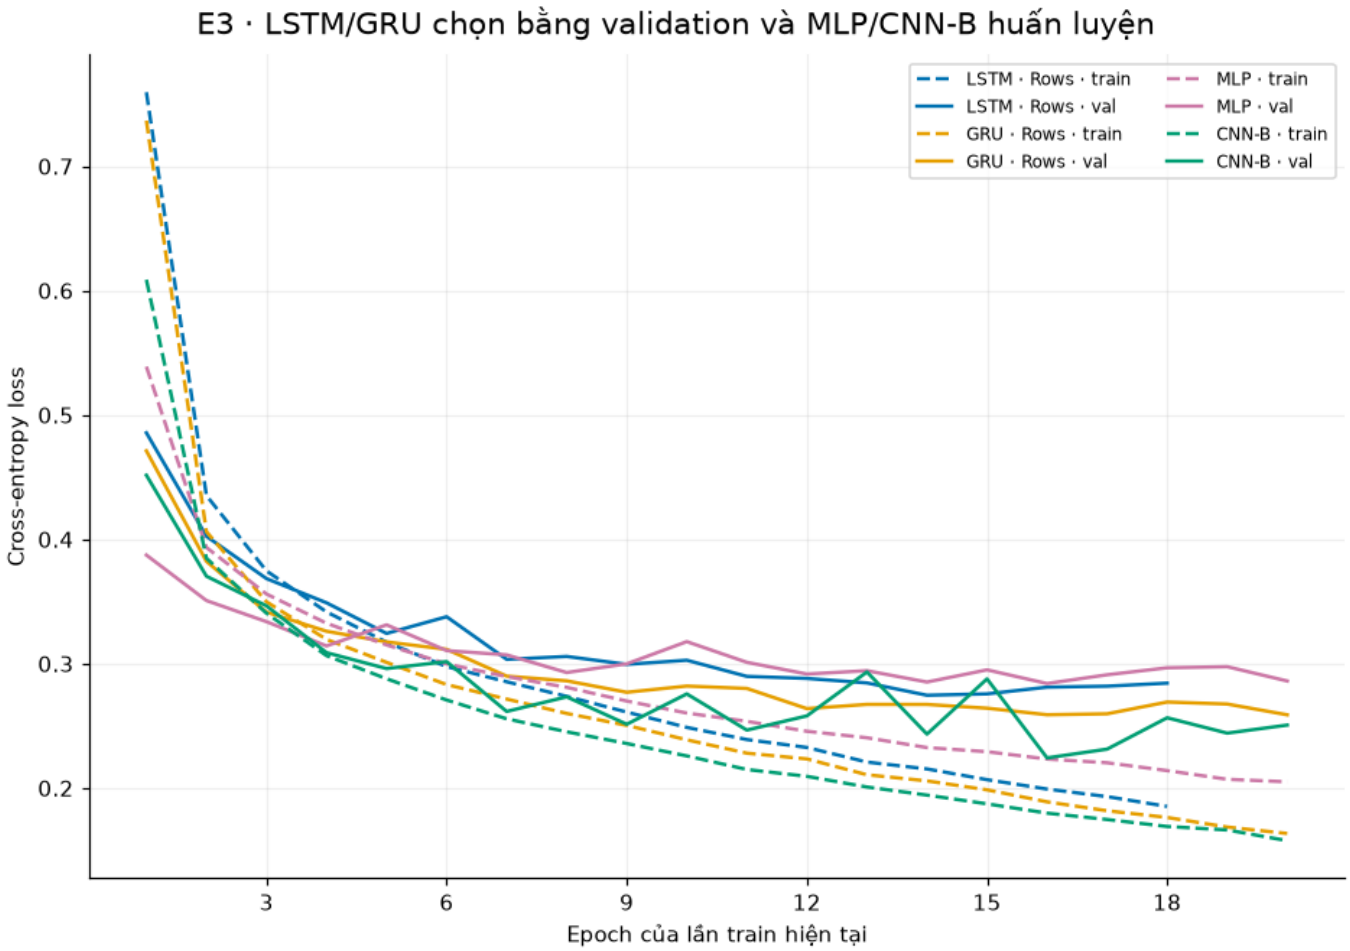

Hình 4.7: Loss của LSTM/GRU Rows và MLP/CNN-B; nét đứt train, nét liền validation.

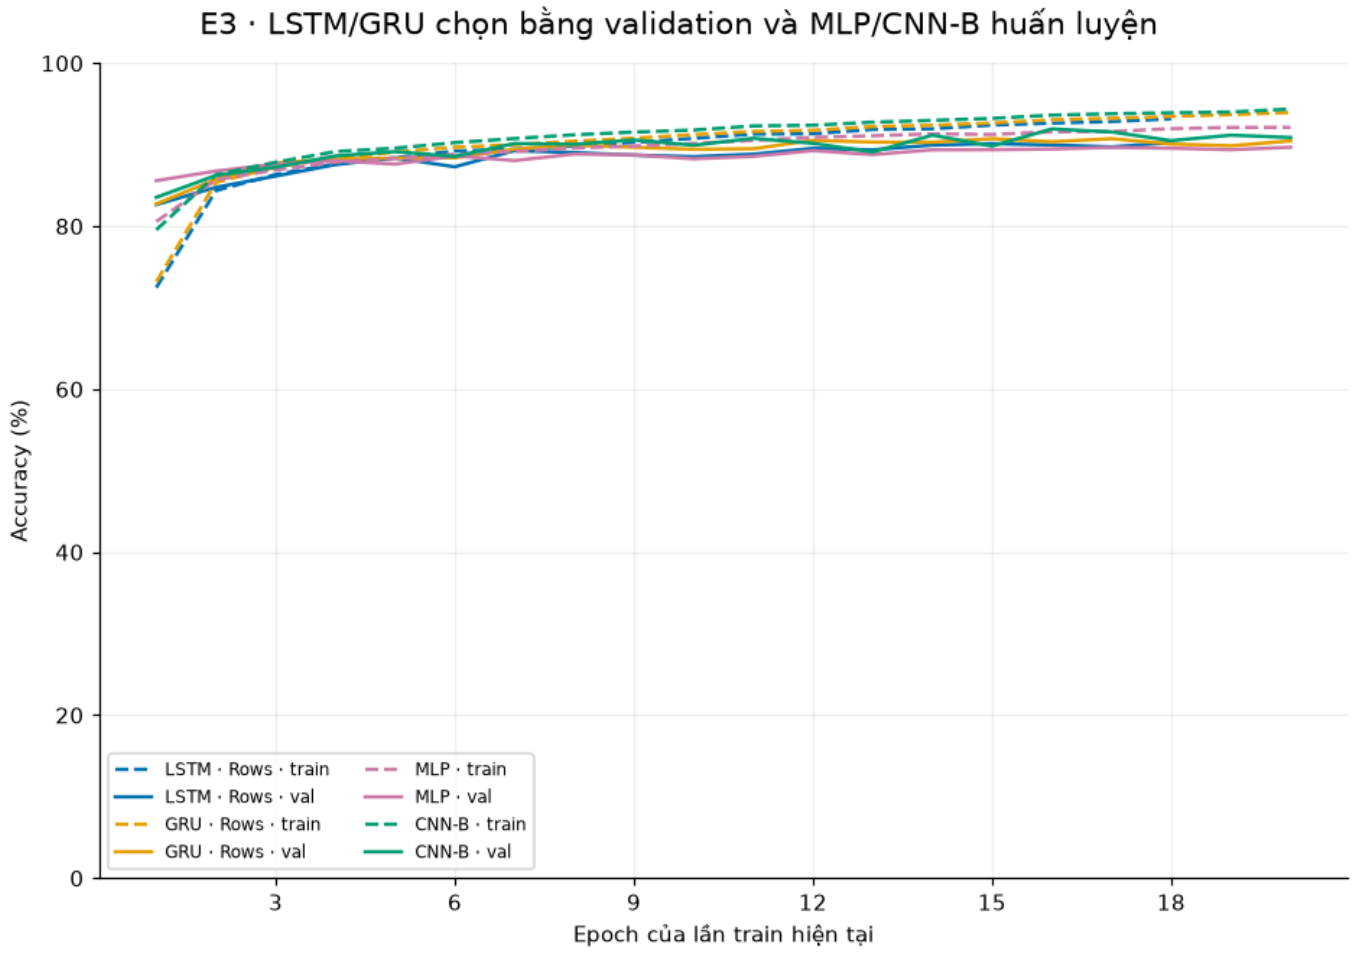

Hình 4.8: Accuracy của recurrent đại diện và hai mô hình không hồi tiếp.

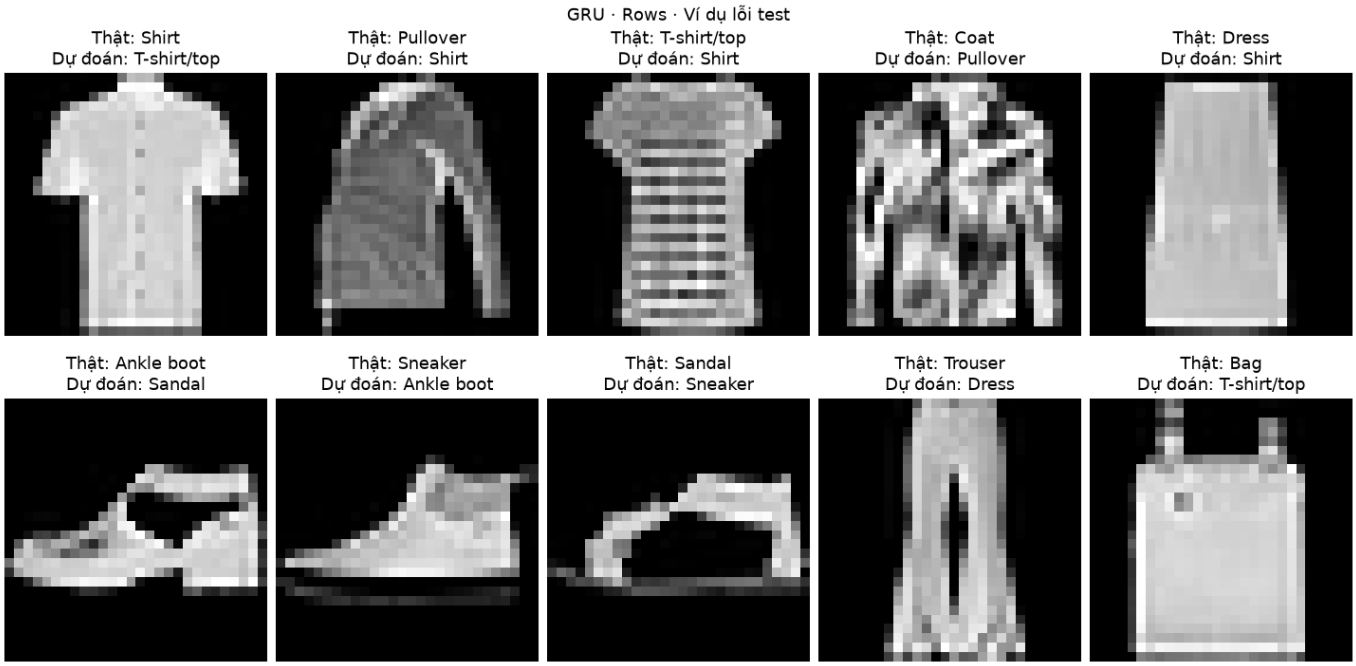

Hình 4.9: Mẫu lỗi của GRU Rows, bố cục 2 × 5.

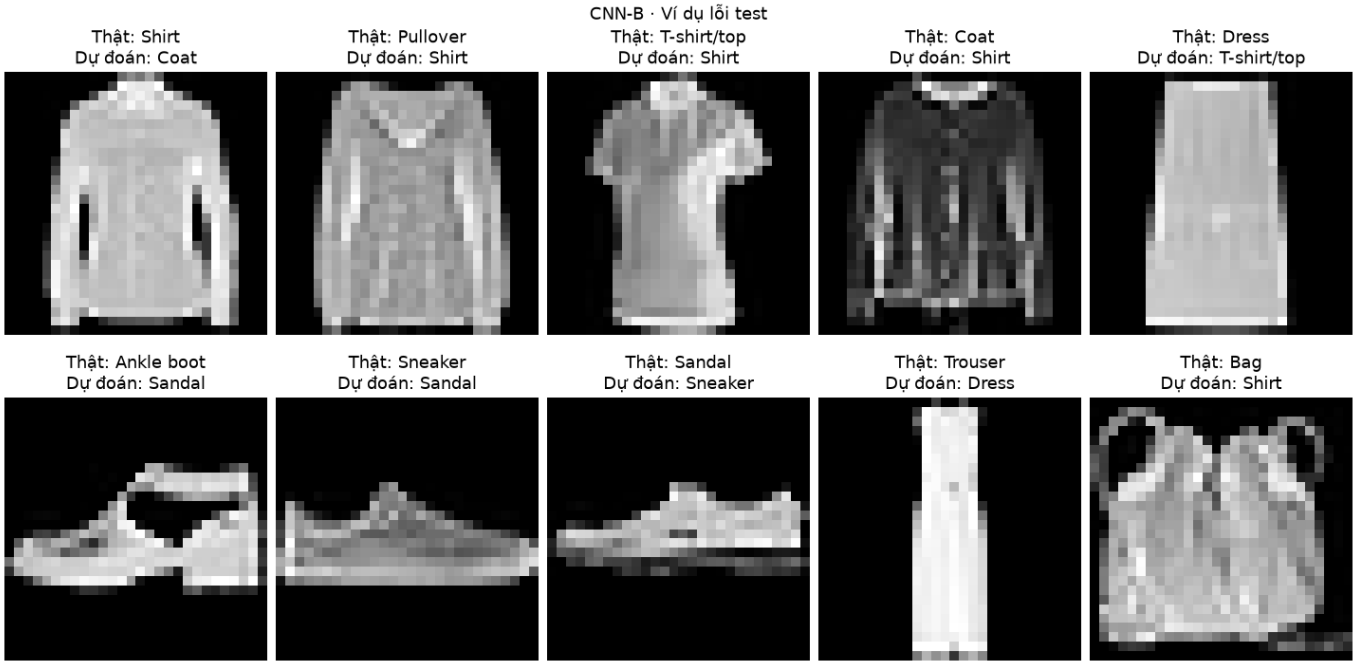

Hình 4.10: Mẫu lỗi của CNN-B huấn luyện độc lập trong E3.

5. A1: CNN và Transformer trên GTSRB

5.1 Dữ liệu, phân bố lớp và cách chia tập

GTSRB [8, 9] gồm 43 loại biển giao thông, với 39.209 ảnh train nguồn và 12.630 ảnh test. Dataset khác Fashion-MNIST/CIFAR-10, có quy mô hàng chục nghìn ảnh, lớp gần nhau và biến đổi ánh sáng/góc nhìn, phù hợp yêu cầu A1. Nguồn tải là archive tác giả trên ERDA [10]; metadata archive chưa xác nhận mã giấy phép SPDX. Project ghi nguồn, tác giả và điều kiện/README nguồn, không tự gán MIT/CC. Nhãn ClassId là số nguyên 0–42; ảnh PPM được chuẩn bị thành PNG lossless.

Train/validation chia theo nhóm class_id + physical_sign_track, seed 42, giữ khoảng 20% track mỗi lớp cho validation. Cách chia hạn chế các frame của cùng biển vật lý xuất hiện trong cả hai tập.

Bảng 5.1: Split GTSRB sử dụng toàn bộ dữ liệu.

Tập	Ảnh	Lớp	Vai trò
Train	31.380	43	Huấn luyện
Validation	7.829	43	Chọn weights và protocol
Official-source test	12.630	43	Đánh giá cuối
Test không trùng SHA256	12.622	43	Phân tích độ nhạy

Fingerprint của split:

c1c1759f478eeeeaac0faddf424717574
f6f1895f6a5511ed77964c34eb2c7ac

Đối chiếu SHA256 trong metadata không ghi nhận trùng train–validation hoặc validation–test; có 8 ảnh test lớp Stop (ID 14) trùng train. Giữ test nguồn và báo thêm kết quả trên test không trùng. SHA256 chỉ phát hiện trùng byte, không loại mọi ảnh gần giống.

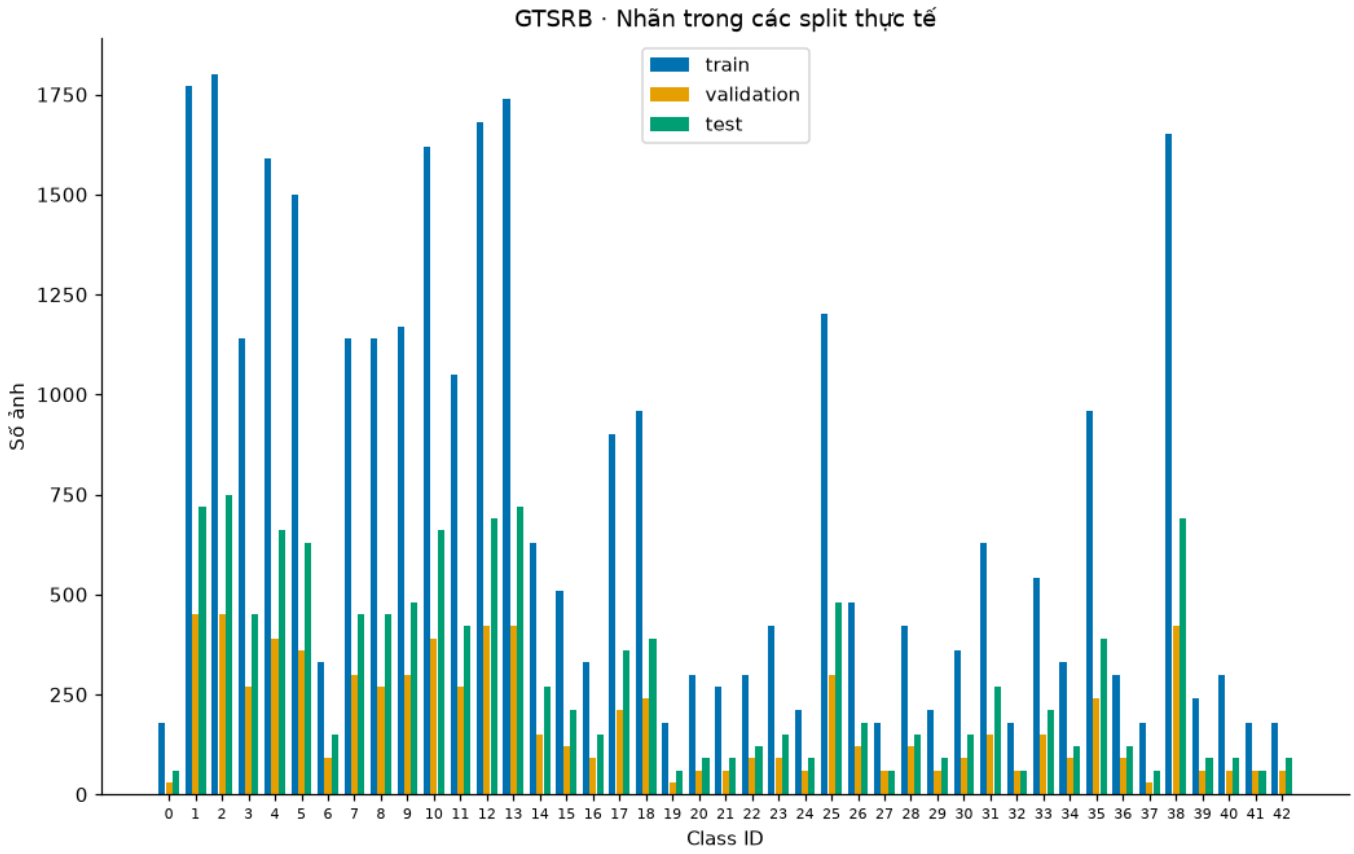

Hình 5.1: Số ảnh theo 43 lớp trong train, validation và test; ID tra theo bảng lớp ở Phụ lục.

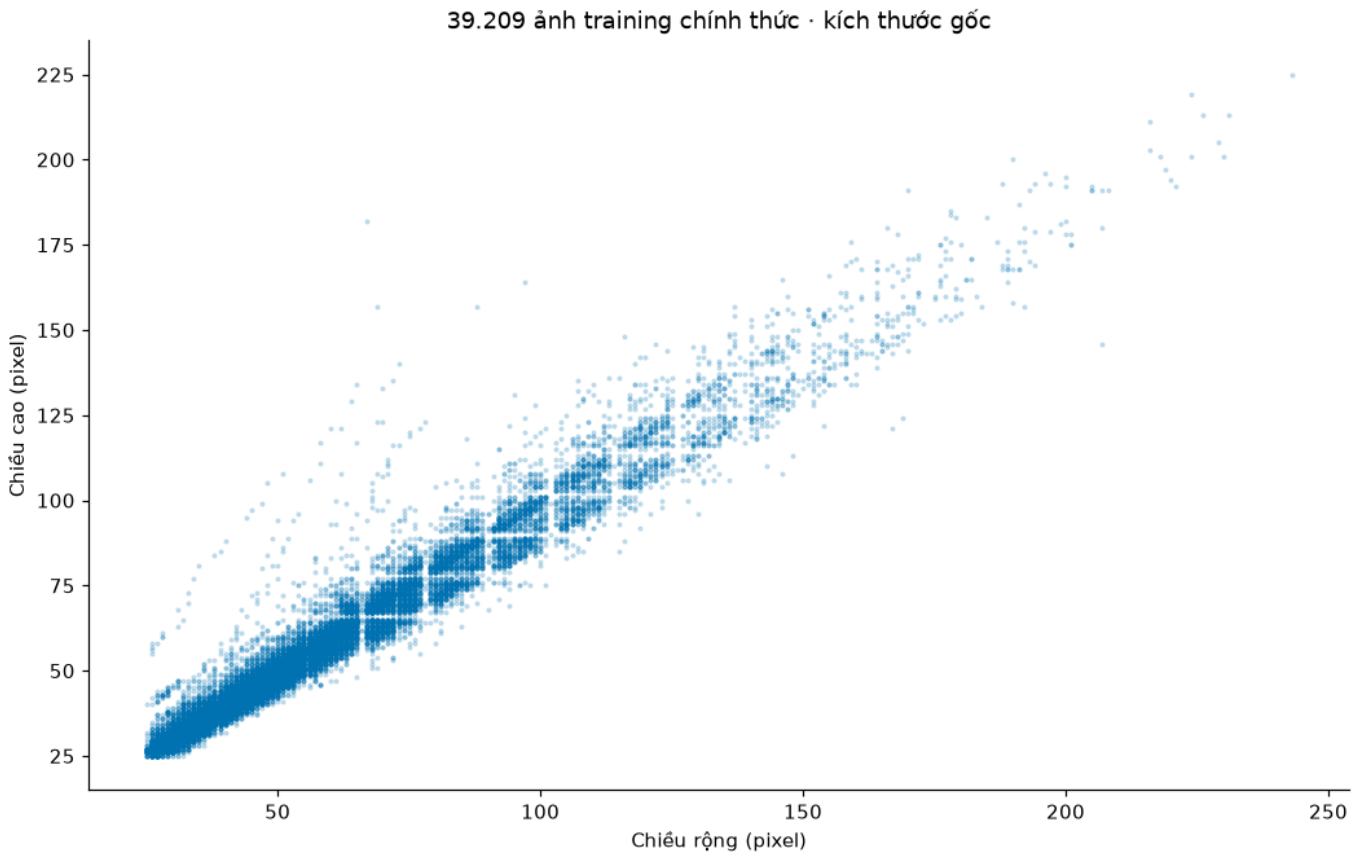

Hình 5.2: Kích thước gốc của 39.209 ảnh train nguồn, trước khi chia train/validation.

Train mất cân bằng: Speed limit 50 có 1.800 ảnh, trong khi Speed limit 20, Pedestrians và một số lớp hiếm có 180 ảnh. Validation Turn right ahead có 149 ảnh, phản ánh split theo track không ép đúng tỷ lệ ảnh 20%.

Hình 5.3: Ảnh train đại diện cho lớp 0–9, bố cục 2 × 5.

Hình 5.4: Ảnh train đại diện cho lớp 10–19.

Hình 5.5: Ảnh train đại diện cho lớp 20–29.

Hình 5.6: Ảnh train đại diện cho lớp 30–39.

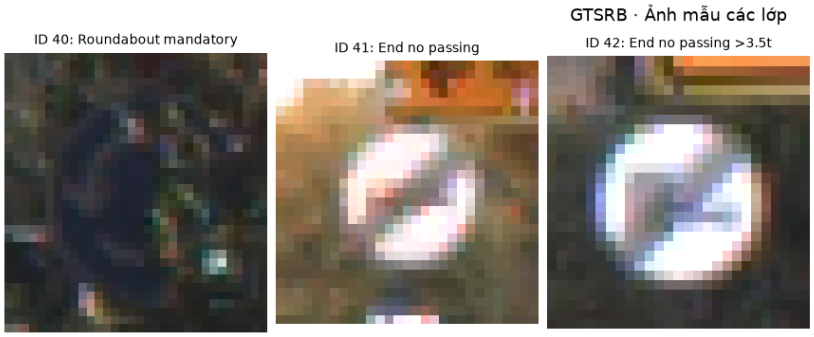

Hình 5.7: Ảnh train đại diện cho ba lớp 40–42.

5.2 DataLoader, augmentation và kiến trúc

Ảnh RGB resize toàn ảnh về 224×224, không center-crop, rồi chuẩn hóa ImageNet mean $(0{,}485; 0{,}456; 0{,}406)$, std $(0{,}229; 0{,}224; 0{,}225)$. Augmentation train gồm RandomAffine góc $\pm 10°$, translate tối đa 5% mỗi trục và ColorJitter brightness/contrast 0,2, saturation 0,1. Không

flip vì có thể đảo ý nghĩa biển; validation/test chỉ resize và normalize. Dataset đọc ảnh theo samples.csv; DataLoader shuffle train, workers 0, seed cố định và không bỏ batch cuối.

ResNet-50 dùng Bottleneck 3/4/6/3, expansion 4, stride tại Conv 3×3 theo convention torchvision [4]. DeiT-Small/16 non-distilled dùng patch 16, embedding 384, depth 12, 6 head, FFN $384 \rightarrow 1536 \rightarrow 384$ và LayerNorm eps 10^{-6} [11]. Hai mạng được định nghĩa trong notebook, dùng head 43 lớp. Pretrained ResNet lấy ImageNet-1K V1 của torchvision; DeiT lấy checkpoint ImageNet-1K chính thức non-distilled, không dùng distillation token/teacher hoặc loss distillation.

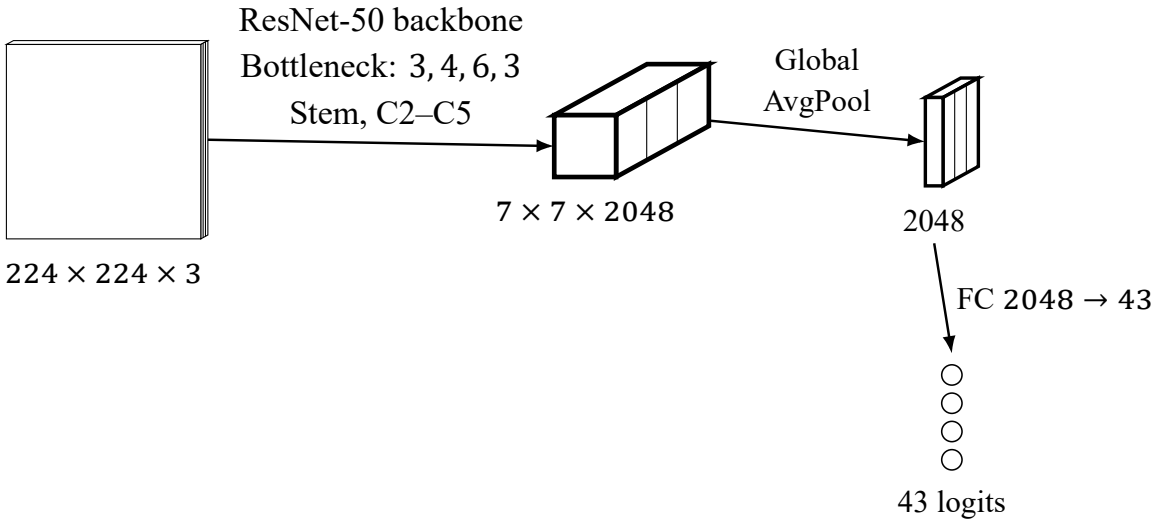

Hình 5.8: ResNet-50: backbone gom khối, global average pooling và FC 43 lớp. Head 88.107 tham số; toàn mạng 23.596.139.

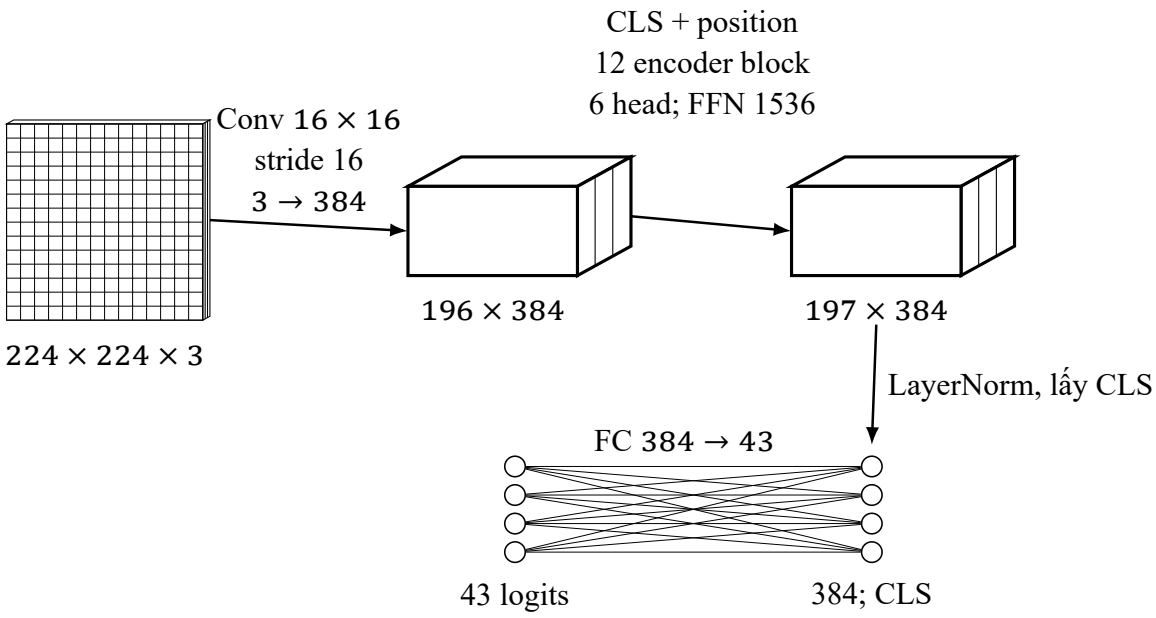

Hình 5.9: DeiT-Small/16: 196 patch và CLS, 12 encoder block, một head 43 lớp. Head 16.555 tham số; toàn mạng 21.682.219.

Pretrained chỉ nạp backbone, giữ head 43 lớp của bài toán GTSRB; code đối chiếu đầy đủ tên/kích thước trọng số khi nạp.

5.3 Các cấu hình và thiết lập huấn luyện

Ký hiệu bảng: R=ResNet-50, D=DeiT-Small/16; S=scratch, H=head-only, P=partial, F=full pretrained; số sau dấu/ là seed.

Bảng 5.2: Các mức freeze và số tham số được tối ưu.

Họ	Chế độ	Thành phần trainable	Tham số	% tổng
ResNet	Scratch/full	Toàn bộ mạng	23.596.139	100,00
ResNet	Head-only	FC 43	88.107	0,37
ResNet	Partial	layer4 và FC 43	15.052.843	63,79
DeiT	Scratch/full	Toàn bộ mạng	21.682.219	100,00
DeiT	Head-only	FC 43	16.555	0,08
DeiT	Partial	Hai block cuối, norm, head	3.566.251	16,45

Partial mở 63,79% tham số ResNet và 16,45% DeiT; vì vậy phép so sánh này không giữ capacity trainable ngang nhau. BatchNorm bị freeze dùng eval mode, không cập nhật running statistics.

AdamW weight decay 0,01; scratch LR 3×10^{-4}, tối đa 40 epoch; pretrained backbone LR 10^{-4} và head 10^{-3}, tối đa 25 epoch. Warmup 3 epoch rồi cosine, clip gradient norm 1, AMP train và FP32 eval. Early stopping theo validation loss, patience 2, min-delta 10^{-3}. Best weights lưu khi loss thấp hơn best loss; min-delta dùng riêng cho bộ đếm dừng sớm, nên best epoch có thể gần epoch dừng. Batch 128, accumulation 1 cho mọi run; train có 246 batch/epoch, batch cuối 20 ảnh. Validation/test có 62/99 batch.

Hai họ × bốn regime tạo tám run chính, cùng seed 42 và augmentation. Mỗi họ chọn regime bằng validation accuracy, macro-F1 rồi loss; full được chọn ở cả hai. Với regime này, thêm no-augmentation seed 42 và repeat seed 43/44 cho mỗi họ, tổng 14 run. Split giữ seed 42; test đánh giá sau khi khóa các lựa chọn.

Scratch không nạp ImageNet weights. Mỗi run có đường dẫn latest.pt riêng; Run All nạp trọng số này nếu có, rồi tạo optimizer, scheduler và bộ đếm mới. Muốn khởi tạo hoàn toàn theo seed, dùng CHECKPOINT_ROOT trống. Epoch, updates và thời gian trong bảng chỉ tính vòng train/validation được ghi trong output, không gồm test, vẽ hình hoặc đánh giá trọng số đầu vào.

5.4 Kết quả chính: CNN, Transformer và pretraining

Bảng 5.3: Accuracy và macro-F1 của tám cấu hình chính; test có 12.630 ảnh.

Run	Train (%)	Val (%)	Val F1	Test (%)	Test F1
R-S/42	98,51	98,26	0,9688	96,33	0,9447
R-H/42	86,06	66,84	0,5682	67,33	0,5759
R-P/42	99,53	97,02	0,9560	95,21	0,9261
R-F/42	99,43	99,32	0,9911	97,83	0,9678
D-S/42	93,78	91,76	0,8791	88,64	0,8267
D-H/42	89,37	70,26	0,5932	69,41	0,6016
D-P/42	98,64	89,32	0,8360	87,85	0,8063
D-F/42	99,79	99,39	0,9863	98,92	0,9790

Bảng 5.4: Capacity, số epoch/best, thời gian mỗi epoch và peak allocated VRAM.

Run	Total params	Trainable	%	Epoch/best	s/epoch	Peak MiB
R-S/42	23.596.139	23.596.139	100,00	7/5	230,838	5828
R-H/42	23.596.139	88.107	0,37	10/8	153,500	1567
R-P/42	23.596.139	15.052.843	63,79	7/5	164,455	1682
R-F/42	23.596.139	23.596.139	100,00	4/2	222,561	5827
D-S/42	21.682.219	21.682.219	100,00	11/9	240,167	6631
D-H/42	21.682.219	16.555	0,08	12/10	170,014	636
D-P/42	21.682.219	3.566.251	16,45	6/4	182,845	1373
D-F/42	21.682.219	21.682.219	100,00	8/6	236,812	6635

Bảng 5.5: CNN và Transformer cùng regime; Δ val là DeiT trừ ResNet, tính theo điểm phần trăm từ giá trị chưa làm tròn.

Regime	R val (%)	D val (%)	Δ val	R test (%)	D test (%)
Scratch	98,26	91,76	-6,50	96,33	88,64
Head-only	66,84	70,26	+3,42	67,33	69,41
Partial	97,02	89,32	-7,70	95,21	87,85
Full	99,32	99,39	+0,06	97,83	98,92

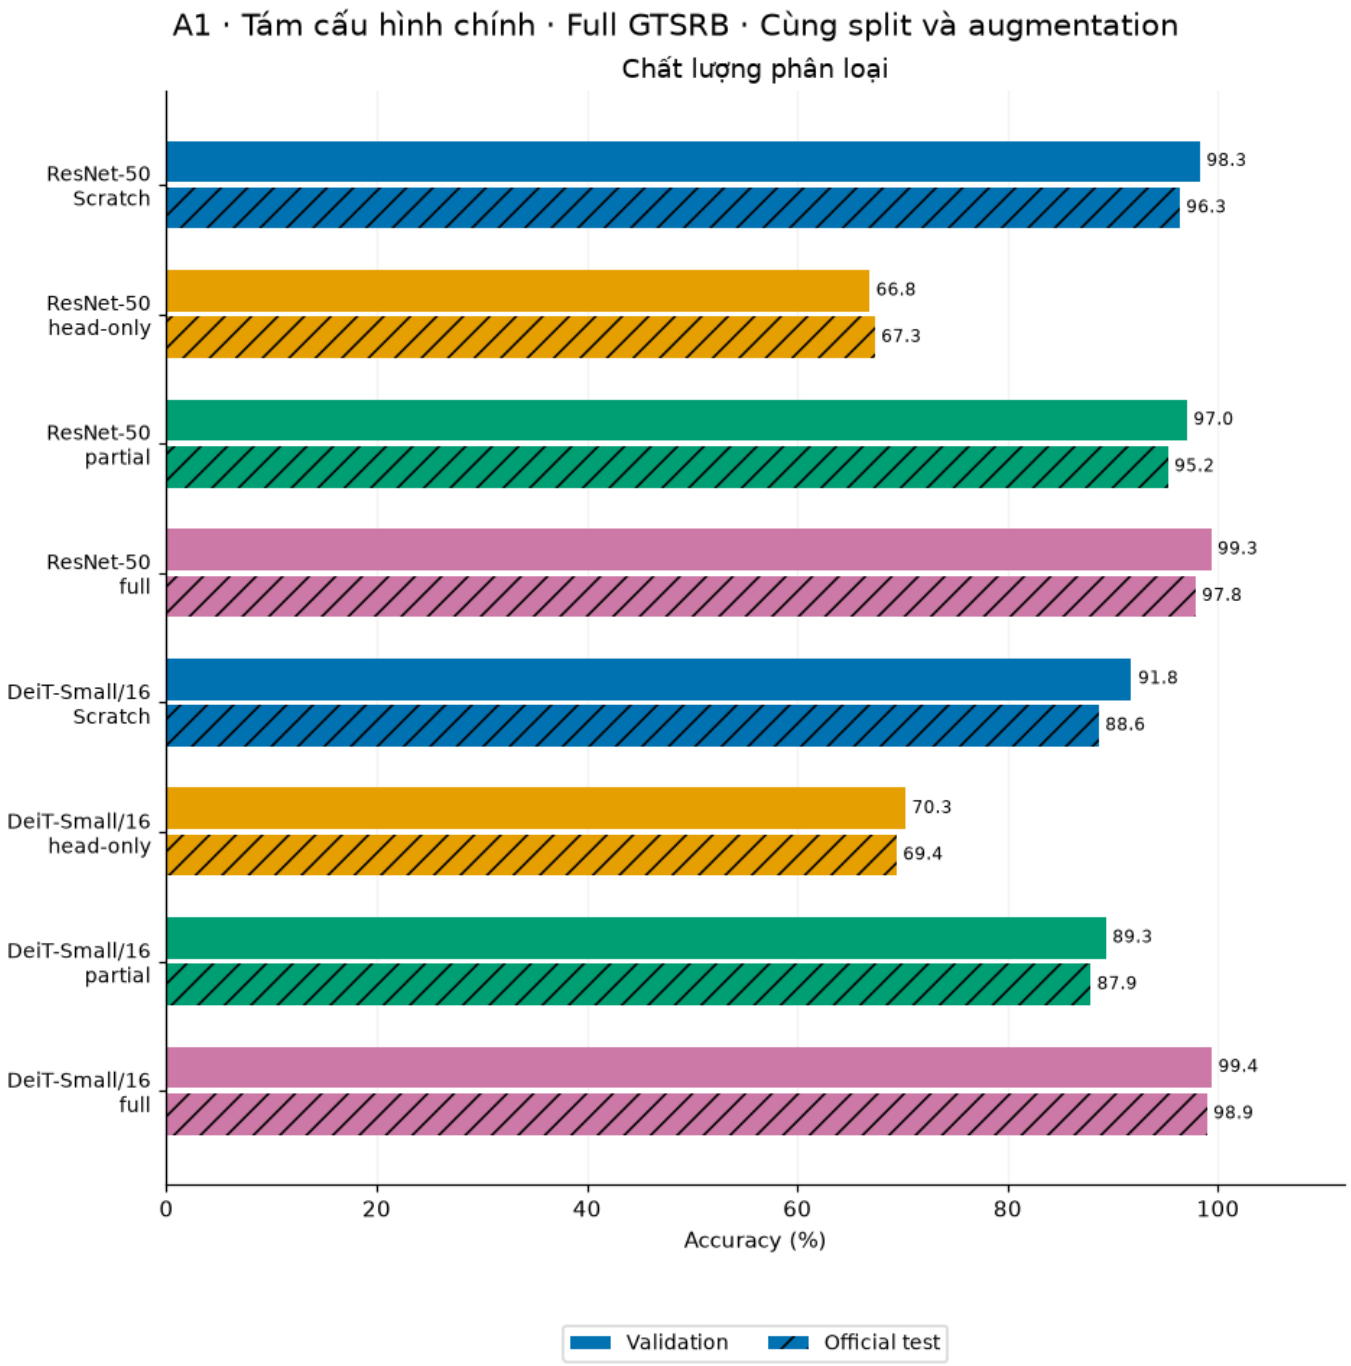

Hình 5.10: Validation và test accuracy của tám cấu hình A1, cùng split và augmentation.

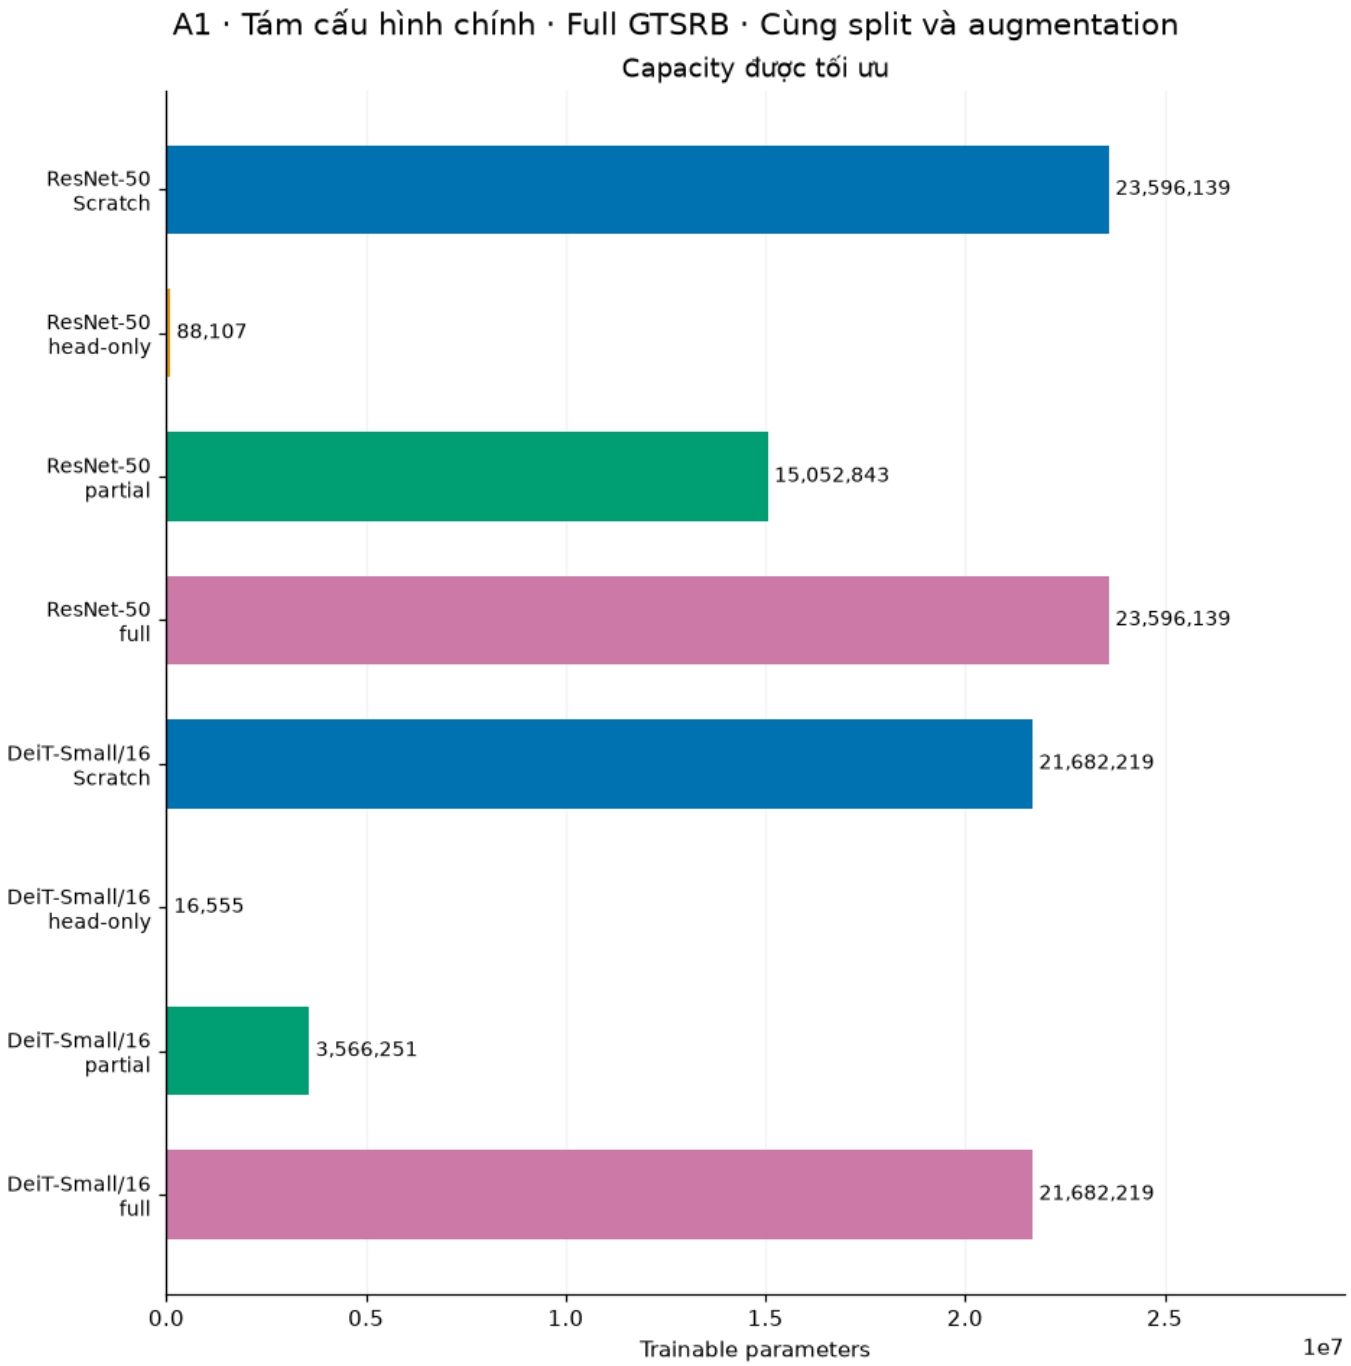

Hình 5.11: Số tham số được tối ưu trong từng regime; phần backbone freeze không tính vào trainable.

Full pretrained đạt validation cao nhất ở cả hai họ: ResNet 99,32%, DeiT 99,39%. Trên test, tương ứng 97,83% và 98,92%; DeiT cao hơn 1,09 điểm. Chênh lệch validation là 0,06 điểm từ số chưa làm tròn, không đủ để suy kết luận mạnh chỉ từ một seed.

Bảng 5.6: Lợi ích validation của pretraining và unfreeze; mọi chênh lệch tính theo điểm phần trăm.

Họ	Full − scratch	Full − head	Partial − head
ResNet-50	+1,06	+32,48	+30,18
DeiT-Small/16	+7,63	+29,12	+19,06

Full pretrained tăng test so với scratch 1,50 điểm với ResNet (96,33% lên 97,83%) và 10,28 điểm với DeiT (88,64% lên 98,92%). Trong protocol này, DeiT hưởng lợi rõ hơn từ ImageNet weights; không khẳng định Transformer luôn cần pretraining trên mọi dataset. Scratch ResNet cao hơn DeiT 7,69 điểm test. Head-only DeiT cao hơn ResNet 2,08 điểm; partial ResNet cao hơn DeiT 7,36 điểm, nhưng phạm vi unfreeze khác nhau nên không quy chênh lệch này riêng cho họ kiến trúc.

5.5 Freeze, chi phí và đường cong học

Head-only đạt validation 66,84%/70,26% và test 67,33%/69,41% cho ResNet/DeiT. Train tại best là 86,06%/89,37%, tạo gap 19,22/19,11 điểm. Chỉ tối ưu head chưa thích nghi tốt với GTSRB trong thiết lập này. Freeze giảm tham số học và VRAM: head-only dùng 1.567/636 MiB, so với full 5.827/6.635 MiB. Partial ResNet đạt test 95,21% với 1.682 MiB; partial DeiT đạt 87,85% với 1.373 MiB. Nếu ưu tiên accuracy thì full phù hợp hơn; nếu hạn chế bộ nhớ, partial ResNet là một lựa chọn trong các cấu hình đã thử.

Bảng 5.7: Thời gian train+validation và inference FP32; CUDA Events batch 32, tách DataLoader.

Run	Train+val (s)	GPU ms/batch	Images/s	Test (s)
R-S/42	1615,87	76,84	416,5	50,93
R-H/42	1535,00	74,80	427,8	42,04
R-P/42	1151,19	75,20	425,5	41,91
R-F/42	890,24	74,78	427,9	41,96
D-S/42	2641,83	139,56	229,3	62,57
D-H/42	2040,17	139,92	228,7	62,91
D-P/42	1097,07	139,93	228,7	62,85
D-F/42	1894,50	140,50	227,8	62,92

Full ResNet dùng 890,24 s cho bốn epoch, DeiT 1.894,50 s cho tám epoch. Thời gian mỗi epoch là 222,561/236,812 s; thời gian tổng còn phụ thuộc early stopping, không chỉ tốc độ kiến trúc. Benchmark GPU-only cho 427,9/227,8 ảnh/s, tương ứng 74,78/140,50 ms mỗi batch 32; throughput ResNet khoảng 1,88 lần DeiT. Test end-to-end dùng batch 128, gồm DataLoader/H2D/metric, nên không đồng nhất với benchmark GPU-only. Peak là allocated PyTorch, không phải reserved hoặc tổng VRAM máy.

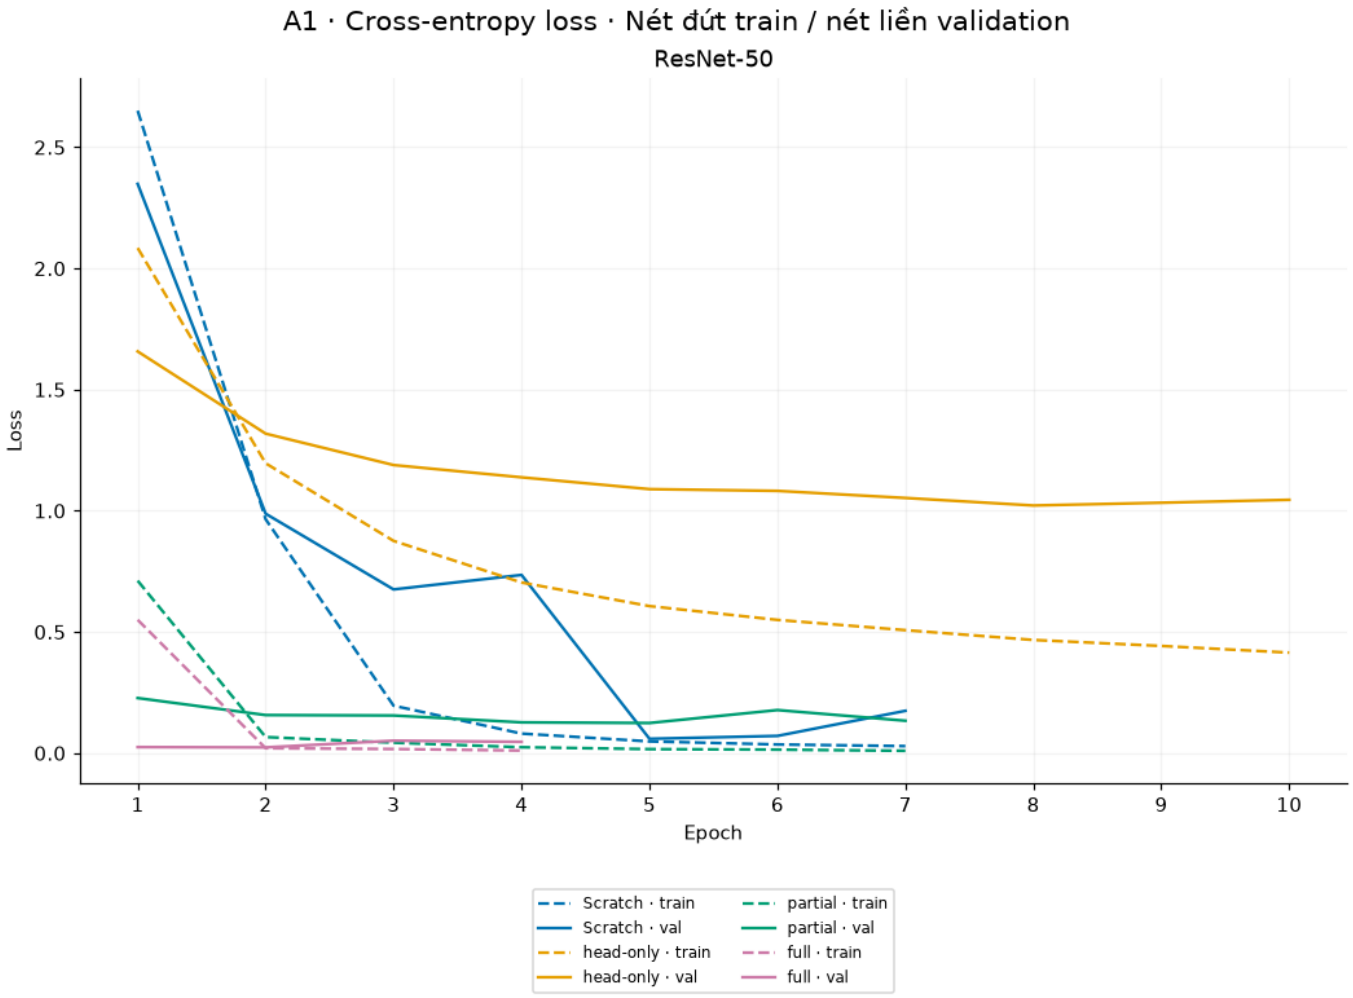

Hình 5.12: Cross-entropy ResNet-50 theo bốn regime; train nét đứt, validation nét liền.

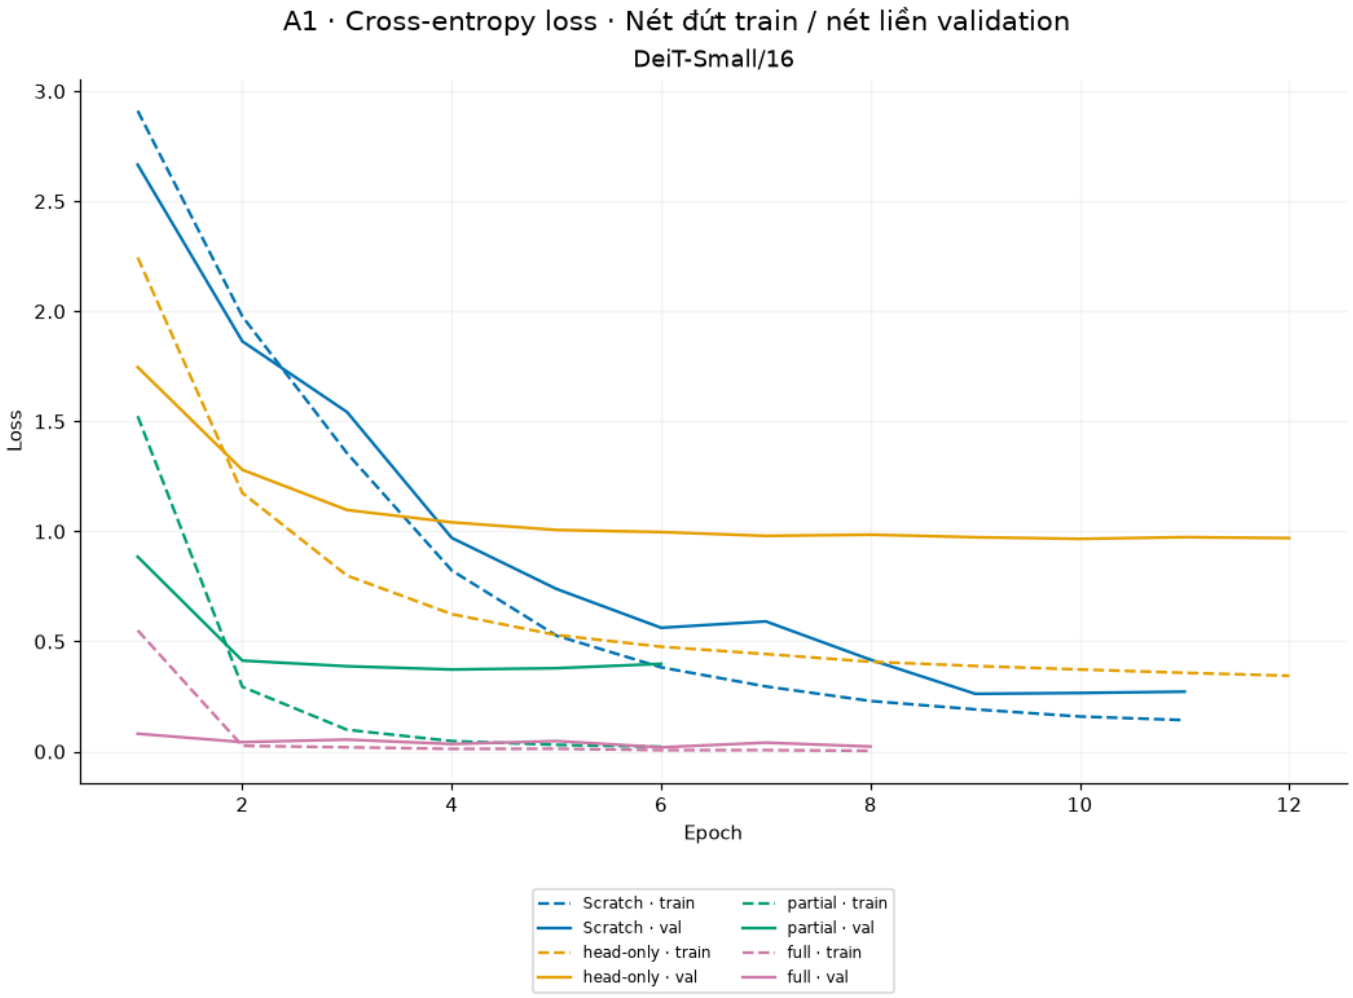

Hình 5.13: Cross-entropy DeiT-Small/16 theo bốn regime.

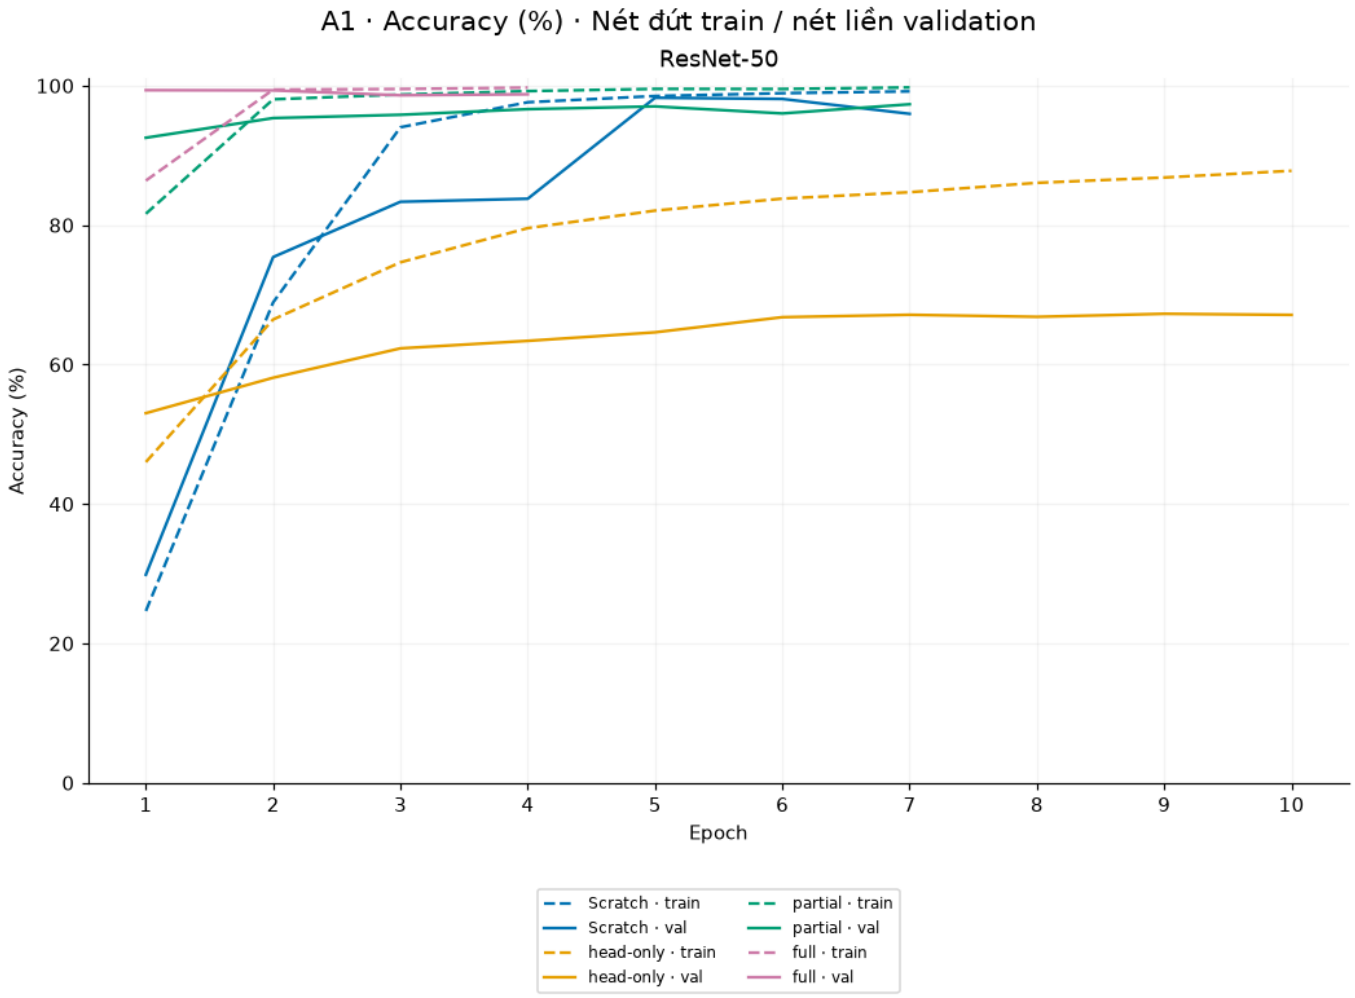

Hình 5.14: Accuracy train/validation ResNet-50 theo epoch.

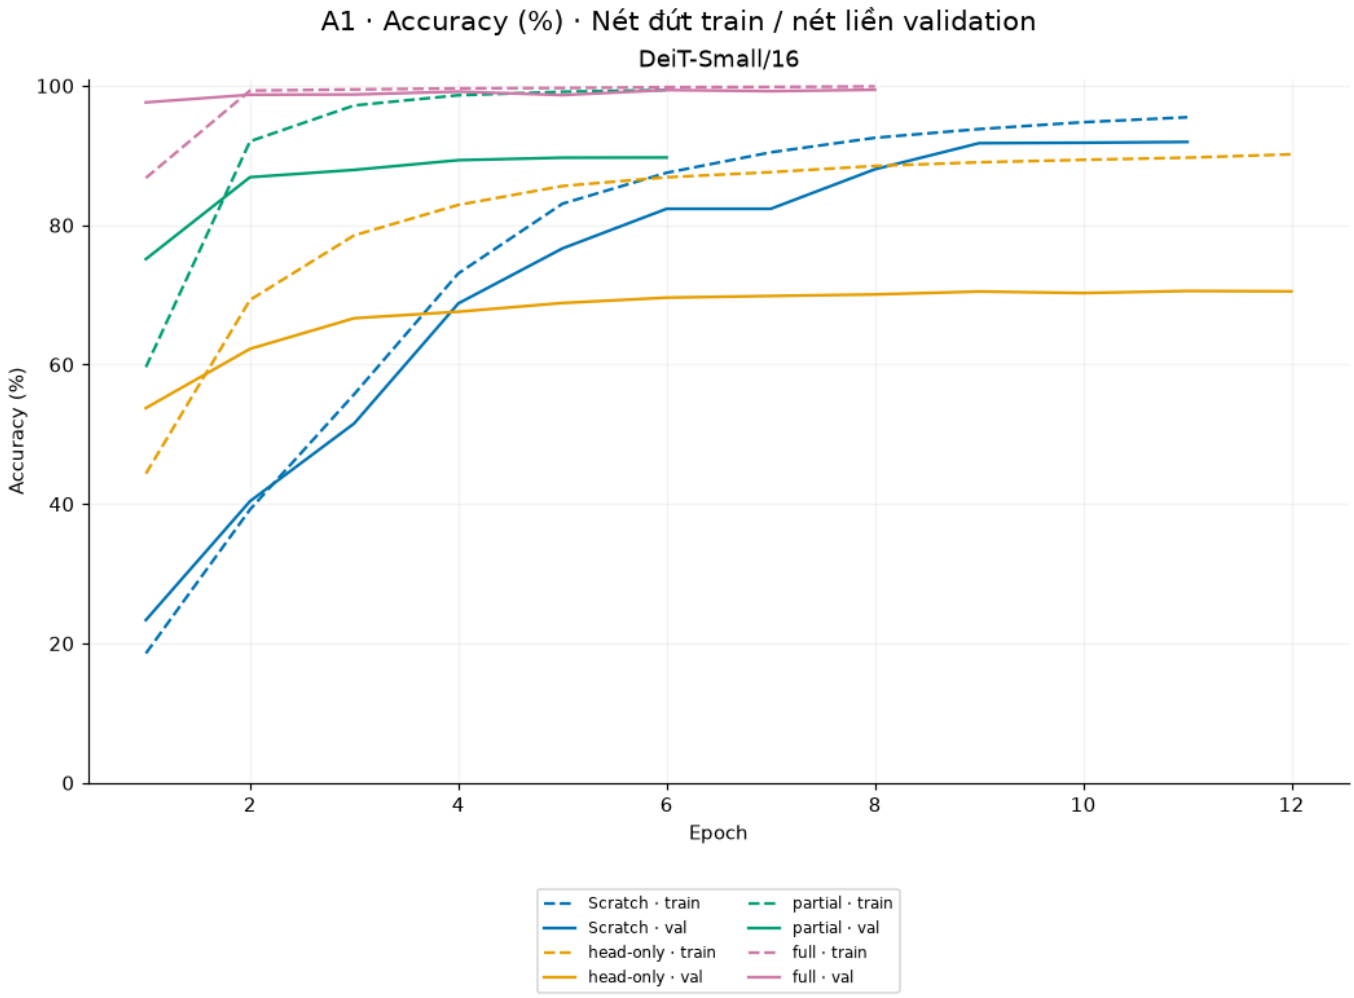

Hình 5.15: Accuracy train/validation DeiT-Small/16 theo epoch.

Head-only có gap lớn; full pretrained sớm đạt validation cao. DeiT scratch dừng sau 11 epoch và đạt test 88,64%, cho thấy kết quả phụ thuộc cả khởi tạo và quy tắc dừng. Train accuracy đo trong train mode với augmentation, validation trong eval mode; hai đường không phải cùng một điều kiện đo.

5.6 Augmentation và độ biến thiên giữa seed

Bảng 5.8: Sáu thực nghiệm bổ sung trên full pretrained; cấu hình chọn bằng validation.

Run	Val (%)	Val F1	Test (%)	Test F1	Train+val (s)
R-F/42 no-aug	98,85	0,9811	97,20	0,9545	543,43
R-F/43	98,80	0,9817	97,83	0,9591	683,57
R-F/44	99,28	0,9881	98,19	0,9630	1133,57
D-F/42 no-aug	98,10	0,9776	97,80	0,9593	587,72
D-F/43	99,39	0,9902	98,29	0,9768	2362,09
D-F/44	99,02	0,9864	98,30	0,9705	1176,05

Bảng 5.9: Augmentation ablation, cùng full mode và seed 42; accuracy tính bằng %.

Họ	Aug val	No-aug val	Aug test	No-aug test
ResNet-50	99,32	98,85	97,83	97,20
DeiT-Small/16	99,39	98,10	98,92	97,80

Augmentation tăng validation 0,47/1,29 điểm và test 0,63/1,12 điểm cho ResNet/DeiT. Biến đổi đã chọn hữu ích với cả hai họ trong lượt đo này; một seed chưa xác lập tác dụng trên mọi split hoặc cách augmentation.

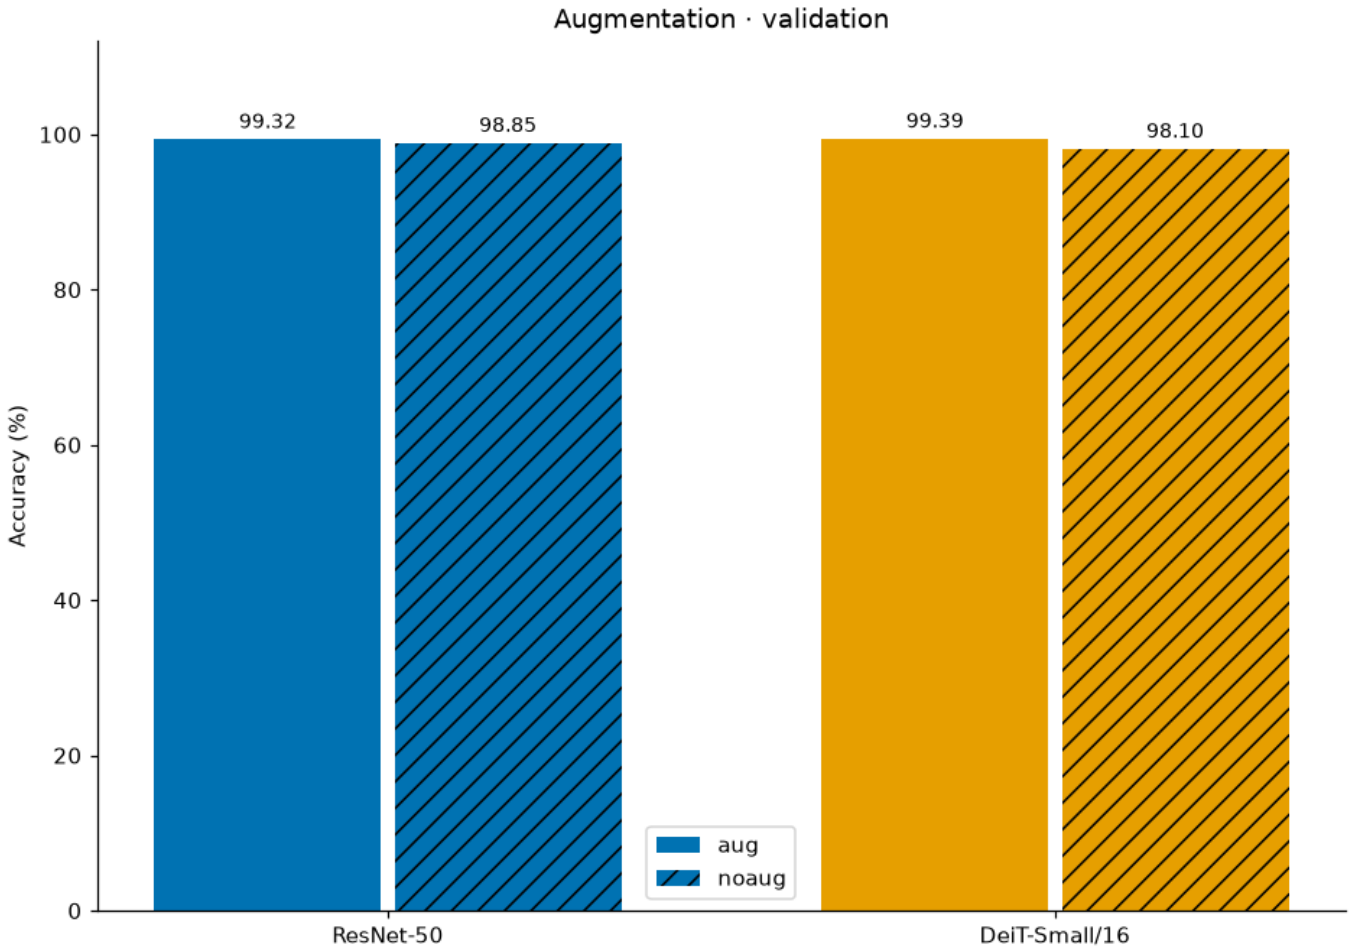

Hình 5.16: Validation accuracy có/không augmentation, cùng seed 42.

Bảng 5.10: Full pretrained qua seed 42/43/44, giữ split 42; mean ± std mẫu, ddof=1.

Họ	Val acc (%)	Test acc (%)	Val macro-F1	Test macro-F1
ResNet-50	$99,14 \pm 0,29$	$97,95 \pm 0,21$	$0,9870 \pm 0,0048$	$0,9633 \pm 0,0044$
DeiT-Small/16	$99,26 \pm 0,21$	$98,50 \pm 0,36$	$0,9876 \pm 0,0022$	$0,9754 \pm 0,0044$

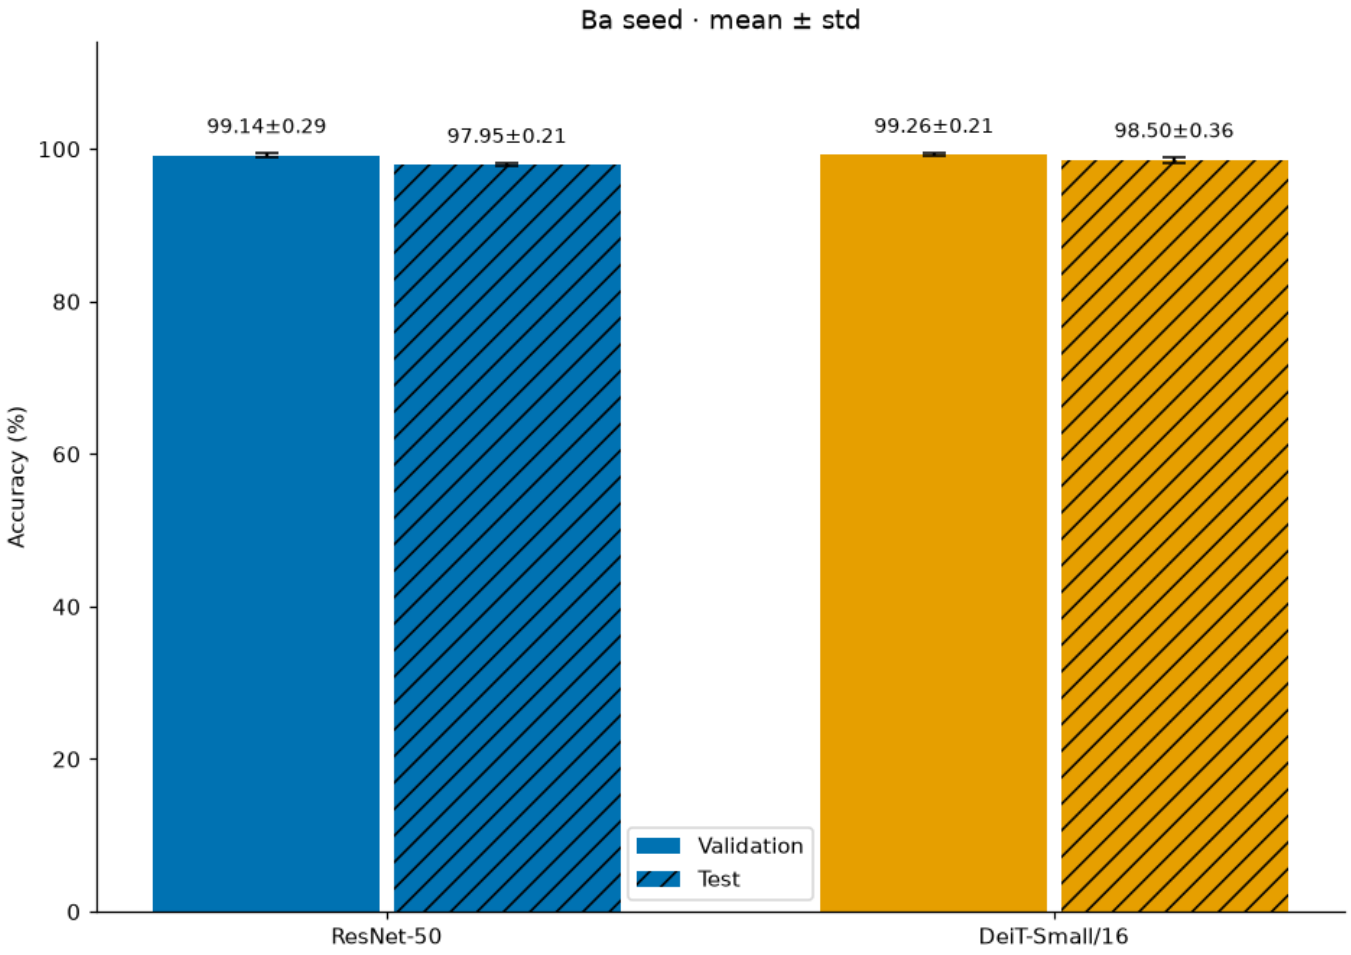

Hình 5.17: Accuracy trung bình và độ lệch chuẩn mẫu của ba seed; error bar không phải khoảng tin cậy.

Test accuracy trung bình là $97,95 \pm 0,21\%$ cho ResNet và $98,50 \pm 0,36\%$ cho DeiT; chênh lệch 0,55 điểm. Với $n = 3$ trên một split, đây là mô tả độ biến thiên, chưa là bằng chứng thống kê mạnh. Kết quả đại diện giữ seed 42, không chọn seed tốt nhất theo test.

5.7 Ma trận nhầm lẫn, lỗi và ảnh trùng

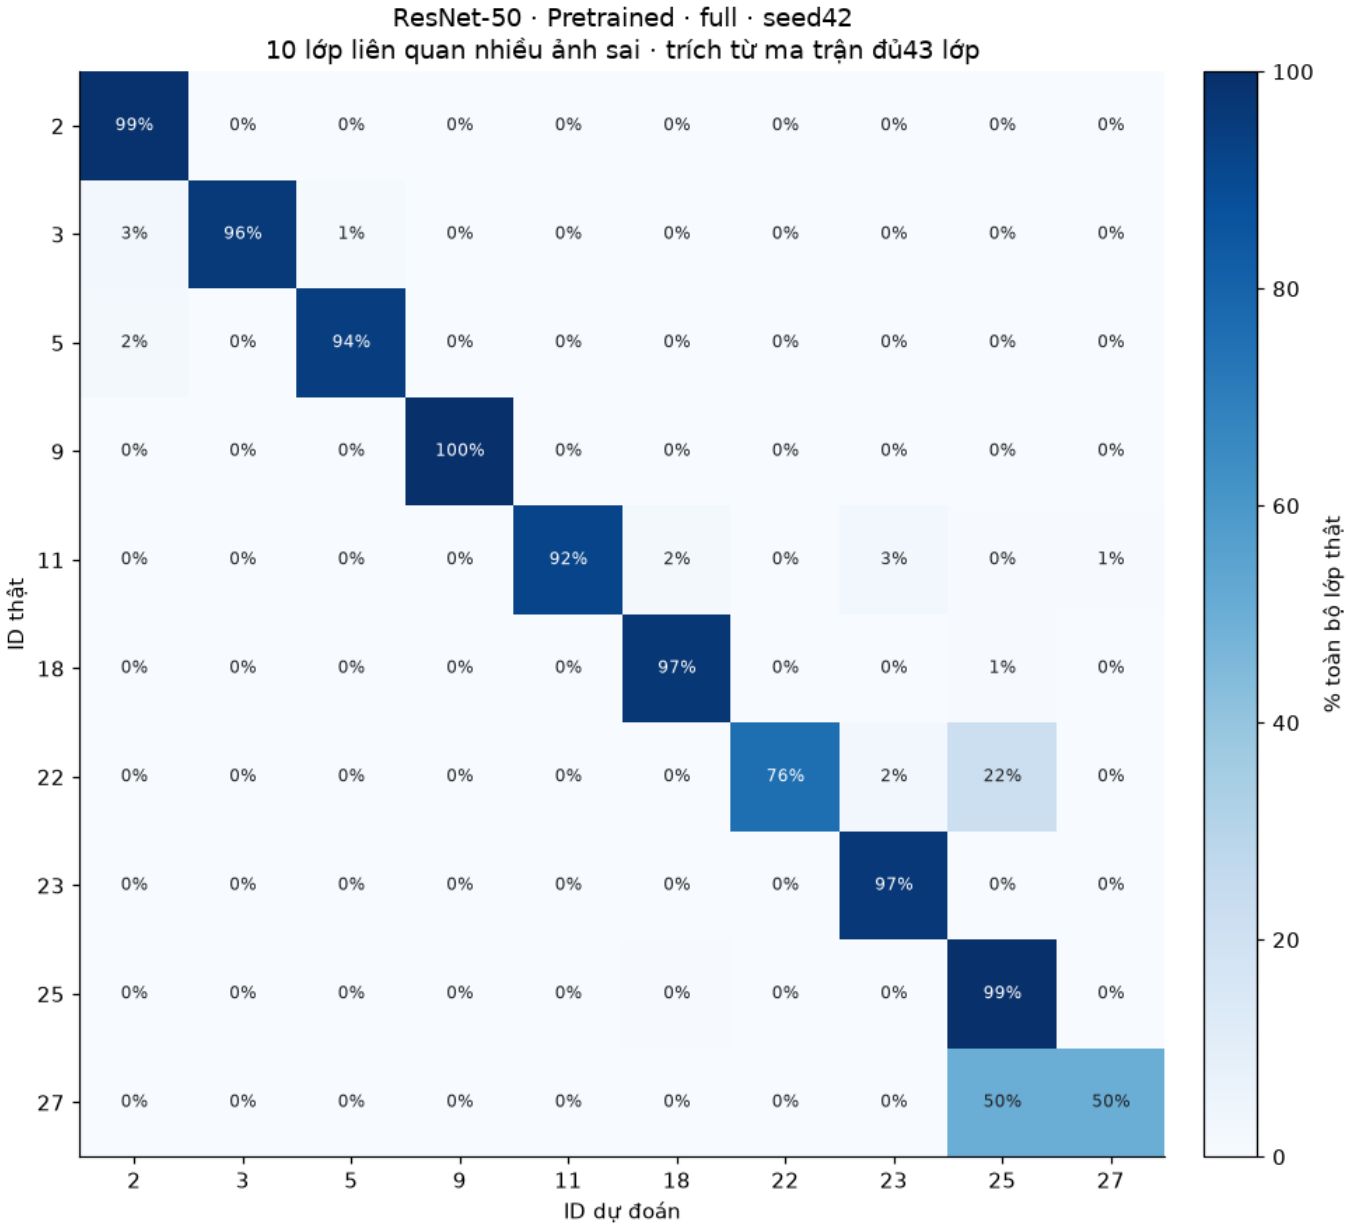

Hình 5.18: ResNet full seed 42: 10 lớp liên quan nhiều ảnh sai, trích chỉ số từ ma trận 43 lớp.

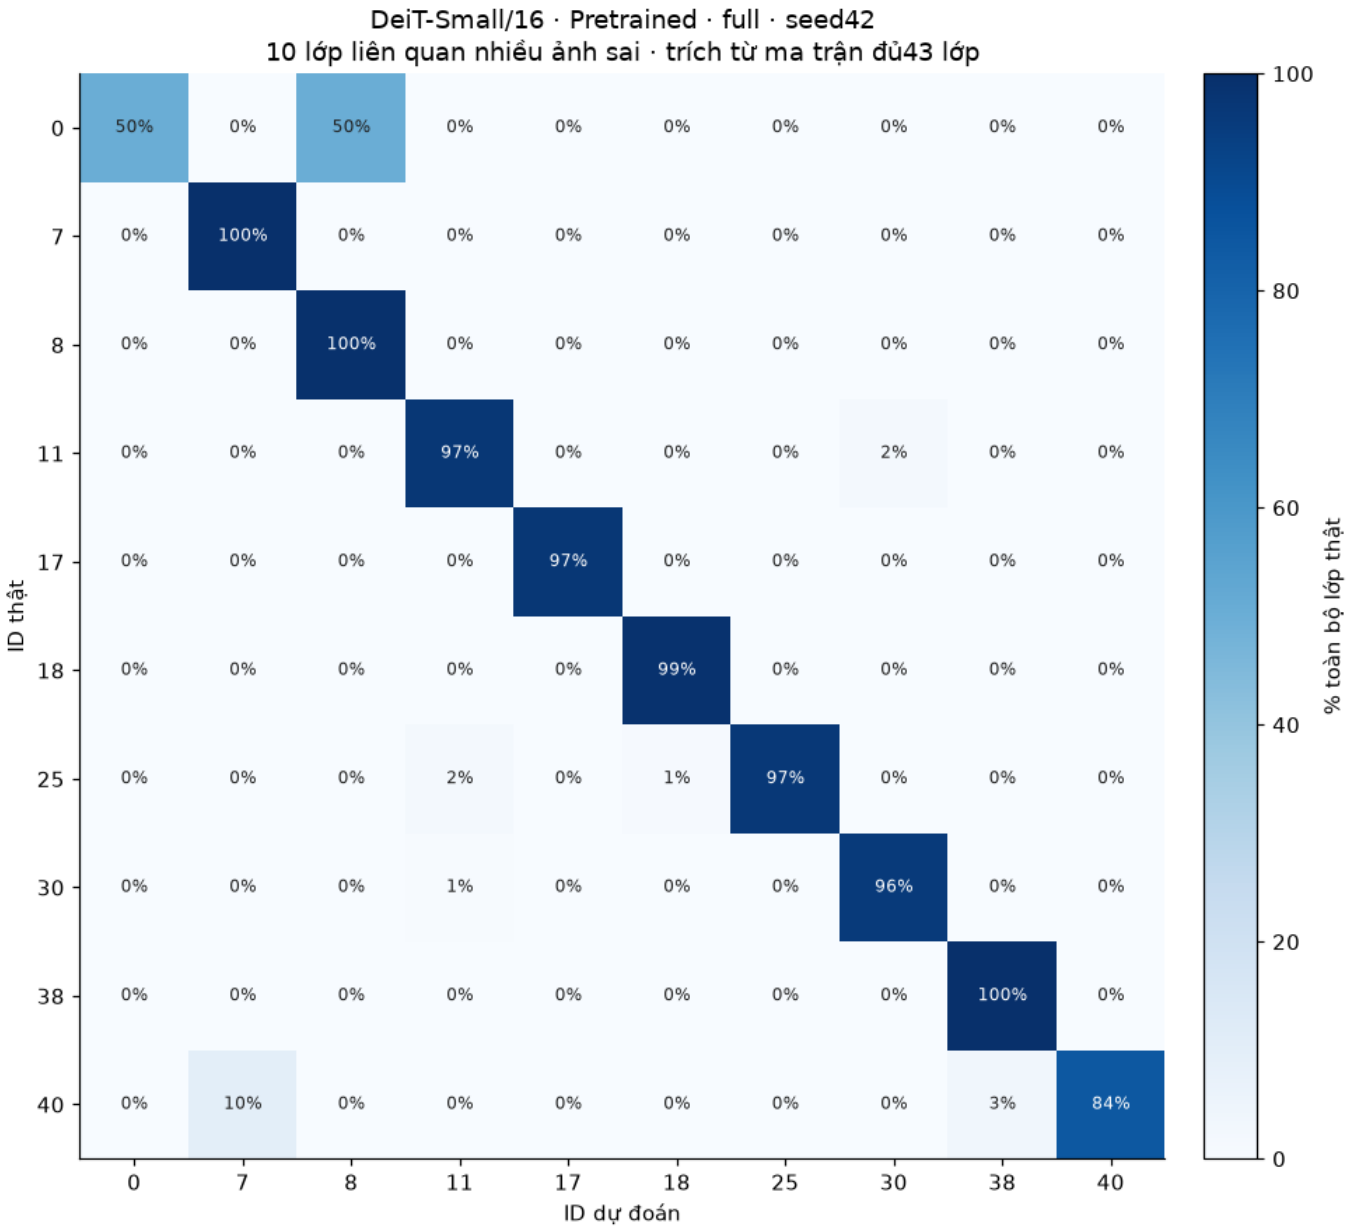

Hình 5.19: DeiT full seed 42: 10 lớp liên quan nhiều ảnh sai, cùng thang 0–100%.

Hàng là lớp thật, cột là dự đoán. Phần trăm dùng toàn bộ support lớp thật, không chuẩn hóa lại trên 10 lớp; tổng hàng hiển thị có thể dưới 100%. Ô làm tròn số nguyên. Ma trận đầy đủ 43×43 có trong notebook; Phụ lục liệt kê precision/recall/F1 của toàn bộ 43 lớp.

Bảng 5.11: Cặp lớp nhầm nhiều nhất của tám cấu hình chính; ID đi cùng tên lớp.

Run	Thật → dự đoán	Ảnh	% lớp thật
R-S/42	27: Pedestrians → 11: Right-of-way intersection	29	48,33%
R-H/42	1: Speed limit 30 → 2: Speed limit 50	197	27,36%
R-P/42	4: Speed limit 70 → 3: Speed limit 60	53	8,03%
R-F/42	27: Pedestrians → 25: Road work	30	50,00%
D-S/42	0: Speed limit 20 → 4: Speed limit 70	50	83,33%
D-H/42	1: Speed limit 30 → 2: Speed limit 50	133	18,47%
D-P/42	34: Turn left ahead → 33: Turn right ahead	78	65,00%
D-F/42	0: Speed limit 20 → 8: Speed limit 120	30	50,00%

ResNet full nhầm 30/60 Pedestrians (ID 27) thành Road work (ID 25), recall 0,500 và F1 0,638. DeiT full nhầm 30/60 Speed limit 20 (ID 0) thành Speed limit 120 (ID 8), recall 0,500 và F1 0,667. DeiT có recall Pedestrians 0,883; ResNet có recall Speed limit 20 0,967. Accuracy tổng cao vẫn có thể đi cùng lỗi ở lớp hiếm.

Bảng 5.12: Một số lớp khó trong hai full model seed 42; support, recall và F1.

Lớp	Support	R recall	R F1	D recall	D F1
Speed 20	60	0,967	0,983	0,500	0,667
Pedestrians	60	0,500	0,638	0,883	0,938
Bumpy road	120	0,758	0,863	0,950	0,970
Roundabout	90	0,933	0,923	0,844	0,916
Ice/snow	150	0,987	0,961	0,960	0,938

Hình 5.20: Ảnh sai ResNet full seed 42, bố cục 2 × 5; ghi nhãn thật và dự đoán.

Hình 5.21: Ảnh sai DeiT full seed 42; các mẫu minh họa không thay thế tần suất lỗi toàn tập.

Ví dụ cho thấy mờ, thiếu sáng và ký hiệu gần nhau. Đây là yếu tố nhìn thấy trong ảnh, chưa chứng minh nguyên nhân lỗi. Nhiều frame có thể cùng track, nên số ảnh sai không đồng nghĩa số biển vật lý độc lập.

Loại 8 ảnh trùng khỏi test làm accuracy tám run thay đổi từ $-0,001$ đến $-0,021$ điểm phần trăm. Hai full model đạt 97,83%/98,91% trên 12.622 ảnh không trùng. Macro-F1 head-only giảm 0,0001 ở mức làm tròn bốn chữ số; các run còn lại giữ cùng mức hiển thị. Độ nhạy tổng nhỏ nhưng không loại bỏ giới hạn độc lập của test nguồn.

5.8 Kết luận A1 và giới hạn

Full pretrained được chọn bằng validation ở cả hai họ. DeiT đạt test accuracy cao hơn ở seed 42 và trung bình ba seed; ResNet có throughput suy luận tốt hơn. Head-only tiết kiệm bộ nhớ nhưng accuracy thấp; partial cần được đánh giá cùng phạm vi unfreeze. Augmentation cải thiện cả hai họ trong phép so sánh seed 42.

Giới hạn gồm mất cân bằng lớp, ảnh trùng/gần giống, nhiều frame cùng track, ba seed chỉ cho full, partial không matched capacity và ngân sách/LR khác scratch–pretrained. Cơ chế nạp latest làm trạng thái trọng số đầu run ảnh hưởng khả năng tái lập; số epoch dừng sớm không đủ để suy tổng ngân sách học của một checkpoint. Các kết luận áp dụng cho dataset, split và protocol đã mô tả.

6. A2: RetinaNet và Faster R-CNN trên VOC2012

6.1 Bài toán và dữ liệu

Khác với phân loại ở A1, mỗi ảnh ở A2 có thể chứa nhiều đối tượng thuộc nhiều lớp. Mạng phải đồng thời dự đoán nhãn, bounding box và độ tin cậy. Thí nghiệm so sánh RetinaNet một giai đoạn với Faster R-CNN hai giai đoạn. Cả hai dùng ResNet-50 pretrained ImageNet và FPN; sự khác biệt nằm ở các mức pyramid, anchors, cách chọn mẫu và detection head.

PASCAL VOC2012 [2, 3] có 20 lớp và 11.540 ảnh trainval có nhãn. Toàn bộ số ảnh này được chia 80/10/10 bằng seed 42; các tập không giao nhau theo định danh ảnh. Test trong báo cáo là *holdout nội bộ*, không phải test chính thức VOC2012; không so trực tiếp với leaderboard của cuộc thi. Manifest tham chiếu JPEG/XML có sẵn, không nhân bản ảnh. Việc sử dụng tuân theo VOC Database Rights; quyền đối với từng ảnh thuộc về tác giả/chủ sở hữu gốc. Nguồn tải và định dạng nhãn được ghi trong README dữ liệu.

Bảng 6.1: Số ảnh và annotation VOC2012. Một bbox có thể vừa difficult vừa truncated.

Tập	Ảnh	Bbox thường	Difficult	Truncated
train	9.232	21.975	3.267	13.182
val	1.154	2.788	468	1.647
test	1.154	2.687	376	1.561

Nhãn XML gồm tên lớp, bndbox, difficult và truncated. Tọa độ VOC đánh số từ 1, bao gồm cả hai đầu, được chuyển thành khoảng nửa mở đánh số từ 0: $[x_{\min}-1, y_{\min}-1, x_{\max}, y_{\max}]$. Dataset trả về tensor RGB và danh sách bbox, class ID 1–20 cùng các cờ annotation. RetinaNet ánh xạ nhãn sang 0–19 khi tính loss, rồi chuyển về 1–20 khi suy luận. Faster R-CNN dành ID 0 cho background.

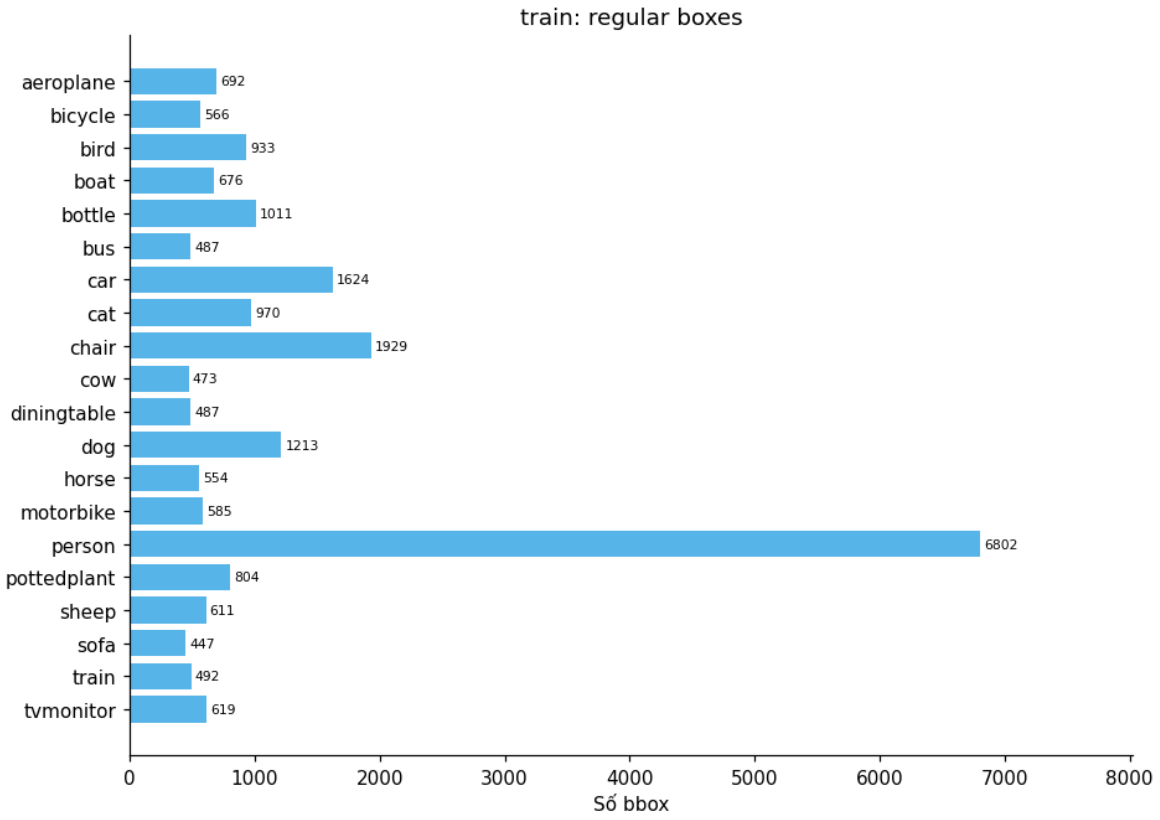

Hình 6.1: Số bbox thường theo lớp trong train.

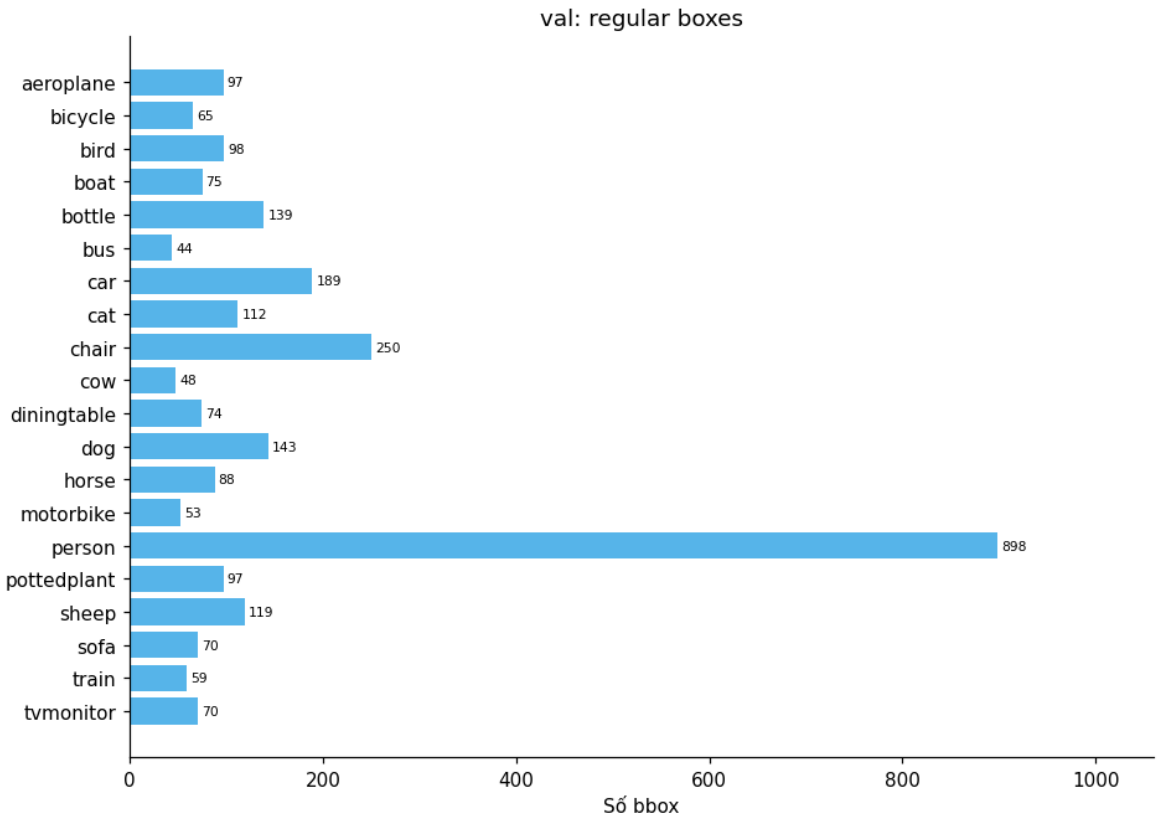

Hình 6.2: Số bbox thường theo lớp trong validation.

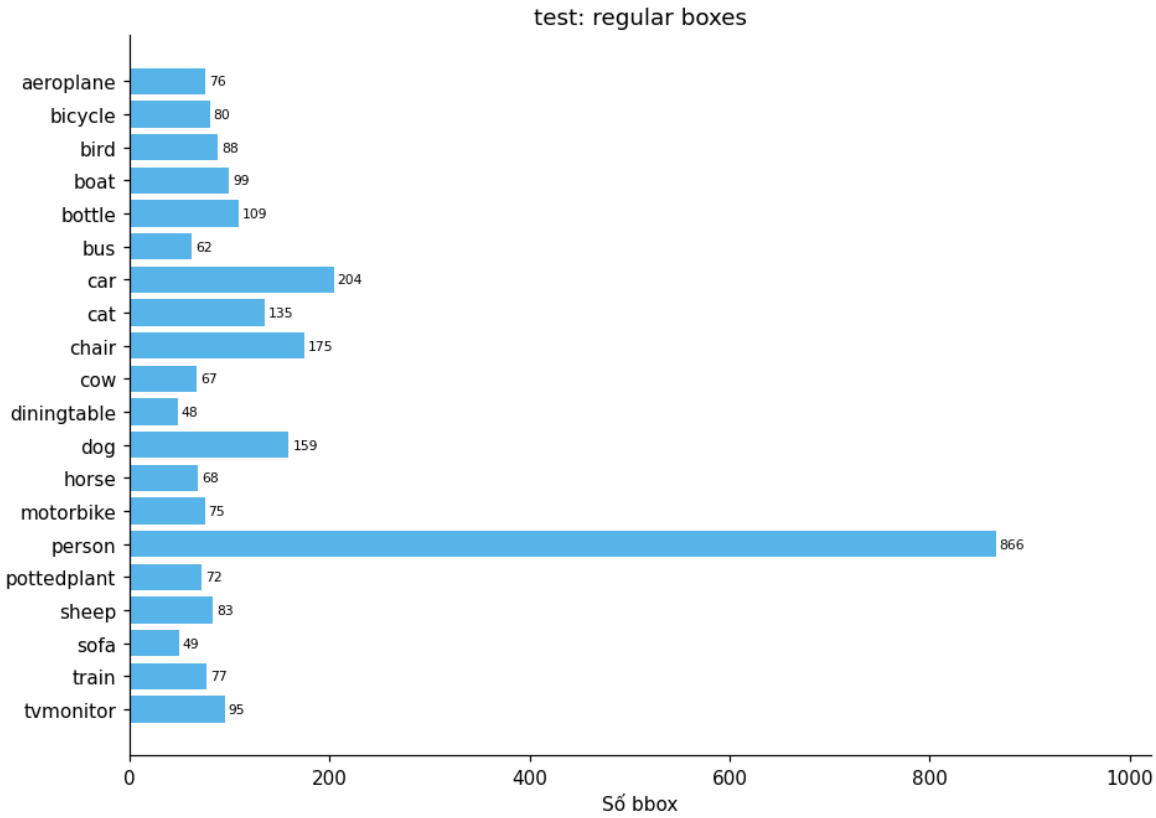

Hình 6.3: Số bbox thường theo lớp trong test.

Person chiếm 6.802/21.975 bbox thường ở train, khoảng 30,95%; sofa chỉ có 447 bbox. Báo cáo dùng cả AP từng lớp và macro-F1 để nhìn ảnh hưởng của mất cân bằng. Tổng theo lớp là số đối tượng, không phải số ảnh.

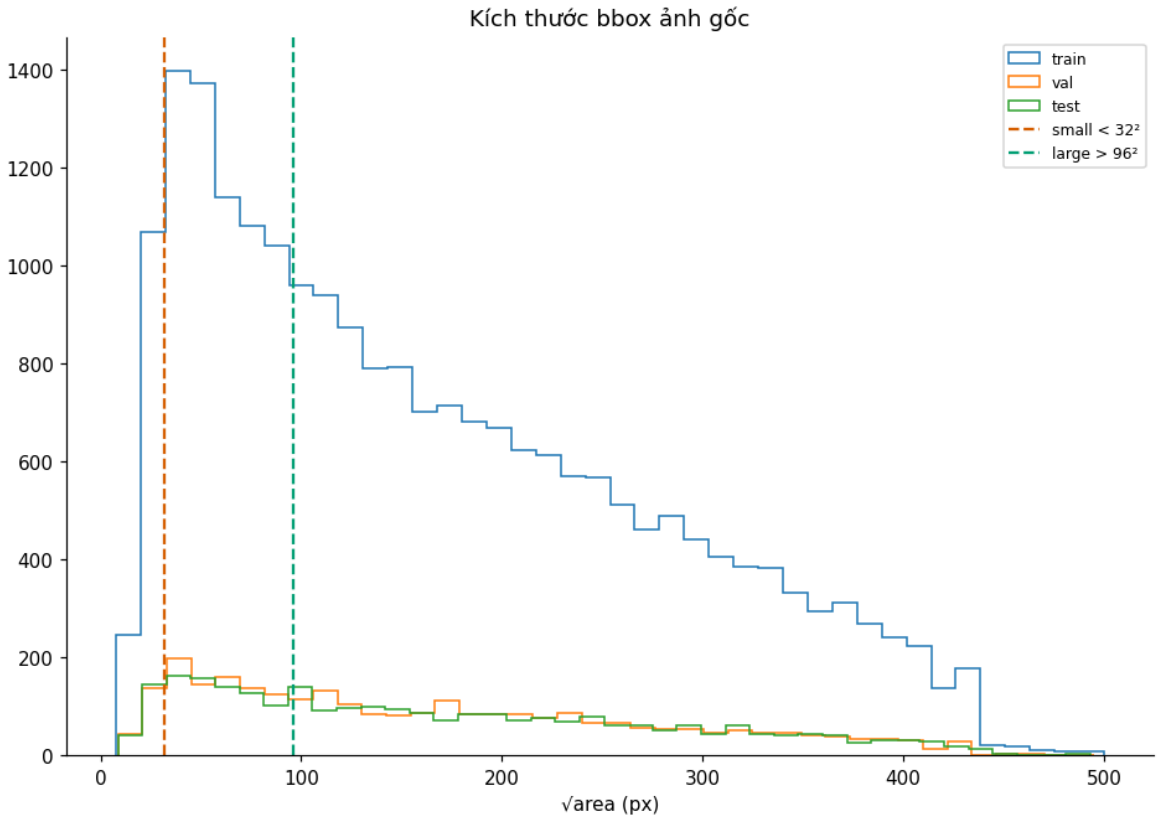

Hình 6.4: Phân bố diện tích bbox trên ảnh gốc theo split.

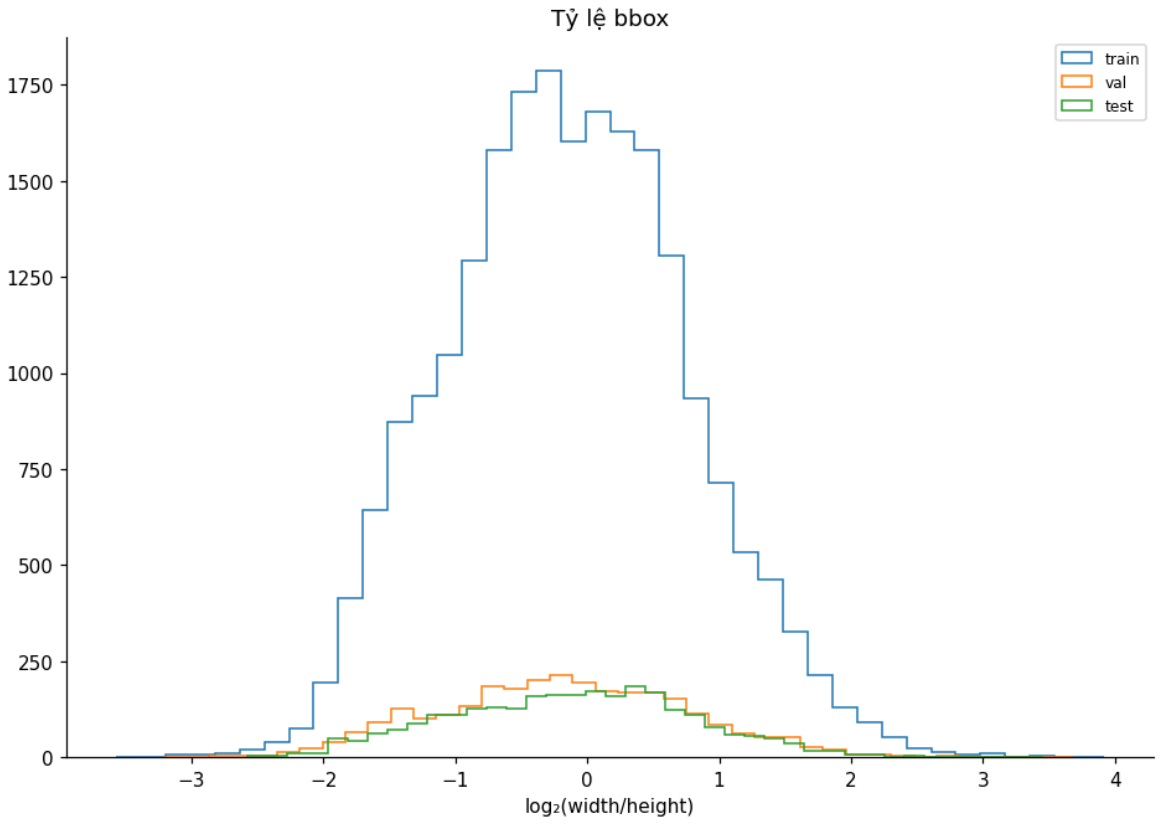

Hình 6.5: Phân bố tỷ lệ chiều rộng/chiều cao bbox.

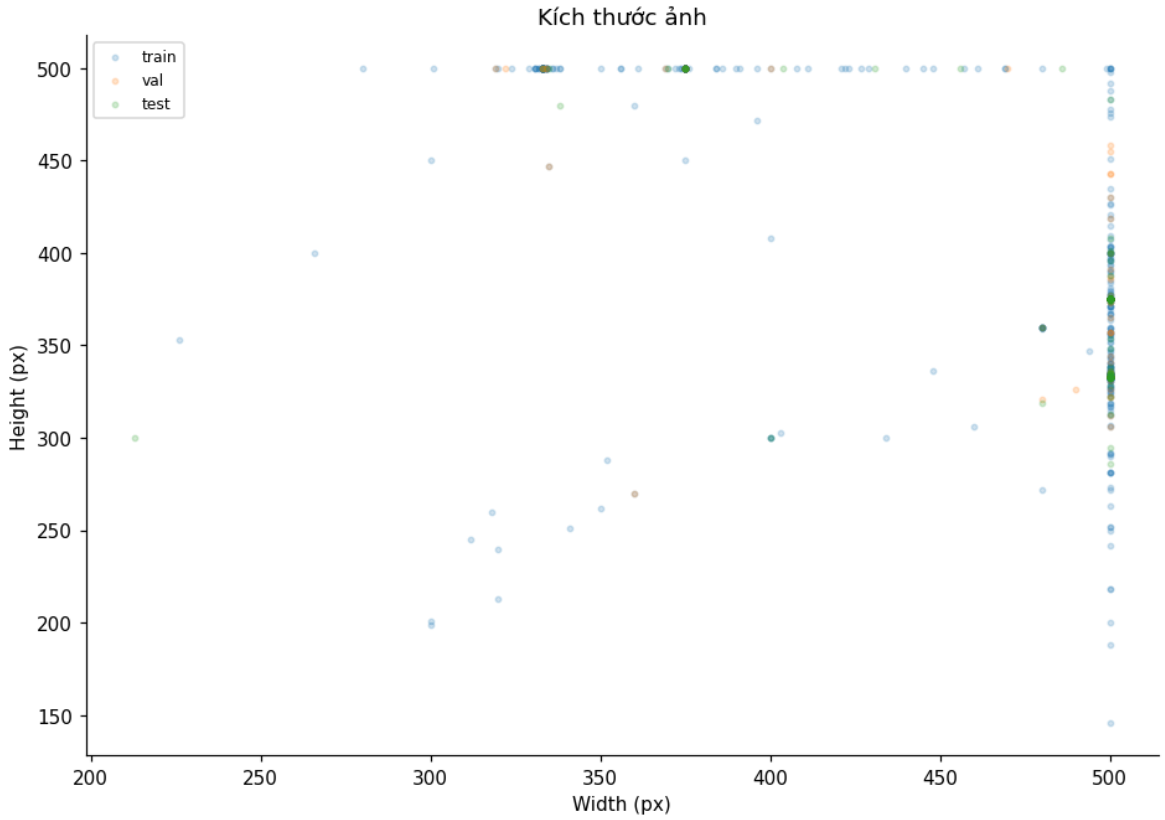

Hình 6.6: Chiều rộng và chiều cao ảnh nguồn.

BBox đa dạng về scale và tỷ lệ cạnh. FPN cung cấp nhiều stride, còn ba aspect ratio bao phủ vật thể cao, vuông và rộng.

6.2 Tiền xử lý và DataLoader

Resize giữ tỷ lệ, cạnh ngắn 600 px, cạnh dài tối đa 1.000 px. Phóng ảnh không bổ sung chi tiết đã mất ở ảnh gốc. Tensor nằm trong $[0, 1]$; model chuẩn hóa ImageNet một lần. Batch được pad đến bội số 32, nên VRAM còn phụ thuộc tỷ lệ cạnh các ảnh cùng batch. Không chia tiles.

Train áp dụng horizontal flip xác suất 0,5 và biến đổi bbox tương ứng; validation/test không có augmentation. DataLoader shuffle train, workers 0, không bỏ batch cuối. Cả hai mạng học toàn bộ bbox có nhãn, kể cả difficult. Khi đánh giá, difficult không tính vào số GT thường và detection khớp difficult được bỏ qua theo VOC. Truncated vẫn được học/đánh giá.

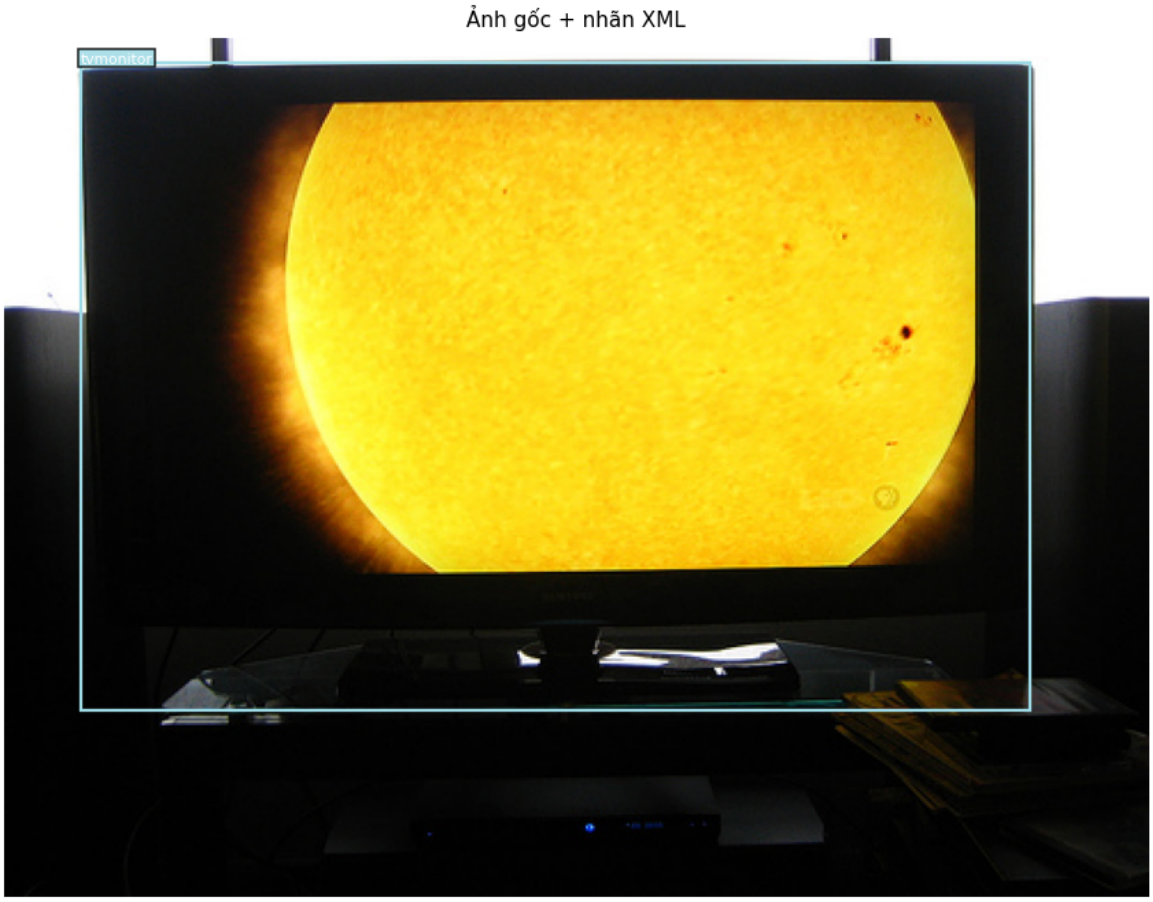

Hình 6.7: Ảnh gốc và bbox annotation.

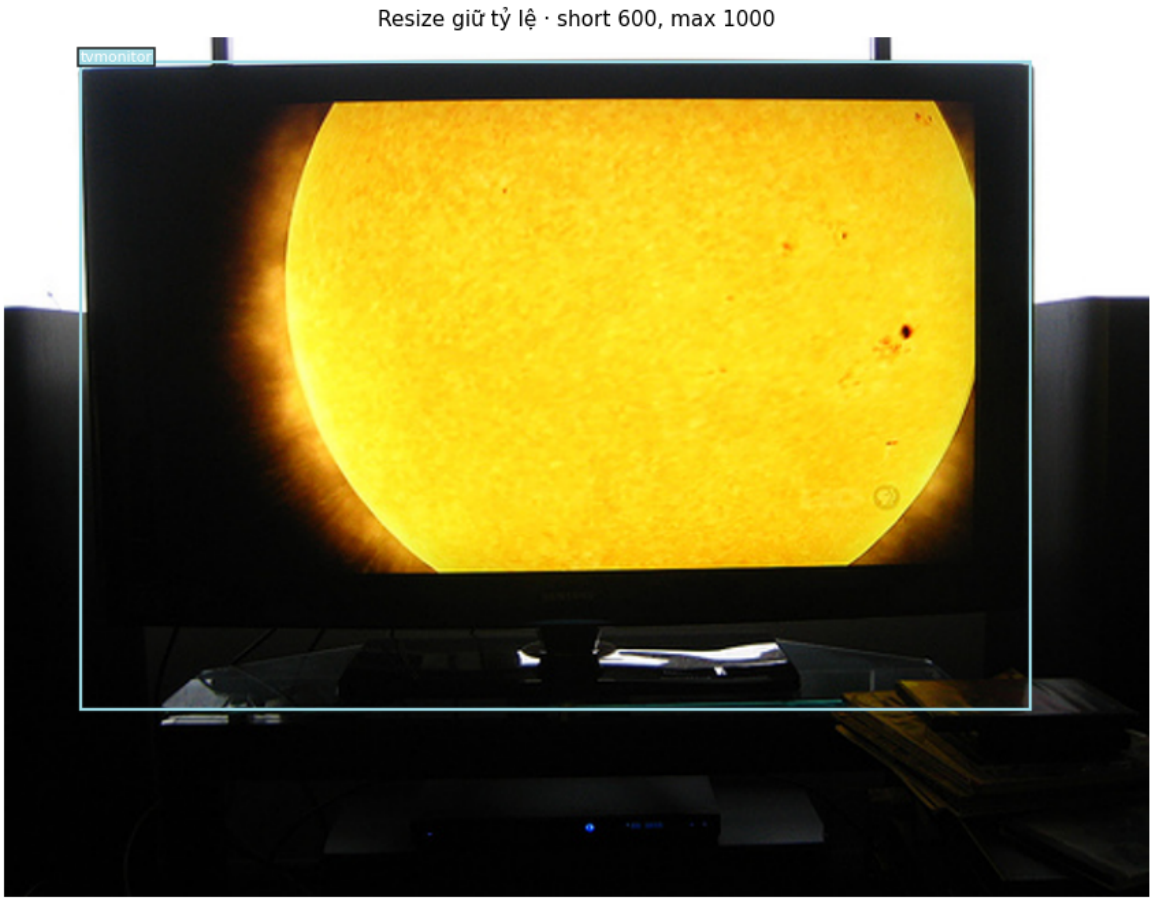

Hình 6.8: Resize giữ tỷ lệ; tọa độ bbox được đổi cùng ảnh.

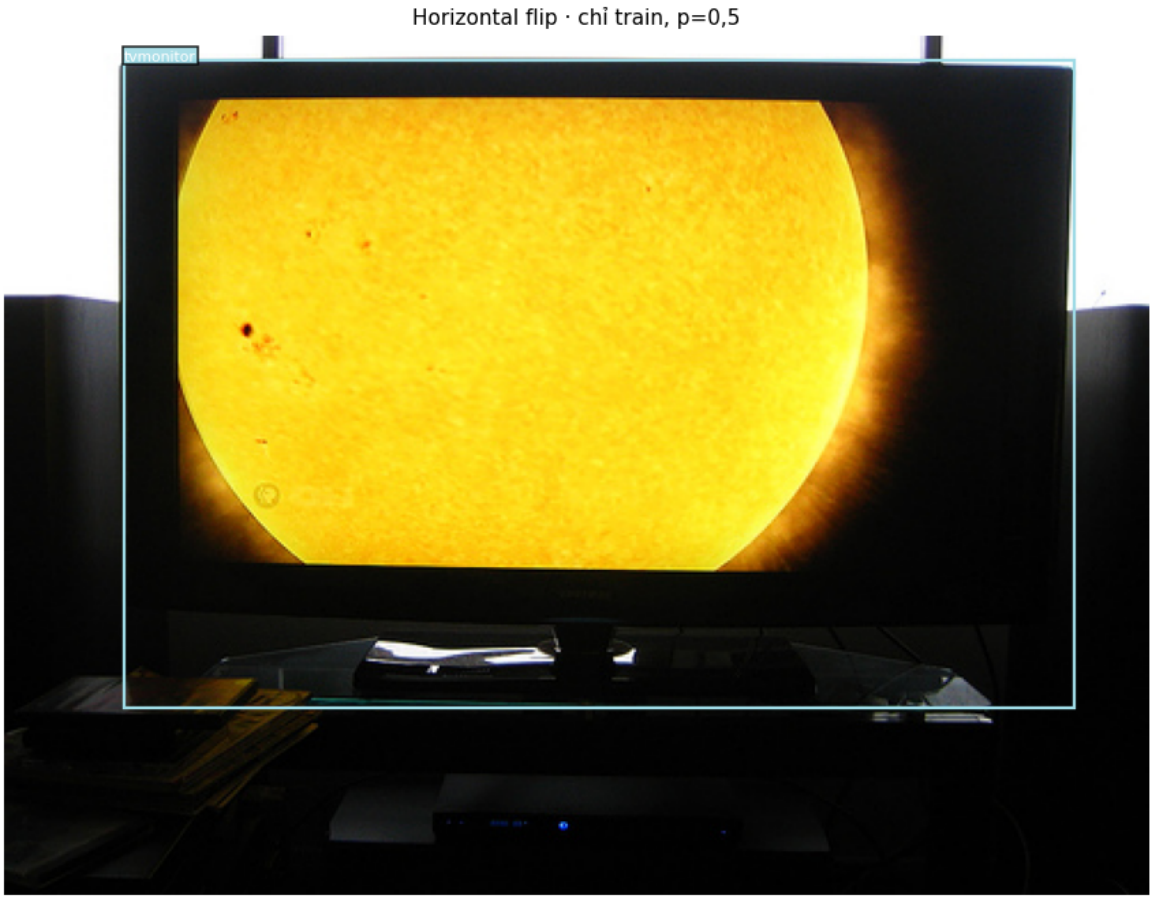

Hình 6.9: Horizontal flip của ảnh và bbox, chỉ áp dụng khi train.

6.3 FPN: phương pháp, thí nghiệm và giới hạn

Feature tầng sớm giữ chi tiết vị trí, trong khi tầng sâu có ngữ nghĩa mạnh hơn. FPN [5] kết hợp chúng bằng top-down và lateral connections. ResNet-50 xuất C2–C5, strides 4/8/16/32, channels 256/512/1.024/2.048. Với lateral L_l là Conv 1×1 đưa về 256 channels:

$$T_5 = L_5(C_5), \quad T_l = L_l(C_l) + \text{Upsample}_{\text{nearest}}(T_{l+1}), \quad P_l = \text{Conv}_{3\times3}(T_l). \tag{6.1}$$

Upsample đến đúng shape lateral; nhánh top-down truyền T trước smoothing, không truyền P sau smoothing. Neck không thêm BN/ReLU tại các mức này.

Bảng 6.2: Kết quả và ablation của FPN trên COCO; số liệu tác giả [5].

Thiết lập	Chỉ số	Giá trị
Table 1, ResNet-50 RPN C4	AR@1k	48,3
RPN FPN đầy đủ	AR@1k	56,3
Bỏ top-down / bỏ lateral	AR@1k	49,5 / 46,1
Chỉ P2, tăng anchors lên 750k	AR@1k	51,3
Table 3, Faster R-CNN C4 / FPN	AP	31,6 / 33,9
Table 3, Faster R-CNN C4 / FPN	AP50	53,1 / 56,9

Paper dùng COCO trainval35k và minival 5 k cho ablation. Bỏ một nhánh làm giảm recall; chỉ tăng số anchors ở P2 chưa đạt FPN đầy đủ. Kết quả hỗ trợ vai trò phối hợp ngữ nghĩa và độ phân giải, ngoài việc tăng số vị trí dự đoán. Thí nghiệm VOC dùng FPN cho cả hai mạng; không có ablation bỏ nhánh để đo riêng đóng góp của neck. FPN tăng activation ở mức độ phân giải cao và không tự giải quyết vật thể quá nhỏ, che khuất hoặc nhãn nhiễu.

6.4 RetinaNet và Focal Loss

6.4.1 Động cơ và hàm mất mát

Các anchors phủ dày trên ảnh tạo nhiều mẫu nền dễ phân loại, có thể lấn át gradient từ đối tượng thật. Focal Loss [6] giảm đóng góp của mẫu đã được dự đoán đúng:

$$\mathrm{FL}(p_t) = -\alpha_t(1-p_t)^{\gamma}\log p_t, \qquad \alpha = 0,25, \quad \gamma = 2. \tag{6.2}$$

Với $p_t = 0,9$, hệ số điều chỉnh là 0,01; với $p_t = 0,1$ là 0,81. $\alpha_t = \alpha$ cho mẫu dương, $1-\alpha$ cho mẫu âm; đây là cân bằng foreground/background, không phải cân bằng tần suất 20 lớp. Mỗi anchor có 20 xác suất sigmoid độc lập, không thêm một logit background. Loss phân loại chuẩn hóa theo số anchors dương; bbox dùng Smooth L1 beta 1. Bias classification khởi tạo theo xác suất tiên nghiệm của foreground $\pi = 0,01$.

Bảng 6.3: RetinaNet Table 1: ablation trên COCO minival và đánh đổi tốc độ/AP trên test-dev; số liệu tác giả [6].

Thiết lập	AP	Thời gian
Ablation, COCO minival (Table 1a–d)		
Alpha-balanced CE tốt nhất / Focal Loss	31,1 / 34,0	–
3 scales × 3 ratios	34,0	–
ResNet-101: OHEM tốt nhất / Focal Loss	32,8 / 36,0	–
Tốc độ/chất lượng, COCO test-dev (Table 1e)		
ResNet-50, cạnh ngắn 500	32,5	72 ms
ResNet-50, cạnh ngắn 800	35,7	153 ms

Paper dùng COCO trainval35k; thời gian đo trên GPU M40. Focal Loss cải thiện 2,9 điểm AP so với CE được cân bằng; trên ResNet-101, hơn OHEM tốt nhất 3,2 điểm AP. Tăng resize cũng tăng AP nhưng tốn thời gian. Các kết quả giải thích lựa chọn loss/scale, không phải mốc trực tiếp cho holdout VOC. Mẫu khó cũng có thể là annotation nhiễu; tập trung vào chúng không bảo đảm giải quyết mọi lớp hiếm hoặc che khuất.

6.4.2 Neck, anchors và head

RetinaNet dùng P3–P7. P3–P5 lấy từ C3–C5; P6 là Conv 3^2/stride 2 trên C5; P7 là Conv 3^2/stride 2 trên ReLU(P6).

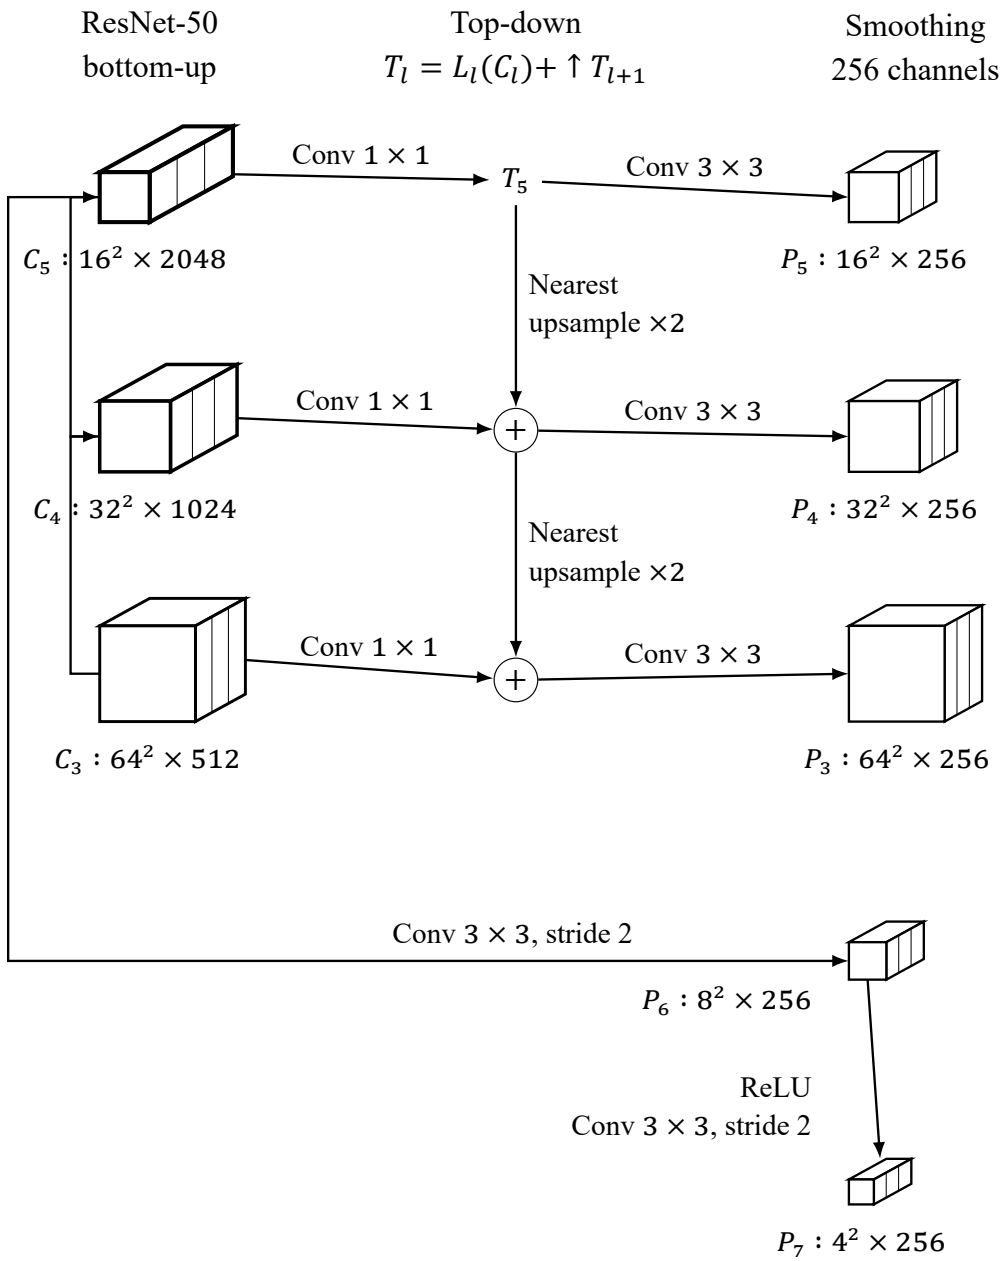

Hình 6.10: FPN RetinaNet. Shape minh họa tại input 512×512; thí nghiệm dùng resize 600/max 1000. Độ sâu khối thể hiện channels, không dùng cùng tỷ lệ với kích thước không gian.

Anchor bases 32/64/128/256/512, scales $1, 2^{1/3}, 2^{2/3}$, ratios $0,5, 1, 2$ tạo 9 anchors/vị trí. IoU $\geq 0,5$ là positive, $< 0,4$ là negative, khoảng giữa bỏ qua; matching giữ low-quality matches theo torchvision. Hai subnet có trọng số riêng; mỗi subnet gồm bốn Conv 3^2/256 + ReLU và một Conv output. Trọng số mỗi subnet dùng chung trên các mức.

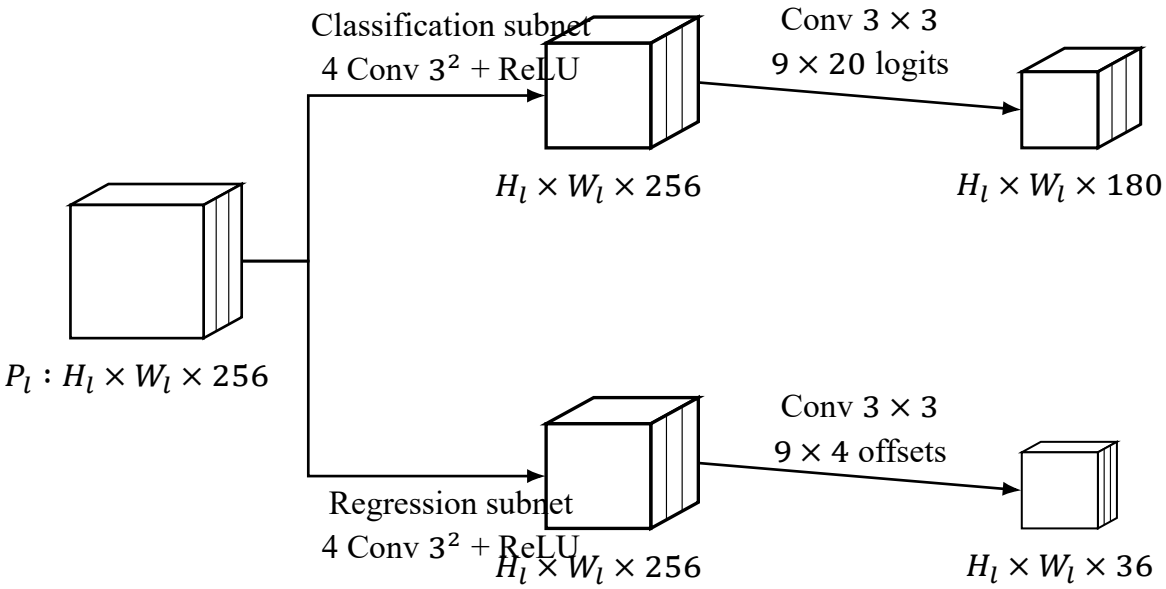

Hai subnet riêng; trọng số từng subnet dùng chung trên P3–P7.
Focal Loss ($\alpha = 0,25, \gamma = 2$) + Smooth L1.

Hình 6.11: RetinaNet head: $9 \times 20 = 180$ class logits, $9 \times 4 = 36$ offsets mỗi vị trí; không có logit background riêng.

6.5 Faster R-CNN: RPN và RoI head

Faster R-CNN [7] tạo đề xuất vùng rồi phân loại/hiệu chỉnh vùng. FPN dùng P2–P6 cho RPN; P6 là MaxPool 1^2/stride 2 trên P5. RoI head dùng P2–P5.

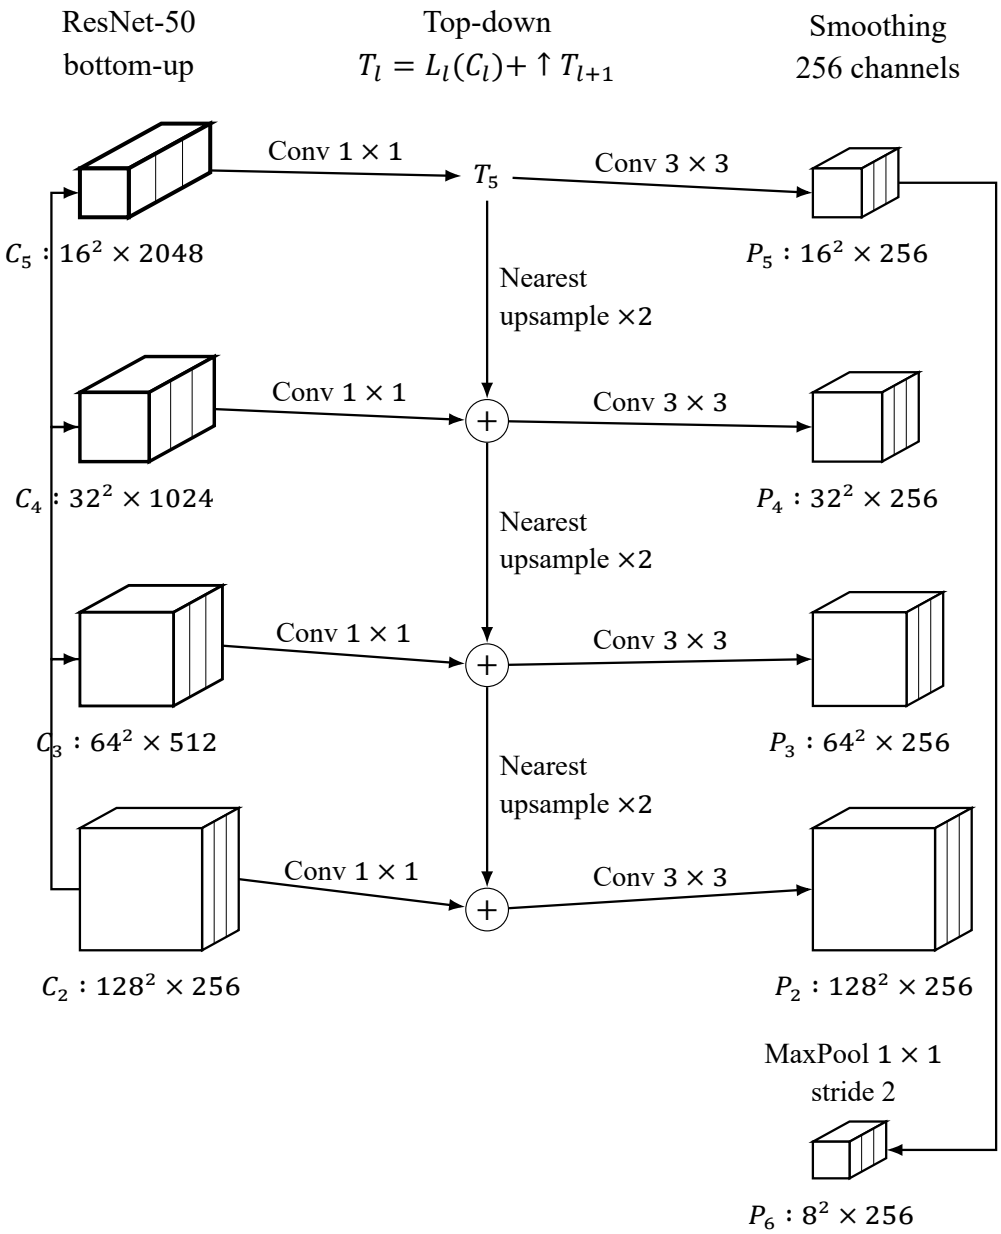

Hình 6.12: FPN Faster R-CNN: P2 có độ phân giải cao, P6 lấy từ P5. Shape ở input 512×512 chỉ để đối chiếu cấu trúc.

RPN gồm Conv $3^2/256$ + ReLU và hai nhánh 1^2 cho objectness/bbox. Bases 32–512, một scale, ba ratios tạo 3 anchors/vị trí. Positive IoU $\geq 0,7$ hoặc best anchor, negative $< 0,3$; sample 256 anchors/ảnh, tối đa 50% positive. NMS proposals dùng 0,7, giữ 2.000 proposals/train và 1.000/test.

RoI gán mức theo FPN:

$$k = \text{clip}_{[2,5]} \left\lfloor 4 + \log_2 \left(\frac{\sqrt{wh}}{224} \right) \right\rfloor. \tag{6.3}$$

RoI Pooling 7^2 lượng tử hóa tọa độ và max pooling, không dùng RoIAlign. Tensor $7 \times 7 \times 256$ flatten thành 12.544, qua hai FC 1.024 + ReLU rồi tách 21 logits và 84 class-specific offsets.

Train sample 512 RoIs/ảnh, tối đa 25% positive. Bốn loss gồm RPN objectness/bbox và RoI classification/bbox; hai bbox loss dùng Smooth L1 beta $1/9$.

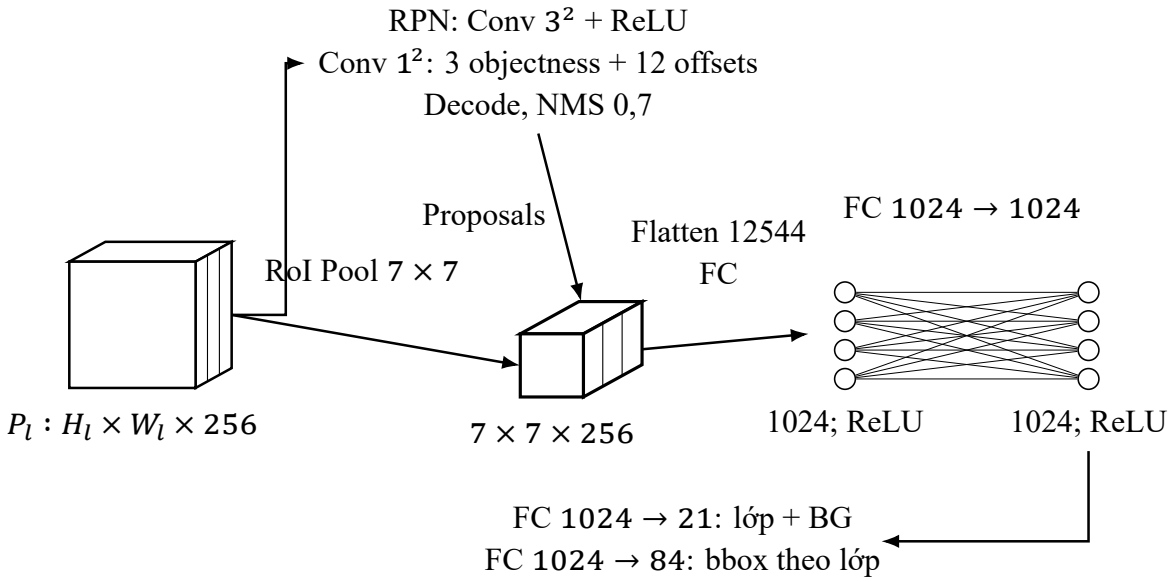

RPN: P2–P6; RoI Pool: P2–P5 theo $\lfloor 4 + \log_2(\sqrt{wh}/224) \rfloor$.
Loss: objectness + classification CE, hai thành phần Smooth L1.

Hình 6.13: Faster R-CNN: RPN tạo proposals, RoI Pool gom feature, hai FC trước hai nhánh output.

Hai mạng cùng decode bbox, score floor 0,05, class-wise Hard-NMS 0,5, cap 100 detections/ảnh. RetinaNet lọc top 1.000 candidates/mức trước NMS. Gallery dùng score từ 0,30 và tối đa 15 boxes; metric không bị giới hạn theo số box hiển thị.

Bảng 6.4: Số tham số trainable. FrozenBatchNorm giữ statistics/buffers cố định.

Mạng	Backbone	FPN	Head/RPN/RoI	Tổng
RetinaNet	23.454.912	7.997.440	5.218.520	36.670.872
Faster R-CNN	23.454.912	3.344.384	14.597.240	41.396.536

6.6 Huấn luyện và lựa chọn weights

ResNet-50 nạp ImageNet-1K V1, bỏ FC ImageNet; các Conv được fine-tune. Các lateral/smoothing chung khởi tạo giống nhau theo seed; head và neck bổ sung khởi tạo mới. Không nạp pretrained detection trên COCO.

Thí nghiệm chạy trên Kaggle với hai Tesla T4, mỗi GPU có 14,6 GiB bộ nhớ khả dụng. Hai worker độc lập train đồng thời: RetinaNet trên GPU 0, Faster R-CNN trên GPU 1. Mỗi model nằm trên một GPU, không chia batch qua hai GPU và không dùng distributed training.

SGD LR 0,01, momentum 0,9, weight decay 10^{-4}; warmup một epoch từ 0,1 lần LR rồi cosine đến 0,01 lần LR trong lịch tối đa 30 epoch. Clip gradient norm 10; AMP float16 cho

convolution, RetinaNet loss và RoI Pool tính FP32. Batch train/eval 8, accumulation 3, effective batch 24. Mỗi epoch có 1.154 batches train và 145 validation; test cũng có 145. Có 385 cập nhật SGD/epoch. Gradient chuẩn hóa theo số ảnh thực của cửa sổ; cửa sổ cuối chỉ có 16 ảnh nên không được chia như một cửa sổ 24 ảnh.

Dừng sớm theo validation VOC mAP50, patience 2, min-delta 0,001. Checkpoint giữ điểm validation cao nhất, cập nhật khi có bất kỳ cải thiện nào; riêng bộ đếm dừng sớm đòi hỏi cải thiện hơn 0,001 so với mốc của nó. File latest.pt chỉ giữ best weights. Nếu nạp weights có sẵn, validation ban đầu làm baseline, còn optimizer, lịch LR và bộ đếm bắt đầu cho lượt train hiện tại. Đây là tiếp tục từ weights, không khôi phục đầy đủ trạng thái của một epoch bị gián đoạn.

Hai worker hoàn tất train/validation trước khi mở test. Sau đó cả hai model được test và benchmark lần lượt trên GPU 0; test không chọn epoch hoặc confidence.

Bảng 6.5: Epoch thực chạy, best epoch, validation VOC mAP50 và số cập nhật SGD.

Mạng	Epoch	Best	Val mAP50	Updates	AMP skips
RetinaNet	21	19	0,7323	8.085	0
Faster R-CNN	17	15	0,7626	6.545	0

RetinaNet chạy 21 epoch, chọn epoch 19; Faster R-CNN chạy 17 epoch, chọn epoch 15. Tổng 38 epoch và 14.630 cập nhật, không AMP skips. Thời gian train/validation từng worker là 465,01 và 430,23 phút, gồm tải dữ liệu, validation metric và ghi checkpoint/lịch sử, không gồm test/vẽ hình. Hai worker chạy song song; thời gian chờ chung ghi trong output là 465,1 phút, không phải tổng hai cột thời gian.

6.6.1 Phạm vi đối chiếu paper

FPN paper dùng COCO và feature sharing bốn bước; cài đặt VOC train joint RPN/RoI. RetinaNet paper dùng batch 16/lịch 90k iterations với các mốc giảm LR; ở đây dùng effective batch 24, epoch/cosine/dừng sớm. Resize chung 600/max 1000, ResNet-v1.5, anchor rounding, low-quality matching và Smooth L1 theo torchvision cũng khác một số chi tiết của tác giả. Thí nghiệm tái hiện nguyên lý top-down/lateral/smoothing của FPN và head/Focal Loss của RetinaNet; không tái lập điểm benchmark COCO của paper. Hai detector dùng chung split, backbone khởi tạo, resize, optimizer và protocol đánh giá để so sánh trong phạm vi holdout VOC.

6.7 Chỉ số đánh giá

VOC2010–2012 mAP50 all-point là metric chính: sort score, matching one-to-one cùng class, IoU $> 0,5$, tích phân precision envelope theo recall [3]. Duplicate thường là FP; matches difficult bị bỏ qua. VOC07 AP11 bổ sung để phân biệt cách nội suy.

COCO-style AP trung bình 10 ngưỡng IoU 0,50–0,95, bước 0,05, 101 recall points, max 100 detections/ảnh [1]. AP50/AP75 và AP/AR theo scale bổ sung phân tích định vị. Small/medium/large dùng diện tích bbox ảnh gốc, theo mốc $32^2/96^2$. Evaluator giữ union IoU và bỏ qua repeated matches difficult theo VOC. Đây là metric COCO-style trên VOC, không phải điểm chính thức COCO; cách xử lý difficult không tương đương crowd annotation của COCO. VOC AP50 và COCO-style AP50 khác cách nội suy/biên IoU.

P/R/F1 dùng matching class-wise VOC tại score 0,30; micro-F1 gộp TP/FP/FN, macro-F1 trung bình 20 lớp. Ma trận chẩn đoán dùng class-agnostic greedy theo score, IoU $\geq 0,5$, để nhìn nhầm lớp. Background biểu diễn FP/FN. Matched IoU là trung bình TP trong chẩn đoán, không thay thế AP. Score floor/cap chung có thể giới hạn recall, được giữ như nhau ở hai mạng.

6.8 Kết quả test và so sánh

Bảng 6.6: Test holdout 1.154 ảnh, 2.687 bbox thường. Metric ở thang 0–1.

Chỉ số	RetinaNet	Faster R-CNN
VOC mAP50	0,7088	0,7316
VOC07 mAP11	0,6886	0,7123
COCO-style AP50:95	0,3913	0,4098
COCO-style AP50	0,7077	0,7308
COCO-style AP75	0,3767	0,4189
Precision (score 0,30)	0,5037	0,3873
Recall (score 0,30)	0,7838	0,8366
Micro-F1 (score 0,30)	0,6133	0,5295
Macro-F1 (score 0,30)	0,5836	0,5324
Matched IoU (chẩn đoán)	0,7707	0,7775

Faster R-CNN đạt VOC mAP50 73,16%, hơn RetinaNet 2,28 điểm phần trăm; COCO-style AP50:95 đạt 40,98%, hơn 1,85 điểm. AP75 cũng cao hơn (41,89% so với 37,67%), cho thấy lợi thế vẫn giữ khi đòi hỏi bbox khớp chặt hơn. Khoảng cách validation–test mAP50 là 2,35 điểm ở RetinaNet và 3,10 điểm ở Faster R-CNN.

Tại confidence 0,30, Faster R-CNN recall cao hơn (0,8366 so với 0,7838), nhưng precision thấp hơn (0,3873 so với 0,5037). RetinaNet có micro-F1 0,6133, hơn Faster R-CNN 0,5295; macro-F1 cũng cao hơn. AP tổng hợp thứ hạng trên cả đường precision–recall, còn F1 phản ánh một ngưỡng cố định; hai cách xếp hạng này không mâu thuẫn. Không điều chỉnh confidence bằng test.

Bảng 6.7: COCO-style AP theo scale và AR trung bình qua các ngưỡng IoU.

Chỉ số	RetinaNet	Faster R-CNN
AP small	0,1296	0,1392
AP medium	0,2684	0,3057
AP large	0,4473	0,4606
AR@1	0,3730	0,3862
AR@10	0,5210	0,5386
AR@100	0,5345	0,5437
AR small	0,2860	0,2038
AR medium	0,4238	0,4616
AR large	0,5814	0,5866

APsmall chỉ 12,96%/13,92%, thấp hơn nhiều so với APlarge 44,73%/46,06%. Faster R-CNN hơn APsmall 0,96 điểm, nhưng RetinaNet có ARsmall cao hơn (0,2860 so với 0,2038). Recall nhóm nhỏ và AP nhóm nhỏ không đo cùng một đánh đổi precision–recall. Hai model còn khác anchors/head/sampling, chưa thể quy riêng lợi ích cho P2. AR@10 lên AR@100 chỉ tăng 0,0135/0,0051; tăng số detections giữ lại đem lại ít recall trong thiết lập này.

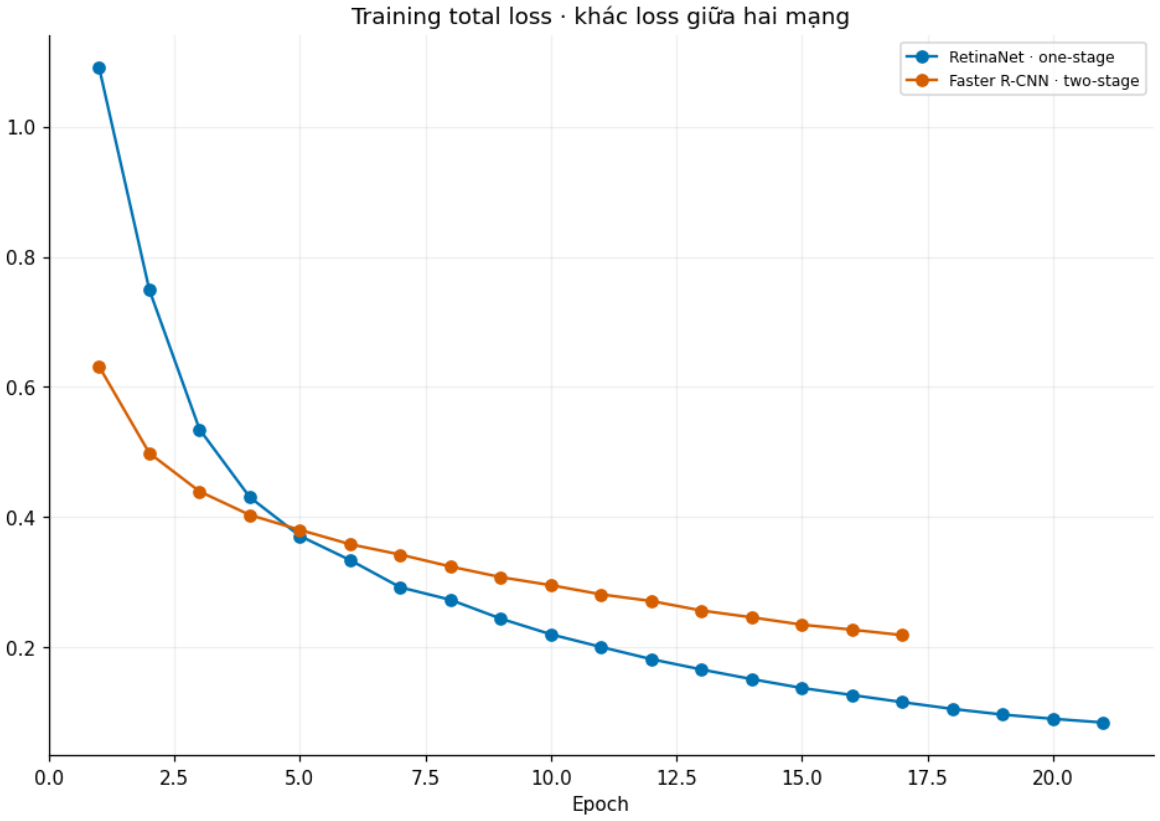

Hình 6.14: Tổng loss train của hai detector; độ lớn loss không dùng xếp hạng vì thành phần và chuẩn hóa khác nhau.

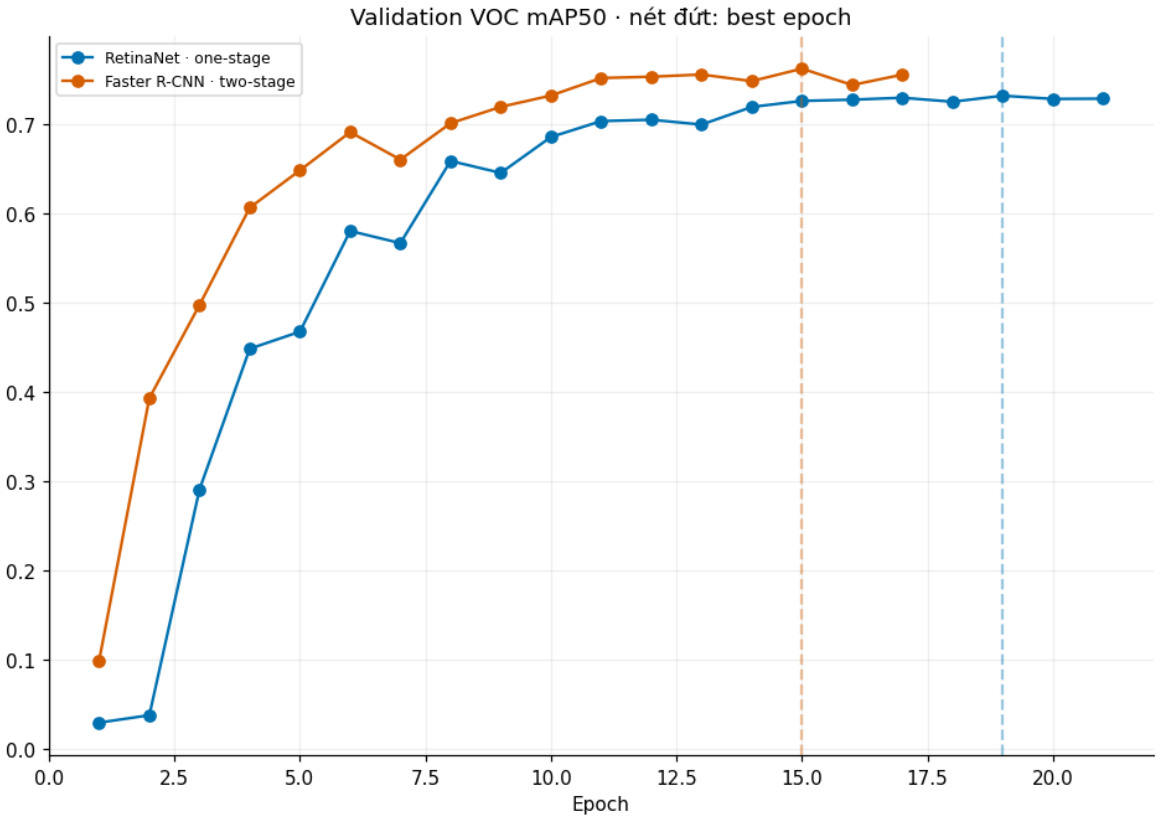

Hình 6.15: Validation VOC mAP50; nét đứt đứng chỉ best epoch của từng model.

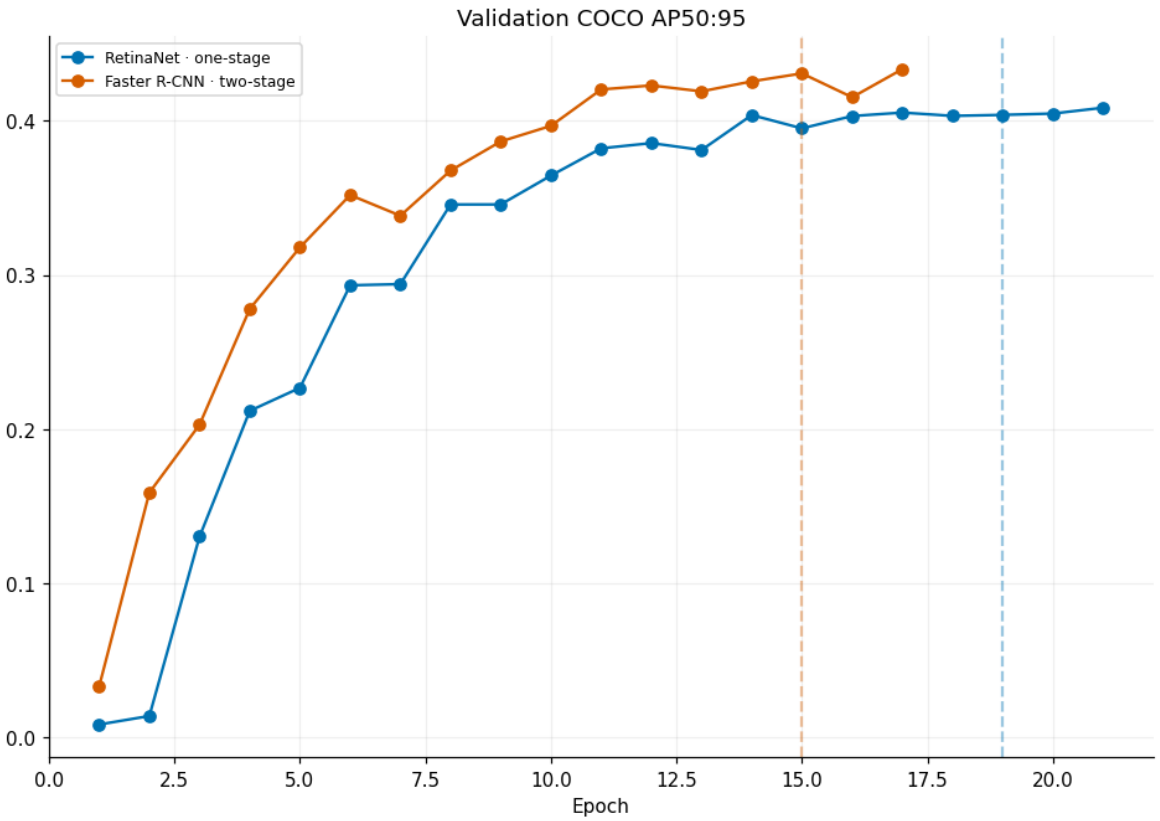

Hình 6.16: Validation COCO-style AP50:95 qua các epoch.

Loss giảm trong khi validation dao động quanh vùng bão hòa. RetinaNet chạy nhiều epoch hơn nhưng không vượt Faster R-CNN ở hai chỉ số AP test chính. Early stopping hạn chế các epoch không cải thiện đủ; best weights được đánh giá riêng sau khi train.

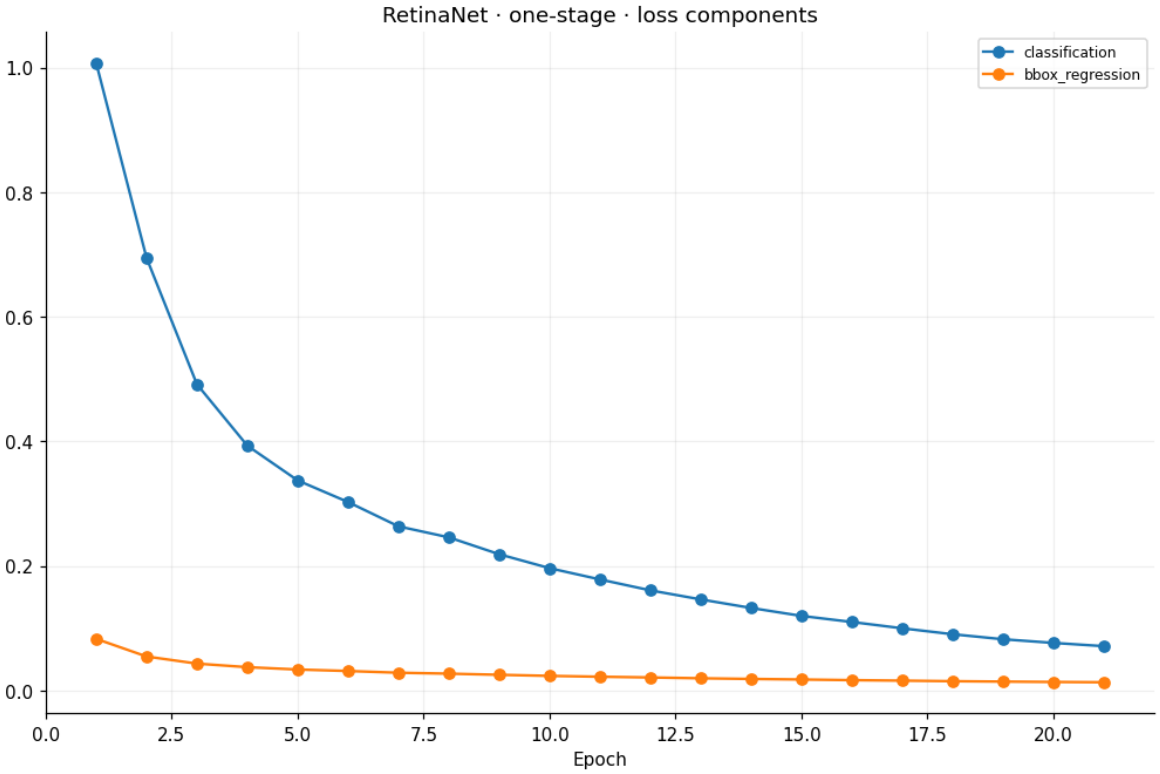

Hình 6.17: Hai thành phần loss RetinaNet: classification và bbox regression.

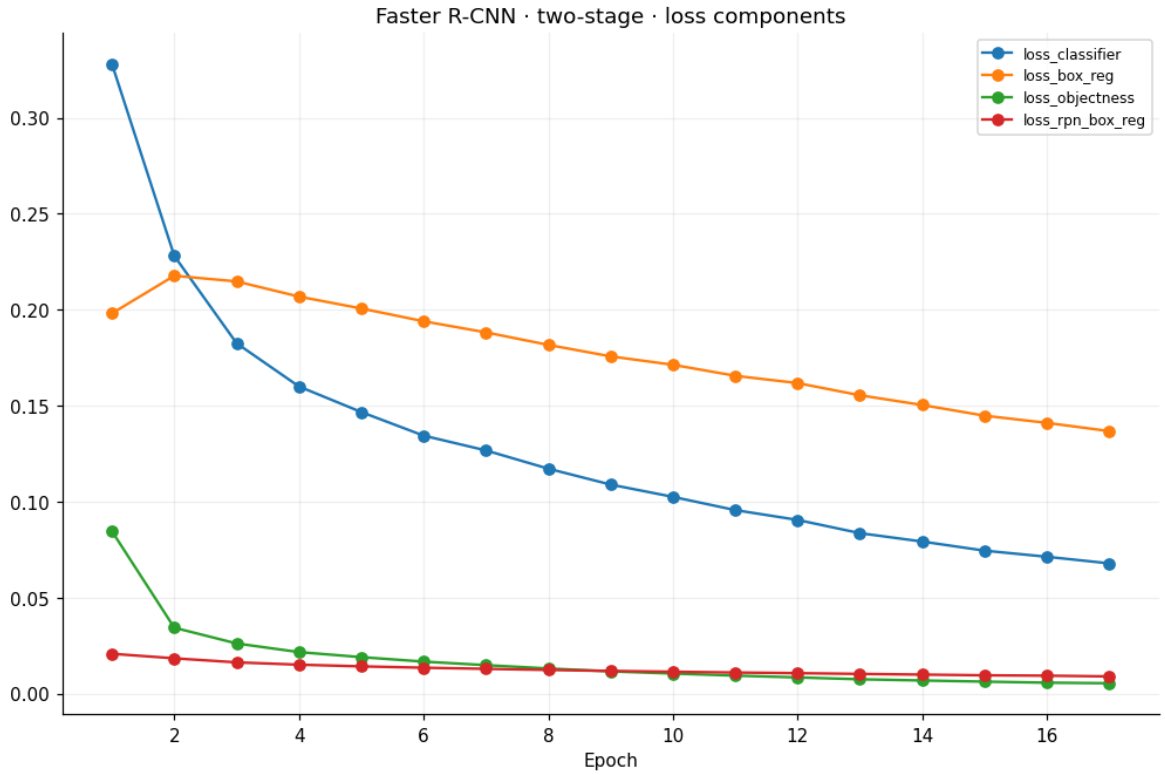

Hình 6.18: Bốn thành phần loss Faster R-CNN: objectness/bbox RPN và classification/bbox RoI.

6.8.1 Chi phí huấn luyện và suy luận

Bảng 6.8: Chi phí trên Tesla T4. Peak là allocated PyTorch từng worker; benchmark hai model lần lượt trên cùng GPU 0.

Chỉ số	RetinaNet	Faster R-CNN
Tham số (triệu)	36,6709	41,3965
Peak allocated VRAM (MiB)	12818,4980	12939,5137
Train + validation (phút)	465,0069	430,2281
Median latency batch 1 (ms)	39,8742	44,0897
P95 latency batch 1 (ms)	47,3764	45,7869
FPS batch 1	25,0789	22,6810
Throughput batch 8 (ảnh/s)	17,6673	15,1885
Batch benchmark	8	8
Pipeline test (ảnh/s)	13,8253	14,4813

RetinaNet có 36,67 triệu tham số, ít hơn Faster R-CNN 4,73 triệu. Train/validation trung bình 22,14/25,31 phút mỗi epoch; Faster R-CNN có tổng thời gian riêng thấp hơn vì chạy ít epoch. Peak allocated là 12,52/12,64 GiB. Số tham số hoặc số giai đoạn chưa đủ để suy ra chi phí thực tế.

Benchmark dùng AMP và CUDA events, warmup ba lượt; batch 1 đo 20 lần, batch 8 đo 10 lần. Latency model gồm resize, normalize, backbone, neck, head và decode/NMS; không

gồm đọc JPEG, chuyển ảnh từ CPU hoặc metric CPU. Median batch 1 là 39,87/44,09 ms, tương ứng 25,08/22,68 FPS; RetinaNet cao hơn khoảng 10,6% về FPS. P95 lại là 47,38/45,79 ms, nên lợi thế median không kéo theo lợi thế ở đuôi phân bố latency.

Throughput batch 8 là 17,67/15,19 ảnh/s. Batch 1 dùng một ảnh, batch 8 dùng nhóm ảnh khác tỷ lệ cạnh và padding; đây không phải phép thử scaling với workload đồng nhất. Pipeline test gồm DataLoader, chuyển tensor lên GPU và thu predictions về CPU, không gồm tính metric, đạt 13,83/14,48 ảnh/s. Faster R-CNN cao hơn ở phép đo pipeline dù chậm hơn theo median model batch 1. Các phép đo là mẫu trên T4 trong phiên thực nghiệm, không khẳng định tốc độ cho mọi kích thước ảnh hay phần cứng.

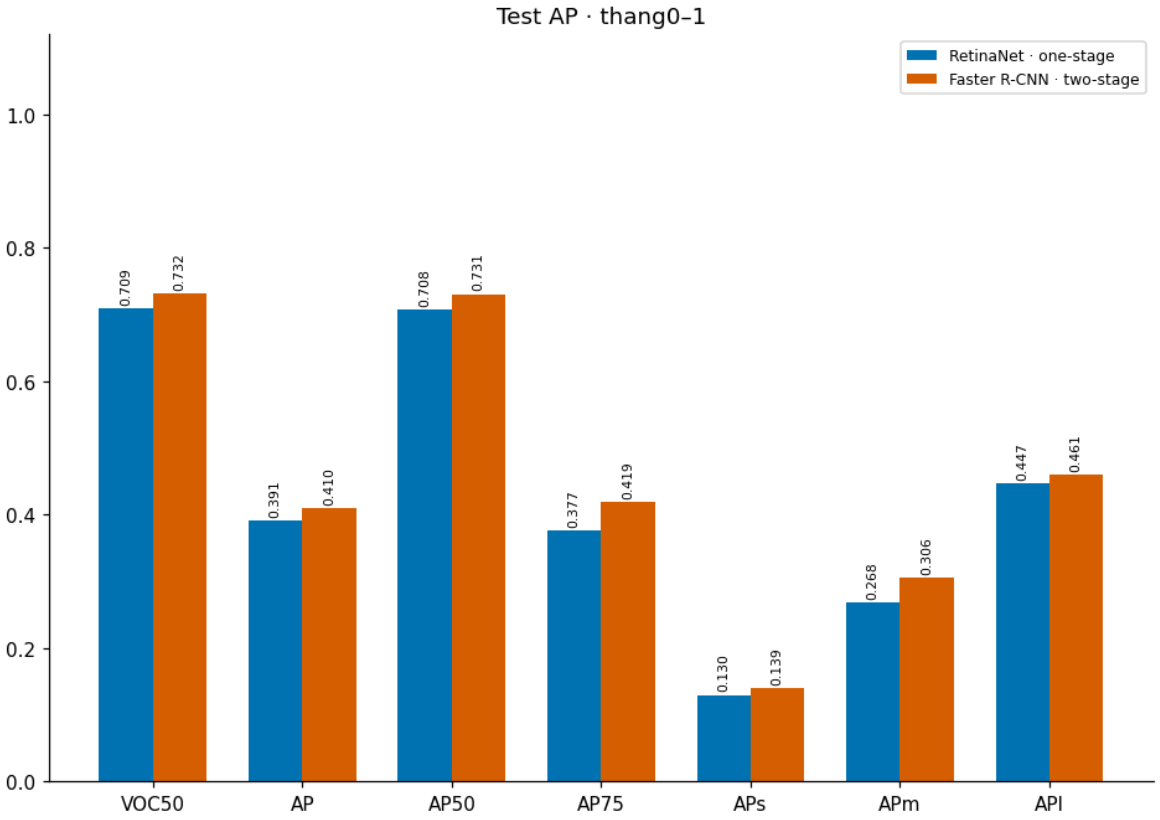

Hình 6.19: Đối chiếu các chỉ số AP trên cùng tập test.

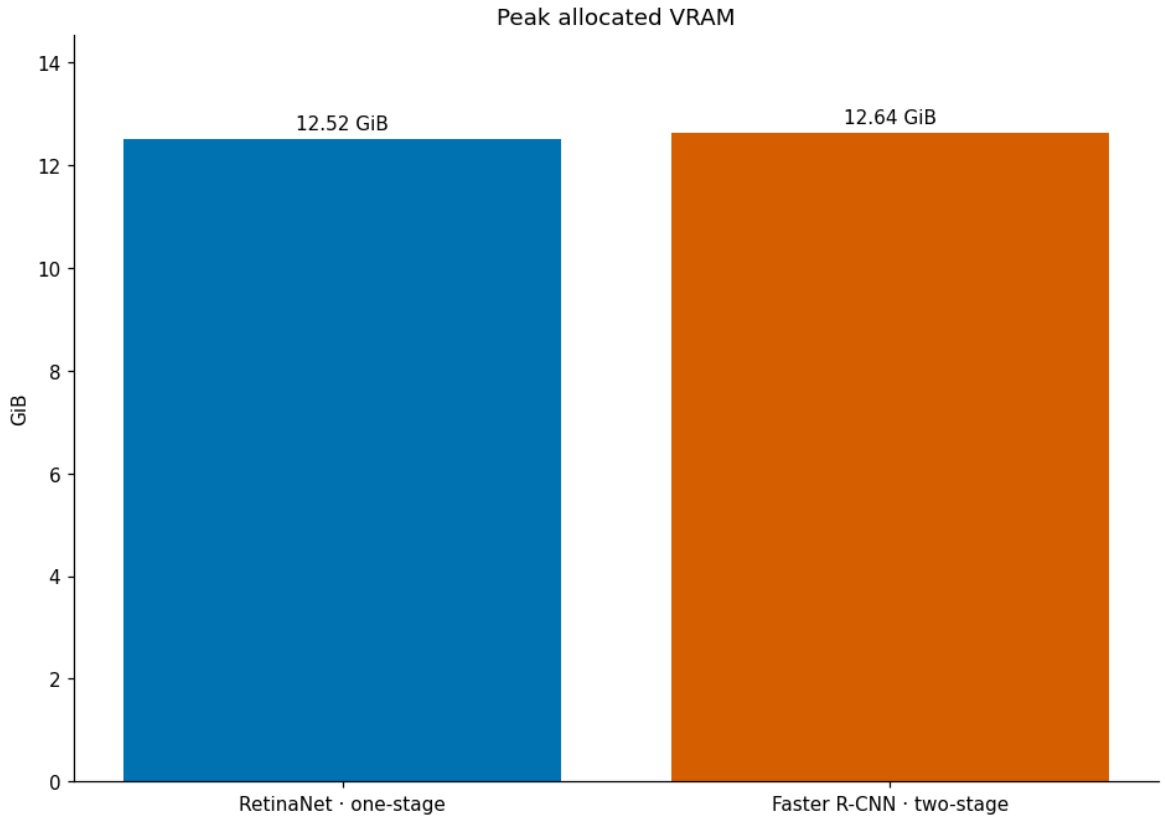

Hình 6.20: Peak allocated VRAM từng worker khi train.

6.9 Theo lớp, ma trận và trường hợp sai

Bảng 6.9: R=RetinaNet, F=Faster R-CNN; AP là COCO-style AP50:95, F1 tại score 0,30.

Lớp	GT	R AP50	F AP50	R AP	F AP	R F1	F F1
aeroplane	76	0,7757	0,7752	0,4617	0,4761	0,6243	0,6448
bicycle	80	0,8074	0,8405	0,4664	0,4842	0,6878	0,5681
bird	88	0,8353	0,7748	0,4322	0,4351	0,6609	0,6303
boat	99	0,5562	0,6065	0,2442	0,2465	0,5210	0,4928
bottle	109	0,6330	0,6252	0,3143	0,3276	0,5153	0,4883
bus	62	0,8706	0,8982	0,5768	0,5908	0,6250	0,4609
car	204	0,8186	0,8362	0,4994	0,4750	0,6252	0,4753
cat	135	0,9178	0,9107	0,5354	0,5262	0,7697	0,6513
chair	175	0,4547	0,4842	0,1987	0,2206	0,4265	0,3666
cow	67	0,6813	0,7748	0,3559	0,4190	0,5171	0,6087
diningtable	48	0,3173	0,5423	0,1488	0,2789	0,3279	0,5082
dog	159	0,8530	0,8697	0,5189	0,5157	0,6682	0,6729
horse	68	0,8287	0,8025	0,4855	0,4889	0,5911	0,6506
motorbike	75	0,8222	0,8149	0,4677	0,4498	0,6231	0,5185
person	866	0,8229	0,8429	0,4001	0,4464	0,6654	0,5613
pottedplant	72	0,3072	0,3012	0,1271	0,1342	0,3704	0,2558
sheep	83	0,7221	0,7632	0,4309	0,4544	0,5603	0,6244
sofa	49	0,5919	0,5733	0,3201	0,3186	0,5691	0,3111
train	77	0,8125	0,8132	0,4585	0,4459	0,6425	0,6740
tvmonitor	95	0,7479	0,7822	0,3831	0,4616	0,6800	0,4841

Cat, bus và dog có VOC AP50 cao; pottedplant/chair khó hơn ở cả hai model. Faster R-CNN cải thiện diningtable từ 0,3173 lên 0,5423 (22,50 điểm phần trăm) và cow từ 0,6813 lên 0,7748. RetinaNet cao hơn ở bird (0,8353/0,7748) và bottle (0,6330/0,6252). Trung bình toàn tập che khuất các khác biệt theo lớp.

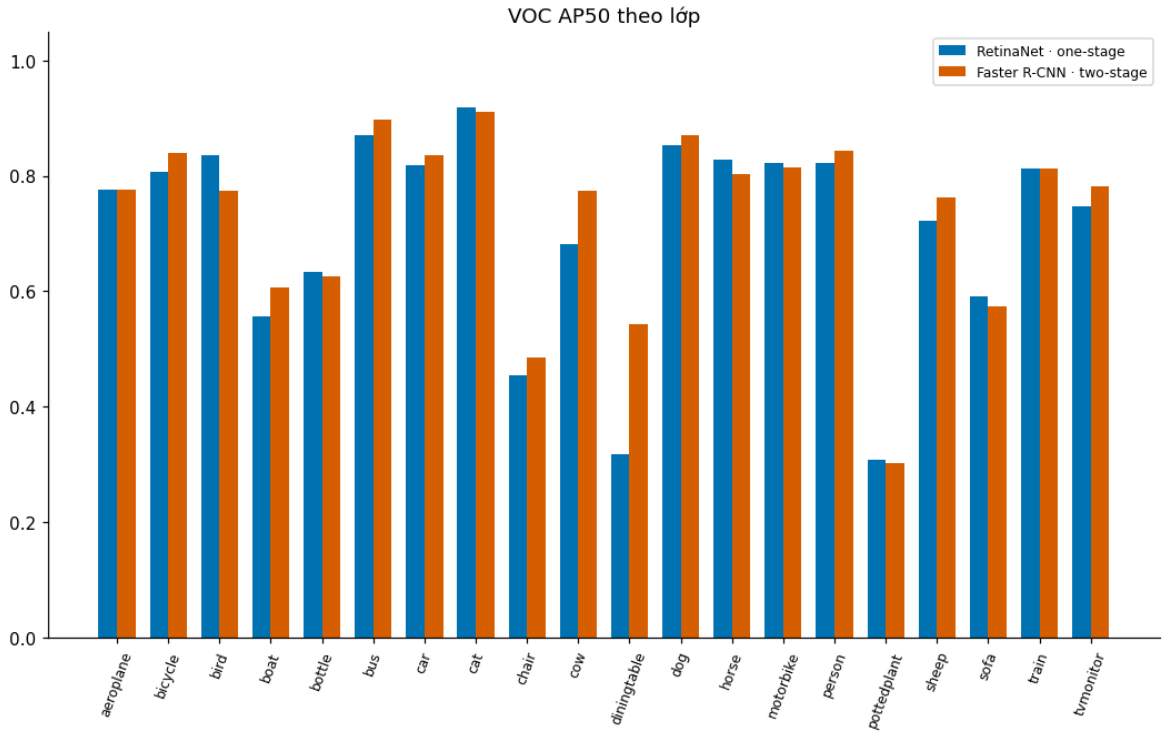

Hình 6.21: VOC AP50 từng lớp; hai detector dùng chung trục.

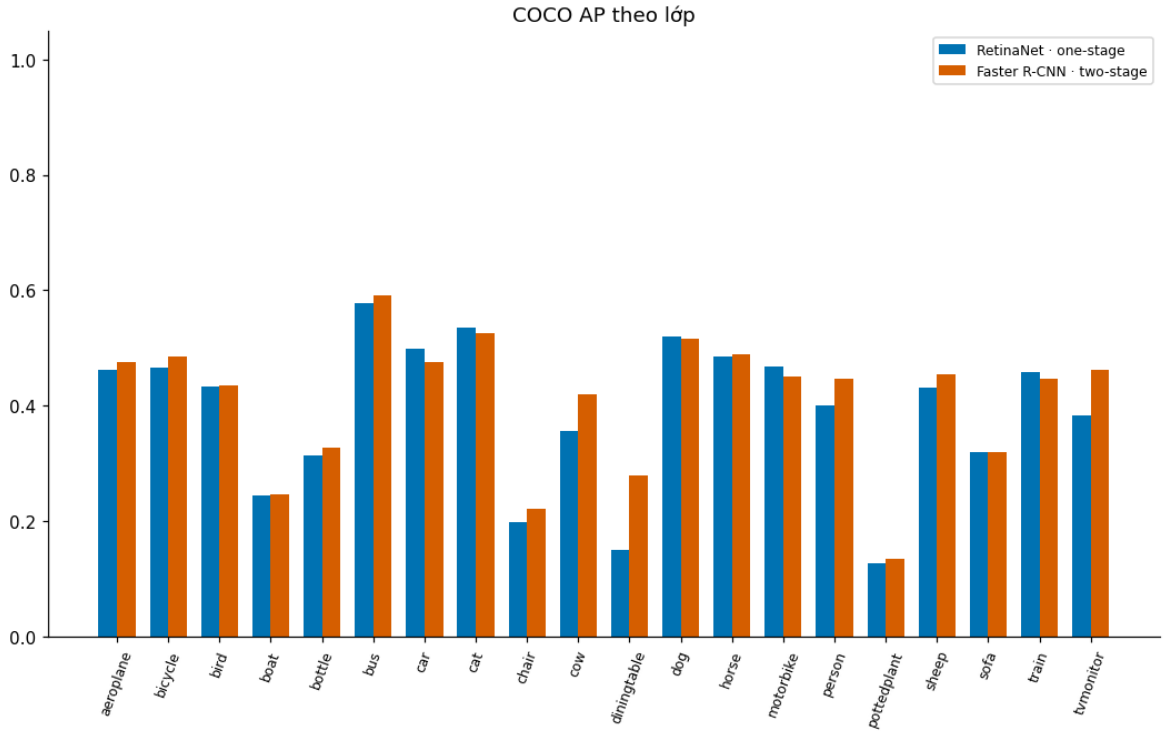

Hình 6.22: COCO-style AP50:95 từng lớp.

Phụ lục trình bày PR curves của cả 20 lớp, ma trận và từng ảnh GT/dự đoán độc lập. Ma trận chuẩn hóa theo hàng, mỗi ô chỉ ghi phần trăm nguyên; hàng background là detection không ghép GT, cột background là GT bỏ sót. P/R/F1 chính được tính class-wise, không lấy trực tiếp

từ ma trận chẩn đoán.

Ba ảnh preview cho thấy Faster R-CNN có thêm ba FP ở ảnh tvmonitor, nhưng ít FP hơn RetinaNet ở ảnh boat và horse. Trong nhóm failure, ảnh car/bottle có 4/11 FP ở RetinaNet/Faster R-CNN; ảnh kiosk có một FN ở RetinaNet, trong khi Faster R-CNN tìm được GT nhưng có 10 FP. Ở ảnh boat còn lại, RetinaNet có một TP và ba FP; Faster R-CNN có một nhầm lớp và chín FP. Các số này tính trên mọi detection vượt score 0,30, không chỉ tối đa 15 boxes được vẽ.

Các ví dụ được chọn sau test để phân tích, không dùng chọn cấu hình và không đại diện cho tần suất lỗi toàn tập. Một prediction không ghép annotation có thể là bbox lặp, lệch vị trí, nhầm lớp hoặc một vật thể nhìn thấy nhưng không có nhãn nguồn; cần đối chiếu GT trước khi diễn giải FP.

6.10 Kết luận A2 và giới hạn

Faster R-CNN tốt hơn về VOC mAP50, COCO-style AP50:95/AP75, recall tại score 0,30 và APsmall. RetinaNet có precision/F1 cao hơn ở ngưỡng này, ít tham số hơn và FPS median batch 1 cao hơn. Lựa chọn phụ thuộc ưu tiên chất lượng AP, precision–recall và workload suy luận; P95 và pipeline không cùng thứ tự với median.

Kết luận dựa trên một seed và holdout nội bộ. Hai mạng khác nhiều thành phần cùng lúc, chưa cô lập riêng P2, Focal Loss hoặc proposals. Giới hạn epoch, dừng sớm, score floor/cap, nhãn difficult và resize ảnh hưởng phép so sánh. Các hướng tiếp theo là nhiều seed, ablation neck/anchors với head giữ cố định và chọn confidence bằng validation; chưa nằm trong kết quả báo cáo.

7. Kết luận

E1 cho thấy MLP phi tuyến cải thiện so với classifier tuyến tính; CNN tăng accuracy bằng locality và chia sẻ trọng số. CNN-B ít tham số hơn CNN-A nhưng test accuracy tương đương trong một seed. E2 xác nhận MSA thủ công qua forward/gradient; CNN-stem hữu ích trong cả hai cách cài đặt. Tăng số head không tạo cải thiện đơn điệu. E3 cho thấy rows tốt nhất trong các biểu diễn đã thử; GRU dùng ít tham số hơn LSTM cùng representation, nhưng thời gian đo cao hơn. CNN-B hiệu quả hơn về độ chính xác/thời gian ở bài toán ảnh tĩnh.

A1 cho thấy pretrained full cho kết quả validation tốt nhất trong hai họ. Head-only tiết kiệm bộ nhớ nhưng accuracy thấp; partial phụ thuộc phạm vi unfreeze. DeiT pretrained full có test accuracy trung bình ba seed cao hơn ResNet; ResNet suy luận nhanh hơn và dùng ít peak memory hơn. Augmentation cải thiện cả hai họ trong phép so sánh seed 42.

A2 cho thấy Faster R-CNN hơn ở VOC mAP50, COCO-style AP50:95/AP75, recall và APsmall; RetinaNet hơn ở precision/F1 tại score 0,30 và FPS median batch 1, đồng thời ít tham số hơn. P95 và tốc độ pipeline có thứ tự khác median. FPN tạo feature đa tỉ lệ, nhưng vẫn khó với vật thể nhỏ/nội thất; Focal Loss không thay thế phân tích FP/FN hoặc lựa chọn confidence trên validation.

Các kết luận gắn với dataset, split, seed và ngân sách thực nghiệm. Hướng tiếp theo là nhiều seed cho E1–E3/A2, so sánh cùng capacity/ngân sách cập nhật, ablation neck/anchors ở detection và kiểm tra độ ổn định theo track ở GTSRB. Những hướng này chưa nằm trong số liệu báo cáo.

7.1 Ghi nhận hỗ trợ của công cụ AI

Công cụ AI được dùng để hỗ trợ lập trình, kiểm tra code, tổng hợp output, đối chiếu tài liệu và biên tập LaTeX/TikZ. Số liệu thực nghiệm lấy từ các notebook đã chạy và lưu output, không được tạo để minh họa kết quả. Người thực hiện chịu trách nhiệm hiểu, kiểm chứng và bảo vệ code, số liệu và phần phân tích; phạm vi hỗ trợ được ghi nhận theo mục 1.6 đề E1–E3.

Tài liệu tham khảo

[1] COCO Consortium. Coco detection evaluation, 2015. URL https://cocodataset.org/dataset/detection-eval.htm.

[2] Mark Everingham, Luc Van Gool, Christopher K. I. Williams, John Winn, and Andrew Zisserman. The pascal visual object classes (voc) challenge. *International Journal of Computer Vision*, 88:303–338, 2010. doi: 10.1007/s11263-009-0275-4.

[3] Mark Everingham et al. The pascal visual object classes challenge 2012 development kit, 2012. URL https://www.robots.ox.ac.uk/~vgg/projects/pascal/VOC/voc2012/htmldoc/index.html.

[4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, 2016. URL https://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html.

[5] Tsung-Yi Lin, Piotr Dollar, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *CVPR*, 2017. URL https://openaccess.thecvf.com/content_cvpr_2017/html/Lin_Feature_Pyramid_Networks_CVPR_2017_paper.html.

[6] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollar. Focal loss for dense object detection. In *ICCV*, pages 2980–2988, 2017. URL https://openaccess.thecvf.com/content_ICCV_2017/html/Lin_Focal_Loss_for_ICCV_2017_paper.html.

[7] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster r-cnn: Towards real-time object detection with region proposal networks. In *NeurIPS*, 2015. URL https://arxiv.org/abs/1506.01497.

[8] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. The german traffic sign recognition benchmark: A multi-class classification competition. In *International Joint Conference on Neural Networks*, pages 1453–1460, 2011.

[9] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition. *Neural Networks*, 32:323–332, 2012. doi: 10.1016/j.neunet.2012.02.016.

[10] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. German traffic sign recognition benchmark: Public archive, 2019. URL https://sid.erda.dk/public/archives/daaeac0d7ce1152aea9b61d9f1e19370/published-archive.html. Accessed 8 October 2026.

[11] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Herve Jegou. Training data-efficient image transformers and distillation through attention. In *ICML*, 2021. URL https://proceedings.mlr.press/v139/touvron21a.html.

[12] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms. *arXiv:1708.07747*, 2017. URL https://arxiv.org/abs/1708.07747.

A. Kết quả chi tiết và tái lập

A.1 Chi tiết huấn luyện E1–E3 và A1

Các bảng dưới ghi số epoch đã chạy, best epoch, optimizer updates thực tế, AMP skips và peak allocated MiB. Chúng đối chiếu trực tiếp output cell, không suy số updates chỉ từ số epoch.

Bảng A.1: Chi tiết lượt train E1.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
Softmax	12	8	5.064	0	18
MLP	20	16	8.440	0	22
CNN-A	12	8	5.064	0	50
CNN-B	20	16	8.440	0	56

Bảng A.2: Chi tiết lượt train E2; ký hiệu M/T và R/P/C như Chương E2.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
M-R4	20	16	8.440	0	43
M-P4	23	19	9.706	0	69
M-C4	24	20	10.127	1	78
T-R4	20	16	8.440	0	47
T-P4	23	19	9.706	0	79
T-C4	23	19	9.706	0	89
M-C2	22	18	9.284	0	70
M-C8	22	18	9.284	0	99

Bảng A.3: Chi tiết lượt train E3.

Model	Epoch	Best	Updates	AMP skips	Peak MiB
LSTM Rows	18	14	7.596	0	27
LSTM Columns	23	19	9.706	0	27
LSTM Patch	20	16	8.440	0	33
GRU Rows	20	20	8.440	0	28
GRU Columns	23	19	9.706	0	28
GRU Patch	24	20	10.128	0	35
MLP	20	16	8.440	0	22
CNN-B	20	16	8.440	0	56

Bảng A.4: Chi tiết tám lượt train chính A1.

Run	Epoch	Best	Updates	AMP skips	Peak MiB
R-S/42	7	5	1.722	0	5828
R-H/42	10	8	2.460	0	1567
R-P/42	7	5	1.722	0	1682
R-F/42	4	2	984	0	5827
D-S/42	11	9	2.706	0	6631
D-H/42	12	10	2.952	0	636
D-P/42	6	4	1.476	0	1373
D-F/42	8	6	1.968	0	6635

Bảng A.5: Epoch, cập nhật và peak memory của sáu run mở rộng A1.

Run	Epoch	Best	Updates	AMP skips	Peak MiB
R-F/42 no-aug	3	3	738	0	5830
R-F/43	3	1	738	0	5829
R-F/44	5	3	1.230	0	5830
D-F/42 no-aug	3	2	738	0	6631
D-F/43	10	8	2.460	0	6635
D-F/44	5	3	1.230	0	6635

A.2 Metric theo lớp và độ nhạy A1

Hai cột model là full pretrained seed 42, được chọn bằng validation. Support là số ảnh test nguồn. ID tra bằng bảng tên lớp dưới đây.

Bảng A.6: Precision/recall/F1 trên test GTSRB, lớp 0–21.

ID	Lớp	n	R-P	R-R	R-F1	D-P	D-R	D-F1
0	Speed limit 20	60	1,000	0,967	0,983	1,000	0,500	0,667
1	Speed limit 30	720	0,977	1,000	0,988	0,997	0,997	0,997
2	Speed limit 50	750	0,957	0,991	0,974	0,999	0,997	0,998
3	Speed limit 60	450	1,000	0,958	0,978	1,000	0,993	0,997
4	Speed limit 70	660	0,994	0,986	0,990	0,997	0,998	0,998
5	Speed limit 80	630	0,988	0,944	0,966	0,994	0,998	0,996
6	End speed limit 80	150	0,955	1,000	0,977	1,000	0,973	0,986
7	Speed limit 100	450	0,968	0,993	0,980	0,976	1,000	0,988
8	Speed limit 120	450	0,991	0,991	0,991	0,937	0,996	0,966
9	No passing	480	0,939	0,998	0,968	0,986	1,000	0,993
10	No passing >3.5t	660	1,000	0,980	0,990	0,998	1,000	0,999
11	Right-of-way intersection	420	0,997	0,921	0,958	0,978	0,971	0,975
12	Priority road	690	1,000	0,999	0,999	0,996	1,000	0,998
13	Yield	720	0,996	0,999	0,997	1,000	0,997	0,999
14	Stop	270	1,000	0,993	0,996	0,996	1,000	0,998
15	No vehicles	210	1,000	0,990	0,995	0,991	0,995	0,993
16	Vehicles >3.5t prohibited	150	1,000	0,907	0,951	0,987	1,000	0,993
17	No entry	360	0,992	1,000	0,996	1,000	0,969	0,984
18	General caution	390	0,972	0,969	0,970	0,982	0,990	0,986
19	Dangerous curve left	60	1,000	1,000	1,000	1,000	1,000	1,000
20	Dangerous curve right	90	0,989	1,000	0,994	1,000	1,000	1,000
21	Double curve	90	0,934	0,944	0,939	0,968	1,000	0,984

Bảng A.7: Precision/recall/F1 trên test GTSRB, lớp 22–42.

ID	Lớp	n	R-P	R-R	R-F1	D-P	D-R	D-F1
22	Bumpy road	120	1,000	0,758	0,863	0,991	0,950	0,970
23	Slippery road	150	0,879	0,967	0,921	0,968	1,000	0,984
24	Road narrows right	90	1,000	0,989	0,994	0,947	1,000	0,973
25	Road work	480	0,885	0,994	0,936	0,985	0,967	0,976
26	Traffic signals	180	0,989	0,989	0,989	1,000	0,972	0,986
27	Pedestrians	60	0,882	0,500	0,638	1,000	0,883	0,938
28	Children crossing	150	1,000	0,993	0,997	1,000	1,000	1,000
29	Bicycle crossing	90	0,978	1,000	0,989	1,000	1,000	1,000
30	Ice/snow caution	150	0,937	0,987	0,961	0,917	0,960	0,938
31	Wild animals crossing	270	0,971	0,996	0,984	0,993	1,000	0,996
32	End speed/passing limits	60	1,000	1,000	1,000	1,000	1,000	1,000
33	Turn right ahead	210	0,991	1,000	0,995	1,000	1,000	1,000
34	Turn left ahead	120	1,000	1,000	1,000	0,992	1,000	0,996
35	Ahead only	390	0,992	0,974	0,983	1,000	0,982	0,991
36	Straight or right	120	0,991	0,933	0,961	0,976	1,000	0,988
37	Straight or left	60	0,968	1,000	0,984	1,000	1,000	1,000
38	Keep right	690	0,991	0,996	0,993	0,989	1,000	0,994
39	Keep left	90	1,000	0,989	0,994	1,000	1,000	1,000
40	Roundabout mandatory	90	0,913	0,933	0,923	1,000	0,844	0,916
41	End no passing	60	0,982	0,933	0,957	1,000	1,000	1,000
42	End no passing >3.5t	90	1,000	0,944	0,971	0,927	0,989	0,957

Bảng A.8: Độ nhạy A1 với 8 ảnh test trùng train; accuracy tính bằng %.

Run	Full acc	Clean acc	Δ (điểm%)	Full F1	Clean F1
R-S/42	96,33	96,33	-0,002	0,9447	0,9447
R-H/42	67,33	67,31	-0,021	0,5759	0,5758
R-P/42	95,21	95,21	-0,003	0,9261	0,9261
R-F/42	97,83	97,83	-0,001	0,9678	0,9678
D-S/42	88,64	88,63	-0,007	0,8267	0,8267
D-H/42	69,41	69,39	-0,019	0,6016	0,6015
D-P/42	87,85	87,85	-0,008	0,8063	0,8063
D-F/42	98,92	98,91	-0,001	0,9790	0,9790

Full test có 12.630 ảnh, clean test có 12.622; mọi accuracy tính bằng %. Bảng ghi mức làm tròn trong output; delta tính trên giá trị chưa làm tròn nên không nhất thiết bằng phép trừ hai cột accuracy hiển thị.

A.3 Đường cong theo tokenizer và biểu diễn chuỗi

Các hình dùng cùng split và protocol với các bảng kết quả; mỗi đồ thị được trình bày độc lập để đọc rõ tên mô hình và legend.

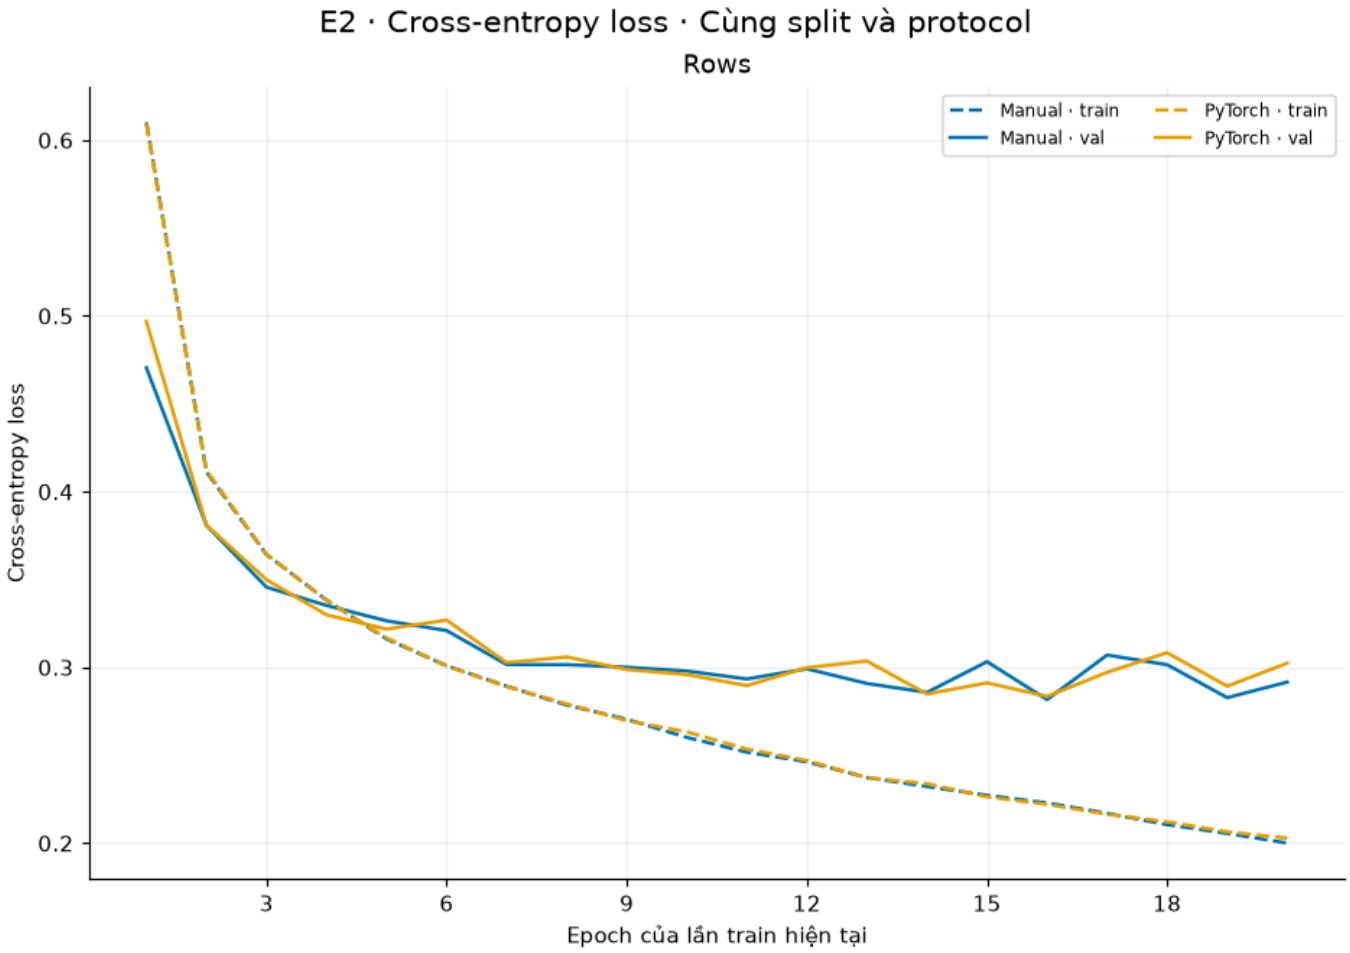

Hình A.1: Loss E2: Manual/PyTorch với Rows, H=4.

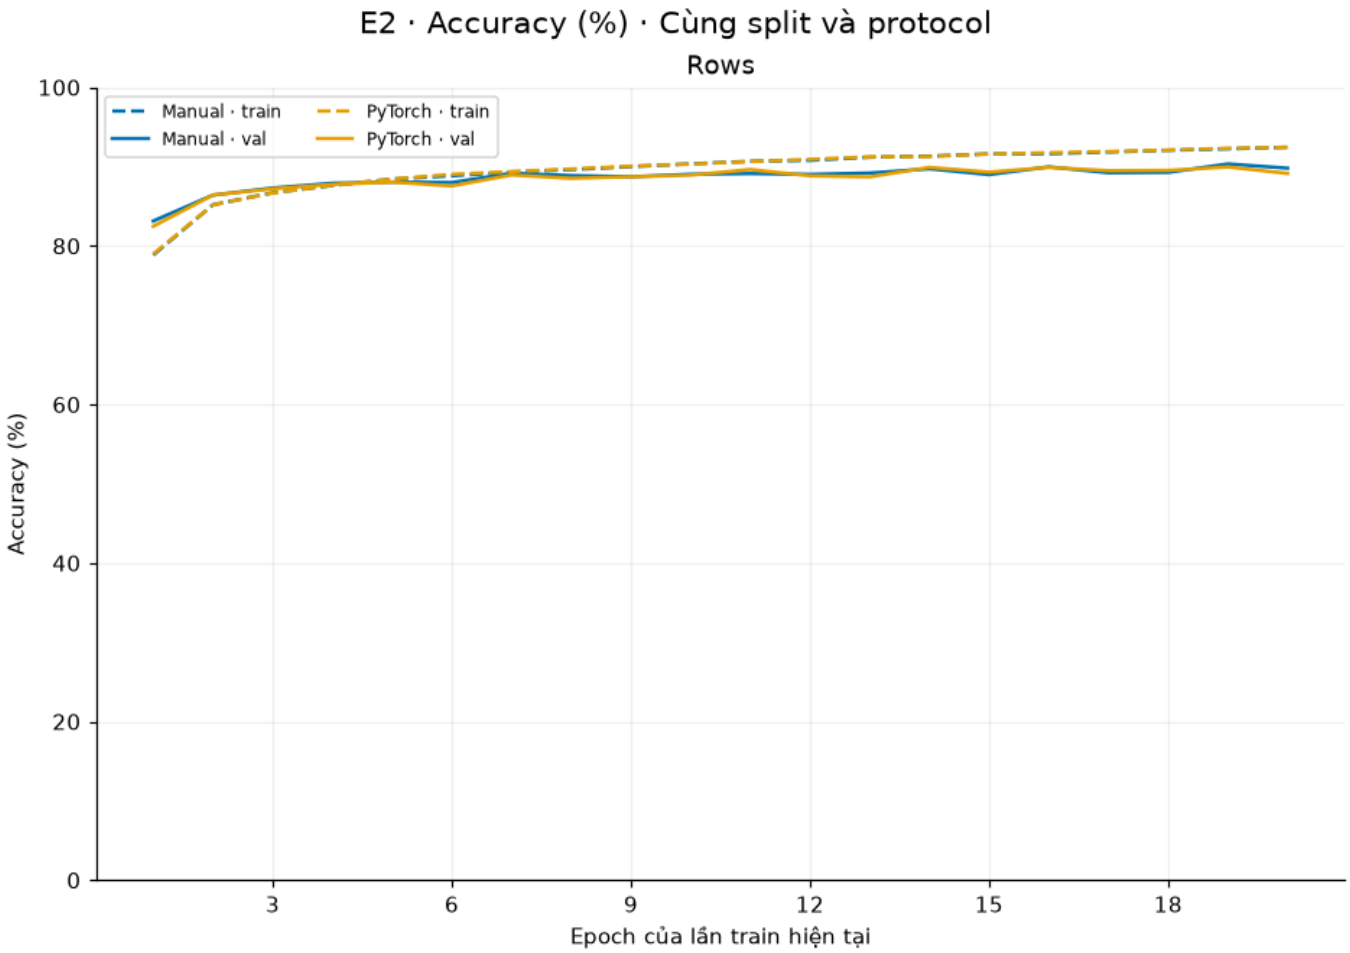

Hình A.2: Accuracy E2: Manual/PyTorch với Rows, H=4.

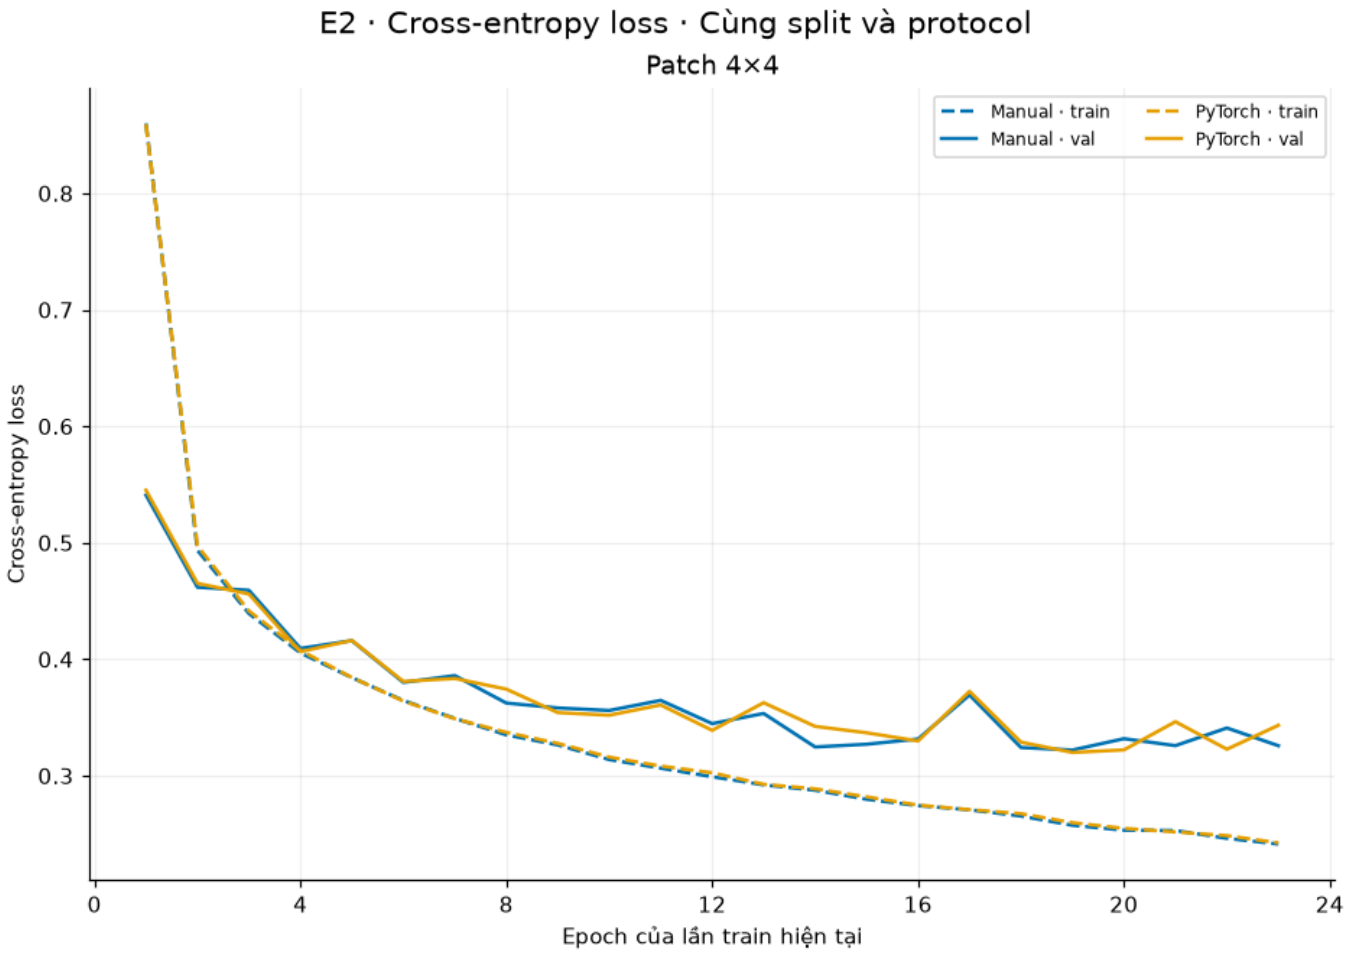

Hình A.3: Loss E2: Manual/PyTorch với Patch, H=4.

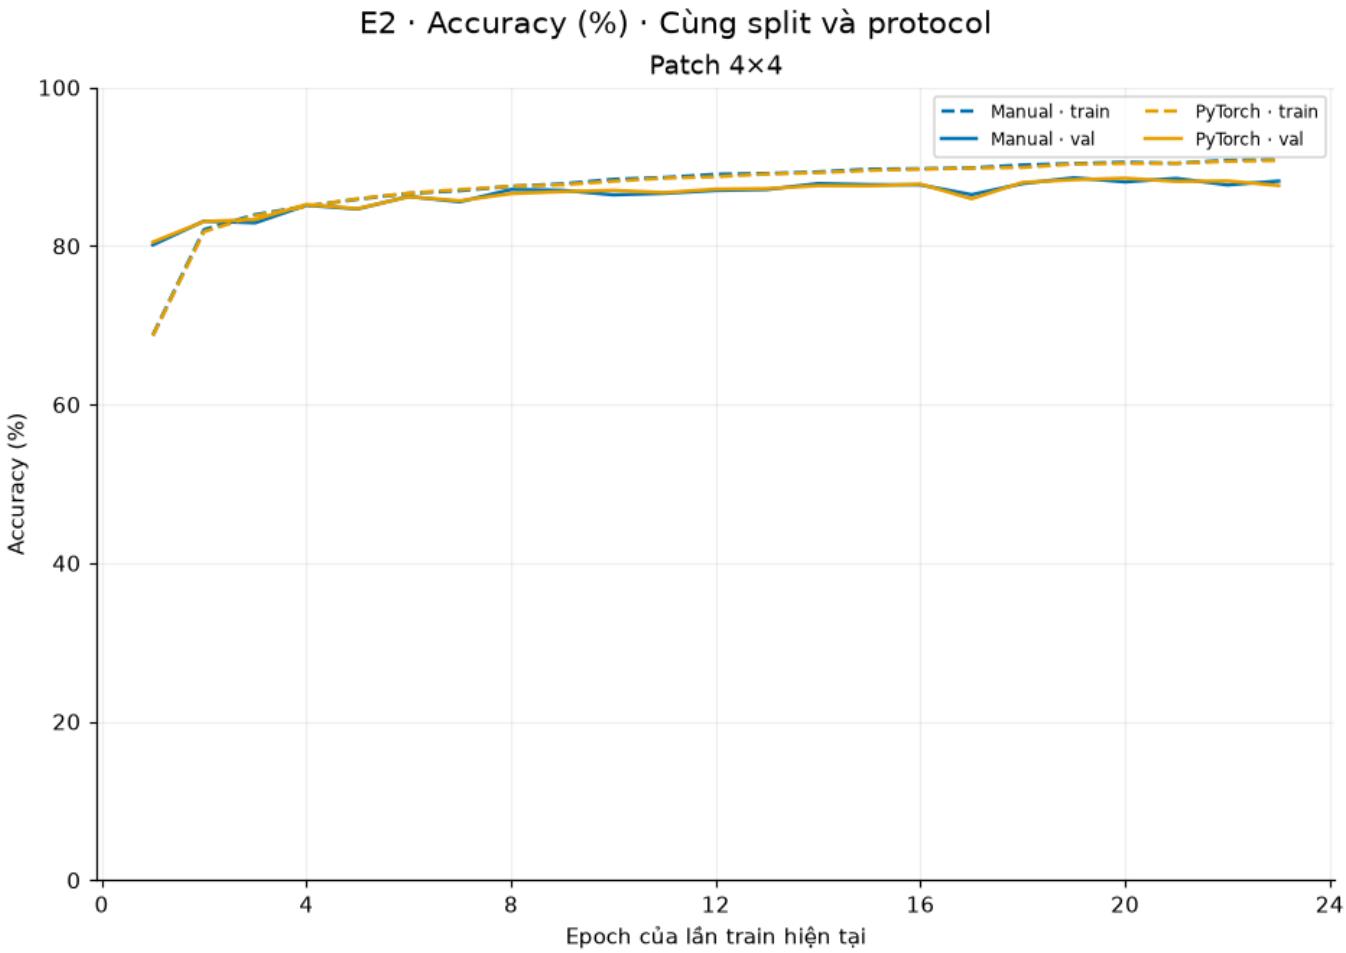

Hình A.4: Accuracy E2: Manual/PyTorch với Patch, H=4.

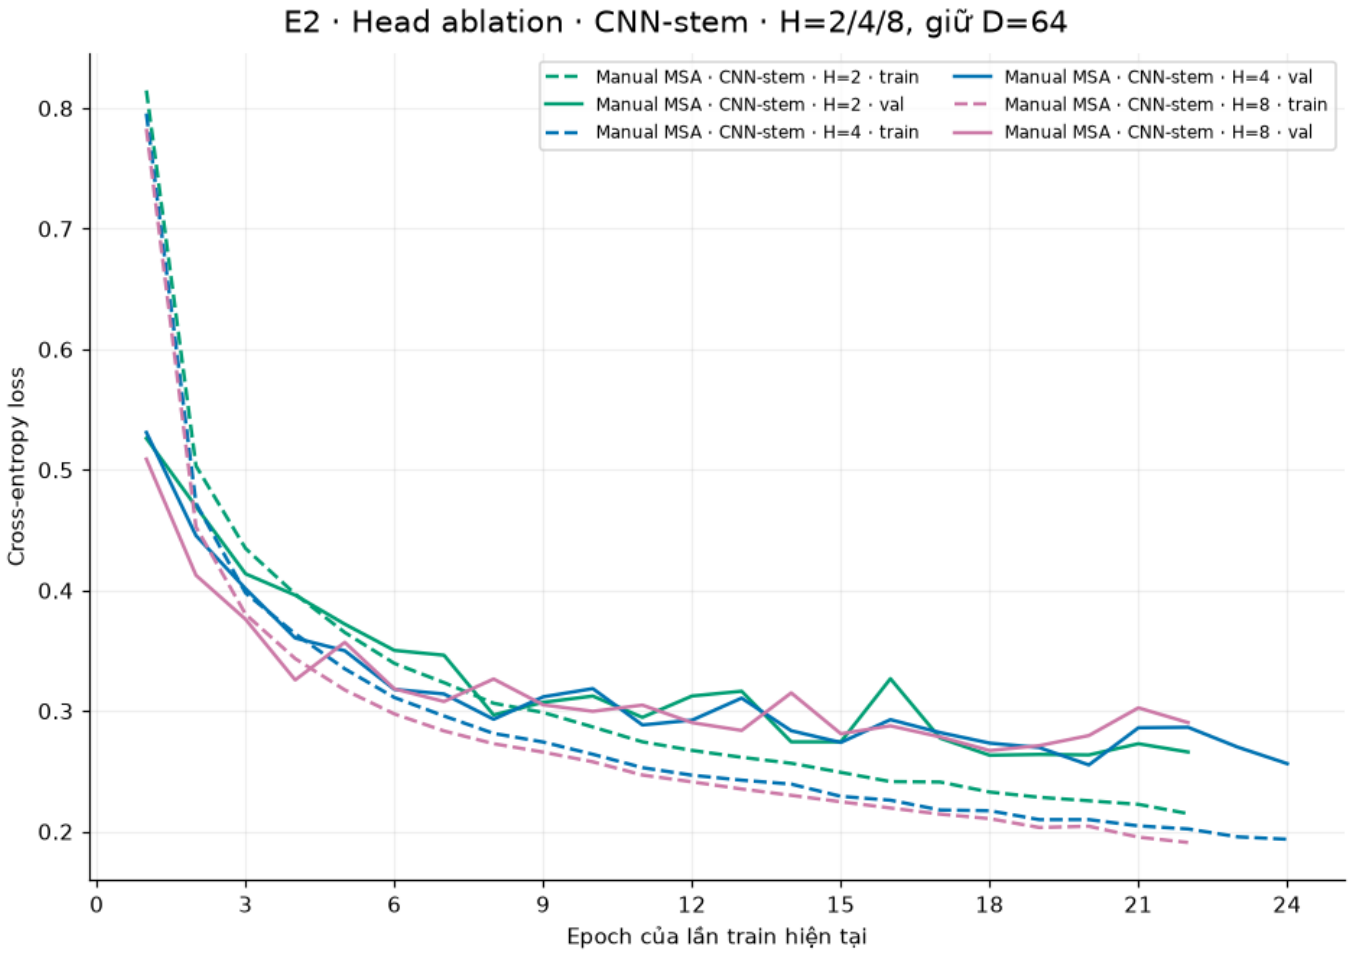

Hình A.5: Loss E2: Manual CNN-stem với H=2, 4 và 8.

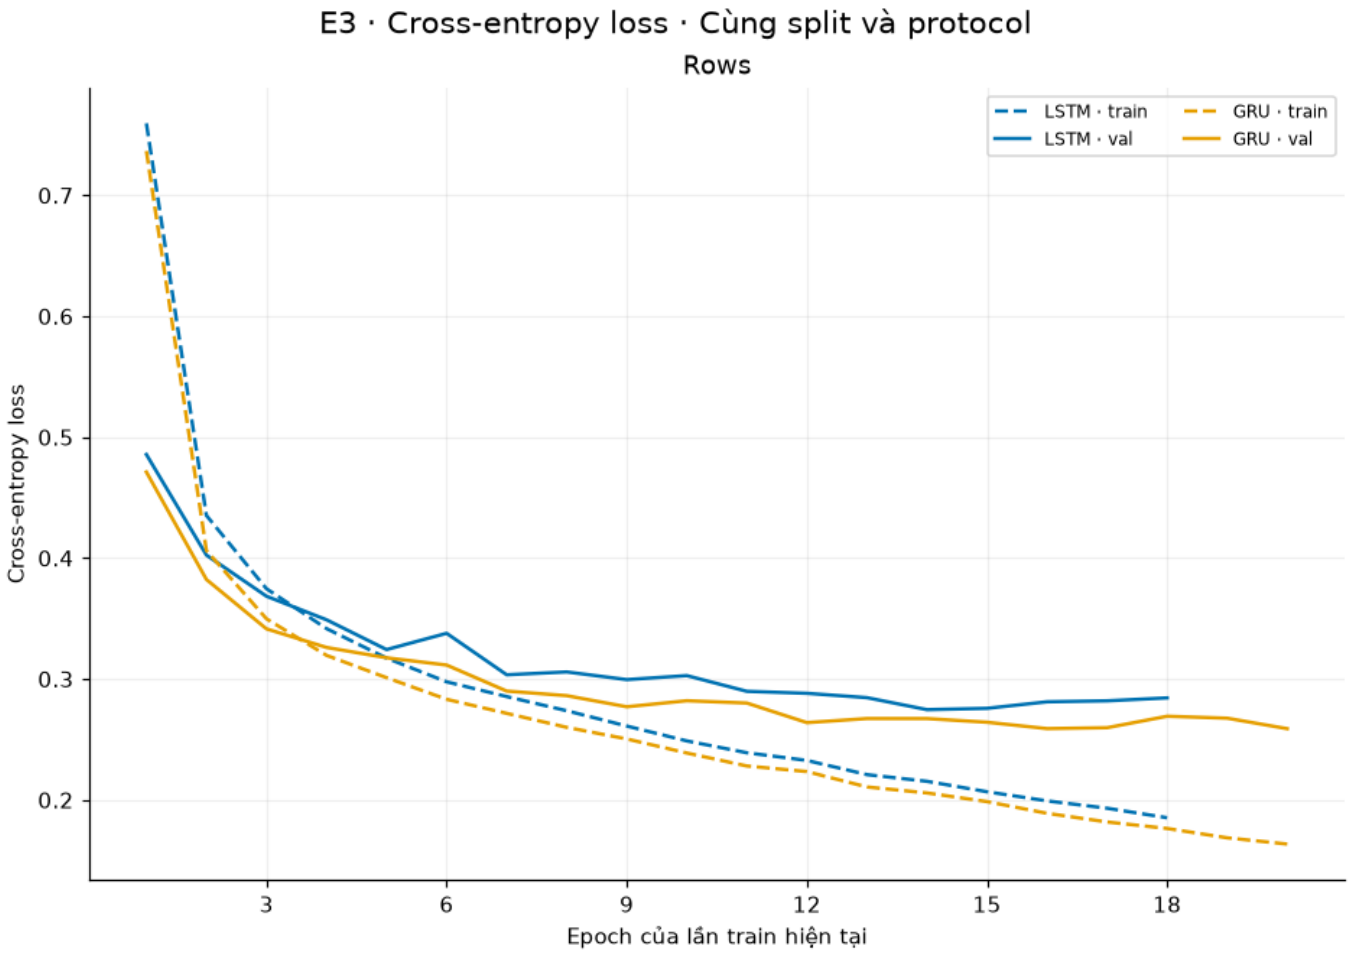

Hình A.6: Loss E3: LSTM/GRU với Rows.

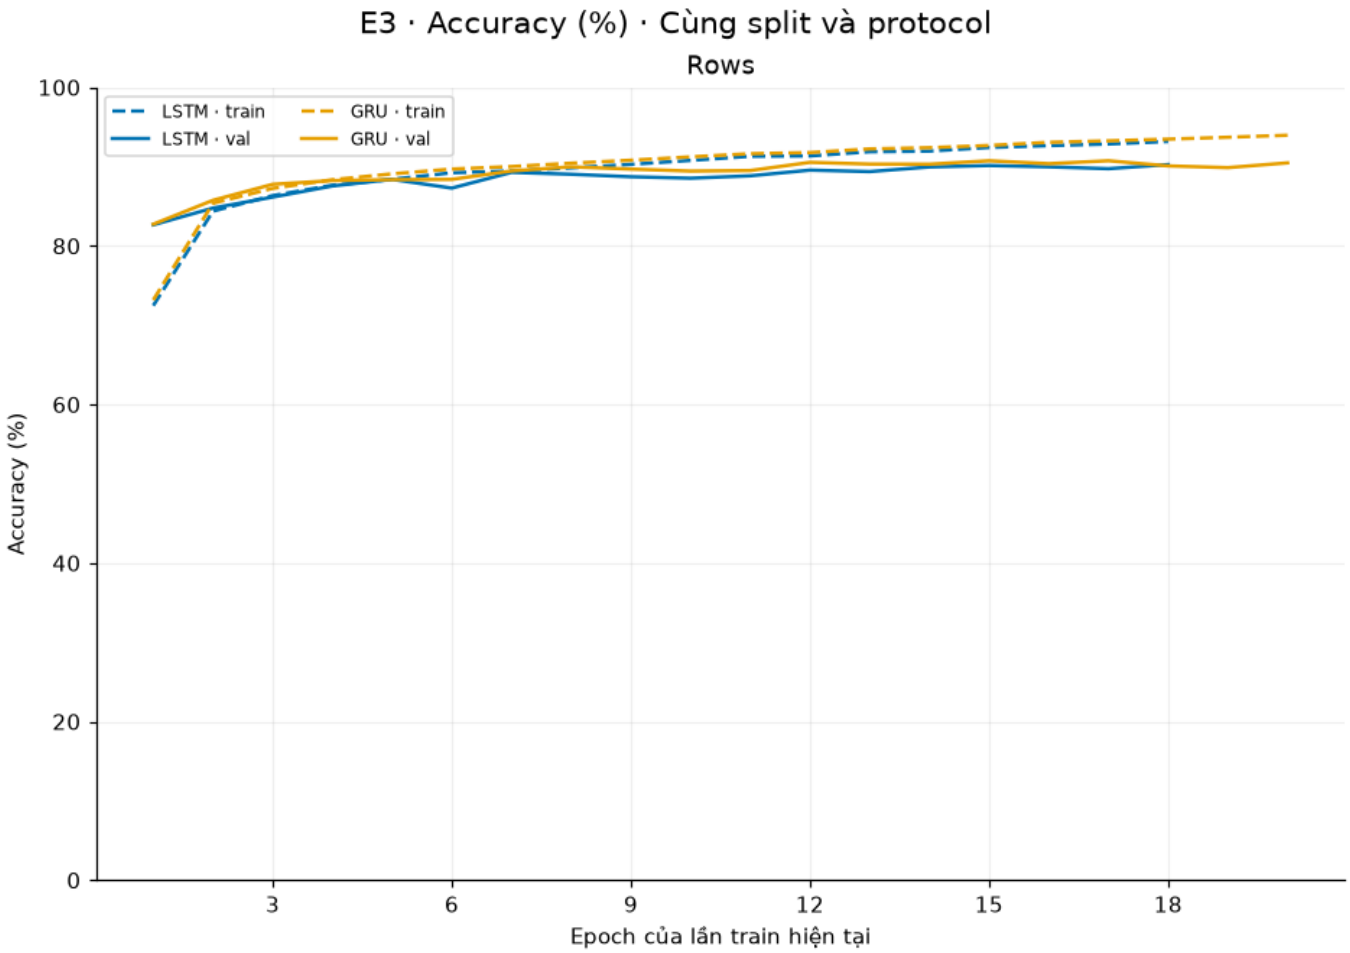

Hình A.7: Accuracy E3: LSTM/GRU với Rows.

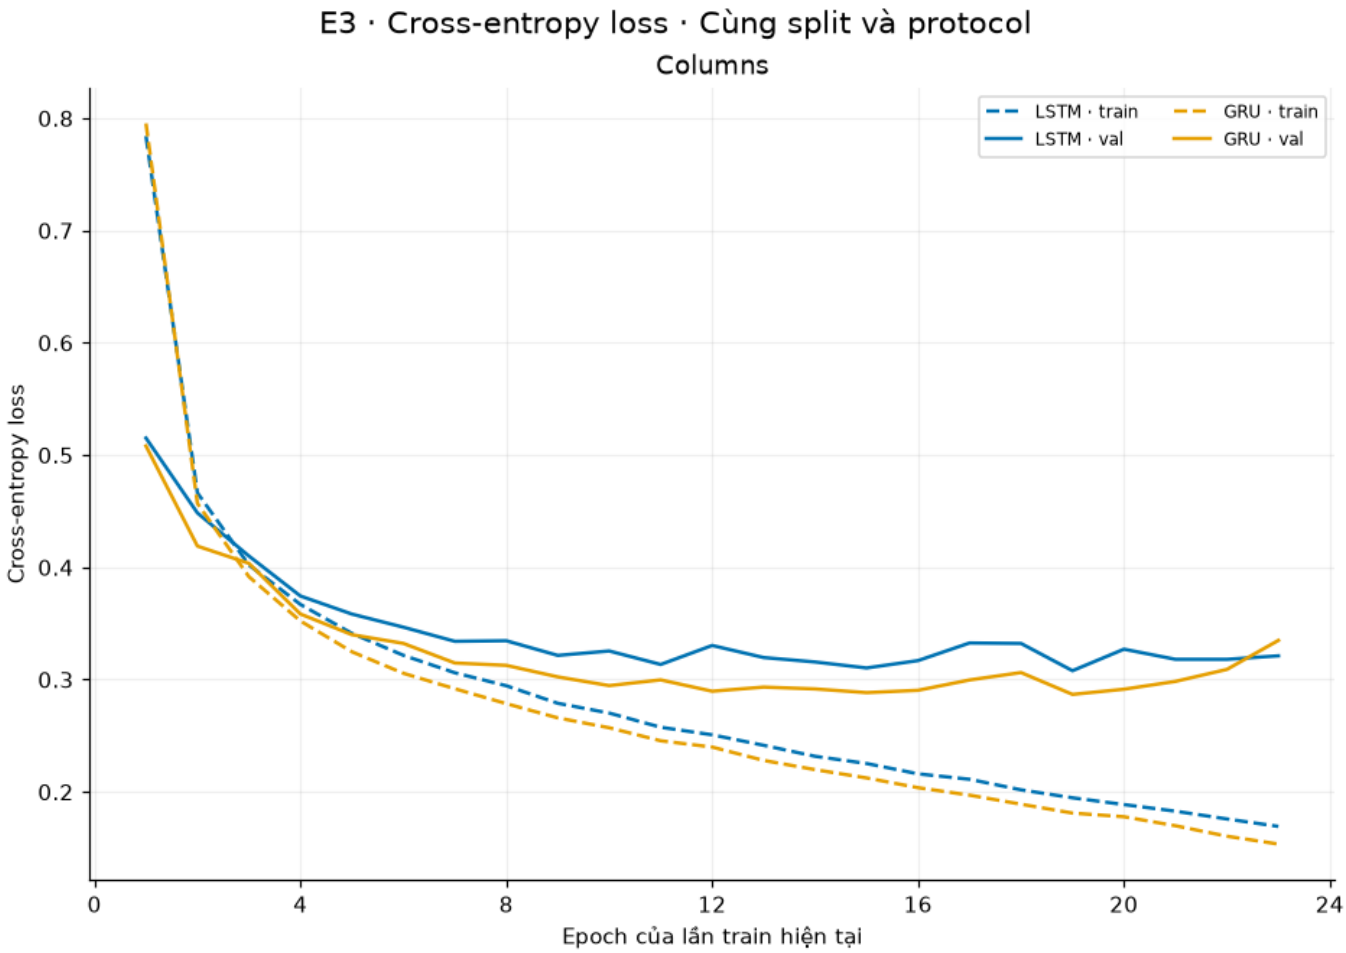

Hình A.8: Loss E3: LSTM/GRU với Columns.

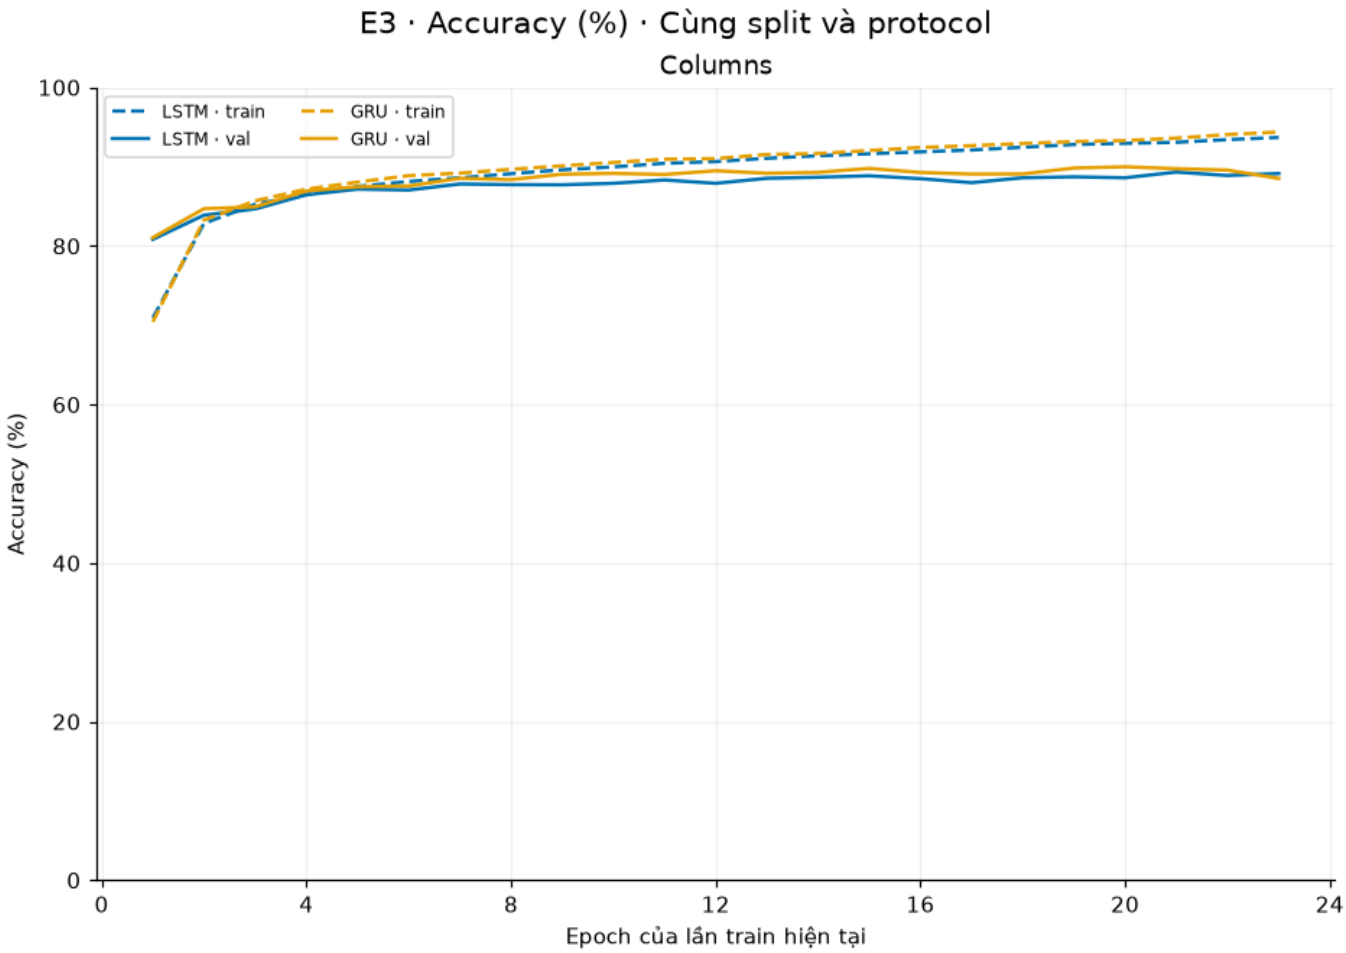

Hình A.9: Accuracy E3: LSTM/GRU với Columns.

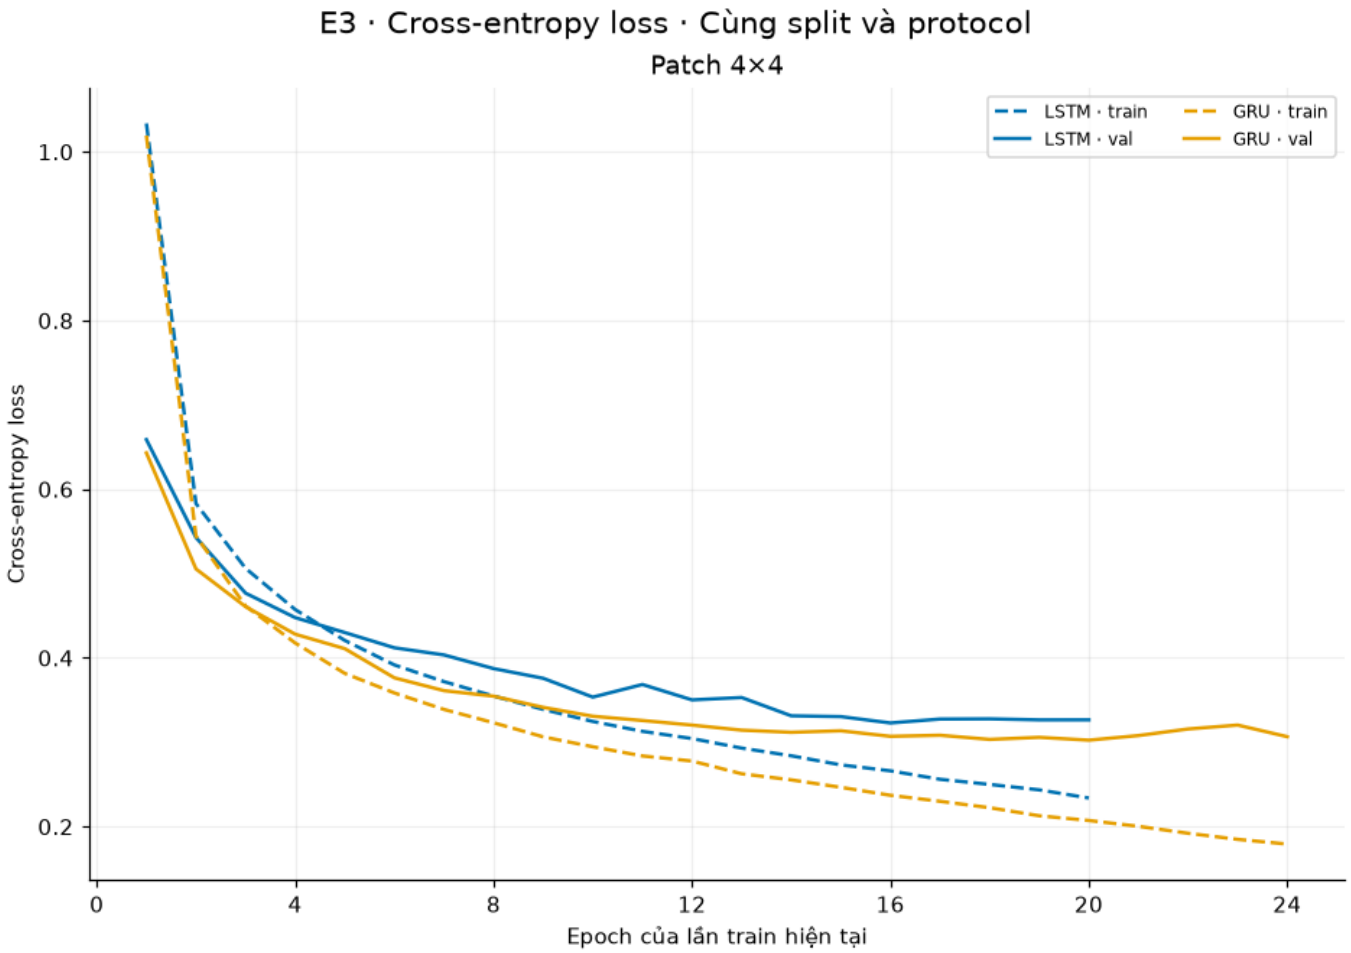

Hình A.10: Loss E3: LSTM/GRU với Patch.

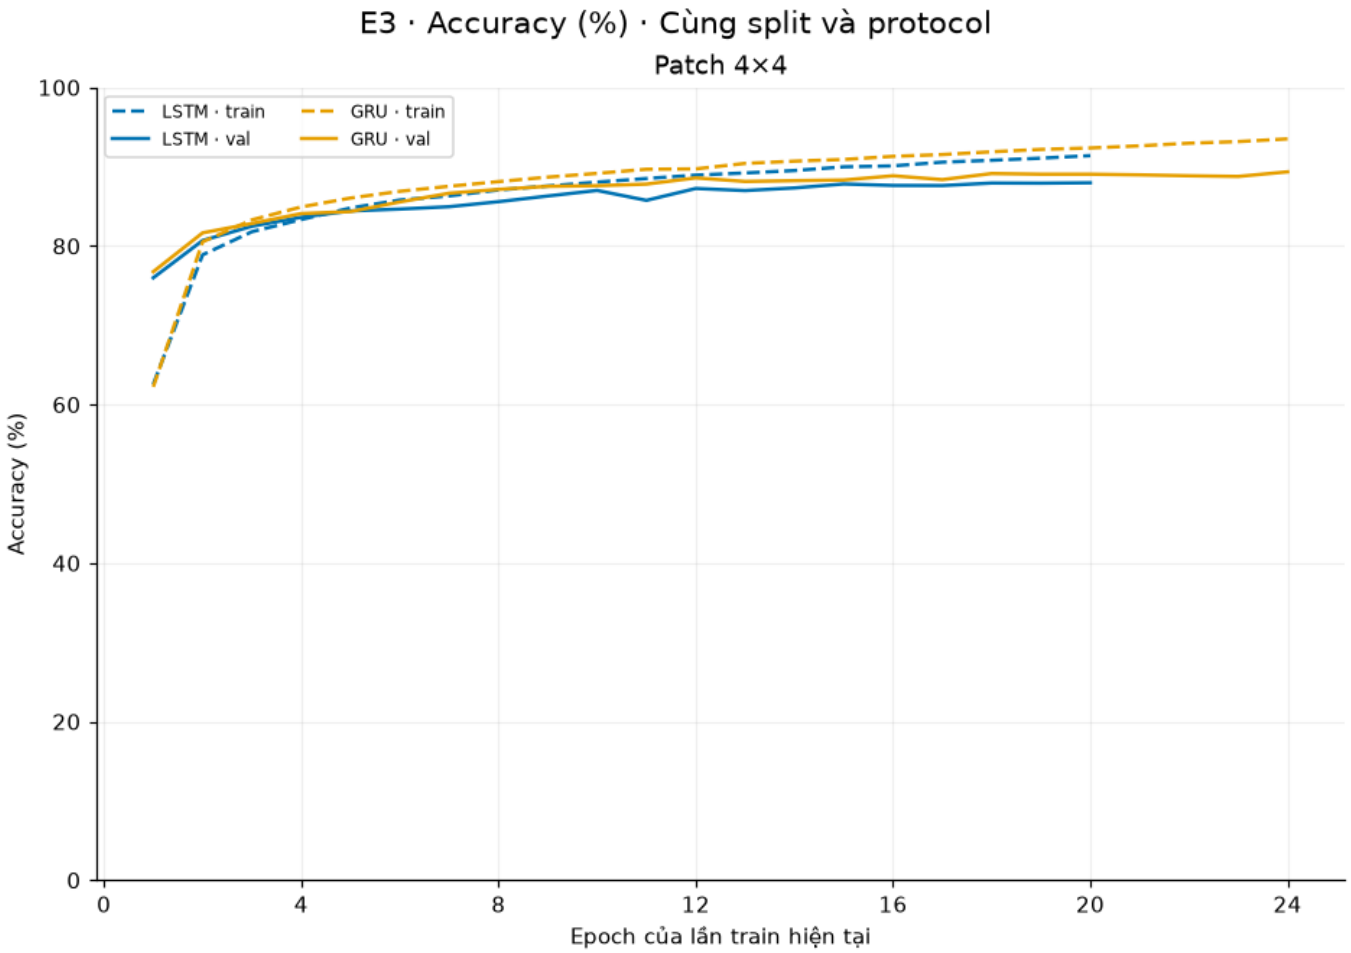

Hình A.11: Accuracy E3: LSTM/GRU với Patch.

A.4 Ma trận nhầm lẫn E1–E3

Mỗi ma trận dùng toàn bộ 10.000 ảnh test; hàng là lớp thật, cột là lớp dự đoán. Ô ghi phần trăm theo hàng, làm tròn số nguyên nên tổng một hàng có thể khác 100%. Thang màu thống nhất 0–100%.

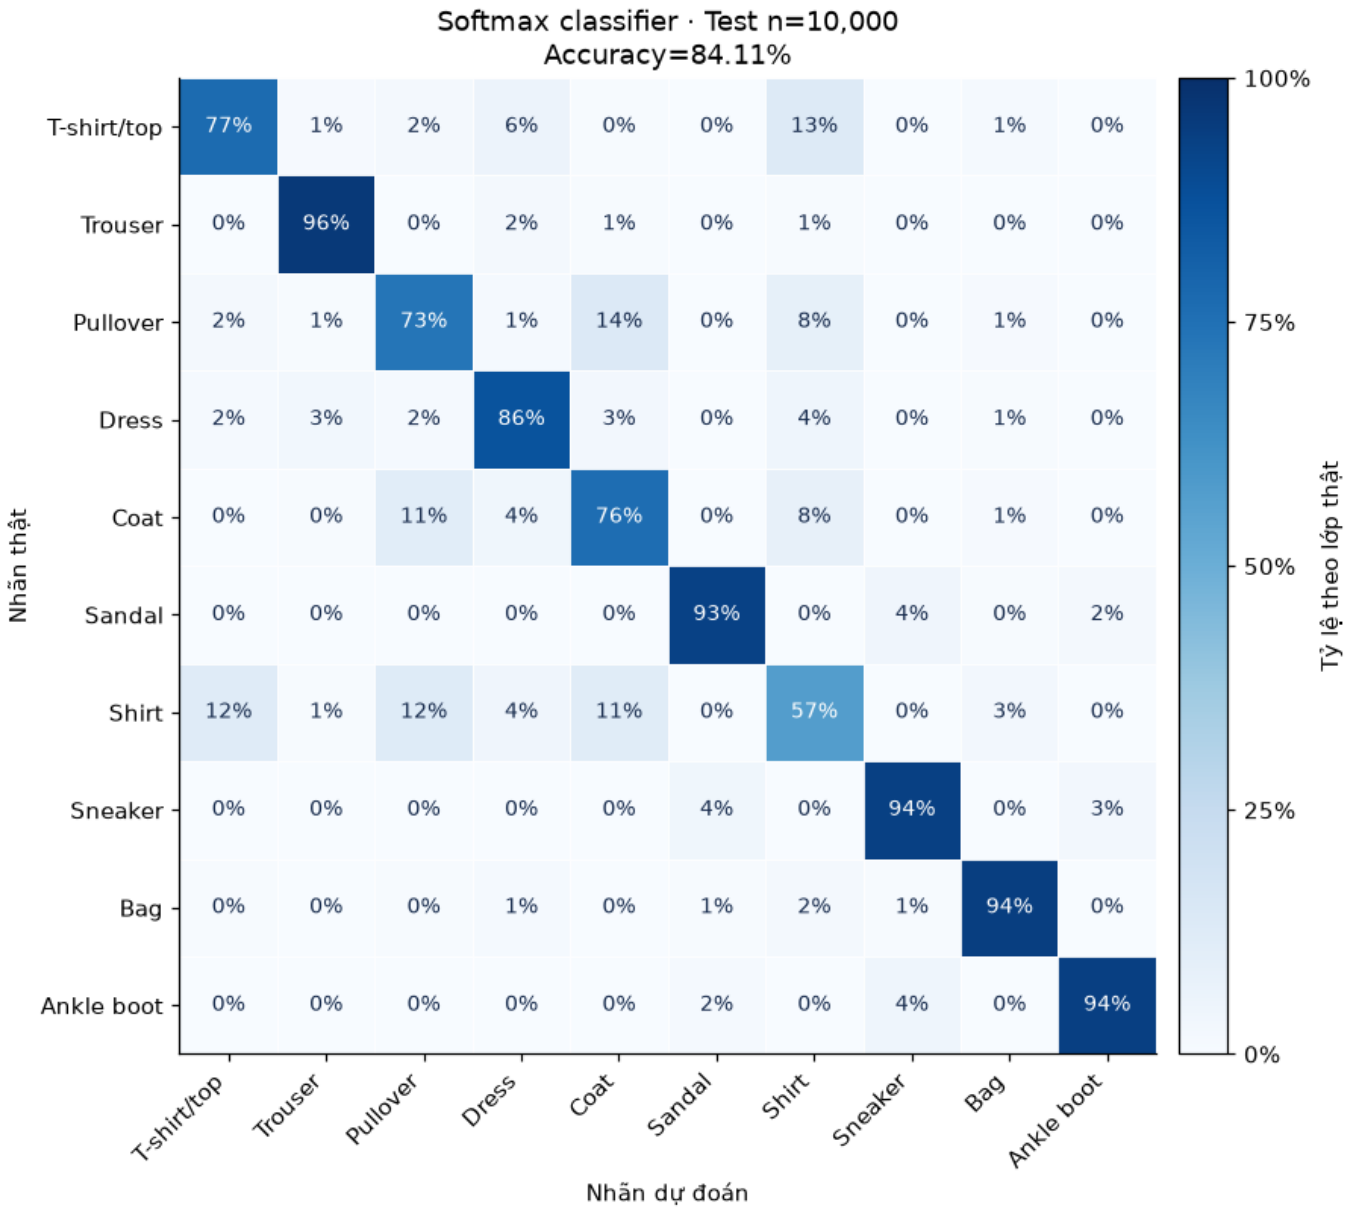

Hình A.12: E1: ma trận test của Softmax.

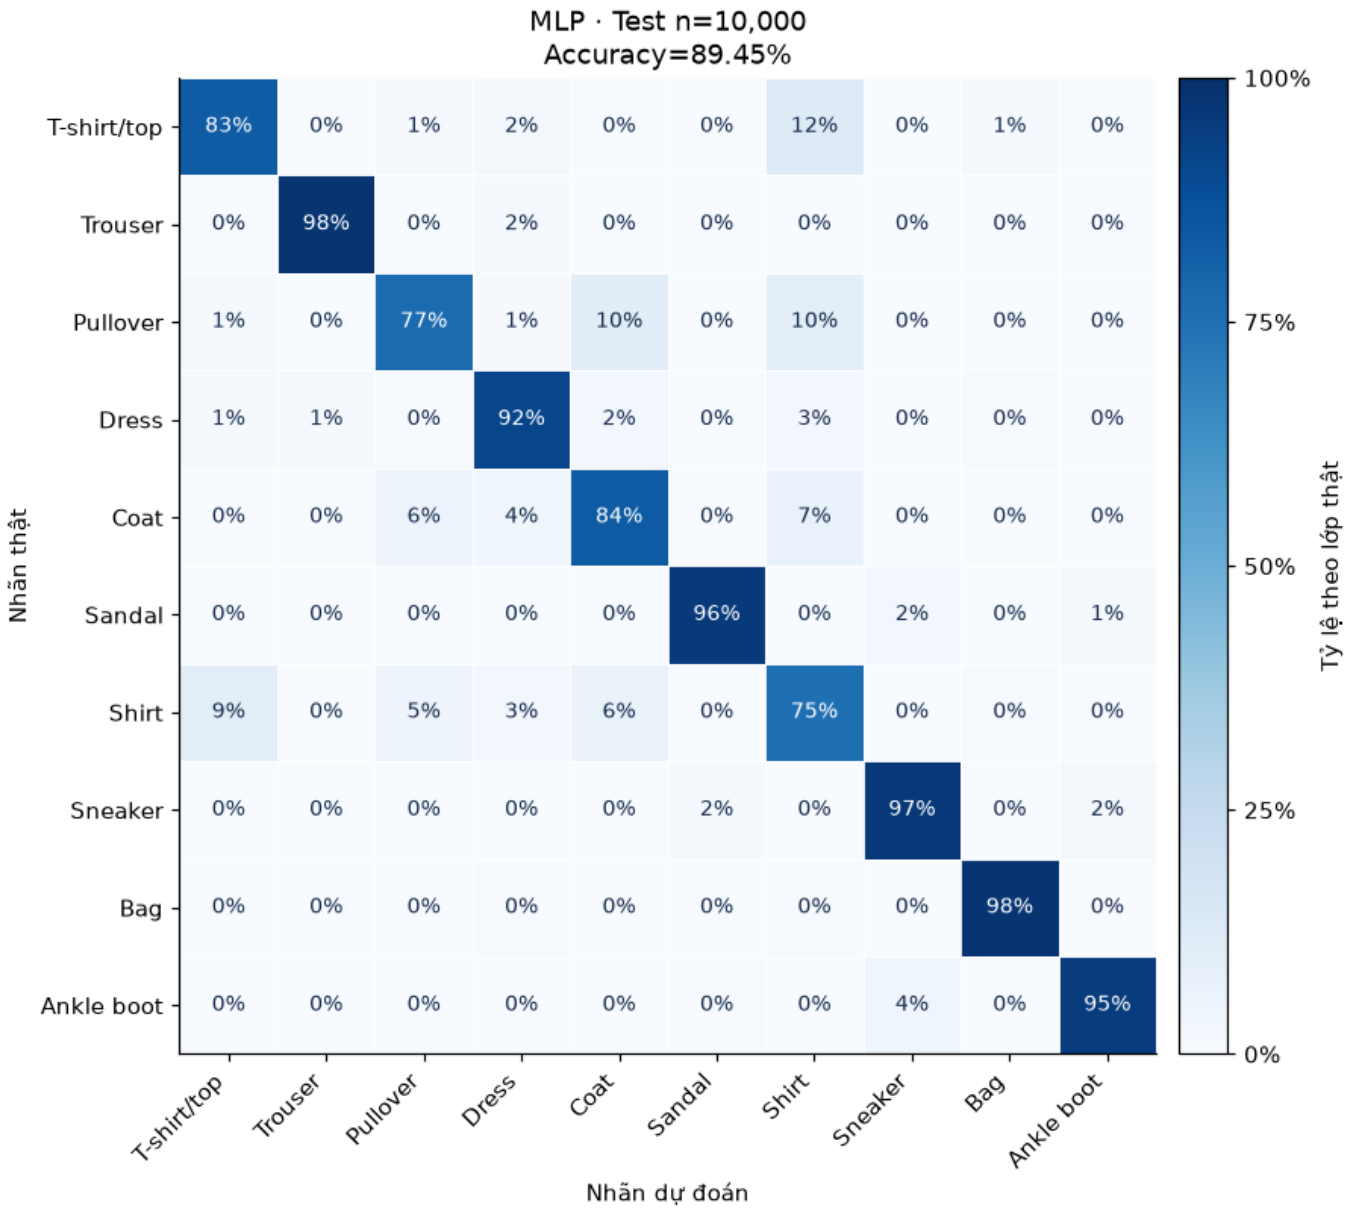

Hình A.13: E1: ma trận test của MLP.

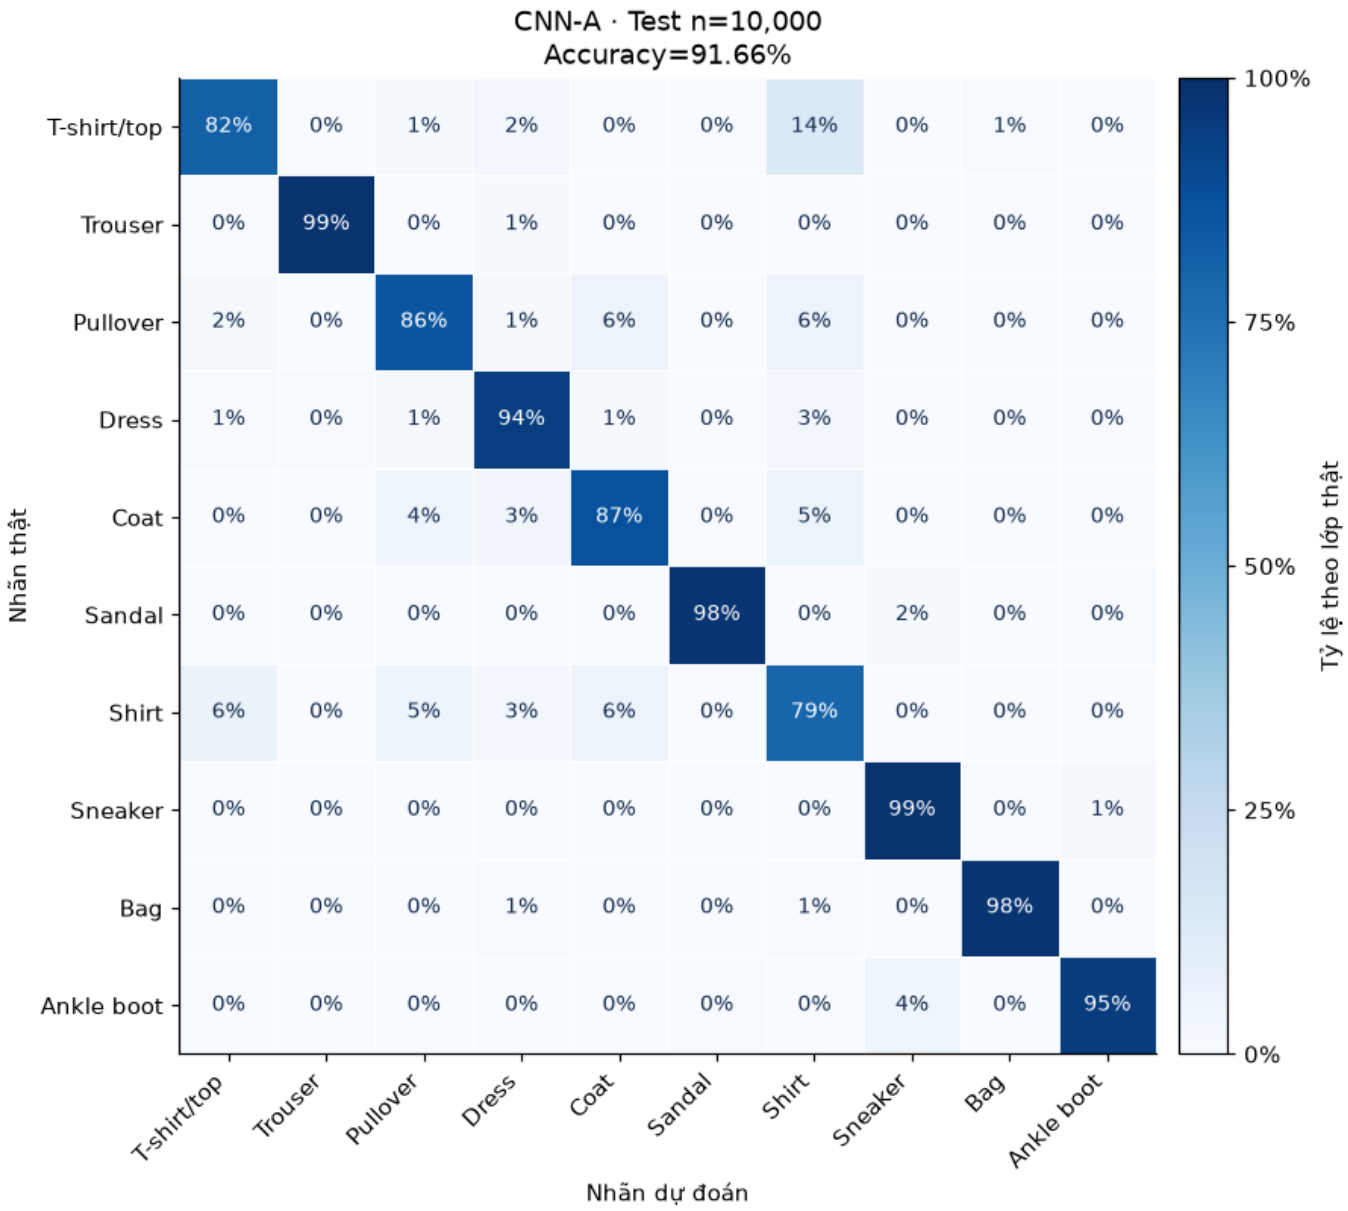

Hình A.14: E1: ma trận test của CNN-A.

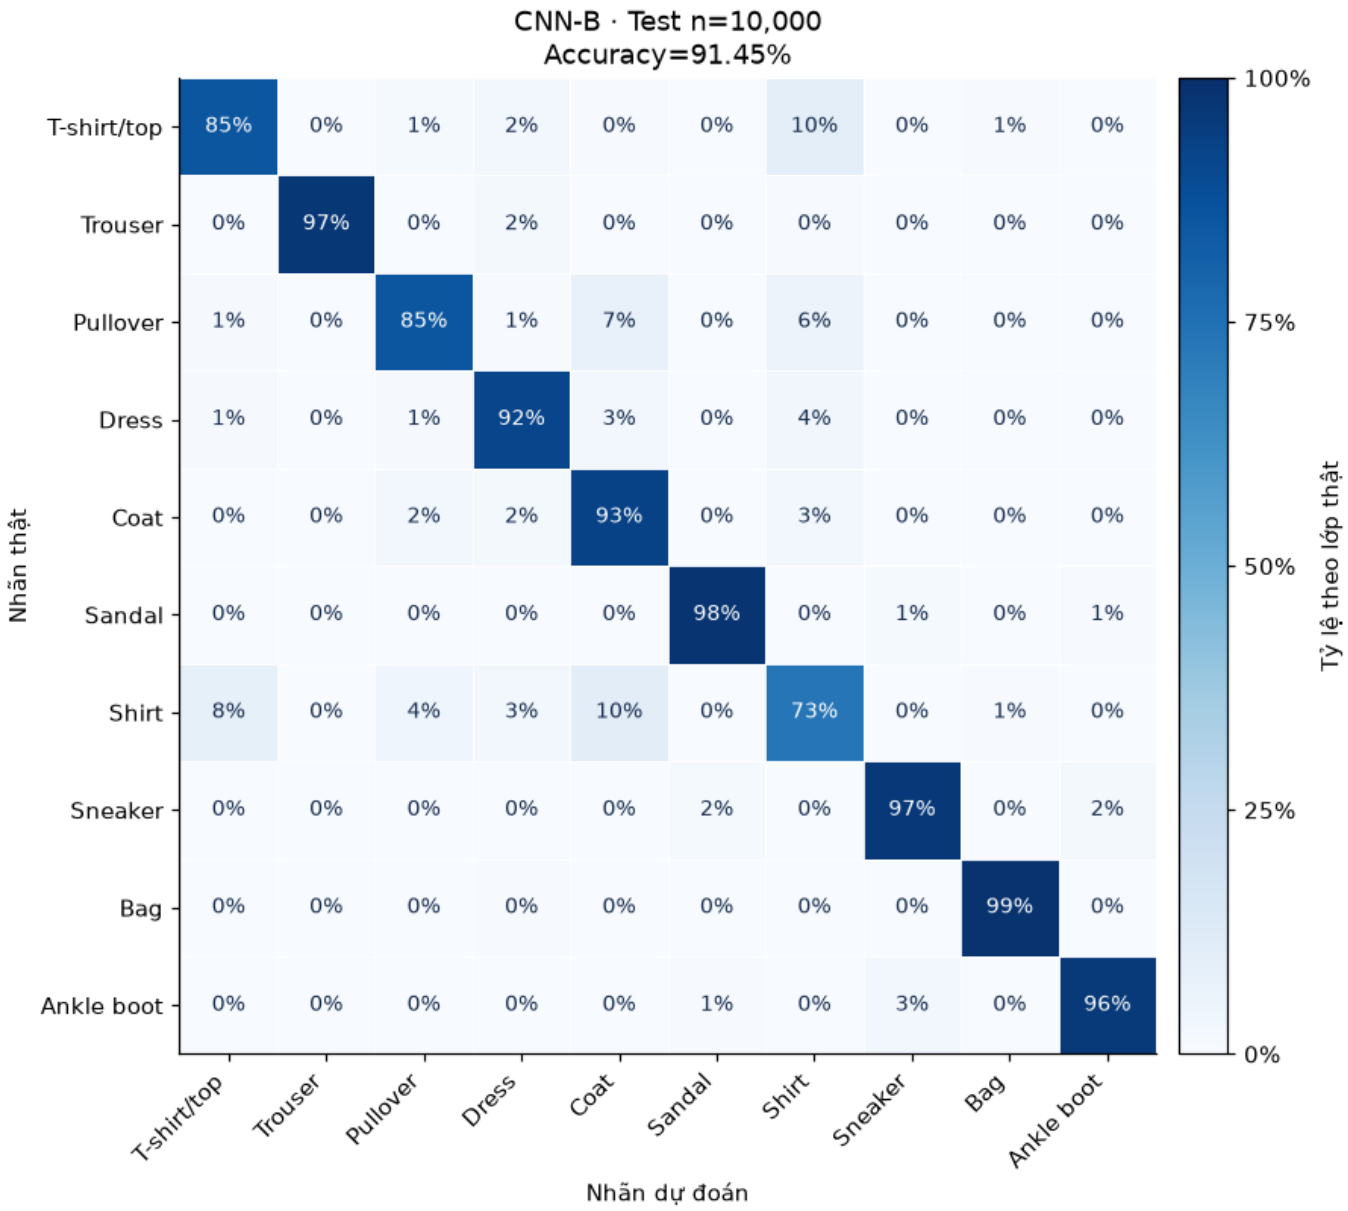

Hình A.15: E1: ma trận test của CNN-B.

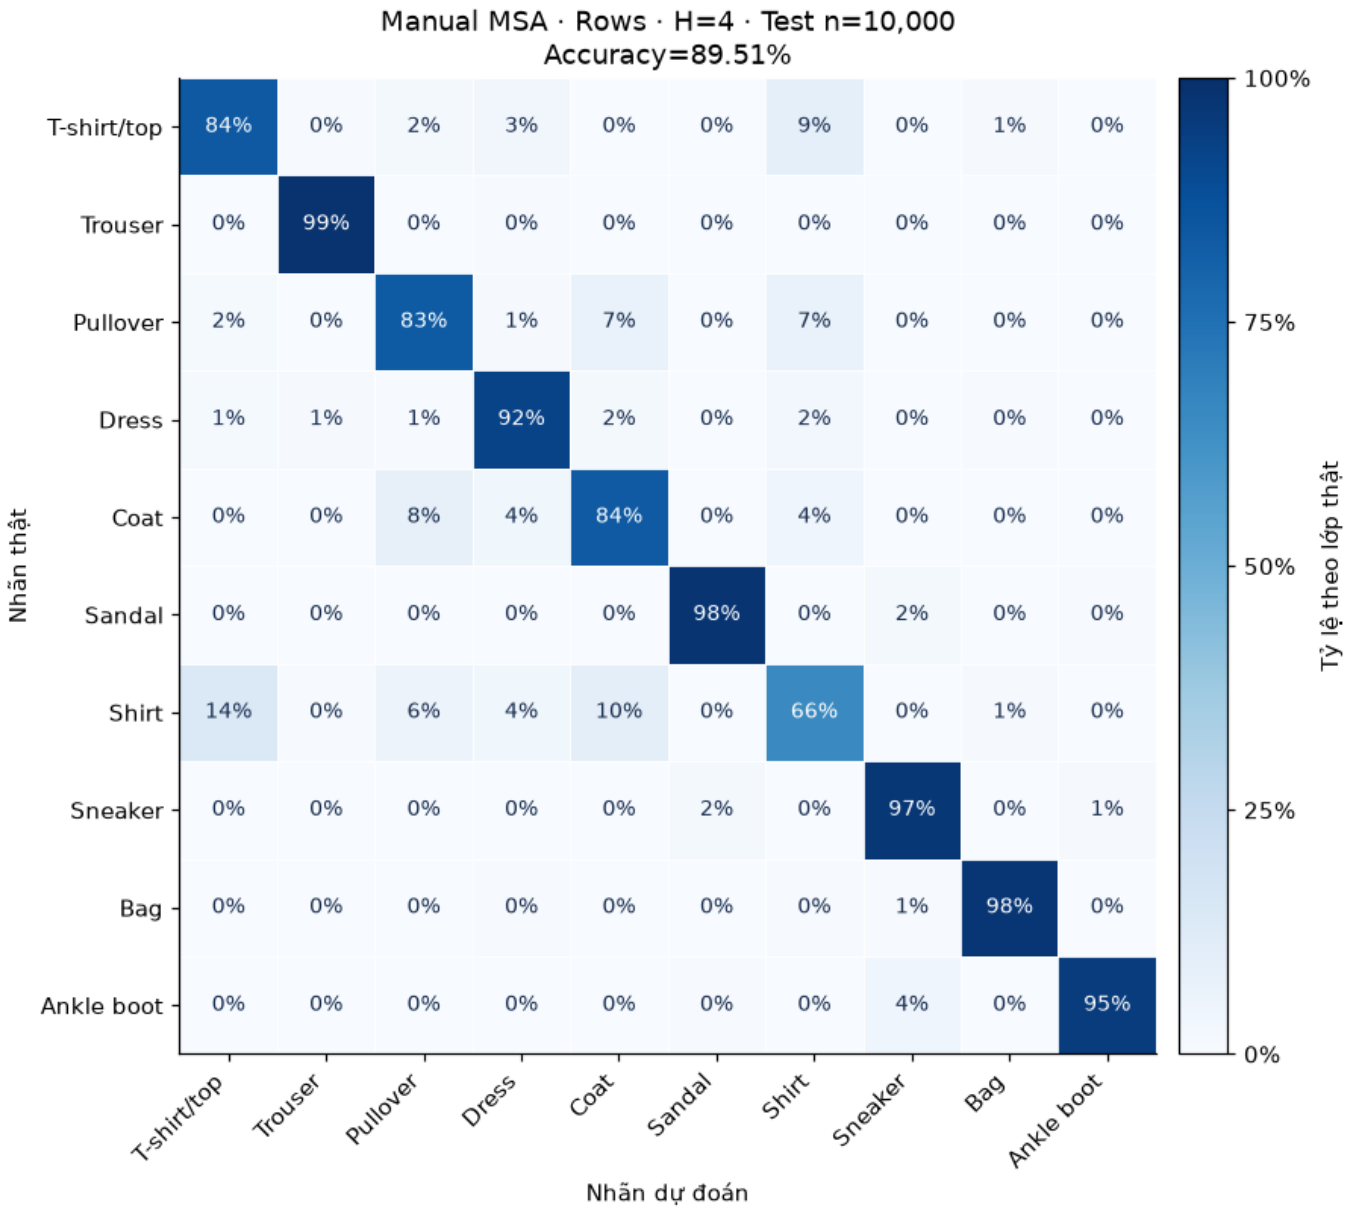

Hình A.16: E2: ma trận test của Manual Rows H=4.

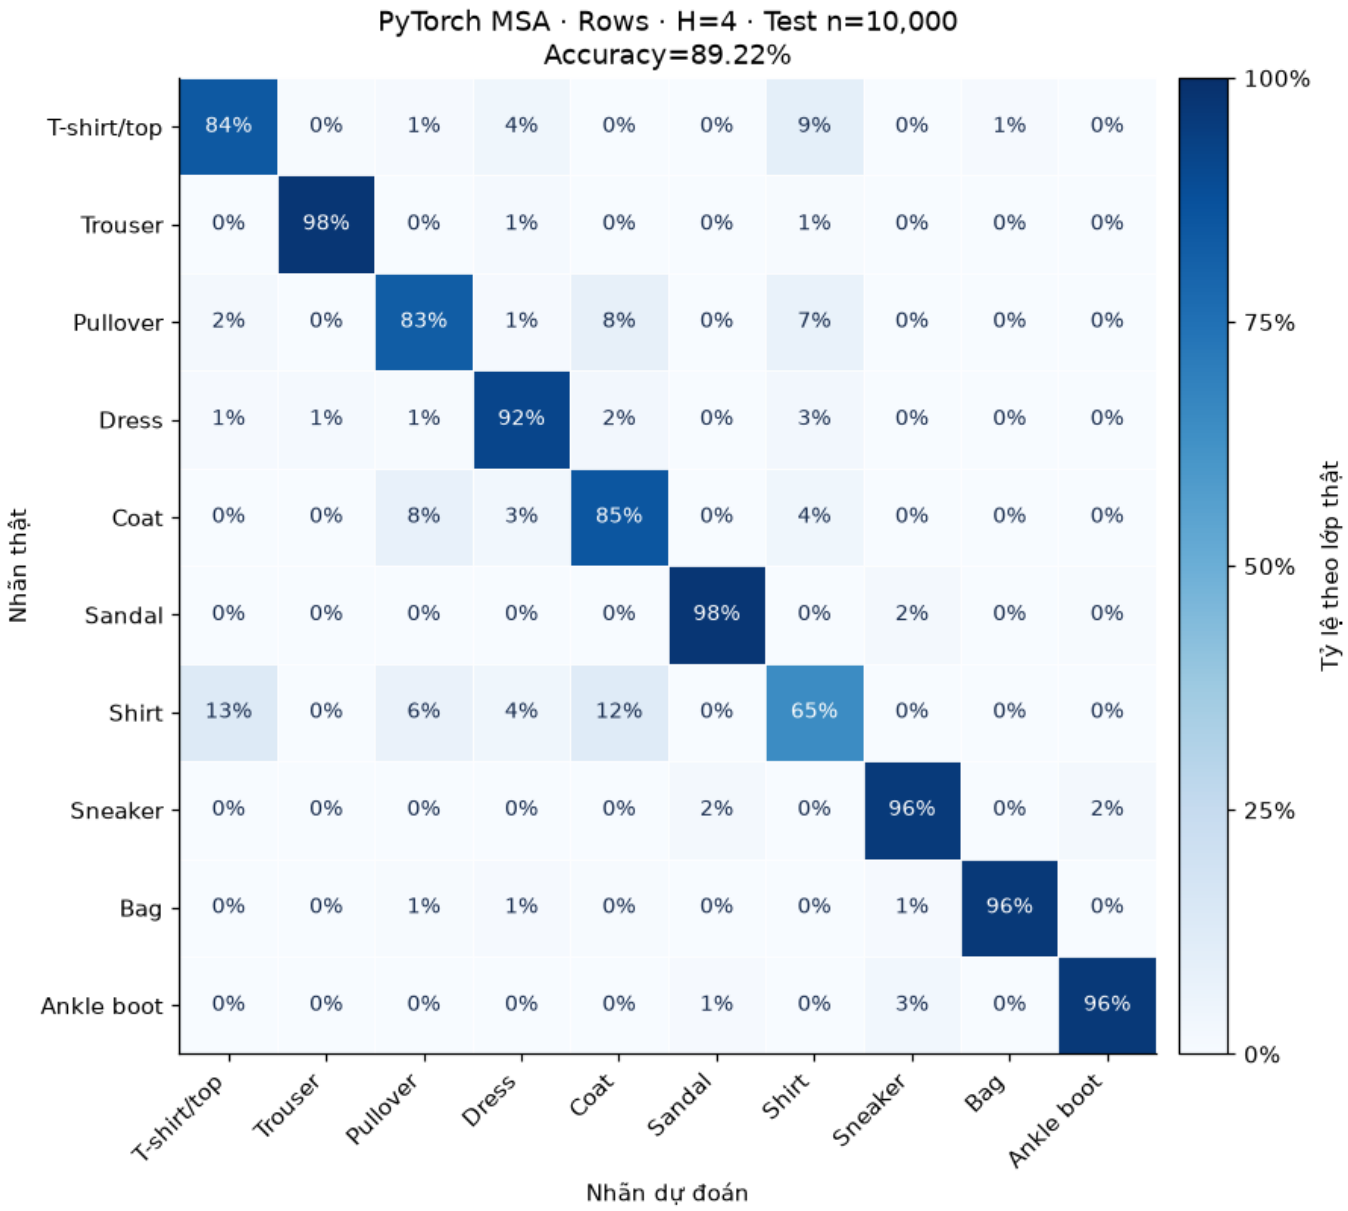

Hình A.17: E2: ma trận test của PyTorch Rows H=4.

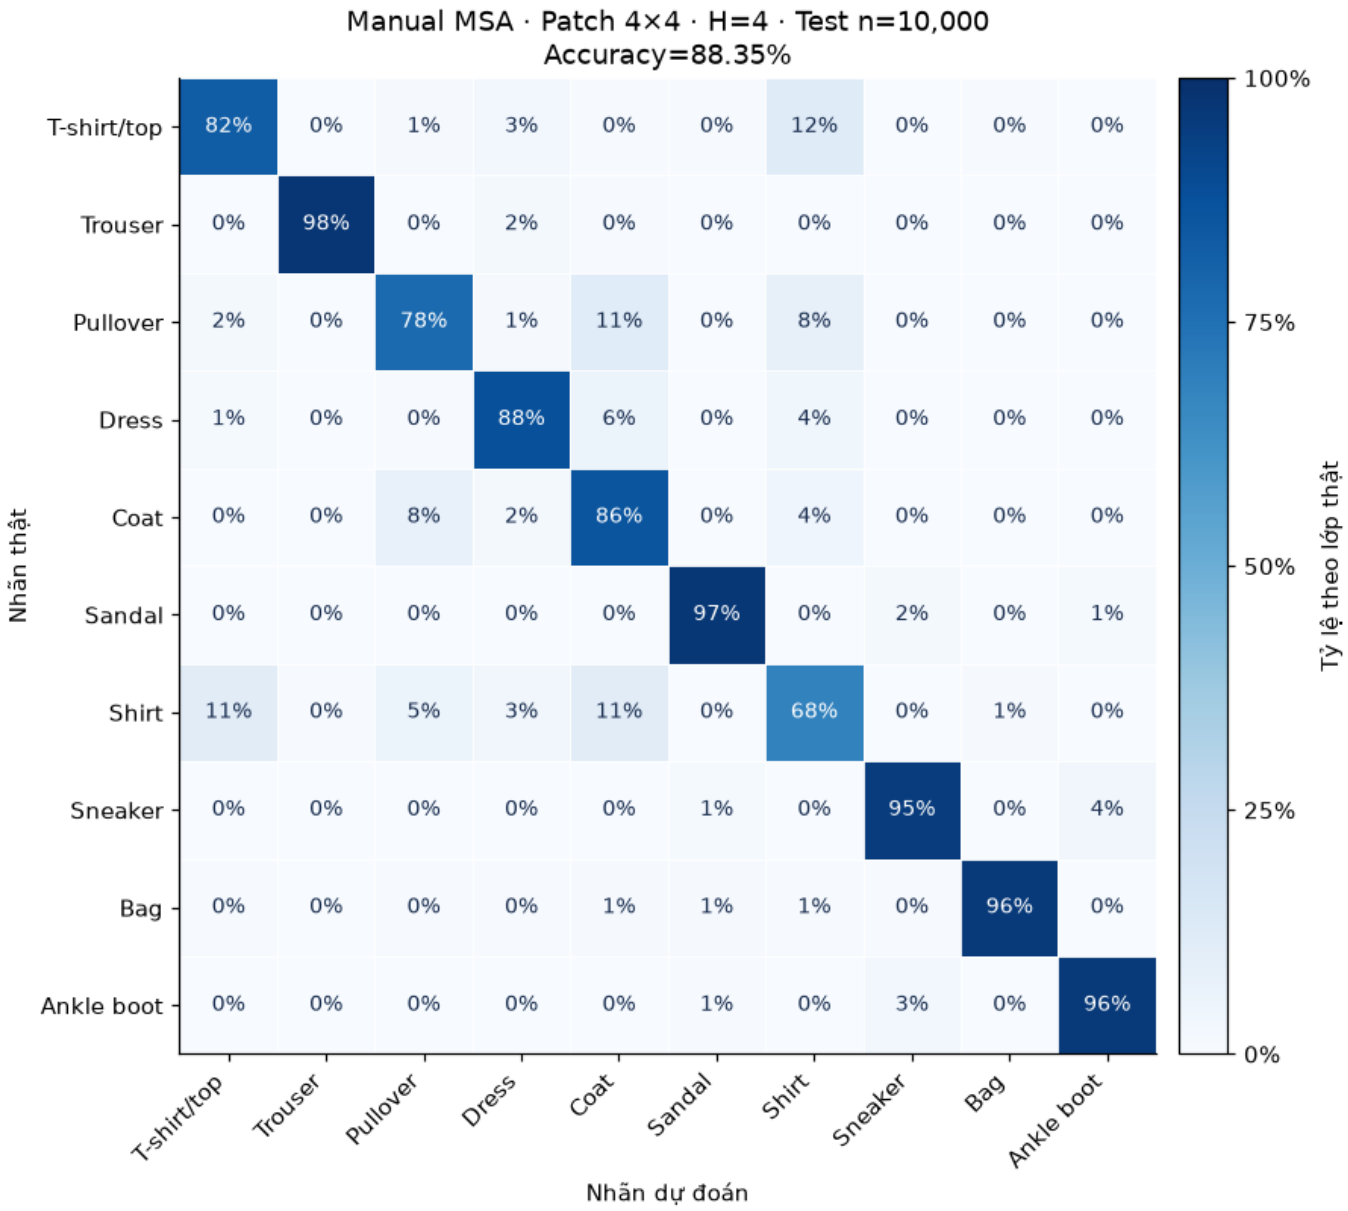

Hình A.18: E2: ma trận test của Manual Patch H=4.

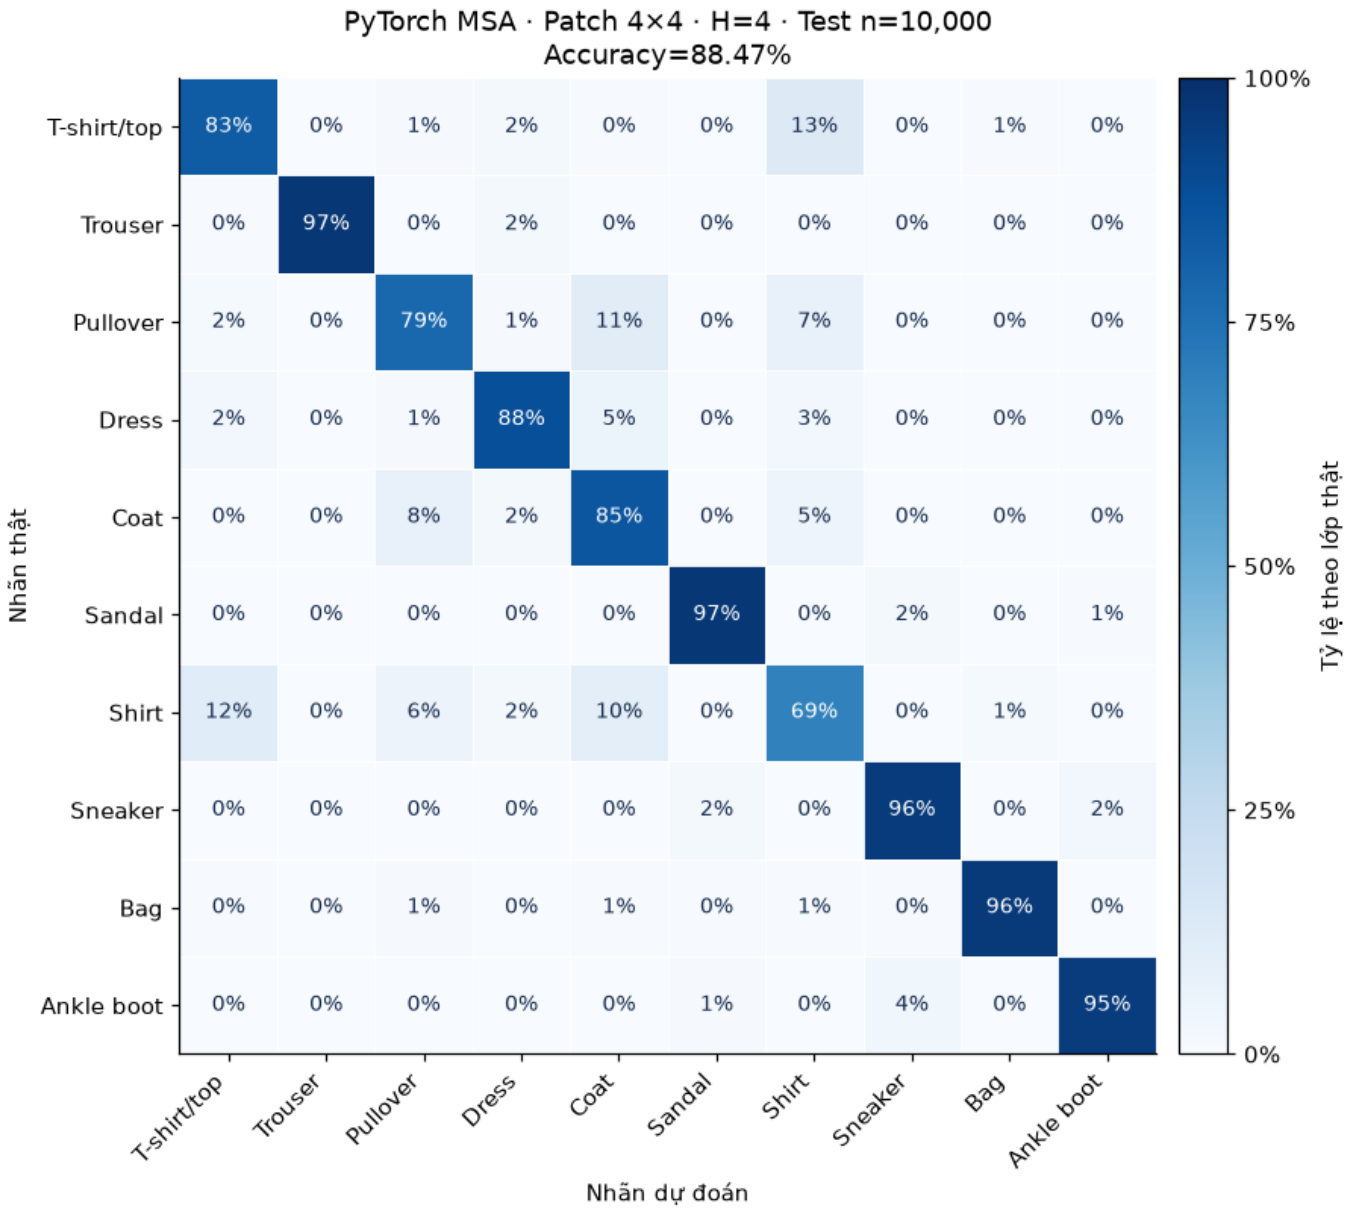

Hình A.19: E2: ma trận test của PyTorch Patch H=4.

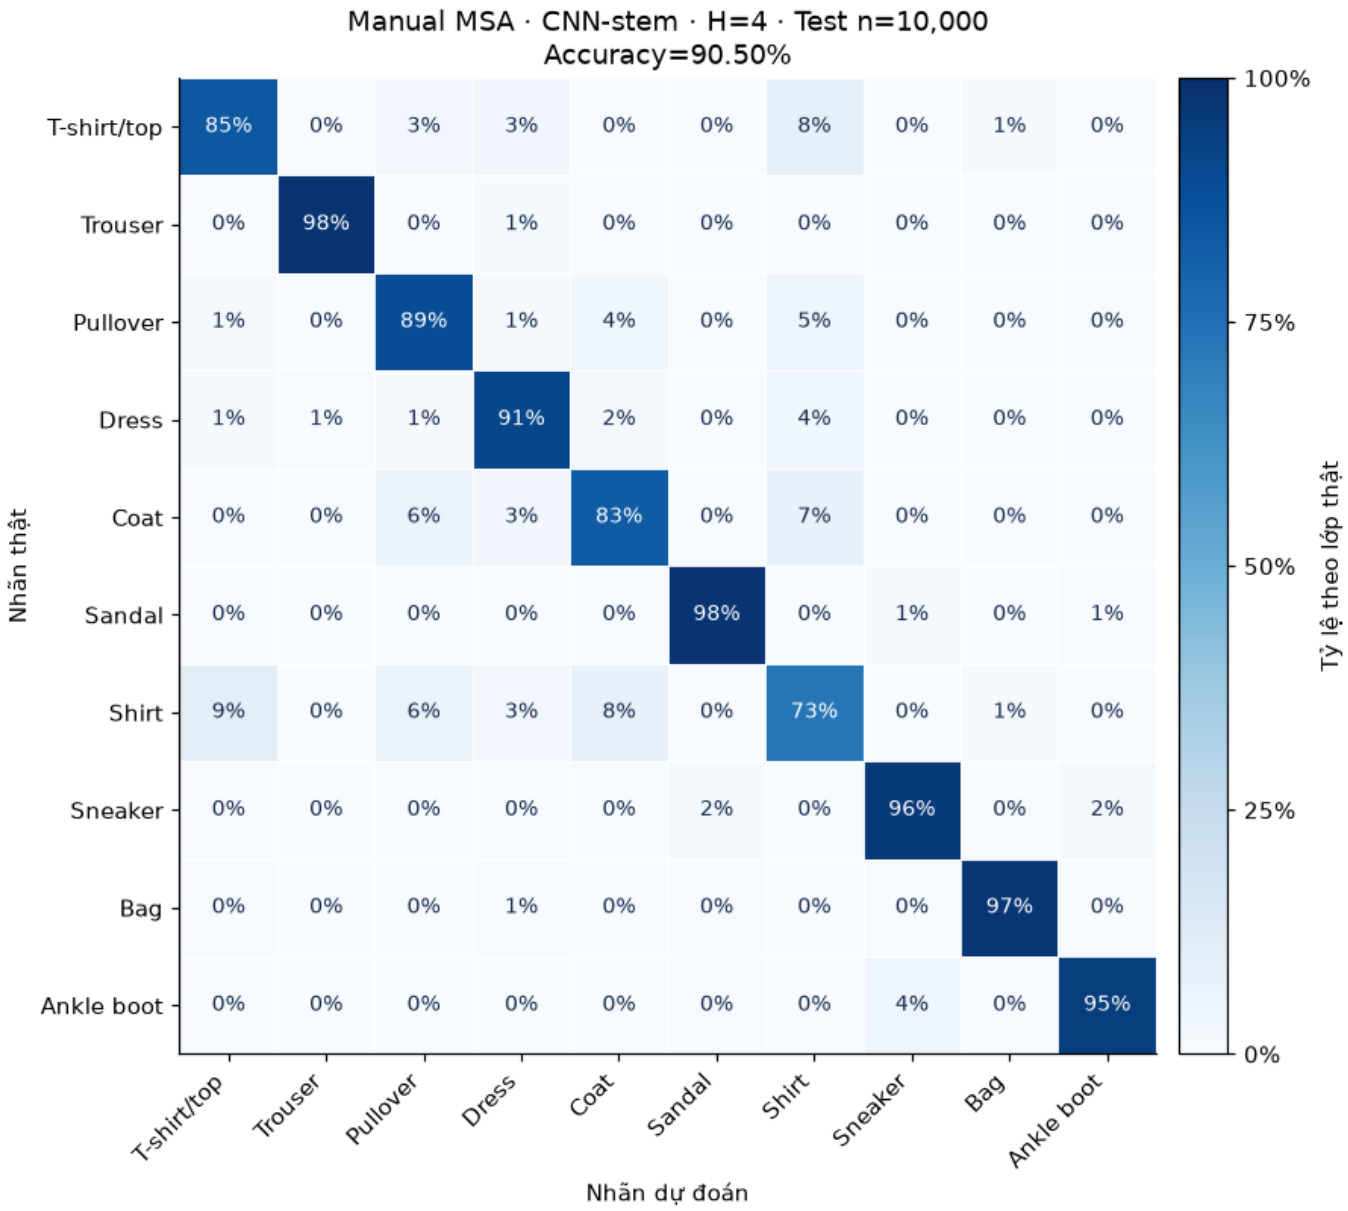

Hình A.20: E2: ma trận test của Manual CNN-stem H=4.

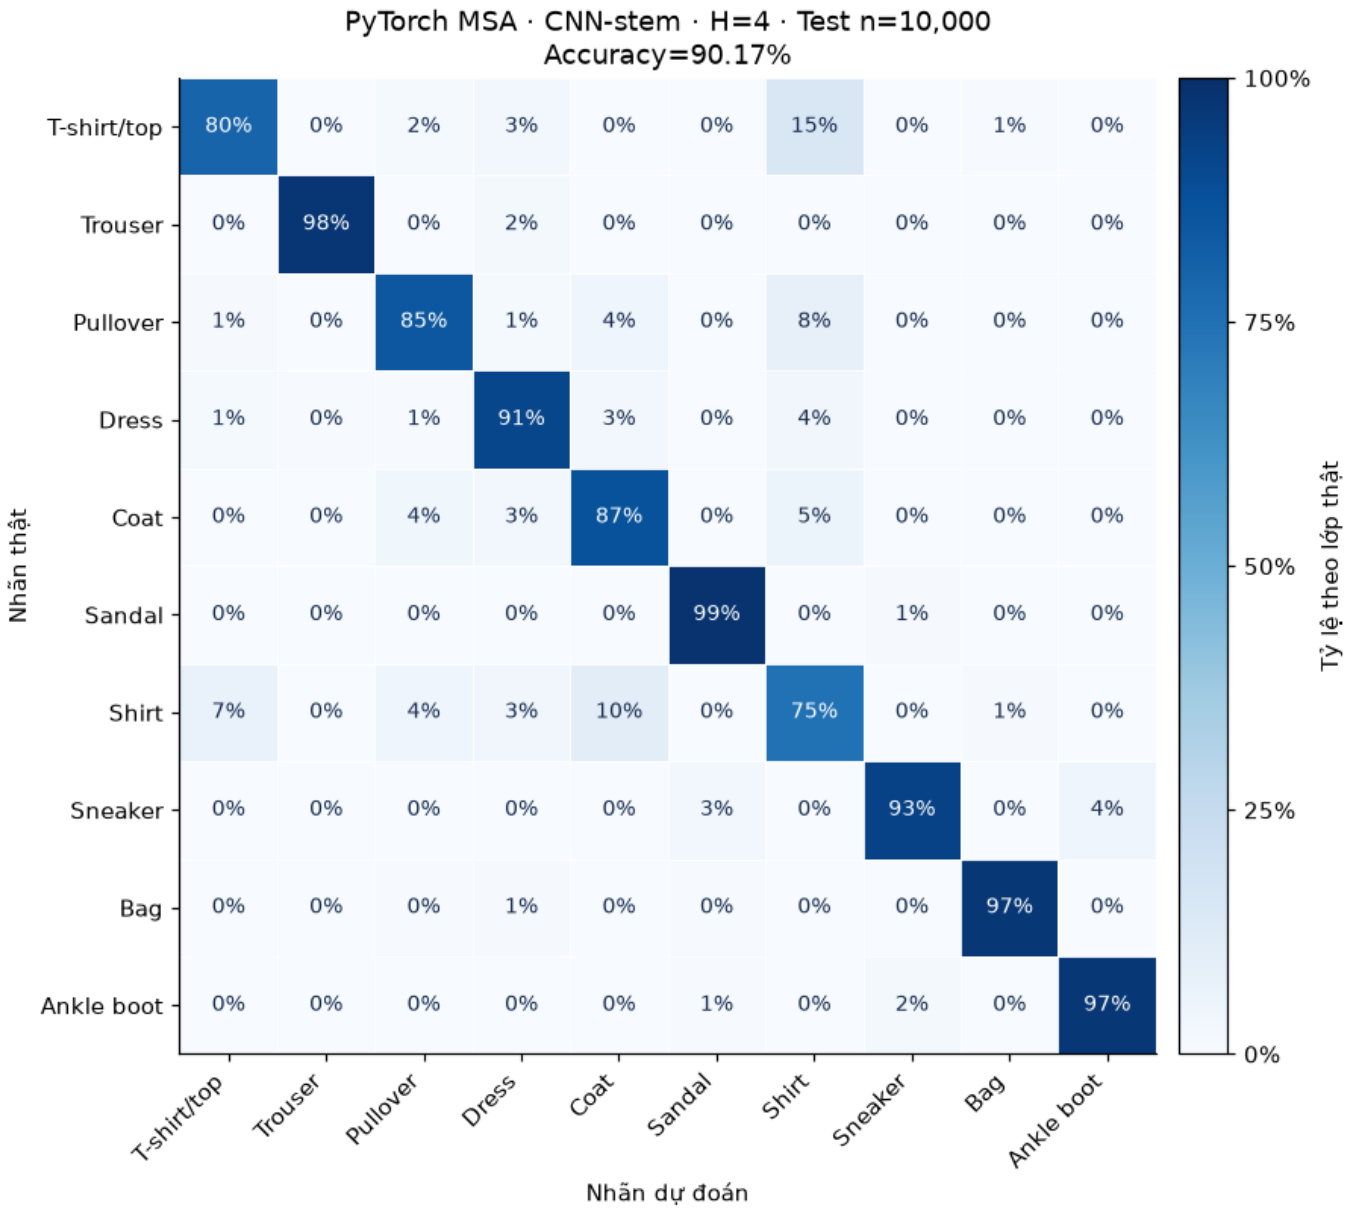

Hình A.21: E2: ma trận test của PyTorch CNN-stem H=4.

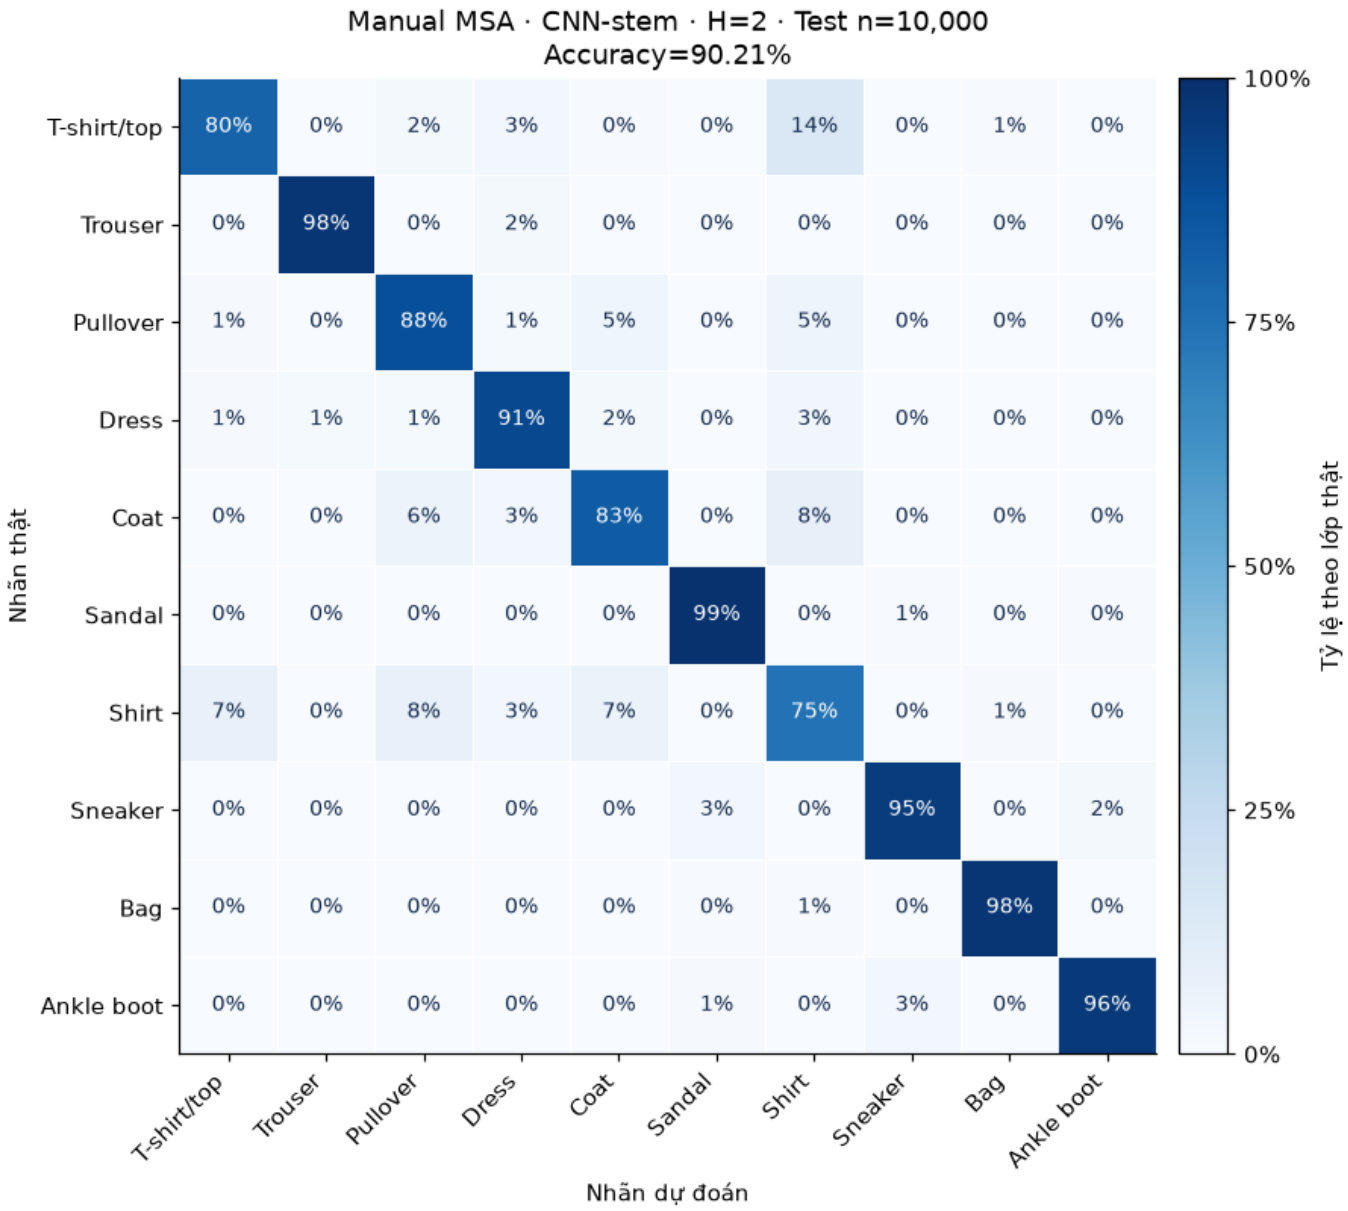

Hình A.22: E2: ma trận test của Manual CNN-stem H=2.

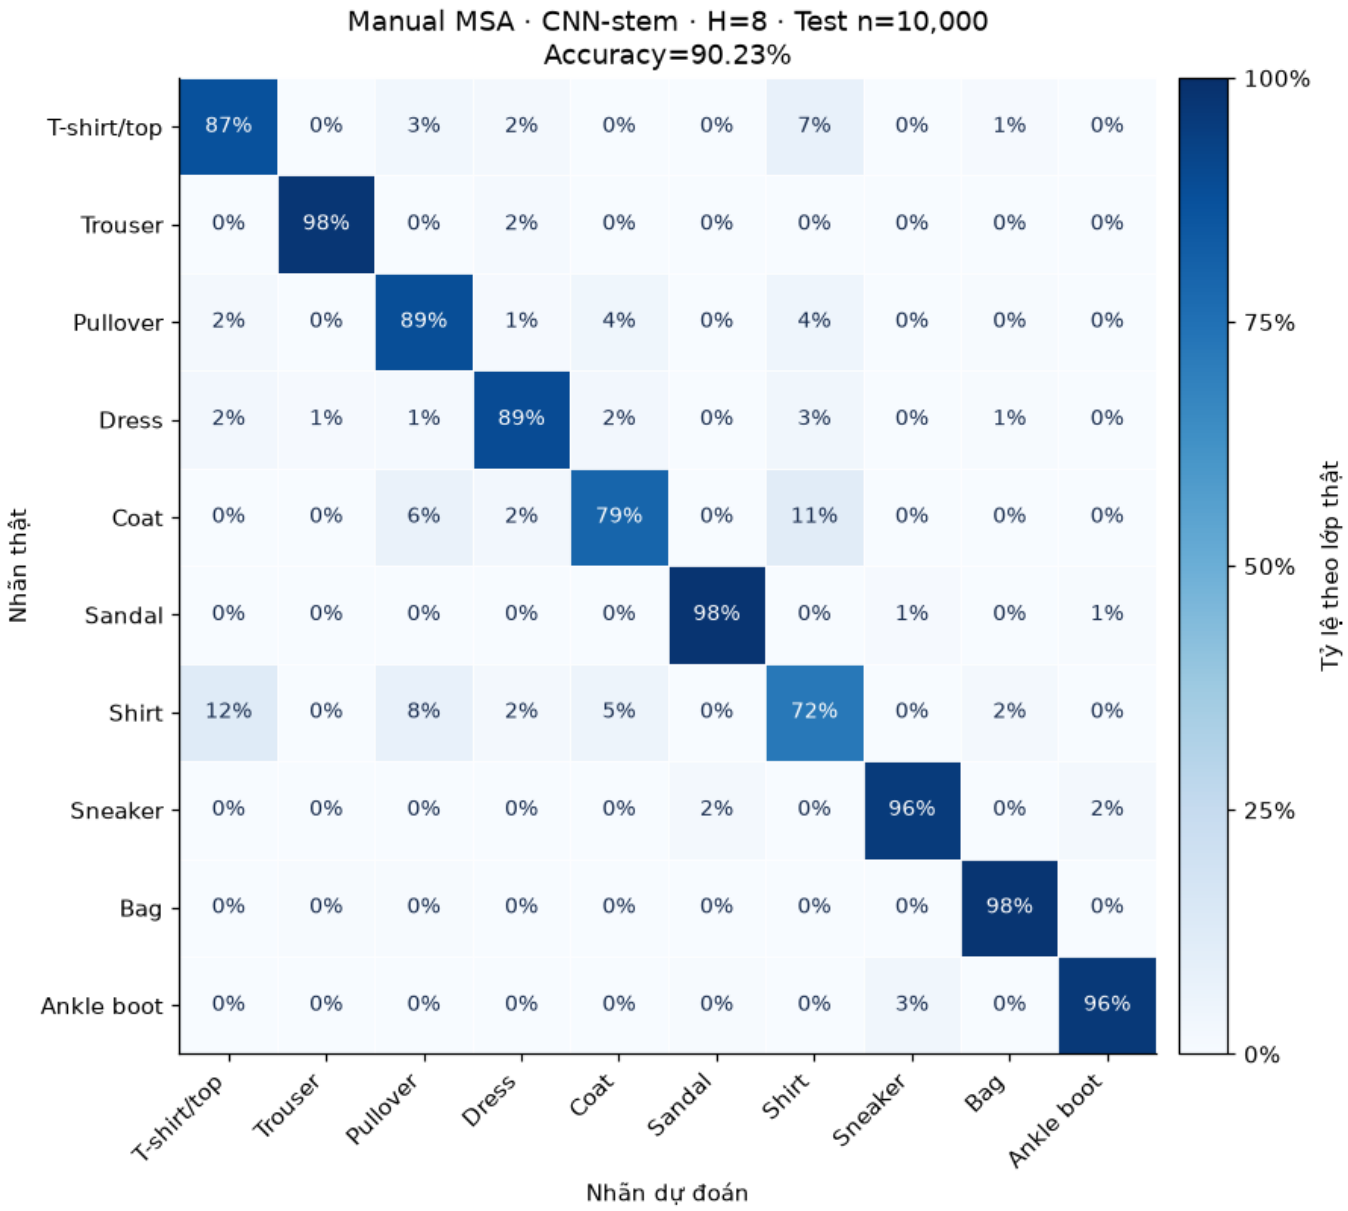

Hình A.23: E2: ma trận test của Manual CNN-stem H=8.

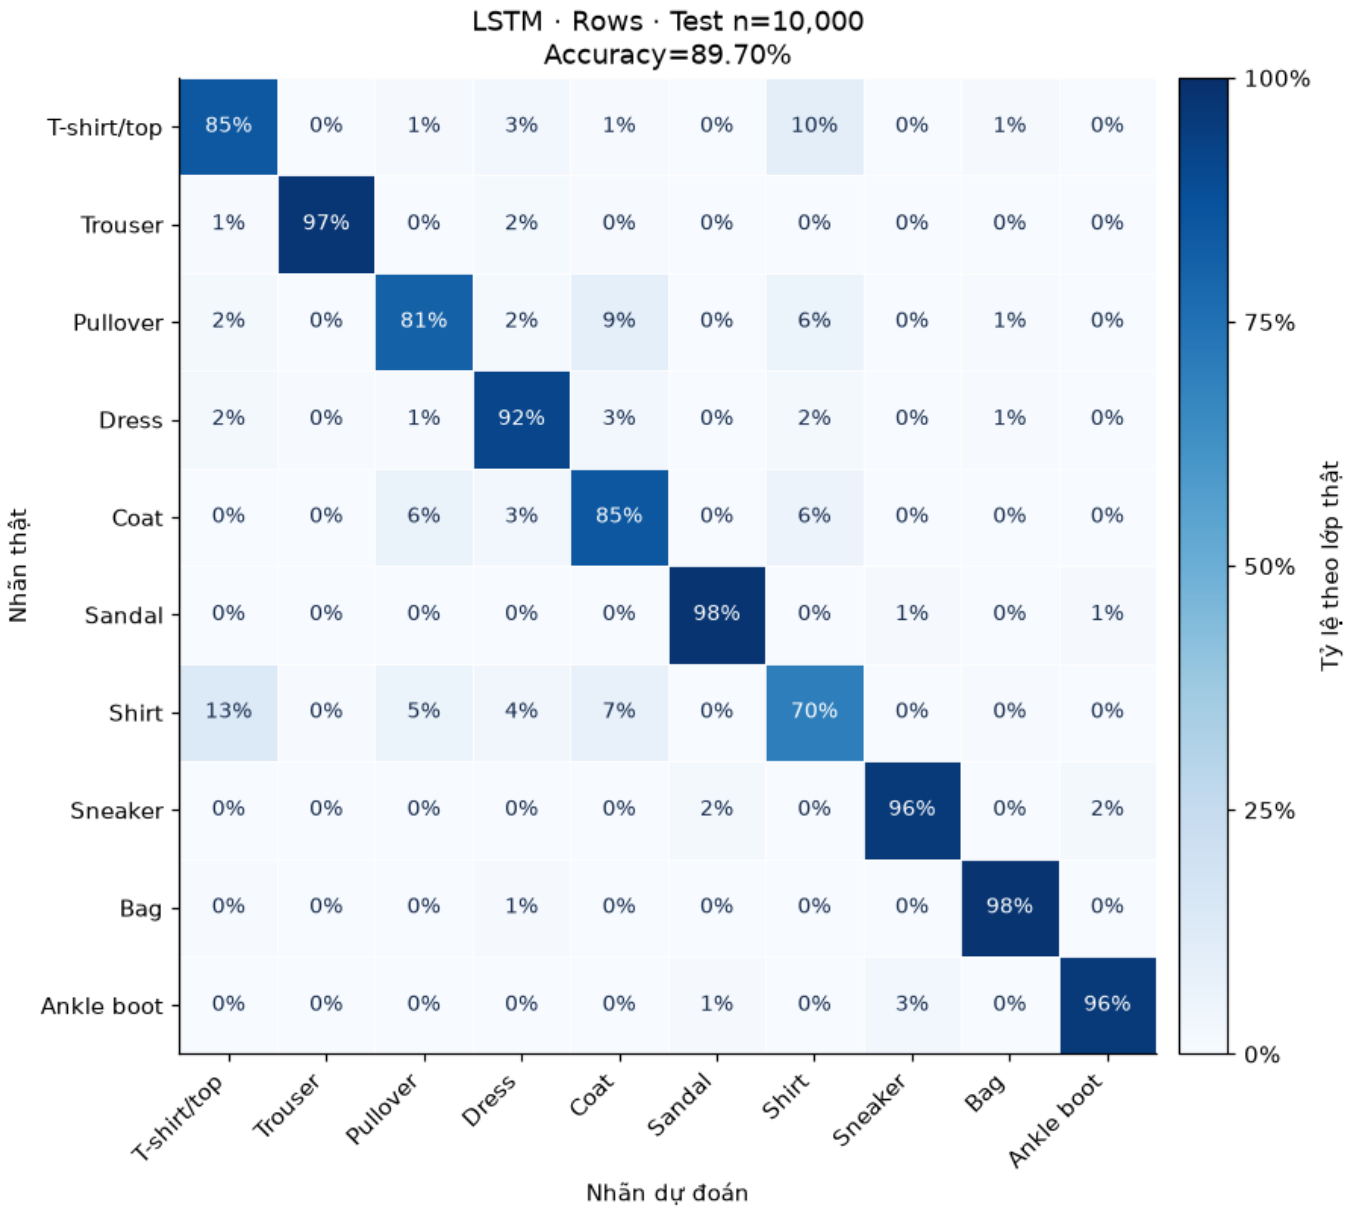

Hình A.24: E3: ma trận test của LSTM Rows.

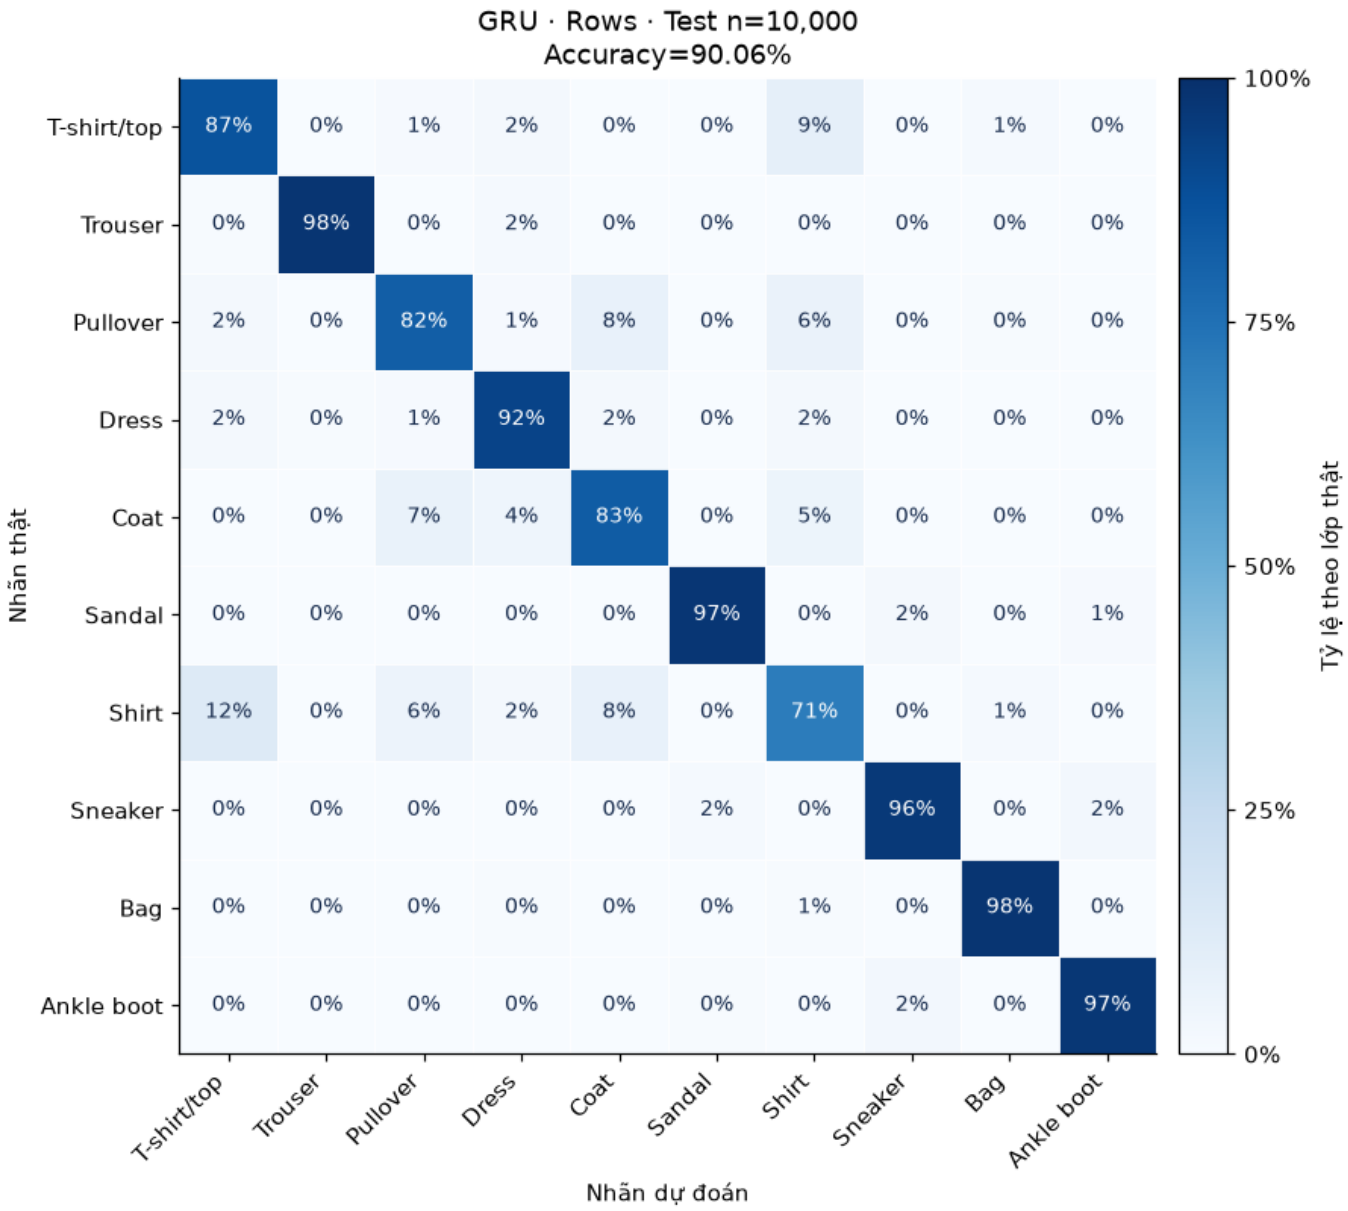

Hình A.25: E3: ma trận test của GRU Rows.

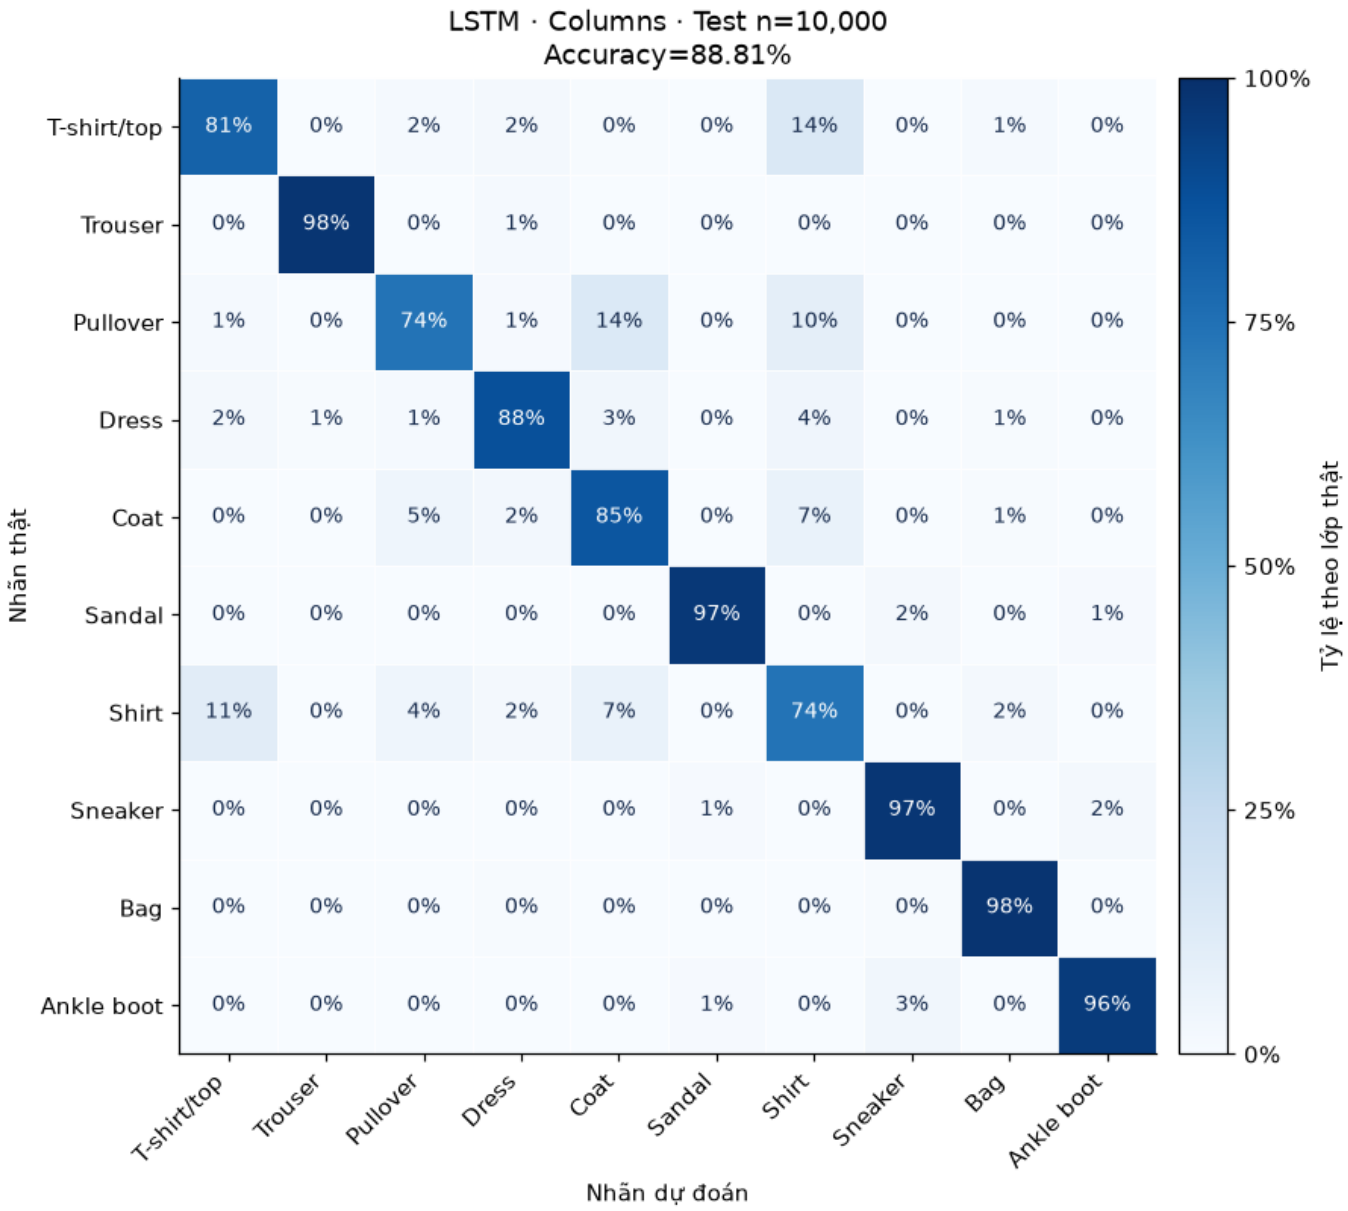

Hình A.26: E3: ma trận test của LSTM Columns.

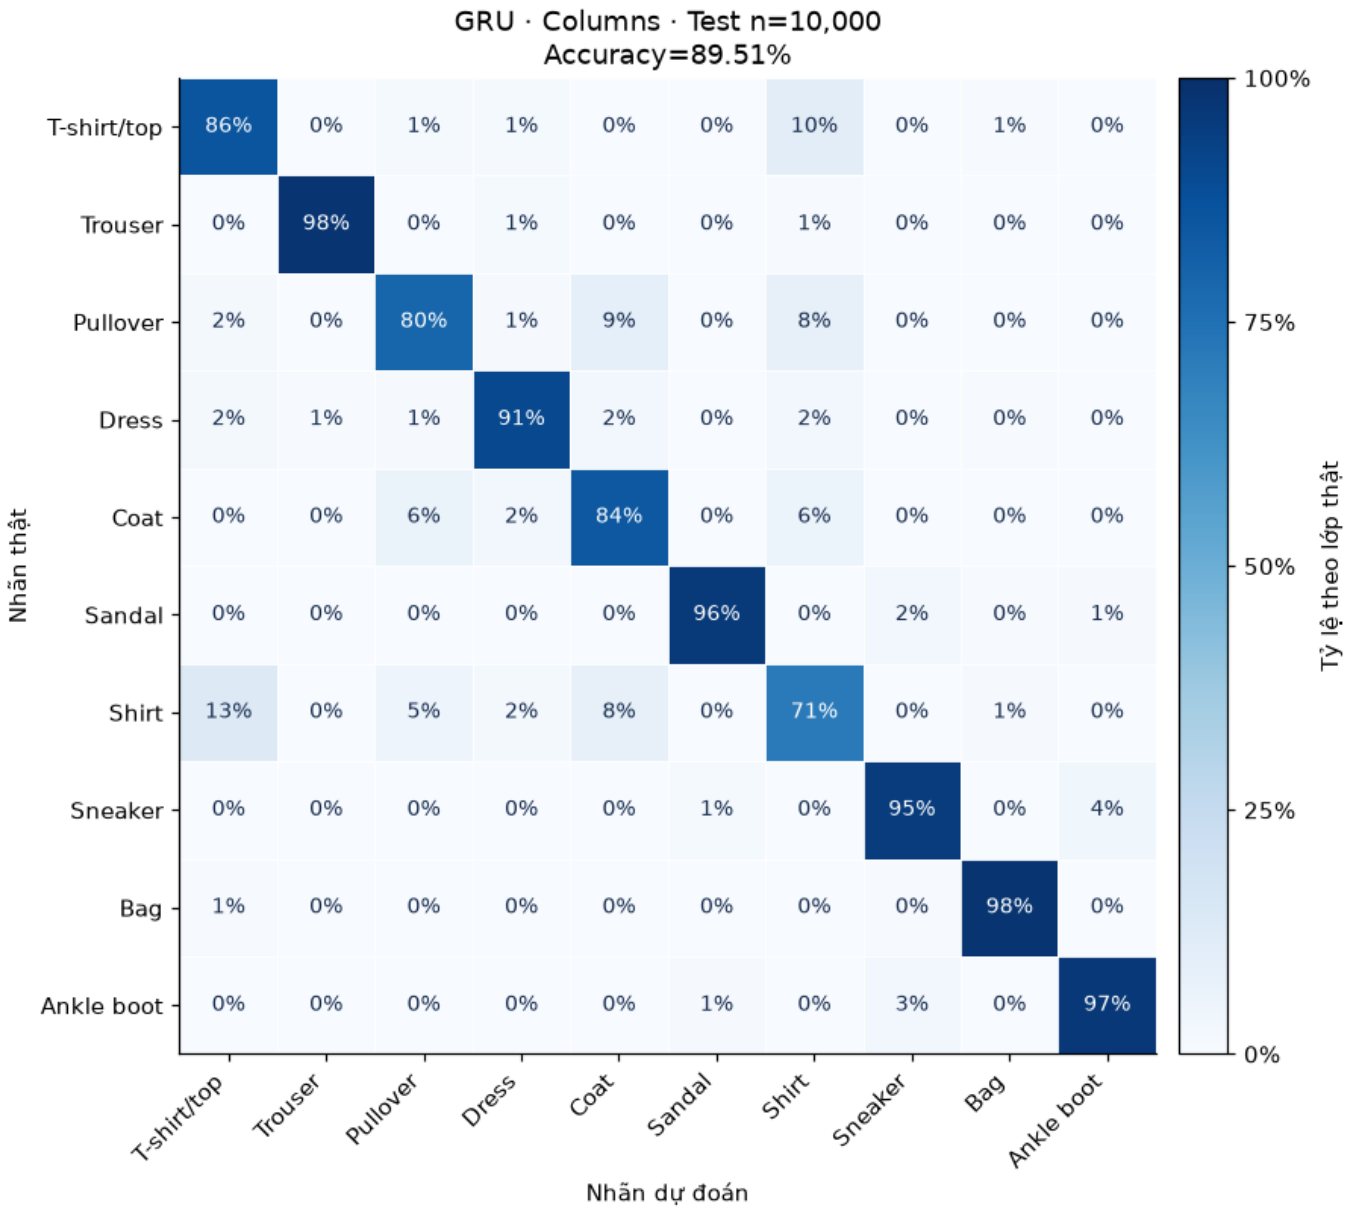

Hình A.27: E3: ma trận test của GRU Columns.

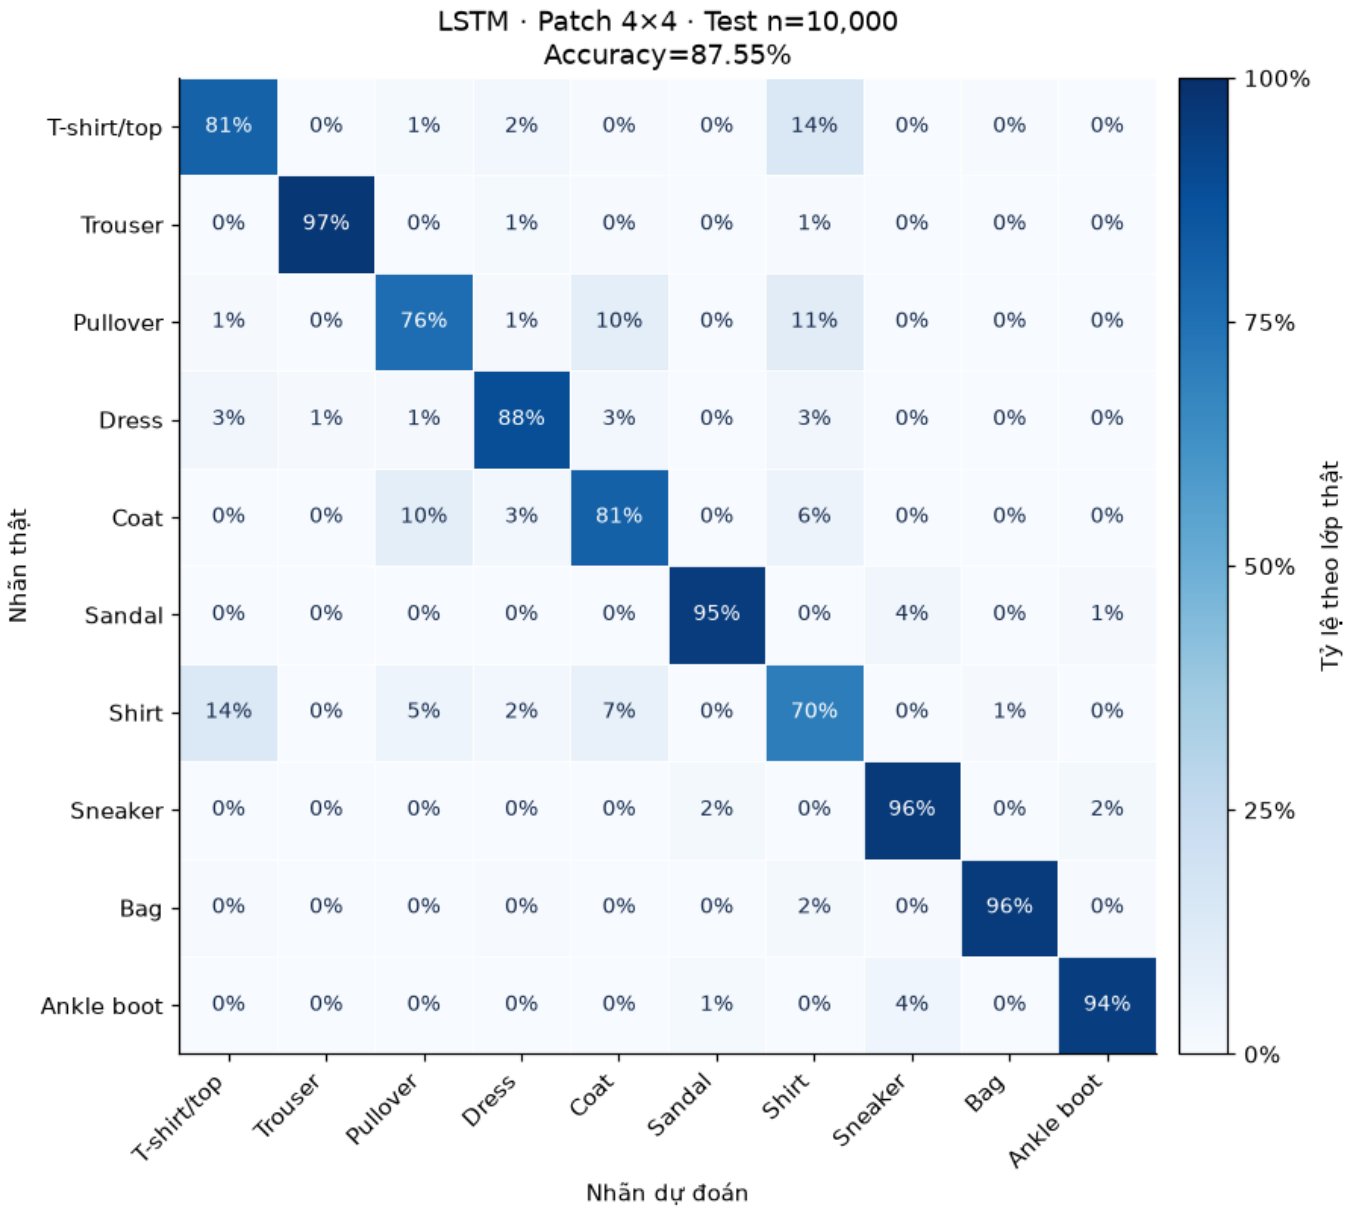

Hình A.28: E3: ma trận test của LSTM Patch.

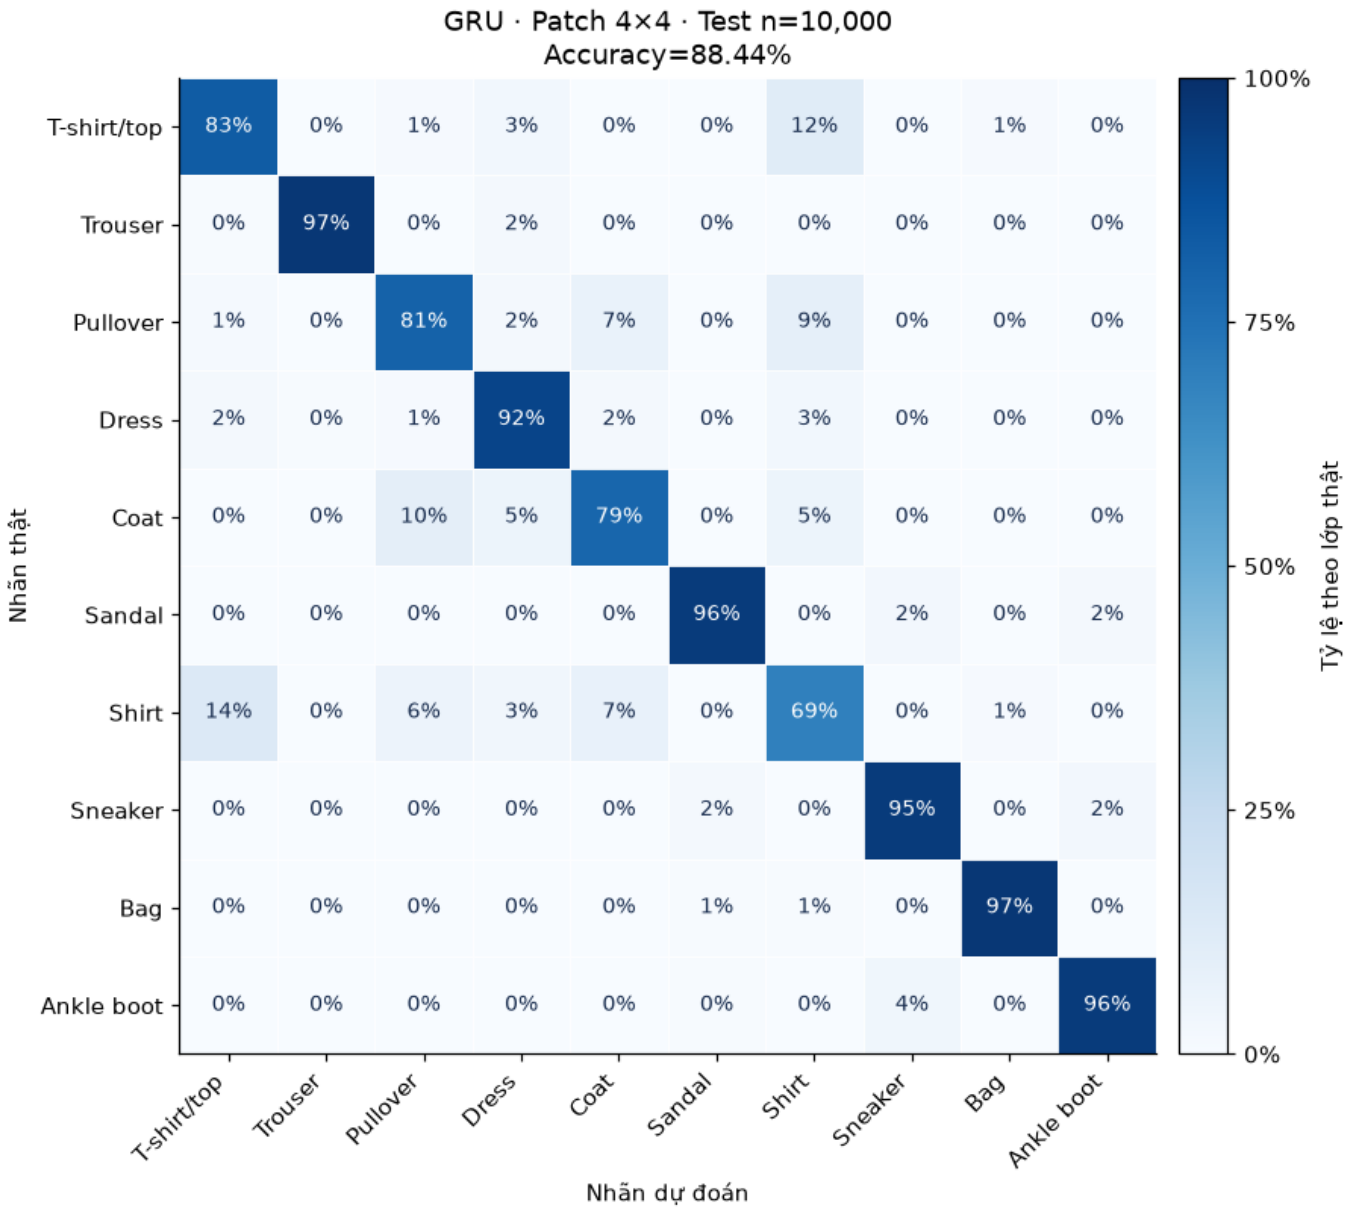

Hình A.29: E3: ma trận test của GRU Patch.

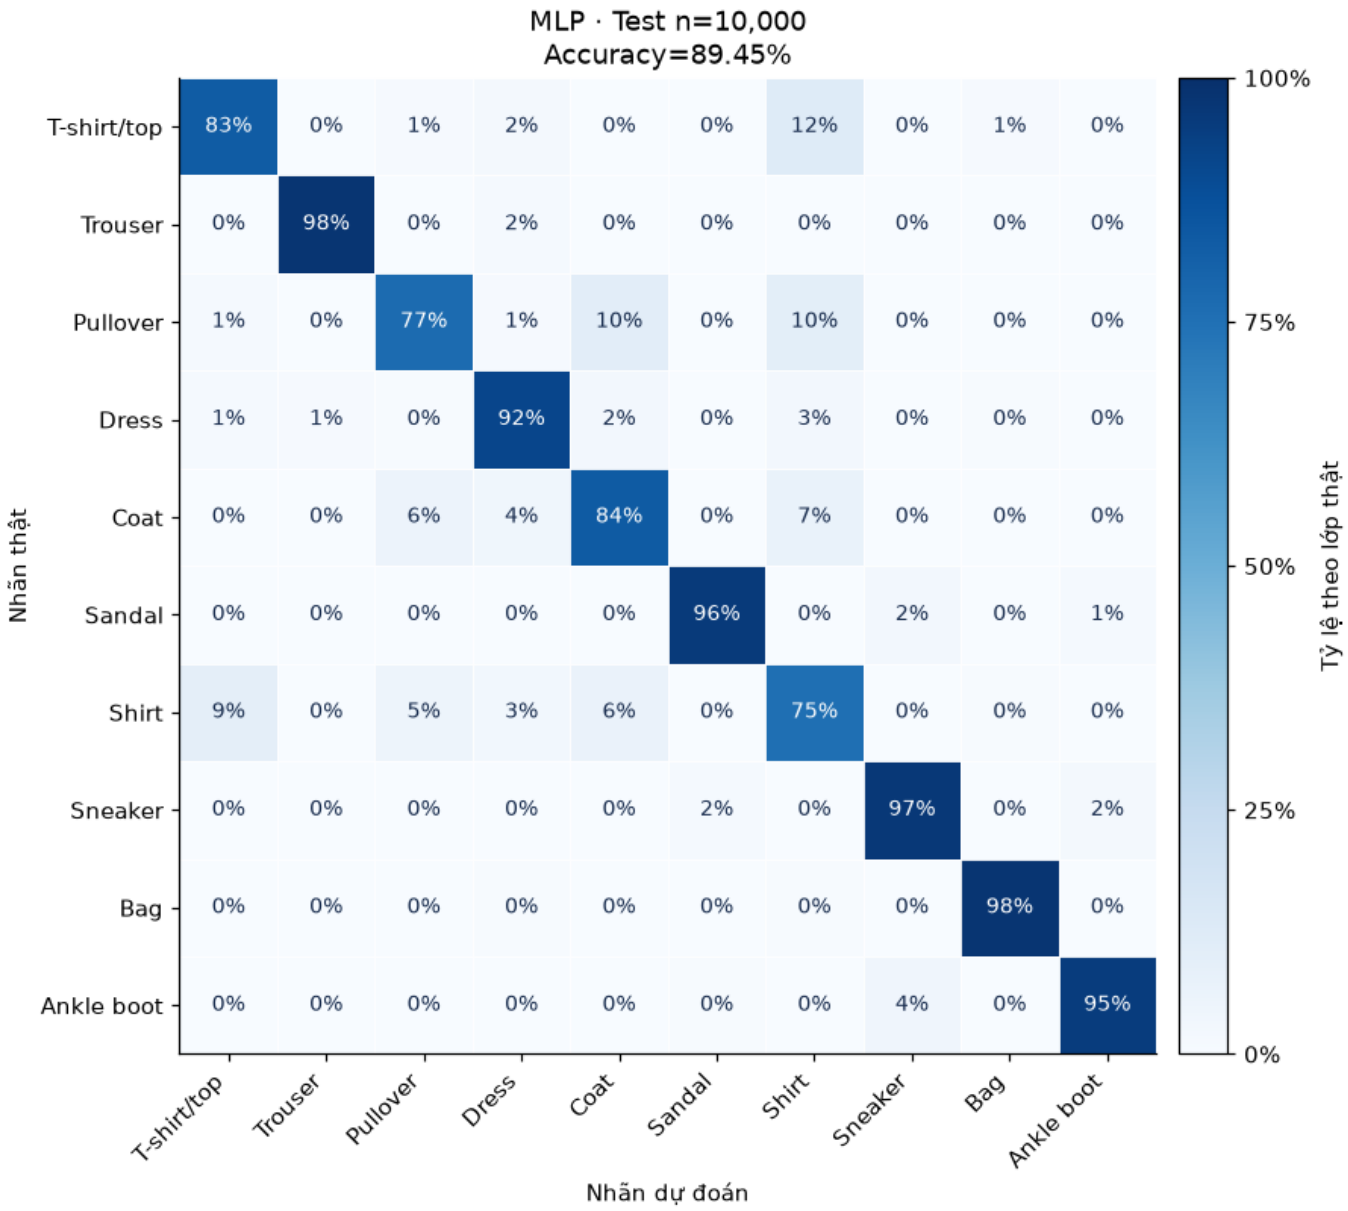

Hình A.30: E3: ma trận test của MLP.

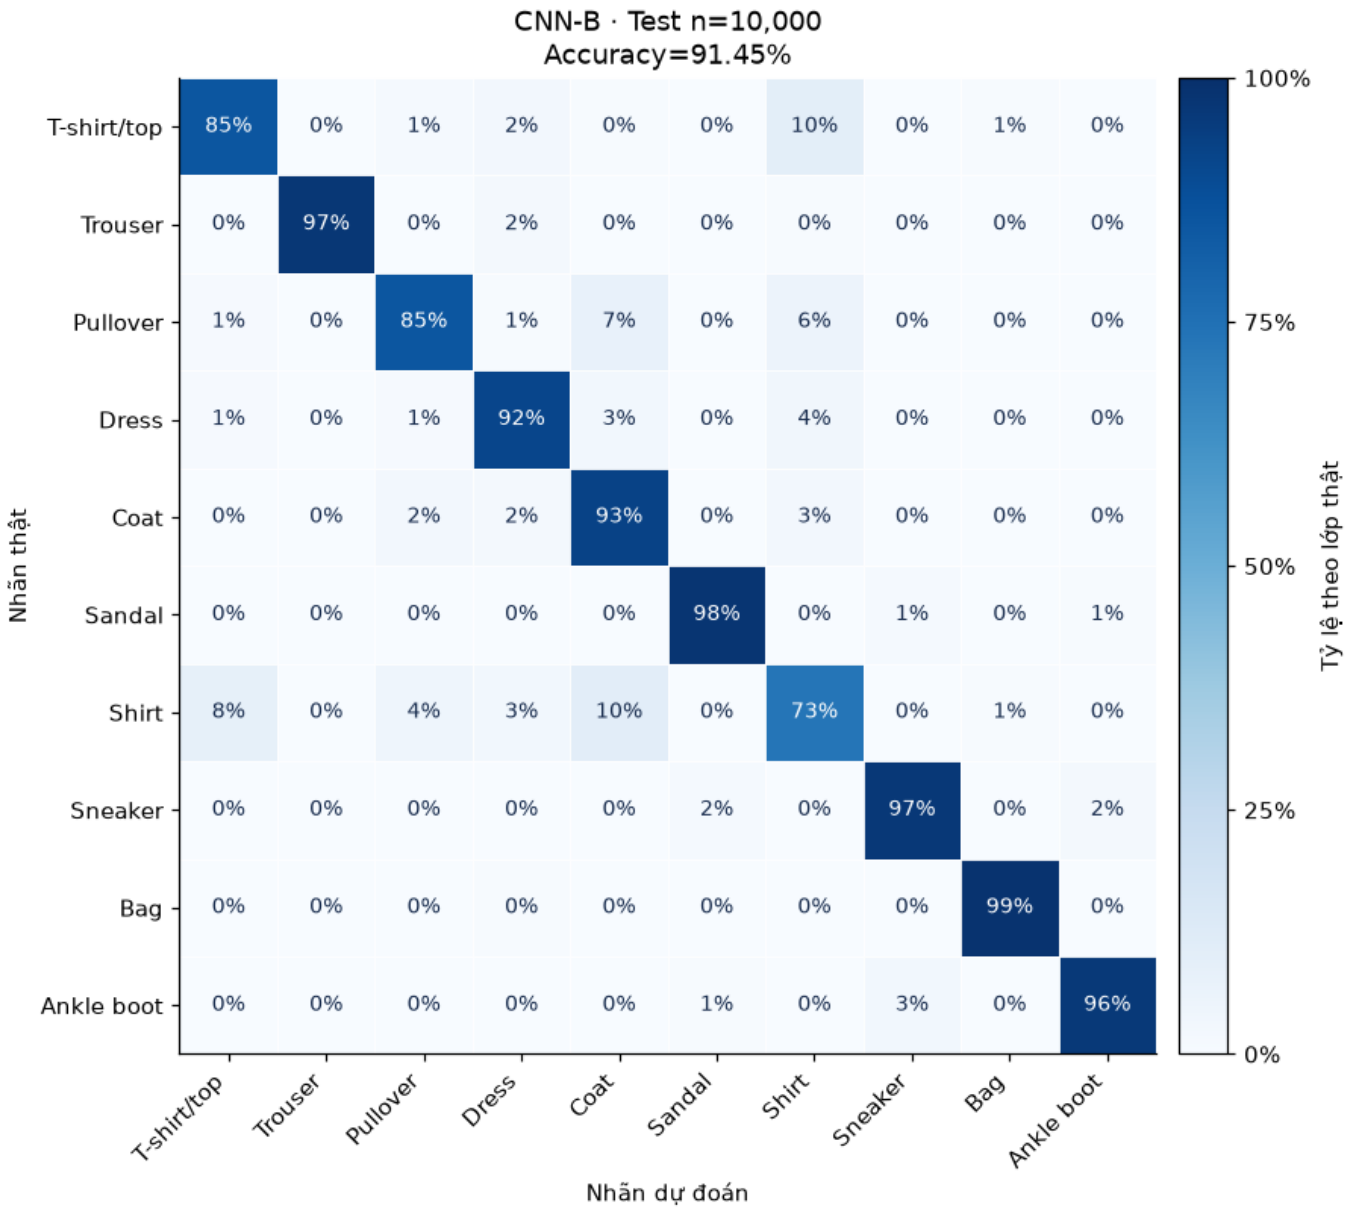

Hình A.31: E3: ma trận test của CNN-B.

A.5 Dữ liệu và chỉ số theo lớp A2

Bảng A.9: Số bbox thường từng lớp VOC2012; difficult không nằm trong các cột này.

Lớp	Train	Validation	Test
aeroplane	692	97	76
bicycle	566	65	80
bird	933	98	88
boat	676	75	99
bottle	1.011	139	109
bus	487	44	62
car	1.624	189	204
cat	970	112	135
chair	1.929	250	175
cow	473	48	67
diningtable	487	74	48
dog	1.213	143	159
horse	554	88	68
motorbike	585	53	75
person	6.802	898	866
pottedplant	804	97	72
sheep	611	119	83
sofa	447	70	49
train	492	59	77
tvmonitor	619	70	95

Bảng A.10: P/R/F1 tại score 0,30; R=RetinaNet, F=Faster R-CNN, Rec là recall.

Lớp	R P	R Rec	R F1	F P	F Rec	F F1
aeroplane	0,5221	0,7763	0,6243	0,5514	0,7763	0,6448
bicycle	0,5963	0,8125	0,6878	0,4124	0,9125	0,5681
bird	0,5310	0,8750	0,6609	0,5000	0,8523	0,6303
boat	0,4460	0,6263	0,5210	0,3842	0,6869	0,4928
bottle	0,4086	0,6972	0,5153	0,3842	0,6697	0,4883
bus	0,4825	0,8871	0,6250	0,3041	0,9516	0,4609
car	0,4985	0,8382	0,6252	0,3203	0,9216	0,4753
cat	0,6513	0,9407	0,7697	0,4980	0,9407	0,6513
chair	0,3644	0,5143	0,4265	0,2569	0,6400	0,3666
cow	0,3841	0,7910	0,5171	0,4786	0,8358	0,6087
diningtable	0,2703	0,4167	0,3279	0,4189	0,6458	0,5082
dog	0,5316	0,8994	0,6682	0,5331	0,9119	0,6729
horse	0,4444	0,8824	0,5911	0,5510	0,7941	0,6506
motorbike	0,5000	0,8267	0,6231	0,3750	0,8400	0,5185
person	0,5517	0,8383	0,6654	0,4074	0,9018	0,5613
pottedplant	0,3333	0,4167	0,3704	0,1774	0,4583	0,2558
sheep	0,4362	0,7831	0,5603	0,5246	0,7711	0,6244
sofa	0,4730	0,7143	0,5691	0,1900	0,8571	0,3111
train	0,5345	0,8052	0,6425	0,5865	0,7922	0,6740
tvmonitor	0,6476	0,7158	0,6800	0,3333	0,8842	0,4841

Bảng A.11: AP50/AP75 COCO-style và AP11 VOC07 từng lớp; metric ở thang 0–1.

Lớp	R AP50	F AP50	R AP75	F AP75	R AP11	F AP11
aeroplane	0,7733	0,7727	0,4642	0,5304	0,7494	0,7504
bicycle	0,8154	0,8482	0,4475	0,5418	0,7823	0,8094
bird	0,8317	0,7715	0,4608	0,4788	0,7927	0,7428
boat	0,5551	0,6044	0,1775	0,1392	0,5445	0,6001
bottle	0,6310	0,6243	0,2458	0,2861	0,6123	0,6194
bus	0,8670	0,8964	0,6035	0,6571	0,8309	0,8615
car	0,8150	0,8362	0,5320	0,5418	0,7912	0,8067
cat	0,9134	0,9061	0,5668	0,5394	0,8686	0,8655
chair	0,4557	0,4906	0,1515	0,2008	0,4602	0,4883
cow	0,6811	0,7724	0,2501	0,3833	0,6740	0,7576
diningtable	0,3203	0,5424	0,1113	0,2228	0,3417	0,5436
dog	0,8499	0,8671	0,5499	0,6080	0,8140	0,8414
horse	0,8262	0,8003	0,4770	0,5385	0,7878	0,7794
motorbike	0,8201	0,8136	0,4664	0,4178	0,8091	0,7942
person	0,8230	0,8412	0,3261	0,4221	0,7961	0,8143
pottedplant	0,3096	0,3035	0,0770	0,0736	0,3225	0,3094
sheep	0,7199	0,7613	0,4787	0,5093	0,6937	0,7513
sofa	0,5902	0,5727	0,2758	0,3385	0,5762	0,5784
train	0,8093	0,8104	0,5118	0,4701	0,7894	0,7680
tvmonitor	0,7463	0,7803	0,3613	0,4796	0,7350	0,7636

A.6 Ma trận chẩn đoán A2

Hàng là ground truth, cột là prediction. Hàng background biểu diễn false positives, cột background biểu diễn false negatives. Ô ghi tỷ lệ theo hàng làm tròn số nguyên; tổng một hàng có thể khác 100%. Matching class-agnostic dùng IoU $\geq 0,5$, confidence $\geq 0,30$; các chỉ số class-wise được tính riêng.

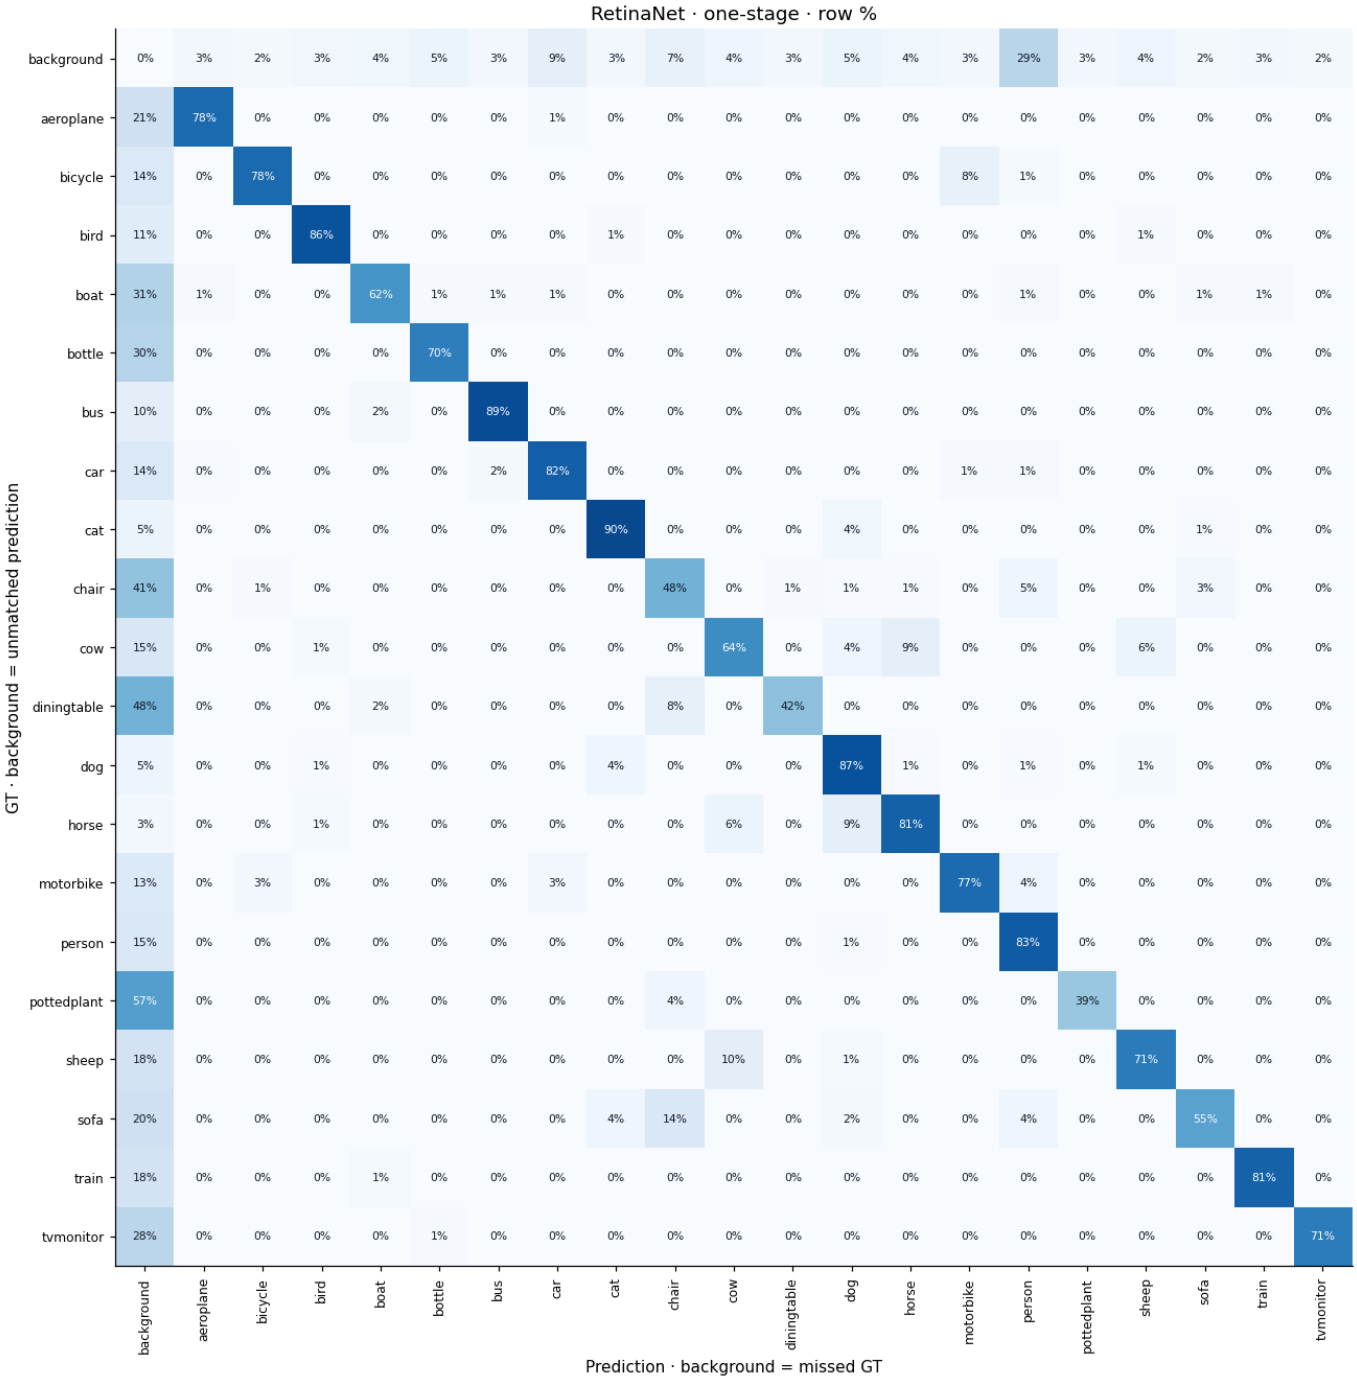

Hình A.32: A2 RetinaNet: ma trận chẩn đoán chuẩn hóa theo hàng.

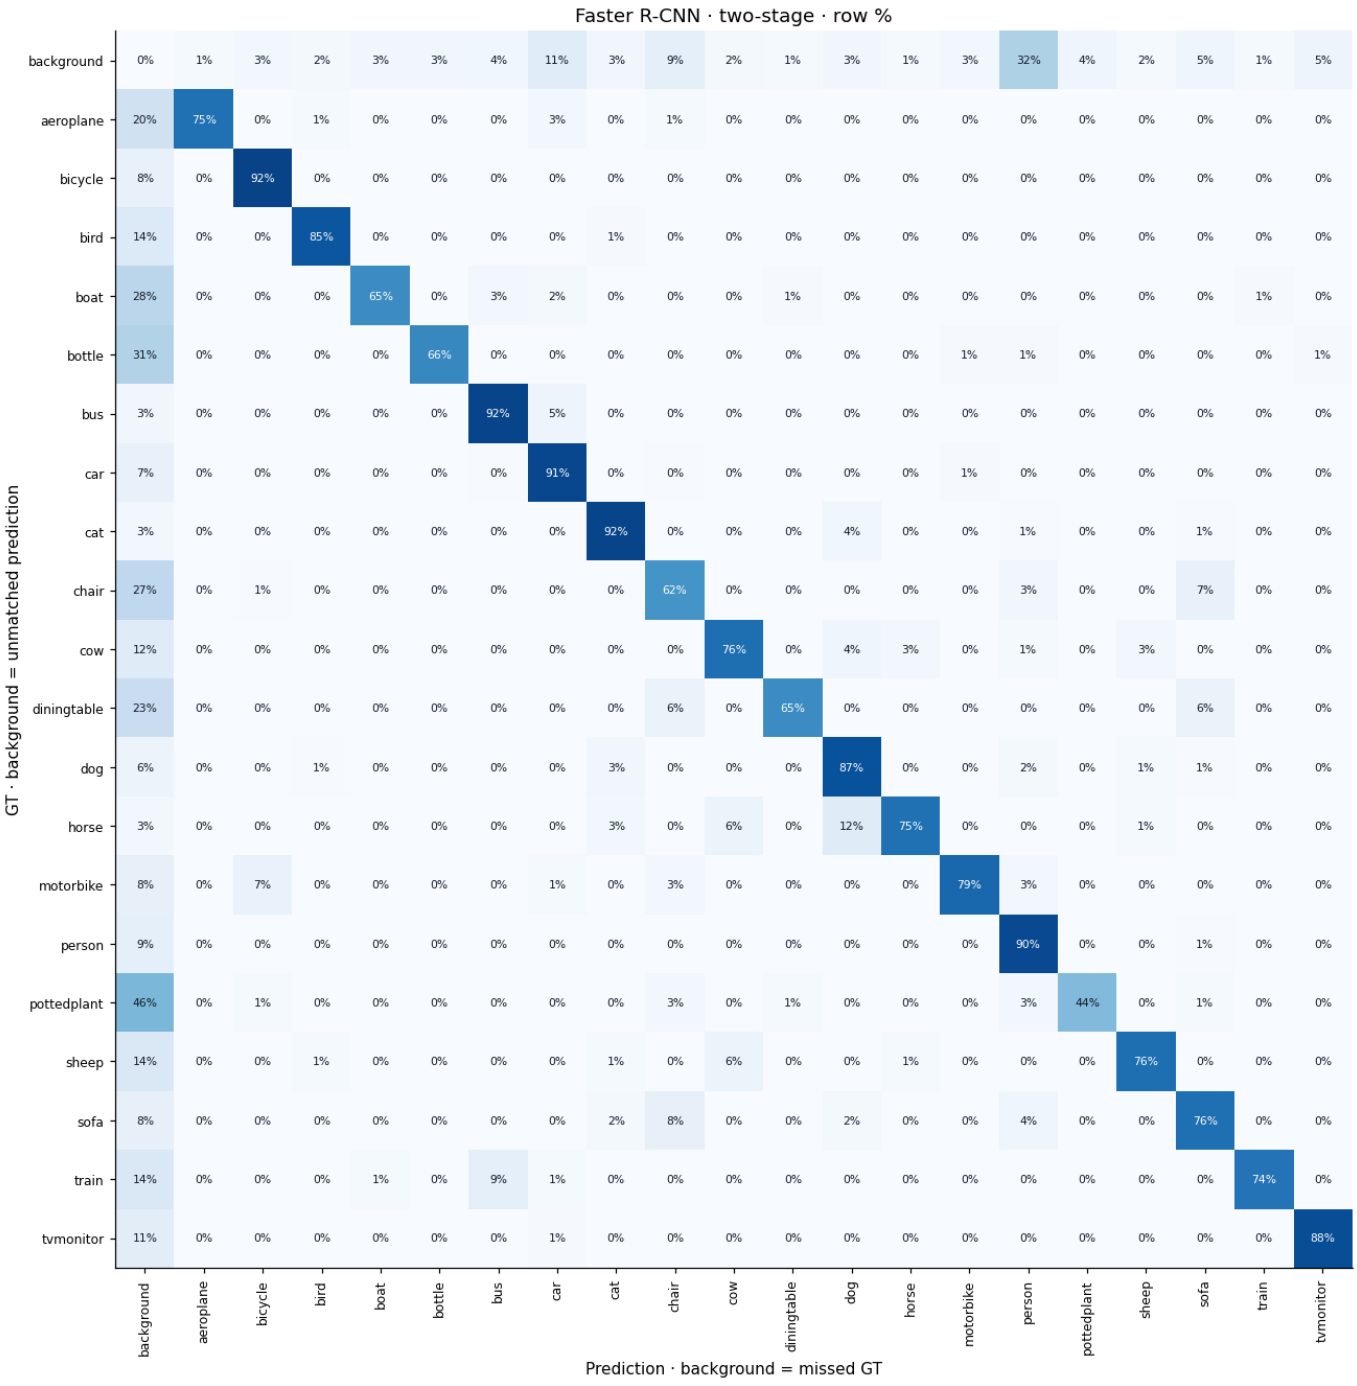

Hình A.33: A2 Faster R-CNN: ma trận chẩn đoán chuẩn hóa theo hàng.

A.7 Precision–recall theo lớp A2

Mỗi hình dùng cùng lớp và tập test cho hai model. AP trong legend là VOC AP50 all-point; đường cong cho thấy cả đánh đổi theo confidence, không chỉ điểm đo P/R/F1 ở score 0,30.

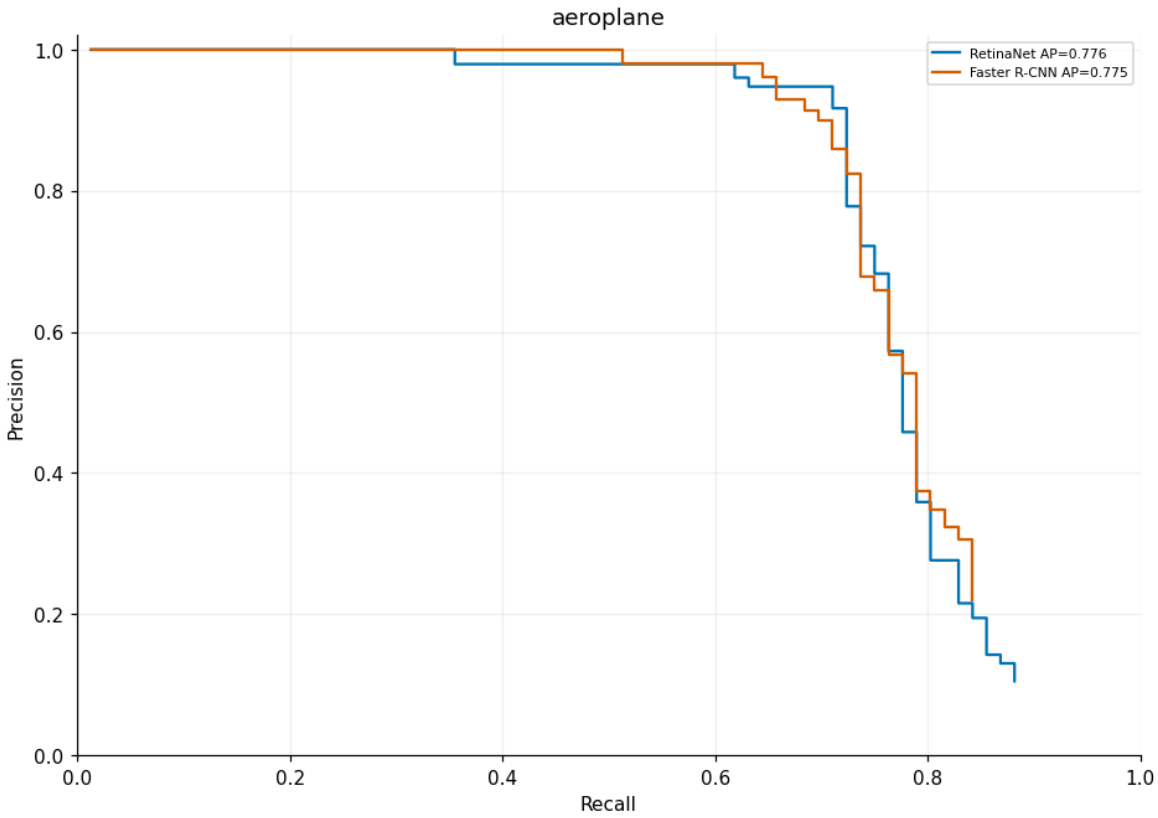

Hình A.34: A2: precision–recall của lớp aeroplane.

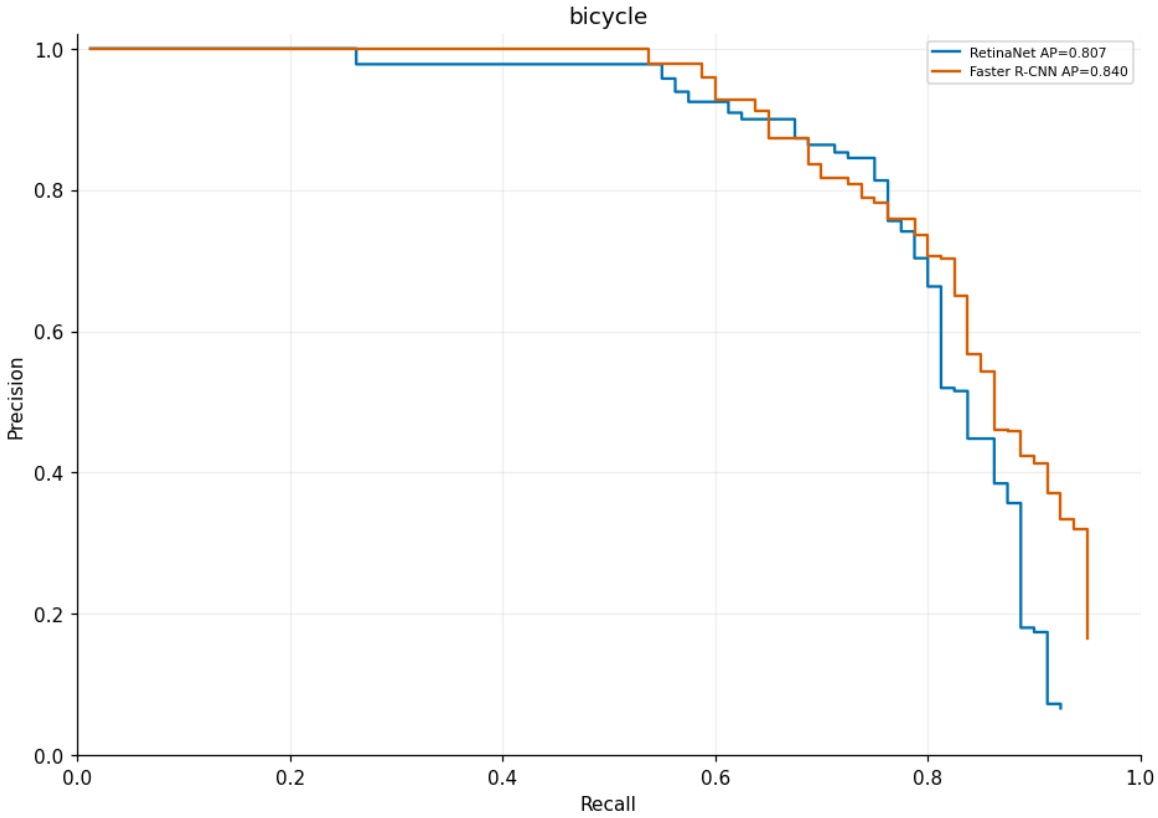

Hình A.35: A2: precision–recall của lớp bicycle.

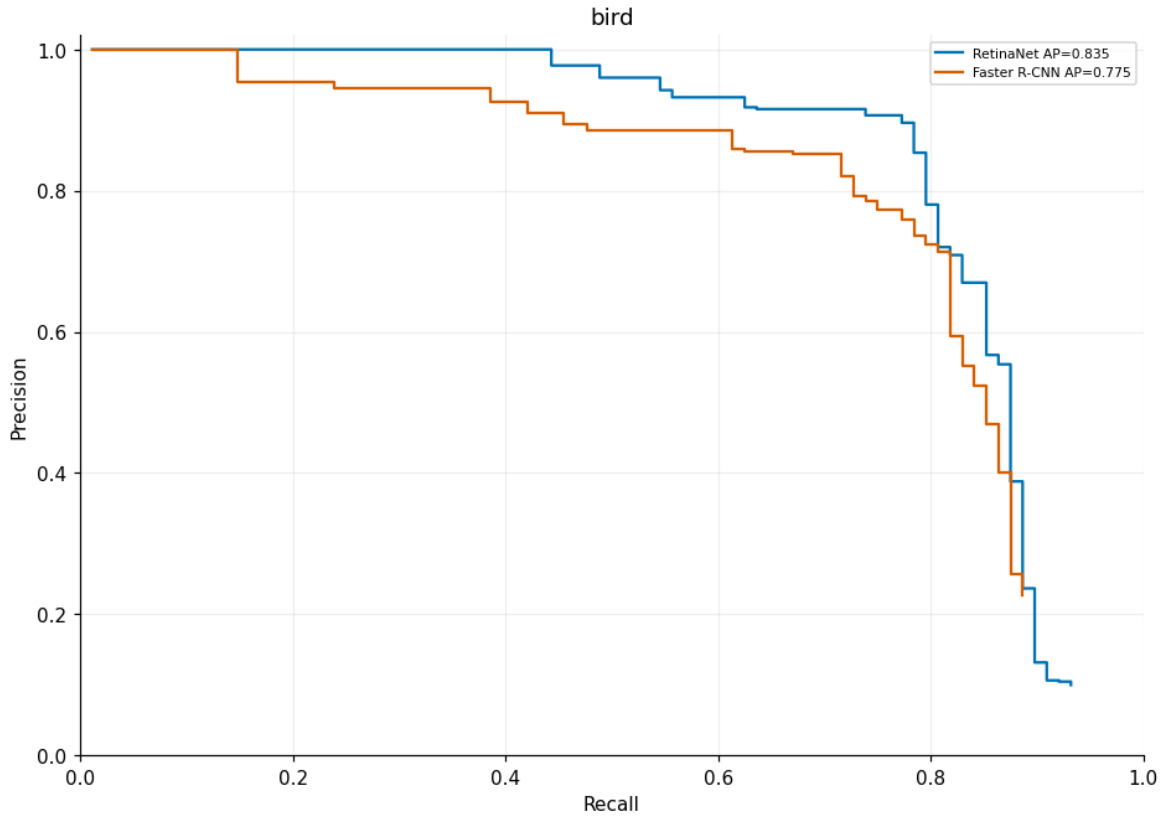

Hình A.36: A2: precision–recall của lớp bird.

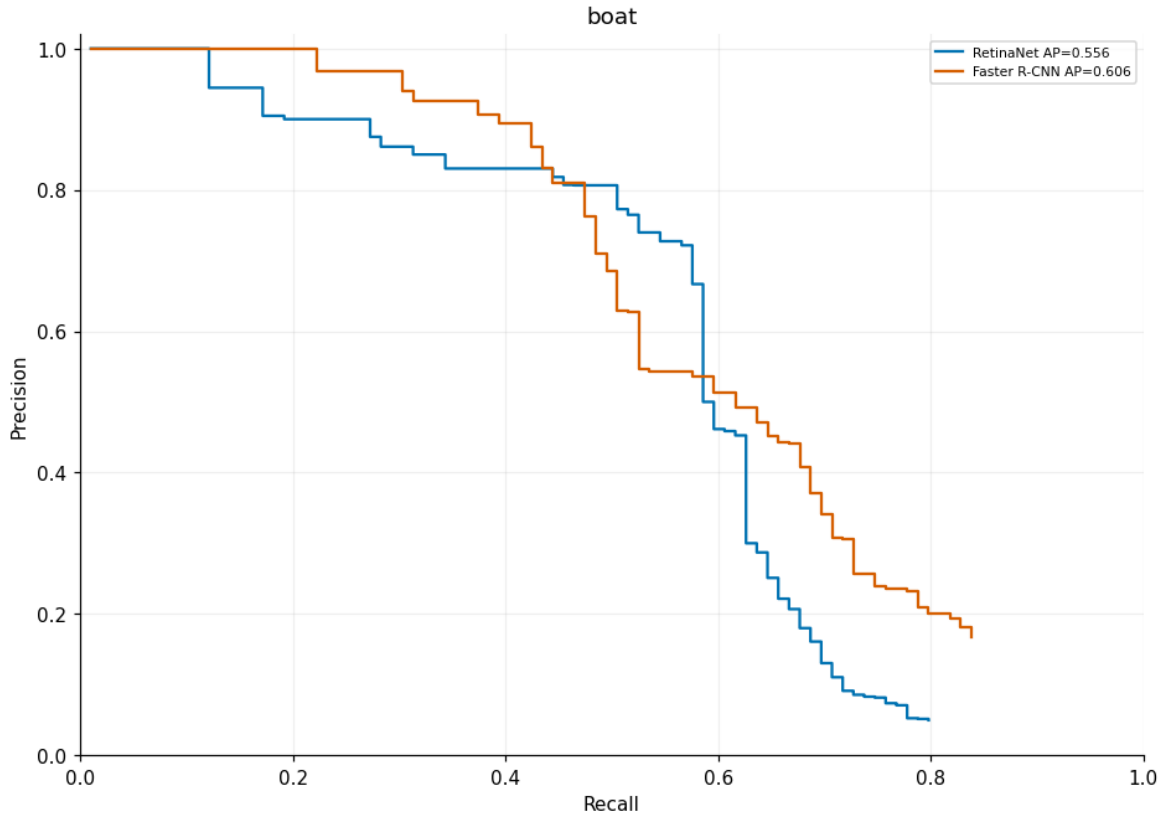

Hình A.37: A2: precision–recall của lớp boat.

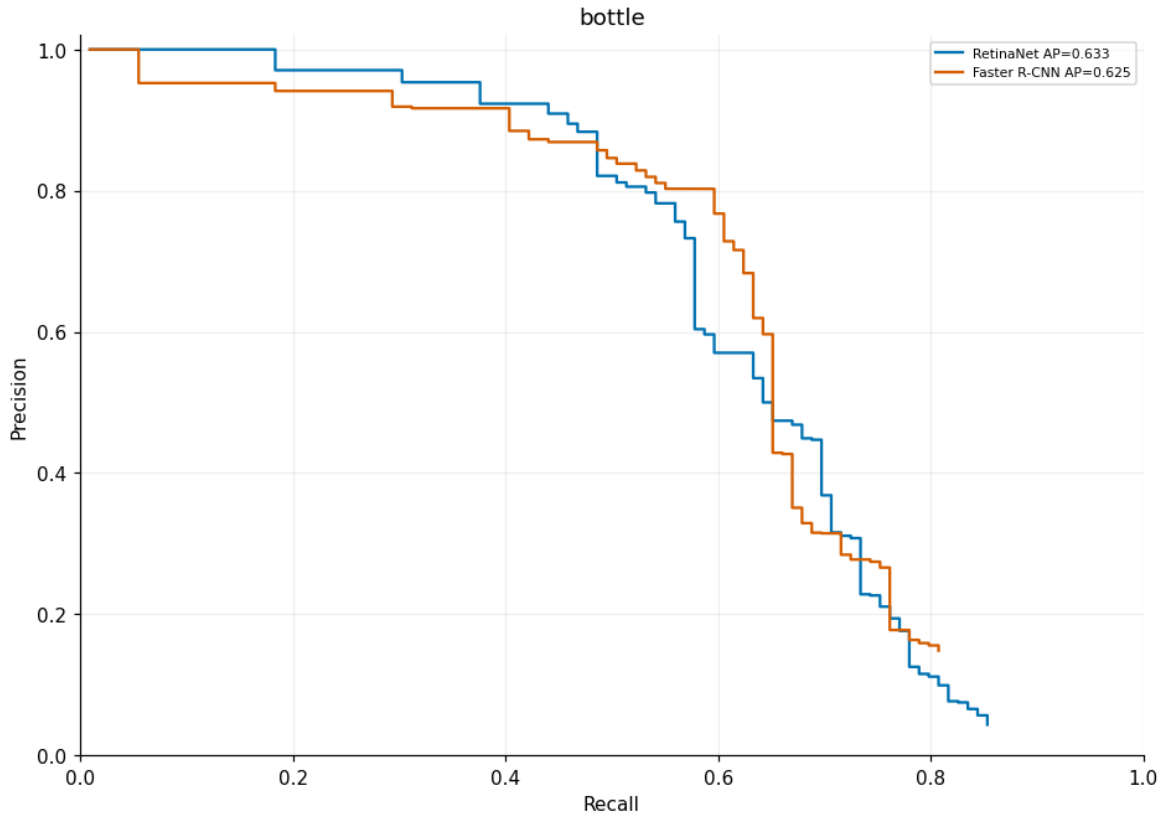

Hình A.38: A2: precision–recall của lớp bottle.

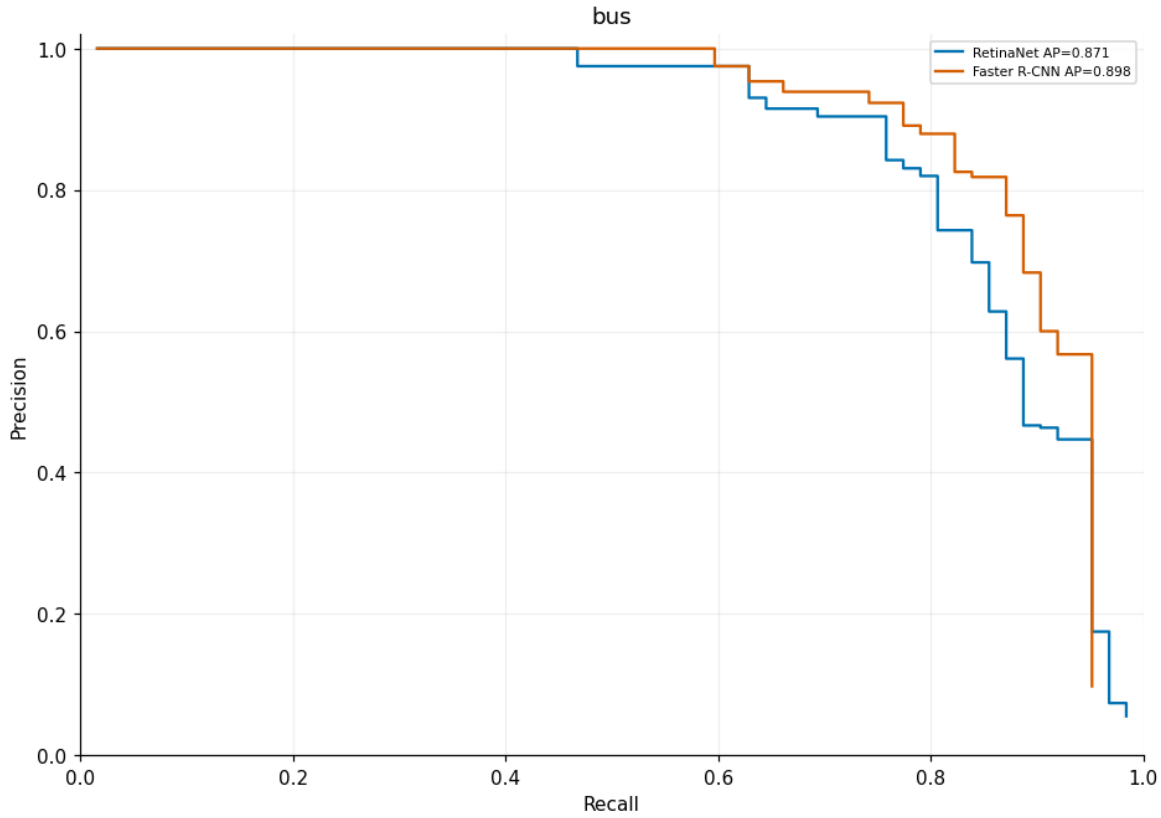

Hình A.39: A2: precision–recall của lớp bus.

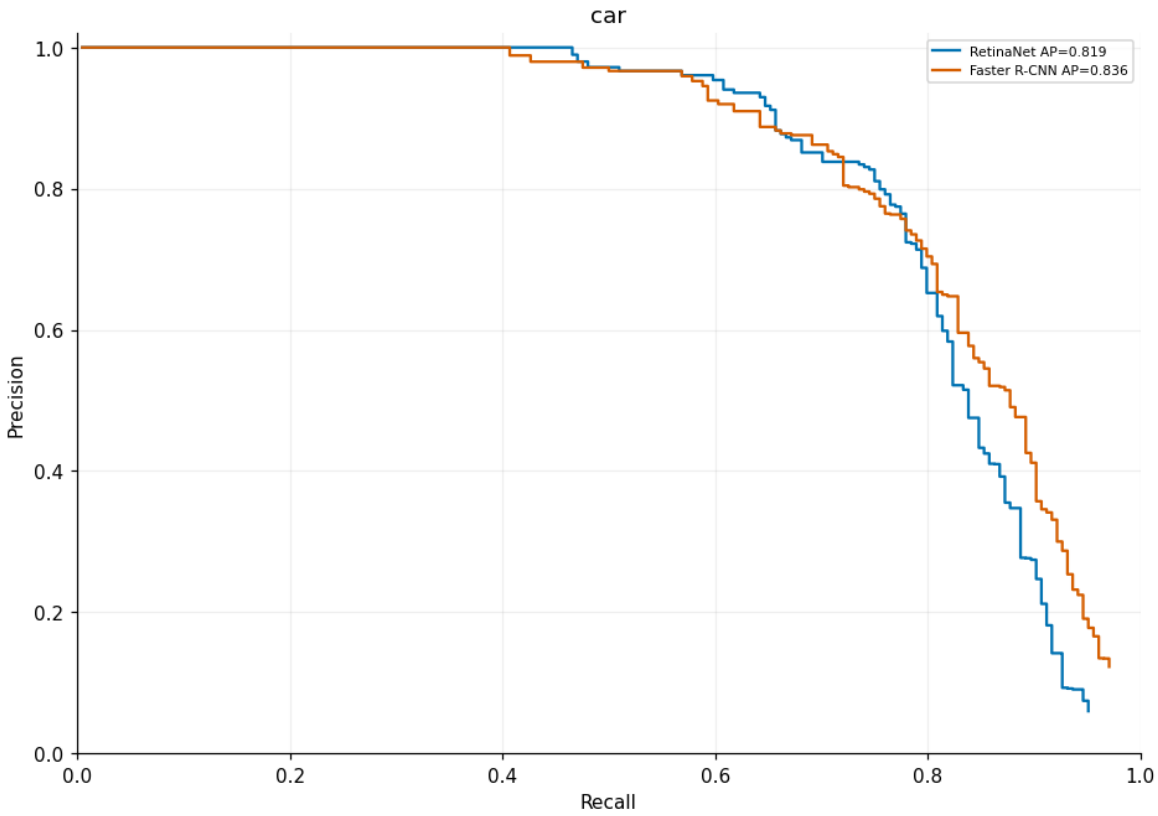

Hình A.40: A2: precision–recall của lớp car.

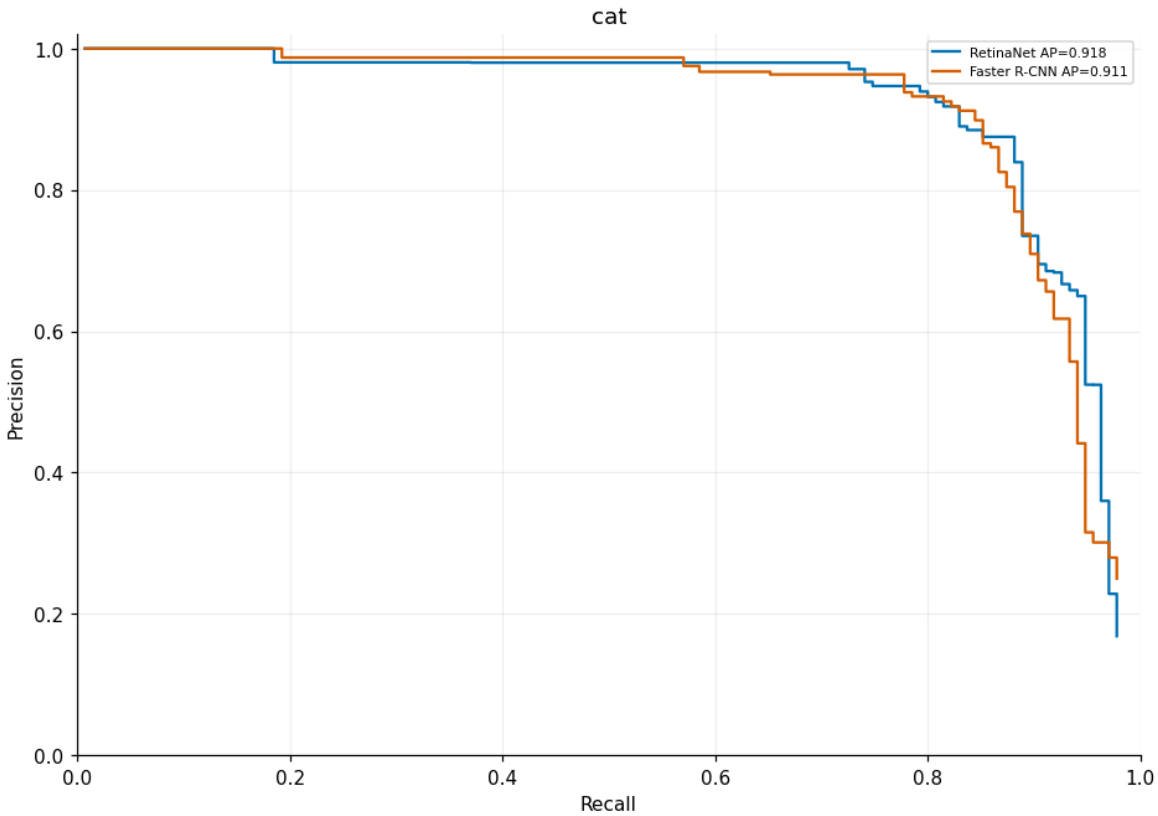

Hình A.41: A2: precision–recall của lớp cat.

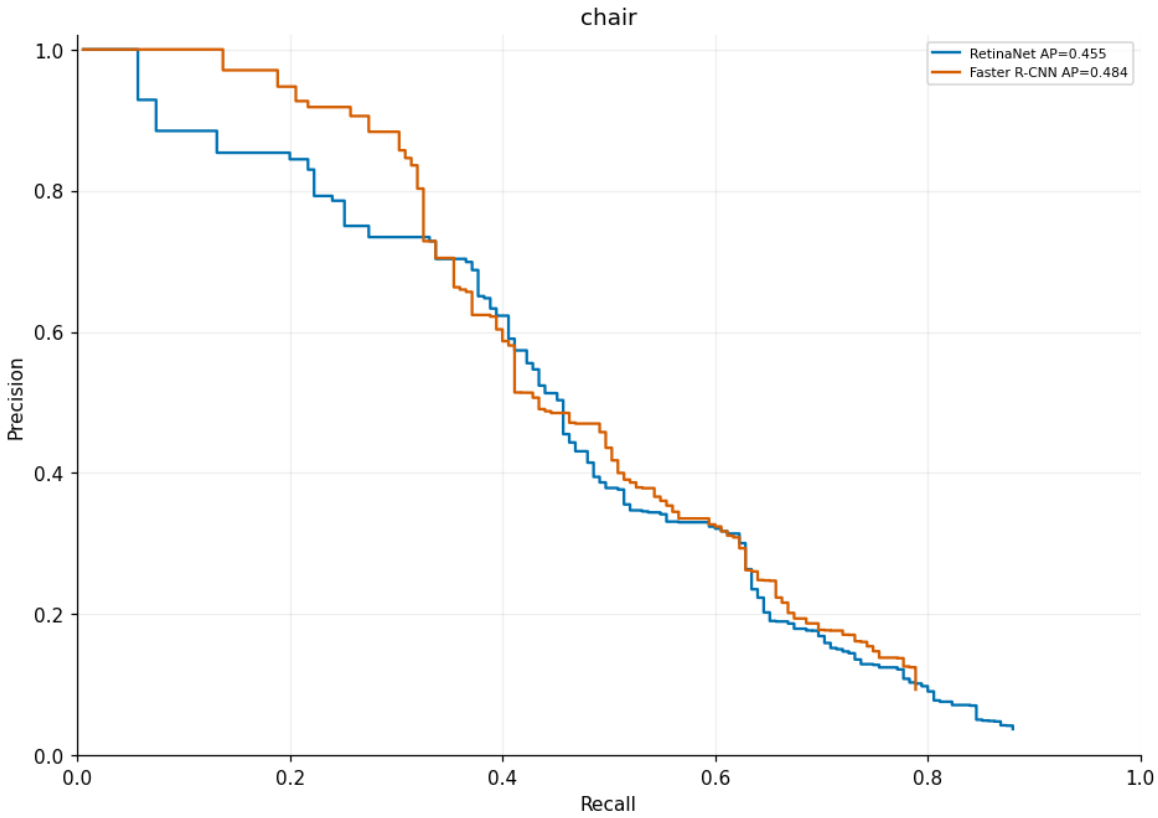

Hình A.42: A2: precision–recall của lớp chair.

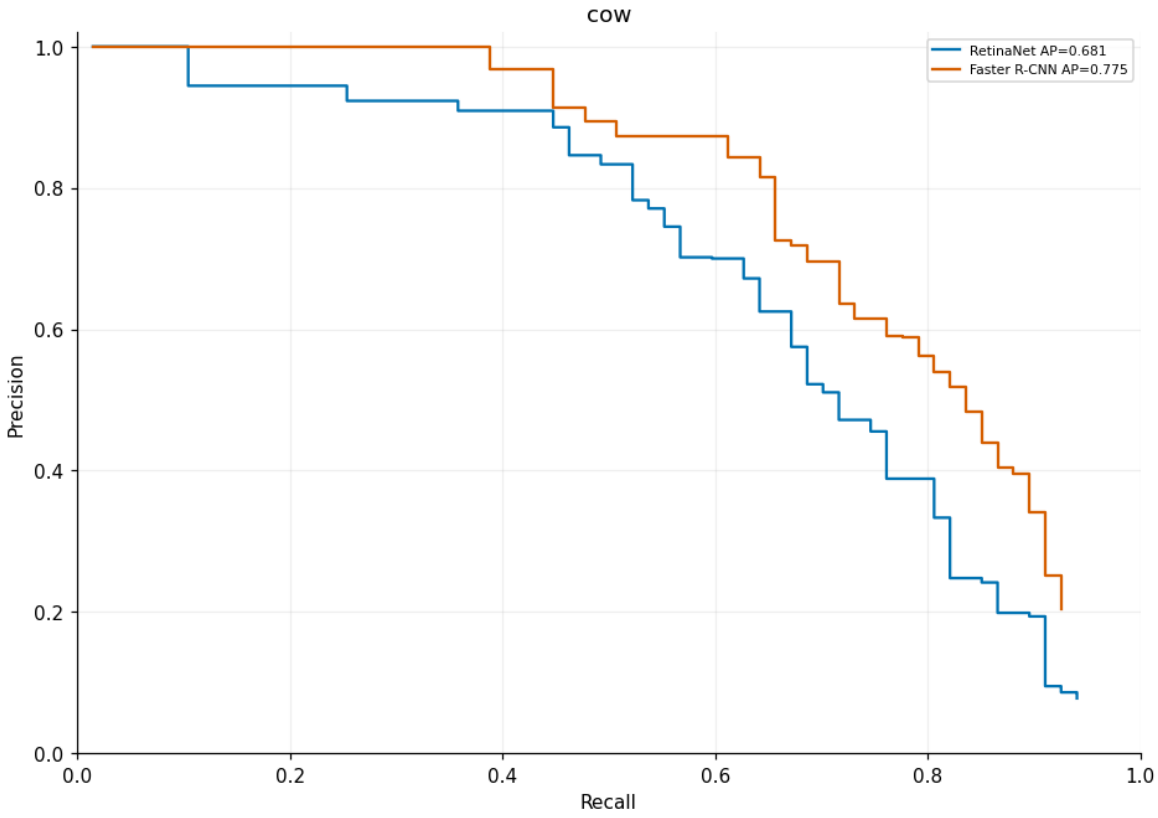

Hình A.43: A2: precision–recall của lớp cow.

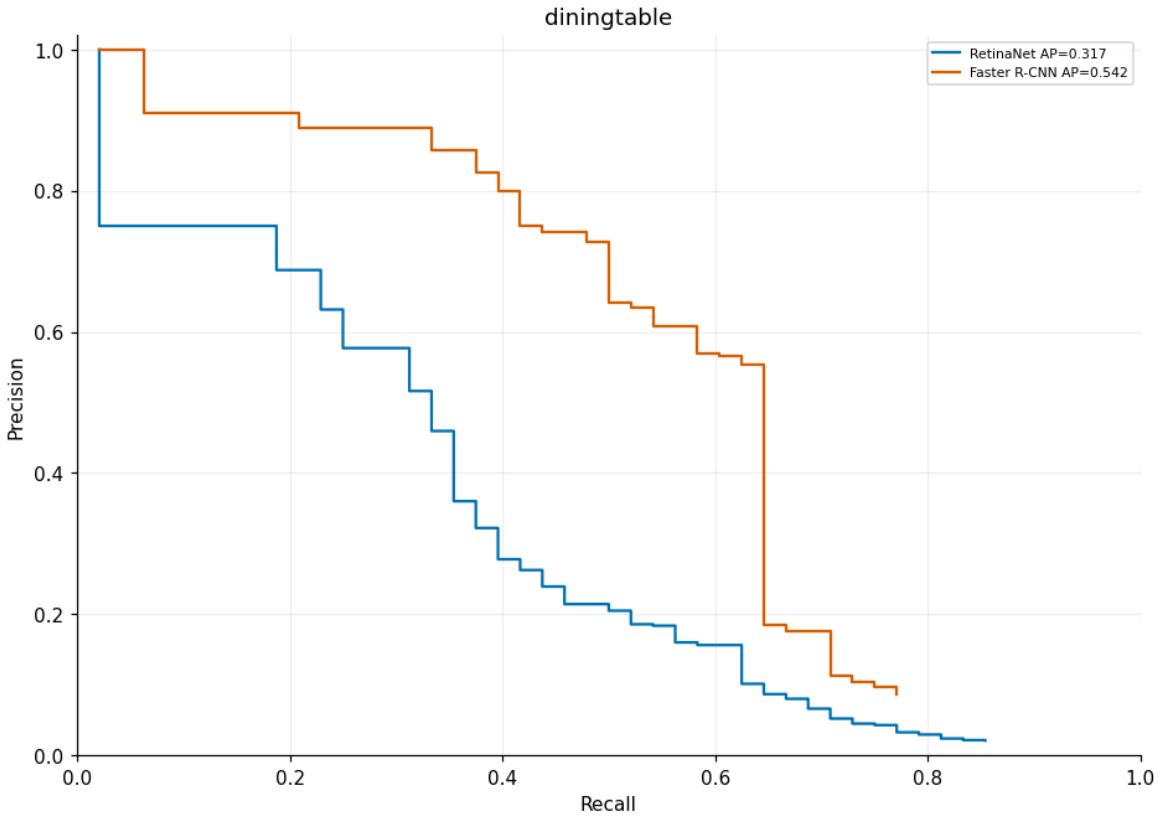

Hình A.44: A2: precision–recall của lớp diningtable.

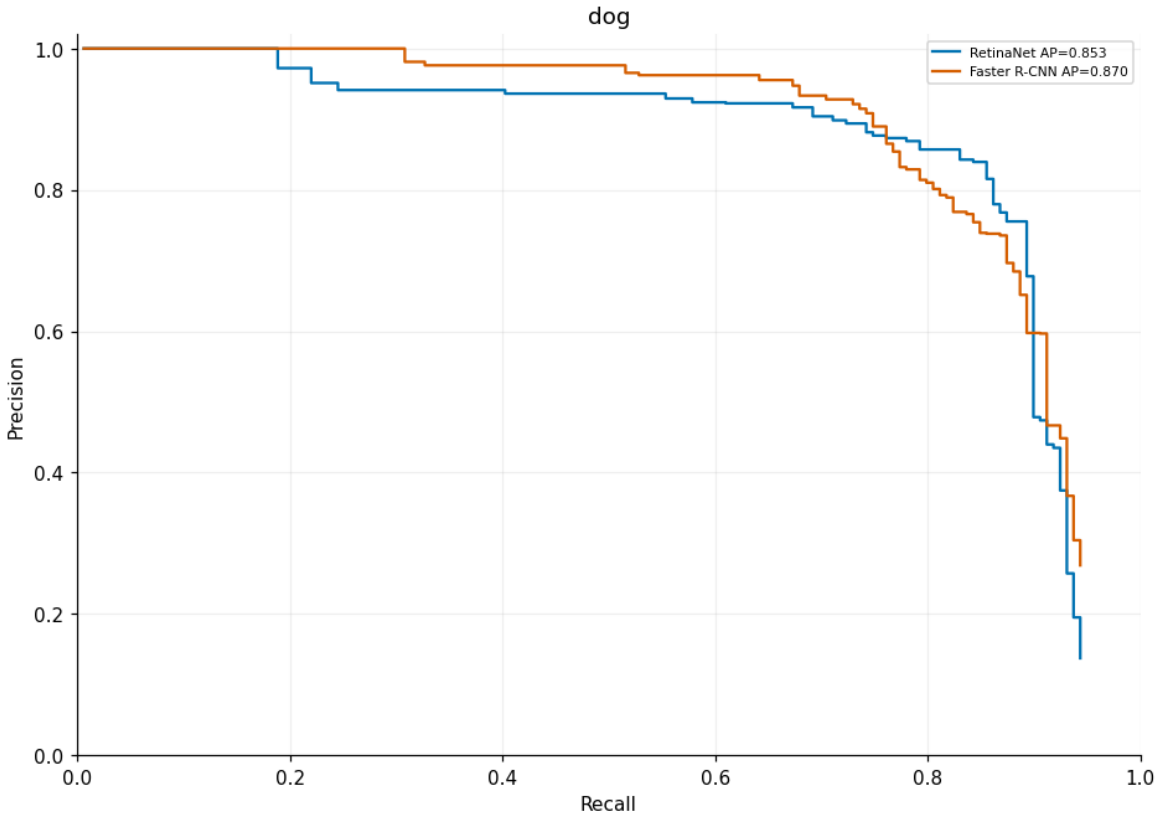

Hình A.45: A2: precision–recall của lớp dog.

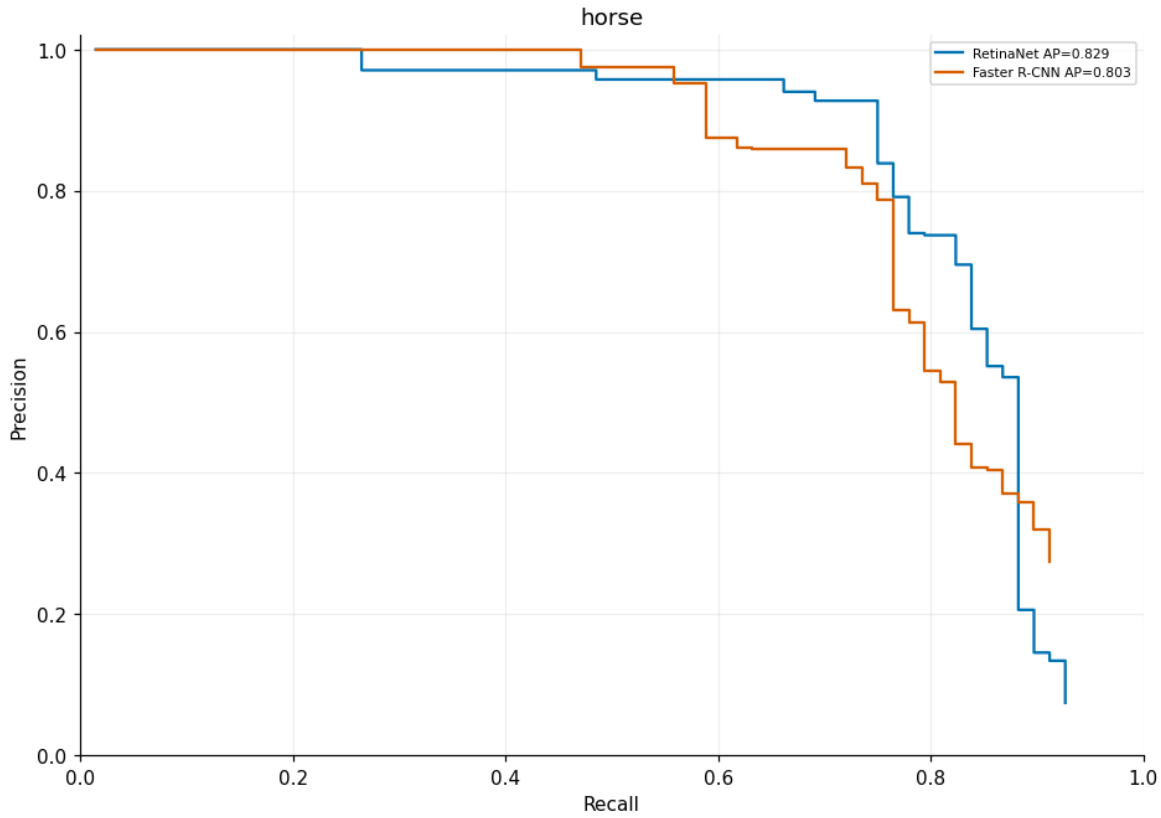

Hình A.46: A2: precision–recall của lớp horse.

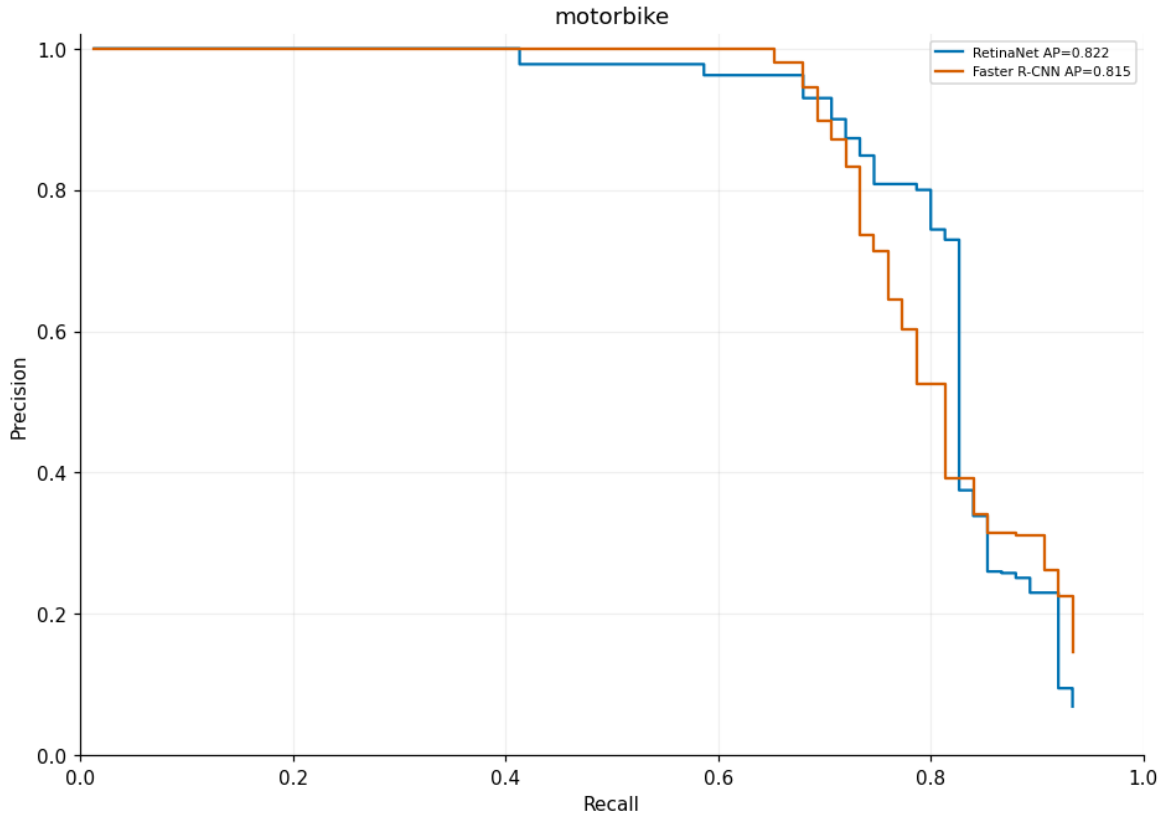

Hình A.47: A2: precision–recall của lớp motorbike.

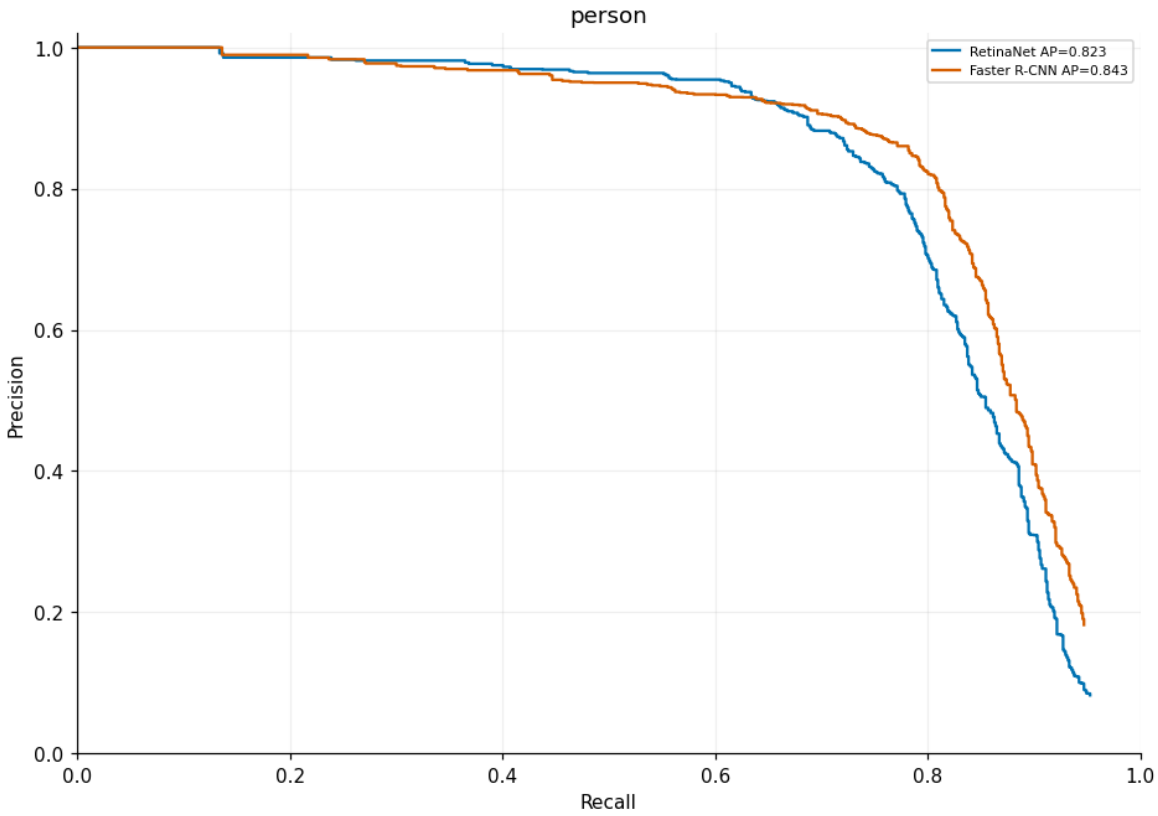

Hình A.48: A2: precision–recall của lớp person.

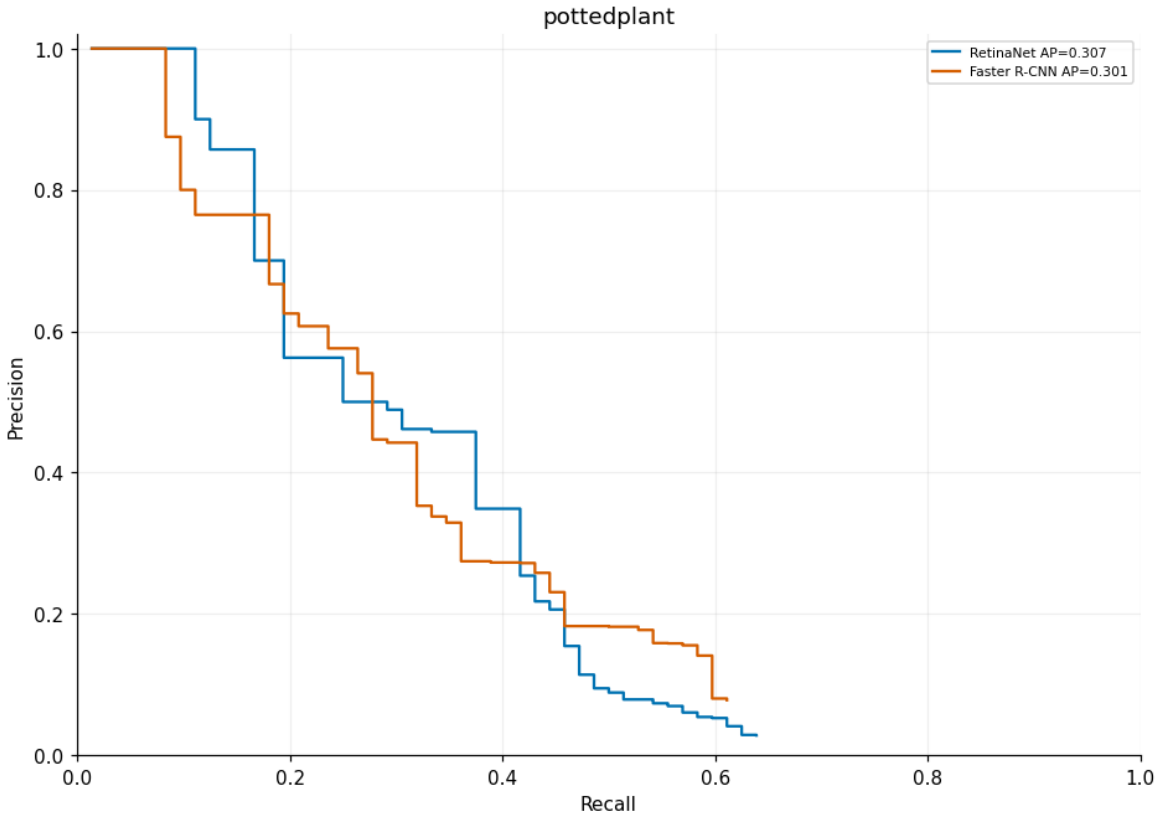

Hình A.49: A2: precision–recall của lớp pottedplant.

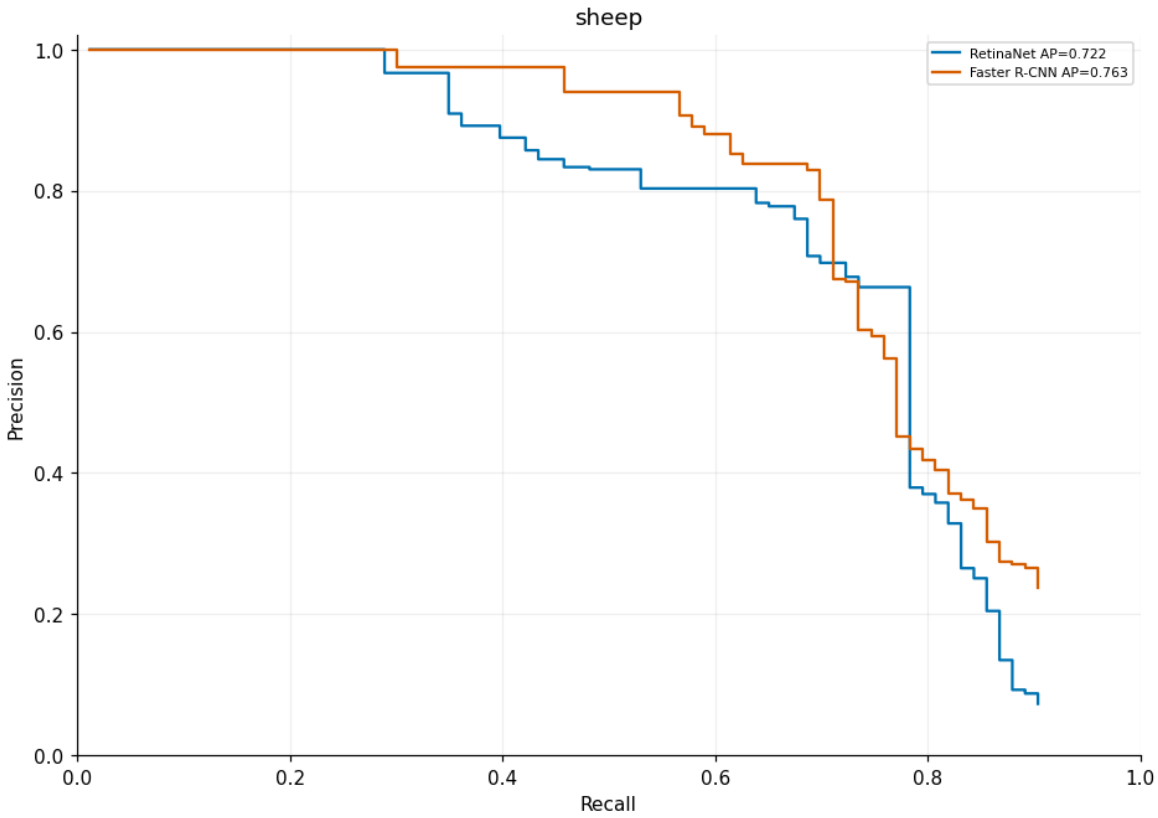

Hình A.50: A2: precision–recall của lớp sheep.

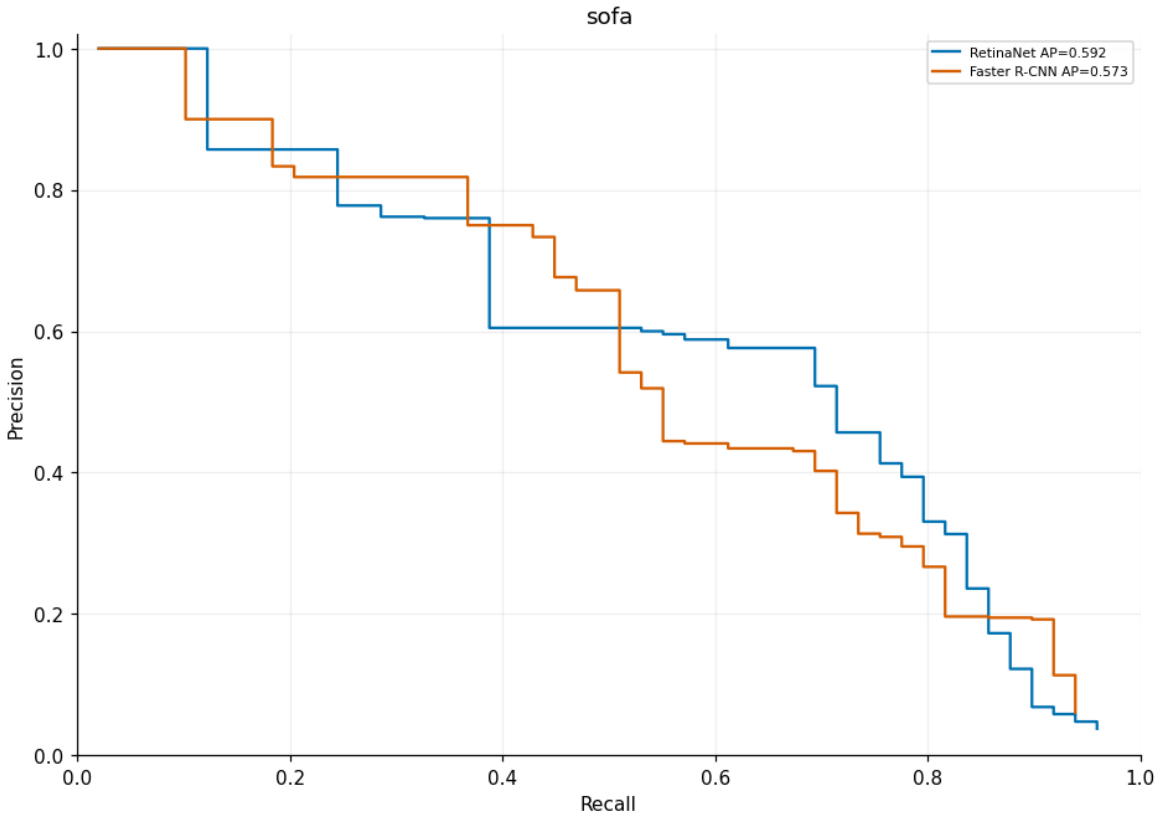

Hình A.51: A2: precision–recall của lớp sofa.

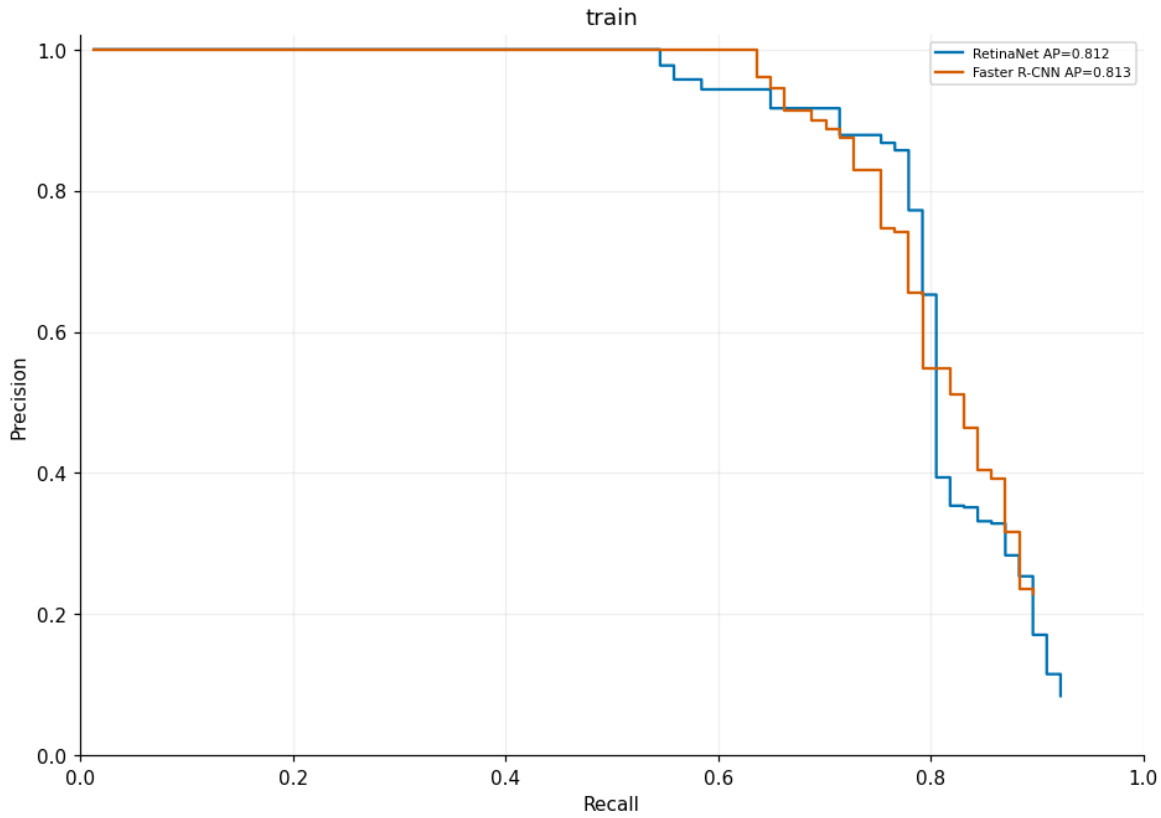

Hình A.52: A2: precision–recall của lớp train.

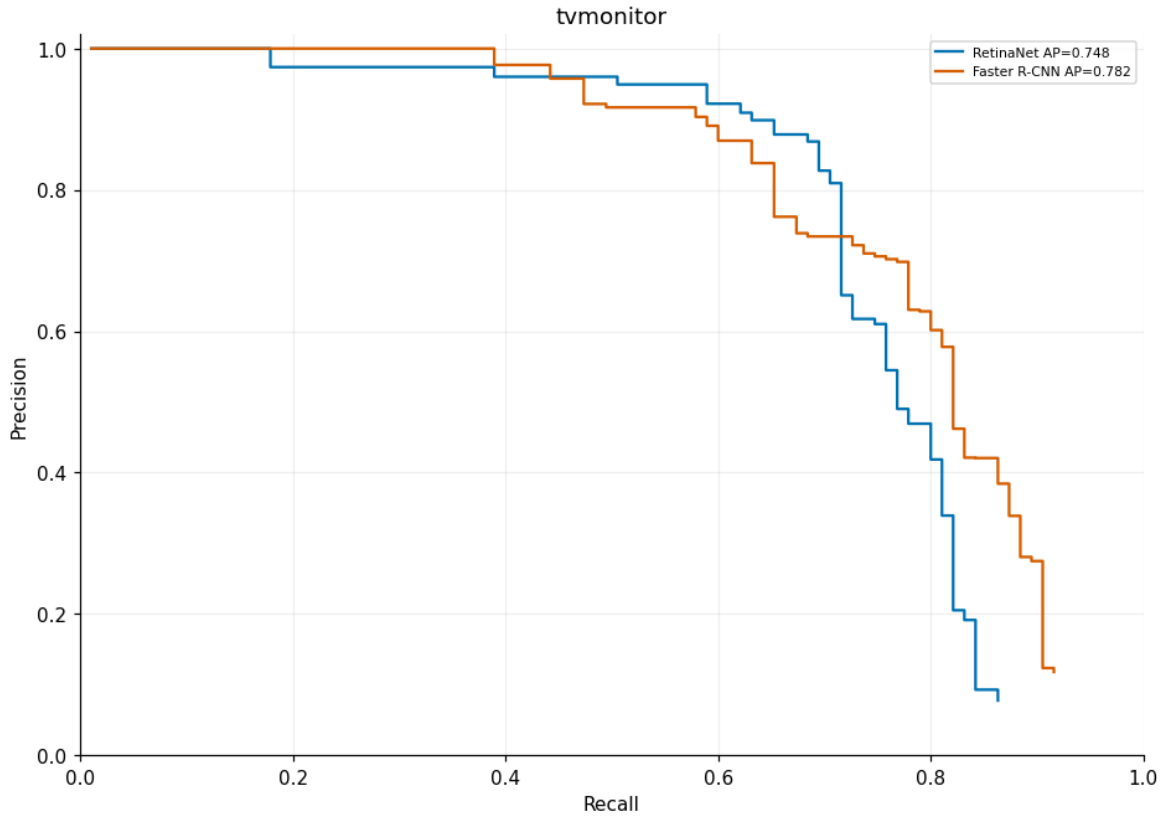

Hình A.53: A2: precision–recall của lớp tvmonitor.

A.8 Ảnh test và dự đoán A2

Cùng một ảnh được trình bày theo GT, RetinaNet và Faster R-CNN. GT difficult dùng nét đứt; predictions chỉ vẽ score từ 0,30, tối đa 15 boxes. Các ảnh được giữ độc lập từ output notebook để đọc rõ nhãn và bbox.

Hình A.54: Ảnh test 2012_2008_000016: ground truth.

Hình A.55: Ảnh test 2012_2008_000016: RetinaNet.

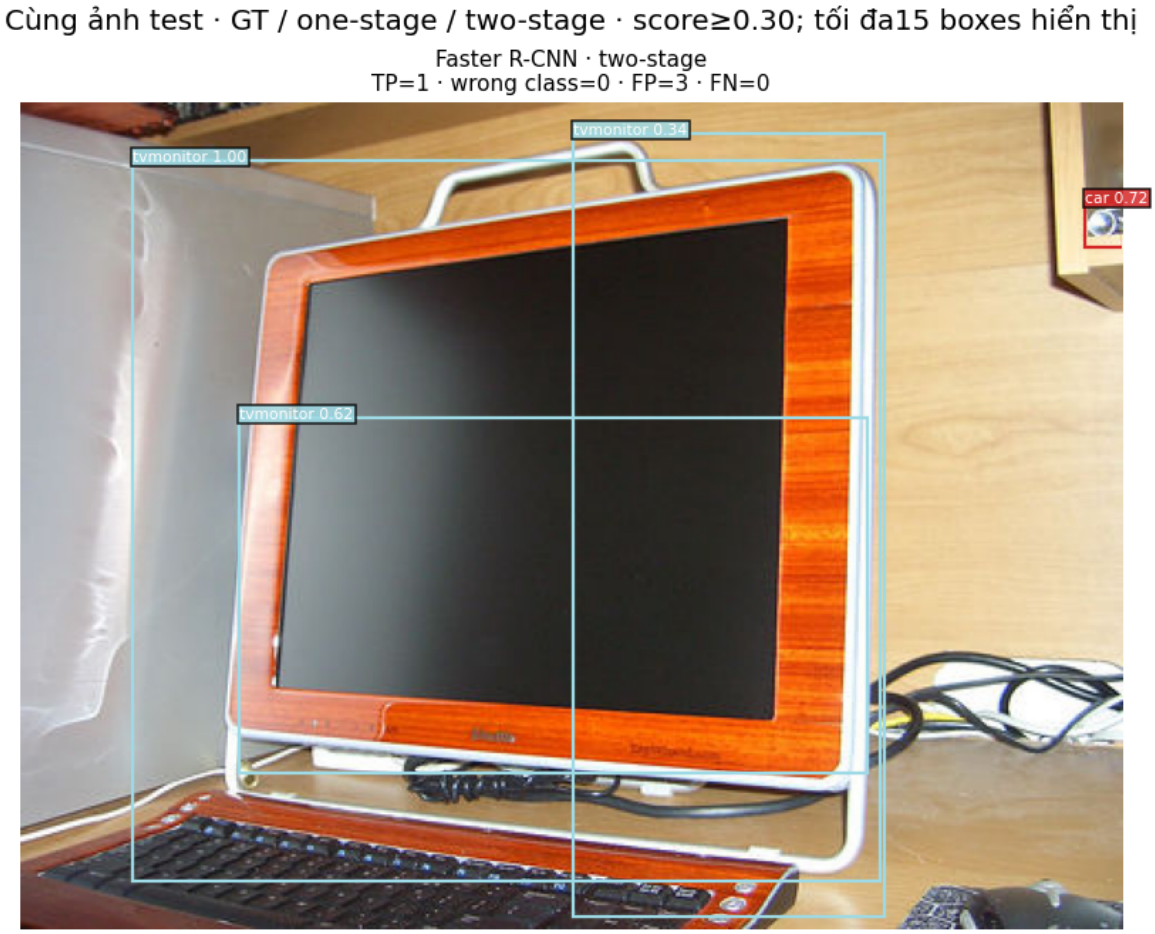

Hình A.56: Ảnh test 2012_2008_000016: Faster R-CNN.

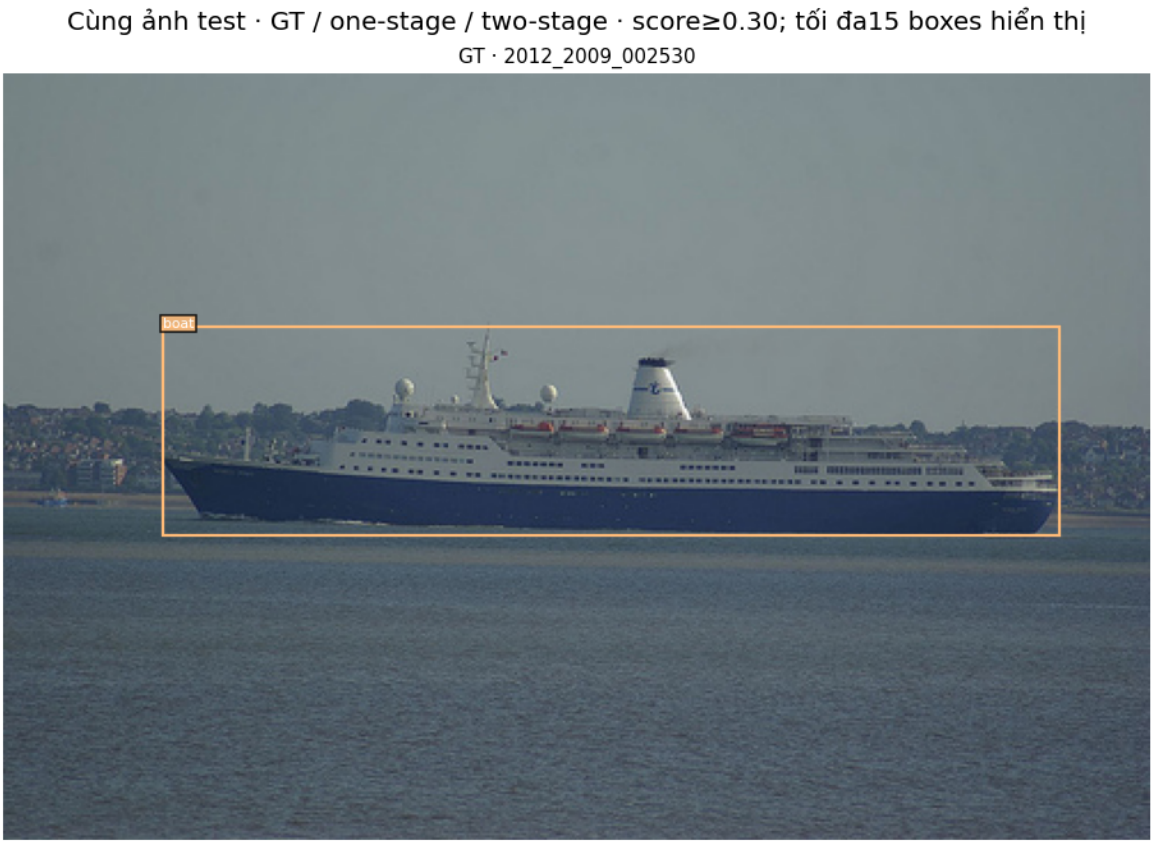

Hình A.57: Ảnh test 2012_2009_002530: ground truth.

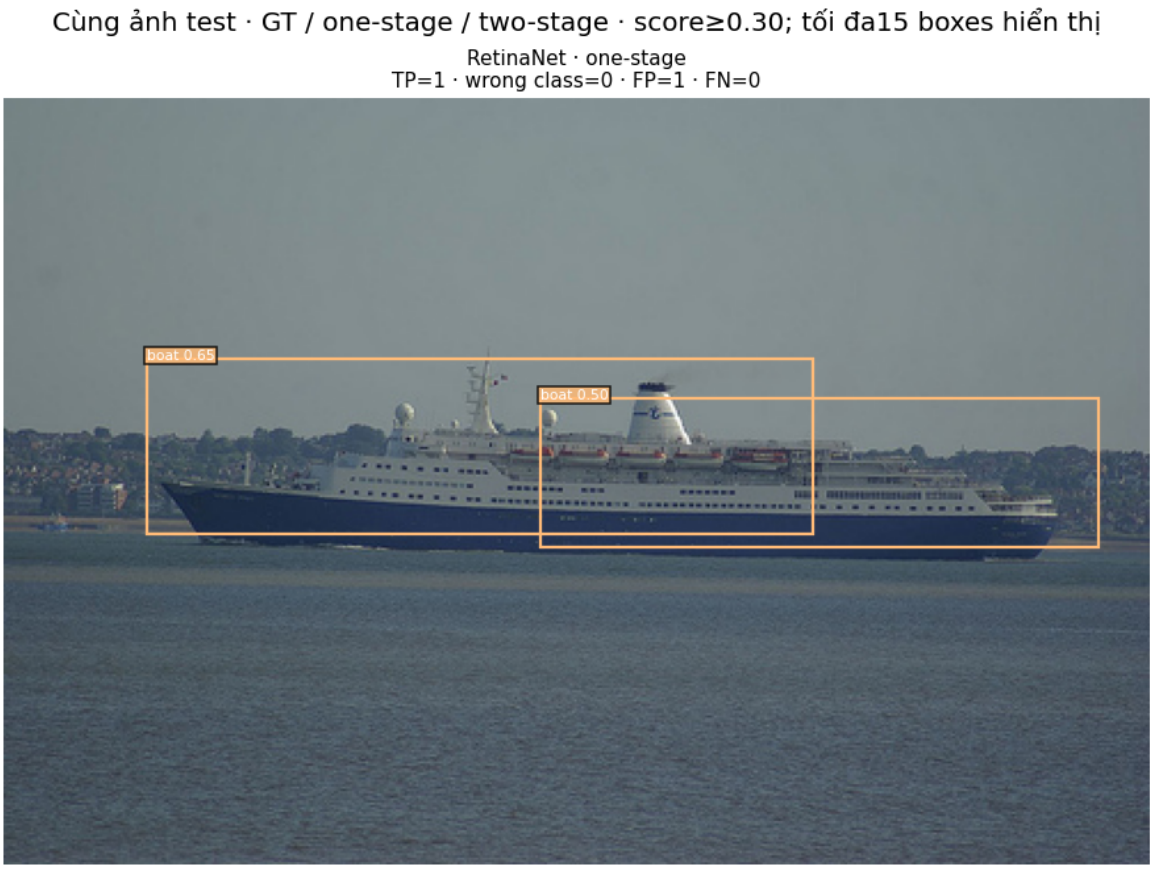

Hình A.58: Ảnh test 2012_2009_002530: RetinaNet.

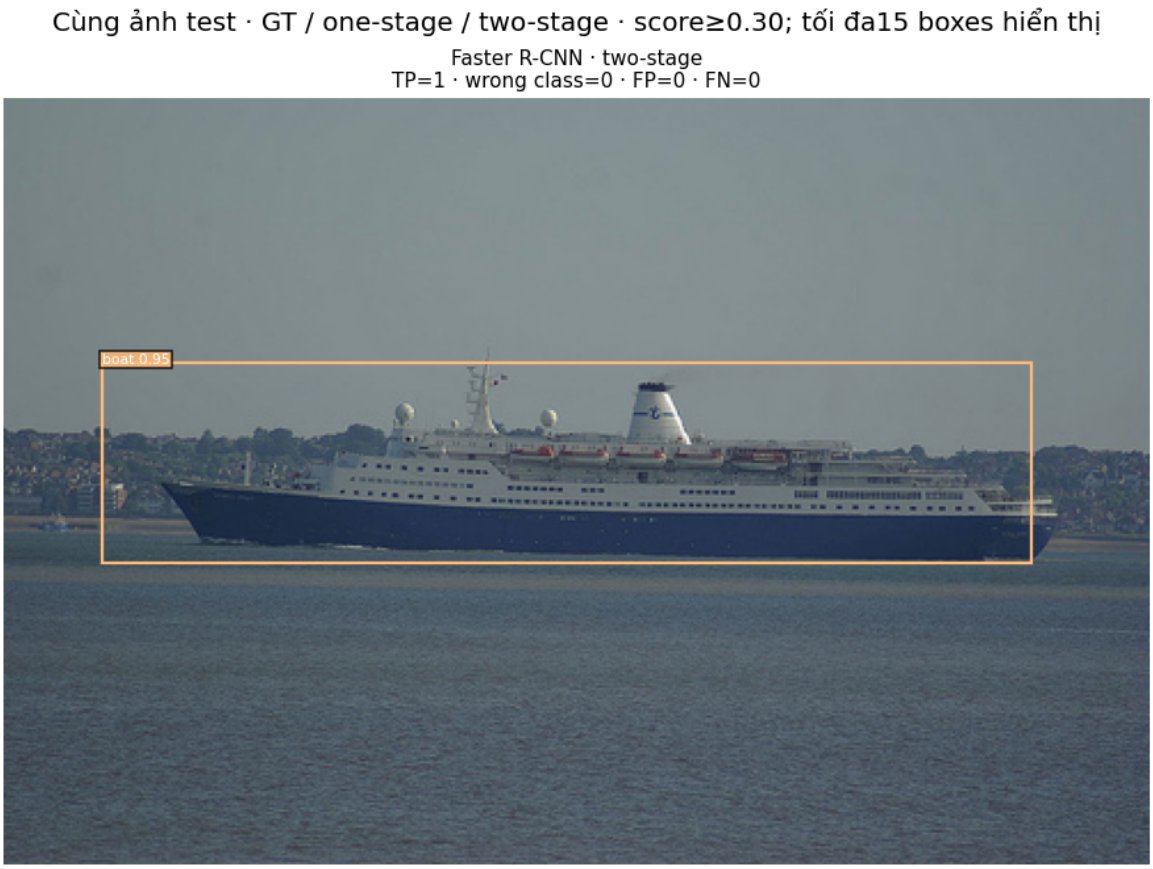

Hình A.59: Ảnh test 2012_2009_002530: Faster R-CNN.

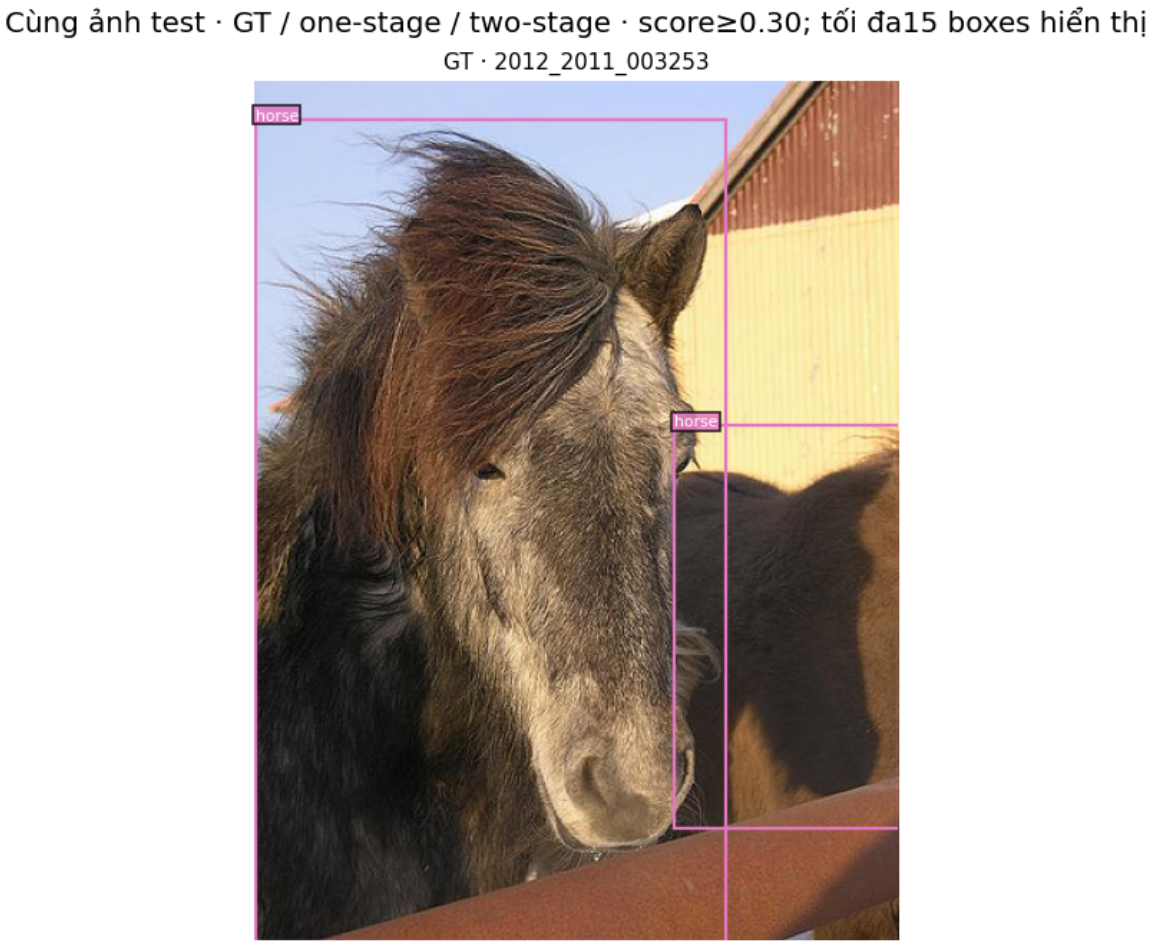

Hình A.60: Ảnh test 2012_2011_003253: ground truth.

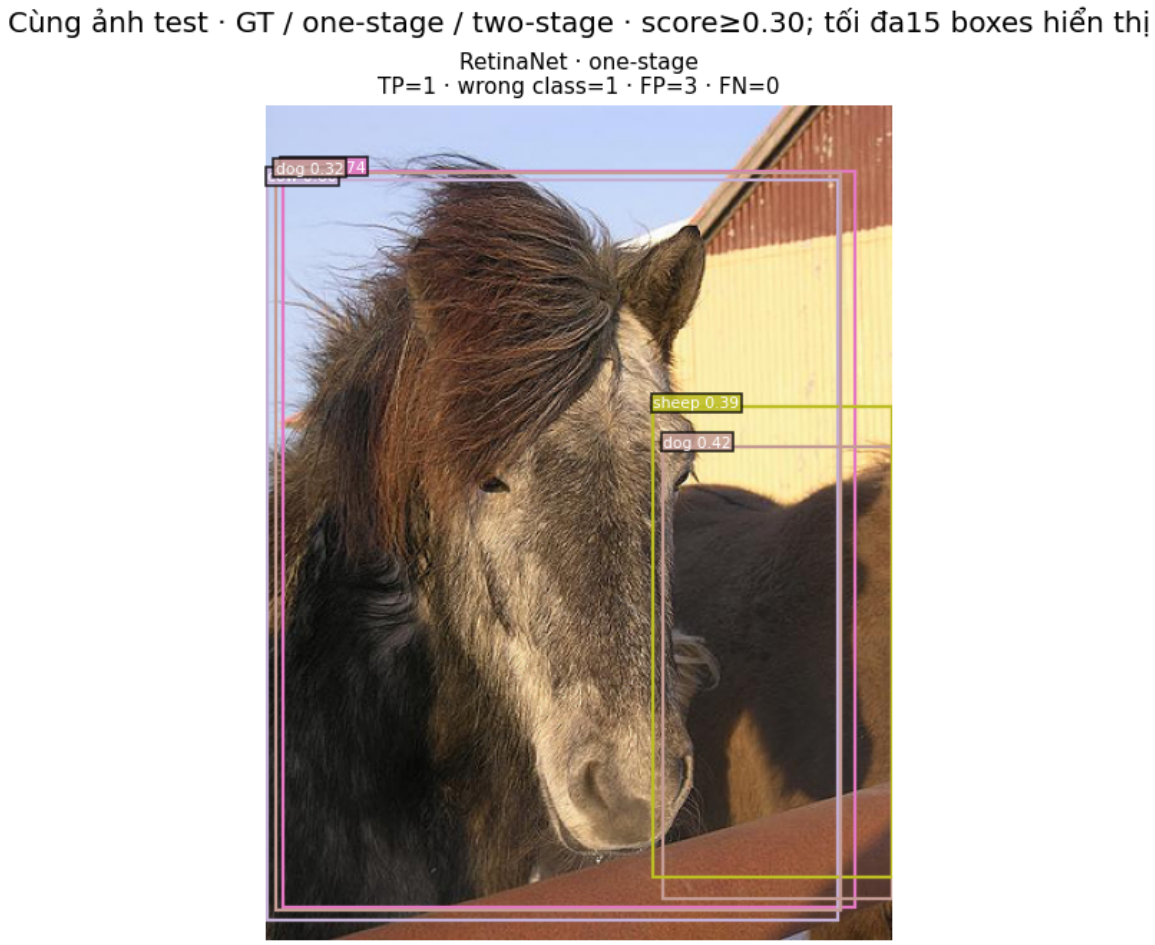

Hình A.61: Ảnh test 2012_2011_003253: RetinaNet.

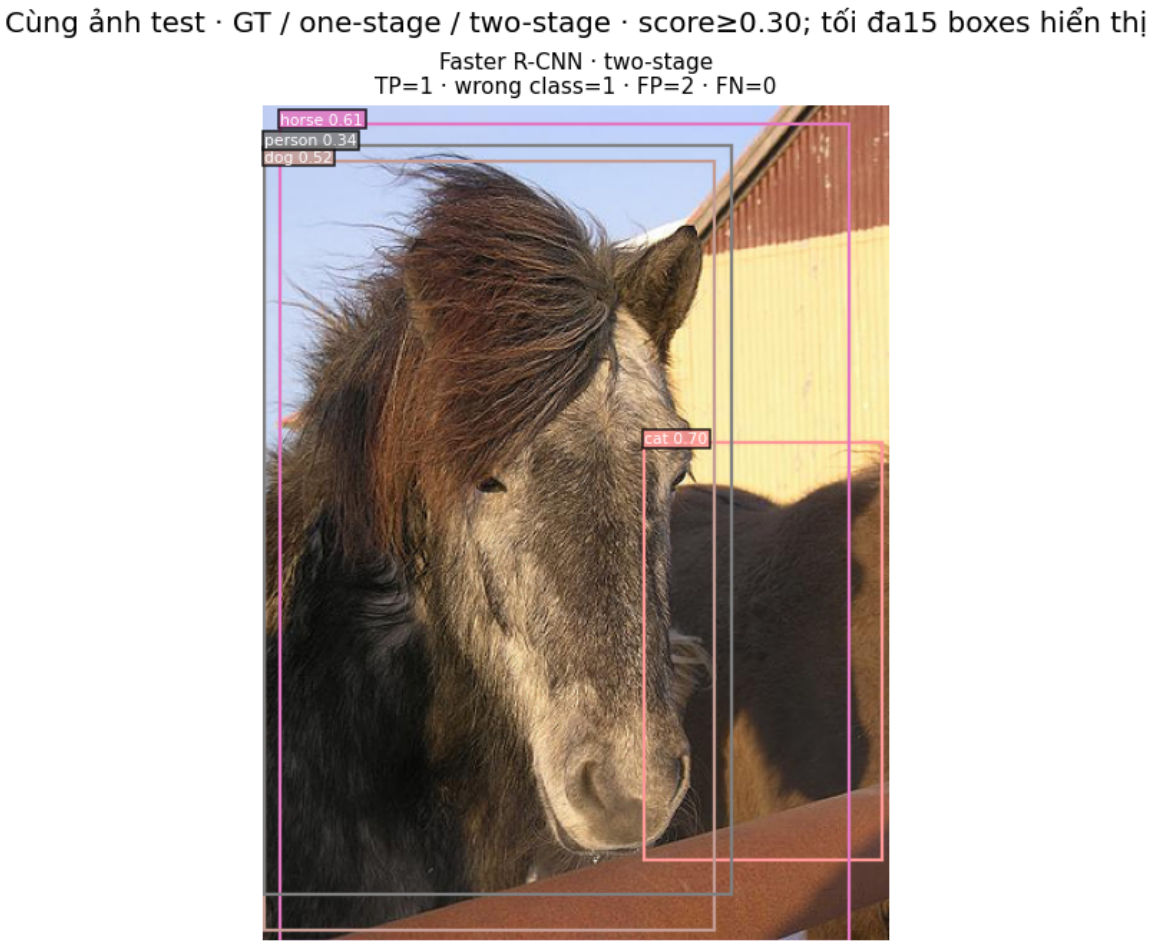

Hình A.62: Ảnh test 2012_2011_003253: Faster R-CNN.

A.9 Trường hợp sai A2

Các ảnh có lỗi được đối chiếu cùng GT; số TP/nhầm lớp/FP/FN trong tiêu đề tính trên mọi detection vượt ngưỡng, còn hình chỉ hiển thị tối đa 15 boxes.

Hình A.63: Trường hợp sai 2012_2008_004581: ground truth.

Hình A.64: Trường hợp sai 2012_2008_004581: RetinaNet.

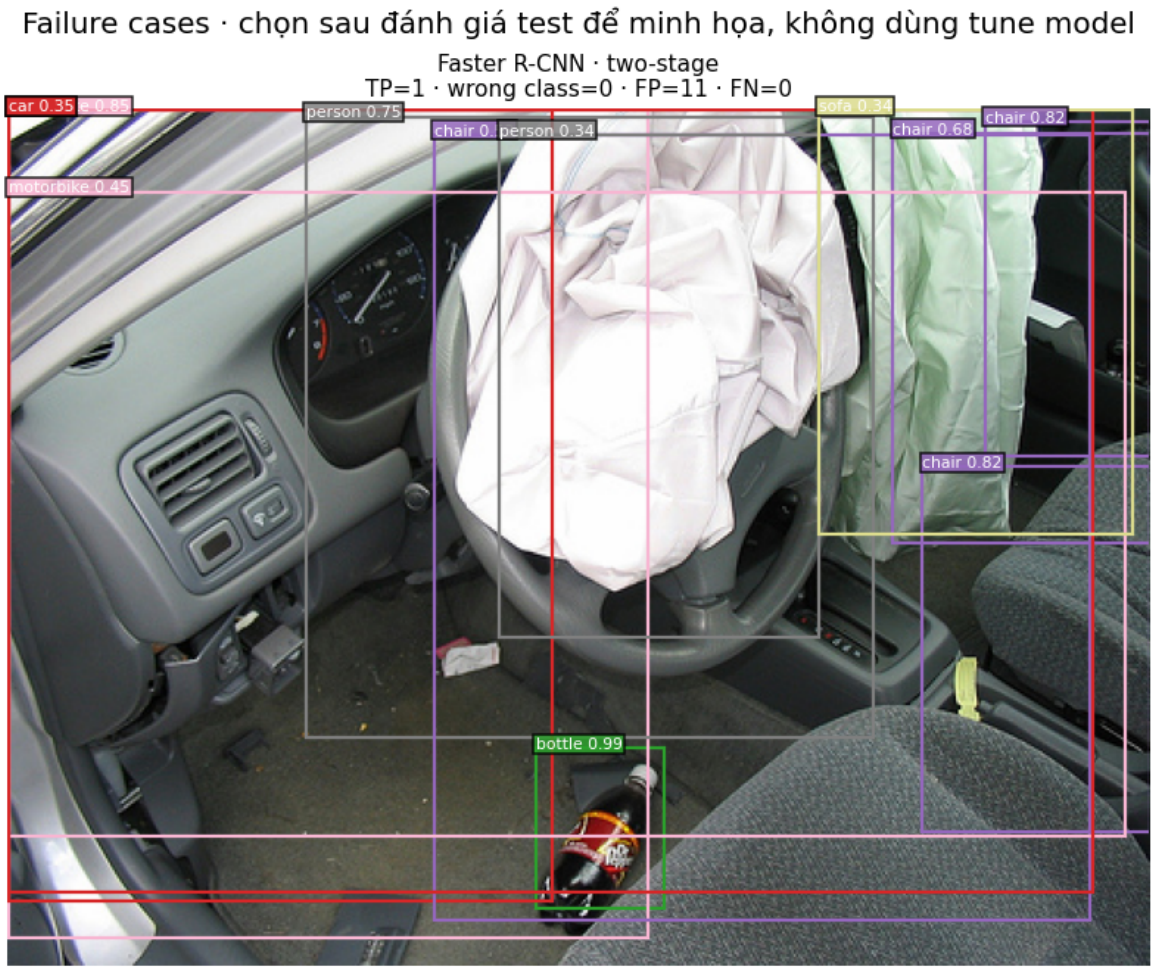

Hình A.65: Trường hợp sai 2012_2008_004581: Faster R-CNN.

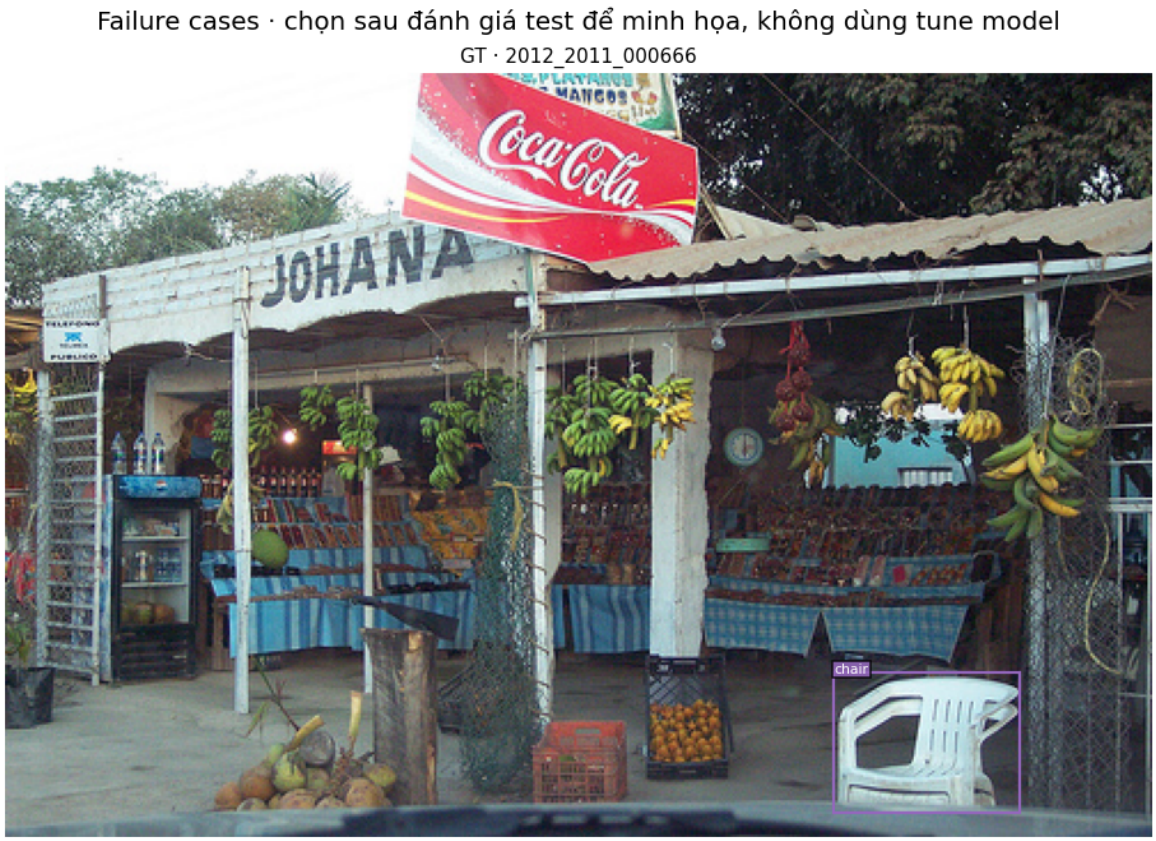

Hình A.66: Trường hợp sai 2012_2011_000666: ground truth.

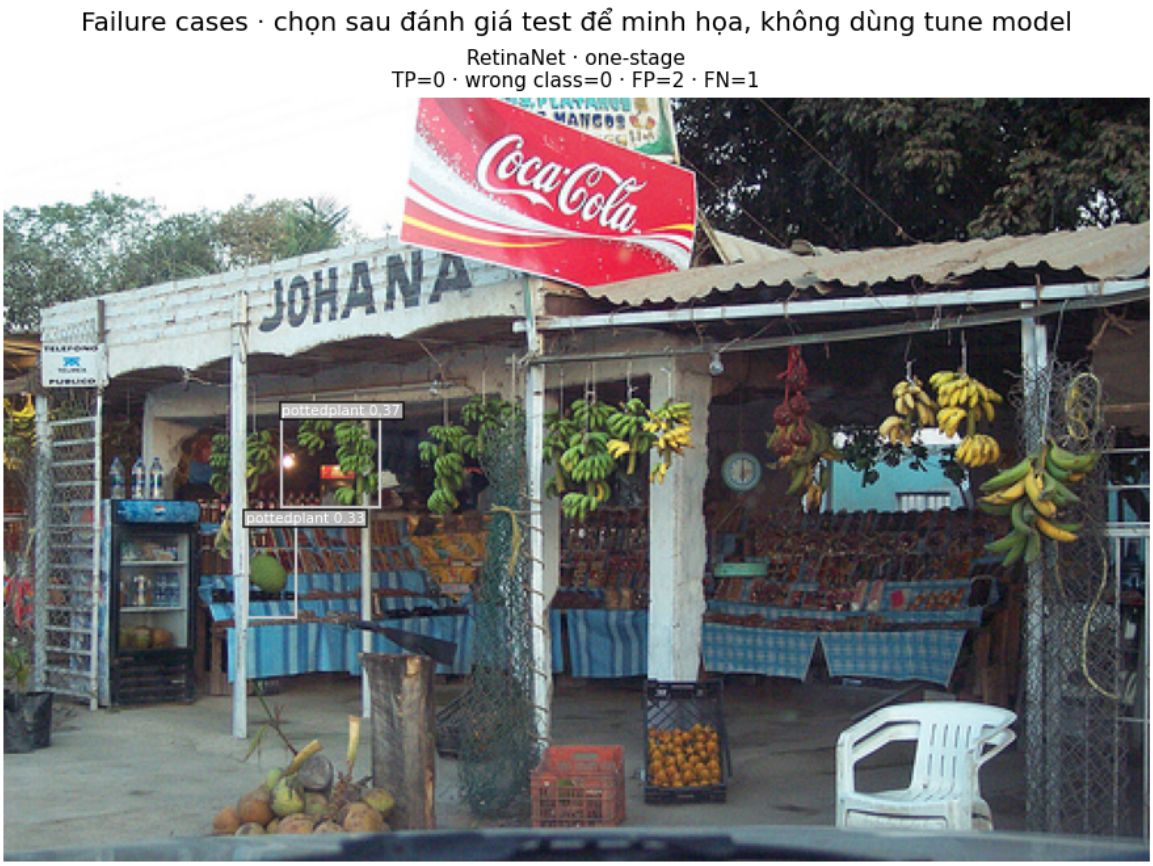

Hình A.67: Trường hợp sai 2012_2011_000666: RetinaNet.

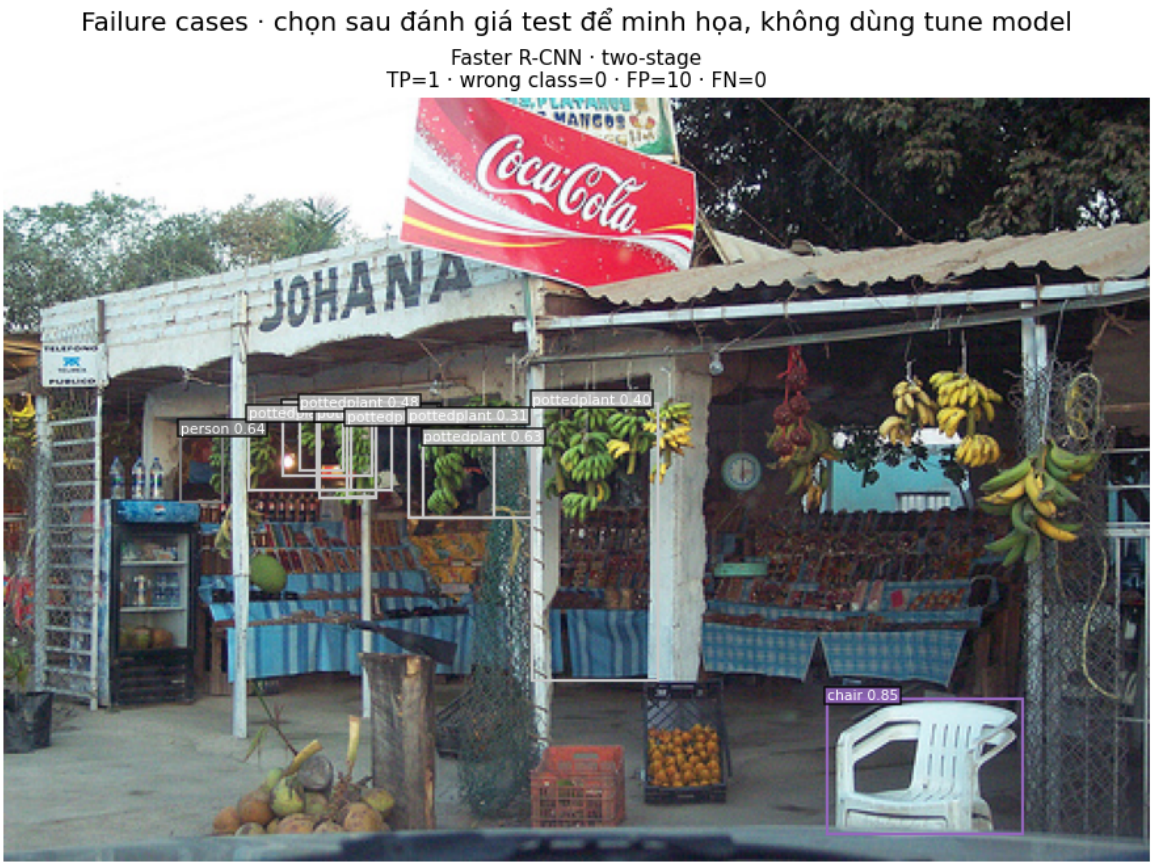

Hình A.68: Trường hợp sai 2012_2011_000666: Faster R-CNN.

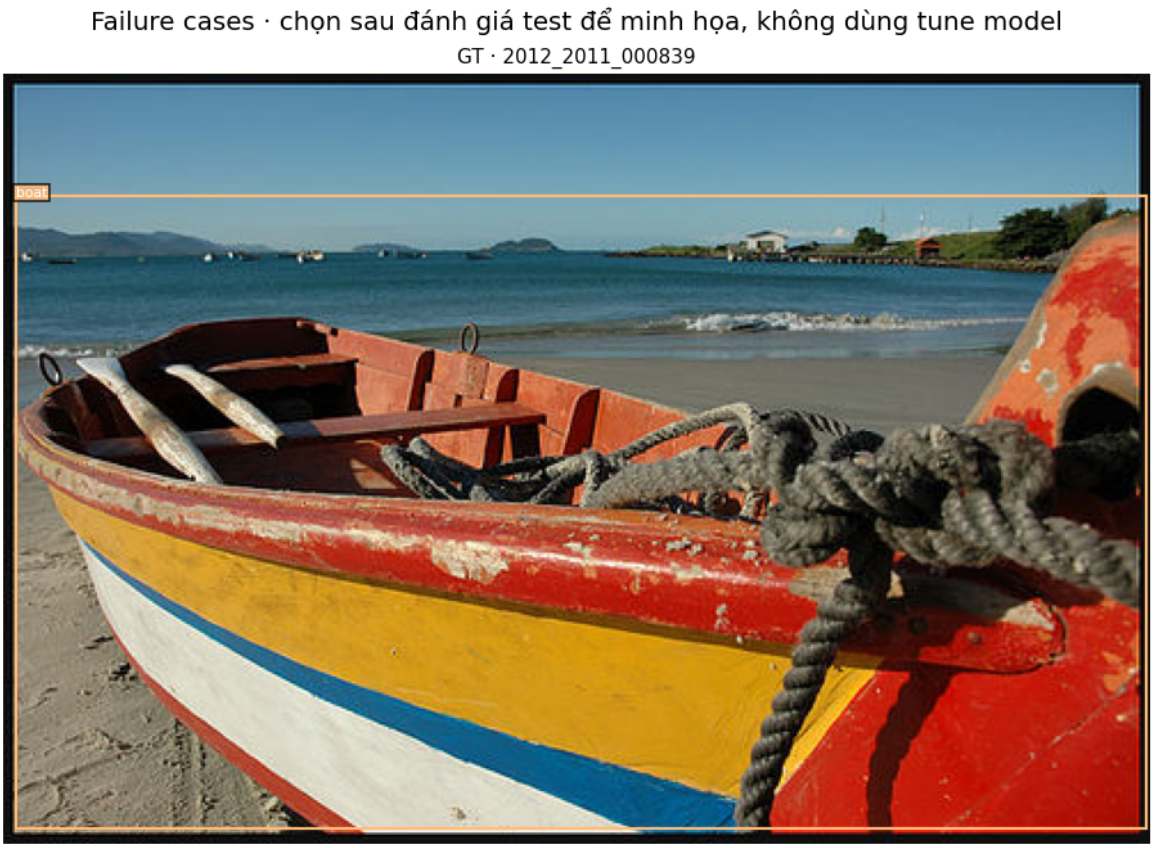

Hình A.69: Trường hợp sai 2012_2011_000839: ground truth.

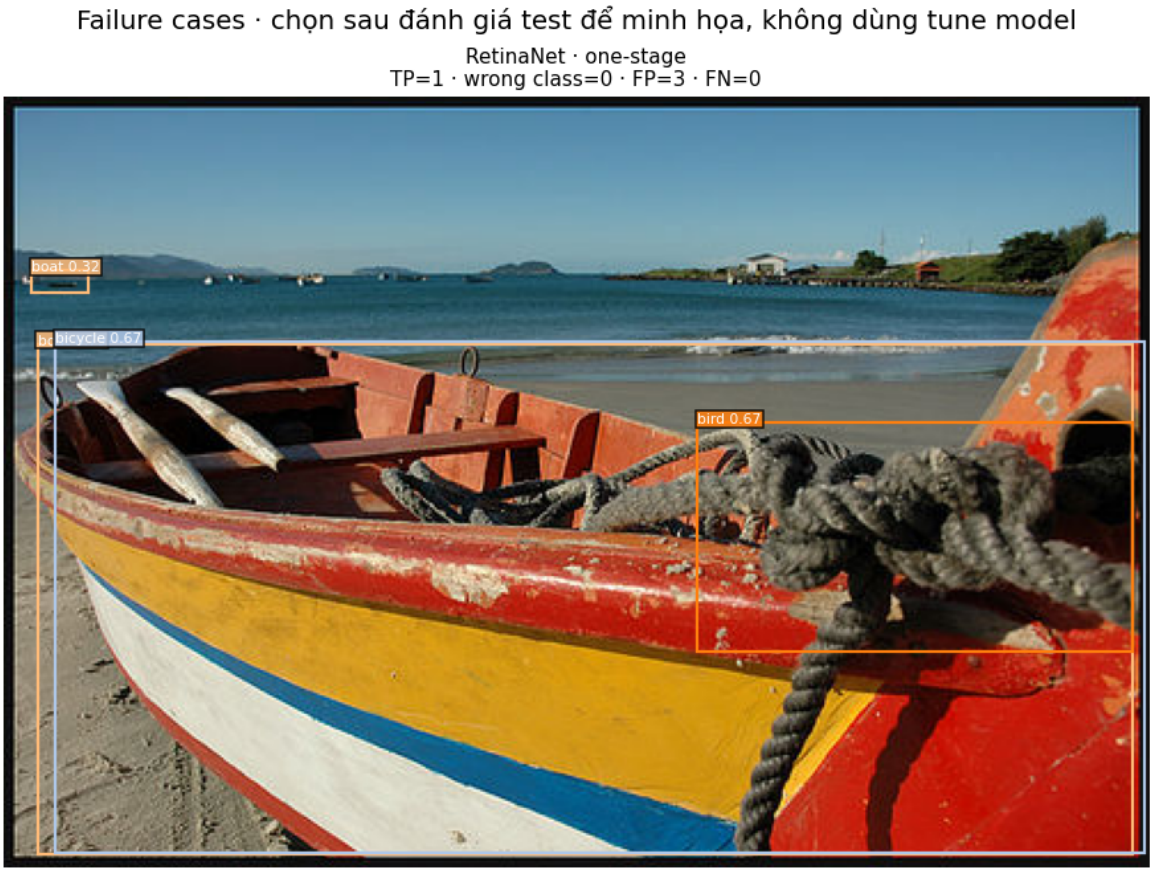

Hình A.70: Trường hợp sai 2012_2011_000839: RetinaNet.

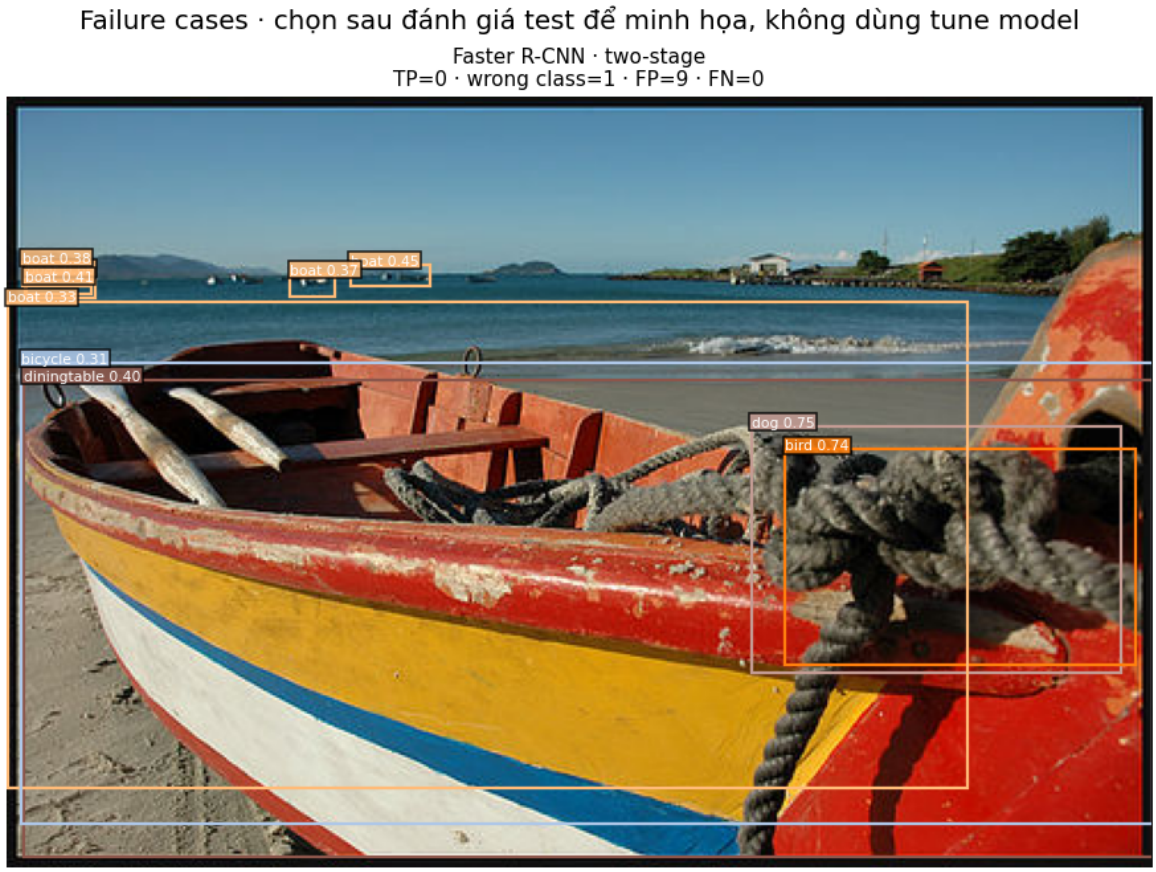

Hình A.71: Trường hợp sai 2012_2011_000839: Faster R-CNN.

A.10 Nguồn số liệu và hướng dẫn tái lập

Nguồn số liệu là output đã lưu của E1.ipynb, E2.ipynb, E3.ipynb, A1.ipynb và A2.kaggle.ipynb trong source_code. Manifest của từng bài dưới assets ghi notebook nguồn, cell/output và bảng Markdown. Các ảnh là output độc lập hoặc được vẽ trực tiếp từ số liệu/dữ liệu gốc, không cắt từ hình ghép. Sơ đồ kiến trúc được vẽ bằng TikZ từ định nghĩa mạng.

E1–E3/A1: chuẩn bị dữ liệu theo README trong datasets, chọn Python 3.14 có CUDA, Restart Kernel và Run All, sau đó Save. Không cần thứ tự giữa các bài. E1–E3 dùng patience 4, min-delta 10^{-4}; A1 dùng patience 2, min-delta 10^{-3}.

A2: mở A2.kaggle.ipynb trên Kaggle, gắn dataset a2-voc2012 đúng đường dẫn trong cell cấu hình và chọn accelerator T4 x2. Bật Internet nếu cần tải ResNet-50 ImageNet hoặc cài thư viện còn thiếu. Run All chạy hai worker train đồng thời rồi test/benchmark lần lượt. Cấu hình code và bảng train là batch 8, accumulation 3, effective batch 24, tối đa 30 epoch, patience 2, min-delta 0,001. Metadata notebook ghi Python 3.13.15; phiên bản PyTorch/torchvision không có trong output đã lưu, nên cần ghi lại môi trường khi tái lập. Notebook xuất thêm PNG/CSV vào /kaggle/working/report/A2, checkpoint/lịch sử dưới /kaggle/working/model/A2; lưu notebook có output và tải các sản phẩm này khi kết thúc phiên Kaggle.

Để chạy từ khởi tạo, dùng CHECKPOINT_ROOT trống. Nếu có latest.pt, notebook tiếp

tục train từ weights đó với optimizer và bộ đếm mới. Seed cố định không đảm bảo tái lập bitwise qua GPU, phiên bản thư viện hoặc đường thực thi AMP. A2.ipynb là notebook chạy local; các số liệu A2 trong báo cáo lấy riêng từ A2.kaggle.ipynb và điều kiện đo ở Chương 6.

Báo cáo biên dịch bằng XeLaTeX và BibTeX từ report/source_latex/main.tex; TikZ định nghĩa trong architectures.tex, ảnh kết quả nằm ở assets. PDF chung giữ tại report/CO5085_Report.pdf.